

Università Ca' Foscari Venezia

Dipartimento di Economia

LAUREA MAGISTRALE IN
ECONOMIA E FINANZA

Econometria

Dispensa del corso

Appunti di:

Silvio Angelo Baratto Roldan

Contenuto:

7 capitoli · 337 slide di riferimento

Anno Accademico:

2026/2027

Appunti rielaborati dal materiale didattico ufficiale del corso. Documento a uso personale di studio.

Indice

1	Econometria — Introduzione al corso	1
2	Econometria — Il Modello di Regressione Semplice	11
3	Il modello di regressione multipla	28
4	Test F per le restrizioni multiple	46
5	L'ipotesi di Eteroschedasticità	54
6	Introduzione ai Modelli Dinamici	66
7	Econometria — Introduzione alla Cointegrazione	102

1 | Econometria — Introduzione al corso

Fonte: ECON_Teoria_01_Introduzione-al-corso.pdf — 32 slide

1.1. Informazioni generali sul corso

Docente: Davide Raggi. Lezione del 11 novembre 2025.

Syllabus (sintesi) - Elementi fondamentali dell'analisi di regressione con dati cross section: - il modello di regressione semplice con un regressore; - sistemi d'ipotesi ed intervalli di confidenza; - il modello di regressione multipla; - omoschedasticità ed eteroschedasticità. - Regressioni con serie storiche: - modelli dinamici; - dati stazionari e non stazionari; - modelli autoregressivi ed a media mobile; - regressioni spurie e test di stazionarietà; - cointegrazione (approccio di Engle-Granger). - Applicazioni con il software GRETL.

Altre informazioni - Esercitazioni: Marco Bidoia. - Materiale didattico: pagina Moodle del corso “Econometria”, anno 2025/2026 (<https://moodle.unive.it/course/view.php?id=22785>). - Metodi didattici: lezioni in presenza e materiale supplementare (materiali e ricevimenti aggiuntivi dedicati agli studenti aventi diritto, nella sezione Moodle “Accessibilità e Supporto allo studio”). - Software: Gretl (<https://gretl.sourceforge.net/>).

Libro di testo - *Principi di econometria*, 2013, C. Hill, W. E. Griffiths e G. C. Lim, Ed. Zanichelli. - Modelli di regressione: capitoli 2–8. - Serie storiche: capitoli 9, 10 e 12. (slide 1–4)

1.2. Cos'è l'econometria?

Definizione 1.1. Non esiste una definizione unica di econometria. Secondo il docente, si può definire come **un insieme di tecniche statistiche che hanno lo scopo di:** - definire e misurare relazioni causali tra variabili economiche; - validare la credibilità di modelli economici teorici; - fare previsioni.

(slide 5)

1.3. Causalità: definizione e criteri

Definizione 1.2. Un legame causale tra due variabili X e Y , indicato $X \rightarrow Y$, specifica che X è una variabile esplicativa che ha impatto su Y : questa dipendenza non è simmetrica, cioè Y non causa X .

Si può parlare di **causalità** se i seguenti tre criteri valgono **contemporaneamente**: 1. **Associazione tra le variabili**. 2. **Un ordine logico/temporale**: la causa precede l'effetto (prima si implementa una politica, poi se ne misura l'impatto). Alcune variabili non possono essere conseguenza di una decisione (ad esempio il sesso, la razza, l'età) e per questo possono essere considerate cause. In altri casi non è facile capire quale sia la causa e quale l'effetto: ad esempio, nei periodi di alta disoccupazione i tassi di criminalità sembrano aumentare. La disoccupazione è una causa? Forse, ma potrebbe esserci **causalità inversa**: in aree ad alta criminalità le imprese potrebbero chiudere, aumentando la disoccupazione. 3. **L'esclusione di spiegazioni alternative**.

(slide 6)

1.4. Esempio: consumo di caffè e probabilità d'infarto

Esempio 1.1. Alcuni studi epidemiologici hanno evidenziato un'associazione positiva tra la probabilità di avere un infarto (variabile Y) e il consumo di caffè (variabile X). - Un possibile link causale: bere caffè aumenta la pressione sanguigna, che rappresenta un fattore di rischio per questa patologia.

Altri studi hanno mostrato che, una volta controllato per altri fattori (tipo di lavoro, residenza, genere, reddito, livello di stress), l'associazione condizionata si riduce a zero. - Questo fornisce una spiegazione alternativa: persone con lavori più stressanti bevono più caffè. È il lavoro stressante il fattore determinante per la probabilità di avere un infarto, e non il caffè.

In pratica, in questo esempio (non supportato da analisi empiriche reali) esiste una variabile Z , lo stress, che ha un impatto congiunto su X e Y . La relazione tra X e Y viene detta **spuria**, ed è indotta da Z : in questo caso la relazione spuria è indotta da una variabile omessa nello studio.

(slide 7-8)

1.5. Esempio: boy scout e criminalità

Esempio 1.2. Si vuole investigare la relazione tra l'essere stati boy scout (S) e la criminalità giovanile (D), nel senso che ci si aspetta che aver frequentato i boy scout riduca la probabilità di commettere crimini.

Alcune evidenze empiriche (dati non reali) sono sintetizzate nella tabella seguente:

Tabella 1 — Essere boy scout e crimine

Boy scout	Delinquency: Yes	Delinquency: No	Total
Yes	36 (9%)	364 (91%)	400
No	60 (15%)	340 (85%)	400

L'evidenza empirica suggerisce una relazione negativa tra S e D . Dal punto di vista logico questo legame sembra sensato, per cui $S \rightarrow D$. Tuttavia non possiamo escludere che un criminale possa aver evitato ambienti “virtuosi”, per cui anche la relazione inversa ha senso logico: $D \rightarrow S$.
- Entrambe le spiegazioni sono ragionevoli. - L'ordinamento logico non è chiaro, quindi non possiamo parlare di causalità.

(slide 9–10)

1.6. Causalità: l'impossibilità di dimostrarla e il ruolo della confutazione

In generale **non è possibile dimostrare l'esistenza di una relazione causale**, perché quasi mai è possibile escludere tutte le altre possibili spiegazioni di un fenomeno. Spesso non siamo in grado di controllare per tutte le possibili spiegazioni alternative (sono troppe) rispetto a un certo livello di associazione misurato.

Possiamo però **confutare** ipotesi di causalità: se riusciamo a confutare tutte le ipotesi tranne una, possiamo essere abbastanza certi nel definire il legame come nesso causale. (slide 11)

1.7. Esempio: fumo e cancro ai polmoni

Esempio 1.3. L'associazione tra fumo e probabilità di tumore è ampiamente documentata. È sintomo di legame causale? - Esiste una ricca letteratura epidemiologica che documenta la relazione tra le due variabili. - Esiste un legame logico sensato (il cancro si manifesta di solito dopo un consumo intensivo di sigarette). - Non sono state trovate, nella letteratura epidemiologica, spiegazioni alternative più convincenti. Esistono inoltre evidenze teoriche che spiegano il legame tra fumo e malattia.

A differenza dei casi precedenti (caffè, boy scout), questo esempio soddisfa tutti e tre i criteri di causalità: associazione, ordine logico/temporale, esclusione di spiegazioni alternative.

(slide 12)

1.8. Associazione non implica causalità

In generale, l'associazione tra variabili **non** rappresenta un criterio sufficiente per stabilire se un legame sia interpretabile come causale. Una raccolta (a scopo illustrativo) di associazioni spurie “divertenti” è disponibile su <http://www.tylervigen.com/spurious-correlations>.

Non è difficile trovare variabili fortemente associate ma non legate tra loro: come visto sopra, l'associazione in questi casi rappresenta un **legame spurio**.

Una volta osservato un legame statistico, risulta indispensabile spiegarlo dal punto di vista teorico e verificare se risulti anche credibile dal punto di vista logico. (slide 13)

1.9. Tipi di dato

Definizione 1.3.

- **Cross Section:** tipo di dati che fanno riferimento a osservazioni raccolte in un unico istante temporale su molti soggetti (individui, Paesi, imprese). Esempio: il database STAR, che raccoglie osservazioni su scuole, bambini e alcune loro caratteristiche.
- **Serie storiche:** sequenze di osservazioni misurate sequenzialmente, spesso a intervalli regolari; il tempo definisce un ordine. Esempi: i prezzi di chiusura di un particolare asset finanziario, o il volume d'acqua orario di un fiume.
- **Dati Panel** (o longitudinali): fanno riferimento a cross section sui medesimi individui, osservate nel tempo. Ogni osservazione è caratterizzata da una doppia dimensione, tempo e soggetto. Esempio: l'evoluzione dei prezzi di un campione di case in un intervallo temporale limitato.

(slide 14)

1.10. Esempio Cross Section: dimensione della classe e punteggio ai test

Esempio 1.4. Il problema. Si pensa spesso che un basso rapporto studenti/insegnanti (*class size*) possa migliorare la performance degli alunni. In California, verso la fine degli anni '90, tutte le classi K-3 furono ridotte per ottenere un rapporto studenti/insegnanti pari a 20 (*Class Size Reduction Act* – CSR), con un costo iniziale di \$1.8 miliardi annui. Per questo costo, ne vale davvero la pena?

Ci si chiede se la dimensione della classe sia l'unico (o il principale) fattore rilevante nello spiegare la variazione della performance attesa degli studenti, oppure se esistano ulteriori informazioni rilevanti da considerare. Si vuole inoltre **quantificare** come una riduzione della dimensione della classe impatti sui voti degli alunni.




Figura 1 — Scatterplot delle variabili rilevanti (Fonte: *California Standardized Testing and Reporting Survey*, year 1999). Lo scatterplot mette in relazione l'*Average Class Size* (*str*, asse orizzontale) con l'*Average Score* (*avg_score*, asse verticale); la retta interpolante (*fitted values*) ha pendenza negativa, suggerendo che classi più numerose sono associate a punteggi mediamente più bassi.

Sembrerebbe quindi che ridurre il rapporto studenti/insegnanti sia rilevante: a una riduzione della dimensione delle classi corrisponde un aumento medio dei punteggi. La correlazione tra le due variabili è **-0.2264** (rappresenta la pendenza della retta di regressione). Esiste inoltre un legame temporale e logico plausibile: prima viene implementata la policy, poi si valutano i benefici.

Un'altra possibile spiegazione. Un'analisi più dettagliata suggerisce che anche il reddito medio (*avginc*) delle persone che vivono in ogni distretto scolastico risulta positivamente correlato con il punteggio *avg_score*: distretti più ricchi tendono ad essere associati a voti migliori. Inoltre esiste una dipendenza negativa tra *income* e *class size* (*str*), suggerendo che distretti ad alto reddito sono legati a scuole in cui le classi sono mediamente più piccole.

Matrice di correlazione (comando `correlate avg_score str avginc`):

	avg_score	str	avginc
avg_score	1.0000		
str	-0.2264	1.0000	
avginc	0.7124	-0.2322	1.0000

Sulla base di questi risultati, ci si chiede se sia il **reddito** la variabile rilevante per spiegare la performance, e non la dimensione della classe.




Figura 2 — Scatterplot delle variabili a coppie. La matrice di scatterplot incrocia *avg_score*, *str* e *avginc* a due a due, confermando visivamente le correlazioni riportate nella matrice sopra (in particolare la forte associazione positiva tra *avg_score* e *avginc*).




Figura 3 — Rappresentazione causale del nuovo modello (in parentesi le correlazioni): $income \rightarrow average\ score$ (0.7124), $income \rightarrow class\ size$ (-0.2322), $class\ size \rightarrow average\ score$ (-0.2264). Il diagramma mostra uno schema in cui il reddito (*income*) influisce sia sul punteggio medio sia sulla dimensione delle classi, potendo così generare una correlazione osservata (ma potenzialmente spuria) tra *class size* e *average score*.

Questa evidenza empirica suggerisce che la dipendenza negativa tra *class size* e *performance* potrebbe essere **spuria**, poiché potrebbe essere spiegata dall'effetto reddito. Questa relazione causale più complessa potrebbe rappresentare una nuova spiegazione del fenomeno e fornire strumenti per una migliore comprensione della realtà.

Verifica: controllo per il reddito. Cosa si può fare? Si divide il dataset in due parti: da un lato i distretti ad alto reddito, dall'altro quelli a basso reddito. In questi due sottoinsiemi si calcola la correlazione tra *class size* e *test score*. In questo modo è possibile controllare l'effetto reddito, poiché ogni sottoinsieme risulta omogeneo rispetto a quel fattore: quindi l'effetto reddito dovrebbe non essere più rilevante. - Nei distretti a **basso reddito**, la correlazione tra *class size* e *test score* è **-0.1464**, debolmente statisticamente significativa. - Nei distretti ad **alto reddito** la correlazione è **-0.1962**, comunque non significativa.

Quindi, una volta controllato l'effetto reddito, la correlazione tra la variabile di policy *class size* e *test score* viene praticamente azzerata. Questo rappresenta, con buona probabilità, il sintomo di una relazione **spuria**.

(slide 15–22)

1.11. Serie storiche: il modello CAPM

Teorema 1.1. In ambito finanziario si ipotizza spesso che gli investitori abbiano bisogno di incentivi per aumentare il rischio che sono disposti ad accollarsi: i rendimenti attesi R di un investimento rischioso dovrebbero essere maggiori di quelli di un investimento non rischioso (*risk-free*, R_f). Gli extra rendimenti $R - R_f \geq 0$ dovrebbero quindi essere positivi.

Il rischio viene spesso descritto tramite la varianza; può essere minimizzato costruendo portafogli diversificati, comprando o vendendo asset i cui prezzi sono correlati alle variazioni di

mercato. Misurare il rischio, quindi, non implica solo il calcolo delle varianze, ma anche della struttura di covarianza tra l'investimento e il mercato.

Il modello **CAPM** (*Capital Asset Pricing Model*) è stato proposto per descrivere la relazione tra i rendimenti di un portafoglio generico e il *portafoglio di mercato*. Gli investitori decidono come allocare le proprie risorse massimizzando il rendimento atteso di un portafoglio, mantenendo fissato il livello di rischio.

In equilibrio si dimostra che deve valere:

$$\underbrace{E[R_t]}_{\text{Rendimenti attesi}} = \beta \underbrace{E[(R_{mt})]}_{\text{Rendimento del mercato}}$$

Ci si chiede se questa relazione teorica sia credibile dal punto di vista empirico.

Si ipotizzi di descrivere la relazione come segue:

$$E[R_t] = \alpha + \beta R_{mt}$$

La variabilità di R_t può essere descritta aggiungendo una componente di *noise* ϵ_t , che descrive l'impatto di notizie improvvise, con media 0 e varianza σ^2 . Quindi:

$$R_t = \alpha + \beta R_{mt} + \epsilon_t$$

dove: - R_t sono i rendimenti di un asset all'istante t ; - R_{mt} rappresenta i rendimenti del mercato a t ; - $\beta = \frac{\text{Cov}(R_t, R_{mt})}{\text{Var}(R_{mt})}$; - ϵ_t è una componente non prevedibile che rappresenta uno shock finanziario; - α è un'intercetta (costante).

(slide 23–25)

1.12. Serie storiche: verifica empirica del CAPM

Esempio 1.5.




Figura 4 — Serie storiche dei rendimenti del portafoglio (*Portfolio*) e del mercato (*Market*) nel tempo, da gennaio 1960 a inizio anni 2000. I due andamenti mostrano un forte comovimento: i rendimenti del portafoglio seguono da vicino le oscillazioni dei rendimenti di mercato, con ampiezza leggermente maggiore nei picchi (positivi e negativi).




Figura 5 — Scatterplot di *Portfolio Returns* contro *Market Portfolio*, con retta di regressione interpolante (*fitted values*). La nuvola di punti mostra una chiara relazione lineare positiva, con pendenza superiore a 1, coerente con un β maggiore di uno.

Se il modello CAPM fosse coerente con i dati, ci si aspetta che il parametro α sia 0. Per verificarlo è quindi necessario stimarlo e verificare l'ipotesi che sia nullo. L'analisi di regressione può essere utilizzata a questo scopo. - Una stima credibile per β è **1.083759**, con errore standard **.0404768**. L'intervallo di confidenza al 95% è **[1.004; 1.163]**, che suggerisce che questo

investimento è più rischioso del mercato. Infatti:

$$\text{Var}(R_t) = \beta^2 \text{Var}(R_{mt}) + \sigma^2, \quad \beta > 1$$

- La stima di α è **.2942161**, e l'intervallo di confidenza al 95% è **[-.063; .651]**. Questa evidenza non permette di escludere che 0 possa essere il vero valore per l'intercetta.
- Il rischio idiosincratico è $\sigma = 4.157$.

(slide 26–28)

1.13. Panel data: l'impatto di un inceneritore sul prezzo delle case

Esempio 1.6. Kiel e McClain (1995) hanno studiato l'effetto che la costruzione di un nuovo inceneritore di rifiuti ha avuto sul valore delle case a North Andover, nel Massachusetts. Gli autori originali eseguirono un'analisi econometrica piuttosto complicata; in questo esempio si considera un modello semplificato, anche se la strategia implementata è simile all'originale.

I rumor secondo cui un nuovo inceneritore sarebbe stato costruito a North Andover iniziarono dopo il 1978, anche se la costruzione iniziò solo nel 1981. L'inceneritore sarebbe entrato in funzione subito dopo l'inizio della costruzione, e ha effettivamente iniziato a funzionare nel 1985. Si utilizzano i dati sui prezzi delle case vendute nel 1978 e un altro campione su quelle vendute nel 1981. L'ipotesi è che il prezzo delle case situate vicino all'inceneritore diminuisca maggiormente rispetto a quello delle case più distanti.

Prima evidenza (solo 1981). Alcune evidenze empiriche suggeriscono che nel 1981 le case costruite vicino al nuovo stabilimento costavano circa 30mila dollari in meno rispetto alle altre:

year	Base price	“Near” effect
1981	101,308.0	-30,688.3

Tuttavia, queste evidenze non sono sufficienti per affermare che l'inceneritore abbia causato una perdita sui prezzi delle case: non sappiamo se ci fossero differenze nei prezzi già prima del 1981. Ci si aspetta infatti che un inceneritore non venga costruito in una zona di pregio.

Confronto 1978 vs 1981. Per fare chiarezza su questo punto è necessario conoscere quali erano i prezzi anche prima che cominciassero le voci. Queste evidenze congiunte sono riassunte nella tabella seguente:

year	Base price	“Near” effect
1978	82,517.7	-18,824.4
1981	101,308.0	-30,688.3

Una regola per verificare se il nuovo inceneritore ha ridotto il valore delle abitazioni è calcolare la seguente statistica (uno stimatore **differenza-nelle-differenze**):

$$\hat{\delta} = \left(\overline{price}_{81, near} - \overline{price}_{81, far} \right) - \left(\overline{price}_{78, near} - \overline{price}_{78, far} \right)$$

dove il primo termine tra parentesi è il coefficiente sull'effetto vicinanza (*near effect*) del 1981, e il secondo è quello del 1978.

Calcolo. Come possiamo sapere se la costruzione di un nuovo inceneritore ha ridotto il valore delle case? Possiamo osservare come è cambiato il coefficiente sull'effetto vicinanza tra il 1978 e il 1981. La differenza nel valore medio delle case era molto maggiore nel 1981 rispetto al 1978 (30.688,27 contro 18.824,37), anche come percentuale del valore medio delle case non vicine al sito dell'inceneritore. La differenza tra i due coefficienti sulla vicinanza è:

$$\hat{\delta} = -30,688.3 - (-18,824.4) = -11,863.9$$

$\hat{\delta}$ è statisticamente diverso da 0? Occorre calcolare opportuni errori standard. Per questo, risulta opportuno usare modelli di regressione specifici per l'analisi dei **dati panel**.

(slide 29–32)

2 | Econometria — Il Modello di Regressione Semplice

Fonte: ECON_Teoria_02_Regressione-Semplice.pdf — 57 slide

2.1. Introduzione: l'associazione tra variabili quantitative — l'esempio wage vs. education

Il filo conduttore della lezione è un esempio applicato: la relazione tra **salari (wage)** e **livello di istruzione (educ)**. Le domande a cui l'analisi vuole rispondere sono:

- Esiste una relazione positiva tra istruzione e salario?
- Per un dato livello di istruzione, qual è il salario medio che un lavoratore può ottenere?
- Qual è il guadagno atteso se si decide di studiare un anno in più?
- Quanto farebbe guadagnare in più conseguire una laurea magistrale (2 anni di studio in più)?

Questo tipo di informazione è utile per prendere decisioni: ad esempio, un individuo potrebbe decidere di iscriversi a una magistrale se il salario atteso aumenta di almeno 1 euro l'ora.




Figura 1 — Scatterplot di educ vs. wage (526 individui osservati nel 1976). Mostra la relazione grezza tra anni di istruzione e salario orario per un campione di 526 lavoratori; i punti presentano una tendenza crescente ma con forte dispersione attorno ad essa.

Con l'analisi di regressione si cerca un modello che riassuma, **in modo semplice**, come variano le distribuzioni condizionali di una variabile Y al variare di una seconda variabile X . Nell'esempio, la distribuzione condizionale è la distribuzione di probabilità dei salari (Y) per un qualsiasi livello di istruzione (X). Questo modello rappresenta l'ipotesi (ex-ante) sulla relazione causa-

le: si definisce una variabile obiettivo (variabile dipendente) e una variabile causale (regressore, causa scatenante). Il nesso causale ipotizzato è, per costruzione, **unidirezionale** ($X \rightarrow Y$).




Figura 2 — Distribuzione condizionale dei salari per ogni livello di istruzione. Boxplot che mostrano come la distribuzione del salario (mediana, quartili, valori estremi) cambi per ciascun valore di anni di istruzione; sia il livello medio sia la dispersione dei salari tendono a crescere con l'istruzione.

Trovare un modello che si adatti con precisione a **tutte** le distribuzioni condizionali sarebbe troppo complicato. I modelli statistici si concentrano quindi sul descrivere la dinamica di alcuni momenti (caratteristiche) delle distribuzioni condizionali; nel modello di regressione queste caratteristiche sono i valori attesi (medie). L'obiettivo diventa costruire un modello che descriva le **medie condizionali** di Y : ad esempio, qual è il salario atteso per i lavoratori che hanno studiato esattamente 10 anni?




Figura 3 — Scatterplot di educ vs. wage e $E[wage|educ]$ (quadrati rossi). Sovrappone ai dati osservati le medie condizionate stimate per ciascun livello di istruzione, evidenziando un andamento crescente ma non perfettamente lineare delle medie.

Per rispondere a queste domande è conveniente definire un modello che descriva la relazione tra istruzione e salari attesi: **la linea è il modello più semplice che si conosca.**




Figura 4 — Scatterplot di educ vs. wage con $E[\text{wage}|\text{educ}]$ (quadrati rossi) e la linea di regressione. Aggiunge alla figura precedente la retta di regressione stimata (fitted values), mostrando come la retta approssimi in modo semplice l'andamento delle medie condizionate.

Il valore atteso condizionale $E[Y|X = x]$ è la media di Y per un dato livello x di X . La retribuzione media stimata per un dato numero di anni di istruzione è riportata nella tabella seguente:

Tabella 1 — Valori attesi stimati di wage fissato educ

years of educ	$E[\text{wage} \text{educ}]$	years of educ	$E[\text{wage} \text{educ}]$
educ=0	3.53	educ=10	3.83
educ=1	not available	educ=11	4.18
educ=2	3.75	educ=12	5.37
educ=3	2.92	educ=13	5.59
educ=4	3.17	educ=14	6.23
educ=5	2.90	educ=15	6.32
educ=6	3.98	educ=16	8.04
educ=7	4.38	educ=17	11.34
educ=8	5.03	educ=18	10.67
educ=9	3.27	educ=19	not available

(slide 3–10)

2.2. Il modello di regressione semplice

Definizione 2.1. La **funzione di regressione semplice** descrive le medie condizionali $E[Y|X = x]$ attraverso un modello lineare:

$$E[Y|X] = \alpha + \beta X$$

Questa retta è un'**approssimazione** della vera media condizionale (i quadrati rossi delle figure precedenti), poiché in generale non è possibile trovare un modello semplice che corrisponda esattamente a tutte le medie condizionate.

Data questa ipotesi per la media condizionale, ogni osservazione (X_i, Y_i) nel campione può essere rappresentata come

$$Y_i = E[Y|X = X_i] + \epsilon_i$$

dove ϵ_i è una quantità stocastica che misura la distanza tra ciascuna osservazione e la retta di regressione.

Terminologia: - Y_i , $i = 1, \dots, n$: variabile dipendente; - X_i , $i = 1, \dots, n$: regressore o predittore; - ϵ_i , $i = 1, \dots, n$: termine di errore.

Intuitivamente ϵ_i è un fattore di rumore che raccoglie gli effetti di tutte le variabili che potrebbero influenzare Y (escluso X) e non sono incluse esplicitamente nel modello. Si assume che l'unico predittore utile per il valore atteso di Y sia il regressore: per questo ci si aspetta che, in media, l'impatto di ϵ non sia rilevante, ovvero formalmente che $E[\epsilon|X] = 0$. Ciò significa che il termine di errore per alcuni soggetti è positivo, per altri negativo, ma in media tutti questi errori si sommano a zero.

Interpretazione causale — effetto di una variazione di X . Ipotizzando che i parametri α e β siano noti, la previsione di Y per un individuo con $X = X_1$ è

$$\hat{Y}(X_1) = \alpha + \beta X_1 + \epsilon(X_1)$$

e per $X = X_2$:

$$\hat{Y}(X_2) = \alpha + \beta X_2 + \epsilon(X_2)$$

dove $\epsilon(X_1)$ ed $\epsilon(X_2)$ rappresentano le caratteristiche non osservate di soggetti con istruzione rispettivamente X_1 o X_2 anni. La variazione di Y è quindi

$$\underbrace{\hat{Y}(X_2) - \hat{Y}(X_1)}_{\Delta Y} = \beta \underbrace{(X_2 - X_1)}_{\Delta X} + \underbrace{[\epsilon(X_2) - \epsilon(X_1)]}_{\Delta \epsilon}$$

ΔY dipende quindi da una scelta economica (ΔX) e da qualcos'altro ($\Delta \epsilon$), quest'ultimo in generale non misurabile. Se si assume che ϵ non dipenda da X , diversi livelli di X non porteranno a variazioni di ϵ , cioè $\Delta \epsilon = 0$. Pertanto la variazione di Y è proporzionale alla variazione di X , con coefficiente di proporzionalità β :

$$\Delta Y = \beta \Delta X$$

Inoltre, sapendo che $\text{Cov}(X, \epsilon) = 0$, si può dimostrare che $E[\epsilon|X] = 0$ e, di conseguenza, che $\hat{Y}(X) \approx E[Y|X]$. Questa ipotesi stabilisce che l'unica spiegazione delle variazioni di Y è fornita da X : ipotizzando che ϵ e X non siano correlati, il risultato di una scelta dipende unicamente dalla scelta stessa (ΔX) e non da altri fattori confondenti ($\Delta \epsilon$). Questa ipotesi è nota come **esogeneità**, ed è un ingrediente cruciale nello studio di relazioni causali.

Esempio numerico. Si consideri il modello che lega salario e istruzione con $\alpha = -1$ e $\beta = 0.5$:

$$wage_i = \alpha + \beta educ_i + \epsilon_i = -1 + 0.5 educ_i + \epsilon_i$$

Assumendo che altre caratteristiche (genere, esperienza, tenure, ecc.), riassunte in ϵ_i , non siano rilevanti, un anno di scuola in più ($\Delta educ = 1$) induce una variazione della retribuzione oraria prevista di 0.50 dollari; due anni in più inducono una variazione dello stipendio atteso di 1 dollaro.

(slide 11–16)

2.3. Stima del modello: il metodo dei minimi quadrati ordinari (OLS)

Definizione 2.2. Considerati dei dati, è fondamentale poter stimare i parametri α e β del modello di regressione. L'idea di base è trovare valori per α e β che **minimizzino la distanza media** tra ciascuna osservazione e la retta di regressione: questi due parametri identificano in modo univoco la retta.

Il metodo dei **minimi quadrati ordinari (OLS)** suggerisce di minimizzare la varianza del termine di errore, ovvero calcolare

$$\min_{\alpha, \beta} \text{Var}(\epsilon) = \min_{\alpha, \beta} E[\epsilon^2] \approx \min_{\alpha, \beta} \frac{1}{n} \sum_{i=1}^n (Y_i - \alpha - \beta X_i)^2$$

Si può dimostrare facilmente che la pendenza della retta di regressione β è proporzionale alla covarianza tra X e Y :

$$\hat{\beta} = \frac{\frac{1}{n} \sum_{i=1}^n (Y_i - \bar{Y})(X_i - \bar{X})}{\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2} = \frac{\text{Cov}(X, Y)}{\text{Var}(X)}$$

Esempio: wage vs. education. Si consideri il modello $wage_i = \alpha + \beta educ_i + \epsilon_i$. Le stime OLS basate su un campione di 526 osservazioni sono:

Variabile	Coef.	Std. Err.	t	P> t	IC 95% inf.	IC 95% sup.
educ	.5413593	.053248	10.17	0.000	.4367534	.6459651
_cons	-.9048516	.6849678	-1.32	0.187	-2.250472	.4407687

Il modello stimato risulta quindi

$$wage = -.9048 + .5413 educ$$

Studiare un anno in più induce una variazione positiva di circa 54 centesimi nei salari.

Valori predetti e residui. La previsione della media condizionale, o valore predetto, è

$$\hat{Y}_i = \hat{E}[Y_i|X = x_i] = \hat{\alpha} + \hat{\beta}x_i$$

Il termine di errore viene stimato come differenza tra la variabile osservata Y_i e il valore atteso $\hat{Y}_i$; è chiamato **residuo** ed è definito come

$$\hat{\epsilon}_i = Y_i - \hat{\alpha} - \hat{\beta}X_i = Y_i - \hat{Y}_i$$




Figura 5 — Rappresentazione grafica di Y_i come somma di residuo ($\hat{\epsilon}_i$) e valore predetto ($\hat{Y}_i$). Mostra graficamente come ogni osservazione Y_i si scomponga nella somma del valore previsto dalla retta di regressione e del residuo, cioè la distanza verticale tra il punto osservato e la retta.

(slide 17–21)

2.4. Il termine d'errore ϵ : proprietà, omoschedasticità ed eteroschedasticità

Definizione 2.3. Le proprietà della variabile casuale ϵ sono cruciali per derivare le proprietà degli stimatori OLS: interessano i suoi momenti e la relazione tra ϵ ed X .

Per costruzione, ϵ_i è la differenza tra Y_i e la media condizionale $E[Y|X_i]$:

$$\epsilon_i = Y_i - E[Y|X_i] = Y_i - \alpha - \beta X_i$$

ϵ raccoglie tutte le caratteristiche non esplicitamente considerate dal modello e descrive l'eterogeneità presente nei dati: non tutte le persone che hanno studiato 10 anni ricevono la stessa somma di denaro, alcune ricevono uno stipendio superiore alla media condizionata, altre inferiore. Il termine di errore spiega questa variabilità e raccoglie intuitivamente la quantità di informazioni su Y non osservabili che non sono spiegate da X .

Media condizionale $E[\epsilon|X]$. Ipotizzando che $\alpha + \beta X$ sia un'approssimazione credibile di $E[Y|X]$ (cioè $E[Y|X] \approx \alpha + \beta X$), la media condizionale di ϵ deve essere

$$E[\epsilon|X] = E[Y|X] - \alpha - \beta X = 0$$

Come conseguenza principale, $\text{Cov}(\epsilon, X) = 0$: tutte le variabili che contribuiscono alla costruzione di ϵ non possono essere correlate con X . Questo implica

$$\Delta E[Y|X] = \Delta Y = \beta \Delta X + \Delta \epsilon = \beta \Delta X$$

L'intuizione è che l'unica informazione rilevante per descrivere la media condizionale di Y è fornita da X ; tutte le altre variabili non possono avere un impatto sistematico su di essa.

Varianza condizionale $\text{Var}(\epsilon|X)$. In generale spesso non si sa come descrivere la varianza condizionale di ϵ . Si noti però che la variabilità di ϵ descrive anche la variabilità della variabile dipendente Y :

$$\text{Var}(\epsilon|X) = \text{Var}(Y|X)$$

Si possono formulare due ipotesi alternative sulle varianze condizionali:

- **Omoschedasticità:** $\text{Var}(\epsilon|X) = \sigma^2$, cioè non dipende da X .
- **Eteroschedasticità:** $\text{Var}(\epsilon|X) = \sigma^2(X)$, quindi è funzione di X .

Differenti ipotesi su $\text{Var}(\epsilon|X)$ portano a diversi stimatori OLS.




Figura 6 — Retta di regressione $E(Y|X = x)$ ed errori omoschedastici. Lo scatterplot mostra che, a diversi valori di X , la dispersione di Y attorno alla retta rimane simile (livelli simili di variabilità condizionale).




Figura 7 — Retta di regressione $E(Y|X = x)$ ed errori eteroschedastici. Lo scatterplot mostra che a diversi valori di X corrispondono diverse ampiezze della variabilità di Y attorno alla retta, cioè diverse $\text{Var}(Y|X)$.

(slide 22–27)

2.5. Le ipotesi del modello di regressione OLS

Definizione 2.4. Sembra cruciale, ai fini pratici, verificare se la strategia OLS fornisce stime affidabili dei parametri di interesse: il coefficiente β misura l'impatto di una politica (valutata come ΔX) sulla variabile dipendente. Per valutare queste proprietà occorre definire formalmente le ipotesi sul modello di regressione:

1. Il vero modello (la retta nella popolazione) è lineare: $E[Y|X] = \alpha + \beta X$;
2. Il modello statistico (approssimato) coincide con quello vero, ovvero $Y = \alpha + \beta X + \epsilon$.
Come conseguenza principale, $\text{Cov}(X, \epsilon) = 0$;

3. Le coppie (X_i, Y_i) , $i = 1, \dots, n$ sono **I.I.D.**;
4. I momenti quarti di X e Y esistono e sono finiti;
5. Si suppone, ad esempio, che $\text{var}[\epsilon|X] = \sigma^2$ (**Omoschedasticità**).

Nota: ipotesi OLS equivalenti. L'ipotesi OLS può essere formulata in modo diverso ma equivalente. Finora si è ipotizzato che il modello empirico (quello valutato attraverso un dataset) sia $Y = \alpha + \beta X + \epsilon$, e che la media condizionale (il vero modello) sia $E[Y|X] = \alpha + \beta X$. Nell'ipotesi che il modello empirico coincida con quello vero, $\epsilon \equiv Y - E[Y|X]$, quindi

$$E[\epsilon|X] = 0 \Rightarrow \text{Cov}(X, \epsilon) = 0$$

Un modo alternativo ed equivalente di definire l'ipotesi:

- si considera che il modello empirico sia lineare, $Y = \alpha + \beta X + \epsilon$;
- si suppone inoltre che $E[\epsilon|X] = 0$;
- quindi $E[Y|X] = \alpha + \beta X$ corrisponde al vero modello.

Le ipotesi alternative ma equivalenti per il metodo OLS si possono quindi riassumere come:

- Il regressore X è **esogeno**, ovvero la media condizionale di $\epsilon|X$ è zero ($E[\epsilon|X] = 0$); conseguenza principale: $E[Y|X] = \alpha + \beta X$;
- Le coppie (X_i, Y_i) , $i = 1, \dots, n$ sono I.I.D.;
- I momenti quarti di X e Y esistono e sono finiti;
- Si suppone che $\text{var}[\epsilon|X] = \sigma^2$ (Omoschedasticità).

Nota: sull'esogeneità. Si supponga che il regressore non sia esogeno, cioè sia **endogeno**, quindi $\text{Cov}(X, \epsilon) \neq 0$. Considerando la variazione attesa di Y

$$\underbrace{\hat{Y}(X_2) - \hat{Y}(X_1)}_{\Delta Y} = \alpha + \beta X_2 + \epsilon(X_2) - [\alpha + \beta X_1 + \epsilon(X_1)] = \beta \underbrace{(X_2 - X_1)}_{\Delta X} + \underbrace{[\epsilon(X_2) - \epsilon(X_1)]}_{\Delta \epsilon}$$

Poiché $\text{Cov}(X, \epsilon) \neq 0$, ragionevolmente ci si aspetta che $E[\Delta \epsilon|X]$, misurato come $\epsilon(X_2) - \epsilon(X_1)$, sia diverso da zero. In questo caso

$$\Delta Y = \beta \Delta X + \Delta \epsilon$$

Le variazioni attese di Y non dipendono solo da β ma anche da $\Delta \epsilon$, in generale non calcolabile: quindi β non è più una misura precisa delle implicazioni di ΔX .

Esempio: sull'esogeneità. Si consideri un dataset simulato di dimensione 200 che soddisfa

$$Y_i = 3 + 1.5X_i + \epsilon_i, \quad \text{cov}(X, \epsilon) = 0.6$$

Si stima il modello $Y = \alpha + \beta X + \epsilon$:

Variabile	Coef.	Std. Err.	t	P> t	IC 95% inf.	IC 95% sup.
X	2.129496	.063634	33.46	0.000	2.004008	2.254983
_cons	2.962697	.0635759	46.60	0.000	2.837324	3.08807

Si noti che $\hat{\beta} = 2.129$ è abbastanza diverso da 1.5. Qui $\hat{\beta}$ non è una stima affidabile del parametro di policy β : in questo caso 2.129 è una stima affidabile di $(\beta + \Delta\epsilon)$, che non è ciò che interessa.

(slide 28–33)

2.6. Le proprietà degli stimatori OLS: non distorsione, consistenza e teorema di Gauss-Markov

Teorema 2.1. Domanda guida: OLS è una buona strategia per stimare β e α ?

La funzione di regressione stimata nel campione (**Sample Regression Function - SRF**) va confrontata con la funzione di regressione nella popolazione (**PRF**), il vero modello che descrive i dati. Poiché non si potrà mai conoscere la PRF, non si potrà mai sapere quanto siano vicine SRF e PRF: un altro campione fornirebbe una SRF diversa, più o meno vicina alla PRF. Occorre quindi capire quando la regressione stimata è una buona proxy per l'intera popolazione: in pratica, la SRF è una buona approssimazione nel campione, ma non è detto lo sia per tutta la popolazione.




Figura 8 — Modello reale sulla popolazione $E(Y|X = x)$ (linea tratteggiata) rispetto alla regressione stimata (linea retta). Ci si attende che OLS funzioni correttamente se le due rette sono molto vicine tra loro, cioè se $\hat{\alpha} \approx \alpha$ e $\hat{\beta} \approx \beta$.

Le stime OLS si basano su un set di dati estratti casualmente dalla popolazione: campioni diversi forniscono stime diverse, quindi $\hat{\alpha}$ e $\hat{\beta}$ sono **variabili casuali**. Interessa derivarne media e varianza, e approssimarne le distribuzioni di probabilità per calcolare intervalli di confidenza ed eseguire test statistici.

Rappresentazione di $\hat{\beta}$ in funzione di ϵ . È sempre possibile scrivere $\hat{\beta}$ come

$$\hat{\beta} = \sum_{i=1}^n \underbrace{\left[\frac{(X_i - \bar{X})}{\sum_{i=1}^n (X_i - \bar{X})^2} \right]}_{\omega_i} (Y_i - \bar{Y}) = \sum_{i=1}^n \omega_i \underbrace{Y_i}_{\alpha + \beta \bar{X}_i + \epsilon_i} - \bar{Y} \underbrace{\sum_{i=1}^n \omega_i}_{=0} = \beta + \sum_{i=1}^n \omega_i \epsilon_i \quad (1)$$

Non distorsione (valore atteso di $\hat{\beta}$). Dalla eq. (1):

$$E[\hat{\beta}|X_1, \dots, X_n] = \beta + \sum \omega_i \underbrace{E[\epsilon_i|X_1, \dots, X_n]}_{\text{per hyp. } =0} = \beta$$

I momenti marginali, cioè la media di $\hat{\beta}$ rispetto a tutti i possibili $X_1, \dots, X_n$ osservati, è quindi β : lo stimatore è **non distorto**. Se $E[\epsilon|X_1, \dots, X_n] \neq 0$, questo risultato non è più valido e, in media, lo stimatore non fornisce una buona proxy per il vero coefficiente β .

Varianza condizionale (consistenza). La varianza condizionale di $\hat{\beta}$ è

$$\text{Var}[\hat{\beta}|X_1, \dots, X_n] = \sum \omega_i^2 \underbrace{\text{Var}[\epsilon_i|X_1, \dots, X_n]}_{\times \text{ip. } = \sigma^2} = \frac{\sigma^2}{\sum_{i=1}^n (X_i - \bar{X})^2} = \frac{\sigma^2}{(n-1)} \underbrace{\frac{n-1}{\sum_{i=1}^n (X_i - \bar{X})^2}}_{=1/\sigma^2 \text{ if } n \rightarrow +\infty} \quad (\text{consistency})$$

Per questo risultato si è utilizzata l'ipotesi di omoschedasticità.




Figura 9 — Distribuzioni di $\hat{\beta}$ per campioni di diverse dimensioni ($n_1 < n_2 < n_3$). Mostra come la dispersione della distribuzione campionaria di $\hat{\beta}$ si riduca al crescere della dimensione campionaria, collassando su β quando $n \rightarrow \infty$.




Figura 10 — Distribuzioni di $\hat{\beta}$ per campioni di diverse dimensioni (standardizzate per ottenere una media pari a 0), per $n = 2, 10, 50, 100$. Se $n \rightarrow \infty$, $\hat{\beta} \rightarrow \beta$ (**Legge dei grandi numeri**).

Teorema di Gauss-Markov. Se sono soddisfatte le seguenti ipotesi:

- **Linearità:** il modello nella popolazione è lineare nei parametri, $Y = \alpha + \beta X + \epsilon$;
- **I.I.D.:** campione casuale di (X_i, Y_i) , $i = 1, \dots, N$;
- **Esogenità:** il regressore non è correlato al termine di errore;
- **Omoschedasticità:** $\text{Var}(Y|X = x_i) = \sigma^2$;

allora OLS fornisce il **miglior stimatore lineare non distorto (BLUE)**, il più efficiente (con varianza minore) nella classe degli stimatori lineari e non distorti.

(slide 34-42)

2.7. La distribuzione di β : campioni finiti e normalità asintotica

Teorema 2.2. Distribuzione in campioni finiti. Si può dimostrare che, sotto opportune ipotesi, la distribuzione di $\hat{\beta}$ è gaussiana. In particolare, se l'errore nella popolazione ϵ è indipendente da X ed è normalmente distribuito con media nulla e varianza σ^2 , cioè $\epsilon \sim N(0, \sigma^2)$, allora:

- lo stimatore di β ha distribuzione normale: $\hat{\beta} \sim N(\beta, \text{Var}(\hat{\beta}|X))$;
- lo stimatore standardizzato ha distribuzione Student t :

$$\frac{\hat{\beta} - \beta}{\sqrt{\text{Var}(\hat{\beta}|X)}} \sim t_{n-2}$$

Quest'ultimo risultato dipende dal fatto che il denominatore è ignoto e deve essere stimato. Se $n \rightarrow \infty$, la Student t converge a una gaussiana.

Normalità asintotica. In statistica, per stimare il valore atteso di una popolazione si usa la media campionaria, che si distribuisce come una v.c. gaussiana per campioni sufficientemente grandi. Nell'ipotesi che $E[\epsilon|X] = 0$, $\hat{\beta}$ gode della stessa proprietà, essendo sostanzialmente costruito come una media:

$$\hat{\beta} \sim N(\beta, \hat{\sigma}_{\hat{\beta}}^2)$$

in cui

$$\hat{\sigma}_{\hat{\beta}}^2 = \frac{\hat{\sigma}^2}{\sum_{i=1}^n (X_i - \bar{X})^2}, \quad \hat{\sigma}^2 = \frac{1}{n-2} \sum_{i=1}^n \hat{\epsilon}_i^2$$

Questo risultato consente di effettuare test di ipotesi su β e di costruire intervalli di confidenza.

Perché vale la normalità asintotica — Teorema del limite centrale (CLT). Se una sequenza Z_i è I.I.D. tale che $E[Z_i] = \mu_Z < +\infty$ e $0 < \text{Var}[Z_i] = \sigma_Z^2 < +\infty$, allora

$$\frac{(\bar{Z} - \mu_Z)}{\sigma_{\bar{Z}}} \rightarrow N(0, 1)$$

Il numeratore di $\hat{\beta}$ è la media campionaria di variabili $Z = (X - E[X])(Y - E[Y])$, indipendenti per ipotesi, a cui si può applicare il CLT. Il denominatore converge a una costante, essendo in pratica una media di variabili X^2 (Legge dei Grandi Numeri). Quindi

$$\frac{\hat{\beta} - E[\hat{\beta}]}{\sqrt{\text{Var}(\hat{\beta})}} = \frac{\hat{\beta} - \beta}{\sigma_{\hat{\beta}}} \rightarrow N(0, 1) \Rightarrow \hat{\beta} \sim N(\beta, \sigma_{\hat{\beta}}^2)$$




Figura 11 — Istogramma rispetto alla densità normale: stime standardizzate di β per diversi campioni di dimensione n , rappresentate come istogrammi. Pannello di sinistra: campione di piccole dimensioni ($n = 2$); pannello di destra: campione di grandi dimensioni ($n = 50$, buona approssimazione gaussiana). Il confronto mostra come l'approssimazione normale migliori al crescere della dimensione campionaria.

(slide 43–46)

2.8. Lo stimatore della varianza σ^2 e gli errori standard

Definizione 2.5. In caso di omoschedasticità, il modello di regressione è caratterizzato anche dal parametro σ , che descrive l'eterogeneità dei soggetti che condividono lo stesso livello di X . Uno stimatore non distorto di σ^2 è

$$\hat{\sigma}^2 = \frac{1}{n-2} \sum_{i=1}^n \hat{\epsilon}_i^2$$

Si può dimostrare che $E[\hat{\sigma}^2] = \sigma^2$.

Gli errori standard per $\hat{\alpha}$ e $\hat{\beta}$ si ricavano inserendo $\hat{\sigma}^2$ nella formula di $\text{Var}(\hat{\beta}|X_1, \dots, X_n)$. Quindi, $\sigma_{\hat{\beta}}$ si stima come

$$\hat{\sigma}_{\hat{\beta}} = \sqrt{\frac{\hat{\sigma}^2}{\sum_{i=1}^n (X_i - \bar{X})^2}}$$

Gli errori standard per $\hat{\alpha}$ sono quindi

$$\hat{\sigma}_{\hat{\alpha}} = \sqrt{\frac{\hat{\sigma}^2 \left(\frac{1}{n} \sum_{i=1}^n X_i^2 \right)}{\sum_{i=1}^n (X_i - \bar{X})^2}}$$

(slide 47–48)

2.9. Intervalli di confidenza per β

Definizione 2.6. Per quanto riguarda la media campionaria, è utile fornire un intervallo di possibili valori in cui si ritiene il vero parametro β rientrerà con alta probabilità. Come per la media campionaria, $\hat{\beta}$ è distribuita normalmente, e si vuole ottenere un intervallo che includa il vero parametro sconosciuto β con alta probabilità (diciamo $1 - \alpha$). Valgono quindi tutti i risultati validi per la media campionaria: un intervallo di confidenza per β può essere calcolato come

$$\text{Confidence interval} = \left[\hat{\beta} - z_{\frac{\alpha}{2}} \times \hat{\sigma}_{\hat{\beta}} ; \hat{\beta} + z_{\frac{\alpha}{2}} \times \hat{\sigma}_{\hat{\beta}} \right]$$

Esempio: wage vs. educ. L'intervallo di confidenza al 95% per β è calcolato come

$$[0.541 - 1.96 \times 0.053 ; 0.541 + 1.96 \times 0.053] = [.436 ; .645]$$

Variabile	Coef.	Std. Err.	t	P> t	IC 95% inf.	IC 95% sup.
educ	.5413593	.053248	10.17	0.000	.4367534	.6459651
_cons	-.9048516	.6849678	-1.32	0.187	-2.250472	.4407687

Ci si aspetta quindi che, con probabilità 95%, il vero β sia compreso tra $[\cdot436; \cdot645]$, suggerendo l'esistenza di un'associazione positiva tra wages e years of education.

(slide 49–50)

2.10. Verifica d'ipotesi per β

Definizione 2.7. Ci si potrebbe chiedere se X sia un predittore utile, cioè se abbia un impatto sulla media condizionale di Y . Si ricordi che $\Delta\hat{Y} = \beta\Delta X$: se β fosse 0, non importa quale sia la variazione di X , la variazione attesa di Y prevista dal modello sarebbe nulla. È quindi naturale verificare se β sia abbastanza vicino a 0 oppure no. In generale, si potrebbe voler verificare se l'evidenza empirica riassunta in $\hat{\beta}$ sia coerente con qualche valore specifico, corrispondente a un'ipotesi di natura economica.

Poiché $\hat{\beta}$ è distribuito come una variabile casuale gaussiana, la procedura di test si basa sugli stessi risultati validi per la media campionaria. Un'ipotesi tipica da verificare è $H_0 : \beta = 0$ contro l'alternativa $H_a : \beta \neq 0$. La statistica t è definita come

$$t = \frac{\hat{\beta} - 0}{\hat{\sigma}_{\hat{\beta}}}$$

Il p-value si calcola allo stesso modo del caso della media. In generale, il sistema di ipotesi $H_0 : \beta = \kappa$ contro una delle tre possibili alternative ($>$, $<$ o $\neq$) può essere verificato tramite

$$t = \frac{\hat{\beta} - \kappa}{\hat{\sigma}_{\hat{\beta}}}$$

Esempio: wage vs. educ. Ci si potrebbe chiedere se un anno in più di scuola abbia un effetto positivo sui salari.

Variabile	Coef.	Std. Err.	t	P> t	IC 95% inf.	IC 95% sup.
educ	.5413593	.053248	10.17	0.000	.4367534	.6459651
_cons	-.9048516	.6849678	-1.32	0.187	-2.250472	.4407687

Scritto in linguaggio statistico: $H_0 : \beta = 0$ vs. $H_a : \beta > 0$.

La statistica t osservata è

$$t^{obs} = \frac{.5413593 - 0}{.053248} = 10.17$$

Il p-value $P_{H_0}(t > t^{obs}) \approx 0$, che permette di rifiutare l'ipotesi nulla.

Se si considera invece il sistema d'ipotesi $H_0 : \beta = 0$ vs. $H_a : \beta \neq 0$, la statistica t osservata rimane $t^{obs} = 10.17$ e il p-value viene calcolato come $2 P_{H_0}(t > |t^{obs}|) \approx 0$.

(slide 51-53)

2.11. Misure di bontà di adattamento: l' R^2

Definizione 2.8. Non è stato ancora considerato il problema di misurare come la variabile X approssimi la variabile dipendente Y . Spesso è utile calcolare un indicatore che riassume quanto bene la linea di regressione OLS si adatti ai dati. L'idea è calcolare la correlazione tra la variabile dipendente Y e le previsioni del modello $\hat{Y}$: maggiore è questo numero, migliore è l'adattamento del modello empirico ai dati. L' R^2 è definito come

$$R^2 = \text{Corr}^2(Y, \hat{Y})$$

Per costruzione $0 \leq R^2 \leq 1$:

- Un R^2 vicino a 1 significa che il regressore è un **buon** predittore per il valore atteso condizionale della variabile dipendente.
- Un R^2 vicino a 0 significa che il regressore è un predittore **mediocre**.
- R^2 **non dice nulla riguardo alla causalità!** Indica solamente come, in uno specifico campione, la retta di regressione approssima le medie dei dati osservati.

Esempio 1 — caso endogeno. Si consideri l'esempio precedente in cui X è endogeno ($Y_i = 3 + 1.5X_i + \epsilon_i$, $\text{cov}(X, \epsilon) = 0.6$, $n = 200$):

Source	SS	df	MS
Model	903.491169	1	903.491169
Residual	159.74002	198	.806767779
Total	1063.23119	199	5.3428703

Number of obs = 200; F(1, 198) = 1119.89; Prob > F = 0.0000; R-squared = 0.8498; Adj R-squared = 0.8490; Root MSE = .8982

Variabile	Coef.	Std. Err.	t	P> t	IC 95% inf.	IC 95% sup.
x	2.129496	.063634	33.46	0.000	2.004008	2.254983
_cons	2.962697	.0635759	46.60	0.000	2.837324	3.08807

Si noti che l' R^2 è elevato ($\approx 84.9\%$). Tuttavia si sa già che il modello **non** rappresenta una relazione causale: un R^2 alto non implica causalità.

Esempio 2 — wage vs. educ. Si consideri ora la relazione tra salari e istruzione, che potrebbe rappresentare un legame causale:

Source	SS	df	MS
Model	1179.73204	1	1179.73204
Residual	5980.68225	524	11.4135158
Total	7160.41429	525	13.6388844

Number of obs = 526; F(1, 524) = 103.36; Prob > F = 0.0000; R-squared = 0.1648; Adj R-squared = 0.1632; Root MSE = 3.3784

Variabile	Coef.	Std. Err.	t	P> t	IC 95% inf.	IC 95% sup.
educ	.5413593	.053248	10.17	0.000	.4367534	.6459651
_cons	-.9048516	.6849678	-1.32	0.187	-2.250472	.4407687

Si noti che R^2 è piuttosto basso ($\approx 16.4\%$). Nonostante questo risultato, il collegamento tra le due variabili ha comunque senso da un punto di vista logico: un R^2 basso non esclude una relazione causale plausibile.

(slide 54–57)

3 | Il modello di regressione multipla

Fonte: ECON_Teoria_03_Regressione-Multipla.pdf — 53 slide

3.1. Esempio motivante: test scores e dimensione della classe

Esempio 3.1. Comunemente si pensa che un rapporto studenti-insegnanti più basso induca un rendimento migliore degli studenti. Di conseguenza, ad esempio in California, verso la fine degli anni '90, tutte le classi K-3 sono state ridotte per avere un rapporto massimo studenti-insegnanti di 20 (*Class Size Reduction Act* - CSR). Ciò ha un costo, ovviamente: inizialmente era di 1,8 miliardi di dollari all'anno. Per un costo così alto, sorge spontanea la domanda se ne valga la pena o meno. Il Commissario per l'Istruzione potrebbe essere interessato a sapere se questa spesa extra ha un impatto significativo sul rendimento scolastico atteso.

Ci chiediamo se la dimensione della classe sia l'unica informazione rilevante che ha un impatto nello spiegare la variazione del punteggio medio atteso di questi studenti, o se c'è qualcosa di più da considerare.

Un modello di regressione naïve evidenzia che esiste una dipendenza negativa significativa tra la dimensione media della classe, **str**, e il punteggio medio atteso, **avg_score**:

	Coef.	Std. Err.	t	P> t	[95% Conf.	Interval]
str	-2.279808	.4798256	-4.75	0.000	-3.22298	-1.336637
_cons	698.933	9.467491	73.82	0.000	680.3231	717.5428

Apparentemente sembra che ridurre la dimensione delle classi sia una scelta rilevante, poiché una riduzione della dimensione di una classe induce un aumento del punteggio medio di circa 2,28 punti. Ma questo modello statistico è una relazione causale? Esistono altre spiegazioni più credibili?

Ad un esame più attento, osserviamo che il reddito medio (**avginc**) per le persone che vivono in ciascun distretto è correlato positivamente con **avg_score**: i distretti con reddito più alto tendono ad avere studenti con voti più alti. Esiste anche una dipendenza negativa tra reddito e dimensione della classe (**str**): i distretti a reddito più elevato tendono ad avere classi di dimensioni inferiori. Le correlazioni (comando `correlate avg_score str avginc`) sono:

	avg_score	str	avginc
avg_score	1.0000		
str	-0.2264	1.0000	
avginc	0.7124	-0.2322	1.0000

Ci chiediamo se includere il reddito nel modello di regressione possa essere utile per prevedere il punteggio medio e spiegare la relazione causa-effetto performance vs. riduzione delle classi.




Figura 1 — Scatterplot a coppie delle variabili coinvolte (avg_score, str, avginc). La matrice di scatterplot mostra visivamente le correlazioni della tabella precedente: avg_score cresce al crescere di avginc e decresce (debolmente) al crescere di str; str e avginc sono debolmente correlate negativamente.

Questa evidenza empirica suggerisce che l'associazione negativa tra dimensione della classe e punteggio del test potrebbe essere **spuria**, poiché può essere spiegata dall'effetto del reddito su ciascuna variabile.




Figura 2 — Rappresentazione causale del modello (diagramma con income che punta sia ad average score con correlazione 0.7124 sia a class size con correlazione -0.2322, e una freccia da class size ad average score con correlazione -0.2264). Il diagramma illustra come il reddito (income) sia una causa comune che influenza sia il punteggio medio sia la dimensione

della classe, generando una correlazione osservata tra `class size` e `average score` che non riflette necessariamente un nesso causale diretto.

(slide 3-7)

3.2. Il modello di regressione multipla e l'interpretazione dei parametri

Definizione 3.1. Si ipotizzi esistano due o più variabili esplicative, X_1 ed X_2 ($X_3, \dots, X_k$) potenzialmente utili per descrivere la media condizionale di Y . In questo caso, la funzione di regressione semplice può essere generalizzata da

$$E[Y|X_1, X_2] = \alpha + \beta_1 X_1 + \beta_2 X_2$$

Come per il modello di regressione semplice, ogni osservazione è descritta da

$$Y_i = \alpha + \beta_1 X_{1,i} + \beta_2 X_{2,i} + \epsilon_i$$

Y è la variabile dipendente, X_1 e X_2 sono i regressori mentre ϵ è un termine di errore che misura la distanza tra il modello di regressione e l'osservabile Y .

Interpretazione dei parametri. Nell'ambito della regressione semplice, β_1 misura la variazione attesa di Y a condizione che $\Delta X = 1$. Infatti $\Delta \hat{Y} = \beta_1 \underbrace{\Delta X}_{=1}$.

Nell'impostazione data dalla regressione multipla, il coefficiente β_1 è la variazione attesa di Y dovuta a una variazione unitaria di X_1 a condizione che X_2 sia mantenuto costante. In pratica, se calcoliamo la variazione attesa di Y per un dato livello dei due regressori $X_1 = \bar{X}_1$ e $X_2 = \bar{X}_2$, otteniamo

$$\hat{Y}(\bar{X}_1, \bar{X}_2) = \alpha + \beta_1 \bar{X}_1 + \beta_2 \bar{X}_2 + \epsilon(\bar{X}_1, \bar{X}_2).$$

Supponiamo ora di voler calcolare Y atteso per $X_1 = \bar{X}_1 + \Delta X_1$ e $X_2 = \bar{X}_2$:

$$\hat{Y}(\bar{X}_1 + \Delta X_1, \bar{X}_2) = \alpha + \beta_1 (\bar{X}_1 + \Delta X_1) + \beta_2 \bar{X}_2 + \epsilon(\bar{X}_1 + \Delta X_1, \bar{X}_2).$$

La variazione prevista di Y è la differenza

$$\Delta \hat{Y} = \hat{Y}(\bar{X}_1 + \Delta X_1, \bar{X}_2) - \hat{Y}(\bar{X}_1, \bar{X}_2) = \beta_1 \Delta X_1 + \Delta \epsilon$$

Nell'ipotesi che ϵ non sia rilevante per descrivere il valore atteso di Y , cioè $\Delta \epsilon = 0$, allora una variazione del valore atteso di Y è proporzionale alla variazione di X_1 , cioè

$$\Delta Y = \beta_1 \Delta X_1$$

Nella regressione multipla, un parametro descrive l'effetto di una variabile esplicativa una volta controllati gli effetti dell'altra variabile esplicativa nel modello (imponendo $X_2 = \bar{X}_2$). La regressione semplice ha una sola variabile esplicativa, quindi il parametro descrive l'effetto di una variabile al netto di tutte le altre possibili variabili esplicative. I coefficienti β_j sono chiamati **effetti marginali**.

Esempio: class scores vs. reddito e class size. Consideriamo il modello di regressione multipla che lega il punteggio medio degli studenti, la dimensione della classe e il reddito delle famiglie:

$$\text{avg_score}_i = \alpha + \beta_1 \text{str}_i + \beta_2 \text{avginc}_i + \epsilon_i$$

	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]
str	-.6487401	.354405	-1.83	0.068	-1.345383 .0479028
avginc	1.839112	.0927868	19.82	0.000	1.656724 2.0215
_cons	638.7292	7.449077	85.75	0.000	624.0867 653.3716

Questi risultati suggeriscono che, per un dato livello di reddito, se la dimensione della classe si riduce di un'unità, allora il punteggio medio atteso aumenta di circa 0.65 punti. Questa variazione però risulta debolmente significativa.

(slide 8–11)

3.3. Cause di endogeneità: distorsione da variabile omessa

Teorema 3.1. Nel modello di regressione semplice, abbiamo ipotizzato che $E[\epsilon|X] = 0$ ($\Rightarrow \text{Cov}(\epsilon, X) = 0$).

Supponiamo che la **vera** media condizionale (relazione causale) sia ben approssimata dal seguente modello:

$$\text{Modello 1: } Y = \alpha + \beta_1 X_1 + \beta_2 X_2 + \tilde{\epsilon}$$

Poiché non conosciamo il vero modello, supponiamo di stimare la seguente regressione **sbagliata**, ovvero un modello statistico non correttamente specificato:

$$\text{Modello 2: } Y = \alpha + \beta_1 X_1 + \epsilon$$

Quali sono le conseguenze di questo errore?

Supponiamo ad esempio che valga la seguente ipotesi: - $\text{Cov}(\tilde{\epsilon}, X_j) = 0$, $j = 1, 2$ (esogeneità rispetto al vero modello) - $\text{Cov}(X_1, X_2) \neq 0$

Nel Modello 2, la variabile X_2 è stata omessa. Ciò significa che il suo impatto atteso su Y è stato inglobato dal termine di errore ϵ . Come conseguenza principale, nel Modello 2, $\epsilon = \beta_2 X_2 + \tilde{\epsilon}$, quindi

$$\text{Cov}(X_1, \epsilon) = \beta_2 \text{Cov}(X_1, X_2) \neq 0 \quad \text{se } \beta_2 \neq 0$$

In particolare, è violata la condizione di esogeneità per il modello di regressione semplice. Si può dimostrare che gli stimatori OLS di β_1 sono distorti in campioni piccoli e grandi. Quindi, se $n \rightarrow \infty$:

$$\hat{\beta}_1 \xrightarrow{p} \beta_1 + \rho_{X_1\epsilon} \frac{\sigma_\epsilon}{\sigma_X} \quad (\text{non consistenza di } \hat{\beta}_1)$$

Se prendiamo come punto di riferimento una regressione sbagliata, probabilmente prenderemo decisioni sbagliate. Come affermato prima, ciò che effettivamente stimiamo è

$$\hat{\beta}_1 = \beta_1 + \rho_{X_1\epsilon} \frac{\sigma_\epsilon}{\sigma_X} \neq \beta_1$$

In particolare, una variazione unitaria di X , cioè $\Delta X = 1$, produce

$$\Delta Y = \beta_1 + \underbrace{\Delta \epsilon}_{\approx \rho_{X_1\epsilon} \sigma_\epsilon / \sigma_X}$$

In questo caso non possiamo distinguere gli effetti dovuti dai regressori inclusi e da quelli omessi dal modello. Nell'esempio della CAL school, non sappiamo se la stima di $\hat{\beta} = -2.279$ sia dovuta all'effettiva variazione della dimensione della classe o ad altri fattori come ad esempio il reddito.

Sintesi. Nel modello di regressione semplice, l'ipotesi chiave è $E(\epsilon|X) = 0 \Rightarrow \text{Cov}(\epsilon, X) = 0$. Se una variabile rilevante viene omessa, dobbiamo affrontare delle conseguenze: - L'omissione di una variabile rilevante induce una correlazione non nulla tra il regressore incluso ed il termine di errore $\Rightarrow \text{Cov}(\epsilon, X) \neq 0$. L'ipotesi di **esogeneità** non è più valida; - $E[\hat{\beta}] \neq \beta$, ovvero $\hat{\beta}$ è **distorto**; - Questa distorsione persiste anche se n è grande (**non consistenza**).

(slide 12-16)

3.4. Cause di endogeneità: errori di misura

Teorema 3.2. Si trova endogeneità anche quando il regressore non è osservato esattamente, ma conosciamo solo una sua approssimazione. Consideriamo l'esempio seguente, in cui non possiamo osservare X_i ma solo un suo proxy, diciamo X_i^* . Poi

$$Y_i = \gamma X_i + \epsilon_i$$

$$X_i^* = X_i + u_i \quad \text{Cov}(X_i, u_i) = 0$$

- X_i è il vero regressore, non osservabile;
- X_i^* è il regressore osservabile, ma impreciso;
- u_i è l'errore di misura.

La regressione calcolabile è quindi

$$Y_i = \beta X_i^* + \epsilon_i^*$$

Per comprendere a fondo ciò che stiamo facendo, scriviamo la regressione originale in funzione del regressore osservabile X^* , per verificare se la regressione ammissibile soddisfa l'ipotesi OLS:

$$Y_i = \gamma X_i + \epsilon_i = \gamma(X_i^* - u_i) + \epsilon_i = \gamma X_i^* + \underbrace{\epsilon_i - \gamma u_i}_{\epsilon_i^*}$$

La regressione calcolabile diventa

$$Y_i = \gamma X_i^* + \epsilon_i^* \Rightarrow \text{Cov}(X_i^*, \epsilon_i^*) = \gamma \text{Var}(u_i) \neq 0 \Rightarrow \text{Endogeneity}$$

Quindi, l'utilizzo di regressori che non sono osservati accuratamente porta a stimatori distorti e non consistenti.

Esempio numerico. Consideriamo un dataset simulato di dimensione 200 che soddisfa le seguenti condizioni:

$$Y = 3 + 1.5X + \epsilon$$

La variabile X è il vero regressore (misurato senza errore). Come benchmark, stimiamo il modello di regressione $Y = \alpha + \beta X + \epsilon$, in cui utilizziamo X come regressore:

	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]
X	1.427984	.0654388	21.82	0.000	1.298938 1.557031
_cons	3.072873	.06727	45.68	0.000	2.940215 3.205531

Le stime sono molto precise, nel senso che $\hat{\beta}$ e $\hat{\alpha}$ sono vicini rispettivamente a 1.5 e 3.

Ipotizziamo ora che X non sia osservabile ma sia disponibile solo $X^* = X + u$, $u \sim N(0, 1)$. Cosa accade se stimiamo la seguente regressione:

$$Y = \alpha + \beta X^* + \epsilon$$

in cui anche $\epsilon \sim N(0, 1)$ ed è indipendente da u :

	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]
Xs	.70249	.0742756	9.46	0.000	.5560173 .8489628
_cons	3.135813	.1029848	30.45	0.000	2.932726 3.338901

Si noti che in questo caso $\hat{\beta}$ non è neanche vicino a 1.5 (il valore vero per questo parametro) poiché l'intervallo di confidenza del 95% non lo include.

La distorsione o bias in questo caso può essere quantificato. Sappiamo infatti che nella regressione calcolabile (con X^*),

$$\hat{\beta} = \frac{\text{Cov}(X^*, y)}{V(X^*)} = \beta \frac{V(X)}{V(X) + V(u) + \text{Cov}(X, u)} \approx \frac{1}{2}\beta$$

Nella simulazione è stato ipotizzato $\text{Var}(X) = \text{Var}(u) = 1$. Inoltre si è ipotizzato $\text{Cov}(X, u) = 0$. Di conseguenza la distorsione risulta essere la metà del vero valore del parametro, in questo esempio circa 0.75. Si noti quindi che quello che stimo (.70249) corrisponde al vero $\beta = 1.5$ meno la distorsione (.75).

(slide 17–21)

3.5. L'errore ϵ : momenti condizionali

Definizione 3.2. Le proprietà della variabile casuale ϵ sono cruciali per derivare le proprietà degli stimatori OLS. In particolare, ci interessa valutare i suoi momenti e le relazioni tra ϵ e $X_1, \dots, X_k$.

Per costruzione, ϵ_i può essere visto come la differenza tra Y_i e la media condizionale $E[Y|X_1, \dots, X_k]$, cioè

$$\epsilon_i = Y_i - E[Y|X_{j1}, \dots, X_{ki}] = Y_i - \alpha - \sum_{j=1}^k \beta_j X_{ji}$$

ϵ raccoglie tutte le caratteristiche dei soggetti non esplicitamente prese in considerazione dal modello e descrive una certa eterogeneità del campione.

Media condizionale, $E[\epsilon|X_1, \dots, X_k]$. Supponiamo, ad esempio, che $E[Y|X] = \alpha + \beta X$ sia un'approssimazione credibile della media condizionale. Con questa ipotesi, la media condizionale di ϵ è quindi

$$E[\epsilon|X] = E[Y|X] - \alpha - \sum_{j=1}^k \beta_j X_j = 0$$

Come conseguenza principale, $\text{Cov}(\epsilon, X) = 0$ e quindi tutte le variabili che concorrono a costruire ϵ devono essere incorrelate con X_j , $\forall j$. L'intuizione alla base di questo risultato è che le uniche informazioni rilevanti per descrivere la media condizionale di Y sono $X_1, \dots, X_k$. Tutte le altre variabili non possono avere un impatto sistematico su di esso.

Varianza condizionale, $\text{Var}(\epsilon|X_1, \dots, X_k)$. In generale, la forma funzionale della varianza condizionale di ϵ non è nota. In ogni caso, la variabilità di ϵ descrive anche la variabilità della variabile dipendente Y , ovvero

$$\text{Var}(Y|X) = \text{Var}(\epsilon|X)$$

Possiamo formulare due diverse ipotesi riguardo alle varianze condizionali: - **Omoschedasticità**: si assume che $\text{Var}(\epsilon|X_1, \dots, X_k) = \sigma^2$ non dipende da X . - **Eteroschedasticità**: si assume che $\text{Var}(\epsilon|X_1, \dots, X_k) = \sigma^2(X_1, \dots, X_k)$ dipende da X_j , $\forall j$.

(slide 22–24)

3.6. Le ipotesi OLS

Definizione 3.3. Sono le ipotesi necessarie per valutare correttamente i coefficienti tramite OLS. Le slide propongono due formulazioni equivalenti (Caso I e Caso II), contenenti lo stesso insieme di ipotesi:

- Il modello vero (nella popolazione) è lineare, ovvero $E[Y|X] = \alpha + \beta_1 X_1 + \dots + \beta_k X_k$;
- Il modello statistico corrisponde a quello vero, ovvero $Y = \alpha + \beta_1 X_1 + \dots + \beta_k X_k + \epsilon$;
 - Come conseguenza principale, $\text{Cov}(X_j, \epsilon) = 0$, e quindi X_j si dice **esogeno** (per ogni j);
- Le k -uple $(X_{1,i}, \dots, X_{k,i}, Y_i)$, $i = 1, \dots, n$ sono **I.I.D.**;
- I momenti quarti di X_j e Y esistono e sono finiti (per tutti i j);
- Supponiamo, ad esempio, che $\text{var}[\epsilon|X] = \sigma^2$ (**Omoschedasticità**);
- **Assenza di perfetta collinearità**: non esistono relazioni lineari esatte tra le variabili indipendenti.

(slide 25–26)

3.7. Perfetta collinearità

Esempio 3.2. Intuitivamente, il motivo per cui la perfetta multicollinearità è un problema è legato alla logica alla base del modello di regressione. In generale, un parametro rappresenta come varia Y in corrispondenza di una variazione unitaria del regressore, diciamo X_1 , una volta che tutte le altre variabili sono fissate. Ma se, ad esempio, X_1 e X_2 sono perfettamente correlati, come è possibile variare X_1 e fissare X_2 , dato che X_1 ed X_2 si muovono assieme?

Perfetta collinearità viene osservata quando almeno uno dei regressori è funzione lineare esatta di alcuni altri regressori. Un esempio di una relazione lineare esatta tra X_1, X_2, X_3 e X_5 è $X_2 = a_1X_1 + a_3X_3 + a_5X_5$ per alcune costanti note a_1, a_3, a_5 .

Esempio. Consideriamo la regressione multipla

$$Y = \beta_0 + \beta_1X_1 + \beta_2X_2 + \beta_3X_3 + \epsilon$$

Si ricordi che l'impatto atteso di X_2 o X_3 su Y è misurato rispettivamente da β_2 e β_3 . Supponiamo ad esempio che $X_2 = \phi X_3$ e ϕ sia una costante nota. La previsione $\hat{Y}$ può essere calcolata come

$$E[Y|X_1, X_2, X_3] = \beta_0 + \beta_1X_1 + \beta_2X_2 + \beta_3X_3 = \beta_0 + \beta_1X_1 + (\beta_2\phi + \beta_3)X_3 = \beta_0 + \beta_1X_1 + \tilde{\beta}_3X_3$$

In questo caso non è possibile distinguere gli effetti di X_2 e X_3 . La combinazione di β_2 e β_3 , ovvero $(\beta_2\phi + \beta_3)$, misura l'impatto congiunto di X_2 e X_3 sulla Y attesa.

Conseguenza: quando stimiamo i parametri tramite OLS, il sistema di equazioni non ha un'unica soluzione e quindi non possiamo stimare i parametri.

La soluzione alla collinearità perfetta è semplice: **eliminare uno qualsiasi dei regressori che causano collinearità** al modello.

(slide 27–29)

3.8. Stima OLS della regressione multipla

Dimostrazione. Una volta osservati dei dati, è fondamentale poter stimare i parametri α e β_j che definiscono il modello di regressione. L'idea di base è trovare i parametri α e β_j che permettano di minimizzare la distanza tra ciascuna osservazione e la retta di regressione.

Come nel caso della regressione semplice, OLS suggerisce di minimizzare la varianza del termine di errore:

$$\min_{\alpha, \beta_1, \beta_2} \text{Var}(\epsilon) = \min_{\alpha, \beta_1, \beta_2} E[\epsilon^2] \approx \min_{\alpha, \beta_1, \beta_2} \frac{1}{n} \sum_{i=1}^n (Y_i - \alpha - \beta_1 X_{1,i} - \beta_2 X_{2,i})^2$$

La soluzione OLS per $\hat{\beta}_j$ potrebbe essere una funzione poco intuitiva di X_1, X_2 ed Y . Tuttavia, lo stimatore può essere ricavato come risultato di una regressione semplice del tipo

$$Y = \alpha + \beta_j \hat{u}_j + \eta,$$

Il regressore ausiliario $\hat{u}_j$ è definito come segue:

$$\hat{u}_j = X_j - \hat{a} - \hat{b}X_i, \quad i \neq j$$

Si noti che $\hat{u}_j$ sono i residui della regressione $X_j = a + bX_i + u_j$, per cui lo stimatore OLS risulta

$$\hat{\beta}_j = \frac{\sum_{i=1}^n \hat{u}_{j,i} Y_i}{\sum_{i=1}^n \hat{u}_{j,i}^2}, \quad j = 1, 2$$

In particolare, $\hat{u}_j$ rappresenta l'informazione fornita dalla variabile X_j , ma che non dipende da X_i . Risultati equivalenti possono essere ottenuti per regressioni con un numero generico k di regressori.

Questa formula mostra che possiamo quindi eseguire una semplice regressione di Y su $\hat{u}_j$ per ottenere $\hat{\beta}_j$. L'intuizione è la seguente: l'informazione fornita dai regressori X_j può essere suddivisa in due segnali: (1) la parte che può essere spiegata da altri fattori ($X_i, i \neq j$); (2) la parte che non dipende da X_i . Ad esempio, per $\hat{\beta}_1$, i residui $\hat{u}_{1,i}$ sono la parte di X_1 non correlata con X_2 .

Un altro modo per dirlo è che $\hat{u}_{1,i}$ rappresenta $X_{1,i}$ dopo che gli effetti di $X_{2,i}$ sono stati controllati. Quindi, $\hat{\beta}_1$ misura la **relazione campionaria tra Y e X_1 dopo che l'effetto di X_2 è stato controllato/eliminato**.

Valori predetti e residui. La previsione del valore atteso di Y , o valore predetto, è

$$\hat{Y}_i = \hat{E}[Y_i | X_1 = x_{1,i}, X_2 = x_{2,i}] = \hat{\alpha} + \hat{\beta}_1 x_{1,i} + \hat{\beta}_2 x_{2,i}$$

Il termine di errore viene stimato come la differenza tra la variabile osservata Y_i e il valore atteso stimato $\hat{Y}_i$. Viene detto **residuo** ed è definito come

$$\hat{\epsilon}_i = Y_i - \hat{\alpha} - \hat{\beta}_1 X_{1,i} - \hat{\beta}_2 X_{2,i} = Y_i - \hat{Y}_i$$

Come per la regressione semplice, ogni osservazione Y_i può essere scritta come la somma tra la previsione della media condizionale e della componente residuale:

$$Y_i = \hat{Y}_i + \hat{\epsilon}_i = \underbrace{\hat{\alpha} + \hat{\beta}_1 X_{1,i} + \hat{\beta}_2 X_{2,i}}_{\text{previsione}} + \underbrace{\hat{\epsilon}_i}_{\text{Residuo}}$$

□

(slide 30–33)

3.9. Il teorema di Frisch-Waugh-Lovell (caso a due regressori) e verifica numerica

Teorema 3.3. Come evidenziato prima, invece di calcolare $\hat{\beta}_1$ tramite la consueta procedura OLS, esso può essere ottenuto come segue:

- (a) Si regredisce Y su X_2 e si ottiene il residuo $\hat{\epsilon}_y$.
- (b) Si regredisce X_1 su X_2 e si calcolano i residui $\hat{u}$.
- (c) Infine, si regredisce $\hat{\epsilon}_y$ su $\hat{u}$ per ottenere $\hat{\beta}_1$.

Questo risultato, noto come **Teorema di Frisch-Waugh-Lovell**, permette di interpretare ciascun coefficiente OLS β_1 come la correlazione tra la variabile dipendente Y e il regressore X_1 , una volta eliminati gli effetti di X_2 (lo stesso vale se siamo interessati a β_2).

Esempio. Consideriamo il modello di regressione che lega le performance e la dimensione della classe:

$$\text{avg_score}_i = \alpha + \beta_1 \text{str}_i + \beta_2 \text{avginc}_i + \epsilon_i$$

Le stime OLS basate su un campione di 420 osservazioni sono:

	Coef.	Std. Err.	t	P> t	[95% Conf.	Interval]
str	-.6487401	.354405	-1.83	0.068	-1.345383	.0479028
avginc	1.839112	.0927868	19.82	0.000	1.656724	2.0215
_cons	638.7292	7.449077	85.75	0.000	624.0867	653.3716

Il modello stimato diventa quindi

$$E[\text{avg_score}] = 638.72 - 0.648 \text{str} + 1.839 \text{avginc}$$

Usando il teorema di Frisch-Waugh-Lovell:

- (1) Si stimi $\text{str} = a + b \text{avginc} + u_{\text{str}}$ e si calcoli $\hat{u}_{\text{str}}$:

	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]
avginc	-.0607907	.0124556	-4.88	0.000	-.0852741 - .0363073
_cons	20.57153	.2108957	97.54	0.000	20.15698 20.98608

(2) Si stimi $\text{avg_score} = a + b \text{avginc} + u_{\text{score}}$ e si calcoli $\hat{u}_{\text{score}}$:

	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]
avginc	1.87855	.0905044	20.76	0.000	1.700649 2.05645
_cons	625.3836	1.532405	408.11	0.000	622.3714 628.3958

(3) Si stimi $\hat{u}_{\text{score}} = a + b \hat{u}_{\text{str}} + u$ per ottenere $\hat{\beta}_1$:

	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]
resid_str	-.6487401	.3539808	-1.83	0.068	-1.344544 .0470642
_cons	1.35e-08	.6505869	0.00	1.000	-1.27883 1.27883

Il coefficiente ottenuto nel passo (3), -.6487401, coincide esattamente con il coefficiente di **str** stimato nella regressione multipla completa, verificando numericamente il teorema.

(slide 34–36)

3.10. Bontà di adattamento (R^2)

Definizione 3.4. La misura della bontà di adattamento R^2 può essere calcolata anche per un modello di regressione multipla. Come per la regressione semplice, possiamo calcolarla come la correlazione al quadrato tra la variabile dipendente e la previsione, ovvero

$$R^2 = \text{Corr}^2(Y, \hat{Y})$$

Vale la pena notare che questo indicatore è appropriato per verificare se il modello prevede correttamente la variabile dipendente, **ma non indica presenza di relazioni causali**.

Output completo (esempio avg_score su str e avginc, n = 420):

Source	SS	df	MS	
(ESS) Model	77801.487	2	38900.7435	Number of obs = 420
(RSS) Residual	74308.1067	417	178.196898	F(2, 417) = 218.30
(TSS) Total	152109.594	419	363.030056	Prob > F = 0.0000
				R-squared = 0.5115
				Adj R-squared = 0.5091
				Root MSE = 13.349

	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]
str	-.6487401	.354405	-1.83	0.068	-1.345383 .0479028
avginc	1.839112	.0927868	19.82	0.000	1.656724 2.0215
_cons	638.7292	7.449077	85.75	0.000	624.0867 653.3716

(slide 37–38)

3.11. Proprietà degli stimatori OLS: distribuzione e varianza

Teorema 3.4. Come per la media campionaria, le stime OLS si basano su un dataset ottenuto da campionamento casuale. Per questo motivo campioni diversi forniscono stime diverse: **le stime OLS sono quindi variabili casuali.**

Si può dimostrare che $\hat{\beta}_j, \forall j$, è ben approssimato da una variabile casuale Normale. In particolare, se $E[\epsilon|X_1, X_2, \dots, X_k] = 0$, e $\hat{\beta}_j$ è uno stimatore OLS di β_j , allora

$$\hat{\beta}_j \sim N\left(\beta_j, \hat{\sigma}_{\hat{\beta}_j}^2\right)$$

in cui

$$\hat{\sigma}_{\hat{\beta}_j}^2 = \frac{\hat{\sigma}^2}{\sum_{i=1}^n (X_{i,j} - \bar{X}_j)^2 (1 - R_j^2)}, \quad \hat{\sigma}^2 = \frac{1}{n - k} \sum_{i=1}^n \hat{\epsilon}_i^2$$

e R_j^2 è il coefficiente di bontà di adattamento calcolato dalla regressione di X_j su tutte le altre variabili indipendenti. Questo risultato consente di effettuare test di ipotesi su β_j e di costruire intervalli di confidenza.

La varianza di $\hat{\beta}_j$. L'errore standard di $\hat{\beta}_j$ è

$$\hat{\sigma}_{\hat{\beta}_j} = \sqrt{\frac{\hat{\sigma}^2}{\sum_{i=1}^n (X_{i,j} - \bar{X}_j)^2 (1 - R_j^2)}}$$

- Valori grandi di σ^2 rendono grande l'errore standard (nota: questa grandezza non dipende dalla dimensione del campione n);
- Valori grandi di $\sum_{i=1}^n (X_{ji} - \bar{X}_j)^2$ rendono piccolo l'errore standard. Cioè, maggiore è la variabilità di X_j , minore è l'errore standard;
- Inoltre, maggiore è la dimensione del campione n , minore è l'errore standard;
- Alta correlazione tra regressori (quasi collinearità) implica un errore standard grande. Vale la pena notare che, nel caso di perfetta collinearità, $R_j^2 = 1 \Rightarrow \hat{\sigma}_{\hat{\beta}} \rightarrow +\infty$.

(slide 39–40)

3.12. Intervalli di confidenza per β_j

Definizione 3.5. Per quanto riguarda la media campionaria, è utile fornire un intervallo di possibili valori in cui riteniamo il vero parametro β probabilmente cadrà con alta probabilità. Si noti che, come per la media campionaria, $\hat{\beta}_j$ è normalmente distribuita.

Per questo motivo valgono ancora tutti i risultati validi per la media campionaria. Un intervallo di confidenza per β_j può quindi essere calcolato come

$$\text{Intervallo di confidenza} = \left[\hat{\beta}_j - z_{\alpha/2} \times \hat{\sigma}_{\hat{\beta}_j} ; \hat{\beta}_j + z_{\alpha/2} \times \hat{\sigma}_{\hat{\beta}_j} \right]$$

Esempio: intervalli di confidenza per scores vs. income and class size. Nell'esempio del performance vs. class size e reddito, l'intervallo di confidenza al 95% per β_1 e β_2 è calcolato come

$$C.I.(\beta_1) \equiv [-0.648 - 1.96 \times 0.354 ; -0.648 + 1.96 \times 0.354] = [-1.345; 0.047]$$

$$C.I.(\beta_2) \equiv [1.839 - 1.96 \times 0.092 ; 1.839 + 1.96 \times 0.092] = [1.656; 2.021]$$

	Coef.	Std. Err.	t	P> t	[95% Conf.	Interval]
str	-.6487401	.354405	-1.83	0.068	-1.345383	.0479028
avginc	1.839112	.0927868	19.82	0.000	1.656724	2.0215
_cons	638.7292	7.449077	85.75	0.000	624.0867	653.3716

(slide 41-42)

3.13. Verifica d'ipotesi per β_j

Teorema 3.5. Potremmo chiederci se X_1 o X_2 siano predittori utili, nel senso che hanno un impatto sul valore atteso di Y . Si ricordi che

$$\Delta \hat{Y} = \beta_j \Delta X_j.$$

Se β_j fosse 0, allora qualunque sia la variazione di X_j , la variazione attesa di Y prevista dal modello sarebbe nulla. Diventa quindi abbastanza naturale verificare se β_j è abbastanza vicino a 0 oppure no.

In generale, potremmo essere interessati a verificare se l'evidenza empirica è **coerente** con qualche valore specifico del parametro. Si noti che $\hat{\beta}_j$ è distribuito secondo una variabile casuale

gaussiana. Quindi la procedura di test può basarsi esattamente sugli stessi risultati forniti per la regressione semplice.

Per verificare $H_0 : \beta_j = 0$ rispetto all'alternativa $H_a : \beta_j \neq 0$, la statistica t è

$$t = \frac{\hat{\beta}_j - 0}{\hat{\sigma}_{\hat{\beta}_j}}$$

Il p-value può essere facilmente calcolato come al solito.

Esempio. Nel punteggio medio vs. dimensione della classe e reddito, per il sistema di ipotesi $H_0 : \beta_1 = 0$ vs. $H_a : \beta_1 \neq 0$, la statistica t osservata è

$$t^{obs} = \frac{-.6487401 - 0}{.354405} = -1.83$$

e il p-value è calcolato come $2P_{H_0}(|t| > t^{obs}) = 0.068$. Ciò significa che a un livello del 5% non rifiutiamo l'ipotesi nulla e quindi questo parametro non è considerato statisticamente diverso da 0. Quindi la dimensione della classe, secondo questo modello, non è una variabile rilevante.

Per il sistema di ipotesi $H_0 : \beta_2 = 0$ vs. $H_a : \beta_2 \neq 0$ la statistica t osservata è

$$t^{obs} = \frac{1.839112 - 0}{.0927868} = 19.82$$

e il p-value calcolato è $2P_{H_0}(|t| > t^{obs}) \approx 0$. Ciò significa che al livello dell'1% (e anche al 5%) rifiutiamo l'ipotesi nulla: il reddito è un predittore statisticamente significativo.

(slide 43-44)

3.14. Il teorema di Gauss-Markov

Teorema 3.6. Un risultato importante può essere enunciato come segue. Se sono soddisfatte le seguenti ipotesi:

- **Linearità:** nel modello sulla popolazione, la variabile dipendente Y è correlata alle variabili indipendenti $X_1, \dots, X_k$ e all'errore ϵ , come

$$Y = \alpha + \beta_1 X_1 + \dots + \beta_k X_k + \epsilon$$

- **Esogenità:** l'errore ϵ ha un valore atteso condizionato pari a zero per qualsiasi valore delle variabili esplicative. In altre parole, $E(\epsilon|X) = 0$.
- **Omoschedasticità:** $\text{Var}(Y|X_1, \dots, X_k) = \sigma^2$;
- **Campionamento casuale:** i dati sono ottenuti da un campione casuale di dimensione n , $(X_{1,i}, \dots, X_{k,i}, Y_i)$, $i = 1, \dots, n$.

Allora, OLS fornisce il **miglior stimatore lineare non distorto (BLUE)**, che è il più efficiente (con varianza minore) nella classe degli stimatori lineari e non distorti.

(slide 45-46)

3.15. Rappresentazione matriciale del modello

Definizione 3.6. Un modo compatto e pratico per descrivere un modello di regressione passa per la sua rappresentazione matriciale.

Definiamo la matrice dei regressori come

$$\mathbf{X}_{n \times (k+1)} = \begin{pmatrix} 1 & X_{11} & X_{12} & \dots & X_{1k} \\ 1 & X_{21} & X_{22} & \dots & X_{2k} \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ 1 & X_{n1} & \dots & \dots & X_{nk} \end{pmatrix}$$

X_{ij} è l'osservazione corrispondente al j -esimo regressore relativo all' i -esimo soggetto. La prima colonna rappresenta un regressore associato all'intercetta α .

Il vettore $\mathbf{Y}$ di dimensione $n \times 1$ (n righe e 1 colonna) raccoglie tutte le osservazioni relative alla variabile dipendente

$$\mathbf{Y}_{n \times 1} = \begin{pmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{pmatrix}$$

Il vettore β di dimensione $k + 1$ raccoglie tutti i parametri associati ai k regressori $\beta_1, \dots, \beta_k$ e l'intercetta α .

$$\beta_{(k+1) \times 1} = \begin{pmatrix} \alpha \\ \beta_1 \\ \vdots \\ \beta_k \end{pmatrix}$$

Il vettore ϵ di dimensione $n \times 1$ include gli errori per ciascun soggetto

$$\epsilon_{n \times 1} = \begin{pmatrix} \epsilon_1 \\ \epsilon_2 \\ \vdots \\ \epsilon_n \end{pmatrix}$$

In poche parole, il modello di regressione può essere scritto come:

$$\begin{pmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{pmatrix} = \begin{pmatrix} 1 & X_{11} & X_{12} & \dots & X_{1k} \\ 1 & X_{21} & X_{22} & \dots & X_{2k} \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ 1 & X_{n1} & \dots & \dots & X_{nk} \end{pmatrix} \begin{pmatrix} \alpha \\ \beta_1 \\ \vdots \\ \beta_k \end{pmatrix} + \begin{pmatrix} \epsilon_1 \\ \epsilon_2 \\ \vdots \\ \epsilon_n \end{pmatrix}$$

... ed in forma compatta con

$$\mathbf{Y} = \mathbf{X}\beta + \epsilon$$

(slide 47-50)

3.16. OLS in notazione matriciale

Dimostrazione. OLS può essere scritto tramite la funzione quadratica

$$S(\alpha, \beta_1, \dots, \beta_k) = (\mathbf{Y} - \mathbf{X}\beta)'(\mathbf{Y} - \mathbf{X}\beta) = \epsilon'\epsilon = \sum_{i=1}^n \epsilon_i^2$$

I coefficienti β possono essere stimati, come al solito, minimizzando $\epsilon'\epsilon \approx n\text{Var}(\epsilon)$, cioè

$$\min_{\alpha, \beta_1, \dots, \beta_k} S(\alpha, \beta_1, \dots, \beta_k) = \min_{\beta} S(\beta)$$

Uguagliando a 0 le derivate prime rispetto a β si ottiene

$$\frac{\partial S}{\partial \beta} = -\mathbf{X}'\mathbf{Y} + \mathbf{X}'\mathbf{X}\beta = 0$$

Gli stimatori OLS possono essere ottenuti come

$$\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y}$$

□

(slide 51)

3.17. Il teorema di Frisch-Waugh-Lovell (versione generale, matriciale)

Teorema 3.7. Consideriamo il seguente modello di regressione

$$\mathbf{Y} = \beta_1\mathbf{X}^1 + \beta_2\mathbf{X}^2 + \epsilon$$

in cui $\mathbf{X}^1$ e $\mathbf{X}^2$ sono sottoinsiemi dei regressori tali che $\mathbf{X} = [\mathbf{X}^1, \mathbf{X}^2]$ e il vettore dei parametri β viene diviso di conseguenza in due parti, ovvero $\beta = (\beta_1, \beta_2)$.

Il modello di regressione può quindi essere scritto come

$$\mathbf{Y} = [\mathbf{X}^1, \mathbf{X}^2] \begin{pmatrix} \beta_1 \\ \beta_2 \end{pmatrix} + \epsilon$$

Il **teorema di Frisch-Waugh-Lovell** afferma che gli stimatori OLS per il vettore dei parametri β_1 possono essere calcolati come:

- (a) Si regredisce $\mathbf{Y}$ su $\mathbf{X}^2$ e si ottiene il residuo $\hat{\epsilon}_y$.
- (b) Quindi si regredisce **ogni** regressore in $\mathbf{X}^1$ su **tutti** i regressori in $\mathbf{X}^2$ per ottenere i residui $\hat{u}$.
- (c) Infine, regredendo $\hat{\epsilon}_y$ su $\hat{u}$ si ottiene $\hat{\beta}_1$.

Stessi risultati si possono ottenere per $\hat{\beta}_2$.

(slide 52–53)

4 | Test F per le restrizioni multiple

Fonte: ECON_Teoria_04_Test-F-Restrizioni-Multiple.pdf — 18 slide

4.1. Esempio introduttivo: differenze salariali tra gruppi

Esempio 4.1. Consideriamo il seguente modello di regressione:

$$\log(wage) = \alpha + \beta_1 educ + \beta_2 exper + \beta_3 tenure + \beta_4 south + \beta_5 urban + \beta_6 marr_black + \beta_7 single_black + \beta_8 marr_nonblack + \beta_9 single_nonblack + \epsilon$$

Ci sono 4 variabili dummy che suddividono il campione in 4 gruppi diversi e non sovrapposti. In particolare, definiamo *married_black*, *single_black*, *married_nonblack* e *single_nonblack* per distinguere lo stato civile insieme alla razza.

Siamo interessati a valutare se i lavoratori sposati e di colore e sposati non di colore ricevono, in media, la stessa quantità di denaro.

Le stime OLS (comando: `reg lwage educ exper tenure south urban marr_black single_black marr_nonblack single_nonblack`) sono:

lwage	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]
educ	.0654751	.006253	10.47	0.000	.0532034 .0777469
exper	.0141462	.003191	4.43	0.000	.0078837 .0204087
tenure	.0116628	.0024579	4.74	0.000	.006839 .0164866
south	-.0919894	.0263212	-3.49	0.000	-.1436455 -.0403333
urban	.1843501	.0269778	6.83	0.000	.1314053 .2372948
marr_black	.2502685	.0940889	2.66	0.008	.0656162 .4349208
single_black	(dropped)				
marr_nonblack	.4297348	.0880447	4.88	0.000	.2569445 .6025251
single_nonblack	.2408201	.0960229	2.51	0.012	.0523724 .4292678
_cons	5.162973	.1359471	37.98	0.000	4.896173 5.429773

(*single_black* viene automaticamente escluso dal software — “dropped” — perché costituisce la categoria di riferimento rispetto alla quale sono definite le altre tre dummy di gruppo, insieme alla costante.)

I salari medi attesi per ogni gruppo, condizionati sulle altre variabili, sono:

- Se $married = 1$ e $black = 1$, cioè $marr_black = 1$:

$$E[lwage|X] = \alpha + \beta_1 educ + \dots + \beta_6 \times 1 + \beta_8 \times 0 + \beta_9 \times 0$$

- Se $married = 1$ e $black = 0$, cioè $marr_nonblack = 1$:

$$E[lwage|X] = \alpha + \beta_1 educ + \dots + \beta_6 \times 0 + \beta_8 \times 1 + \beta_9 \times 0$$

- Se $married = 0$ e $black = 1$, cioè $single_black = 1$:

$$E[lwage|X] = \alpha + \beta_1 educ + \dots + \beta_6 \times 0 + \beta_8 \times 0 + \beta_9 \times 0$$

- Se $married = 0$ e $black = 0$, cioè $single_nonblack = 1$:

$$E[lwage|X] = \alpha + \beta_1 educ + \dots + \beta_6 \times 0 + \beta_8 \times 0 + \beta_9 \times 1$$

Sulla base del modello, tra le persone sposate, la differenza salariale causata dalla razza è rappresentata da:

$$E[lwage|marr_black = 1] - E[lwage|marr_nonblack = 1] = \beta_6 - \beta_8 = .2502685 - .4297348$$

È possibile verificare se questa differenza è statisticamente significativa? Una possibile soluzione è calcolare il seguente statistico t :

$$t = \frac{\hat{\beta}_6 - \hat{\beta}_8 - 0}{\text{st.err.}(\hat{\beta}_6 - \hat{\beta}_8)}$$

Sfortunatamente, in alcuni casi, non è immediato valutare il denominatore (lo standard error di una combinazione lineare di stimatori correlati). Serve quindi una strategia più generale per implementare questo tipo di test — il test F, sviluppato nelle sezioni seguenti.

(slide 2–5)

4.2. Perché un test t ripetuto non è una soluzione valida per ipotesi congiunte

Dimostrazione. Esempio motivante: test di significatività congiunta. Consideriamo un modello di regressione multipla

$$Y = \alpha + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \epsilon$$

e vogliamo testare se X_1 , X_2 e X_3 , congiuntamente, sono predittori utili per Y . Vogliamo cioè valutare l'ipotesi congiunta

$$H_0 : \beta_1 = \beta_2 = \beta_3 = 0 \quad \text{contro} \quad H_1 : \text{almeno un } \beta_j \neq 0, \quad j = 1, 2, 3.$$

Se l'ipotesi nulla è corretta, i tre regressori sono inutili per predire Y : se H_0 fosse vera, la regressione si ridurrebbe a

$$Y = \alpha + \epsilon$$

(il *modello ristretto*). Serve una strategia che permetta di confrontare questo modello ristretto con il *modello completo*.

Un primo tentativo (naïve): ripetere il test t tre volte. La strategia consiste nel:

1. Calcolare tre statistiche t , cioè t_1 , t_2 e t_3 , per le ipotesi $H_0^{(1)} : \beta_1 = 0$, $H_0^{(2)} : \beta_2 = 0$ e $H_0^{(3)} : \beta_3 = 0$, contro l'alternativa bilaterale.
2. Decidere secondo lo schema seguente:
 - Se non rigettiamo tutte e tre le ipotesi nulle, non rigettiamo neanche l'ipotesi congiunta $H_0 : \beta_1 = \beta_2 = \beta_3 = 0$.
 - Se rigettiamo almeno una delle tre ipotesi, rigettiamo anche $H_0 : \beta_1 = \beta_2 = \beta_3 = 0$.

Questa strategia può portare a risultati errati. Se l'ipotesi nulla è vera, la probabilità di non rigettarla in un singolo test è $1 - 0.05$ quando $\alpha = 0.05$. Supponendo (per semplicità algebrica, anche se non è un'ipotesi credibile) che t_1 , t_2 e t_3 siano test indipendenti, e ricordando che per tre eventi indipendenti A, B, C vale $P(A, B, C) = P(A)P(B)P(C)$, la probabilità di non rigettare congiuntamente le tre ipotesi nulle è

$$0.95 \times 0.95 \times 0.95 = 0.8574$$

L'errore di Tipo I del test congiunto — cioè la probabilità di rigettare l'ipotesi nulla quando è corretta — è quindi

$$1 - 0.8574 = 0.1426 \neq 0.05$$

ossia la probabilità di rigettare erroneamente l'ipotesi nulla è circa $3 \times \alpha$. Con la strategia naïve, quindi, si perde il controllo sul vero livello di significatività del test. $\square$

(slide 6–8)

4.3. Restrizioni lineari: definizione generale

Definizione 4.1. I due esempi precedenti coinvolgono entrambi **restrizioni lineari** sui parametri, cioè vincoli del tipo

$$r_1\beta_1 + r_2\beta_2 + \dots + r_{k-1}\beta_{k-1} + r_k\beta_k = q$$

dove $r_1, \dots, r_k$ e q sono costanti note.

- Nel primo esempio (differenze salariali) questo è immediato: consideriamo $\beta_6 - \beta_8 = 0$, con $r_6 = 1$, $r_8 = -1$, tutti gli altri $r_i = 0$ e $q = 0$. Si tratta di un'unica combinazione lineare, cioè **1 restrizione**.
- Anche il secondo esempio (test di significatività congiunta) coinvolge restrizioni lineari particolari: ogni $\beta_j = 0$ è una combinazione lineare in cui tutti i pesi $r_i = 0$ per $i \neq j$, mentre $r_j = 1$ e $q = 0$. In questo caso ci sono **3 diverse combinazioni lineari** che devono essere soddisfatte congiuntamente (3 restrizioni).

Il **test F** consente di valutare in un unico passo se una o più restrizioni lineari sono coerenti con le evidenze empiriche.

(slide 9)

4.4. Costruzione del test F: modello completo vs modello ristretto

Una strategia credibile per implementare un test su parametri multipli passa attraverso la **statistica F**.

Siano R_c^2 e R_r^2 gli indicatori di bontà di adattamento (R^2) rispettivamente del modello *completo* e del modello *ristretto*:

- il **modello ristretto** è quello in cui si ipotizza che l'ipotesi nulla sui parametri sia valida;
- il **modello completo** è il modello di regressione originale (non vincolato).

Se l'ipotesi alternativa fosse corretta, ci si aspetta che la capacità predittiva del modello completo sia superiore a quella del modello ristretto (che è vincolato). In particolare, la differenza tra i due R^2 sarà grande. Il test F studia quindi il comportamento della quantità $(R_c^2 - R_r^2)$.

(slide 10)

4.5. La statistica F: definizione

Definizione 4.2. Il test F è definito come

$$F_{s; n-k-1} = \frac{(R_c^2 - R_r^2)/s}{(1 - R_c^2)/(n - k - 1)}$$

dove:

- s è il numero di vincoli sotto l'ipotesi nulla (nell'esempio di significatività congiunta è 3, poiché si ipotizza $\beta_1 = 0$, $\beta_2 = 0$ e $\beta_3 = 0$);
- k è il numero totale di regressori nel modello completo (nell'esempio è 3);
- n è la dimensione del campione.

(slide 11)

4.6. Proprietà del test F, regola di decisione e p-value

Teorema 4.1. Si può dimostrare che la statistica F ha le seguenti proprietà:

- **È sempre positiva.** Infatti si può dimostrare che R^2 è sempre non decrescente quando si aggiungono regressori (quindi $R_c^2 \geq R_r^2$).
- **I valori di F vicini a 0 sono più favorevoli a H_0 che a H_1 .** Ciò implica che si respinge l'ipotesi nulla solo quando F è grande: si tratta di un **test unilaterale**. In pratica si calcola la statistica F osservata, F^{oss} , e il p-value viene calcolato come $P(F > F^{oss})$. Se il p-value è più piccolo del livello α , si respinge l'ipotesi nulla; altrimenti non c'è sufficiente evidenza per respingerla.
- **Se l'ipotesi nulla è corretta**, allora la distribuzione di F è ben approssimata da una variabile casuale F con s e $n - k - 1$ gradi di libertà (parametri). Per questa distribuzione sono disponibili tabelle.




Figura 1 — Rappresentazione grafica della variabile casuale F . Il grafico (“*The 5% critical value and rejection region in an $F_{3,60}$ distribution*”) mostra la densità di una distribuzione F

asimmetrica a destra: l'area sottesa fino al valore critico 2.76 corrisponde al 95% della probabilità (“area = .95”), mentre l'area a destra di 2.76 (“area = .05”, la *rejection region*) corrisponde al livello di significatività del 5%. Se la statistica F osservata cade in quest'area, l'ipotesi nulla viene respinta.

Regola di decisione con il valore critico. Come al solito si può definire il livello α e calcolare il valore critico utilizzando tabelle F adeguate:

- se F^{oss} è più grande del livello critico, si respinge l'ipotesi nulla;
- se F^{oss} è più piccolo del livello critico, non c'è sufficiente evidenza per respingere l'ipotesi nulla.

Regola di decisione con il p-value. Si può calcolare anche il p-value, cioè $P_{H_0}(F > F^{oss})$: se il p-value è più piccolo di α (in percentuale), si respinge l'ipotesi nulla, altrimenti non la si può respingere.

(slide 12–14)

4.7. Relazione tra la distribuzione F e la distribuzione chi-quadro

Si noti che $F(k_1, k_2)$ è ben approssimata da una variabile $\chi_{k_1}^2$ se k_2 è sufficientemente grande. Questo accade quando n è grande, visto che $F \sim F_{s; n-k-1}$ (e quindi $k_2 = n - k - 1$ cresce con la numerosità campionaria).




Figura 2 — χ_{df}^2 con diversi gradi di libertà, cioè $df = 1, 2, 5, 10$. Il pannello mostra quattro istogrammi di variabili casuali chi-quadro simulate con gradi di libertà crescenti (1, 2, 5, 10): per $df = 1$ la densità è fortemente concentrata vicino allo zero e decrescente; all'aumentare dei gradi di libertà la distribuzione si sposta verso destra, si allarga e assume una forma progressivamente più simmetrica e campanulare, illustrando visivamente come l'approssimazione chi-quadro della F migliori (in forma) al crescere dei gradi di libertà al denominatore. (slide 15)

4.8. Esempio: dimensione della classe e reddito rispetto al punteggio del test

Esempio 4.2. Supponiamo di voler testare se **str** (dimensione della classe) e **avginc** (reddito medio) sono predittori utili per il punteggio del test. Il modello completo è

$$avg_score = \alpha + \beta_1 str + \beta_2 avginc + \epsilon$$

L'ipotesi nulla è quindi $H_0 : \beta_1 = \beta_2 = 0$ contro l'alternativa che almeno uno di questi due parametri sia diverso da 0.

Non è banale calcolare, carta e penna, la statistica F osservata, poiché richiede una serie di calcoli noiosi: stimare i due modelli (completo e ristretto), calcolare i loro indicatori di bontà di adattamento R^2 , e valutare la statistica F osservata, cioè F^{obs} . Di solito i test F vengono calcolati tramite software statistici/econometrici.

Procedura con Gretl:

- Si stimi la regressione completa.
- Dall'output della regressione si utilizzi il menu *Test -> Vincoli lineari*.
- Si definisca il test come segue:

```
b[str] = 0
b[avginc] = 0
```

L'output è riportato di seguito:

```
Insieme di vincoli
1: b[str] = 0
2: b[avginc] = 0
```

Statistica test: $F(2, 417) = 218,302$, con p-value = $1,3533e-65$

In questo caso si respinge l'ipotesi nulla poiché il p-value è prossimo a 0. Ciò significa che almeno uno dei due regressori è un predittore utile per il punteggio medio.

(slide 16–17)

4.9. Esempio: verifica della differenza salariale tra gruppi con il test F

Esempio 4.3. Riprendendo l'esempio delle differenze salariali, per verificare se $\beta_6 - \beta_8 \neq 0$, cioè se la differenza tra lavoratori sposati di colore e sposati non di colore è statisticamente significativa, si implementa il test

$$H_0 : \beta_6 - \beta_8 = 0 \quad \text{vs.} \quad H_1 : \beta_6 - \beta_8 \neq 0$$

In Gretl si procede così:

1. Si stimi la regressione completa (`reg lwage su educ exper tenure south urban marr_black single_black marr_nonblack single_nonblack`).
2. Dall'output della regressione si utilizzi il menu *Test -> Vincoli lineari*.
3. Si definisca il test come segue:

```
b[marr_black] - b[marr_nonblack] = 0
```

L'output è riportato di seguito:

Insieme di vincoli

```
1: b[marr_black] - b[marr_nonblack] = 0
```

Statistica test: $F(1, 926) = 19,60$, con p-value = 0.000

Il p-value è nullo. In altre parole, la differenza tra i due gruppi (lavoratori sposati di colore vs. sposati non di colore) è effettivamente significativamente diversa da 0 — confermando, con lo strumento generale del test F, quanto ci si chiedeva nell'esempio introduttivo senza poter calcolare agevolmente la statistica t per la combinazione $\hat{\beta}_6 - \hat{\beta}_8$.

(slide 18)

5 | L'ipotesi di Eteroschedasticità

Fonte: ECON_Teoria_05_Eteroschedasticita.pdf — 36 slide

5.1. Introduzione e struttura della lezione

Corso: *Econometrics* — lezione **L'ipotesi di Eteroschedasticità**, tenuta da Davide Raggi, 25 novembre 2025.

Argomenti trattati nella lezione:

- L'ipotesi di omoschedasticità
- Soluzioni per l'eteroschedasticità
- Stimatori Robusti
- Test robusti (t ed F)
- Test per l'eteroschedasticità

(slide 1–2)

5.2. L'ipotesi di omoschedasticità

Definizione 5.1.

- L'ipotesi di omoschedasticità **non è necessaria** per dimostrare la non distorsione e la consistenza di $\hat{\beta}_j$.
- Tuttavia, per dimostrare il **teorema di Gauss-Markov**, si assume che le varianze condizionali di ϵ_i siano costanti:

$$\text{Var}(\epsilon_i | X_{1i}, \dots, X_{ki}) = \sigma^2 \quad \forall i$$

- In base a questa ipotesi, gli stimatori OLS sono **BLUE** (*Best Linear Unbiased Estimator*), ovvero quelli con la minore deviazione standard (migliori) nella classe degli stimatori lineari e non distorti.
- Domanda aperta: possiamo chiederci se/perché questa ipotesi sia rilevante per scopi pratici, e quali siano le conseguenze della sua violazione.

(slide 3)

5.3. Standard error nel modello semplice e conseguenze dell'eteroschedasticità

Richiamo. Nel modello di regressione semplice, l'ipotesi di omoschedasticità è stata utilizzata per calcolare le deviazioni standard degli stimatori. In particolare, le deviazioni standard di $\hat{\beta}$ e $\hat{\alpha}$ sono:

$$\hat{\sigma}_{\hat{\beta}} = \sqrt{\frac{\hat{\sigma}^2}{\sum_{i=1}^n (X_i - \bar{X})^2}}$$

$$\hat{\sigma}_{\hat{\alpha}} = \sqrt{\frac{\hat{\sigma}^2 \left(\frac{1}{n} \sum_{i=1}^n X_i^2 \right)}{\sum_{i=1}^n (X_i - \bar{X})^2}}$$

Domanda: questi stimatori per $\sigma_{\hat{\alpha}}$ e $\sigma_{\hat{\beta}}$ sono ancora affidabili nel caso in cui l'ipotesi di omoschedasticità non sia verificata?

Conseguenze della violazione.

- Si può dimostrare che sotto l'ipotesi di eteroschedasticità, gli stimatori della deviazione standard **non sono consistenti** e quindi forniscono una scarsa approssimazione alla vera deviazione standard.
- Una stima inaccurata di $\sigma_{\hat{\beta}}$ può portare al calcolo di statistiche t non affidabili (poiché $\sigma_{\hat{\beta}}$ è il denominatore di t). In particolare, una stima distorta della deviazione standard influirà probabilmente sui risultati inferenziali.
- I test di ipotesi e gli intervalli di confidenza saranno quindi fortemente influenzati dall'ipotesi che facciamo sulla varianza condizionale. È quindi naturale cercare stimatori ragionevoli per $\sigma_{\hat{\beta}}$ che siano coerenti anche con l'ipotesi di eteroschedasticità.

(slide 4–5)

5.4. Esempio: modello di regressione multipla sul prezzo delle case

Esempio 5.1. Si consideri un modello di regressione in cui il prezzo di alcune case (*price*) viene spiegato attraverso alcune variabili: la dimensione (*sqrft*), la dimensione del lotto (*lotsize*), il numero di stanze (*bdrms*). I dati sono raccolti in `hprices.gdt`.

Una delle principali ipotesi per la regressione stimata con OLS è l'omogeneità della varianza degli errori. Se il modello è ben definito, ci si aspetta non venga riconosciuto alcun pattern chiaro tra i residui e i valori predetti dal modello. Esistono metodi grafici e non grafici per rilevare l'eteroschedasticità. Un metodo grafico comunemente usato è rappresentare graficamente i residui (o i residui al quadrato) rispetto ai valori predetti (o ai singoli regressori).




Figura 1 — Residui vs. valori adattati $\hat{\epsilon}$ vs. $\hat{Y}$. Lo scatterplot (residui tra circa -100 e 300 , valori adattati tra 200 e 600) mostra che la dispersione dei residui non è costante: per valori elevati di $\hat{Y} = X\hat{\beta}$ la variabilità dei residui sembra aumentare, e sono presenti pochi residui estremi. In generale, questo grafico è usato per rilevare la non linearità, varianze degli errori non uguali e la presenza di outlier.

Dalla Figura 1 si evince che:

- I residui rimbalzano casualmente intorno alla linea 0 (media dei residui stessi). Ciò suggerisce che l'ipotesi di relazione lineare è ragionevole.
- I residui **non** formano approssimativamente una banda orizzontale intorno allo 0: per valori elevati di $\hat{Y}$ la dispersione/variabilità dei residui aumenta (**eteroschedasticità**).
- Pochi residui risultano estremi rispetto agli altri: questo accade solo per prezzi predetti maggiori di 500 e per una casa il cui residuo sfiora 200 pur avendo un prezzo poco superiore a 200K dollari.




Figura 2 — Esempio di comportamento corretto di $\hat{\epsilon}$ vs. $\hat{Y}$. Lo scatterplot mostra i residui distribuiti in una banda orizzontale uniforme intorno allo zero su tutto il range dei valori adattati (2500–4000), senza l’allargamento a imbuto osservato in Figura 1: questo è ciò che ci si aspetta da un modello omoschedastico ragionevole.

Confronto tra due specificazioni. Di seguito viene stimato il modello di regressione utilizzando due formule alternative per il calcolo degli standard error: il primo output riporta le stime OLS con deviazioni standard naïve (“normali”), il secondo fornisce una correzione per un’eventuale eteroschedasticità.

Modello 1 — Deviazioni standard normali:

price	Coef.	Std. Err.	t	P> t	[95% Conf.	Interval]
sqrft	.1227782	.0132374	9.28	0.000	.0964541	.1491022
lotsize	.0020677	.0006421	3.22	0.002	.0007908	.0033446
bdrms	13.85252	9.010145	1.54	0.128	-4.065141	31.77018
_cons	-21.77031	29.47504	-0.74	0.462	-80.38466	36.84405

Modello 2 — Correzione per eteroschedasticità:

price	Coef.	Std. Err.	t	P> t	[95% Conf.	Interval]
sqrft	.1227782	.0177253	6.93	0.000	.0875294	.158027
lotsize	.0020677	.0012514	1.65	0.102	-.0004209	.0045563
bdrms	13.85252	8.478625	1.63	0.106	-3.008154	30.7132
_cons	-21.77031	37.13821	-0.59	0.559	-95.62371	52.0831

Nelle slide originali la riga di *lotsize* è esplicitamente evidenziata in entrambi i modelli: passando dagli standard error naïve a quelli corretti, il p-value di *lotsize* passa da 0.002 (significativo) a 0.102 (non significativo) — un esempio concreto di come la scelta degli standard error possa cambiare le conclusioni inferenziali. Domanda aperta: quale delle due specificazioni risulta più attendibile?




Figura 3 — Residui al quadrato vs. ogni regressore. I tre scatterplot mostrano $\hat{\epsilon}^2$ rispettivamente contro *bdrms* (asse 2–7), *lotsize* (asse 0–100000) e *sqrft* (asse 1000–4000), con i residui al quadrato sull’asse verticale nel range 0–300000 circa. Si osserva una chiara dipendenza crescente tra $\hat{\epsilon}^2$ e, rispettivamente, *bdrms* e *sqrft* (pattern più marcato e quasi lineare per *sqrft*), mentre la dipendenza con *lotsize* è meno netta.

I residui al quadrato, che sono una proxy della varianza condizionale, risultano fortemente dipendenti dalle variabili del modello: la varianza sembra quindi dipendere da X , evidenziando **eteroschedasticità**. In particolare, i residui al quadrato crescono proporzionalmente a *bdrms* e *sqrft*. La varianza condizionale non sembra dunque costante, per cui l’output più credibile è il **Modello 2**, che corregge per l’eteroschedasticità.

(slide 6–12)

5.5. Soluzioni per l’eteroschedasticità: panoramica e Weighted Least Squares (WLS)

Definizione 5.2. Nella letteratura esistono due metodi principali per stimare gli errori standard di $\hat{\beta}_j$ in presenza di eteroschedasticità:

1. **Weighted Least Squares (WLS)** — forse meno utile, si basa su una standardizzazione adeguata del termine di errore ϵ : se $\text{Var}(\epsilon_i|X) = \sigma_i^2 = (\sigma\tilde{\sigma}_i)^2$, si valuta prima $\tilde{\sigma}_i$ per poi dividere ϵ_i per $\tilde{\sigma}_i$.
2. **Stima robusta** — si basa sulla consistenza degli stimatori OLS per ottenere stimatori robusti rispetto all'eteroschedasticità per gli errori standard: si utilizzano gli $\hat{\epsilon}_i$ per valutare la varianza vera di $\hat{\beta}_i$.

Weighted Least Squares. Si consideri la regressione

$$Y_i = \alpha + \beta_1 X_{i1} + \dots + \beta_k X_{ik} + \epsilon_i$$

Si ipotizzi che $\text{Var}(\epsilon_i|X_1, \dots, X_k) = \sigma_i^2$, dove σ_i^2 dipende da alcuni regressori e da alcuni parametri sconosciuti. Ad esempio, può essere interessante utilizzare

$$\sigma_i^2 = \sigma^2 \exp\{\delta_0 + \delta_1 Z_1 + \dots + \delta_m Z_m\} = (\sigma\tilde{\sigma}_i)^2$$

dove $Z_1, \dots, Z_m$ sono regressori (che possono coincidere con $X_1, \dots, X_k$).

Se i parametri δ_i , $i = 0, \dots, m$ sono noti, possiamo valutare facilmente σ_i . In questo caso si considera la **regressione ausiliaria**

$$\frac{Y_i}{\tilde{\sigma}_i} = \alpha \frac{1}{\tilde{\sigma}_i} + \beta_1 \frac{X_{i1}}{\tilde{\sigma}_i} + \dots + \beta_k \frac{X_{ik}}{\tilde{\sigma}_i} + \frac{\epsilon_i}{\tilde{\sigma}_i}$$

E quindi il modello di regressione originale diventa

$$Y_i^* = \alpha X_{i0}^* + \beta_1 X_{i1}^* + \dots + \beta_k X_{ik}^* + \epsilon_i^*$$

In questa versione $\text{Var}(\epsilon_i^*|X) = \sigma^2$ (errori omoschedastici) e quindi gli stimatori OLS forniscono stimatori **BLUE**.

(slide 13–15)

5.6. Feasible Generalized Least Squares (FGLS)

Definizione 5.3. Applicare OLS alla regressione ausiliaria (Y^*) fornisce risultati diversi rispetto agli OLS standard: WLS è un caso speciale del metodo **Generalized Least Squares (GLS)**. Tuttavia, per applicare WLS/GLS è necessario conoscere i coefficienti δ_j , il che in generale non è ovvio. Una possibile soluzione si basa sul **Feasible Generalized Least Squares (FGLS)**, in cui $\tilde{\sigma}_i$ è stimato tramite OLS.

Si ricordi che la media condizionale di Y è

$$E(Y|X) = \alpha + \beta_1 X_1 + \dots + \beta_k X_k$$

Definiamo un modello che descriva $\text{Var}(Y|X)$. Intuitivamente, possiamo definire questa varianza come

$$\text{Var}(Y|Z_1, \dots, Z_m) = E[\epsilon^2|X] = g(Z_1, \dots, Z_m), \quad g(\cdot) > 0$$

Un'ipotesi ragionevole, ad esempio, è

$$\epsilon^2 = \sigma^2 \exp\{\delta_0 + \delta_1 Z_1 + \dots + \delta_m Z_m\} \nu$$

Consideriamo dunque il modello completo per le medie e le varianze condizionate:

$$Y_i = \alpha + \beta_1 X_{i1} + \dots + X_{ik} + \epsilon_i$$

$$\epsilon^2 = \sigma^2 \exp\{\delta_0 + \delta_1 Z_1 + \dots + \delta_m Z_m\} \nu$$

Un procedimento ragionevole per calcolare $\hat{\sigma}_i$ è il seguente:

1. Regredire Y su $X_1, \dots, X_k$ e calcolare $\hat{\epsilon}$;
2. Calcolare $\log(\hat{\epsilon}^2)$;
3. Regredire $\log(\hat{\epsilon}^2)$ su $Z_1, \dots, Z_m$;
4. Calcolare $\hat{g} = \widehat{\log(\hat{\epsilon}^2)}$ e $\hat{\sigma}_i = \exp\{\hat{g}/2\}$;
5. Utilizzare $\hat{\sigma}_i$ per calcolare lo stimatore WLS.

(slide 16–18)

5.7. Stimatori robusti: l'idea di White (Huber-Heicker) nel modello semplice

Dimostrazione. Gli stimatori robusti sono un insieme di procedure che permettono di valutare gli standard error in maniera corretta, indipendentemente dall'ipotesi fatta su omoschedasticità od eteroschedasticità. L'idea si basa sull'intuizione che gli stimatori OLS forniscono stimatori consistenti dei parametri ($\hat{\beta}_j \xrightarrow{p} \beta_j$) e non distorti, **indipendentemente dall'ipotesi che facciamo sulle varianze condizionali**.

Come calcolare gli standard error in presenza di eteroschedasticità? Per semplificare, si consideri il modello di regressione semplice

$$Y = \alpha + \beta X + \epsilon$$

Lo stimatore può essere espresso come funzione di ϵ , come al solito:

$$\hat{\beta} = \beta + \frac{\sum_{i=1}^n (X_i - \bar{X}) \epsilon_i}{\sum_{i=1}^n (X_i - \bar{X})^2}$$

Nel caso di regressione multipla, otteniamo

$$\hat{\beta} = (X'X)^{-1}X' \underset{=X\beta+\epsilon}{Y} = \beta + (X'X)^{-1}X'\epsilon$$

Vera varianza condizionale. Si vuole stimare la vera varianza condizionale di $\hat{\beta}$, cioè

$$\text{Var}(\hat{\beta}|X) = \frac{\sum_{i=1}^n \overset{\text{Var}(\epsilon_i|X)}{\widetilde{\sigma}_i^2} (X_i - \bar{X})^2}{\left[\sum_{i=1}^n (X_i - \bar{X})^2\right]^2}$$

L'idea di White (1980) è piuttosto semplice: dato che $\hat{\epsilon}_i$ è un'approssimazione di ϵ_i , allora $\hat{\epsilon}_i^2(X_i - \bar{X})^2$ è uno stimatore ragionevole per $E[\epsilon_i^2(X_i - \bar{X})^2|X] = \sigma_i^2(X_i - \bar{X})^2$. White ha proposto:

$$\widehat{\text{Var}}(\hat{\beta}|X) = \frac{\sum_{i=1}^n (X_i - \bar{X})^2 \hat{\epsilon}_i^2}{\left[\sum_{i=1}^n (X_i - \bar{X})^2\right]^2}$$

... e ha anche dimostrato che $\widehat{\text{Var}}(\hat{\beta}|X)$ è **consistente** per $\text{Var}(\hat{\beta}|X)$.

Intuizione del risultato. Nel modello di regressione semplice:

$$\hat{\epsilon}_i = Y_i - \hat{Y}_i = \underbrace{\alpha + \beta X_i + \epsilon_i}_{Y_i} - \underbrace{(\hat{\alpha} + \hat{\beta} X_i)}_{\hat{Y}_i} = \underbrace{(\alpha - \hat{\alpha})}_{=0 \text{ se } n \rightarrow +\infty} + \underbrace{(\beta - \hat{\beta})}_{=0 \text{ se } n \rightarrow +\infty} X_i + \epsilon_i$$

Come conseguenza principale, abbiamo che asintoticamente

$$\frac{1}{n} \sum_{i=1}^n \hat{\epsilon}_i^2 (X_i - \bar{X})^2 \approx \frac{1}{n} \sum_{i=1}^n \epsilon_i^2 (X_i - \bar{X})^2$$

Nella pratica, questo risultato serve per trovare uno stimatore consistente di $\text{Var}(\hat{\beta}|X)$: se le due quantità sono equivalenti, lo saranno anche calcolando il limite per $n \rightarrow \infty$. Per la legge dei grandi numeri vale che

$$\begin{aligned} \frac{1}{n} \sum_{i=1}^n \epsilon_i^2 (X_i - \bar{X})^2 &\rightarrow E \left[\frac{1}{n} \sum_{i=1}^n \epsilon_i^2 (X_i - \bar{X})^2 \right] = \frac{1}{n} \sum_{i=1}^n \sigma_i^2 (X_i - \bar{X})^2 \\ &\Rightarrow \frac{1}{n} \sum_{i=1}^n \hat{\epsilon}_i^2 (X_i - \bar{X})^2 \rightarrow \frac{1}{n} \sum_{i=1}^n \sigma_i^2 (X_i - \bar{X})^2 \end{aligned}$$

□

(slide 20-23)

5.8. Stimatori robusti: caso di regressione multipla e sintesi

Dimostrazione. Nel caso di regressione multipla

$$Y = \alpha + \beta_1 X_1 + \dots + \beta_k X_k + \epsilon$$

si può dimostrare che

$$\widehat{\text{Var}}(\hat{\beta}_j|X) = \frac{\sum_{i=1}^n \hat{r}_{ij}^2 \epsilon_i^2}{\left[\sum_{i=1}^n (X_{ij} - \bar{X}_j)^2\right]^2} \quad j = 1, \dots, k$$

in cui $\hat{r}_{ij}$ è una stima del residuo i -esimo ottenuta dalla regressione di X_j su tutti gli altri regressori:

$$X_j = \alpha_0 + \alpha_1 X_1 + \dots + \alpha_{j-1} X_{j-1} + \alpha_{j+1} X_{j+1} + \dots + \alpha_k X_k + u$$

Usando la notazione matriciale, si consideri la matrice diagonale varianza-covarianza Σ :

$$E[\epsilon\epsilon'] = \Sigma_{n \times n} = \begin{pmatrix} \sigma_1^2 & 0 & \dots & 0 \\ 0 & \sigma_2^2 & 0 & \dots \\ \vdots & \vdots & \vdots & \vdots \\ 0 & \dots & \dots & \sigma_n^2 \end{pmatrix}$$

Si può facilmente dimostrare che

$$\text{Var}(\hat{\beta}|X) = (X'X)^{-1} X' E[\epsilon\epsilon'] X (X'X)^{-1}$$

Come risultato generale, White ha dimostrato che uno stimatore consistente di $\frac{X'\Sigma X}{n}$ è $\frac{X'\hat{\Sigma} X}{n}$, in cui gli elementi diagonali di $\hat{\Sigma}$ sono stimati attraverso $\hat{\sigma}_i^2 = \hat{\epsilon}_i^2$.

Sintesi. Gli stimatori OLS $\hat{\sigma}_{\hat{\beta}_j}$ calcolati sotto l'ipotesi di omoschedasticità non sono adatti quando questa ipotesi non è soddisfatta. Tuttavia, gli stimatori OLS sono consistenti e non distorti a prescindere, e quindi anche $\hat{\epsilon}$ è una misura ragionevole per ϵ : White-(Huber-Heicker) sfruttano questa proprietà per correggere il calcolo dell'errore standard.

Principali vantaggi:

- Nessuna ipotesi viene fatta sulla varianza condizionale: il metodo funziona in caso di omoschedasticità o di qualsiasi tipo di eteroschedasticità (**flessibilità**);
- OLS è ancora valido (**semplicità d'uso**).

D'altra parte, $\hat{\beta}_j$ **non è più BLUE**. □

(slide 24-26)

5.9. Test robusti all'eteroschedasticità: t e F

Definizione 5.4. Il Test t . Le statistiche t , costruite utilizzando gli errori standard robusti, si calcolano in maniera identica al caso omoschedastico. L'unica differenza è il denominatore, che deve essere calcolato in modo robusto (attraverso la formula di White). Quindi, la statistica t robusta è:

$$t = \frac{\hat{\beta} - \text{valore sotto } H_0}{\text{errore standard robusto}}$$

Il Test F . Il calcolo della versione robusta delle statistiche F è complicato. Tuttavia, molti software consentono di calcolarlo in modo automatico, una volta che gli errori standard sono stati stimati mediante metodi robusti (ad esempio, GRETL, STATA).

(slide 27)

5.10. Test per l'eteroschedasticità: principi generali e Test di Breusch-Pagan

Teorema 5.1. Principi generali. In generale, le procedure robuste sono preferibili, poiché consentono di calcolare i test t ed F senza dover fare alcuna ipotesi su $\text{Var}(Y|X)$. Tuttavia, l'utilizzo degli errori standard robusti in caso di omoschedasticità è inefficiente: lo standard error non è più il minimo. Talvolta può essere utile costruire test per validare l'ipotesi di omoschedasticità: se si rifiutasse questa ipotesi converrebbe implementare procedure robuste, altrimenti può essere utilizzato OLS classico.

IMPORTANTE: tutti i test per verificare l'ipotesi di omoschedasticità (ipotesi nulla) rispetto all'eteroschedasticità (ipotesi alternativa) **non accettano l'ipotesi nulla**, ma al più permettono di rifiutarla. In generale, questi test si basano su una definizione della forma funzionale per l'eteroschedasticità, che viene confrontata con l'ipotesi di omoschedasticità.

Test di Breusch-Pagan. Si consideri il solito modello di regressione multipla

$$Y = \alpha + \beta_1 X_1 + \dots + \beta_k X_k + \epsilon$$

e si ipotizzi che la varianza condizionata sia

$$E[\epsilon^2|\mathbf{X}] = \delta_0 + \delta_1 X_1 + \dots + \delta_k X_k$$

che porta al seguente modello di regressione

$$\epsilon^2 = \delta_0 + \delta_1 X_1 + \dots + \delta_k X_k + u$$

Se tutti i coefficienti fossero nulli, i.e. $\delta_j = 0$, allora

$$H_0 : \text{Var}(\epsilon|X_1, \dots, X_k) = E[\epsilon^2|X_1, \dots, X_k] = \sigma^2$$

L'ipotesi nulla di omoschedasticità può essere verificata attraverso il seguente sistema di ipotesi

$$H_0 : \text{Var}(\epsilon|X) = \sigma^2 \Leftrightarrow H_0 : \delta_1 = \delta_2 = \dots = \delta_k = 0 \quad \text{vs.} \quad H_1 : \text{almeno un coefficiente non è zero}$$

Questo test è molto simile a un test F . Ovviamente, ϵ^2 non è osservabile, tuttavia può essere approssimato attraverso $\hat{\epsilon}^2$. Il modello ridotto (sotto H_0) è

$$\hat{\epsilon}^2 = \delta_0 + \text{err} \Rightarrow R_c^2 = 0$$

La statistica test risulta quindi

$$F_{k,n-k-1} = \frac{R_{\hat{\epsilon}^2}^2/k}{(1 - R_{\hat{\epsilon}^2}^2)/(n - k - 1)}$$

Questo test può essere calcolato in un modo leggermente diverso, chiamato **test di Breusch-Pagan** per l'eteroschedasticità:

$$T_{BP} = nR_{\hat{\epsilon}^2}^2$$

Rispetto alla statistica F , T_{BP} è approssimativamente distribuito come una χ_k^2 .

Esempio (Gretl). Il test di Breusch-Pagan può essere implementato tramite Gretl come segue: si stima la regressione di interesse, poi dalla finestra di output si sceglie il menu **Test -> LMTEST - Eteroschedasticità -> Breusch-Pagan**. L'output finale è:

```
Test di Breusch-Pagan per l'eteroschedasticità -
Ipotesi nulla: eteroschedasticità non presente
Statistica test: LM = 30,0227
con p-value = P(Chi-quadro(3) > 30,0227) = 1,36495e-06
```

In questo caso si rifiuta l'ipotesi nulla di omoschedasticità poiché il p-value è piccolo.

(slide 28-32)

5.11. Test di White

Teorema 5.2. Probabilmente il test più comune per i dati cross-sectional è dovuto a White, anche se si basa sulla stessa idea del test di Breusch-Pagan. Il test è costruito mediante la regressione del residuo quadratico. Ad esempio, se si considera un modello con $k = 3$ regressori:

$$\hat{\epsilon}^2 = \delta_0 + \delta_1 X_1 + \delta_2 X_2 + \delta_3 X_3 + \delta_4 X_1^2 + \delta_5 X_2^2 + \delta_6 X_3^2 + \delta_7 X_1 X_2 + \delta_8 X_1 X_3 + \delta_9 X_2 X_3 + \text{errore} \quad (1)$$

Il test di White per l'eteroschedasticità si basa sulla valutazione dell'ipotesi $H_0 : \delta_1 = \dots = \delta_9 = 0$, che se rifiutata produce evidenza in favore dell'eteroschedasticità.

Come per il test di Breusch-Pagan, il test di White può essere calcolato come segue:

$$T_W = nR_{\hat{\epsilon}^2}^2 \sim \chi_{\# \text{vincoli}}^2$$

in cui $R_{\varepsilon_2}^2$ è la bontà di adattamento della regressione ausiliaria completa in eq. (1).

Esempio (Gretl). Si consideri l'esempio sul pricing delle case. Il test di White si ottiene stimando la regressione di interesse e scegliendo, dalla finestra di output, il menu **Test -> LMTEST - Eteroschedasticità -> Test di White**. L'output fornito da Gretl è:

```
Test di White per l'eteroschedasticità -
Ipotesi nulla: eteroschedasticità non presente
Statistica test: LM = 33,7317
con p-value = P(Chi-quadro(9) > 33,7317) = 9,95294e-05
```

Anche in questo caso il test rifiuta l'ipotesi nulla di omoschedasticità.

Stima con errori standard robusti in Gretl. Stimare gli errori standard robusti tramite Gretl è facile: è sufficiente, in sede di definizione del modello, spuntare l'opzione *Errori Standard Robusti*. Dato che si rifiuta l'ipotesi nulla, è necessario stimare la regressione OLS mediante errori standard robusti. La procedura robusta restituisce i seguenti risultati:

Linear regression	Number of obs =	88
	F(3, 84) =	23.72
	Prob > F =	0.0000
	R-squared =	0.6724
	Root MSE =	59.833

price	Coef.	Robust Std. Err.	t	P> t	[95% Conf. Interval]
sqrft	.1227782	.0177253	6.93	0.000	.0875294 .158027
bdrms	13.85252	8.478625	1.63	0.106	-3.008154 30.7132
lotsize	.0020677	.0012514	1.65	0.102	-.0004209 .0045563
_cons	-21.77031	37.13821	-0.59	0.559	-95.62371 52.0831

(slide 33-36)

6 | Introduzione ai Modelli Dinamici

Fonte: ECON_Teoria_06_Modelli-Dinamici.pdf — 108 slide

6.1. Introduzione alle serie storiche

In econometria si fa largo uso di dati di serie storica, cioè osservazioni su una o più variabili economiche raccolte nel tempo. La loro utilità è evidente pensando a come gli eventi economici siano caratterizzati da aspetti dinamici: il passato contribuisce a determinare, almeno in parte, il presente e, di conseguenza, nella spiegazione ed interpretazione dei fatti economici un ruolo molto importante è assunto dalla componente temporale. Per questo motivo in econometria sono stati sviluppati molteplici modelli dinamici con l'obiettivo di catturare questo aspetto. I dati di serie storica sono ordinabili in modo oggettivo e universalmente accettato.

Questi dati sono molto diversi dai dati in cross-section: si tratta di dati **dipendenti**, cioè di osservazioni relative a un'unica entità che si protraggono nel tempo. (slide 2)

6.2. Definizione di processo stocastico e serie storica

Definizione 6.1. In termini semplicistici, un **processo stocastico** è definito come una sequenza di variabili casuali Y_t indicizzate da un indice t . Nel corso, t appartiene all'insieme dei numeri naturali $(0, 1, \dots, t, \dots)$.

Si assume che ognuna delle osservazioni sia descritta da una variabile casuale Y_t per cui: - la media marginale di ogni Y_t è $E[Y_t] = \mu_t$; - la varianza marginale di ogni Y_t è $\text{Var}(Y_t) = \sigma_t^2$; - l'**autocorrelazione** tra due qualsiasi elementi del processo è

$$\text{Corr}(Y_t, Y_s) = \frac{E[(Y_t - \mu_t)(Y_s - \mu_s)]}{\sqrt{\sigma_t^2 \sigma_s^2}}.$$

Una **serie storica** è una sequenza finita di variabili casuali in cui l'indice $t = 1, \dots, T$ indica il tempo. Spesso con “serie storica” si intende anche la traiettoria osservata del processo stocastico.




Figura 1 — Esempio di serie storica: Fed funds mensili osservati da luglio 1954 ad ottobre 2022. Il grafico mostra l'andamento del tasso di riferimento della Federal Reserve nel tempo, con marcati periodi di crescita (fine anni '70 - primi '80, con un picco vicino al 20%) e di successiva discesa fino a valori prossimi allo zero.




Figura 2 — Stima della distribuzione di probabilità dei tassi per decenni. Si nota che la distribuzione di Y_t tende a cambiare nel tempo (forma e posizione delle distribuzioni stimate cambiano decade per decade), per cui risulta difficile ipotizzare che le osservazioni siano identicamente distribuite.

(slide 3–5)

6.3. Notazione: ritardi, differenza prima, variazione percentuale

Definizione 6.2. Si consideri la variabile Y che si assume osservabile nel tempo: - Y_t è la realizzazione della variabile osservata al tempo t , $t = 1, \dots, T$; - Y_{t-j} è il ritardo j -esimo di Y_t ; - la **differenza prima** di una variabile Y_t è definita da

$$\Delta Y_t = Y_t - Y_{t-1};$$

- la **variazione percentuale** della serie Y_t tra i periodi t e $t-1$ è

$$100 \times \Delta \log Y_t = 100(\log Y_t - \log Y_{t-1}) \approx 100 \times \frac{\Delta Y_t}{Y_{t-1}}.$$

Infatti, sapendo che $\log(X+a) - \log X \approx a/X$ se $a \rightarrow 0$, si ha che

$$100 \times [\log Y_t - \log Y_{t-1}] = 100 \times [\log(Y_{t-1} + \Delta Y_t) - \log Y_{t-1}] \approx 100 \times \frac{\Delta Y_t}{Y_{t-1}}, \quad \text{se } \Delta Y_t \rightarrow 0.$$

(slide 6)

6.4. La trasformazione logaritmica e la stabilizzazione della varianza

Dimostrazione. Nell'analisi empirica spesso accade che, invece di analizzare la serie storica originale, risulti più conveniente considerare opportune trasformazioni monotone crescenti del tipo $Y_t = T(Z_t)$. In molti casi una trasformazione logaritmica consente di **stabilizzare la varianza** della serie trasformata.

Si consideri la trasformazione generica $Y_t = T(Z_t)$ e il suo sviluppo in serie di Taylor al primo ordine attorno alla media di Z_t , cioè μ_t :

$$T(Z_t) \approx T(\mu_t) + T'(\mu_t)(Z_t - \mu_t).$$

Dimostrazione. Si consideri una serie storica Z_t la cui varianza sia proporzionale alla media, cioè $\text{Var}(Z_t) = \sigma_t^2 = c\mu_t^2$, con c costante positiva. Questa condizione si verifica frequentemente in molte serie storiche macroeconomiche e finanziarie.

Considerando $Y_t = T(Z_t) = \log(Z_t)$, per cui $T'(\mu_t) = 1/\mu_t$, si ottiene

$$\text{Var}(Y_t) = \text{Var}(T(\mu_t) + T'(\mu_t)(Z_t - \mu_t)) = 0 + \frac{1}{\mu_t^2} \underbrace{\text{Var}(Z_t)}_{\text{per ip. } \sigma_t^2 = c\mu_t^2} = c \frac{1}{\mu_t^2} \mu_t^2 = c.$$

Quindi la varianza della serie trasformata $Y_t = \log(Z_t)$ non dipende più da t : la trasformazione logaritmica ha stabilizzato la varianza. $\square$

(slide 7-8)

6.5. Distribuzioni condizionali e distribuzione congiunta

Definizione 6.3. I modelli per le serie storiche descrivono, come tutti i modelli di regressione, l'evoluzione delle **medie condizionali**. Rispetto ai modelli di regressione classica, hanno anche come obiettivo quello di misurare la relazione esistente tra presente e passato di una certa variabile.

Più in generale, lo scopo dei modelli per le serie storiche è approssimare le **distribuzioni condizionali** dei dati; in particolare cercano di approssimare

$$p(Y_t|X_t) = p(Y_t|Y_{t-1}, Y_{t-2}, Y_{t-3}, \dots).$$

La distribuzione condizionale descrive, da un punto di vista statistico, il comportamento della variabile Y_t una volta che si osserva tutto quello che è successo prima, avendo quindi informazioni esatte su $Y_{t-1}, Y_{t-2}, \dots$ fino a Y_1 .

In un'ottica di stima di massima verosimiglianza, tutte le distribuzioni condizionali contribuiscono a definire la **distribuzione congiunta**, cioè la distribuzione di probabilità dei dati nel loro insieme, $p(Y_1, Y_2, \dots, Y_T)$. In generale, la distribuzione congiunta si ottiene come prodotto delle distribuzioni condizionali:

$$p(Y_1, Y_2, \dots, Y_T) = p(Y_1)p(Y_2|Y_1) \dots p(Y_t|Y_{t-1}, Y_{t-2}, \dots, Y_1) \dots p(Y_T|Y_{T-1}, \dots, Y_1).$$

(slide 9-10)

6.6. Esempio: verosimiglianza di un modello AR(1) Normale

Esempio 6.1. Si consideri il modello di regressione

$$Y_t = \alpha + \beta Y_{t-1} + \epsilon_t,$$

che suggerisce che il dato odierno Y_t dipenda dall'osservazione misurata nel periodo precedente, Y_{t-1} , più uno shock ϵ_t che misura una variazione della variabile dipendente oggi, non predicibile. Ad esempio ϵ_t può essere una variabile casuale con media 0 e varianza σ^2 .

In questo caso il generico regressore X_t coincide con la variabile Y osservata al periodo precedente, cioè Y_{t-1} . La distribuzione condizionale è descritta dalle seguenti medie e varianze: - media condizionale: $E[Y_t|Y_{t-1}, Y_{t-2}, \dots] = \alpha + \beta Y_{t-1}$; - varianza condizionale: $\text{Var}[Y_t|Y_{t-1}, Y_{t-2}, \dots] = \sigma^2$.

Ipotizzando che ϵ_t sia una v.c. Normale con media 0 e varianza σ^2 , si ottiene

$$p(Y_t|Y_{t-1}, Y_{t-2}, \dots, Y_1) \sim N\left(\underbrace{\alpha + \beta Y_{t-1}}_{E[Y|X]}, \underbrace{\sigma^2}_{\text{Var}[Y|X]}\right).$$

Di conseguenza la funzione di verosimiglianza è

$$p(Y_1, \dots, Y_T) = p(Y_1)p(Y_2|Y_1)p(Y_3|Y_2) \dots p(Y_T|Y_{T-1}) \\ \propto \prod_{t=2}^T \frac{1}{\sigma\sqrt{2\pi}} \exp\left[-\frac{1}{2\sigma^2}(Y_t - \alpha - \beta Y_{t-1})^2\right] = \frac{1}{(2\pi\sigma^2)^{T/2}} \exp\left\{-\frac{\sum_{t=2}^T (Y_t - \alpha - \beta Y_{t-1})^2}{2\sigma^2}\right\}.$$

(slide 11-12)

6.7. La distribuzione marginale

Definizione 6.4. Scopo dell'analisi statistica delle serie storiche è descrivere **come** la distribuzione condizionale della variabile dipendente evolve nel tempo. La distribuzione condizionale non deve essere confusa con quella marginale, che descrive la variabile Y al netto del fattore tempo.

La distribuzione marginale di Y_t può essere calcolata dalla distribuzione congiunta di Y_t e Y_{t-1} sommando le probabilità di tutti i possibili risultati per i quali Y assume un valore specifico. Se Y_{t-1} potesse assumere k valori diversi $y_1, \dots, y_k$, allora la probabilità marginale che Y_t assuma il valore y è

$$p(Y_t = y) = \sum_{i=1}^k \Pr(Y_t = y, Y_{t-1} = y_i).$$

(slide 13)

6.8. Esempio: distribuzioni marginale e condizionale nell'albero binomiale

Esempio 6.2. Si consideri un modello statistico, detto **albero binomiale**, che cerca di approssimare l'andamento di una serie storica finanziaria; è utilizzato di solito nel *pricing* di titoli derivati.

Si consideri la variabile S che descrive il prezzo nel tempo di una *security*. Si ipotizzi che oggi (giorno 0) il prezzo sia 4\$. Il giorno 1 il prezzo può raddoppiare (evento H) con probabilità 0.4, o dimezzarsi (evento T) con probabilità 0.6. Lo stesso accade per il giorno 2. S_0, S_1, S_2 sono le variabili che descrivono il prezzo nei tre giorni analizzati.




Figura 3 — Esempio di albero binomiale: da $S_0 = 4$ si diramano $S_1(H) = 8$ e $S_1(T) = 2$; da $S_1(H) = 8$ si diramano $S_2(HH) = 16$ e $S_2(HT) = 4$; da $S_1(T) = 2$ si diramano $S_2(TH) = 4$ e $S_2(TT) = 1$. Il grafico mostra tutte le traiettorie possibili del prezzo nei due giorni successivi ad oggi, con le relative probabilità di transizione (0.4 per il ramo “raddoppia”, 0.6 per il ramo “dimezza”).

La **distribuzione condizionale** tra un giorno è

$$p(S_1 = s_1 | S_0 = 4) = \begin{cases} s_1 = 8, & p = 0.4 \\ s_1 = 2, & p = 0.6 \end{cases}$$

Le **distribuzioni condizionali** tra due giorni risultano

$$p(S_2 = s_2 | S_1 = 8) = \begin{cases} s_2 = 16, & p = 0.4 \\ s_2 = 4, & p = 0.6 \end{cases} \quad p(S_2 = s_2 | S_1 = 2) = \begin{cases} s_2 = 4, & p = 0.4 \\ s_2 = 1, & p = 0.6 \end{cases}$$

La **distribuzione marginale** dopo il primo giorno è

$$p(S_1 = s_1) = \begin{cases} s_1 = 8, & p = 0.4 \\ s_1 = 2, & p = 0.6 \end{cases}$$

La **distribuzione marginale** tra due giorni risulta quindi

$$p(S_2 = s_2) = \begin{cases} s_2 = 16, & p = 0.4^2 \\ s_2 = 4, & p = 0.4 \times 0.6 + 0.6 \times 0.4 \\ s_2 = 1, & p = 0.6^2 \end{cases}$$

si ottengono così i valori numerici $p(S_2 = 16) = 0.16$, $p(S_2 = 4) = 0.48$, $p(S_2 = 1) = 0.36$, che sommano correttamente a 1. Si noti la differenza concettuale rispetto alle distribuzioni condizionali sopra riportate: la marginale “integra via” l’informazione su S_1 .

(slide 14–17)

6.9. Autocorrelazione: definizione, ACF e PACF

Definizione 6.5. Nelle serie temporali è lecito aspettarsi che il valore di Y al tempo t sia dipendente dal proprio valore nel periodo successivo. La correlazione di una serie con i propri valori ritardati è detta **autocorrelazione** (o correlazione seriale): è la dipendenza lineare tra le realizzazioni di una variabile osservata in due istanti temporali diversi.

Se, ad esempio, esiste un’autocorrelazione positiva, ci si aspetta che se $Y_{t-1} > 0$, in media, anche Y_t tenderà ad assumere valori positivi; oppure, al contrario, un’osservazione negativa sarà seguita da un’altra osservazione negativa.

Si definisce la j -esima autocorrelazione ρ_j come

$$\rho_j = \frac{\text{Cov}(Y_t, Y_{t-j})}{\sqrt{\text{Var}(Y_t)\text{Var}(Y_{t-j})}}.$$

Lo stimatore della covarianza è

$$\widehat{\text{Cov}}(Y_t, Y_{t-j}) = \frac{1}{T-j-1} \sum_{t=j+1}^T (Y_t - \bar{Y}_{j+1,T})(Y_{t-j} - \bar{Y}_{1,T-j}),$$

dove $\bar{Y}_{j+1,T}$ è la media campionaria calcolata sulle osservazioni $t = j+1, \dots, T$. Quindi lo stimatore della correlazione, **nell’ipotesi che** $\text{Var}(Y_t) = \text{Var}(Y_{t-j})$, è

$$\hat{\rho}_j = \frac{\widehat{\text{Cov}}(Y_t, Y_{t-j})}{\widehat{\text{Var}}(Y_t)}.$$

La **funzione di autocorrelazione (ACF)** descrive in maniera sintetica la struttura di correlazione tra Y_t ed Y_{t-j} , indicata con ρ_j per qualsiasi $j \geq 1$. Una rappresentazione grafica di tale dipendenza al variare di j è detta **correlogramma**.

Il coefficiente di **autocorrelazione parziale** misura la dipendenza di Y_t da Y_{t-j} al netto dei valori intermedi $Y_{t-1}, \dots, Y_{t-j+1}$. La **funzione di autocorrelazione parziale (PACF)** descrive in maniera sintetica la sequenza di queste statistiche al variare di j .




Figura 4 — Dipendenza tra Y_t e Y_{t-j} , $j = 1, 2, 3, 4$ (serie “ar3”): quattro scatterplot di Y_t contro i propri ritardi mostrano che la nuvola di punti è più “allineata” (correlata) per ritardi bassi e diventa più dispersa (meno correlata) all’aumentare del ritardo.




Figura 5 — Correlogramma della serie Y_t (ar3): l’ACF mostra valori significativi ai primi ritardi che decrescono, mentre la PACF mostra picchi significativi solo ai primi ritardi (coerente con un processo autoregressivo di ordine basso); le bande tratteggiate rappresentano i limiti di significatività $\pm 1.96/\sqrt{T}$.

6.10. Il test di Ljung-Box per l'autocorrelazione

Teorema 6.1. La struttura di autocorrelazione di una serie storica fornisce importanti informazioni, utili (i) per identificare un modello appropriato per i dati e (ii) per verificare se il modello proposto è corretto. È quindi importante controllare se le osservazioni presentano un'autocorrelazione seriale significativa. Tale verifica si basa sullo studio delle autocorrelazioni campionarie $\hat{\rho}_j$, $j = 1, 2, \dots$, che al variare del ritardo j descrivono l'**autocorrelogramma**.

Si dimostra che, sotto opportune ipotesi,

$$\sqrt{T} \hat{\rho}_j \rightarrow N(0, 1).$$

Quindi, per verificare l'ipotesi nulla $H_0 : \rho_j = 0$ si può usare la statistica $\sqrt{T} \hat{\rho}_j$ e calcolare l'opportuno p-value con la distribuzione $N(0, 1)$.

Molto spesso si è interessati a verificare ipotesi più complesse, ad esempio l'ipotesi nulla congiunta $H_0 : \rho_1 = \rho_2 = \dots = \rho_j = 0$, cioè che le prime j correlazioni siano nulle. Il **test di Ljung-Box** si basa sulla statistica

$$Q_{LB}(j) = T(T+2) \sum_{i=1}^j \frac{\hat{\rho}_i^2}{T-i} \rightarrow \chi_j^2,$$

ed è quindi possibile calcolare l'opportuno p-value.




Figura 6 — Esempio di autocorrelogramma (serie “linvpc”): evidenzia la dipendenza tra un’osservazione della serie ed i suoi ritardi; sia ACF che PACF mostrano un picco marcato al primo ritardo, superiore alle bande di significatività.

Esempio numerico — Funzione di autocorrelazione per y_t per 12 ritardi:

LAG	ACF	Q-stat.	[p-value]
1	0.5941 ***	15.1699	[0.000]
2	0.1864	16.6981	[0.000]
3	-0.0987	17.1372	[0.001]
4	-0.0255	17.1674	[0.002]
5	0.1031	17.6713	[0.003]
6	0.1613	18.9365	[0.004]
7	0.2280	21.5325	[0.003]
8	0.1696	23.0087	[0.003]
9	0.1315	23.9214	[0.004]
10	0.0556	24.0896	[0.007]
11	0.0110	24.0964	[0.012]
12	0.0475	24.2268	[0.019]

Tutti i p-value della statistica $Q_{LB}(j)$ sono molto piccoli (≤ 0.019): si rifiuta l'ipotesi nulla di assenza di autocorrelazione fino al ritardo 12.

(slide 23–26)

6.11. Modelli statici e il Capital Asset Pricing Model (CAPM)

Esempio 6.3. Il primo esempio di regressione statica riguarda la regressione semplice tra due variabili Y ed X in cui la relazione è definita da

$$Y_t = \beta_0 + \beta_1 X_t + \epsilon_t, \quad t = 1, \dots, T.$$

Il nome “statico” deriva dal fatto che si modella una relazione **contemporanea** tra le due grandezze. Questi modelli descrivono relazioni di lungo periodo, situazioni in cui l'economia si ipotizza essere in equilibrio. Sono proposti quando sembra ragionevole ipotizzare che X abbia un impatto immediato su Y ; quindi, se $\Delta\epsilon_t = 0$, si può scrivere

$$\Delta Y_t = \beta_1 \Delta X_t.$$

Esempio: il CAPM. Un'idea rilevante della finanza moderna è che un investitore ha bisogno di un incentivo finanziario per assumere un rischio, cioè il rendimento atteso rischioso dovrebbe sempre essere maggiore di quello non rischioso. Il CAPM formalizza l'idea che il rischio dell'investimento è legato al rischio del mercato, approssimato tramite un **portafoglio di mercato**. Il CAPM si basa sulla relazione

$$r_t - r_f = \beta(r_{mt} - r_f) + \epsilon_t,$$

in cui r_t ed r_{mt} sono i rendimenti di un titolo rischioso e del portafoglio di mercato al tempo t , mentre r_f è il rendimento di un titolo risk-free.




Figura 7 — Serie storiche del rendimento dell'indice Standard & Poor's 500 (portafoglio di mercato) e del titolo rischioso Boeing Co., dal 1996 al 2006: le due serie mostrano un andamento comoviente, con la volatilità di Boeing generalmente amplificata rispetto a quella dell'indice.

Stime OLS usando le 130 osservazioni 1996:02-2006:11, variabile dipendente: return_ba

VARIABILE	COEFFICIENTE	ERRORE STD	STAT T	P-VALUE
return_sp	0.781803	0.161229	4.849	<0.00001 ***

Media della variabile dipendente = 0.729731; Deviazione standard della variabile dipendente = 8.77071; Somma dei quadrati dei residui = 8452.02; Errore standard dei residui = 8.09441; R-quadro = 0.154171; R-quadro corretto = 0.154171; Statistica F (1, 129) = 23.5132 (p-value < 0.00001); Statistica Durbin-Watson = 1.92748.

Un titolo con β minore di 1 risulta meno rischioso rispetto al portafoglio di mercato e ha quindi un eccesso di rendimento atteso minore rispetto al portafoglio stesso. In pratica, un incremento dell'1% al tempo t dell'eccesso di rendimento del portafoglio di mercato (S&P500) causa un incremento dello 0.78% del rendimento di Boeing.

Il valore di

$$R^2 = \frac{\hat{\beta}_i^2 \hat{\sigma}_M^2}{\hat{\sigma}_i^2} = 0.15$$

può essere interpretato come la percentuale di rischio sistematico sul rischio complessivo.

(slide 27-31)

6.12. Motivazioni per la specificazione dinamica dei modelli

In econometria esistono almeno due ragioni fondamentali che giustificano il ricorso alla specificazione dinamica dei modelli. - Da un lato vi è l'esigenza di giungere ad una migliore comprensione del funzionamento nel tempo del sistema oggetto di studio, differenziando, ad esempio, il

comportamento di breve periodo da quello di lungo periodo. - Dall'altro lato vi può essere la necessità di disporre di un modello che, utilizzando osservazioni provenienti da serie storiche, abbia caratteristiche idonee a produrre buone previsioni.

Quindi l'idea è considerare modelli che, oltre a relazioni statiche tra variabili, incorporino al loro interno relazioni tra variabili differite nel tempo, quindi dinamiche. (slide 32)

6.13. Il processo white noise

Definizione 6.6. Una successione di variabili aleatorie ϵ_t si dice **white noise** (o rumore bianco) se ha le seguenti proprietà:

$$E[\epsilon_t] = 0 \quad \forall t$$

$$E[\epsilon_t \epsilon_s] = \begin{cases} \sigma_\epsilon^2 & \text{se } t = s \\ 0 & \text{altrimenti.} \end{cases}$$

Questo modello in generale non è adeguato per descrivere dati reali, che come già accennato sono molto spesso dipendenti; viene tuttavia utilizzato spesso per definire il processo che descrive il termine di errore (in inglese *noise*) di modelli più generali.




Figura 8 — Esempio di dati generati da un modello White Noise: la serie oscilla in modo irregolare attorno a zero, senza pattern visibile, con ampiezza compresa circa tra -4 e 4 .




Figura 9 — Grafico dell'autocorrelogramma di un modello White Noise: sia l'ACF che la PACF non mostrano alcun valore significativamente diverso da zero a nessun ritardo, coerentemente con l'assenza di dipendenza seriale.

(slide 33–35)

6.14. Modelli a media mobile MA(1) e MA(q)

Definizione 6.7. Una semplice estensione del modello White Noise si ottiene facendo dipendere l'osservazione presente dagli shock passati. Questa categoria di modelli prende il nome di **Moving Average (MA)**. Il modello MA(1), in cui l'osservabile dipende esclusivamente dallo shock passato e da quello presente, è

$$Y_t = \alpha + \epsilon_t + \theta\epsilon_{t-1}, \quad \epsilon_t \sim WN(0, \sigma^2).$$

L'autocorrelogramma di Y_t si calcola come segue:

$$\text{Cov}(Y_t, Y_{t-j}) = \begin{cases} (1 + \theta)\sigma^2 & \text{se } j = 0 \\ \theta\sigma^2 & \text{se } j = 1 \\ 0 & \text{altrimenti.} \end{cases}$$

Dimostrazione. Si ricordi che la sequenza ϵ_t soddisfa $\text{Cov}(\epsilon_t, \epsilon_{t-j}) = 0$ per $j \geq 1$. Di conseguenza

$$\text{Cov}(Y_t, Y_{t-1}) = \text{Cov}(\alpha + \epsilon_t + \theta\epsilon_{t-1}, \alpha + \epsilon_{t-1} + \theta\epsilon_{t-2}) = \theta\sigma^2.$$

La correlazione a ritardi superiori a 1 risulta sempre nulla.




Figura 10 — Grafico di una serie storica MA(1) con $\theta = -0.7$ e $\sigma = 0.9$: la serie oscilla in modo irregolare, con un pattern leggermente più “liscio” rispetto al white noise puro a causa della dipendenza dal ritardo 1.

Generalizzazione: MA(q). L’osservazione di oggi dipende da q shock passati:

$$Y_t = \alpha + \epsilon_t + \theta_1 \epsilon_{t-1} + \dots + \theta_q \epsilon_{t-q}.$$

La media marginale è $E[Y_t] = \alpha$. La varianza marginale è

$$\text{Var}[Y_t] = \sigma^2(1 + \theta_1^2 + \dots + \theta_q^2).$$

In generale, la funzione di autocorrelazione di un modello MA(q) assume valori diversi da 0 solo ai primi q ritardi.

Esempio: MA(2). Si consideri $Y_t = \alpha + \epsilon_t + \theta_1 \epsilon_{t-1} + \theta_2 \epsilon_{t-2}$. La struttura di autocorrelazione si calcola come segue.

A ritardo 1:

$$\text{Cov}(Y_t, Y_{t-1}) = \text{Cov}(\epsilon_t + \theta_1 \epsilon_{t-1} + \theta_2 \epsilon_{t-2}, \epsilon_{t-1} + \theta_1 \epsilon_{t-2} + \theta_2 \epsilon_{t-3}) = \sigma^2 \theta_1 + \sigma^2 \theta_1 \theta_2 = \theta_1 \sigma^2 (1 + \theta_2).$$

A ritardo 2:

$$\text{Cov}(Y_t, Y_{t-2}) = \text{Cov}(\epsilon_t + \theta_1 \epsilon_{t-1} + \theta_2 \epsilon_{t-2}, \epsilon_{t-2} + \theta_1 \epsilon_{t-3} + \theta_2 \epsilon_{t-4}) = \sigma^2 \theta_2.$$

Per ritardi $j > 2$:

$$\text{Cov}(Y_t, Y_{t-j}) = \text{Cov}(\epsilon_t + \theta_1 \epsilon_{t-1} + \theta_2 \epsilon_{t-2}, \epsilon_{t-j} + \theta_1 \epsilon_{t-j-1} + \theta_2 \epsilon_{t-j-2}) = 0.$$




Figura 14 — Grafico di una serie storica di un modello MA(2) con $\theta_1 = -0.9, \theta_2 = 0.7, \sigma = 0.9$: la serie mostra oscillazioni più regolari rispetto al MA(1), riflesso della dipendenza da due shock passati.




Figura 15 — Autocorrelogramma del modello MA(2) precedente: sia l'ACF sia la PACF mostrano valori significativi solo ai primi due ritardi, coerentemente con la teoria.

(slide 36–38)

6.15. Esempio: il modello di Roll per il bid-ask spread (MA(1))

Esempio 6.4. Nel caso di applicazioni finanziarie, il modello MA(1) può essere interessante per descrivere l'andamento di un rendimento atteso in presenza di uno spread tra prezzi di domanda e di offerta.

In alcuni mercati (NYSE) i *market maker* forniscono liquidità comprando e vendendo quantità rilevanti di asset in maniera anonima, senza modificarne sostanzialmente il prezzo. In cambio si

riservano il diritto di vendere gli asset ad un prezzo leggermente maggiore rispetto a quello di acquisto. Essi acquistano un asset al prezzo *bid* P_b e cercano di venderlo al prezzo *ask* P_a ; la differenza $S = P_a - P_b$, detta **bid-ask spread**, è di solito piccola.

Si consideri la serie storica dei prezzi intra-giornalieri di un asset finanziario osservata per 15 giorni nel mercato NYSE.




Figura 12 — Prezzi intra-giornalieri dell'asset: la serie oscilla tra circa 1.04 e 1.24, con andamento a zig-zag rapido tipico dei dati ad alta frequenza intraday.

Modello di Roll (1984). Il prezzo osservato P_t di un asset al tempo t è

$$P_t = P_t^* + I_t \frac{S}{2} = P_t^* + \begin{cases} +S/2 & \text{con prob. } 0.5 \\ -S/2 & \text{con prob. } 0.5 \end{cases}$$

dove: $S = P_a - P_b$ è lo spread; P_t^* è il prezzo teorico (fondamentale) dell'asset in un mercato senza frizioni; I_t è una sequenza di variabili binarie con $P(I_t = -1) = P(I_t = 1) = 0.5$, interpretabile come indicatore del tipo d'ordine: +1 se la transazione è iniziata dall'acquirente, -1 se dal venditore.

Ipotizzando che il prezzo fondamentale non cambi, si calcola il rendimento

$$\Delta P_t = (I_t - I_{t-1}) \frac{S}{2}.$$

Si può facilmente dimostrare che: - $E[\Delta P_t] = 0$ (coerente con la teoria dei mercati efficienti); - $\text{Var}(\Delta P_t) = S^2/2$; - $\text{Cov}(\Delta P_t, \Delta P_{t-1}) = -S^2/4 \Rightarrow \text{Corr}(\Delta P_t, \Delta P_{t-1}) = -0.5$; - $\text{Cov}(\Delta P_t, \Delta P_{t-j}) = 0, \forall j > 1$.

Questo modello riproduce esattamente la struttura di autocorrelazione di un modello MA(1). Il bid-ask spread induce quindi una correlazione negativa a ritardo 1 nella serie osservata dei rendimenti: fenomeno chiamato in letteratura **bid-ask bounce**.

Intuizione. Ipotizzando $P_t^* = (P_a + P_b)/2$, il prezzo osservabile risulta essere P_a o P_b . Supponendo che il prezzo osservabile passato ($t-1$) sia P_a , oggi il prezzo sarà ancora P_a oppure

più basso (P_b). Come conseguenza:

$$\Delta P_t = \begin{cases} 0 & \text{con prob. } 0.5 \\ -S & \text{con prob. } 0.5 \end{cases}$$

L'autocorrelazione negativa a ritardo 1 (e non a ritardi successivi) viene introdotta in maniera evidente.




Figura 13 — Struttura di autocorrelazione (ACF e PACF) dei rendimenti calcolati sui dati di Figura 12: si osserva un unico valore negativo significativo al ritardo 1 nell'ACF, in linea con quanto atteso per un modello MA(1); la PACF mostra invece una struttura decrescente su più ritardi, tipica della rappresentazione AR di un processo MA.

Stima di massima verosimiglianza. I modelli MA si stimano tipicamente per massima verosimiglianza. Stima dei parametri del modello MA(1) $Y_t = \alpha + \theta\epsilon_{t-1} + \epsilon_t$:

Modello 2: MA, usando le osservazioni 1:002-124:017 ($T = 12316$). Stimato usando il filtro di Kalman (MV esatta). Variabile dipendente: rendimenti. Errori standard basati sull'Hessiana.

	coefficiente	errore std.	z	p-value
const	-8.20737e-06	9.22571e-06	-0.8896	0.3737
theta_1	-0.815431	0.00521480	-156.4	0.0000 ***

Media var. dipendente -8.80e-06; SQM var. dipendente 0.007132; Media innovazioni -7.63e-07; SQM innovazioni 0.005545; Log-verosimiglianza 46503.13; Criterio di Akaike -93000.26; Criterio di Schwarz -92978.01; Hannan-Quinn -92992.81. (Note: SQM = scarto quadratico medio; E.S. = errore standard)

(slide 39-46)

6.16. Modelli autoregressivi AR(1) e AR(p)

Definizione 6.8. Molto spesso i modelli specificati per dati di serie storica vengono utilizzati per fare previsioni su una variabile di interesse. Il primo modello considerato è il **Modello**

Autoregressivo, in cui una variabile è spiegata dal proprio passato tramite ritardi. Il modello più semplice è quello autoregressivo del primo ordine, **AR(1)**:

$$Y_t = \beta_0 + \beta_1 Y_{t-1} + \epsilon_t.$$

L'autocorrelogramma tipico per questo modello tende a decrescere a zero: Y_t dipende fortemente dalle osservazioni vicine ($Y_{t-1}, Y_{t-2}, \dots$) ma non da quelle lontane. Ad esempio, ciò che è successo 10 giorni fa potrebbe non essere interessante per prevedere ciò che accadrà domani, mentre lo è ciò che è accaduto ieri, l'altro ieri e così via, con importanza decrescente, fino a diventare nulla ad un numero elevato di ritardi.




Figura 16 — Grafico di una serie autocorrelata al primo ordine: la serie oscilla con maggiore persistenza rispetto al white noise, alternando fasi più prolungate sopra e sotto lo zero.




Figura 17 — Autocorrelogramma del modello AR(1): l'ACF decresce gradualmente verso zero all'aumentare del ritardo, mentre la PACF mostra un unico picco significativo al ritardo 1, coerente con la teoria del modello AR(1).

Modello AR(p). Il modello AR(1) utilizza solo l'informazione fornita da Y_{t-1} per prevedere Y_t . Un'estensione naturale è il modello autoregressivo di ordine p :

$$Y_t = \beta_0 + \beta_1 Y_{t-1} + \cdots + \beta_p Y_{t-p} + \epsilon_t.$$

La previsione per Y_{T+1} è data da

$$\hat{Y}_{T+1|T} = \hat{\beta}_0 + \hat{\beta}_1 Y_T + \cdots + \hat{\beta}_p Y_{T-p+1}.$$




Figura 18 — Grafico di una serie autocorrelata al terzo ordine (AR(3)): la serie mostra cicli più ampi e persistenti rispetto all'AR(1), con più lenta reversione verso lo zero.




Figura 19 — Autocorrelogramma del modello AR(3): l'ACF decresce lentamente e in modo oscillante, mentre la PACF mostra picchi significativi solo ai primi tre ritardi, coerentemente

con l'ordine del processo generatore.

(slide 51–56)

6.17. Il modello autoregressivo misto ADL(p,q)

Definizione 6.9. I modelli visti fino ad ora sono modelli statistici, utili per fare previsioni. In economia, però, si è più spesso interessati allo studio delle relazioni causali tra variabili, per cercare di capire il tipo di dipendenza che esiste tra grandezze economiche. Per analizzare queste relazioni, quando i dati sono espressi in forma di serie storica, è stata proposta una tipologia di modelli più generali detti **modelli autoregressivi misti** o **ADL(p,q)** (“Autoregressive Distributed Lag”), definiti come segue:

$$Y_t = \beta_0 + \beta_1 Y_{t-1} + \dots + \beta_p Y_{t-p} + \delta_0 X_t + \delta_1 X_{t-1} + \dots + \delta_q X_{t-q} + \epsilon_t,$$

in cui la dinamica riguarda sia la parte autoregressiva (relativa a Y) sia la componente detta **a ritardi distribuiti** (legata a X).

(slide 57)

6.18. Le ipotesi per la stima OLS nei modelli dinamici: il problema dell'esogenità

Dimostrazione. Per fare inferenza è necessario prima verificare se sono soddisfatte le ipotesi per gli OLS. Si consideri ad esempio il modello AR(1)

$$Y_t = \beta Y_{t-1} + \epsilon_t.$$

Nel modello di regressione semplice deve valere, tra l'altro, $E[\epsilon_i | X_1, \dots, X_N] = 0, \forall i$. Nel contesto dinamico AR(1), l'unico regressore è $X_t \equiv Y_{t-1}$. La condizione di esogenità diviene quindi $E[\epsilon_t | Y_1, \dots, Y_T] = 0, \forall t$.

Dimostrazione (l'esogenità stretta non vale nei modelli dinamici). Se vale $E[\epsilon_t | X_t] = E[\epsilon_t | Y_{t-1}] = 0$, allora $\text{Cov}[\epsilon_t Y_{t-1}] = 0$. Si calcoli però

$$E[\epsilon_t X_{t+1}] = E[\epsilon_t Y_t] = E[\epsilon_t (\beta Y_{t-1} + \epsilon_t)] = \beta \underbrace{E[\epsilon_t Y_{t-1}]}_{=0 \text{ per ip.}} + E[\epsilon_t^2] \neq 0.$$

Per cui, nel caso di modelli dinamici, **non può essere utilizzata** l'ipotesi di stretta esogenità e quindi non si può parlare di non distorsione (unbiasedness) dello stimatore OLS. Fortunatamente è ancora possibile dimostrare, sotto opportune ipotesi, che lo stimatore OLS è **consistente** (l'eventuale distorsione sparisce per T sufficientemente grande).

La sostituzione dell'ipotesi di indipendenza con la stazionarietà. Non si può utilizzare l'ipotesi di indipendenza del vettore $(Y, X_1, \dots, X_K)$: i dati in serie storica per loro natura non

sono indipendenti. È comunque possibile indebolire tale ipotesi sostituendola con opportune condizioni di regolarità sulla forma di dipendenza, ad esempio richiedendo che la serie storica sia **stazionaria**.

Una serie storica è definita **stazionaria (debolmente)** se: - la media di Y_t non dipende dal tempo, $E[Y_t] = \mu$; - la varianza di Y_t non dipende da t , $\text{Var}(Y_t) = \sigma^2$; - la struttura di dipendenza lineare dipende solo dalla distanza tra due osservazioni: $\text{Cov}(Y_s, Y_t) = \gamma_{t-s}$.

Un altro caso di endogenità: errore autocorrelato con endogena ritardata. Si consideri il modello

$$Y_t = \beta_1 + \beta_2 X_t + \beta_3 Y_{t-1} + \varepsilon_t, \quad \varepsilon_t = \rho \varepsilon_{t-1} + v_t.$$

È vero che $E(Y_{t-1} \varepsilon_t) = 0$? Sostituendo,

$$Y_t = \beta_1 + \beta_2 X_t + \beta_3 Y_{t-1} + \underbrace{\rho \varepsilon_{t-1} + v_t}_{\varepsilon_t}.$$

Se $\rho \neq 0$, ε_t risulta chiaramente correlata con Y_{t-1} (poiché Y_{t-1} dipende, tramite la sua stessa equazione, da ε_{t-1}). Di conseguenza il modello non descrive una media condizionale corretta:

$$E(Y_t | X_t, Y_{t-1}) = \beta_1 + \beta_2 X_t + \beta_3 Y_{t-1} + \underbrace{E(\varepsilon_t | X_t, Y_{t-1})}_{\neq 0}.$$

OLS, di conseguenza, **non è consistente** in questo caso. □

(slide 58–61)

6.19. L'ipotesi di stazionarietà nel caso AR(1)

Dimostrazione. Si consideri il modello AR(1) definito da $Y_t = \beta_0 + \beta_1 Y_{t-1} + \epsilon_t$, con $\epsilon_t \sim WN(0, \sigma^2)$. È interessante chiedersi sotto quali condizioni questo modello risulta stazionario. Per semplicità si ipotizzi $\beta_0 = 0$; risolvendo all'indietro:

$$Y_t = \beta_1 \underbrace{Y_{t-1}}_{\beta_1 Y_{t-2} + \epsilon_{t-1}} + \epsilon_t = \beta_1^2 Y_{t-2} + \beta_1 \epsilon_{t-1} + \epsilon_t = \dots = \sum_{j=0}^{\infty} \beta_1^j \epsilon_{t-j}.$$

Media. È immediato constatare che

$$E[Y_t] = \sum_{j=0}^{\infty} \beta_1^j E[\epsilon_{t-j}] = 0,$$

non dipende quindi da t .

Varianza. Diversamente, la varianza non dipende da t solo se $|\beta_1| < 1$:

$$\text{Var}(Y_t) = \text{Var}(\epsilon_t) \sum_{j=0}^{\infty} \beta_1^{2j} = \frac{\sigma^2}{1 - \beta_1^2}.$$

Nota: si ricordi che $\sum_{j=0}^{\infty} x^j = \frac{1}{1-x} \iff |x| < 1$. In questa applicazione $x \equiv \beta_1^2$.

Covarianza. La covarianza dipende unicamente dalla distanza tra le due osservazioni. Tramite opportune sostituzioni all'indietro si può scrivere

$$Y_t = \beta_1^s Y_{t-s} + \sum_{j=0}^{s-1} \beta_1^j \epsilon_{t-j},$$

per cui la covarianza tra Y_t ed Y_{t-s} risulta

$$\begin{aligned} \text{Cov}(Y_t, Y_{t-s}) &= E[Y_t Y_{t-s}] = E \left[\left(\beta_1^s Y_{t-s} + \sum_{j=0}^{s-1} \beta_1^j \epsilon_{t-j} \right) Y_{t-s} \right] \\ &= \beta_1^s \text{Var}[Y_{t-s}] + \sum_{j=0}^{s-1} \text{Cov}(Y_{t-s}, \beta_1^j \epsilon_{t-j}) = \beta_1^s \text{Var}(Y_t). \end{aligned}$$

□

(slide 62-64)

6.20. Break strutturali e il test di Chow

Teorema 6.2. Quando si analizzano modelli di serie storiche, può succedere che un evento esterno modifichi il tipo di relazione tra variabile dipendente e regressore. I parametri del modello di regressione in un sotto-campione (ad esempio le prime T_1 osservazioni) possono essere diversi da quelli del secondo sotto-campione (le osservazioni da $T_1 + 1$ a T). Si parla in questi casi di **break strutturale**.

Si scelga, per fissare le idee, il modello ADL(1,1)

$$Y_t = \beta_0 + \beta_1 Y_{t-1} + \delta_0 X_t + \delta_1 X_{t-1} + \epsilon_t,$$

ipotizzando che un evento capace di causare un break strutturale sia avvenuto ad un tempo $\tau \in [1, T]$ **noto**.

Il test di Chow. Si vuole verificare se i parametri del modello per le osservazioni precedenti a τ sono diversi da quelli per le osservazioni successive. Si costruisce una variabile dummy $D_t(\tau)$:

$$D_t(\tau) = \begin{cases} 0 & \text{se } t \leq \tau \\ 1 & \text{se } t > \tau. \end{cases}$$

Il modello si riscrive come

$$Y_t = \beta_0 + \beta_1 Y_{t-1} + \delta_0 X_t + \delta_1 X_{t-1} + \gamma_0 D_t(\tau) + \gamma_1 D_t(\tau) Y_{t-1} + \gamma_2 D_t(\tau) X_t + \gamma_3 D_t(\tau) X_{t-1} + \epsilon_t,$$

che assume le due forme:

$$Y_t = \begin{cases} \beta_0 + \beta_1 Y_{t-1} + \delta_0 X_t + \delta_1 X_{t-1} + \epsilon_t & t \leq \tau \\ (\beta_0 + \gamma_0) + (\beta_1 + \gamma_1) Y_{t-1} + (\delta_0 + \gamma_2) X_t + (\delta_1 + \gamma_3) X_{t-1} + \epsilon_t & t > \tau. \end{cases}$$

Se non ci fosse rottura strutturale in τ , le funzioni di regressione prima e dopo tale data dovrebbero coincidere. Il test di Chow verifica sotto H_0 l'uguaglianza a zero dei parametri γ_i , $\forall i$, cioè $\gamma_0 = \gamma_1 = \gamma_2 = \gamma_3 = 0$. Se H_0 fosse vera, non si verificherebbe un cambiamento del modello in data τ . Dal punto di vista pratico si tratta di calcolare un'opportuna statistica F .

Il problema della data ignota e la statistica QLR. In generale non è nota a priori la data τ in cui si verificherà il break strutturale. Si può affrontare il problema calcolando il test di Chow per ogni potenziale valore di τ , ottenendo una sequenza di statistiche F_τ : la statistica F con valore più grande presumibilmente corrisponde al possibile break. La statistica **QLR** (Quandt Likelihood Ratio) è

$$QLR = \max\{F(1), \dots, F(T)\},$$

la cui distribuzione non è nota in forma chiusa, anche se è comunque possibile calcolare numericamente i p-value.

(slide 65–68)

6.21. Esempio: break strutturale nel titolo Exelon

Esempio 6.5. Si supponga di voler sottoporre a verifica il modello CAPM utilizzando gli extra-rendimenti mensili del titolo Exelon per il periodo 1991-2000, usando come proxy del mercato l'indice S&P 500.

La verifica del CAPM su tutto il periodo evidenzia come il β del titolo sia nullo — risultato apparentemente strano. Un'analisi economica più dettagliata ha evidenziato come nel 1998, in corrispondenza di una breve crisi economica, il titolo Exelon abbia realizzato una serie di extra-rendimenti elevati in controtendenza con l'intero mercato. Ci si chiede quindi se nel 1998 si siano verificati break strutturali che spieghino un valore del β così anomalo.

Regressione sull'intero campione (extra-rendimenti dal 1991 al 2000). Stime OLS usando le 119 osservazioni 1991:02-2000:12, variabile dipendente: rend_exln

VARIABILE	COEFFICIENTE	ERRORE STD	STAT T	P-VALUE
const	0.00529475	0.00662467	0.799	0.42577
rend_mkt	0.0153368	0.171593	0.089	0.92893

VARIABILE	COEFFICIENTE	ERRORE STD	STAT T	P-VALUE
-----------	--------------	------------	--------	---------

Errore standard dei residui = 0.0722002; R-quadro = 6.82742e-005; R-quadro corretto = -0.00847815.

Test QLR. Test del rapporto di verosimiglianza di Quandt per break strutturale in un punto sconosciuto del campione, escludendo il 15 percento iniziale e finale: il massimo di $F(2, 115) = 7.6702$ corrisponde all'osservazione 1998:04, significativo al livello del 5 per cento (5% valore critico = 5.86). Il test suggerisce che la data τ più plausibile per il break strutturale corrisponde al mese di aprile 1998.

Regressione sul primo sottocampione (febbraio 1991 - marzo 1998, prima del break). Modello 2: stime OLS usando le 86 osservazioni 1991:02-1998:03, variabile dipendente: rend_exln

VARIABILE	COEFFICIENTE	ERRORE STD	STAT T	P-VALUE
const	-0.00507088	0.00580824	-0.873	0.38513
rend_mkt	0.582303	0.181555	3.207	0.00190 ***

Ora il β risulta significativamente diverso da 0.

Regressione sul secondo sottocampione (aprile 1998 - dicembre 2000, dopo il break). Stime OLS usando le 33 osservazioni 1998:04-2000:12, variabile dipendente: rend_exln

VARIABILE	COEFFICIENTE	ERRORE STD	STAT T	P-VALUE
const	0.0254586	0.0170836	1.490	0.14627
rend_mkt	-0.483655	0.328312	-1.473	0.15079

Ora il β risulta non significativo, ma solo in questo sottocampione (si verifichi che applicando il test QLR nei due sottocampioni non si verificano altri break).

(slide 69–73)

6.22. Trend deterministico e trend stocastico

Definizione 6.10. Molto spesso le variabili economiche sono influenzate da una componente detta **trend**, che rappresenta un movimento persistente di lungo periodo di una variabile nel corso del tempo. Esistono due tipi di trend, che producono effetti molto diversi sulle serie dei dati: - **Trend deterministico:** la componente tendenziale è descritta da una funzione $g(\cdot)$ non aleatoria del tempo, ad esempio $g(t) = t$ oppure $g(t) = \alpha_1 t + \alpha_2 t^2 + \dots + \alpha_p t^p$, con gli α_i noti. - **Trend stocastico:** la componente tendenziale varia nel tempo in maniera aleatoria; ad esempio

può manifestarsi come un prolungato periodo di crescita della serie seguito da un prolungato periodo di stabilità o di decrescita.




Figura 20 — Esempio di trend deterministico del tipo $Y_t = \alpha_0 + \alpha_1 t + \alpha_2 t^2 + \epsilon_t$: la serie cresce in modo regolare, curvilineo, con oscillazioni casuali di ampiezza contenuta attorno alla curva deterministica.




Figura 21 — Esempio di trend stocastico: la serie mostra fasi prolungate di crescita e decrescita irregolari, senza seguire un percorso deterministico prevedibile, scendendo fino a circa -14 nell'arco delle osservazioni mostrate.

(slide 74–76)

6.23. Il random walk e la sua non stazionarietà

Dimostrazione. Il caso più interessante da un punto di vista economico è quello dei trend stocastici, poiché spesso non è credibile supporre che una serie storica economica sia predicibile in

maniera deterministica. Uno dei modelli più semplici che generano trend stocastici è un AR(1) in cui $\beta_1 = 1$, detto **random walk**:

$$Y_t = Y_{t-1} + \epsilon_t.$$

L'idea di base è che quello che si osserverà domani, Y_{t+1} , sia uguale a quello che si osserva oggi, Y_t , più uno shock con media nulla. Tale modello sembra ragionevole soprattutto in applicazioni finanziarie, dove si pensa che la migliore previsione del prezzo di domani sia rappresentata dal prezzo osservato oggi (teoria dei mercati efficienti).




Figura 22 — Grafico di $Y_t = Y_{t-1} + \epsilon_t$: la serie mostra un tipico andamento “a deriva”, con lunghe escursioni non prevedibili, muovendosi tra circa -8 e 10 .




Figura 23 — Correlogramma di $Y_t = Y_{t-1} + \epsilon_t$: l'ACF decresce molto lentamente restando elevata anche a ritardi alti, mentre la PACF mostra un solo picco significativo al ritardo 1 — tipica “firma” di non stazionarietà.

Dimostrazione (il random walk non è stazionario). Il random walk è un caso particolare del modello AR(1) con $\beta_0 = 0, \beta_1 = 1$. Se fosse stazionario, si dovrebbe avere $\text{Var}(Y_t) = \sigma_Y^2, \forall t$.

Tuttavia

$$\text{Var}(Y_t) = \text{Var}(Y_{t-1}) + \text{Var}(\epsilon_t),$$

condizione vera solo se $\text{Var}(\epsilon_t) = 0$, il che è impossibile poiché $\text{Var}(\epsilon_t) = \sigma^2$ per ipotesi.

Scrivendo Y_t in funzione degli errori passati, ipotizzando per semplicità $Y_0 = 0$, si ottiene

$$Y_1 = \epsilon_1, \quad Y_2 = Y_1 + \epsilon_2 = \epsilon_1 + \epsilon_2, \quad \dots, \quad Y_t = \epsilon_1 + \dots + \epsilon_t = \underbrace{\sum_{j=1}^t \epsilon_j}_{\text{trend stocastico}}.$$

Quindi

$$\text{Var}(Y_t) = \text{Var}\left(\sum_{j=1}^t \epsilon_j\right) = t\sigma^2,$$

che dipende da t : la varianza diverge con t , e le autocorrelazioni non sono nemmeno definite (in senso teorico). Le autocorrelazioni campionarie però si possono comunque calcolare, e tendono ad essere prossime a uno anche ad elevati ritardi. $\square$

(slide 77-81)

6.24. Random walk con drift

Definizione 6.11. Di frequente le serie economiche mostrano una tendenza sistematica. In questo caso una buona previsione non potrà essere data semplicemente dall'osservazione al tempo t , ma dovrà essere corretta per tenere conto della tendenza sistematica.

L'estensione più ovvia del modello random walk è il **Random Walk con drift**:

$$Y_t = \beta_0 + Y_{t-1} + \epsilon_t = \beta_0 t + Y_0 + \sum_{j=1}^t \epsilon_j.$$

- Se $\beta_0 > 0$ allora Y_t tenderà in media a crescere; - Se $\beta_0 < 0$ allora Y_t tenderà in media a decrescere.

La previsione associata a questo modello è il valore osservato oggi più il drift β_0 .





Figura 24 — Grafico di $Y_t = 0.5 + Y_{t-1} + \epsilon_t$: la serie mostra una crescita netta e progressiva, da circa 0 fino a circa 120-140, sovrapposta a fluttuazioni casuali di breve periodo — il drift positivo domina l'andamento di lungo periodo.

(slide 82-83)

6.25. Conseguenze dei trend stocastici per la stima OLS

Teorema 6.3. L'ipotesi di stazionarietà è imprescindibile ai fini dell'inferenza. La sua violazione ha importanti conseguenze:

1. Se un regressore X_{jt} ha un trend stocastico, la distribuzione della statistica $t = \frac{\hat{\beta}_j - \beta_{j0}}{\hat{\sigma}_{\hat{\beta}_j}}$ ha una distribuzione diversa da quella Gaussiana sotto H_0 , con la conseguenza che l'abituale procedura di verifica d'ipotesi porta a risultati errati.
2. Se la serie Y_t è correttamente descritta da un modello random walk, ma per errore si stima un modello AR(1), si può dimostrare che lo stimatore è consistente ma **distorto**: infatti $E[\hat{\beta}_1] = 1 - 5.3/T$. Inoltre, la distribuzione asintotica di $\hat{\beta}_1$ risulta non Gaussiana ed asimmetrica (verso lo zero).



Densità simulate con lo stesso esperimento dell'originale (regressione tra random walk indipendenti).

Figura 25 — Distribuzione della statistica t nel caso standard (area verde — $N(0, 1)$) e nel caso in cui X ed Y sono random walk (area rosa), con $T = 500$: la densità dell'area rosa risulta molto più concentrata e stretta attorno allo zero rispetto alla Normale standard, mostrando che la statistica t calcolata sotto trend stocastici non è confrontabile con i valori critici usuali di una $N(0, 1)$.

(slide 84–85)

6.26. La regressione spuria

Teorema 6.4. Si consideri la regressione

$$Y_t = \beta_0 + \beta_1 X_t + \epsilon_t$$

in cui sia X_t che Y_t sono descritti da **random walk indipendenti**. Il vero valore di β_1 è 0 per costruzione. Si dimostra che: - lo stimatore OLS $\hat{\beta}_1$ non converge a 0, ma ad una variabile casuale non Gaussiana e non necessariamente a media nulla; - la conseguenza più evidente riguarda la distribuzione della statistica t , che risulta ben lungi dall'essere una Normale standard (si veda la Figura 25); - l' R^2 della regressione tende a 1 se $T \rightarrow +\infty$, e quindi il modello potrebbe sembrare avere un buon adattamento anche se non è correttamente specificato.




Figura 26 — Grafico delle serie storiche indipendenti (X, Y) , entrambe simulate come random walk indipendenti dal 1971 al 2008: le due serie mostrano andamenti di lungo periodo apparentemente correlati (una cresce mentre l'altra decresce, o viceversa) pur essendo generate in modo completamente indipendente — l'illusione visiva alla base della regressione spuria.

Esempio numerico. Regressione tra Y ed X simulate al computer tramite due random walk indipendenti. Stime OLS usando le 150 osservazioni 1971:2-2008:3, variabile dipendente: Y , errori standard HAC (Kernel di Bartlett)

	coefficiente	errore std.	t-ratio	p-value
const	-2.99441	0.675510	-4.433	1.80E-05
X	-0.792102	0.0829947	-9.544	4.05E-017

Errore standard della regressione = 3.31238; R-quadro = 0.75623; R-quadro corretto = 0.75458.

Si noti che si rifiuta l'ipotesi nulla $H_0 : \beta_1 = 0$ — nonostante X e Y siano per costruzione indipendenti: è l'evidenza empirica del fenomeno della regressione spuria.

(slide 86–88)

6.27. Modelli per variabili non stazionarie: trend deterministico e stocastico

Definizione 6.12. È stato evidenziato come la non stazionarietà di una serie possa essere descritta da componenti deterministiche oppure stocastiche. Una formalizzazione generale è

$$Y_t = TD_t + Y_t^*,$$

dove: TD_t è la componente deterministica, che potrebbe essere una semplice costante $TD_t = \kappa$, una retta $TD_t = \kappa + \delta t$ oppure un polinomio di secondo grado $TD_t = \kappa + \delta t + \gamma t^2$; Y_t^* rappresenta la componente stocastica del processo generatore di Y_t ; Y_t è la serie storica osservabile.

Se la componente stocastica Y_t^* è stazionaria, allora Y_t è detto **trend stazionario**, nel senso che il processo $Y_t - TD_t = Y_t^*$ è stazionario. In questi casi è possibile stimare la componente deterministica tramite OLS per poi descrivere la componente residuale (l'andamento di breve periodo) tramite un modello stazionario.

Se invece Y_t^* fosse un random walk, la componente di lungo periodo è descritta da

$$Y_t^* = \sum_{i=1}^t \epsilon_i + Y_0^*,$$

e si parla di presenza di **trend stocastico**.

Derivazione. Ipotizzando $Y_t^* = Y_{t-1}^* + \epsilon_t$ (random walk), semplici passaggi algebrici permettono di scrivere il modello per Y_t come

$$Y_t = TD_t + Y_t^* = TD_t + Y_{t-1}^* + \epsilon_t = TD_t - TD_{t-1} + \underbrace{Y_{t-1}^*}_{Y_{t-1}^*} + \epsilon_t.$$

- Nel caso di trend deterministico costante, $TD_t = \kappa$, la serie originale è descritta da un random walk:

$$Y_t = Y_{t-1} + \epsilon_t.$$

- Nel caso di trend lineare, $TD_t = \kappa + \delta t$, si ricava un random walk con drift:

$$Y_t = \delta + Y_{t-1} + \epsilon_t = Y_0 + \delta t + \sum_{j=1}^t \epsilon_j.$$

- Nel caso di trend polinomiale di grado 2, si ottiene

$$Y_t = (\delta - \gamma) - 2\gamma t + Y_{t-1} + \epsilon_t.$$

(slide 89-92)

6.28. Verifica della non stazionarietà: il test di Dickey-Fuller

Teorema 6.5. Quando si usano serie storiche di dati economici, è necessario verificare se sono stazionari oppure no. In letteratura sono stati proposti diversi test per verificare la presenza o meno di una **radice unitaria**, cioè la presenza di una componente di tipo random walk nei dati.

Si consideri innanzitutto il modello AR(1),

$$Y_t = \beta_0 + \beta_1 Y_{t-1} + \epsilon_t, \quad \text{Cov}(\epsilon_t, \epsilon_{t-j}) = 0, \quad \forall j.$$

Il random walk è un caso particolare di questo modello in cui $\beta_1 = 1$. L'idea alla base del test di **Dickey-Fuller (DF)** per verificare la non stazionarietà è di stimare il modello AR(1) e verificare il sistema d'ipotesi

$$H_0 : \beta_1 = 1 \quad \text{vs.} \quad H_1 : \beta_1 < 1.$$

Spesso in pratica risulta più utile considerare il modello AR(1) equivalente, riparametrizzato come

$$\Delta Y_t = \beta_0 + \delta Y_{t-1} + \epsilon_t, \quad \delta = \beta_1 - 1,$$

con la conseguenza che l'ipotesi di interesse diventa

$$H_0 : \delta = 0 \quad \text{vs.} \quad H_1 : \delta < 0.$$

Il sistema di ipotesi si verifica tramite la solita statistica $t = \hat{\delta}/\hat{\sigma}_{\hat{\delta}}$. La distribuzione asintotica di tale statistica **non è una Normale standard** e dipende dal modello utilizzato per la stima di δ .

Ipotizzando che il vero processo generatore dei dati sia il random walk $Y_t = Y_{t-1} + \epsilon_t$, $\epsilon_t \sim WN(0, \sigma^2)$, la statistica t del test DF può essere calcolata sulla base di diversi modelli, ad esempio: - $Y_t = \beta_1 Y_{t-1} + \epsilon_t$; - $Y_t = \beta_0 + \beta_1 Y_{t-1} + \epsilon_t$.

Si può dimostrare che la distribuzione asintotica della statistica t dipende dal modello utilizzato (Figura 27). È comunque possibile calcolare per via numerica i valori critici ed i p-value; i pacchetti econometrici disponibili forniscono tali quantità.

Distribuzione asintotica della statistica t al variare del modello:




Figura 27 — Distribuzione asintotica della statistica t (o DF) al variare del modello: se $|\beta_1| < 1$, $t \rightarrow N(0, 1)$; se $\beta_1 = 1, \beta_0 = 0$ la distribuzione è non standard (Dickey-Fuller, $t_{\beta_0=0, \beta_1=1}$); se $\beta_1 = 1, \beta_0 \neq 0$ la distribuzione è non standard (Dickey-Fuller con drift, $t_{\beta_0 \neq 0, \beta_1=1}$). Il grafico sovrappone le tre densità: quella $N(0, 1)$ è la più stretta e centrata, mentre le due densità di Dickey-Fuller (senza e con drift) sono spostate verso sinistra e più larghe. Il valore critico al 5% unilaterale a sinistra risulta -2.85 per il test DF con drift, -1.95 per il test senza drift, ed -1.64 per una $N(0, 1)$.

(slide 93–96)

6.29. Il test aumentato di Dickey-Fuller (ADF)

Dimostrazione. Il test DF fornisce una decisione corretta sulla non stazionarietà se la serie originale è descritta da un modello AR(1) con errori incorrelati, cioè $\text{Cov}(\epsilon_t, \epsilon_{t-j}) = 0, \forall j$. In generale questa potrebbe essere un'ipotesi poco credibile in casi pratici. Nel caso di autocorrelazione dei residui, la distribuzione asintotica della statistica t risulta **non trattabile**.

Per ovviare a questo inconveniente è stato proposto il test **Augmented Dickey-Fuller (ADF)**, che estende il test DF a un modello autoregressivo generico di ordine p . Come prima, la statistica test verifica sotto H_0 la presenza di radici unitarie. Si ipotizzi che i dati seguano un processo AR(p):

$$Y_t = \beta_0 + \beta_1 Y_{t-1} + \dots + \beta_p Y_{t-p} + \epsilon_t.$$

Una rappresentazione equivalente del modello, utile ai fini del calcolo del test, è

$$\Delta Y_t = \beta_0^* + \delta Y_{t-1} + \beta_1^* \Delta Y_{t-1} + \dots + \beta_p^* \Delta Y_{t-p+1} + \epsilon_t.$$

Anche in questa parametrizzazione $\delta = \beta_1 - 1$. Il caso $\delta = 0$ è equivalente alla presenza di radice unitaria; se $\delta < 0$ vale la condizione di stazionarietà. L'alternativa è unilaterale, poiché se la serie fosse stazionaria δ risulterebbe negativo:

$$H_0 : \delta = 0 \quad \text{vs.} \quad H_1 : \delta < 0.$$

Dimostrazione (derivazione per un processo AR(2), $p = 2$).

$$\begin{aligned} Y_t &= \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \epsilon_t = \phi_1 Y_{t-1} + (\phi_2 Y_{t-1} - \phi_2 Y_{t-1}) + \phi_2 Y_{t-2} + \epsilon_t \\ &= (\phi_1 + \phi_2) Y_{t-1} - \phi_2 \Delta Y_{t-1} + \epsilon_t = \phi Y_{t-1} + \alpha \Delta Y_{t-1} + \epsilon_t \quad (\phi \equiv \phi_1 + \phi_2, \alpha = -\phi_2). \end{aligned}$$

Il primo regressore rappresenta il solito modello per il test DF; il secondo è la parte *augmented*, che se omessa introdurrebbe autocorrelazione nel termine d'errore della procedura standard del test DF.

Sotto l'ipotesi nulla, la statistica t si distribuisce seguendo una distribuzione non standard, diversa rispetto al caso del modello AR(1). Anche per il test ADF risulta possibile calcolare p-value e valori critici tramite simulazione.

Estensione: trend deterministico nel modello AR(p). Un'ulteriore generalizzazione consiste nell'ipotizzare un modello in cui, oltre alla componente AR(p), si aggiunge un trend deterministico:

$$Y_t = \beta_0 + \alpha_1 t + \alpha_2 t^2 + \beta_1 Y_{t-1} + \dots + \beta_p Y_{t-p} + \epsilon_t.$$

Anche in questo caso è possibile calcolare la statistica test in maniera equivalente al caso precedente; quello che cambia in questa versione del test è la sua distribuzione asintotica. $\square$

(slide 97–100)

6.30. Quale test di radice unitaria utilizzare?

Si ricordi che una serie storica può essere rappresentata dal modello $Y_t = TD_t + Y_t^*$. Risulta rilevante saper discriminare quale componente sia la causa della non stazionarietà, definendo un test che discrimini se una serie storica è (i) caratterizzata da trend stocastico, nel qual caso Y_t^* è assimilabile a un random walk; oppure (ii) da un trend deterministico, nel qual caso la componente TD_t risulta statisticamente significativa; oppure ancora (iii) se la non stazionarietà dipende da entrambi i fattori.




Figura 28 — $Y_t = TD_t + Y_t^*$: la linea verde Y_t rappresenta la serie osservata (con andamento crescente da circa 5 fino a circa 25-30 tra il 2006 e il 2022), rappresentata come combinazione del trend deterministico TD_t (retta arancione crescente) e della dinamica stocastica Y_t^* (serie blu oscillante attorno a zero senza trend).

Caso 1: trend deterministico costante. Si ipotizzi $TD_t = \kappa$ e $Y_t^* = \alpha Y_{t-1}^* + \epsilon_t$. Ne consegue che

$$Y_t = TD_t + Y_t^* = \kappa + \alpha Y_{t-1}^* + \epsilon_t = \kappa(1 - \alpha) + \alpha Y_{t-1} + \epsilon_t.$$

Se fosse vera l'ipotesi nulla di non stazionarietà di Y_t^* , cioè $\alpha = 1$, si ottiene

$$Y_t = Y_{t-1} + \epsilon_t = Y_0 + \sum_{j=0}^{t-1} \epsilon_{t-j}.$$

Sotto la nulla, il modello diventa un random walk senza costante ma con valore iniziale Y_0 non necessariamente pari a 0.

Caso 2: trend deterministico lineare. Se $TD_t = \kappa + \delta t$,

$$Y_t = TD_t + Y_t^* = \kappa + \delta t + \alpha Y_{t-1}^* + \epsilon_t = \kappa(1 - \alpha) + \delta\alpha + \delta(1 - \alpha)t + \alpha Y_{t-1} + \epsilon_t.$$

Se fosse vera l'ipotesi nulla $\alpha = 1$, si ottiene

$$Y_t = \delta + Y_{t-1} + \epsilon_t,$$

cioè, sotto la nulla, un random walk con drift, con valore iniziale y_0 non necessariamente pari a 0.

Regola approssimativa per decidere quale test utilizzare: - se la serie storica non evidenzia un andamento tendenziale netto, si può usare il primo test (componente deterministica definita solo da una costante): sia sotto l'ipotesi nulla che sotto l'alternativa il processo ha media costante; - se la serie storica evidenzia un andamento tendenziale di tipo lineare, si usa il secondo test: i processi compatibili sotto entrambe le ipotesi sono compatibili con un trend. Sotto la nulla il trend è causato dal drift del random walk; sotto l'alternativa è indotto dalla retta deterministica.

(slide 101-105)

6.31. La differenziazione come soluzione alla non stazionarietà

Il trend, o comunque gli andamenti di tipo evolutivo che spesso caratterizzano le serie economiche, impongono di apportare alcune trasformazioni ai dati prima di poterne fare un'analisi statistica corretta. La **differenziazione** dei dati costituisce una trasformazione tipica utilizzata per rendere stazionarie serie integrate del primo ordine, cioè serie le cui differenze sono stazionarie, per cui si considera

$$\Delta Y_t = \beta_0 + \beta_1 \Delta X_t + \epsilon_t.$$

In maniera analoga è possibile considerare la **differenza logaritmica**, anche se in questo caso i risultati devono essere interpretati in termini di tassi di crescita (o incrementi percentuali):

$$\Delta \log(Y_t) = \beta_0 + \beta_1 \Delta \log(X_t) + \epsilon_t.$$

(slide 106)

6.32. Riepilogo delle ipotesi OLS per le serie storiche e distribuzione asintotica

Teorema 6.6. Concludendo, le ipotesi necessarie per ottenere stimatori OLS ottimali nel caso di modelli dinamici sono: - il modello è lineare; - il vettore (Y_t, X_t) è stazionario, ed inoltre la dipendenza seriale tra (Y_t, X_t) e (Y_{t-j}, X_{t-j}) diventa nulla per j grande; - Y_t ed X_t possiedono almeno i primi 8 momenti; - i regressori sono **esogeni**, nel senso che $E[\epsilon_t | X_{1,t}, \dots, X_{K,t}] = 0$; - vale la condizione di **omoschedasticità**; - non c'è perfetta collinearità.

Teorema (distribuzione asintotica per OLS). Se valgono le ipotesi precedenti, si dimostra che:

(i) lo stimatore $\hat{\beta}_j$ è **consistente**:

$$\hat{\beta}_j \xrightarrow{p} \beta_j \quad \forall j;$$

(ii) lo stimatore $\hat{\beta}_j$ è **asintoticamente Normale**:

$$\hat{\beta}_j \overset{a}{\sim} N\left(\beta_j, \sigma_{\hat{\beta}_j}^2\right) \quad \forall j;$$

(iii) la variabile casuale t , definita come $t = \frac{\hat{\beta}_j - \beta_j}{\hat{\sigma}_{\hat{\beta}_j}}$, converge ad una Normale standard:

$$t = \frac{\hat{\beta}_j - \beta_j}{\hat{\sigma}_{\hat{\beta}_j}} \xrightarrow{p} N(0, 1);$$

(iv) lo stimatore $\hat{\sigma}_{\hat{\beta}_j}$ viene calcolato come nel caso del modello di regressione con errori omoschedastici.

(slide 107–108)

7 | Econometria — Introduzione alla Cointegrazione

Fonte: ECON_Teoria_07_Cointegrazione.pdf — 33 slide

7.1. Motivazione: serie non stazionarie che si muovono insieme

Corso: Econometria — *Introduzione alla Cointegrazione*, Davide Raggi, 10 dicembre 2025.

In linea di principio una variabile economica osservata come serie storica potrebbe avere un comportamento **non stazionario**. Tuttavia si può osservare che tale variabile tende ad evolvere in maniera simile ad altre (a loro volta non stazionarie). In sostanza, una variabile, seppur erratica, potrebbe tendere a **non discostarsi mai, in maniera sistematica, da altre**.

Questa evenienza può verificarsi quando più variabili tendono a muoversi attorno ad un **unico trend stocastico**. In questo caso, calcolando le differenze a coppie, queste tenderebbero ad essere stazionarie.




Figura 1 — Serie storiche dei tassi di interesse USA ad 1 anno ed a 90 giorni (rispettivamente R_{1yr} ed R_{90}), dal 1955 al 2000. I trend stocastici tendono ad essere simili. Il grafico mostra le due serie muoversi in maniera pressoché parallela nel tempo, suggerendo che condividano lo stesso trend stocastico sottostante.




Figura 2 — La differenza tra tassi d'interesse, o spread = $(R1yr - R90)$, potrebbe sembrare un processo stazionario. A differenza delle serie di livello (che vagano senza un livello medio fisso), lo spread oscilla attorno a un valore vicino allo zero senza mostrare un trend persistente, suggerendo che la combinazione lineare delle due serie sia stazionaria anche se le serie singole non lo sono. (slide 1-4)

7.2. Definizione di cointegrazione: combinazione lineare stazionaria

Definizione 7.1. Dall'esempio precedente sembrerebbe che la differenza tra due serie X ed Y , definita come $\epsilon_t = Y_t - X_t$, risulti essere stazionaria. In generale si può considerare una **generica combinazione lineare stazionaria** di X ed Y :

$$\epsilon_t = \beta_1 Y_t - \beta_2 X_t \propto Y_t - \underbrace{\frac{\beta_2}{\beta_1}}_{=\beta} X_t = Y_t - \beta X_t$$

Tale relazione tra X ed Y , essendo stazionaria, può essere interpretata come **stabile nel tempo**, o **di lungo periodo**. Il legame vale anche se il comportamento individuale di ogni serie risulta non stazionario. Si dice in questo caso che le variabili **co-integrano**, nel senso che sono integrate (non stazionarie), ma vagano attorno ad un unico trend stocastico.

Una prima soluzione al problema della regressione spuria sarebbe analizzare la relazione tra le serie differenziate:

$$\Delta Y_t = \beta_0 + \beta_1 \Delta X_t + \epsilon_t$$

Tuttavia questo modo di procedere può non essere soddisfacente, perché si perdono tutte le informazioni sul comportamento dei **livelli** delle variabili nel lungo periodo, che rappresentano spesso uno degli obiettivi dell'analisi econometrica. La cointegrazione si presta bene all'analisi economica, in quanto permette di formalizzare opportune relazioni tra variabili di lungo periodo, nel contesto di un modello economico teorico.

(slide 5-6)

7.3. Esempio: due random walk con trend stocastico comune

Esempio 7.1. Si considerino due random walk X_t ed Y_t :

$$Y_t = Y_{t-1} + \epsilon_{y,t} = \sum_{j=1}^t \epsilon_{y,j}$$

$$X_t = X_{t-1} + \epsilon_{x,t} = \sum_{j=1}^t \epsilon_{x,j}$$

Di solito, una combinazione lineare di due variabili non stazionarie X ed Y risulta **non stazionaria**, e quindi problematica dal punto di vista inferenziale.

Tuttavia, si ipotizzi la situazione in cui $\epsilon_{y,j} = \theta \epsilon_{x,j}$. Come conseguenza si avrà che $Y_t = \theta X_t$. In questo caso si dice che Y_t ed X_t condividono lo stesso trend stocastico, in quanto

$$Y_t = \theta \sum_{j=1}^t \epsilon_{x,j} \quad \text{ed} \quad X_t = \sum_{j=1}^t \epsilon_{x,j}$$

Risulta chiaro, in questo caso, che $Y_t - \theta X_t = 0$, relazione che rappresenta, dal punto di vista economico, una situazione di **equilibrio** tra le due variabili, per qualsiasi valore di t .

Più in generale, se si mantiene l'ipotesi che $\epsilon_{x,t}$ ed $\epsilon_{y,t}$ siano proporzionali, ma non IID (ad esempio autocorrelate), la sequenza di deviazioni dall'equilibrio potrebbe essere espressa da

$$\epsilon_t = Y_t - \theta X_t$$

in cui ϵ_t non è sistematicamente nulla ma risulta **stazionaria**.

Definizione. Si dice che X ed Y sono **cointegrate** se esiste una loro opportuna combinazione lineare che è stazionaria. Tale definizione può essere generalizzata ad una n -pla di variabili $(Y, X_1, \dots, X_{n-1})$.

Dal punto di vista statistico ha quindi senso pensare di stimare il parametro θ , che rappresenta il legame stabile nel tempo tra oggetti che individualmente sono instabili, ma congiuntamente lo sono.

(slide 7–9)

7.4. Stima OLS in presenza di cointegrazione: superconsistenza

Teorema 7.1. Siano X ed Y non stazionarie e cointegrate, e si vuole stimare

$$Y_t = \beta_0 + \beta_1 X_t + \epsilon_t$$

Per questo modello, pur essendo le variabili non stazionarie, si dimostra che lo stimatore OLS di β_1 è **superconsistente**, nel senso che

$$(\hat{\beta}_1 - \beta_1) \xrightarrow{p} 0$$

più velocemente rispetto allo stimatore OLS calcolato nelle ipotesi del modello di regressione con variabili stazionarie.

La distribuzione asintotica di $\hat{\beta}_1$ tuttavia **non è Gaussiana**. Tale distribuzione dipende dalle ipotesi che vengono fatte sul termine di errore ϵ_t , che comunque deve rimanere stazionario. In generale, si dimostra che la statistica t **non si distribuisce come una normale standard**. Un caso particolare, in cui vale l'approssimazione alla Normale, si ha quando ϵ_t ed $\epsilon_{x,t}$ sono serialmente e mutualmente incorrelati.

(slide 10)

7.5. Lo stimatore DOLS (Dynamic OLS)

Definizione 7.2. In termini pratici, nel caso di variabili cointegrate, risulta possibile ottenere stime puntuali molto accurate per via della superconsistenza. Tuttavia non risulta possibile costruire delle statistiche test opportune a causa della distribuzione asintotica non standard della statistica t .

Una soluzione è stata proposta da **Stock e Watson (1993)** con lo stimatore **DOLS (Dynamic Ordinary Least Squares)** per β_1 . Tale stimatore si basa sulla stima OLS della regressione aumentata:

$$Y_t = \beta_0 + \beta_1 X_t + \underbrace{\gamma_0 \Delta X_t + \gamma_{-1} \Delta X_{t-1} + \dots + \gamma_{-\ell_T} \Delta X_{t-\ell_T}}_{\text{lags}} + \underbrace{\gamma_1 \Delta X_{t+1} + \dots + \gamma_{\ell_T} \Delta X_{t+\ell_T}}_{\text{leads}} + \epsilon_t^*$$

Il parametro ℓ_T indica il numero di regressori da aggiungere al modello originale. Il valore di ℓ_T dipende dalla numerosità campionaria T .

Si noti che i parametri di interesse nel modello aumentato sono solamente β_0 e β_1 . Gli altri regressori sono solo strumentali ed hanno uno scopo puramente tecnico, nel senso che servono ad eliminare l'effetto dovuto all'eventuale autocorrelazione di $\epsilon_{x,t}$.

Anche in questo caso la distribuzione asintotica dello stimatore DOLS $\hat{\beta}_1$ risulta **non Gaussiana**. In generale i residui del modello rimangono autocorrelati. Occorre quindi utilizza-

re uno stimatore consistente per gli errori standard che tenga conto dell'autocorrelazione e dell'eteroschedasticità (ad es. **Newey-West** o **HAC**).

La statistica t si distribuisce come una variabile casuale Normale standard sotto l'ipotesi nulla, con la conseguenza che l'inferenza può essere condotta come al solito.

(slide 11–12)

7.6. Test di cointegrazione di Engle-Granger (CDF)

Definizione 7.3. La presenza di una relazione di cointegrazione permette di derivare una corretta inferenza nel modello di regressione anche nel caso in cui le variabili in esame siano non stazionarie. Risulta quindi necessario poter accertare quando, avendo variabili non stazionarie, ci si trova in presenza di questo tipo di relazione.

Si consideri la relazione di lungo periodo

$$\epsilon_t = Y_t - \theta X_t$$

Se le variabili X ed Y condividessero lo stesso trend stocastico, ne risulterebbe la stazionarietà di ϵ_t e di conseguenza un test di radice unitaria rifiuterebbe l'ipotesi nulla. Un'idea per verificare la presenza di cointegrazione potrebbe basarsi sulla verifica dell'assenza di radice unitaria per ϵ_t .

Il processo ϵ_t risulta tuttavia non osservabile. Si ricordi però che gli stimatori OLS e DOLS $\hat{\theta}$ sono superconsistenti per θ , e quindi $\hat{\epsilon}_t = Y_t - \hat{\theta}X_t$ è consistente per ϵ_t .

L'idea di **Engle e Granger (1987)** per verificare la presenza di cointegrazione è dunque quella di calcolare un test di radice unitaria per la serie dei residui $\hat{\epsilon}_t$, ad esempio il test **Dickey-Fuller per la Cointegrazione (CDF)**.

NOTA: occorre precisare che la distribuzione asintotica della statistica CDF cambia a seconda che nella relazione di lungo periodo sia inserita l'intercetta oppure no. Inoltre tale distribuzione risulta differente rispetto al caso di test di radice unitaria classici. In ogni caso i principali software econometrici permettono di gestire in maniera automatica tali differenze.

(slide 13–14)

7.7. Esempio applicato: cointegrazione tra tassi di interesse USA (r3 e r60)

Esempio 7.2. Si vuole verificare se le due serie storiche dei tassi di interesse USA, cioè $r3$ (tasso a 3 mesi) ed $r60$ (tasso a 5 anni), sono cointegrate. Occorre:

1. Verificare se $r3$ e $r60$ sono non stazionarie (integrate);

2. Stimare l'eventuale relazione di cointegrazione tramite OLS: $r60_t = a + b r3_t + \epsilon_t$;
3. Verificare se i residui della regressione $\hat{\epsilon}_t$ sono stazionari (tramite un opportuno test di tipo ADF).




Figura 3 — Tassi USA a 3 mesi ed a 5 anni osservati da Dicembre 1946 a Febbraio 1992. Le due serie ($r3$ e $r60$) mostrano andamenti simili nel tempo, con picchi comuni (in particolare attorno al 1980), suggerendo la possibilità di cointegrazione.

Passo 1 — Test ADF sulle singole serie. I test ADF evidenziano che entrambe le serie sono non stazionarie:

Serie	Ritardi di (1-L) inclusi	Specificazione	p-value asintotico
r3	8	Test con costante	0.3643
r60	7	Test con costante	0.5203

Passo 2 — Stima della relazione di cointegrazione. OLS, usando le osservazioni 1946:12-1991:02 ($T = 531$), variabile dipendente $r60$:

	coefficiente	errore std.	rapporto t	p-value
const	1.09161	0.0755948	14.44	4.36e-40 ***
r3	0.952326	0.0124198	76.68	1.06e-288 ***

E.S. della regressione: 0.939385. R-quadro: 0.917454. R-quadro corretto: 0.917298.

Si stimano quindi i residui del modello $\hat{\epsilon}_t$.

Passo 3 — Test CDF sui residui. Si calcola da: Modello $\Rightarrow$ Serie Storiche Multivariate $\Rightarrow$ Test di Cointegrazione (Engle-Granger). Vengono riportati i test di stazionarietà delle serie storiche individuali, la relazione di cointegrazione eventuale e l'opportuno test ADF sui residui

(di seguito solo l'ultimo passo, poiché i risultati dei passi precedenti coincidono con quelli già mostrati).

Passo 4 — Test per una radice unitaria in uhat. Test Dickey-Fuller aumentato per uhat, inclusi 12 ritardi di $(1-L)uhat$, ampiezza campionaria 518. Ipotesi nulla di radice unitaria: $a = 1$.

Modello: $(1 - L)y = b_0 + (a - 1)y_{(-1)} + \dots + e$

- Coefficiente di autocorrelazione del prim'ordine per e : -0.000
- Differenze ritardate: $F(12, 505) = 1.793$ [0.0464]
- Valore stimato di $(a - 1)$: -0.0744308
- Statistica test: $\tau_c(2) = -3.44665$
- p-value asintotico: 0.03747

Il p-value del test CDF sui residui è basso (0.03747), per cui si rifiuta l'ipotesi nulla di radice unitaria nei residui: $r3$ ed $r60$ risultano **cointegrare**.

(slide 15-20)

7.8. Dal modello ADL(1,1) al Modello a Correzione dell'Errore (ECM)

Dimostrazione. I modelli ADL possono essere utilizzati per descrivere ipotesi di teoria economica in cui esiste una relazione di **equilibrio di lungo periodo** tra variabili. Ad esempio potrebbe valere una relazione lineare del tipo $Y = a + bX$.

Si riconsideri il modello ADL(1,1):

$$Y_t = \kappa + \alpha_1 Y_{t-1} + \beta_0 X_t + \beta_1 X_{t-1} + \epsilon_t$$

È possibile riparametrizzare il modello sottraendo Y_{t-1} e sommando/sottraendo $\beta_0 X_{t-1}$:

$$\begin{aligned} Y_t - Y_{t-1} &= \kappa + \alpha_1 Y_{t-1} - Y_{t-1} + \beta_0 X_t + \beta_1 X_{t-1} + \beta_0 X_{t-1} - \beta_0 X_{t-1} + \epsilon_t \\ &= \beta_0 \Delta X_t + (\alpha_1 - 1) \left(Y_{t-1} - \underbrace{\frac{\kappa}{1 - \alpha_1}}_{=a} - \underbrace{\frac{\beta_0 + \beta_1}{1 - \alpha_1}}_{=b} X_{t-1} \right) + \epsilon_t \end{aligned}$$

In sintesi il modello ADL(1,1) può essere riparametrizzato come

$$\Delta Y_t = \beta_0 \Delta X_t + (\alpha_1 - 1) \underbrace{(Y_{t-1} - a - bX_{t-1})}_{\text{disequilibrio a } t-1} + \epsilon_t$$

Il modello così definito evidenzia un **meccanismo a correzione dell'errore**. In particolare una variazione della variabile dipendente viene spiegata da una variazione del regressore X_t e dall'eventuale scostamento dall'equilibrio (disequilibrio) realizzatosi nel periodo precedente. Anche ipotizzando che $\Delta X_t = 0$ e che $\epsilon_t = 0$, la variazione di Y_t risulta diversa da 0 in virtù del fatto che $Y_{t-1} \neq cX_{t-1}$.

La velocità del ritorno all'equilibrio statico dipende dal valore del coefficiente $(\alpha_1 - 1)$. $\square$

(slide 21-22)

7.9. Interpretazione del coefficiente di aggiustamento e dinamica di ritorno all'equilibrio

Dimostrazione. Per interpretare $\alpha_y = \alpha_1 - 1$, si ipotizzi che il regressore sia stabile nel tempo, quindi $X_{t-1} = X_t = X_{t+1} = X_{t+2} = \dots$, che $\epsilon_t = 0$ e, per semplicità, che $a = 0$ e $Y_{t-1} - bX_{t-1} \neq 0$.

$$\Delta Y_t = \underbrace{\beta_0 \Delta X_t}_{=0} + \alpha_y (Y_{t-1} - bX_{t-1})$$

$$\Rightarrow Y_t = Y_{t-1} + \alpha_y (Y_{t-1} - bX_{t-1})$$

$$\Rightarrow Y_t - bX_t = Y_{t-1} + \alpha_y (Y_{t-1} - bX_{t-1}) - \underbrace{bX_t}_{=bX_{t-1} \text{ per ip.}} = (1 + \alpha_y)(Y_{t-1} - bX_{t-1})$$

$$\Rightarrow \Delta Y_{t+1} = \beta_0 \Delta X_{t+1} + \alpha_y (Y_t - bX_t) = \alpha_y (1 + \alpha_y)(Y_{t-1} - bX_{t-1})$$

$$\Rightarrow \Delta Y_{t+2} = \alpha_y (Y_{t+1} - bX_{t+1}) = \alpha_y (1 + \alpha_y)^2 (Y_{t-1} - bX_{t-1})$$

Tipicamente, osservando valori di $\alpha_y < 0$, ci si attende che il ritorno ad un nuovo equilibrio arrivi ad un tasso di $\alpha_y(1 + \alpha_y)^j$. Il ri-equilibrio si otterrebbe se $\Delta Y_{t+h} = 0$ ed in particolare

$$\Delta Y_{t+j} = \alpha_y (1 + \alpha_y)^j (Y_{t+j-1} - bX_{t+j-1})$$

È chiaro che quando $\Delta Y_{t+j} = 0$, vuol dire che il disequilibrio passato è stato riassorbito completamente dal sistema (non essendoci altre variabili che possono aver influenzato la dipendente, in particolare shock e regressori esogeni, che sono fissati). $\square$

(slide 23-24)

7.10. Esempio applicato: ECM per i tassi di interesse USA

Esempio 7.3. In precedenza è stato verificato come i tassi d'interesse USA a 3 mesi ed a 5 anni fossero legati da una relazione di cointegrazione. Risulta quindi possibile definire un modello a correzione dell'errore per descrivere tale relazione:

$$\underbrace{\Delta r60_t}_{\text{staz.}} = \beta_1 \underbrace{\Delta r3_t}_{\text{staz.}} + \alpha \underbrace{(r60_{t-1} - a - b r3_{t-1})}_{\text{staz. se coint.}} + \epsilon_t$$

Per stimare questo modello occorre conoscere $r60_{t-1} - a - b r3_{t-1}$. Ma questi non sono altro che i residui della relazione di cointegrazione calcolati ad un ritardo. Quindi per stimare il modello a correzione dell'errore è sufficiente definire $\Delta r3_t$, $\Delta r60_t$ ed $\hat{\epsilon}_{t-1}$.

Procedura operativa (gretl): - Le variabili $\Delta r3_t$ e $\Delta r60_t$ si calcolano dal menu Aggiungi $\Rightarrow$ Differenze delle Variabili Selezionate. - I residui $\hat{\epsilon}_t$ si stimano a partire dall'output standard del modello di regressione $r60_t = a + b r3_t + \epsilon_t$, usando il menu Salva $\Rightarrow$ Residui $\Rightarrow$ Nome dei residui. - Il modello ECM si stima dal menu Modello $\Rightarrow$ OLS, definendo i regressori e la variabile dipendente. Per includere il ritardo di $\hat{\epsilon}_t$ basta usare l'opzione Ritardi e definire 1 sia come ritardo minimo che come ritardo massimo.

Risultato. OLS, usando le osservazioni 1947:01-1991:02 ($T = 530$), variabile dipendente d_r60 :

	coefficiente	errore std.	rapporto t	p-value
const	0.00691546	0.0116796	0.5921	0.5540
d_r3	0.438546	0.0216191	20.29	4.80e-68 ***
uhat_1	-0.0658423	0.0124831	-5.275	1.95e-07 ***

E.S. della regressione: 0.268831.

Il coefficiente di *uhat_1* suggerisce che un disequilibrio osservato a $t - 1$ viene assorbito nella misura di 0.065 punti percentuali al periodo t .

(slide 25-27)

7.11. La rappresentazione VECM (Vector Error Correction Mechanism)

Dimostrazione. Le relazioni di cointegrazione si prestano bene ad analizzare modelli di equilibrio economico nel contesto di modelli dinamici. Si consideri ad esempio un modello **multivariato**, che descrive congiuntamente la dinamica di due variabili non stazionarie X ed Y :

$$X_t = \delta_x + \phi_{11}X_{t-1} + \phi_{12}Y_{t-1} + \epsilon_{x,t}$$

$$Y_t = \delta_y + \phi_{22}Y_{t-1} + \phi_{21}X_{t-1} + \epsilon_{y,t}$$

Alcuni passaggi algebrici permettono di riparametrizzare il modello come segue:

$$\Delta X_t = \delta_x - \phi_{12}(Y_{t-1} - \beta_x X_{t-1}) + \epsilon_{x,t}$$

$$\Delta Y_t = \delta_y - (1 - \phi_{22})(Y_{t-1} - \beta_y X_{t-1}) + \epsilon_{y,t}$$

ΔX_t , ΔY_t , $\epsilon_{x,t}$ ed $\epsilon_{y,t}$ sono stazionari per costruzione. Il modello risulta ben definito solo se $(Y_{t-1} - \beta_x X_{t-1})$ e $(Y_{t-1} - \beta_y X_{t-1})$ sono stazionarie. Di conseguenza deve esistere una relazione di cointegrazione tra X ed Y .

È possibile dimostrare che, nel caso di soli due processi cointegrati, tutti i possibili coefficienti di cointegrazione sono **proporzionali**. Questo consente di ottenere $\beta_x = \beta_y = \beta$ e quindi:

$$\Delta X_t = \delta_x - \alpha_x(Y_{t-1} - \beta X_{t-1}) + \epsilon_{x,t}$$

$$\Delta Y_t = \delta_y - \alpha_y(Y_{t-1} - \beta X_{t-1}) + \epsilon_{y,t}$$

Questo modello è definito **Meccanismo a Correzione dell'Errore Vettoriale**, o **VECM** (Vector Error Correction Mechanism). □

(slide 28–29)

7.12. VECM semplificato e interpretazione economica dell'aggiustamento

Esempio 7.4. Per capire come funziona in pratica il meccanismo di correzione dell'errore, è utile considerare il seguente sistema VECM semplificato, in cui $\delta_x = \delta_y = \alpha_x = 0$ e $\alpha_y > 0$:

$$\Delta X_t = \epsilon_{x,t}$$

$$\Delta Y_t = -\alpha_y(Y_{t-1} - \beta X_{t-1}) + \epsilon_{y,t}$$

In questo caso la variazione attesa ΔY_t risulta

$$E[\Delta Y_t | \text{passato}] = -\alpha_y(Y_{t-1} - \beta X_{t-1})$$

quindi dipende dal disequilibrio osservato nel periodo precedente. È opportuno notare che se le variabili fossero espresse in termini logaritmici, allora si dovrebbero interpretare i risultati in termini di variazioni percentuali o tassi di crescita.

Sulla base del modello precedente si possono verificare 3 possibili situazioni:

- (a) **Nessun disequilibrio a $t - 1$** , cioè $Y_{t-1} = \beta X_{t-1}$, per cui $E[Y_t | \text{passato}] = Y_{t-1}$. Se a $t - 1$ si osserva equilibrio, ci si aspetta che le variabili rimangano in tale situazione.
- (b) $Y_{t-1} > \beta X_{t-1}$: ci si attende una variazione negativa di Y . Per compensare un disequilibrio positivo occorre che Y_t decresca per tornare in equilibrio.
- (c) $Y_{t-1} < \beta X_{t-1}$: ci si trova in una situazione sotto il livello di equilibrio; per compensare a tale situazione ci si aspetta che Y cresca.

La velocità con cui si ritorna ad un livello di equilibrio è determinata dal coefficiente $\alpha_y > 0$.

(slide 30–31)

7.13. Esempio: ritorno all'equilibrio nel VECM semplificato

Esempio 7.5. Si consideri il modello semplificato definito in precedenza. Si ipotizzi:

- Viene osservato un disequilibrio iniziale pari a $(Y_{t-1} - \beta X_{t-1}) = 2$;
- X sia costante nel tempo, quindi $X_{t-1} = X_t = \dots = X_{t+j}$, ed $\epsilon_{y,t} = 0, \forall t$.

$$\Delta Y_t = -\alpha_y(Y_{t-1} - \beta X_{t-1}) \Rightarrow Y_t = Y_{t-1} - \alpha_y(Y_{t-1} - \beta X_{t-1})$$

$$\Rightarrow Y_t - \beta X_t = (1 - \alpha_y)(Y_{t-1} - \beta X_{t-1})$$

$$\Rightarrow \Delta Y_{t+1} = -\alpha_y(1 - \alpha_y)(Y_{t-1} - \beta X_{t-1})$$

Analogamente si ottiene

$$Y_{t+1} - \beta X_{t+1} = (1 - \alpha_y)(Y_t - \beta X_t) \Rightarrow \Delta Y_{t+2} = -\alpha_y(1 - \alpha_y)(Y_t - \beta X_t)$$

In generale, infine,

$$Y_{t+j-1} - \beta X_{t+j-1} = (1 - \alpha_y)(Y_{t+j} - \beta X_{t+j})$$

$$\Rightarrow \Delta Y_{t+j} = -\alpha_y(1 - \alpha_y)(Y_{t+j-1} - \beta X_{t+j-1}), \quad \forall j \geq 0$$




Figura — Andamento di $E[\Delta Y_t | \text{passato}]$ per diversi valori di α_y ($\alpha_y = 0.5$, $\alpha_y = 1$, $\alpha_y = 2$), sull'orizzonte temporale $t = 0, \dots, 10$, partendo da un disequilibrio iniziale pari a 2. Il grafico mostra che con $\alpha_y = 1$ il disequilibrio viene riassorbito immediatamente (un solo periodo), con $\alpha_y = 0.5$ il ritorno all'equilibrio è più lento e monotono, mentre con $\alpha_y = 2$ il sistema oscilla attorno allo zero con ampiezza decrescente prima di stabilizzarsi: valori di α_y superiori a 1 generano un aggiustamento oscillante (overshooting), mentre valori tra 0 e 1 generano un aggiustamento monotono verso l'equilibrio.

(slide 32–33)