Università Ca' Foscari Venezia

Dipartimento di Economia

Laurea Magistrale in
Economia e Finanza

Econometria

Dispensa del corso

Appunti di:
Silvio Angelo Baratto Roldan

Contenuto:
7 capitoli · 337 slide di riferimento

Anno Accademico:
2026/2027

Appunti rielaborati dal materiale didattico ufficiale del corso. Documento a uso personale di studio.

Indice

1	**Econometria — Introduzione al corso**	**1**
2	**Econometria — Il Modello di Regressione Semplice**	**20**
3	**Il modello di regressione multipla**	**44**
4	**Test F per le restrizioni multiple**	**63**
5	**L'ipotesi di Eteroschedasticità**	**71**
6	**Introduzione ai Modelli Dinamici**	**83**
7	**Econometria — Introduzione alla Cointegrazione**	**120**

1 | Econometria — Introduzione al corso

Fonte: ECON_Teoria_01_Introduzione-al-corso.pdf — *32 slide*

1.1. Informazioni generali sul corso

Docente: Davide Raggi. Lezione del 11 novembre 2025.

Syllabus (sintesi)

- Elementi fondamentali dell'analisi di regressione con dati cross section:
  - il modello di regressione semplice con un regressore;
  - sistemi d'ipotesi ed intervalli di confidenza;
  - il modello di regressione multipla;
  - omoschedasticità ed eteroschedasticità.
- Regressioni con serie storiche:
  - modelli dinamici;
  - dati stazionari e non stazionari;
  - modelli autoregressivi ed a media mobile;
  - regressioni spurie e test di stazionarietà;
  - cointegrazione (approccio di Engle-Granger).
- Applicazioni con il software GRETL.

Altre informazioni

- Esercitazioni: Marco Bidoia.
- Materiale didattico: pagina Moodle del corso "Econometria", anno 2025/2026 (https://moodle.unive.it/course/view.php?id=22785).
- Metodi didattici: lezioni in presenza e materiale supplementare (materiali e ricevimenti aggiuntivi dedicati agli studenti aventi diritto, nella sezione Moodle "Accessibilità e Supporto allo studio").
- Software: Gretl (https://gretl.sourceforge.net/).

Libro di testo

- *Principi di econometria*, 2013, C. Hill, W. E. Griffiths e G. C. Lim, Ed. Zanichelli.
  - Modelli di regressione: capitoli 2–8.
  - Serie storiche: capitoli 9, 10 e 12.

(slide 1–4)

Dalla lezione del 10 novembre 2026: impostazione del corso. L'impostazione è più intuitiva che tecnica. Il corso si concentra sull'interpretazione economica ed è fatto soprattutto di ciò che non si deve fare, più che di come si eseguono i calcoli: lo scopo è dare la consapevolezza di che cosa evitare e di come riconoscere un modello che non va bene. La scelta del modello e delle variabili conta più della metodologia con cui si fanno poi i conti, e a guidarla è la teoria economica, non i dati.

L'econometria è una disciplina ibrida: la distinzione rispetto all'economia non è netta, mentre lo è quella rispetto alla statistica. A separarla dalla statistica è un'ipotesi aggiuntiva con un'importante implicazione economica, l'**ipotesi di esogeneità**, che si formalizza come assenza di correlazione tra qualcosa che non si osserva (l'errore del modello) e qualcosa che si osserva (le variabili esplicative). Se il modello è costruito senza rispettare le regole dell'economia, gli indicatori stimati sono sistematicamente distorti: ciò che si stima non è l'effetto della politica considerata, ma tale effetto sommato a un fattore di disturbo non eliminabile, e l'aumento del numero di osservazioni rende solo più precisa la stima sbagliata. Si finisce per interpretare come effetto di una politica la somma di più effetti collaterali, potenzialmente diversi da quello di interesse. Per lo stesso motivo non interessa che il modello approssimi bene i dati, ma che le relazioni logiche tra le variabili siano corrette.

Dalla lezione del 10 novembre 2026: esame, esercitazioni e materiali. **Esame.** La prova è scritta, tipicamente di una decina di domande, ma il numero non è fissato. Si chiede di interpretare risultati, analizzando grafici e tabelle, e di capire se un modello ha un problema oppure no; per la parte di serie storica si chiede inoltre di stabilire se un modello è corretto dal punto di vista metodologico e di interpretare gli effetti dinamici e statici di un modello dinamico. Non si chiede di eseguire le stime. I vecchi esami sono su Moodle e prima della prova si svolgeranno esercitazioni in stile esame (mock exam) con il docente, con il dottor Peruzzi o con il tutor. Conviene sciogliere i dubbi a ricevimento prima dell'esame, perché dopo il compito è ormai fatto; la visione del compito si fa solo di persona.

Esercitazioni e software. Per il 2026/27 le esercitazioni sono tenute dal dottor Peruzzi (le slide di questa nota, dell'edizione precedente, indicano il dottor Bidoia). Si usa Gretl, scelto perché è semplice, gratuito, disponibile su ogni piattaforma e lascia concentrare sulla parte econometrica più che sui comandi. Le lezioni empiriche contengono anche una componente di interpretazione. La prima tratta il riscalamento delle variabili con trasformazioni come il logaritmo e l'interpretazione degli effetti marginali, e la diagnosi della quasi collinearità: la collinearità esatta blocca il software, mentre quella quasi esatta non è facile da riconoscere e, se non ci si accorge del problema, si crede che il modello dia risultati corretti. Lo strumento diagnostico citato è, presumibilmente, il *variance inflation factor* (VIF).

Percorso. La prima parte riguarda ciò che non va guardato in un output di regressione e ciò che non va fatto quando i dati sono indipendenti. La seconda mostra che cosa cambia in un contesto di dipendenza temporale e quali modelli sfruttano l'inerzia delle serie. I modelli a correzione d'equilibrio sono l'ultimo argomento.

Materiali. Tutto il materiale è sulla pagina Moodle del corso (lucidi, dataset, vecchi esami), caricato prima delle lezioni. Conviene iscriversi manualmente alla pagina, così il docente può contattare tutti insieme. Il libro non è obbligatorio ma è discorsivo, ricco di esempi nei capitoli sulle serie storiche e sulla regressione, e mette a disposizione i dati degli esempi (anche in formato Excel) per replicare i calcoli. I lucidi sono una scaletta per il docente, messa a punto in circa trent'anni di insegnamento: il libro spiega il perché delle cose.

1.2. Cos'è l'econometria?

Definizione 1.1. Non esiste una definizione unica di econometria. Secondo il docente, si può definire come **un insieme di tecniche statistiche che hanno lo scopo di**:

- definire e misurare relazioni causali tra variabili economiche;
- validare la credibilità di modelli economici teorici;
- fare previsioni.

(slide 5)

Dalla lezione del 10 novembre 2026: previsione e spiegazione. Se lo scopo del modello è fare previsioni, la relazione logica tra le variabili non è rilevante: la previsione è un gioco statistico, per cui se x assume un certo livello y ne assumerà un altro. Per rifornire la catena di produzione della Nutella interessa sapere che in un certo periodo dell'anno bisogna acquistare 7 tonnellate di nocciole, non perché la gente la mangi. Se invece si vuole capire perché la gente compra la Nutella, per esempio per decidere di cambiare la ricetta o il packaging, bisogna individuare i driver della variabile, e la sola associazione statistica non basta. Il corso riguarda soprattutto questo secondo scopo, perché il primo, con un modello banale, si ottiene in modo quasi automatico.

1.3. Causalità: definizione e criteri

Definizione 1.2. Un legame causale tra due variabili X e Y, indicato $X \to Y$, specifica che X è una variabile esplicativa che ha impatto su Y: questa dipendenza non è simmetrica, cioè Y non causa X.

Si può parlare di **causalità** se i seguenti tre criteri valgono **contemporaneamente**:

1. **Associazione tra le variabili.**
2. **Un ordine logico/temporale**: la causa precede l'effetto (prima si implementa una politica, poi se ne misura l'impatto). Alcune variabili non possono essere conseguenza di una decisione (ad esempio il sesso, la razza, l'età) e per questo possono essere considerate cause. In altri casi non è facile capire quale sia la causa e quale l'effetto: ad esempio, nei periodi di alta disoccupazione i tassi di criminalità sembrano aumentare. La disoccupazione è una causa? Forse, ma potrebbe esserci **causalità inversa**: in aree ad alta criminalità le imprese potrebbero chiudere, aumentando la disoccupazione.
3. **L'esclusione di spiegazioni alternative.**

(slide 6)

Dalla lezione del 10 novembre 2026: associazione e direzione del legame. Il primo criterio è statistico perché, senza una relazione statistica, una variazione di x non avrebbe alcun impatto su y e il problema non si porrebbe. Ma la correlazione è simmetrica: quella tra x e y e quella tra y e x sono lo stesso numero, quindi non dice nulla sulla direzione e indica solo un legame di qualche natura, non necessariamente logico. Per parlare di causalità servono ipotesi aggiuntive: un legame logico, e non solo statistico, con una variabile che anticipa l'altra non soltanto nel tempo ma nella logica, e una storia che spieghi perché esiste quel legame statistico. Non basta che la storia sia plausibile: deve essere unica.

1.4. Esempio: consumo di caffè e probabilità d'infarto

Esempio 1.1. Alcuni studi epidemiologici hanno evidenziato un'associazione positiva tra la probabilità di avere un infarto (variabile Y) e il consumo di caffè (variabile X).

- Un possibile link causale: bere caffè aumenta la pressione sanguigna, che rappresenta un fattore di rischio per questa patologia.

Altri studi hanno mostrato che, una volta controllato per altri fattori (tipo di lavoro, residenza, genere, reddito, livello di stress), l'associazione condizionata si riduce a zero.

- Questo fornisce una spiegazione alternativa: persone con lavori più stressanti bevono più caffè. È il lavoro stressante il fattore determinante per la probabilità di avere un infarto, e non il caffè.

In pratica, in questo esempio (non supportato da analisi empiriche reali) esiste una variabile Z, lo stress, che ha un impatto congiunto su X e Y. La relazione tra X e Y viene detta **spuria**, ed è indotta da Z: in questo caso la relazione spuria è indotta da una variabile omessa nello studio.

(slide 7–8)

1.5. Esempio: boy scout e criminalità

Esempio 1.2. Si vuole investigare la relazione tra l'essere stati boy scout (S) e la criminalità giovanile (D), nel senso che ci si aspetta che aver frequentato i boy scout riduca la probabilità di commettere crimini.

Alcune evidenze empiriche (dati non reali) sono sintetizzate nella tabella seguente:

Tabella 1 — Essere boy scout e crimine

Boy scout	Delinquency: Yes	Delinquency: No	Total
Yes	36 (9%)	364 (91%)	400
No	60 (15%)	340 (85%)	400

L'evidenza empirica suggerisce una relazione negativa tra S e D. Dal punto di vista logico questo legame sembra sensato, per cui $S \to D$. Tuttavia non possiamo escludere che un criminale possa aver evitato ambienti "virtuosi", per cui anche la relazione inversa ha senso logico: $D \to S$.

- Entrambe le spiegazioni sono ragionevoli.
- L'ordinamento logico non è chiaro, quindi non possiamo parlare di causalità.

(slide 9–10)

Dalla lezione del 10 novembre 2026: causalità inversa. Chi sostiene $S \to D$ osserva che chi ha fatto il boy scout è stato educato al rispetto di regole e principi ed è quindi meno incline a delinquere. Chi sostiene $D \to S$ osserva che chi è avverso alle regole difficilmente si iscrive a un ambiente che ne impone molte. Il legame statistico, essendo simmetrico, non permette di scegliere tra le due letture. Questa situazione si chiama *reverse causality* (causalità inversa) e rende problematica la stima di una relazione di causa ed effetto: per questo, prima ancora di costruire il modello, bisogna ragionare sui possibili legami logici tra le variabili. I dati della tabella non sono reali: il docente li ha ricopiati da un libro di statistica.

1.6. Causalità: l'impossibilità di dimostrarla e il ruolo della confutazione

In generale **non è possibile dimostrare l'esistenza di una relazione causale**, perché quasi mai è possibile escludere tutte le altre possibili spiegazioni di un fenomeno. Spesso non si riescono a controllare tutte le spiegazioni alternative (sono troppe) rispetto a un certo livello di associazione misurato.

Possiamo però **confutare** ipotesi di causalità: se riusciamo a confutare tutte le ipotesi tranne una, possiamo essere abbastanza certi nel definire il legame come nesso causale. *(slide 11)*

Dalla lezione del 10 novembre 2026: come si lavora senza una risposta definitiva. Ogni volta che si costruisce un modello bisogna chiarire perché lo si costruisce e perché si scelgono certe variabili, e verificare poi se descrive le aspettative, per esempio se i coefficienti hanno il segno atteso: un segno sbagliato può indicare che le correlazioni attese non sono stimate in modo corretto. Il modello proposto non sarà quello definitivo, ma contribuisce al lavoro di altri che provano modelli alternativi, finché si arriva a un consenso in cui le spiegazioni concorrenti sono state escluse.

Si procede sempre in questo ordine: prima si individuano i potenziali driver sulla base della teoria, poi si inseriscono nel modello. Il contrario, cioè mettere nel modello tutte le variabili e selezionarle finché si trova qualcosa di gradito in termini di segni, non è sufficiente: la teoria

deve definire a priori i legami logici e non ci si può far raccontare la storia dalla correlazione. È difficilissimo trovare relazioni causali, ma con un po' di pazienza qualcosa si trova.

1.7. Esempio: fumo e cancro ai polmoni

Esempio 1.3. L'associazione tra fumo e probabilità di tumore è ampiamente documentata. È sintomo di legame causale?

- Esiste una ricca letteratura epidemiologica che documenta la relazione tra le due variabili.
- Esiste un legame logico sensato (il cancro si manifesta di solito dopo un consumo intensivo di sigarette).
- Non sono state trovate, nella letteratura epidemiologica, spiegazioni alternative più convincenti. Esistono inoltre evidenze teoriche che spiegano il legame tra fumo e malattia.

A differenza dei casi precedenti (caffè, boy scout), questo esempio soddisfa tutti e tre i criteri di causalità: associazione, ordine logico/temporale, esclusione di spiegazioni alternative.

(slide 12)

Dalla lezione del 10 novembre 2026: il caso del fumo. L'associazione tra fumo e gravi malattie ai polmoni non basta, da sola, a stabilire il nesso di causa. Nel corso di decenni, e non di settimane, sono state testate varie ipotesi e sono stati individuati meccanismi biologici per cui il consumo di sigarette può aumentare l'incidenza di certe malattie. Poiché potrebbero esistere altri meccanismi non ancora visti, il risultato non è definitivo in senso assoluto: oggi si ritiene che la relazione causale esista, ma se un biologo trovasse un'alternativa più convincente bisognerebbe ripensare tutto. La procedura avanza per affinamenti successivi, ed è praticamente impossibile trovare un modello che risolva tutti i problemi in modo definitivo.

1.8. Associazione non implica causalità

In generale, l'associazione tra variabili **non** è un criterio sufficiente per stabilire se un legame sia interpretabile come causale. Una raccolta (a scopo illustrativo) di associazioni spurie "divertenti" è disponibile su http://www.tylervigen.com/spurious-correlations.

Non è difficile trovare variabili fortemente associate ma non legate tra loro: come visto sopra, l'associazione in questi casi è un **legame spurio**.

Una volta osservato un legame statistico, è indispensabile spiegarlo dal punto di vista teorico e verificare che sia credibile anche dal punto di vista logico. *(slide 13)*

Dalla lezione del 10 novembre 2026: correlazioni spurie, R^2 e intelligenza artificiale. Il sito citato nasce da uno statistico che, partendo da un database di circa 10.000 variabili, ha fatto cercare a un programma le coppie più correlate possibili, senza considerare di quali variabili si trattasse. Due esempi:

- il numero di spettatori della serie televisiva *Big Bang Theory* e il numero di ricerche su Google che cominciano con «how to make»: le due serie sono quasi sovrapposte e l'R^2 della relazione è 96,5%;
- l'esito delle partite finali di lacrosse e i biglietti venduti al cinema negli Stati Uniti: la correlazione è elevata, dell'ordine del 74%.

Tra le variabili non c'è alcun legame logico. Dal punto di vista puramente previsivo si potrebbe usare una serie per prevedere l'altra, ma la correlazione non spiega perché una delle due si muova e quindi non permette alcuna analisi di scenario: se si trovasse una correlazione simile tra due variabili economiche senza rapporto reciproco, qualsiasi risultato di uno scenario sarebbe casuale e non replicabile.

L'R^2 è la misura peggiore per valutare un modello e nel corso non va usato come indicatore di bontà: dice che i dati sono ben approssimati, cioè che le due variabili si muovono insieme, non che il modello è logicamente corretto, che è ciò che si cerca. Anzi, i modelli buoni non hanno tipicamente un R^2 molto grande, e un R^2 troppo grande porta con sé problemi statistici non banali, noti come problemi di collinearità.

Lo stesso vale per l'intelligenza artificiale: se le si chiede perché due variabili abbiano una correlazione del 95%, una spiegazione viene sempre prodotta, che abbia senso o no. Il docente riporta il caso di una serie storica con un picco, che un sistema di intelligenza artificiale attribuì alla rivoluzione industriale di quegli anni, avvenuta in realtà circa un secolo prima o dopo. L'intelligenza artificiale può affinare l'intuizione, ma il controllo deve restare allo studente.

1.9. Tipi di dato

Definizione 1.3.

- **Cross Section**: tipo di dati che fanno riferimento a osservazioni raccolte in un unico istante temporale su molti soggetti (individui, Paesi, imprese). Esempio: il database STAR, che raccoglie osservazioni su scuole, bambini e alcune loro caratteristiche.
- **Serie storiche**: sequenze di osservazioni misurate sequenzialmente, spesso a intervalli regolari; il tempo definisce un ordine. Esempi: i prezzi di chiusura di un particolare asset finanziario, o il volume d'acqua orario di un fiume.
- **Dati Panel** (o longitudinali): fanno riferimento a cross section sui medesimi individui, osservate nel tempo. Ogni osservazione è caratterizzata da una doppia dimensione, tempo e soggetto. Esempio: l'evoluzione dei prezzi di un campione di case in un intervallo temporale limitato.

(slide 14)

1.10. Esempio Cross Section: dimensione della classe e punteggio ai test

Esempio 1.4. Il problema. Si pensa spesso che un basso rapporto studenti/insegnanti (*class size*) possa migliorare la performance degli alunni. In California, verso la fine degli anni '90, tutte le classi K-3 furono ridotte per ottenere un rapporto studenti/insegnanti pari a 20 (*Class Size Reduction Act* – CSR), con un costo iniziale di $1.8 miliardi annui. Per questo costo, ne vale davvero la pena?

Ci si chiede se la dimensione della classe sia l'unico (o il principale) fattore rilevante nello spiegare la variazione della performance attesa degli studenti, oppure se esistano ulteriori informazioni da considerare. Si vuole inoltre **quantificare** come una riduzione della dimensione della classe impatti sui voti degli alunni.

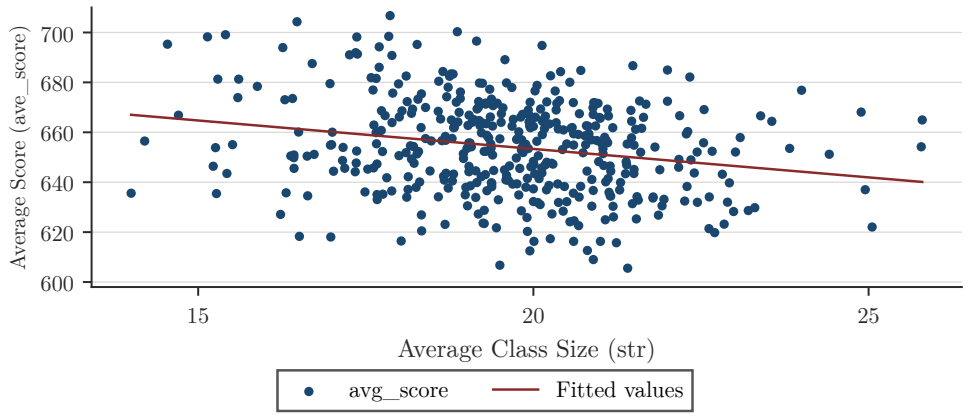


Figura 1 — Scatterplot delle variabili rilevanti (Fonte: *California Standardized Testing and Reporting Survey*, year 1999). Lo scatterplot mette in relazione l'*Average Class Size* (*str*, asse orizzontale) con l'*Average Score* (*avg_score*, asse verticale); la retta interpolante (*fitted values*) ha pendenza negativa: le classi più numerose sono associate a punteggi mediamente più bassi.

Sembrerebbe quindi che ridurre il rapporto studenti/insegnanti sia rilevante: a una riduzione della dimensione delle classi corrisponde un aumento medio dei punteggi. La correlazione tra le due variabili è **-0.2264** (ha il segno della pendenza della retta di regressione, che vale invece -2.28; le slide le identificano). Esiste inoltre un legame temporale e logico plausibile: prima viene implementata la policy, poi si valutano i benefici.

Un'altra possibile spiegazione. Un'analisi più dettagliata suggerisce che anche il reddito medio (*avginc*) delle persone che vivono in ogni distretto scolastico risulta positivamente correlato con il punteggio *avg_score*: distretti più ricchi tendono ad essere associati a voti migliori. Inoltre esiste una dipendenza negativa tra *income* e *class size* (*str*), suggerendo che distretti ad alto reddito sono legati a scuole in cui le classi sono mediamente più piccole.

Matrice di correlazione (comando `correlate avg_score str avginc`):

	avg_score	str	avginc
avg_score	1.0000		
str	-0.2264	1.0000	
avginc	0.7124	-0.2322	1.0000

Sulla base di questi risultati, ci si chiede se sia il **reddito** la variabile rilevante per spiegare la performance, e non la dimensione della classe.

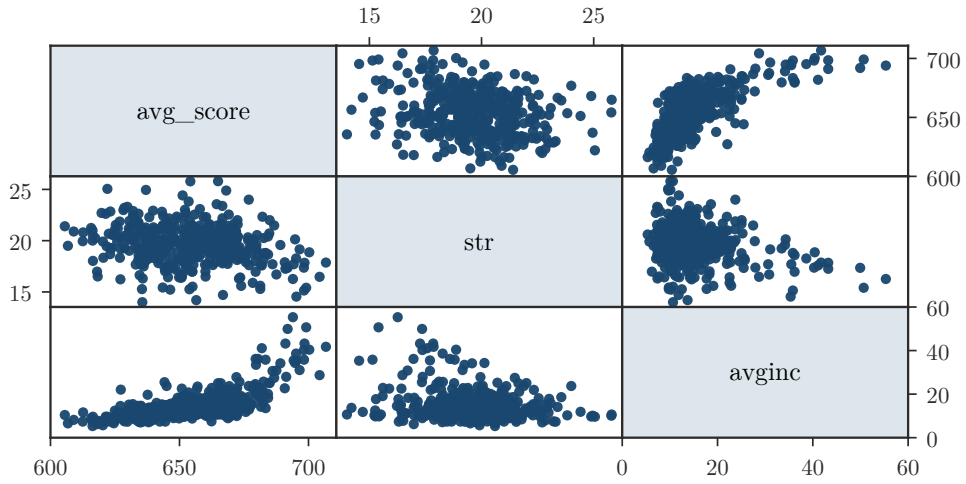


Figura 2 — Scatterplot delle variabili a coppie. La matrice di scatterplot incrocia *avg_score*, *str* e *avginc* a due a due e conferma visivamente le correlazioni riportate nella matrice sopra (in particolare la forte associazione positiva tra *avg_score* e *avginc*).

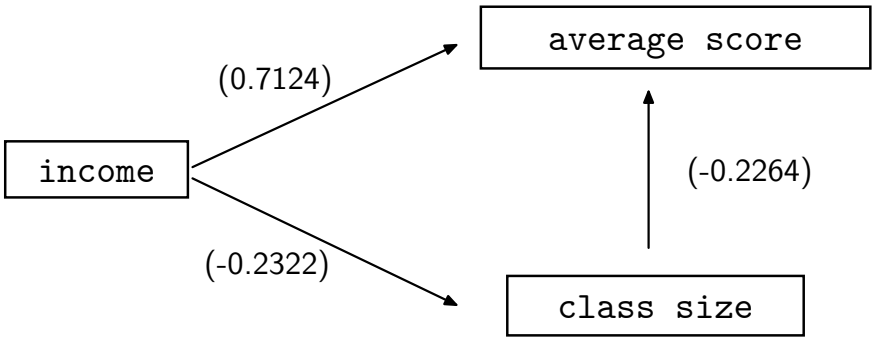


Figura 3 — Rappresentazione causale del nuovo modello (in parentesi le correlazioni): *income* → *average score* (0.7124), *income* → *class size* (-0.2322), *class size* → *average score* (-0.2264). Il diagramma mostra uno schema in cui il reddito (*income*) influisce sia sul punteggio medio sia sulla dimensione delle classi, e può quindi generare una correlazione osservata (ma potenzialmente spuria) tra *class size* e *average score*.

Questa evidenza empirica suggerisce che la dipendenza negativa tra *class size* e *performance* potrebbe essere **spuria**, poiché può essere spiegata dall'effetto reddito. Questa relazione causale più complessa offrirebbe una nuova spiegazione del fenomeno.

Verifica: controllo per il reddito. Cosa si può fare? Si divide il dataset in due parti: da un lato i distretti ad alto reddito, dall'altro quelli a basso reddito. In questi due sottoinsiemi si calcola la correlazione tra *class size* e *test score*. In questo modo è possibile controllare l'effetto reddito, poiché ogni sottoinsieme è omogeneo rispetto a quel fattore: quindi l'effetto reddito dovrebbe non essere più rilevante.

- Nei distretti a **basso reddito**, la correlazione tra *class size* e *test score* è **-0.1464**, debolmente statisticamente significativa.
- Nei distretti ad **alto reddito** la correlazione è **-0.1962**, comunque non significativa.

Quindi, una volta controllato l'effetto reddito, la correlazione tra la variabile di policy *class size* e *test score* viene praticamente azzerata. Questo è, con buona probabilità, il sintomo di una relazione **spuria**.

(slide 15–22)

Dalla lezione del 12 novembre 2026: il problema della dimensione della classe e i tre ingredienti della causalità. Il docente considera l'intuizione la cosa più importante da capire in questa parte: una volta acquisita, formalizzarla con concetti statistico-matematici è abbastanza semplice.

Il docente descrive i bambini come quelli della scuola prescolastica (asilo, scuola dell'infanzia); la nota riferisce la riduzione alle classi K-3. Che cosa significhi "utile" per un programma di questo tipo è una questione più filosofica che statistica e non spetta all'econometrico. Qui "vanno meglio" significa che i bambini ottengono risultati migliori nei test di fine anno. Che sia così è intuitivo: in classi più piccole l'insegnante dedica più tempo a ogni bambino, con miglioramenti nelle capacità pratiche e astratte.

La policy costa molto, perché servono più docenti e una riorganizzazione delle classi: con 100 bambini, classi da 10 anziché da 20 richiedono più classi, più computer e più attrezzatura. Il docente quantifica l'investimento, a memoria, in circa 1,8 miliardi di dollari l'anno, e nel seguito parla di circa due miliardi. La spesa ha senso se la variabile su cui si interviene è in relazione causale con la performance dei bambini: serve un modello causale che dica se la dimensione della classe sia un driver, non statistico ma logico, di tale performance.

I dati sono quelli dei distretti scolastici della California, circa 420, e ogni punto dello scatterplot è un distretto. Sull'asse delle ascisse c'è la dimensione media delle classi della scuola dell'infanzia del distretto, su quello delle ordinate il punteggio medio dei bambini del distretto in un test standardizzato, che valuta competenze di matematica, logica e lingua adatte all'età. La pendenza negativa della retta è il primo ingrediente della relazione causale: la correlazione tra le due variabili è minore di zero. Se la diminuzione sia piccola o grande non spetta a questa analisi. Il secondo ingrediente è una spiegazione logica, che il docente ritiene soddisfatta in termini generali:

classi più piccole significano più attenzione a ciascun bambino e un lavoro più focalizzato. Non è detto che la spiegazione sia corretta, ma è plausibile.

Il terzo ingrediente richiede di poter escludere spiegazioni alternative più convincenti. Per stabilirlo si fanno altri esperimenti e si provano modelli alternativi. Una spiegazione esaustiva non si troverà, perché non si possono costruire infiniti modelli che spieghino in modo alternativo la correlazione negativa: si considera una serie di alternative ragionevoli per vedere se la teoria resta la strategia migliore o se c'è qualcosa di meglio. Stimando la pendenza della retta si potrebbe poi valutare, per esempio, se la riduzione di un'unità della dimensione della classe produca un beneficio di 10 punti al test, che sono molti o pochi a seconda della scala del test. Il problema ora non è però quantificare gli effetti, ma capire se esistano modelli migliori, e questi possono passare per l'analisi congiunta di altre variabili.

Dalla lezione del 12 novembre 2026: perché il reddito può spiegare la relazione negativa. Il reddito ha impatto su fondamentalmente tutte le scelte, e i distretti ad alto reddito potrebbero avere performance migliori per due vie. In primo luogo le famiglie possono permettersi di comprare più libri ai bambini, e questo può riflettersi in una migliore performance scolastica. In secondo luogo i distretti ad alto reddito potrebbero avere scuole mediamente migliori. Nei dati americani il distretto di appartenenza conta: dove ci sono buone scuole pubbliche, la scuola privata costa moltissimo già dalle elementari, nell'ordine di decine di migliaia di dollari l'anno, e chi non può permettersela vorrebbe una scuola pubblica, ma il livello delle scuole pubbliche è abbastanza eterogeneo. Le scuole pubbliche molto buone si trovano in zone dove il prezzo delle case è estremamente più alto, per cui la scuola pubblica buona, che costa relativamente poco, è in un distretto ricco. Il reddito può dunque incidere sulla qualità della scuola, che a sua volta incide sui risultati dei bambini.

Il reddito potrebbe così avere un effetto positivo sulla performance e un effetto negativo sulla dimensione della classe, perché le scuole migliori hanno già classi più piccole, magari perché hanno più insegnanti. Negli Stati Uniti il concetto di dimensione della classe è particolare: non ci sono necessariamente classi fisse, perché le classi si formano di volta in volta, e la dimensione viene calcolata come rapporto studenti-insegnanti. Una scuola migliore può avere più insegnanti e altre caratteristiche favorevoli. Se esistono una relazione negativa tra reddito e dimensione della classe e una relazione positiva tra reddito e performance, la relazione negativa osservata tra le due variabili iniziali potrebbe passare per l'effetto del reddito.

Dalla lezione del 12 novembre 2026: come si controlla per il reddito e che cosa si conclude. Si vuole evitare che il reddito sia il vero driver, e quindi si controlla per il reddito. Prendendo due distretti molto ricchi e calcolando tra loro la dipendenza tra dimensione della classe e performance, la correlazione non può dipendere dal reddito, perché le osservazioni provengono da un contesto molto omogeneo. Per questo il campione si divide in distretti ricchi e poveri e in ciascun sottocampione si calcola la correlazione tra le due variabili. Se le due correlazioni sono diverse, il reddito ha potere esplicativo: per spiegare la correlazione negativa bisogna passare per il reddito, il modello precedente va scartato perché non soddisfacente e si passa al modello

esteso. Se restano uguali, la relazione è la stessa indipendentemente dal reddito, aggiungerlo non ha alcuna utilità pratica e tanto vale usare il modello precedente, quello senza reddito.

L'analisi mostrata è molto grossolana: si calcola la mediana del reddito, e i distretti sotto la mediana sono classificati a basso reddito, quelli sopra ad alto reddito. Come funzioni il procedimento si vedrà meglio con il modello di regressione. Per i distretti a basso reddito la correlazione tra dimensione della classe e performance diventa piuttosto piccola e, secondo il docente, in un test di significatività non risulta statisticamente significativa; la nota riporta per questi distretti -0.1464, debolmente significativa. Il reddito sembra quindi il driver principale della correlazione negativa: condizionatamente al reddito basso, la correlazione condizionale tra dimensione della classe e performance è sostanzialmente zero. Secondo il docente, anche per i distretti ad alto reddito la correlazione è piuttosto bassa e il test la indica come non significativa, con un p-value leggermente più alto, comunque non sufficiente a giustificare un livello di significatività; la nota riporta per questi distretti -0.1962.

Ricalcolando sul dataset del corso (`ECON_Dataset_caschool.csv`, 420 distretti) le correlazioni complessive coincidono con la nota (-0.2264 tra dimensione della classe e punteggio, 0.7124 tra reddito e punteggio), ma quelle nei sottocampioni no. Dividendo alla mediana del reddito (13.73) si ottiene -0.130 per il basso reddito ($t = -1.89$, debolmente significativa) e -0.336 per l'alto reddito ($t = -5.14$, significativa); dividendo alla media (15.32), -0.1464 ($t = -2.41$) e -0.385 ($t = -5.10$). Il -0.1464 della nota si riproduce quindi con la divisione alla media e non alla mediana, mentre il -0.1962 per l'alto reddito non si riproduce con nessuna delle due. Per l'alto reddito la correlazione condizionale risulta significativa in entrambe le divisioni: l'affermazione che sia non significativa, che il docente riprende dalle slide, non trova riscontro in questo dataset. L'esempio resta valido come illustrazione del ragionamento sul controllo per una terza variabile, ma la conclusione numerica che il reddito spieghi da solo la correlazione negativa non è confermata dai dati.

Secondo il docente, controllando per il reddito la correlazione tra la variabile su cui si vorrebbe investire e la performance è dunque non significativa. Il nuovo modello, che passa per il reddito, contiene più informazione, ha senso a parole e supera il precedente: le conclusioni inferenziali escludono il modello precedente, e la correlazione marginale non è così importante perché quella condizionale ai livelli di reddito non è statisticamente significativa.

Per il responsabile politico della California (provveditore, ministro o equivalente) la questione è se i circa due miliardi di dollari l'anno da spendere servano a migliorare la performance. Se la correlazione negativa fosse un semplice effetto collaterale del reddito, assumere nuovi docenti probabilmente non sarebbe utile, perché si interverrebbe su una variabile solo apparentemente legata alla performance dei bambini, da cui questa non dipende direttamente. Sarebbe forse più opportuno dare sussidi alle famiglie meno ricche, se l'obiettivo è migliorare la performance, perché il reddito sembra la variabile chiave.

L'analisi non è conclusa, perché potrebbero esserci altri fattori. Si ha però un meccanismo di scelta: si estende il modello, si verifica se migliora il precedente, si fanno valutazioni di natura logica e si traggono le conclusioni. La strategia è non fissarsi sul modello e sull'idea iniziali,

ma estenderli per capire quale sia la spiegazione migliore della correlazione negativa osservata all'inizio, cioè perché esista.

Dalla lezione del 12 novembre 2026: estendere il modello con coerenza logica. Per capire se una relazione sia causale, uno dei problemi principali è incrementare il modello in modo logico e verificare se il nuovo modello migliora il precedente. Il modello più esteso deve mantenere sempre coerenza logica, con una spiegazione che valga la pena di usare. Non si possono inserire informazioni come il numero di persone che in California vanno a vedere il film di Nicolas Cage: potrebbero essere correlate, ma la correlazione potrebbe dipendere da qualunque cosa. Quando si inserisce una variabile nel modello serve una storia da raccontare, e non si lascia che siano i dati a dire che cosa si vuole spiegare. Il docente indica questo come il punto più importante.

1.11. Serie storiche: il modello CAPM

Teorema 1.1. In ambito finanziario si ipotizza spesso che gli investitori abbiano bisogno di incentivi per aumentare il rischio che sono disposti ad accollarsi: i rendimenti attesi R di un investimento rischioso dovrebbero essere maggiori di quelli di un investimento non rischioso (*risk-free*, R_f). Gli extra rendimenti $R - R_f \geq 0$ dovrebbero quindi essere positivi.

Il rischio viene spesso descritto tramite la varianza; può essere minimizzato costruendo portafogli diversificati, comprando o vendendo asset i cui prezzi sono correlati alle variazioni di mercato. Misurare il rischio richiede quindi, oltre alle varianze, la struttura di covarianza tra l'investimento e il mercato.

Il modello **CAPM** (*Capital Asset Pricing Model*) è stato proposto per descrivere la relazione tra i rendimenti di un portafoglio generico e il *portafoglio di mercato*. Gli investitori decidono come allocare le proprie risorse massimizzando il rendimento atteso di un portafoglio, mantenendo fissato il livello di rischio.

In equilibrio si dimostra che deve valere:

$$\underbrace{E[R_t]}_{\text{Rendimenti attesi}} = \beta \underbrace{E[(R_{mt})]}_{\text{Rendimento del mercato}}$$

Ci si chiede se questa relazione teorica sia credibile dal punto di vista empirico. (Il CAPM vale per gli extra rendimenti: R_t e R_{mt} vanno letti al netto di R_f, cioè $E[R_t] - R_f = \beta\,(E[R_{mt}] - R_f)$; le slide omettono R_f.)

Si ipotizzi di descrivere la relazione come segue:

$$E[R_t] = \alpha + \beta R_{mt}$$

La variabilità di R_t può essere descritta aggiungendo una componente di *noise* ϵ_t, che descrive

l'impatto di notizie improvvise, con media 0 e varianza σ^2. Quindi:

$$R_t = \alpha + \beta R_{mt} + \epsilon_t$$

dove:

- R_t sono i rendimenti di un asset all'istante t;
- R_{mt} rappresenta i rendimenti del mercato a t;
- $\beta = \dfrac{\mathrm{Cov}(R_t, R_{mt})}{\mathrm{Var}(R_{mt})}$;
- ϵ_t è una componente non prevedibile che rappresenta uno shock finanziario;
- α è un'intercetta (costante).

(slide 23–25)

Dalla lezione del 10 novembre 2026: perché il CAPM si valida con l'intercetta. Il CAPM non è un'equazione ma il risultato di due pagine di algebra che poggiano su molte ipotesi: che il mercato dei capitali e quello dei tassi di interesse siano in equilibrio, che gli investitori costruiscano i portafogli con l'algoritmo di Markowitz. Se il modello fosse vero, un investimento non dovrebbe garantire in media alcun premio oltre quello proporzionale al rischio di mercato, e in termini operativi la regressione non può avere intercetta. La validazione consiste allora nello stimare una regressione che include l'intercetta e nel verificare se è uguale a zero: si usa una metodologia econometrica per controllare se un modello economico è coerente con i dati, perché un modello incoerente con ciò che si osserva ha poca utilità.

Se il test non supporta il modello, non si può semplicemente aggiungere un'intercetta: significherebbe cambiare tutte le equazioni e le ipotesi su cui poggia la derivazione. Bisogna rispecificare il modello economico in modo che il modello statistico accetti quelle variazioni. La validazione di una teoria rispetto ai dati è la terza funzione dell'econometria, e quella che al docente interessa di più.

1.12. Serie storiche: verifica empirica del CAPM

Esempio 1.5.

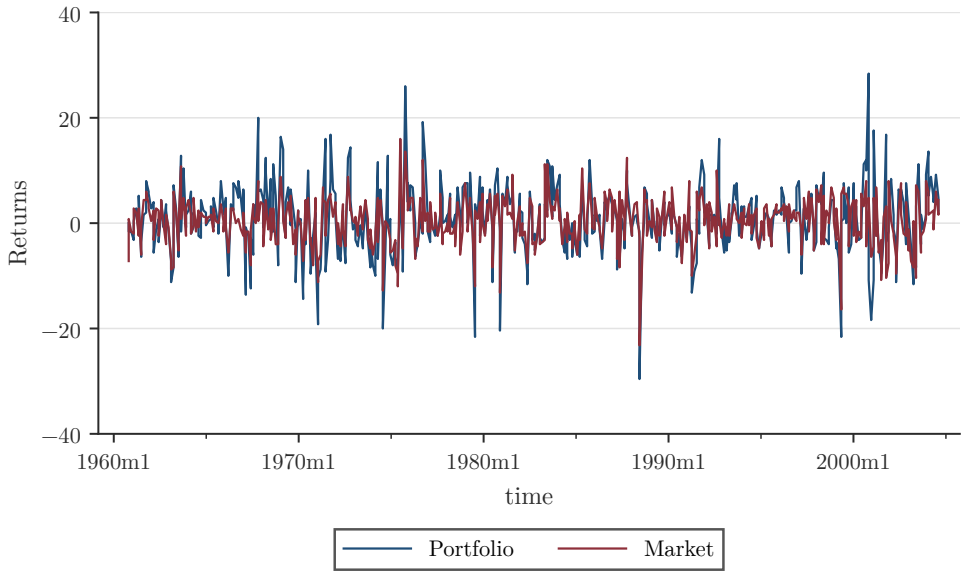


Figura 4 — Serie storiche dei rendimenti del portafoglio (*Portfolio*) e del mercato (*Market*) nel tempo, dal 1960 al 2004 circa. I due andamenti mostrano un forte comovimento: i rendimenti del portafoglio seguono da vicino le oscillazioni dei rendimenti di mercato, con ampiezza leggermente maggiore nei picchi (positivi e negativi).

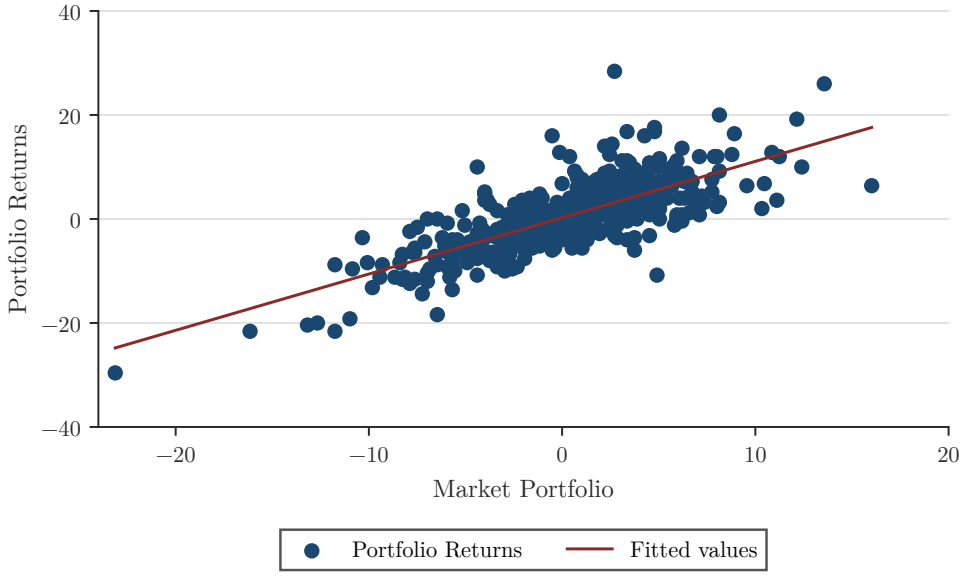


Figura 5 — Scatterplot di *Portfolio Returns* contro *Market Portfolio*, con retta di regressione interpolante (*fitted values*). La nuvola di punti mostra una chiara relazione lineare positiva, con pendenza superiore a 1, coerente con un β maggiore di uno.

Se il modello CAPM fosse coerente con i dati, ci si aspetta che il parametro α sia 0. Per verificarlo è quindi necessario stimarlo e testare l'ipotesi che sia nullo. L'analisi di regressione può essere utilizzata a questo scopo.

- Una stima credibile per β è **1.083759**, con errore standard **.0404768**. L'intervallo di confidenza al 95% è **[1.004; 1.163]**, che suggerisce che questo investimento è più rischioso del mercato. Infatti:
$$\text{Var}(R_t) = \beta^2 \text{Var}(R_{mt}) + \sigma^2, \qquad \beta > 1$$
- La stima di α è **.2942161**, e l'intervallo di confidenza al 95% è **[-.063; .651]**. Questa evidenza non permette di escludere che 0 possa essere il vero valore per l'intercetta.
- Il rischio idiosincratico è $\sigma = 4.157$.

(slide 26–28)

1.13. Panel data: l'impatto di un inceneritore sul prezzo delle case

Esempio 1.6. Kiel e McClain (1995) hanno studiato l'effetto che la costruzione di un nuovo inceneritore di rifiuti ha avuto sul valore delle case a North Andover, nel Massachusetts. Gli autori originali eseguirono un'analisi econometrica piuttosto complicata; in questo esempio si considera un modello semplificato, anche se la strategia implementata è simile all'originale.

I rumor secondo cui un nuovo inceneritore sarebbe stato costruito a North Andover iniziarono dopo il 1978, anche se la costruzione iniziò solo nel 1981. L'inceneritore sarebbe entrato in funzione subito dopo l'inizio della costruzione, e ha effettivamente iniziato a funzionare nel 1985. Si utilizzano i dati sui prezzi delle case vendute nel 1978 e un altro campione su quelle vendute nel 1981 (sono due campioni indipendenti di case diverse, cioè cross section ripetute e non un panel in senso stretto; le slide le trattano come panel). L'ipotesi è che il prezzo delle case situate vicino all'inceneritore diminuisca maggiormente rispetto a quello delle case più distanti.

Prima evidenza (solo 1981). Alcune evidenze empiriche suggeriscono che nel 1981 le case costruite vicino al nuovo stabilimento costavano circa 30mila dollari in meno rispetto alle altre (prezzi reali, in dollari del 1978):

year	Base price	"Near" effect
1981	101,308.0	-30,688.3

Tuttavia, queste evidenze non sono sufficienti per affermare che l'inceneritore abbia causato una perdita sui prezzi delle case: non sappiamo se ci fossero differenze nei prezzi già prima del 1981. Ci si aspetta infatti che un inceneritore non venga costruito in una zona di pregio.

Confronto 1978 vs 1981. Per fare chiarezza su questo punto è necessario conoscere quali erano i prezzi anche prima che cominciassero le voci. Queste evidenze congiunte sono riassunte nella tabella seguente:

year	Base price	"Near" effect
1978	82,517.7	-18,824.4
1981	101,308.0	-30,688.3

Una regola per verificare se il nuovo inceneritore ha ridotto il valore delle abitazioni è calcolare la seguente statistica (uno stimatore **differenza-nelle-differenze**):

$$\hat{\delta} = \left(\overline{price}_{81,near} - \overline{price}_{81,far}\right) - \left(\overline{price}_{78,near} - \overline{price}_{78,far}\right)$$

dove il primo termine tra parentesi è il coefficiente sull'effetto vicinanza (*near effect*) del 1981, e il secondo è quello del 1978.

Calcolo. Come possiamo sapere se la costruzione di un nuovo inceneritore ha ridotto il valore delle case? Possiamo osservare come è cambiato il coefficiente sull'effetto vicinanza tra il 1978 e il 1981. La differenza nel valore medio delle case era molto maggiore nel 1981 rispetto al 1978 (30.688,27 contro 18.824,37), anche come percentuale del valore medio delle case non vicine al sito dell'inceneritore. La differenza tra i due coefficienti sulla vicinanza è:

$$\hat{\delta} = -30{,}688.3 - (-18{,}824.4) = -11{,}863.9$$

$\hat{\delta}$ è statisticamente diverso da 0? Occorre calcolare opportuni errori standard. Per questo, risulta opportuno usare modelli di regressione specifici per l'analisi dei **dati panel**.

(slide 29–32)

1.14. Tre cause di problemi nella stima

Integrazione dalla lezione del 10 novembre 2026.

Per riconoscere quando un modello non va bene bisogna conoscere le potenziali cause di problemi, che sono tipicamente di tre tipi.

Troppe poche informazioni nel modello (variabili omesse). Nel caso più semplice, oltre alla variabile dipendente y e al driver x, il modello contiene un termine d'errore ε. Dal punto di vista statistico è una variabile casuale a media zero e varianza qualsiasi; dal punto di vista economico raccoglie tutte le informazioni che non sono nel modello. Se queste informazioni sono rilevanti e hanno un effetto su x, una variazione di x si associa sia a una variazione di y sia a una variazione di ε: la variazione osservata di y è una combinazione delle due componenti, di cui si misura solo il totale senza sapere quanto conti ciascuna. Poiché ε non è osservabile, non si è più in grado di valutare che cosa stia facendo il modello. È il primo caso di endogeneità. La soluzione è portare nel modello le variabili omesse, scelte con ragionamenti logici e non con una procedura puramente statistica: il problema è economico e si tratta di capire quali variabili contano davvero.

Causalità non chiara. Se non è chiaro se sia x a influenzare y o il contrario, si introduce di fatto un riferimento circolare: non si sa più se, muovendo una variabile, si muova l'altra. Il cortocircuito crea una correlazione tra x e l'errore, e la stima dei coefficienti diventa problematica.

Errori di misura nei dati. Anche se il modello è perfetto, dati approssimativi e poveri di informazione inducono una distorsione nella stima dei parametri, tanto maggiore quanto più grande è l'errore di misura. Si pensi a un'indagine sulle spese delle famiglie che chiede quanto si è speso al supermercato nell'ultima settimana. Chi ha speso 190 euro tende a ricordare e a riportare 200, e chi ne ha spesi 205 riporta ugualmente 200. L'errore di riporto non è sistematico e la spesa media del campione può risultare corretta, ma introduce rumore nella procedura di stima e distorce la stima del parametro. Il caso è diverso per l'evasione fiscale, dove tutti tenderebbero a sottostimare o a sovrastimare: lì la distorsione è sistematica e si controlla più facilmente. Qui si tratta invece di persone oneste ma imprecise perché non ricordano, tanto più quanto più lontano è l'evento a cui la domanda si riferisce, e questo può creare grossi problemi. Gli effetti saranno mostrati con dati simulati, quindi controllabili.

1.15. Dati dinamici e stabilità

Integrazione dalla lezione del 10 novembre 2026.

Nell'analisi di regressione con dati cross section si assume di solito che le osservazioni siano pescate in modo indipendente dalla popolazione. Nei sistemi dinamici, tipici della finanza e dell'economia, le variabili hanno invece una loro inerzia e non sono osservate in modo indipendente: se il tasso di interesse oggi è il 5%, domani sarà intorno al 5% e non allo 0% o al 10%. Ne nasce un problema di stabilità dei dati nel tempo, perché la statistica funziona bene se i dati sono stabili.

Il limite della media. Si pensi ai prezzi giornalieri di un indice azionario come lo Standard & Poor's, che seguono un andamento con trend. Un software calcola senza difficoltà la media dei prezzi, ma la media è un indicatore di centralità che descrive il fenomeno solo in un intervallo temporale, per puro caso, e non negli intervalli che lo precedono e lo seguono. Una media che mette insieme i prezzi degli ultimi cinque anni e quelli di trent'anni fa non descrive né l'oggi né il passato: i dati provengono da popolazioni statistiche diverse, ciascuna con la propria media. Lo stesso accade in una popolazione in cui metà è alta due metri e metà un metro: le medie rappresentative sono due, quelle delle distribuzioni condizionali, mentre la media aritmetica campionaria, circa un metro e mezzo, non è un indicatore utile né per i bassi né per gli alti. Se i dati non sono sufficientemente regolari, le statistiche descrittive e i parametri stimati non hanno alcun significato logico: numericamente si calcola tutto, ma i numeri non significano nulla. Con le serie storiche bisogna perciò assumere che la serie sia stabile nel tempo, almeno nel senso di avere una media comune.

Trasformazioni che stabilizzano. Esistono trasformazioni uno a uno delle serie originali, che quindi non fanno perdere informazione, e tendono a stabilizzarle. Tipicamente, anziché i prezzi si usano le variazioni di prezzo, cioè i rendimenti, che hanno di solito una media stabile, tipicamente zero. Ciò che cambia nel tempo è la variabilità, che si gestisce in modo più naturale

con i modelli ARCH e GARCH, usati in finanza per capire perché la varianza, che è un indicatore di rischio, cambia nel tempo e in che modo. Su questa base si costruiscono le misure di rischio dei corsi di analisi del rischio e di risk management.

Dipendenza, regressione spuria e cointegrazione. Quando i dati sono osservati nel tempo non sono indipendenti, e occorre controllare che la dipendenza sia sotto controllo. Se la dipendenza genera una componente di trend, la statistica descrittiva standard non funziona più: si può dimostrare che il teorema del limite centrale e la legge dei grandi numeri non valgono e che le proprietà statistiche degli indicatori vengono meno. Ne deriva la **regressione spuria**: prendendo due serie indipendenti per costruzione, il test di significatività del coefficiente che le lega risulta quasi sempre diverso da zero, con un p-value estremamente piccolo. Il test si basa su una distribuzione normale, mentre la distribuzione degli stimatori con questi dati non lo è; il software non lo sa e restituisce un numero privo di senso. Con dati non stabili non si può dunque usare facilmente la regressione, a meno che i dati non siano stabilizzati prima. Fa eccezione la **cointegrazione**, molto importante soprattutto in finanza: se le caratteristiche di regolarità sono più o meno stabili, si può sperare che sia stabile anche la relazione tra le variabili e che il parametro che le lega sia identificabile.

2 | Econometria — Il Modello di Regressione Semplice

Fonte: ECON_Teoria_02_Regressione-Semplice.pdf — *57 slide*

2.1. Introduzione: l'associazione tra variabili quantitative — l'esempio wage vs. education

Il filo conduttore della lezione è un esempio applicato: la relazione tra **salari (wage)** e **livello di istruzione (educ)**. Le domande a cui l'analisi vuole rispondere sono:

- Esiste una relazione positiva tra istruzione e salario?
- Per un dato livello di istruzione, qual è il salario medio che un lavoratore può ottenere?
- Qual è il guadagno atteso se si decide di studiare un anno in più?
- Quanto farebbe guadagnare in più conseguire una laurea magistrale (2 anni di studio in più)?

Questo tipo di informazione è utile per prendere decisioni: ad esempio, un individuo potrebbe decidere di iscriversi a una magistrale se il salario atteso aumenta di almeno 1 euro l'ora.

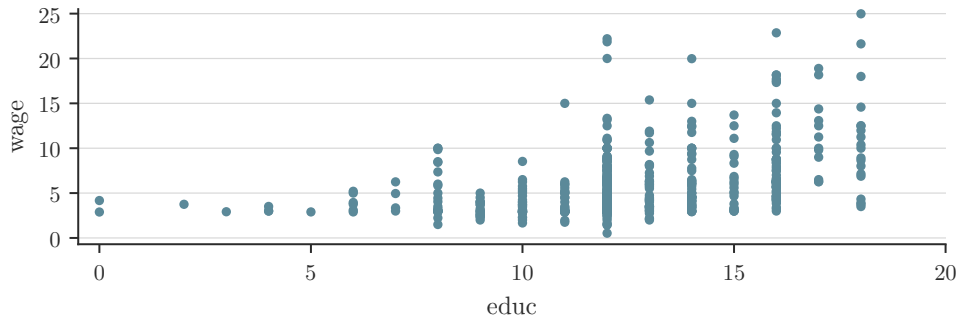


Figura 1 — Scatterplot di educ vs. wage (526 individui osservati nel 1976). Relazione grezza tra anni di istruzione e salario orario: i punti seguono una tendenza crescente, con forte dispersione attorno ad essa.

Con l'analisi di regressione si cerca un modello che riassuma, **in modo semplice**, come variano le distribuzioni condizionali di una variabile Y al variare di una seconda variabile X. Nell'esempio, la distribuzione condizionale è la distribuzione di probabilità dei salari (Y) per un qualsiasi livello di istruzione (X). Questo modello rappresenta l'ipotesi (ex-ante) sulla relazione causa-

le: si definisce una variabile obiettivo (variabile dipendente) e una variabile causale (regressore, causa scatenante). Il nesso causale ipotizzato è, per costruzione, **unidirezionale** ($X \to Y$).

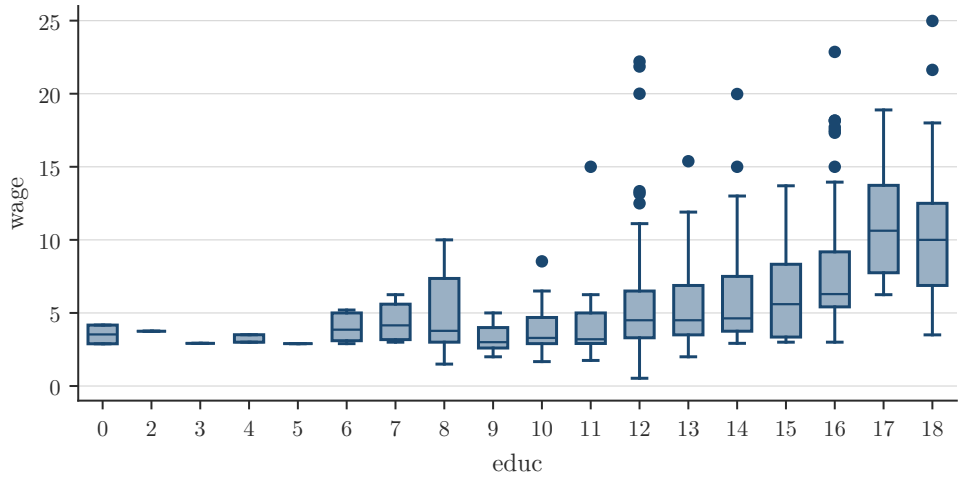


Figura 2 — Distribuzione condizionale dei salari per ogni livello di istruzione. Boxplot del salario (mediana, quartili, valori estremi) per ciascun valore di anni di istruzione: sia il livello medio sia la dispersione dei salari tendono a crescere con l'istruzione.

Trovare un modello che si adatti con precisione a **tutte** le distribuzioni condizionali sarebbe troppo complicato. I modelli statistici descrivono quindi la dinamica di alcuni momenti (caratteristiche) delle distribuzioni condizionali; nel modello di regressione queste caratteristiche sono i valori attesi (medie). L'obiettivo diventa costruire un modello che descriva le **medie condizionali** di Y: ad esempio, qual è il salario atteso per i lavoratori che hanno studiato esattamente 10 anni?

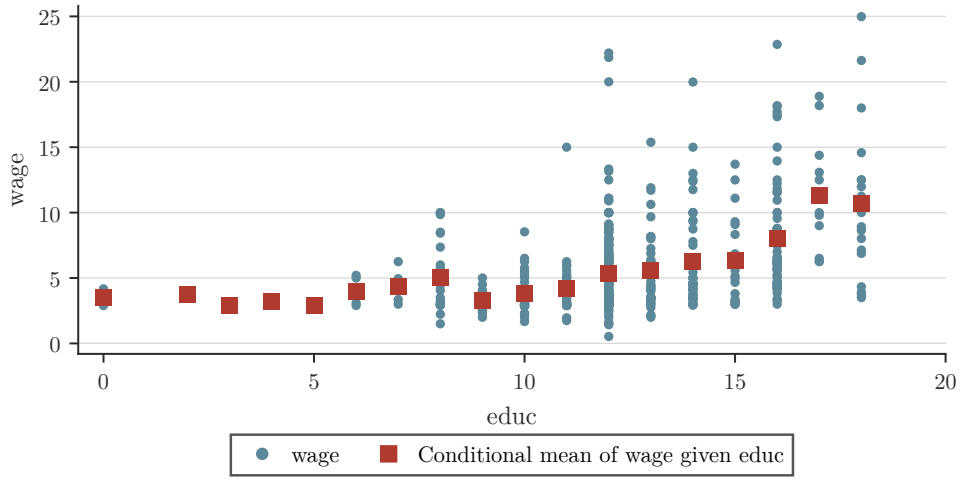


Figura 3 — Scatterplot di educ vs. wage e $E[wage|educ]$ (quadrati rossi). Le medie condizionate stimate per ciascun livello di istruzione sono sovrapposte ai dati osservati; il loro andamento è crescente ma non perfettamente lineare.

Per rispondere a queste domande è conveniente definire un modello che descriva la relazione tra istruzione e salari attesi: **la linea è il modello più semplice che si conosca**.

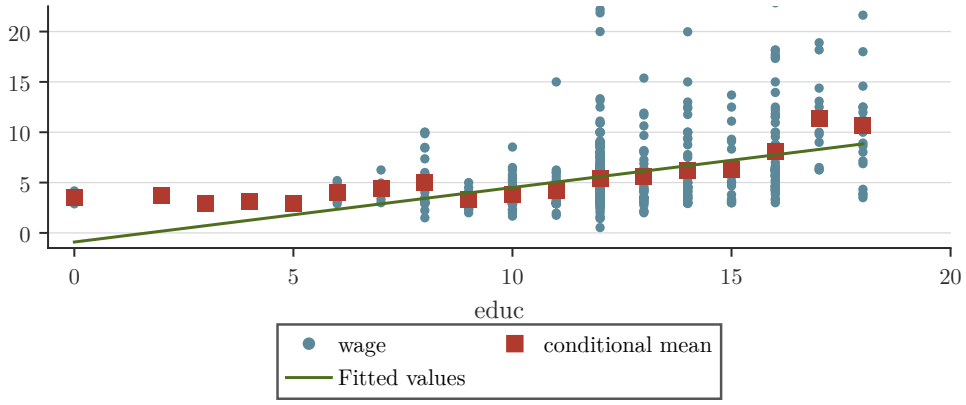


Figura 4 — Scatterplot di educ vs. wage con $E[wage|educ]$ (quadrati rossi) e la linea di regressione. Alla figura precedente si aggiunge la retta di regressione stimata (fitted values), che approssima in modo semplice l'andamento delle medie condizionate.

Il valore atteso condizionale $E[Y|X = x]$ è la media di Y per un dato livello x di X. La retribuzione media stimata per un dato numero di anni di istruzione è riportata nella tabella seguente:

Tabella 1 — Valori attesi stimati di wage fissato educ

years of educ	E[wage|educ]	years of educ	E[wage|educ]
educ=0	3.53	educ=10	3.83
educ=1	not available	educ=11	4.18
educ=2	3.75	educ=12	5.37
educ=3	2.92	educ=13	5.59
educ=4	3.17	educ=14	6.23
educ=5	2.90	educ=15	6.32
educ=6	3.98	educ=16	8.04
educ=7	4.38	educ=17	11.34
educ=8	5.03	educ=18	10.67
educ=9	3.27	educ=19	not available

(slide 3–10)

Dalla lezione del 12 novembre 2026: distribuzioni condizionali ed eterogeneità dei salari. I dati dell'esempio risalgono agli anni Settanta, per cui i salari orari in dollari sono numeri piccoli; l'andamento non è molto diverso da quello atteso oggi, a parte la scala. Ogni colonna di punti dello scatterplot è la distribuzione dei salari dei lavoratori che hanno studiato esattamente un certo numero di anni, per esempio 10 oppure 15. È quindi una distribuzione condizionale, che dice in termini probabilistici quanto è probabile trovare, in quel sottogruppo, un lavoratore che guadagna molto o poco.

I quadrati rossi sono le medie di queste distribuzioni e tendono a crescere con l'istruzione: per i livelli più bassi la variabilità è scarsa e il salario medio è sotto i 5 dollari l'ora, per un livello intermedio è poco sopra i 5 dollari, e per chi ha studiato molto il docente indica un centro della distribuzione intorno ai 15 dollari (la tabella 1 riporta medie condizionali fino a circa 11 dollari). Studiando di più non si guadagna però di più con certezza: in una stessa colonna ci sono persone che guadagnano meno di chi ha studiato zero anni e persone che guadagnano estremamente di più.

Questa eterogeneità dice come varia il salario in funzione di informazioni diverse dall'istruzione, perché i lavoratori di una colonna hanno lo stesso livello di istruzione ma caratteristiche individuali diverse. Il punto in alto, a circa 25 dollari l'ora, può essere il figlio di un dirigente che finirà a fare il dirigente; il punto più in basso può essere qualcuno che ha deciso di studiare archeologia: se gli va bene guadagna molto, se gli va male finisce a fare scavi per i cantieri. Ci sono anche effetti più sottili, come quello di genere: nei dati gli uomini tendono a guadagnare più delle donne. A parità di anni di studio, chi si laurea alla Bocconi può avere aspettative diverse da chi si laurea a Cassino, anche solo perché a Milano i salari sono più alti. All'interno di una colonna l'istruzione è esattamente la stessa e non può spiegare l'eterogeneità, che dipende da altro (il reddito della famiglia, il tipo di studi, l'intelligenza, il genere). La parte di eterogeneità non spiegata dall'istruzione, ma da qualcos'altro, è il termine d'errore, indicato con ε.

Dalla lezione del 12 novembre 2026: perché una retta che approssima le medie condizionali. Il modello di regressione lavora sul momento di ordine uno, cioè sulle medie. Le varianze interessano, ma in generale si vuole capire come in media il livello di istruzione impatti sul salario. Serve quindi un modello che approssimi i quadrati rossi, cioè le medie condizionali.

I quadrati rossi sono però evidenza campionaria, non della popolazione. L'obiettivo non è spiegare il campione: per conoscere guadagno e anni di studio dell'unità statistica numero 73 basta guardare il foglio dei dati, senza bisogno di prevederlo, e per sapere che cosa succede passando da 12 a 14 anni di istruzione basta la differenza tra le due medie condizionali campionarie. Interessa la popolazione, e in particolare le medie condizionali di popolazione, che si conoscerebbero solo intervistando tutti i lavoratori degli Stati Uniti in un certo periodo e conoscendone con esattezza il reddito, il che è impossibile. I quadrati rossi, calcolati su uno specifico insieme di poco più di 500 lavoratori, ne sono solo un'approssimazione.

Per questo non serve una funzione complicata che passi esattamente sui quadrati rossi. Sarebbe possibile, e nemmeno difficile (basta un comando del computer per trovare funzioni molto smooth che li attraversano), ma i quadrati rossi sono già noti, calcolati in una tabella a parte. Serve una funzione abbastanza buona da approssimarli e, allo stesso tempo, da approssimare le medie condizionali che si otterrebbero da altri campioni estratti dalla stessa popolazione. Un modello che si adatta perfettamente ai dati posseduti, e non a tutti i dati possibili, che sono i più interessanti perché ignoti, incorre in **overfitting**.

Si consideri una popolazione di cui il campione osservato è soltanto una parte, e una funzione costruita per approssimare esattamente i punti del campione. Rispetto ai dati usati l'errore è praticamente nullo, ma alcuni punti della popolazione non usati nella stima risultano estrema-

mente distanti dalla funzione, cioè da ciò che si potrebbe osservare in un altro campione della stessa popolazione. Per prevedere y a un dato valore di x si userebbe il punto sulla funzione stimata, la migliore approssimazione possibile con quella funzione, ma l'errore di previsione sarebbe gigantesco per una persona esterna al sottoinsieme osservato. È preferibile un modello che non approssimi troppo bene il campione ma non vada troppo male nemmeno fuori da esso, cioè che faccia da media rispetto alle funzioni che si stimerebbero con campioni diversi: non è perfetto per nessun campione, ma in media non sbaglia in modo sistematico. Il modello serve a capire che cosa succede su ciò che non si osserva. Un modello con un R^2 del 99% non è necessariamente un buon modello, mentre uno con un R^2 del 20% potrebbe essere ottimo.

La funzione cercata deve dunque riflettere un andamento di lungo periodo ed essere universale, non specifica del singolo dataset. Una retta è inoltre un modello molto semplice, facile da identificare e senza curve o polinomi, e dipende da due soli parametri, l'intercetta e il coefficiente angolare: stimati questi due numeri, si caratterizza il comportamento dei dati su tutta la popolazione.

Il modello non approssima direttamente i dati, per i quali non esiste una funzione che si adatti completamente, ma una loro caratteristica, le medie condizionali, che sono indicatori di centralità sufficientemente stabili. Esistono modelli che considerano altri indicatori, come quantili e mediane: è la regressione quantilica, che non fa parte del corso. Il docente la segnala perché permette di capire non solo come reagisce in media un fenomeno a una perturbazione, ma anche come reagiscono le code. In finanza interessano le code delle distribuzioni, cioè perdere o guadagnare molto: i rendimenti medi di un portafoglio sono in media zero, e a chi investe interessa coprirsi dagli eventi estremi, per esempio capire come una variazione della situazione geopolitica impatti le code del portafoglio e non la sua media. Nel corso si considerano le medie condizionali, un indicatore di centralità semplice, sapendo che l'impostazione si può generalizzare.

2.2. Il modello di regressione semplice

Definizione 2.1. La **funzione di regressione semplice** descrive le medie condizionali $E[Y|X = x]$ attraverso un modello lineare:

$$E[Y|X] = \alpha + \beta X$$

Questa retta è un'**approssimazione** della vera media condizionale (i quadrati rossi delle figure precedenti), poiché in generale non è possibile trovare un modello semplice che corrisponda esattamente a tutte le medie condizionate.

Data questa ipotesi per la media condizionale, ogni osservazione (X_i, Y_i) nel campione può essere rappresentata come

$$Y_i = E[Y|X = X_i] + \epsilon_i$$

dove ϵ_i è una quantità stocastica che misura la distanza tra ciascuna osservazione e la retta di regressione.

Terminologia:

- Y_i, $i = 1, \dots, n$: variabile dipendente;
- X_i, $i = 1, \dots, n$: regressore o predittore;
- ϵ_i, $i = 1, \dots, n$: termine di errore.

Intuitivamente ϵ_i è un fattore di rumore che raccoglie gli effetti di tutte le variabili che potrebbero influenzare Y (escluso X) e non sono incluse esplicitamente nel modello. Si assume che l'unico predittore utile per il valore atteso di Y sia il regressore: per questo ci si aspetta che, in media, l'impatto di ϵ non sia rilevante, ovvero formalmente che $E[\epsilon|X] = 0$. Ciò significa che il termine di errore per alcuni soggetti è positivo, per altri negativo, ma in media tutti questi errori si sommano a zero.

Interpretazione causale — effetto di una variazione di X. Ipotizzando che i parametri α e β siano noti, la previsione di Y per un individuo con $X = X_1$ è

$$\hat{Y}(X_1) = \alpha + \beta X_1 + \epsilon(X_1)$$

e per $X = X_2$:

$$\hat{Y}(X_2) = \alpha + \beta X_2 + \epsilon(X_2)$$

dove $\epsilon(X_1)$ ed $\epsilon(X_2)$ rappresentano le caratteristiche non osservate di soggetti con istruzione rispettivamente X_1 o X_2 anni. La variazione di Y è quindi

$$\underbrace{\hat{Y}(X_2) - \hat{Y}(X_1)}_{\Delta Y} = \beta \underbrace{(X_2 - X_1)}_{\Delta X} + \underbrace{[\epsilon(X_2) - \epsilon(X_1)]}_{\Delta \epsilon}$$

ΔY dipende quindi da una scelta economica (ΔX) e da qualcos'altro ($\Delta \epsilon$), quest'ultimo in generale non misurabile. Se si assume che ϵ non dipenda da X, diversi livelli di X non porteranno a variazioni di ϵ, cioè $\Delta \epsilon = 0$. Pertanto la variazione di Y è proporzionale alla variazione di X, con coefficiente di proporzionalità β:

$$\Delta Y = \beta \Delta X$$

Inoltre, se $E[\epsilon|X] = 0$, allora $\text{Cov}(X, \epsilon) = 0$ e $\hat{Y}(X) \approx E[Y|X]$ (le slide scrivono l'implicazione in senso inverso, da $\text{Cov}(X, \epsilon) = 0$ a $E[\epsilon|X] = 0$, che in generale non vale: l'assenza di correlazione è una condizione più debole). Questa ipotesi stabilisce che l'unica spiegazione delle variazioni di Y è fornita da X: ipotizzando che ϵ e X non siano correlati, il risultato di una scelta dipende unicamente dalla scelta stessa (ΔX) e non da altri fattori confondenti ($\Delta \epsilon$). Questa ipotesi è nota come **esogeneità**, ed è alla base dello studio di relazioni causali.

Esempio numerico. Si consideri il modello che lega salario e istruzione con $\alpha = -1$ e $\beta = 0.5$:

$$wage_i = \alpha + \beta\, educ_i + \epsilon_i = -1 + 0.5\, educ_i + \epsilon_i$$

Assumendo che altre caratteristiche (genere, esperienza, tenure, ecc.), riassunte in ϵ_i, non siano rilevanti, un anno di scuola in più ($\Delta educ = 1$) induce una variazione della retribuzione oraria prevista di 0.50 dollari; due anni in più inducono una variazione dello stipendio atteso di 1 dollaro.

(slide 11–16)

Dalla lezione del 12 novembre 2026: notazione e ruolo del termine d'errore. Nella notazione $E(y \mid x)$ la prima variabile è quella su cui si calcola la media, mentre la seconda, che segue la barra verticale, è la variabile di condizionamento: i quadrati rossi sono il valore atteso condizionale dei salari rispetto all'istruzione, con wage come variabile y ed education come variabile x. Per legare le osservazioni individuali alla media condizionale si considerano le coppie (y_i, x_i), dove i indica l'unità statistica (un lavoratore nell'esempio), x_i è l'istruzione del lavoratore i-esimo e y_i il suo salario, e vale $y_i = \alpha + \beta x_i + \varepsilon_i$.

Il salario esatto di un individuo, che non è il salario medio, dipende da due fattori. Il primo è una componente media: per l'appartenenza a una categoria, cioè a un certo livello di istruzione, il salario atteso è $\alpha + \beta x_i$. Il secondo è una componente idiosincratica, individuale, che rappresenta tutte le caratteristiche del lavoratore diverse dall'istruzione: il genere, la famiglia, se è sveglio o no, se ha fatto un master in finanza o in storia dell'arte. Regressore e predittore sono due nomi della stessa variabile x: predittore se si segue una letteratura più statistica, regressore se più economica.

Le caratteristiche di ε determinano se il modello sia una relazione causale oppure no. Nel corso di statistica non sono così importanti, lo sono invece in econometria e in economia, perché la relazione tra ε e x permette di dire se il modello è ben specificato. Si assume che la correlazione tra ε e x sia zero: questa condizione si chiama esogeneità, e se non vale si parla di endogeneità, che ha conseguenze pesanti sulla stima. Il termine d'errore non è osservabile, per cui per capire se il modello sia corretto bisogna stabilire le proprietà di qualcosa che non si può misurare direttamente, e occorre aggirare il problema.

Dalla lezione del 12 novembre 2026: perché senza una condizione sull'errore l'effetto non è identificabile. Il termine ε contiene altri fattori, diversi dall'istruzione, che in linea di principio possono essere collegati al livello di istruzione: più si studia, più si impara, e l'abilità conseguita può aumentare. Per questo si scrive $\varepsilon(x_1)$, facendo dipendere l'errore anche da x_1, e si lega direttamente l'abilità di una persona al livello di istruzione. Aumentando l'istruzione di Δx, per esempio due anni, la variazione di y è $\beta\Delta x + \Delta\varepsilon$, dove $\Delta\varepsilon = \varepsilon(x_1 + \Delta x) - \varepsilon(x_1)$ non è calcolabile perché non è noto, ma teoricamente esiste. La variazione di salario dipende quindi in parte dall'aver studiato due anni in più e in parte da effetti collaterali della scelta.

La variazione complessiva si può calcolare: la differenza dei quadrati rossi dà, per esempio, 3 dollari. Sulla base del modello non si sa però se questi 3 dollari dipendano dalla scelta di studiare o da altro, perché si conosce soltanto la somma: potrebbero essere 1 più 2, oppure 0 più 3, oppure -3 più 6. L'effetto non è identificabile. L'unico modo per identificare l'effetto della scelta, cioè $\beta\Delta x$, è fissare il valore di $\Delta\varepsilon$, e il valore più comodo è 0: se la variazione di ε è nulla, tutta la variazione di y dipende da $\beta\Delta x$. Per identificare l'effetto di un fattore su cui si sceglie bisogna quindi essere sicuri che gli effetti collaterali siano nulli.

La condizione statistica per cui la variazione di tutto il resto è nulla quando varia x è una correlazione uguale a zero tra x ed ε (qui tutto è lineare, quindi basta poco). Concettualmente è difficile verificarla, perché x si può misurare ma ε no. Con questa ipotesi aggiuntiva, l'unica spiegazione plausibile di una variazione di y è la variazione di x pesata dal coefficiente β, la pendenza della retta di regressione. L'ipotesi si chiama esogeneità, in questo caso esogeneità stretta: esistono vari concetti di esogeneità e nei modelli di regressione classici si usa quella stretta, mentre nella seconda parte del corso verrà abbandonata a favore dell'esogeneità debole, che è più che sufficiente. Questa nota formula invece l'esogeneità come $E[\varepsilon \mid X] = 0$, da cui segue $\mathrm{Cov}(X, \varepsilon) = 0$ ma non viceversa, e osserva che le slide enunciano la condizione di correlazione nulla, più debole; il docente usa qui la correlazione nulla e la chiama esogeneità stretta. Se la correlazione fosse diversa da zero, la variazione di ε non potrebbe essere nulla in corrispondenza di una variazione di x, e non si saprebbe valutare perché si osservino variazioni di y.

Dalla lezione del 12 novembre 2026: esempio del bonus fiscale e dei consumi. Uno dei problemi dell'Italia è che i consumi sono molto bassi, e per dare loro impulso si danno tipicamente dei bonus. Il docente richiama la riforma di Matteo Renzi dei mille euro, introdotta come sconto fiscale per una certa fascia di lavoratori. La misura è costosa, ma il costo si valuta in modo abbastanza preciso, perché è una minore entrata per lo Stato. Lo scopo era stimolare i consumi, e ci si chiede se questi siano effettivamente migliorati in conseguenza della policy.

Per rispondere si può calcolare la relazione tra redditi (x) e consumi (y), entrambi pro capite: la policy varia x di 1.000 euro, e ci si chiede come siano variati i consumi. Il docente precisa di non aver svolto questa analisi e di non valutare se la scelta sia stata giusta o sbagliata: pone un problema statistico. Se il parametro che lega consumi e redditi è grande, 1.000 euro in più alle famiglie avranno un impatto sui consumi, e la policy avrà ottenuto il risultato voluto. Il problema è se il modello sia corretto: la variazione dei consumi osservata potrebbe dipendere dai 1.000 euro in più, oppure da altro, come le condizioni economiche di quel periodo. Se l'effetto collaterale fosse più importante, probabilmente sarebbe stato più efficiente usare quei soldi per altro.

Si può investire molto denaro in una policy e stimare un parametro grande tra le due variabili, da cui ci si aspetterebbe un impatto devastante. Tale impatto vale solo se si ipotizza che $\Delta\varepsilon$ sia zero. Altrimenti non si può dire che la policy abbia avuto un impatto, perché occorre considerare una combinazione di eventi e non uno solo: la variazione si può calcolare, ma non si sa da che cosa dipenda. L'unico modo per essere sicuri che l'investimento abbia un impatto è fissare ciò che non si conosce, e ciò che non si conosce si fissa tipicamente a zero. Se $\Delta\varepsilon$ è zero, l'unica

spiegazione della variazione di y è x, pesata da β, che è il moltiplicatore, e il solo problema diventa stimare β.

Dalla lezione del 12 novembre 2026: stimare il parametro o prevedere. Il problema posto non è del modello di regressione in generale, ma di interpretabilità dei risultati. In un corso di statistica il problema dell'eterogeneità nel modello di regressione non viene praticamente considerato, perché lo scopo è trovare un modello da usare per fare previsioni sui dati successivi. Qui interessa invece valutare con precisione il parametro β, perché esso dice, per esempio, quanto denaro si sta spendendo per l'istruzione dei bambini e se la scelta fatta è corretta. Lo scopo dell'analisi con i modelli di regressione in economia è capire quanto una policy abbia impatto, cioè stimare correttamente β, e non avere un modello che si adatti ai dati o che serva per le previsioni; per farlo occorre fissare $\Delta\varepsilon$ a zero. In un corso orientato alle previsioni, invece, che β sia calcolato bene o male non importa, purché la previsione sia corretta.

Un economista vuole sapere se spendere 2 miliardi di dollari l'anno per ridurre la dimensione delle classi sia utile a grande scala, il che è un problema politico o economico. Si può assumere invece il punto di vista di un genitore che deve iscrivere un figlio a scuola, e che sceglie la scuola in cui il voto finale del figlio sarà più alto, così da entrare l'anno dopo in una buona scuola con una borsa di studio e poter sopravvivere a un sistema di istruzione estremamente costoso. Per il genitore lo scopo non è migliorare il mondo ma trovare la scuola più adatta al proprio figlio, e il problema diventa di previsione. Se la variabile che prevede meglio la performance del figlio risultasse la dimensione del parcheggio della scuola, il genitore misurerebbe il parcheggio di tutte le scuole degli Stati Uniti e sceglierebbe in base a quello: non importa che logicamente non abbia senso, funziona. È una black box.

Dal punto di vista dello statistico che fa previsione non interessa quindi calcolare esattamente il parametro che lega le variabili, perché non è necessariamente legato alla capacità previsiva del modello. Se invece si usa il modello per valutare politiche, o per confermare congetture economiche e finanziarie di qualsiasi tipo, interessa conoscere il parametro. Il docente precisa che non sta dicendo che un approccio sia migliore dell'altro: lo stesso strumento risponde a criteri diversi perché i problemi sono diversi.

2.3. Stima del modello: il metodo dei minimi quadrati ordinari (OLS)

Definizione 2.2. Dati i dati campionari, occorre stimare i parametri α e β del modello di regressione. L'idea di base è trovare valori per α e β che **minimizzino la distanza media** tra ciascuna osservazione e la retta di regressione: questi due parametri identificano in modo univoco la retta.

Il metodo dei **minimi quadrati ordinari (OLS)** suggerisce di minimizzare la varianza del termine di errore, ovvero calcolare

$$\min_{\alpha,\beta} \mathrm{Var}(\epsilon) = \min_{\alpha,\beta} E[\epsilon^2] \approx \min_{\alpha,\beta} \frac{1}{n} \sum_{i=1}^{n} (Y_i - \alpha - \beta X_i)^2$$

Si dimostra che la pendenza della retta di regressione β è proporzionale alla covarianza tra X e Y:

$$\hat{\beta} = \frac{\frac{1}{n}\sum_{i=1}^{n}(Y_i - \bar{Y})(X_i - \bar{X})}{\frac{1}{n}\sum_{i=1}^{n}(X_i - \bar{X})^2} = \frac{\mathrm{Cov}(X,Y)}{\mathrm{Var}(X)}$$

Esempio: wage vs. education. Si consideri il modello $wage_i = \alpha + \beta\, educ_i + \epsilon_i$. Le stime OLS basate su un campione di 526 osservazioni sono:

Variabile	Coef.	Std. Err.	t	P>|t|	IC 95% inf.	IC 95% sup.
educ	.5413593	.053248	10.17	0.000	.4367534	.6459651
_cons	-.9048516	.6849678	-1.32	0.187	-2.250472	.4407687

Il modello stimato risulta quindi (coefficienti arrotondati alla quarta cifra; le slide troncano a $-.9048$ e $.5413$)

$$wage = -.9049 + .5414\, educ$$

Studiare un anno in più induce una variazione positiva di circa 54 centesimi nei salari.

Valori predetti e residui. La previsione della media condizionale, o valore predetto, è

$$\hat{Y}_i = \hat{E}[Y_i | X = x_i] = \hat{\alpha} + \hat{\beta} x_i$$

Il termine di errore viene stimato come differenza tra la variabile osservata Y_i e il valore atteso $\hat{Y}_i$; è chiamato **residuo** ed è definito come

$$\hat{\epsilon}_i = Y_i - \hat{\alpha} - \hat{\beta} X_i = Y_i - \hat{Y}_i$$

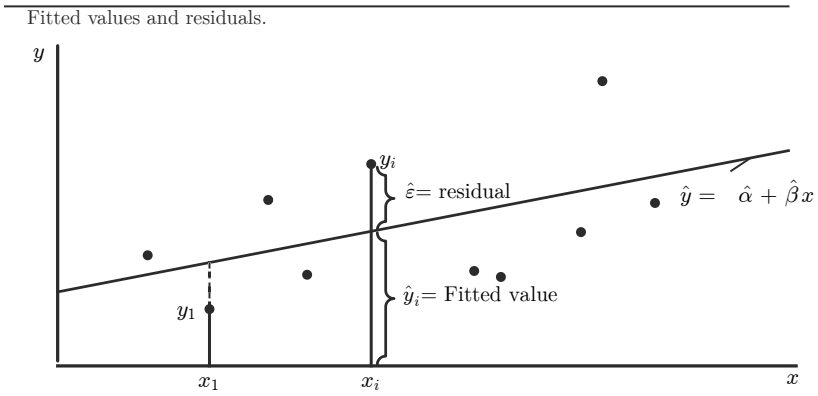


Figura 5 — Rappresentazione grafica di Y_i come somma di residuo ($\hat{\epsilon}_i$) e valore predetto ($\hat{Y}_i$). Ogni osservazione Y_i si scompone nella somma del valore previsto dalla retta e del residuo, cioè la distanza verticale tra il punto osservato e la retta.

(slide 17–21)

Dalla lezione del 12 novembre 2026: il parametro β ricavato con il metodo dei momenti. Tutti i libri indicano come modo corretto il metodo dei minimi quadrati: si prendono le osservazioni su y e il modello e si trovano α e β tali che la distanza media tra y e la trasformazione lineare di x sia la più piccola possibile. La distanza si calcola con il quadrato, per evitare che gli scarti positivi e negativi si compensino. Si derivano le espressioni rispetto ad α e β, si pongono le derivate uguali a zero e si risolve il sistema di due equazioni in due incognite: la soluzione per β è un rapporto tra quantità, quella per α una differenza di medie. Il docente considera questa la via più noiosa e ne presenta una con un'algebra più breve e a suo parere più intuitiva.

Si assume che il modello sia corretto, cioè che valga l'esogeneità: la covarianza tra x ed ε è zero. Nella popolazione y è data dalla combinazione $\alpha + \beta x + \varepsilon$, per cui

$$\mathrm{Cov}(x, y) = \mathrm{Cov}(x, \alpha + \beta x + \varepsilon).$$

La covarianza di una variabile rispetto a una combinazione lineare è la combinazione lineare delle covarianze, perché la covarianza si può pensare come una media, una sommatoria o un integrale, che sono operatori lineari. Si ottiene quindi

$$\mathrm{Cov}(x, y) = \mathrm{Cov}(x, \alpha) + \mathrm{Cov}(x, \beta x) + \mathrm{Cov}(x, \varepsilon).$$

Il primo termine è zero, perché la covarianza tra una costante e una variabile casuale è nulla: al variare di x, α resta costante. Il terzo termine è zero per ipotesi, che il docente sottolinea essere una scelta e non necessariamente corretta. Nel secondo la costante β si porta fuori dalla covarianza e resta la covarianza di x con se stessa, cioè la varianza di x. Quindi

$$\mathrm{Cov}(x, y) = \beta \,\mathrm{Var}(x), \qquad \beta = \frac{\mathrm{Cov}(x, y)}{\mathrm{Var}(x)}.$$

Questa relazione vale nella popolazione: il vero β, quello che si otterrebbe considerando tutti i lavoratori degli Stati Uniti, è la covarianza tra livello di istruzione e salario divisa per la varianza del livello di istruzione. Se la formula vale nella popolazione, si può applicare al campione: numeratore e denominatore si stimano con covarianza e varianza campionarie, che per la legge dei grandi numeri convergono ai momenti di popolazione, per cui lo stimatore converge al vero β per n sufficientemente grande. Il procedimento si chiama **metodo dei momenti**.

Il docente lo preferisce alla costruzione con le derivate perché l'ipotesi viene formulata in modo specifico: la condizione di esogeneità è imposta direttamente, in modo brutale, nelle condizioni usate per la stima, e la formula funziona solo se la covarianza tra x ed ε è uguale a zero. Minimizzando poi la distanza tra y e il modello di regressione si trova uno stimatore dei minimi quadrati che coincide esattamente con quello appena ricavato. In questo caso i due approcci coincidono, cosa che non sempre accade; ci sono motivi profondi per cui succede. La differenza è che nel metodo dei momenti le ipotesi economiche specifiche, cioè l'esogeneità, sono imposte direttamente.

2.4. Il termine d'errore ε: proprietà, omoschedasticità ed eteroschedasticità

Definizione 2.3. Le proprietà della variabile casuale ϵ servono a derivare le proprietà degli stimatori OLS: interessano i suoi momenti e la relazione tra ϵ ed X.

Per costruzione, ϵ_i è la differenza tra Y_i e la media condizionale $E[Y|X_i]$:

$$\epsilon_i = Y_i - E[Y|X_i] = Y_i - \alpha - \beta X_i$$

ϵ raccoglie tutte le caratteristiche non esplicitamente considerate dal modello e descrive l'eterogeneità presente nei dati: non tutte le persone che hanno studiato 10 anni ricevono la stessa somma di denaro, alcune ricevono uno stipendio superiore alla media condizionata, altre inferiore. Il termine di errore spiega questa variabilità e raccoglie intuitivamente la quantità di informazioni su Y non osservabili che non sono spiegate da X.

Media condizionale $E[\epsilon|X]$. Ipotizzando che $\alpha + \beta X$ sia un'approssimazione credibile di $E[Y|X]$ (cioè $E[Y|X] \approx \alpha + \beta X$), la media condizionale di ϵ deve essere

$$E[\epsilon|X] = E[Y|X] - \alpha - \beta X = 0$$

Come conseguenza principale, $\mathrm{Cov}(\epsilon, X) = 0$: tutte le variabili che contribuiscono alla costruzione di ϵ non possono essere correlate con X. Questo implica

$$\Delta E[Y|X] = \Delta Y = \beta \Delta X + \Delta \epsilon = \beta \Delta X$$

L'intuizione è che l'unica informazione rilevante per descrivere la media condizionale di Y è fornita da X; tutte le altre variabili non possono avere un impatto sistematico su di essa.

Varianza condizionale $\mathrm{Var}(\epsilon|X)$**.** In generale spesso non si sa come descrivere la varianza condizionale di ϵ. Si noti però che la variabilità di ϵ descrive anche la variabilità della variabile dipendente Y:

$$\mathrm{Var}(\epsilon|X) = \mathrm{Var}(Y|X)$$

Si possono formulare due ipotesi alternative sulle varianze condizionali:

- **Omoschedasticità**: $\mathrm{Var}(\epsilon|X) = \sigma^2$, cioè non dipende da X.
- **Eteroschedasticità**: $\mathrm{Var}(\epsilon|X) = \sigma^2(X)$, quindi è funzione di X.

Differenti ipotesi su $\mathrm{Var}(\epsilon|X)$ portano a formule diverse per la varianza, e quindi per gli errori standard, dello stimatore OLS; i coefficienti stimati restano gli stessi (le slide parlano di «diversi stimatori OLS»).

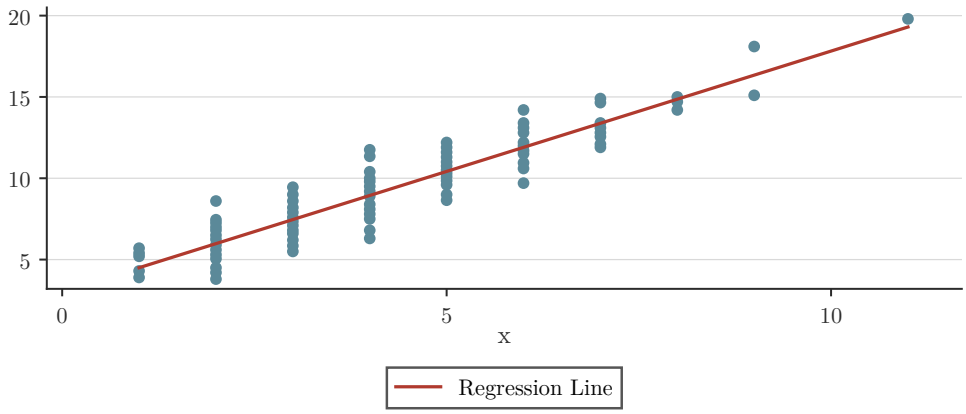


Figura 6 — Retta di regressione $E(Y|X = x)$ ed errori omoschedastici. A diversi valori di X la dispersione di Y attorno alla retta rimane simile (variabilità condizionale simile).

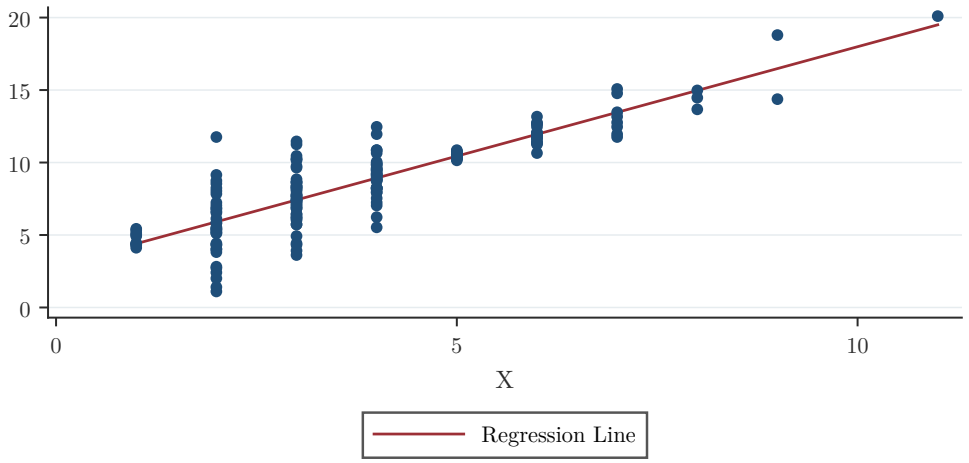


Figura 7 — Retta di regressione $E(Y|X = x)$ ed errori eteroschedastici. A diversi valori di X corrispondono ampiezze diverse della variabilità di Y attorno alla retta, cioè diverse $\text{Var}(Y|X)$.

(slide 22–27)

2.5. Le ipotesi del modello di regressione OLS

Definizione 2.4. Ai fini pratici occorre verificare se la strategia OLS fornisce stime affidabili dei parametri di interesse: il coefficiente β misura l'impatto di una politica (valutata come ΔX) sulla variabile dipendente. Per valutare queste proprietà occorre definire formalmente le ipotesi sul modello di regressione:

1. Il vero modello (la retta nella popolazione) è lineare: $E[Y|X] = \alpha + \beta X$;
2. Il modello statistico (approssimato) coincide con quello vero, ovvero $Y = \alpha + \beta X + \epsilon$. Come conseguenza principale, $\text{Cov}(X, \epsilon) = 0$;
3. Le coppie (X_i, Y_i), $i = 1, \dots, n$ sono **I.I.D.**;
4. I momenti quarti di X e Y esistono e sono finiti;
5. Si suppone, ad esempio, che $\text{var}[\epsilon|X] = \sigma^2$ (**Omoschedasticità**).

Nota: ipotesi OLS equivalenti. L'ipotesi OLS può essere formulata in modo diverso ma equivalente. Finora si è ipotizzato che il modello empirico (quello valutato attraverso un dataset) sia $Y = \alpha + \beta X + \epsilon$, e che la media condizionale (il vero modello) sia $E[Y|X] = \alpha + \beta X$. Nell'ipotesi che il modello empirico coincida con quello vero, $\epsilon \equiv Y - E[Y|X]$, quindi

$$E[\epsilon|X] = 0 \;\Rightarrow\; \text{Cov}(X, \epsilon) = 0$$

Un modo alternativo ed equivalente di definire l'ipotesi:

- si considera che il modello empirico sia lineare, $Y = \alpha + \beta X + \epsilon$;
- si suppone inoltre che $E[\epsilon|X] = 0$;
- quindi $E[Y|X] = \alpha + \beta X$ corrisponde al vero modello.

Le ipotesi alternative ma equivalenti per il metodo OLS si possono quindi riassumere come:

- Il regressore X è **esogeno**, ovvero la media condizionale di $\epsilon|X$ è zero ($E[\epsilon|X] = 0$); conseguenza principale: $E[Y|X] = \alpha + \beta X$;
- Le coppie (X_i, Y_i), $i = 1, \dots, n$ sono I.I.D.;
- I momenti quarti di X e Y esistono e sono finiti;
- Si suppone che $\text{var}[\epsilon|X] = \sigma^2$ (Omoschedasticità).

Nota: sull'esogeneità. Si supponga che il regressore non sia esogeno, cioè sia **endogeno**, quindi $\text{Cov}(X, \epsilon) \neq 0$. Considerando la variazione attesa di Y

$$\underbrace{\hat{Y}(X_2) - \hat{Y}(X_1)}_{\Delta Y} = \alpha + \beta X_2 + \epsilon(X_2) - [\alpha + \beta X_1 + \epsilon(X_1)] = \beta \underbrace{(X_2 - X_1)}_{\Delta X} + \underbrace{[\epsilon(X_2) - \epsilon(X_1)]}_{\Delta \epsilon}$$

Poiché $\text{Cov}(X, \epsilon) \neq 0$, ragionevolmente ci si aspetta che $E[\Delta\epsilon|X]$, misurato come $\epsilon(X_2) - \epsilon(X_1)$, sia diverso da zero. In questo caso

$$\Delta Y = \beta \Delta X + \Delta \epsilon$$

Le variazioni attese di Y non dipendono solo da β ma anche da $\Delta\epsilon$, in generale non calcolabile: quindi β non è più una misura precisa delle implicazioni di ΔX.

Esempio: sull'esogeneità. Si consideri un dataset simulato di dimensione 200 che soddisfa

$$Y_i = 3 + 1.5X_i + \epsilon_i, \qquad \text{cov}(X, \epsilon) = 0.6$$

Si stima il modello $Y = \alpha + \beta X + \epsilon$:

Variabile	Coef.	Std. Err.	t	P>|t|	IC 95% inf.	IC 95% sup.
X	2.129496	.063634	33.46	0.000	2.004008	2.254983
_cons	2.962697	.0635759	46.60	0.000	2.837324	3.08807

Si noti che $\hat{\beta} = 2.129$ è abbastanza diverso da 1.5. Qui $\hat{\beta}$ non è una stima affidabile del parametro di policy β: in questo caso 2.129 è una stima affidabile di $(\beta + \Delta\epsilon)$, che non è ciò che interessa (più precisamente, $\hat{\beta}$ converge a $\beta + \text{Cov}(X, \epsilon)/\text{Var}(X)$, qui circa $1.5 + 0.6 = 2.1$ se $\text{Var}(X) \approx 1$, valore coerente con gli errori standard in tabella).

(slide 28–33)

Dalla lezione del 12 novembre 2026: che cosa succede alla stima se l'esogeneità non vale. Si supponga che la covarianza tra x ed ε sia diversa da zero e la si indichi con $\rho_{x\varepsilon}$. Ripetendo il

calcolo della covarianza descritto per il metodo dei momenti, si ottiene $\text{Cov}(x, y) = \beta \text{Var}(x) + \rho_{x\varepsilon}$. Se questa condizione valesse e il numero fosse noto, β andrebbe calcolato come

$$\beta = \frac{\text{Cov}(x, y) - \rho_{x\varepsilon}}{\text{Var}(x)}.$$

Per ottenere β correttamente occorrerebbe dunque stimare anche $\rho_{x\varepsilon}$, cosa che non si sa fare, perché quel numero non è noto. Un software non lo fa: a meno che non gli venga detto, tratta $\rho_{x\varepsilon}$ come se fosse zero. Applicando la formula sbagliata quando l'esogeneità non vale, lo stimatore di β non risulta collegato a β ma a β più un termine ulteriore, perché il numeratore dovrebbe essere ripulito dall'effetto di $\rho_{x\varepsilon}$. Si ha quindi una distorsione sistematica tra ciò che si vuole stimare e ciò che si stima effettivamente dai dati, che non sparisce nemmeno aumentando il numero di osservazioni. Con endogeneità gli stimatori che si vedranno nel corso sono distorti, e l'implicazione di policy che si vuole valutare con il modello sarà sistematicamente sbagliata.

Uno studente chiede se l'endogeneità indichi l'assenza di esogeneità. Il docente conferma: si ha endogeneità quando la correlazione tra x ed ε è diversa da zero, cioè quando vale il contrario dell'esogeneità.

Il docente chiude il discorso osservando che tutto il gioco dell'econometria, almeno a questo livello, consiste nel capire quando si può dire che la variazione di ε è uguale a zero in corrispondenza della variazione di x. Tutto il resto è algebra banale: la difficoltà è economica più che tecnica. Nelle lezioni successive la parte tecnica viene introdotta gradualmente, per mostrare che quanto detto qualitativamente ha un corrispettivo formale.

2.6. Le proprietà degli stimatori OLS: non distorsione, consistenza e teorema di Gauss-Markov

Teorema 2.1. **Domanda guida:** OLS è una buona strategia per stimare β e α?

La funzione di regressione stimata nel campione (**Sample Regression Function - SRF**) va confrontata con la funzione di regressione nella popolazione (**PRF**), il vero modello che descrive i dati. Poiché non si potrà mai conoscere la PRF, non si potrà mai sapere quanto siano vicine SRF e PRF: un altro campione fornirebbe una SRF diversa, più o meno vicina alla PRF. Occorre quindi capire quando la regressione stimata è una buona proxy per l'intera popolazione: in pratica, la SRF è una buona approssimazione nel campione, ma non è detto lo sia per tutta la popolazione.

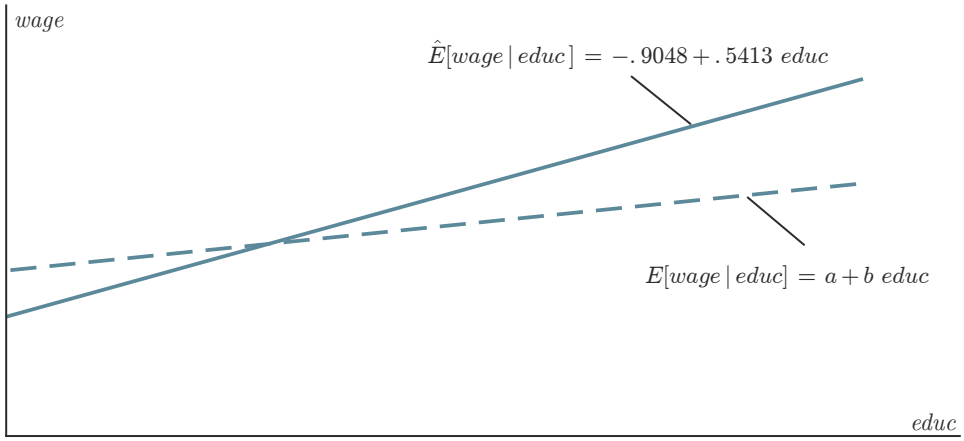


Figura 8 — Modello reale sulla popolazione $E(Y|X = x)$ (linea tratteggiata) rispetto alla regressione stimata (linea retta). Ci si attende che OLS funzioni correttamente se le due rette sono molto vicine tra loro, cioè se $\hat{\alpha} \approx \alpha$ e $\hat{\beta} \approx \beta$.

Le stime OLS si basano su un set di dati estratti casualmente dalla popolazione: campioni diversi forniscono stime diverse, quindi $\hat{\alpha}$ e $\hat{\beta}$ sono **variabili casuali**. Interessa derivarne media e varianza, e approssimarne le distribuzioni di probabilità per calcolare intervalli di confidenza ed eseguire test statistici.

Rappresentazione di $\hat{\beta}$ in funzione di ϵ. È sempre possibile scrivere $\hat{\beta}$ come

$$\hat{\beta} = \sum_{i=1}^{n} \underbrace{\left[\frac{(X_i - \bar{X})}{\sum_{i=1}^{n}(X_i - \bar{X})^2}\right]}_{\omega_i} (Y_i - \bar{Y}) = \sum_{i=1}^{n} \omega_i \underbrace{Y_i}_{\alpha+\beta X_i+\epsilon_i} - \bar{Y} \underbrace{\sum_{i=1}^{n} \omega_i}_{=0} = \beta + \sum_{i=1}^{n} \omega_i \epsilon_i \qquad (1)$$

Non distorsione (valore atteso di $\hat{\beta}$). Dalla eq. (1):

$$E[\hat{\beta}|X_1, \dots, X_n] = \beta + \sum \omega_i \underbrace{E[\epsilon_i|X_1, \dots, X_n]}_{\text{per hyp. } =0} = \beta$$

Il momento marginale, cioè la media di $\hat{\beta}$ rispetto a tutti i possibili $X_1, \dots, X_n$ osservati, è quindi β: lo stimatore è **non distorto**. Se $E[\epsilon|X_1, \dots, X_n] \neq 0$, questo risultato non è più valido e, in media, lo stimatore non fornisce una buona proxy per il vero coefficiente β.

Varianza condizionale (consistenza). La varianza condizionale di $\hat{\beta}$ è

$$\text{Var}[\hat{\beta}|X_1, \dots, X_n] = \sum \omega_i^2 \underbrace{\text{Var}[\epsilon_i|X_1, \dots, X_n]}_{\times \text{ ip. } =\sigma^2} = \frac{\sigma^2}{\sum_{i=1}^{n}(X_i - \bar{X})^2} = \frac{\sigma^2}{(n-1)} \underbrace{\frac{n-1}{\sum_{i=1}^{n}(X_i - \bar{X})^2}}_{\to 1/\sigma_X^2 \text{ if } n\to+\infty} \qquad \text{(consistency)}$$

Per questo risultato si è utilizzata l'ipotesi di omoschedasticità. Il limite è l'inverso della varianza di X, $\sigma_X^2 = \text{Var}(X)$ (le slide scrivono $1/\sigma^2$, che si confonderebbe con la varianza dell'errore).

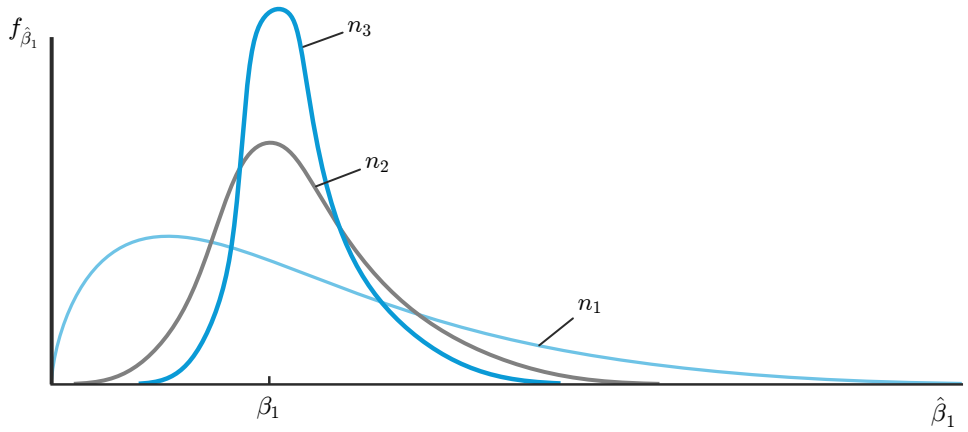


Figura 9 — Distribuzioni di $\hat{\beta}$ per campioni di diverse dimensioni ($n_1 < n_2 < n_3$). La dispersione della distribuzione campionaria di $\hat{\beta}$ si riduce al crescere della dimensione campionaria e collassa su β quando $n \to \infty$.

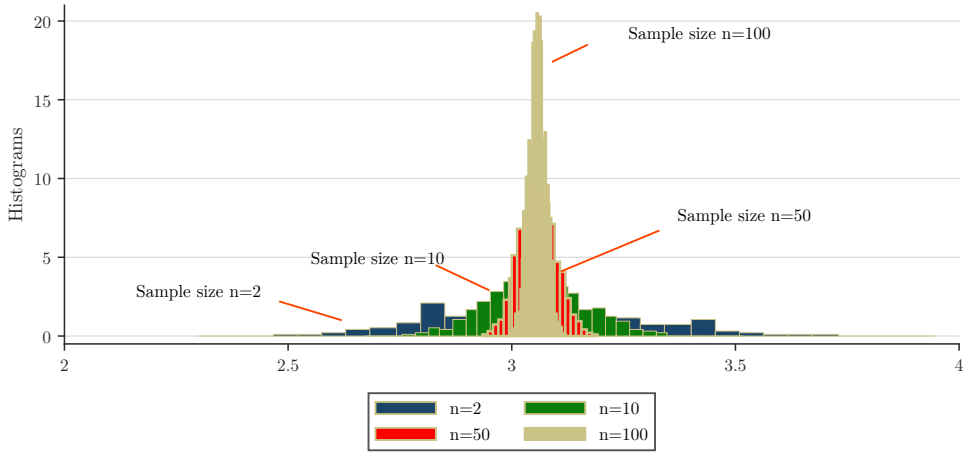


Figura 10 — Distribuzioni di $\hat{\beta}$ per campioni di diverse dimensioni (standardizzate per ottenere una media pari a 0), per $n = 2, 10, 50, 100$. Se $n \to \infty$, $\hat{\beta} \to \beta$ (**Legge dei grandi numeri**).

Teorema di Gauss-Markov. Se sono soddisfatte le seguenti ipotesi:

- **Linearità**: il modello nella popolazione è lineare nei parametri, $Y = \alpha + \beta X + \epsilon$;
- **I.I.D.**: campione casuale di (X_i, Y_i), $i = 1, \dots, N$;
- **Esogeneità**: $E[\epsilon|X] = 0$ (le slide scrivono «il regressore non è correlato al termine di errore», condizione più debole);
- **Omoschedasticità**: $\text{Var}(Y|X = x_i) = \sigma^2$;

allora OLS fornisce il **miglior stimatore lineare non distorto (BLUE)**, il più efficiente (con varianza minore) nella classe degli stimatori lineari e non distorti.

(slide 34–42)

2.7. La distribuzione di $\hat{\beta}$: campioni finiti e normalità asintotica

Teorema 2.2. Distribuzione in campioni finiti. Si può dimostrare che, sotto opportune ipotesi, la distribuzione di $\hat{\beta}$ è gaussiana. In particolare, se l'errore nella popolazione ϵ è indipendente da X ed è normalmente distribuito con media nulla e varianza σ^2, cioè $\epsilon \sim N(0, \sigma^2)$, allora:

- lo stimatore di β ha distribuzione normale: $\hat{\beta} \sim N(\beta,\ \mathrm{Var}(\hat{\beta}|X))$;
- lo stimatore standardizzato ha distribuzione Student t:

$$\frac{\hat{\beta} - \beta}{\hat{\sigma}_{\hat{\beta}}} \sim t_{n-2}$$

Quest'ultimo risultato dipende dal fatto che il denominatore è ignoto e deve essere stimato: $\hat{\sigma}_{\hat{\beta}}$ è l'errore standard stimato, definito più sotto (le slide scrivono $\sqrt{\mathrm{Var}(\hat{\beta}|X)}$ al denominatore; con la varianza vera, cioè con σ^2 noto, il rapporto sarebbe $N(0,1)$). Se $n \to \infty$, la Student t converge a una gaussiana.

Normalità asintotica. In statistica, per stimare il valore atteso di una popolazione si usa la media campionaria, che si distribuisce come una v.c. gaussiana per campioni sufficientemente grandi. Nell'ipotesi che $E[\epsilon|X] = 0$, $\hat{\beta}$ gode della stessa proprietà, essendo sostanzialmente costruito come una media:

$$\hat{\beta} \sim N(\beta,\ \hat{\sigma}^2_{\hat{\beta}})$$

in cui

$$\hat{\sigma}^2_{\hat{\beta}} = \frac{\hat{\sigma}^2}{\sum_{i=1}^{n}(X_i - \bar{X})^2}, \qquad \hat{\sigma}^2 = \frac{1}{n-2}\sum_{i=1}^{n}\hat{\epsilon}_i^2$$

Questo risultato consente di effettuare test di ipotesi su β e di costruire intervalli di confidenza.

Perché vale la normalità asintotica — Teorema del limite centrale (CLT). Se una sequenza Z_i è I.I.D. tale che $E[Z_i] = \mu_Z < +\infty$ e $0 < \mathrm{Var}[Z_i] = \sigma_Z^2 < +\infty$, allora

$$\frac{(\bar{Z} - \mu_Z)}{\sigma_{\bar{Z}}} \to N(0,1)$$

Il numeratore di $\hat{\beta}$ è la media campionaria di variabili $Z = (X - E[X])(Y - E[Y])$, indipendenti per ipotesi, a cui si può applicare il CLT. Il denominatore converge a una costante, essendo in pratica una media di variabili X^2 (Legge dei Grandi Numeri). Quindi

$$\frac{\hat{\beta} - E[\hat{\beta}]}{\sqrt{\text{Var}(\hat{\beta})}} = \frac{\hat{\beta} - \beta}{\sigma_{\hat{\beta}}} \to N(0,1) \;\Rightarrow\; \hat{\beta} \sim N(\beta, \sigma^2_{\hat{\beta}})$$

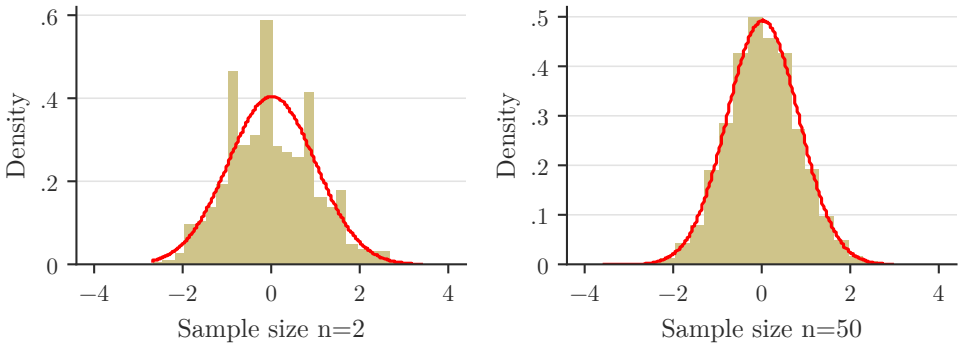


Figura 11 — Istogramma rispetto alla densità normale: stime standardizzate di β per diversi campioni di dimensione n. Pannello di sinistra: campione di piccole dimensioni ($n = 2$); pannello di destra: campione di grandi dimensioni ($n = 50$, buona approssimazione gaussiana). L'approssimazione normale migliora al crescere della dimensione campionaria.

(slide 43–46)

2.8. Lo stimatore della varianza σ^2 e gli errori standard

Definizione 2.5. In caso di omoschedasticità, il modello di regressione è caratterizzato anche dal parametro σ, che descrive l'eterogeneità dei soggetti che condividono lo stesso livello di X. Uno stimatore non distorto di σ^2 è

$$\hat{\sigma}^2 = \frac{1}{n-2} \sum_{i=1}^{n} \hat{\epsilon}_i^2$$

Si può dimostrare che $E[\hat{\sigma}^2] = \sigma^2$.

Gli errori standard per $\hat{\alpha}$ e $\hat{\beta}$ si ricavano inserendo $\hat{\sigma}^2$ nella formula di $\text{Var}(\hat{\beta}|X_1, \dots, X_n)$. Quindi, $\sigma_{\hat{\beta}}$ si stima come

$$\hat{\sigma}_{\hat{\beta}} = \sqrt{\frac{\hat{\sigma}^2}{\sum_{i=1}^{n}(X_i - \bar{X})^2}}$$

Gli errori standard per $\hat{\alpha}$ sono quindi

$$\hat{\sigma}_{\hat{\alpha}} = \sqrt{\frac{\hat{\sigma}^2\left(\frac{1}{n}\sum_{i=1}^{n} X_i^2\right)}{\sum_{i=1}^{n}(X_i - \bar{X})^2}}$$

(slide 47–48)

2.9. Intervalli di confidenza per β

Definizione 2.6. Come per la media campionaria, è utile fornire un intervallo di valori in cui il vero parametro sconosciuto β rientra con alta probabilità (diciamo $1-\alpha$; in questa formula α è il livello di significatività, non l'intercetta). Poiché $\hat{\beta}$ è distribuita normalmente, valgono gli stessi risultati della media campionaria: un intervallo di confidenza per β può essere calcolato come

$$\text{Confidence interval} = \left[\hat{\beta} - z_{\frac{\alpha}{2}} \times \hat{\sigma}_{\hat{\beta}} \;;\; \hat{\beta} + z_{\frac{\alpha}{2}} \times \hat{\sigma}_{\hat{\beta}}\right]$$

Esempio: wage vs. educ. L'intervallo di confidenza al 95% per β è calcolato come

$$[0.541 - 1.96 \times 0.053 \;;\; 0.541 + 1.96 \times 0.053] = [.437;\ .645]$$

(Le slide riportano [.436; .645], cioè l'intervallo in tabella troncato. Stata usa il quantile $t_{524} \approx 1.9645$ al posto di 1.96 e ottiene [.4368; .6460].)

Variabile	Coef.	Std. Err.	t	P>|t|	IC 95% inf.	IC 95% sup.
educ	.5413593	.053248	10.17	0.000	.4367534	.6459651
_cons	-.9048516	.6849678	-1.32	0.187	-2.250472	.4407687

Ci si aspetta quindi che il vero β sia compreso tra [.437; .646], con livello di confidenza del 95%: il 95% riguarda la procedura (in campionamenti ripetuti il 95% degli intervalli così costruiti contiene β), non è la probabilità che β cada in questo intervallo particolare. L'intervallo suggerisce l'esistenza di un'associazione positiva tra wages e years of education.

(slide 49–50)

2.10. Verifica d'ipotesi per β

Definizione 2.7. Ci si potrebbe chiedere se X sia un predittore utile, cioè se abbia un impatto sulla media condizionale di Y. Si ricordi che $\Delta\hat{Y} = \beta\Delta X$: se β fosse 0, non importa quale sia la variazione di X, la variazione attesa di Y prevista dal modello sarebbe nulla. È quindi naturale verificare se β sia abbastanza vicino a 0 oppure no. In generale, si potrebbe voler verificare se

l'evidenza empirica riassunta in $\hat{\beta}$ sia coerente con qualche valore specifico, corrispondente a un'ipotesi di natura economica.

Poiché $\hat{\beta}$ è distribuito come una variabile casuale gaussiana, la procedura di test si basa sugli stessi risultati validi per la media campionaria. Un'ipotesi tipica da verificare è $H_0 : \beta = 0$ contro l'alternativa $H_a : \beta \neq 0$. La statistica t è definita come

$$t = \frac{\hat{\beta} - 0}{\hat{\sigma}_{\hat{\beta}}}$$

Il p-value si calcola allo stesso modo del caso della media. In generale, il sistema di ipotesi $H_0 : \beta = \kappa$ contro una delle tre possibili alternative ($>$, $<$ o $\neq$) può essere verificato tramite

$$t = \frac{\hat{\beta} - \kappa}{\hat{\sigma}_{\hat{\beta}}}$$

Esempio: wage vs. educ. Ci si potrebbe chiedere se un anno in più di scuola abbia un effetto positivo sui salari.

Variabile	Coef.	Std. Err.	t	P>|t|	IC 95% inf.	IC 95% sup.
educ	.5413593	.053248	10.17	0.000	.4367534	.6459651
_cons	-.9048516	.6849678	-1.32	0.187	-2.250472	.4407687

Scritto in linguaggio statistico: $H_0 : \beta = 0$ vs. $H_a : \beta > 0$.

La statistica t osservata è

$$t^{obs} = \frac{.5413593 - 0}{.053248} = 10.17$$

Il p-value $P_{H_0}(t > t^{obs}) \approx 0$, che permette di rifiutare l'ipotesi nulla.

Se si considera invece il sistema d'ipotesi $H_0 : \beta = 0$ vs. $H_a : \beta \neq 0$, la statistica t osservata rimane $t^{obs} = 10.17$ e il p-value viene calcolato come $2\, P_{H_0}(t > |t^{obs}|) \approx 0$.

(slide 51–53)

2.11. Misure di bontà di adattamento: l'R²

Definizione 2.8. Non è stato ancora considerato il problema di misurare come la variabile X approssimi la variabile dipendente Y. Spesso è utile calcolare un indicatore che riassuma quanto bene la linea di regressione OLS si adatti ai dati. L'idea è calcolare la correlazione tra la variabile dipendente Y e le previsioni del modello $\hat{Y}$: maggiore è questo numero, migliore è l'adattamento del modello empirico ai dati. L'R^2 è definito come

$$R^2 = \text{Corr}^2(Y, \hat{Y})$$

Per costruzione $0 \leq R^2 \leq 1$:

- Un R^2 vicino a 1 significa che il regressore è un **buon** predittore per il valore atteso condizionale della variabile dipendente.
- Un R^2 vicino a 0 significa che il regressore è un predittore **mediocre**.
- R^2 **non dice nulla riguardo alla causalità!** Indica solamente come, in uno specifico campione, la retta di regressione approssima le medie dei dati osservati.

Esempio 1 — caso endogeno. Si consideri l'esempio precedente in cui X è endogeno ($Y_i = 3 + 1.5X_i + \epsilon_i$, $\text{cov}(X, \epsilon) = 0.6$, $n = 200$):

Source	SS	df	MS
Model	903.491169	1	903.491169
Residual	159.74002	198	.806767779
Total	1063.23119	199	5.3428703

Number of obs = 200; F(1, 198) = 1119.89; Prob > F = 0.0000; R-squared = 0.8498; Adj R-squared = 0.8490; Root MSE = .8982

Variabile	Coef.	Std. Err.	t	P>|t|	IC 95% inf.	IC 95% sup.
x	2.129496	.063634	33.46	0.000	2.004008	2.254983
_cons	2.962697	.0635759	46.60	0.000	2.837324	3.08807

Si noti che l'R^2 è elevato ($\approx 85.0\%$; le slide scrivono 84,9%, troncando 84,98%). Tuttavia si sa già che il modello **non** rappresenta una relazione causale: un R^2 alto non implica causalità.

Esempio 2 — wage vs. educ. Si consideri ora la relazione tra salari e istruzione, che potrebbe rappresentare un legame causale:

Source	SS	df	MS
Model	1179.73204	1	1179.73204
Residual	5980.68225	524	11.4135158
Total	7160.41429	525	13.6388844

Number of obs = 526; F(1, 524) = 103.36; Prob > F = 0.0000; R-squared = 0.1648; Adj R-squared = 0.1632; Root MSE = 3.3784

Variabile	Coef.	Std. Err.	t	P>|t|	IC 95% inf.	IC 95% sup.
educ	.5413593	.053248	10.17	0.000	.4367534	.6459651

Variabile	Coef.	Std. Err.	t	P>|t|	IC 95% inf.	IC 95% sup.
_cons	-.9048516	.6849678	-1.32	0.187	-2.250472	.4407687

Si noti che R^2 è piuttosto basso ($\approx 16.5\%$; le slide scrivono 16,4%, troncando 16,48%). Nonostante questo risultato, il collegamento tra le due variabili ha comunque senso da un punto di vista logico: un R^2 basso non esclude una relazione causale plausibile.

(slide 54–57)

3 | Il modello di regressione multipla

Fonte: ECON_Teoria_03_Regressione-Multipla.pdf — *53 slide*

3.1. Esempio motivante: test scores e dimensione della classe

Esempio 3.1. Comunemente si pensa che un rapporto studenti-insegnanti più basso induca un rendimento migliore degli studenti. Per questo, ad esempio in California, verso la fine degli anni '90, tutte le classi K-3 sono state ridotte per avere un rapporto massimo studenti-insegnanti di 20 (*Class Size Reduction Act* - CSR). Ciò ha un costo: inizialmente era di 1,8 miliardi di dollari all'anno. Con un costo così alto ci si chiede se ne valga la pena. Il Commissario per l'Istruzione potrebbe essere interessato a sapere se questa spesa extra ha un impatto significativo sul rendimento scolastico atteso.

Ci chiediamo se la dimensione della classe sia l'unica informazione rilevante che ha un impatto nello spiegare la variazione del punteggio medio atteso di questi studenti, o se vadano considerati altri fattori.

Un modello di regressione naïve evidenzia che esiste una dipendenza negativa significativa tra la dimensione media della classe, `str`, e il punteggio medio atteso, `avg_score`:

	Coef.	Std. Err.	t	P>|t|	[95% Conf.	Interval]
str	-2.279808	.4798256	-4.75	0.000	-3.22298	-1.336637
_cons	698.933	9.467491	73.82	0.000	680.3231	717.5428

A prima vista ridurre la dimensione delle classi sembra una scelta rilevante, poiché una riduzione della dimensione di una classe induce un aumento del punteggio medio di circa 2,28 punti. Ma questo modello statistico è una relazione causale? Esistono altre spiegazioni più credibili?

Ad un esame più attento, osserviamo che il reddito medio (`avginc`) per le persone che vivono in ciascun distretto è correlato positivamente con `avg_score`: i distretti con reddito più alto tendono ad avere studenti con voti più alti. Esiste anche una dipendenza negativa tra reddito e dimensione della classe (`str`): i distretti a reddito più elevato tendono ad avere classi di dimensioni inferiori. Le correlazioni (comando `correlate avg_score str avginc`) sono:

	avg_score	str	avginc
avg_score	1.0000		
str	-0.2264	1.0000	
avginc	0.7124	-0.2322	1.0000

Ci chiediamo se includere il reddito nel modello di regressione possa essere utile per prevedere il punteggio medio e spiegare la relazione causa-effetto performance vs. riduzione delle classi.

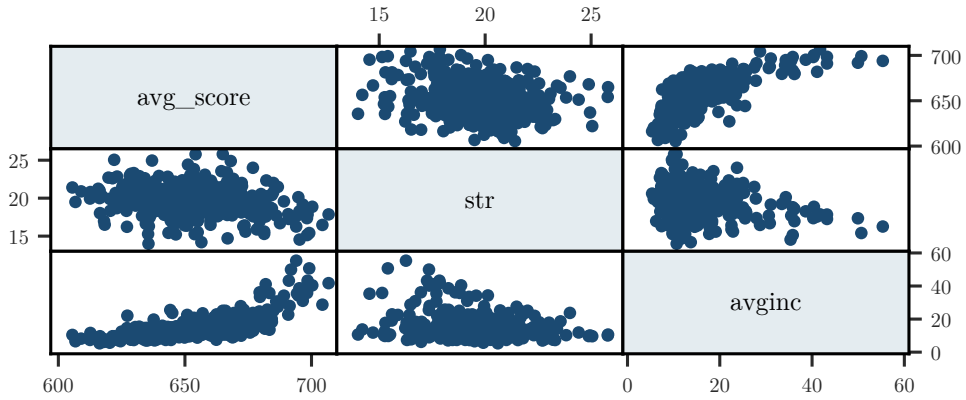


Figura 1 — Scatterplot a coppie delle variabili coinvolte (`avg_score`, `str`, `avginc`). La matrice di scatterplot mostra visivamente le correlazioni della tabella precedente: `avg_score` cresce al crescere di `avginc` e decresce (debolmente) al crescere di `str`; `str` e `avginc` sono debolmente correlate negativamente.

Questa evidenza empirica suggerisce che l'associazione negativa tra dimensione della classe e punteggio del test potrebbe essere **spuria**, poiché può essere spiegata dall'effetto del reddito su ciascuna variabile.

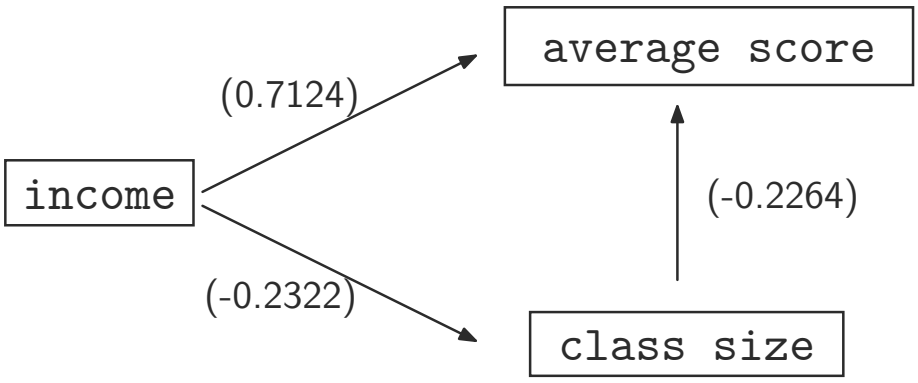


Figura 2 — Rappresentazione causale del modello (diagramma con `income` che punta sia ad `average score` con correlazione 0.7124 sia a `class size` con correlazione -0.2322, e una freccia da `class size` ad `average score` con correlazione -0.2264). Il diagramma illustra come

il reddito (`income`) sia una causa comune che influenza sia il punteggio medio sia la dimensione della classe: la correlazione osservata tra `class size` e `average score` non riflette quindi necessariamente un nesso causale diretto.

(slide 3–7)

3.2. Il modello di regressione multipla e l'interpretazione dei parametri

Definizione 3.1. Si ipotizzi esistano due o più variabili esplicative, X_1 ed X_2 $(X_3, \dots, X_k)$ potenzialmente utili per descrivere la media condizionale di Y. In questo caso, la funzione di regressione semplice può essere generalizzata da

$$E[Y|X_1, X_2] = \alpha + \beta_1 X_1 + \beta_2 X_2$$

Come per il modello di regressione semplice, ogni osservazione è descritta da

$$Y_i = \alpha + \beta_1 X_{1,i} + \beta_2 X_{2,i} + \epsilon_i$$

Y è la variabile dipendente, X_1 e X_2 sono i regressori mentre ϵ è un termine di errore che misura la distanza tra il modello di regressione e l'osservabile Y.

Interpretazione dei parametri. Nella regressione semplice, β_1 misura la variazione attesa di Y a condizione che $\Delta X = 1$. Infatti $\Delta\hat{Y} = \beta_1 \underbrace{\Delta X}_{=1}$.

Nella regressione multipla, il coefficiente β_1 è la variazione attesa di Y dovuta a una variazione unitaria di X_1 a condizione che X_2 sia mantenuto costante. In pratica, se calcoliamo la variazione attesa di Y per un dato livello dei due regressori $X_1 = \bar{X}_1$ e $X_2 = \bar{X}_2$, otteniamo

$$\hat{Y}(\bar{X}_1, \bar{X}_2) = \alpha + \beta_1 \bar{X}_1 + \beta_2 \bar{X}_2 + \epsilon(\bar{X}_1, \bar{X}_2).$$

Supponiamo ora di voler calcolare Y atteso per $X_1 = \bar{X}_1 + \Delta X_1$ e $X_2 = \bar{X}_2$:

$$\hat{Y}(\bar{X}_1 + \Delta X_1, \bar{X}_2) = \alpha + \beta_1(\bar{X}_1 + \Delta X_1) + \beta_2 \bar{X}_2 + \epsilon(\bar{X}_1 + \Delta X_1, \bar{X}_2).$$

La variazione prevista di Y è la differenza

$$\Delta\hat{Y} = \hat{Y}(\bar{X}_1 + \Delta X_1, \bar{X}_2) - \hat{Y}(\bar{X}_1, \bar{X}_2) = \beta_1 \Delta X_1 + \Delta\epsilon$$

Nell'ipotesi che ϵ non sia rilevante per descrivere il valore atteso di Y, cioè $\Delta\epsilon = 0$ (in media vale per $E[\epsilon|X_1, X_2] = 0$; la presenza di ϵ nelle espressioni di $\hat{Y}$ qui sopra è impropria, perché

$\hat{Y}$ è la media condizionale e non contiene l'errore), allora una variazione del valore atteso di Y è proporzionale alla variazione di X_1, cioè

$$\Delta Y = \beta_1 \Delta X_1$$

Nella regressione multipla, un parametro descrive l'effetto di una variabile esplicativa una volta controllati gli effetti dell'altra variabile esplicativa nel modello (imponendo $X_2 = \bar{X}_2$). La regressione semplice ha una sola variabile esplicativa, quindi il parametro descrive l'effetto di una variabile senza controllare per le altre possibili variabili esplicative, la cui influenza, se correlate con il regressore, confluisce nel coefficiente (le slide scrivono «al netto di tutte le altre», da intendere come «ignorando le altre»). I coefficienti β_j sono chiamati **effetti marginali**.

Esempio: class scores vs. reddito e class size. Consideriamo il modello di regressione multipla che lega il punteggio medio degli studenti, la dimensione della classe e il reddito delle famiglie:

$$\text{avg_score}_i = \alpha + \beta_1 \text{str}_i + \beta_2 \text{avginc}_i + \epsilon_i$$

	Coef.	Std. Err.	t	P>|t|	[95% Conf.	Interval]
str	-.6487401	.354405	-1.83	0.068	-1.345383	.0479028
avginc	1.839112	.0927868	19.82	0.000	1.656724	2.0215
_cons	638.7292	7.449077	85.75	0.000	624.0867	653.3716

Questi risultati suggeriscono che, per un dato livello di reddito, se la dimensione della classe si riduce di un'unità, allora il punteggio medio atteso aumenta di circa 0.65 punti. Questa variazione però risulta debolmente significativa.

(slide 8–11)

Dalla lezione del 12 novembre 2026: la dimensione della classe con e senza il reddito. Nella regressione semplice del punteggio dei bambini sulla dimensione della classe, la pendenza stimata è indicata dal docente in $-2{,}27$ (la nota riporta $-2{,}28$). Il test di significatività sul coefficiente, per verificare se il parametro sia diverso da zero, dà un p-value pari a zero: esiste una pendenza negativa, quella della retta dello scatter plot che descrive i dati.

Nel modello esteso l'aspettativa del punteggio dipende dalla dimensione della classe, X_1, e dal reddito, X_2. Stimandolo, il coefficiente che lega la performance alla dimensione della classe si più che dimezza, passando da circa $-2{,}2$ a $-0{,}64$, e il test di significatività dà un p-value maggiore del 5%, non esageratamente grande. Aggiungendo il reddito, l'impatto della dimensione della classe sulla performance si riduce di molto: in un'analisi stretta, condizionatamente al livello di reddito la dipendenza lineare tra performance e dimensione della classe è nulla. Il docente collega questo risultato al p-value dell'analisi per sottocampioni di ECON 01.

Ricalcolando sul dataset del corso (`ECON_Dataset_caschool.csv`, 420 distretti): nella regressione semplice la pendenza è -2.2798 (errore standard 0.4798, $t = -4.75$); aggiungendo il reddito il coefficiente della dimensione della classe diventa -0.6487 (errore standard 0.3544, $t = -1.83$, p-value di circa 0.07), quindi non significativo al 5% e debolmente significativo al 10%. Quanto detto dal docente sul modello esteso è confermato; il collegamento con l'analisi per sottocampioni no, perché sul dataset la correlazione nel gruppo ad alto reddito è significativa (vedi ECON 01).

Il docente presenta la costruzione di un modello con due variabili come equivalente a dividere il campione in due pezzi, alto e basso reddito, e a calcolare il livello di dipendenza nei due sottoinsiemi. Il punto viene ripreso più avanti.

3.3. Cause di endogeneità: distorsione da variabile omessa

Teorema 3.1. Nel modello di regressione semplice, abbiamo ipotizzato che $E[\epsilon|X] = 0$ ($\Rightarrow \text{Cov}(\epsilon, X) = 0$).

Supponiamo che la **vera** media condizionale (relazione causale) sia ben approssimata dal seguente modello:

$$\text{Modello 1:} \quad Y = \alpha + \beta_1 X_1 + \beta_2 X_2 + \tilde{\epsilon}$$

Poiché non conosciamo il vero modello, supponiamo di stimare la seguente regressione **sbagliata**, ovvero un modello statistico non correttamente specificato:

$$\text{Modello 2:} \quad Y = \alpha + \beta_1 X_1 + \epsilon$$

Quali sono le conseguenze di questo errore?

Supponiamo ad esempio che valga la seguente ipotesi:

- $\text{Cov}(\tilde{\epsilon}, X_j) = 0$, $j = 1{,}2$ (esogeneità rispetto al vero modello)
- $\text{Cov}(X_1, X_2) \neq 0$

Nel Modello 2, la variabile X_2 è stata omessa. Ciò significa che il suo impatto atteso su Y è stato inglobato dal termine di errore ϵ. Nel Modello 2 vale $\epsilon = \beta_2 X_2 + \tilde{\epsilon}$, quindi

$$\text{Cov}(X_1, \epsilon) = \beta_2 \text{Cov}(X_1, X_2) \neq 0 \quad \text{se } \beta_2 \neq 0$$

In particolare, è violata la condizione di esogeneità per il modello di regressione semplice. Si può dimostrare che gli stimatori OLS di β_1 sono distorti in campioni piccoli e grandi. Quindi, se $n \to \infty$:

$$\hat{\beta}_1 \xrightarrow{p} \beta_1 + \rho_{X_1\epsilon}\frac{\sigma_\epsilon}{\sigma_X} \quad \text{(non consistenza di } \hat{\beta}_1\text{)}$$

Se prendiamo come punto di riferimento una regressione sbagliata, probabilmente prenderemo decisioni sbagliate. Come affermato prima, ciò che effettivamente stimiamo (al limite, per $n \to \infty$) è

$$\hat{\beta}_1 = \beta_1 + \rho_{X_1\epsilon}\frac{\sigma_\epsilon}{\sigma_X} \neq \beta_1$$

In particolare, una variazione unitaria di X, cioè $\Delta X = 1$, produce

$$\Delta Y = \beta_1 + \underbrace{\Delta\epsilon}_{\approx \rho_{X_1\epsilon}\,\sigma_\epsilon/\sigma_X}$$

In questo caso non possiamo distinguere gli effetti dovuti dai regressori inclusi e da quelli omessi dal modello. Nell'esempio della CAL school, non sappiamo se la stima di $\hat{\beta} = -2.280$ sia dovuta all'effettiva variazione della dimensione della classe o ad altri fattori come ad esempio il reddito.

Sintesi. Nel modello di regressione semplice, l'ipotesi chiave è $E(\epsilon|X) = 0 \Rightarrow \text{Cov}(\epsilon, X) = 0$. Se una variabile rilevante viene omessa, dobbiamo affrontare delle conseguenze:

- L'omissione di una variabile rilevante e correlata con il regressore incluso induce una correlazione non nulla tra il regressore incluso ed il termine di errore $\Rightarrow \text{Cov}(\epsilon, X) \neq 0$. L'ipotesi di **esogeneità** non è più valida;
- $E[\hat{\beta}] \neq \beta$, ovvero $\hat{\beta}$ è **distorto**;
- Questa distorsione persiste anche se n è grande (**non consistenza**).

(slide 12–16)

Dalla lezione del 12 novembre 2026: l'endogeneità nell'esempio della dimensione della classe. Nell'esempio dei bambini a scuola c'è un problema di endogeneità. La prima regressione lega la performance dei bambini alla dimensione della classe più un termine d'errore, e nel termine d'errore c'è l'effetto del reddito, perché non è nel modello: ε raccoglie tutto ciò che non è dimensione della classe, e qui lo si può identificare con il reddito. Poiché la correlazione tra reddito e dimensione della classe è significativamente diversa da zero, stimare quel modello significa ipotizzare di fatto che sia zero.

Si toglie allora dal termine d'errore il reddito, che è la variabile problematica, e lo si inserisce nel modello. L'errore del modello con il regressore in più non è più caratterizzato dall'effetto del reddito, perché questo è ora parte della media condizionale e non della parte residuale. Ristimando il modello si elimina una delle possibili cause di endogeneità, cioè una delle cause che creano relazione tra ε e la dimensione della classe, e il parametro passa da circa $-2{,}2$ a $-0{,}64$.

Secondo il docente nel modello precedente c'era probabilmente un problema di endogeneità che si era fatto finta di non vedere. I parametri sono cambiati molto, quindi per stimare β nella prima regressione si è probabilmente usata la formula sbagliata, supponendo nulla la correlazione tra reddito e dimensione della classe, che invece non lo è. La distorsione non è piccola e il parametro cambia molto: queste sono le conseguenze di stimare un modello facendo finta che $\Delta\varepsilon$ sia uguale a zero quando in realtà non lo è.

3.4. Cause di endogeneità: errori di misura

Teorema 3.2. Si trova endogeneità anche quando il regressore non è osservato esattamente, ma conosciamo solo una sua approssimazione. Consideriamo l'esempio seguente, in cui non possiamo osservare X_i ma solo un suo proxy, diciamo X_i^*. Poi

$$Y_i = \gamma X_i + \epsilon_i$$
$$X_i^* = X_i + u_i \qquad \mathrm{Cov}(X_i, u_i) = 0$$

- X_i è il vero regressore, non osservabile;
- X_i^* è il regressore osservabile, ma impreciso;
- u_i è l'errore di misura.

La regressione calcolabile è quindi

$$Y_i = \beta X_i^* + \epsilon_i^*$$

Scriviamo la regressione originale in funzione del regressore osservabile X^*, per verificare se la regressione ammissibile soddisfa l'ipotesi OLS:

$$Y_i = \gamma X_i + \epsilon_i = \gamma(X_i^* - u_i) + \epsilon_i = \gamma X_i^* + \underbrace{\epsilon_i - \gamma u_i}_{\epsilon_i^*}$$

La regressione calcolabile diventa

$$Y_i = \gamma X_i^* + \epsilon_i^* \;\Rightarrow\; \mathrm{Cov}(X_i^*, \epsilon_i^*) = -\gamma \mathrm{Var}(u_i) \neq 0 \;\Rightarrow\; \text{Endogeneity}$$

Quindi, l'utilizzo di regressori che non sono osservati accuratamente porta a stimatori distorti e non consistenti. (Segno: $\mathrm{Cov}(X + u,\, \epsilon - \gamma u) = -\gamma\, \mathrm{Var}(u)$, con u incorrelato con X ed ϵ; le slide riportano $+\gamma\, \mathrm{Var}(u)$.)

Esempio numerico. Consideriamo un dataset simulato di dimensione 200 che soddisfa le seguenti condizioni:

$$Y = 3 + 1.5X + \epsilon$$

La variabile X è il vero regressore (misurato senza errore). Come benchmark, stimiamo il modello di regressione $Y = \alpha + \beta X + \epsilon$, in cui utilizziamo X come regressore:

	Coef.	Std. Err.	t	P>|t|	[95% Conf.	Interval]
X	1.427984	.0654388	21.82	0.000	1.298938	1.557031
_cons	3.072873	.06727	45.68	0.000	2.940215	3.205531

Le stime sono molto precise, nel senso che $\hat{\beta}$ e $\hat{\alpha}$ sono vicini rispettivamente a 1.5 e 3.

Ipotizziamo ora che X non sia osservabile ma sia disponibile solo $X^* = X + u$, $u \sim N(0, 1)$. Cosa accade se stimiamo la seguente regressione:

$$Y = \alpha + \beta X^* + \epsilon$$

in cui anche $\epsilon \sim N(0, 1)$ ed è indipendente da u:

	Coef.	Std. Err.	t	P>|t|	[95% Conf.	Interval]
Xs	.70249	.0742756	9.46	0.000	.5560173	.8489628
_cons	3.135813	.1029848	30.45	0.000	2.932726	3.338901

Si noti che in questo caso $\hat{\beta}$ non è neanche vicino a 1.5 (il valore vero per questo parametro) poiché l'intervallo di confidenza del 95% non lo include.

La distorsione o bias in questo caso può essere quantificato. Sappiamo infatti che nella regressione calcolabile (con X^*), al limite per $n \to \infty$ (la formula seguente è il limite in probabilità di $\hat{\beta}$),

$$\hat{\beta} = \frac{\operatorname{Cov}(X^*, y)}{V(X^*)} = \beta \frac{V(X)}{V(X) + V(u) + 2\operatorname{Cov}(X, u)} \approx \frac{1}{2}\beta$$

Nella simulazione è stato ipotizzato $\operatorname{Var}(X) = \operatorname{Var}(u) = 1$. Inoltre si è ipotizzato $\operatorname{Cov}(X, u) = 0$ (le slide scrivono $\operatorname{Cov}(X, u)$ senza il fattore 2 al denominatore, ininfluente perché la covarianza è nulla). Di conseguenza la distorsione risulta essere la metà del vero valore del parametro, in questo esempio circa 0.75. Si noti quindi che quello che stimo (.70249) è prossimo al vero $\beta = 1.5$ meno la distorsione (.75).

(slide 17–21)

3.5. L'errore ε: momenti condizionali

Definizione 3.2. Le proprietà della variabile casuale ϵ servono a derivare le proprietà degli stimatori OLS. In particolare, ci interessa valutare i suoi momenti e le relazioni tra ϵ e $X_1, \ldots, X_k$.

Per costruzione, ϵ_i può essere visto come la differenza tra Y_i e la media condizionale $E[Y|X_1, \dots, X_k]$, cioè

$$\epsilon_i = Y_i - E[Y|X_{1i}, \dots, X_{ki}] = Y_i - \alpha - \sum_{j=1}^{k} \beta_j X_{ji}$$

ϵ raccoglie tutte le caratteristiche dei soggetti non esplicitamente prese in considerazione dal modello e descrive una certa eterogeneità del campione.

Media condizionale, $E[\epsilon|X_1, \dots, X_k]$. Supponiamo, ad esempio, che $E[Y|X] = \alpha + \sum_{j=1}^{k} \beta_j X_j$ sia un'approssimazione credibile della media condizionale. Con questa ipotesi, la media condizionale di ϵ è quindi

$$E[\epsilon|X] = E[Y|X] - \alpha - \sum_{j=1}^{k} \beta_j X_j = 0$$

Come conseguenza principale, $\text{Cov}(\epsilon, X) = 0$ e quindi tutte le variabili che concorrono a costruire ϵ devono essere incorrelate con X_j, $\forall j$. L'intuizione è che le uniche informazioni rilevanti per descrivere la media condizionale di Y sono $X_1, \dots, X_k$. Tutte le altre variabili non possono avere un impatto sistematico su di esso.

Varianza condizionale, $\text{Var}(\epsilon|X_1, \dots, X_k)$. In generale, la forma funzionale della varianza condizionale di ϵ non è nota. In ogni caso, la variabilità di ϵ descrive anche la variabilità della variabile dipendente Y, ovvero

$$\text{Var}(Y|X) = \text{Var}(\epsilon|X)$$

Possiamo formulare due diverse ipotesi riguardo alle varianze condizionali:

- **Omoschedasticità**: si assume che $\text{Var}(\epsilon|X_1, \dots, X_k) = \sigma^2$ non dipende da X.
- **Eteroschedasticità**: si assume che $\text{Var}(\epsilon|X_1, \dots, X_k) = \sigma^2(X_1, \dots, X_k)$ dipende dai regressori (da almeno uno degli X_j).

(slide 22–24)

3.6. Le ipotesi OLS

Definizione 3.3. Sono le ipotesi necessarie per valutare correttamente i coefficienti tramite OLS. Le slide propongono due formulazioni equivalenti (Caso I e Caso II), contenenti lo stesso insieme di ipotesi:

- Il modello vero (nella popolazione) è lineare, ovvero $E[Y|X] = \alpha + \beta_1 X_1 + \cdots + \beta_k X_k$;
- Il modello statistico corrisponde a quello vero, ovvero $Y = \alpha + \beta_1 X_1 + \cdots + \beta_k X_k + \epsilon$;

  - Come conseguenza principale, $\text{Cov}(X_j, \epsilon) = 0$, e quindi X_j si dice **esogeno** (per ogni j);
- Le $(k+1)$-uple $(X_{1,i}, \dots, X_{k,i}, Y_i)$, $i = 1, \dots, n$ sono **I.I.D.**;
- I momenti quarti di X_j e Y esistono e sono finiti (per tutti i j);
- Supponiamo, ad esempio, che $\text{var}[\epsilon|X] = \sigma^2$ (**Omoschedasticità**);
- **Assenza di perfetta collinearità**: non esistono relazioni lineari esatte tra le variabili indipendenti.

(slide 25–26)

3.7. Perfetta collinearità

Esempio 3.2. Intuitivamente, la perfetta multicollinearità è un problema perché contraddice la logica del modello di regressione. In generale, un parametro rappresenta come varia Y in corrispondenza di una variazione unitaria del regressore, diciamo X_1, una volta che tutte le altre variabili sono fissate. Ma se, ad esempio, X_1 e X_2 sono perfettamente correlati, come è possibile variare X_1 e fissare X_2, dato che X_1 ed X_2 si muovono assieme?

Perfetta collinearità viene osservata quando almeno uno dei regressori è funzione lineare esatta di alcuni altri regressori. Un esempio di una relazione lineare esatta tra X_1, X_2, X_3 e X_5 è $X_2 = a_1 X_1 + a_3 X_3 + a_5 X_5$ per alcune costanti note a_1, a_3, a_5.

Esempio. Consideriamo la regressione multipla

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \epsilon$$

Si ricordi che l'impatto atteso di X_2 o X_3 su Y è misurato rispettivamente da β_2 e β_3. Supponiamo ad esempio che $X_2 = \phi X_3$ e ϕ sia una costante nota. La previsione $\hat{Y}$ può essere calcolata come

$$E[Y|X_1, X_2, X_3] = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 = \beta_0 + \beta_1 X_1 + (\beta_2 \phi + \beta_3) X_3 = \beta_0 + \beta_1 X_1 + \tilde{\beta}_3 X_3$$

In questo caso non è possibile distinguere gli effetti di X_2 e X_3. La combinazione di β_2 e β_3, ovvero $(\beta_2 \phi + \beta_3)$, misura l'impatto congiunto di X_2 e X_3 sulla Y attesa.

Conseguenza: quando stimiamo i parametri tramite OLS, il sistema di equazioni non ha un'unica soluzione e quindi non possiamo stimare i parametri.

La soluzione alla collinearità perfetta è semplice: **eliminare uno qualsiasi dei regressori che causano collinearità** al modello.

(slide 27–29)

3.8. Stima OLS della regressione multipla

Dimostrazione. Una volta osservati i dati, occorre stimare i parametri α e β_j che definiscono il modello di regressione. L'idea di base è trovare i parametri α e β_j che permettano di minimizzare la distanza tra ciascuna osservazione e la retta di regressione.

Come nel caso della regressione semplice, OLS suggerisce di minimizzare la varianza del termine di errore:

$$\min_{\alpha,\beta_1,\beta_2} \text{Var}(\epsilon) = \min_{\alpha,\beta_1,\beta_2} E[\epsilon^2] \approx \min_{\alpha,\beta_1,\beta_2} \frac{1}{n}\sum_{i=1}^{n}(Y_i - \alpha - \beta_1 X_{1,i} - \beta_2 X_{2,i})^2$$

La soluzione OLS per $\hat{\beta}_j$ potrebbe essere una funzione poco intuitiva di X_1, X_2 ed Y. Tuttavia, lo stimatore può essere ricavato come risultato di una regressione semplice del tipo

$$Y = \alpha + \beta_j \hat{u}_j + \eta,$$

Il regressore ausiliario $\hat{u}_j$ è definito come segue:

$$\hat{u}_j = X_j - \hat{a} - \hat{b}X_h, \qquad h \neq j$$

Si noti che $\hat{u}_j$ sono i residui della regressione $X_j = a + bX_h + u_j$ (l'indice h denota l'altro regressore; i resta l'indice dell'osservazione), per cui lo stimatore OLS risulta

$$\hat{\beta}_j = \frac{\sum_{i=1}^{n} \hat{u}_{j,i} Y_i}{\sum_{i=1}^{n} \hat{u}_{j,i}^2}, \qquad j = 1,2$$

In particolare, $\hat{u}_j$ rappresenta l'informazione fornita dalla variabile X_j, ma che non dipende da X_h. Risultati equivalenti possono essere ottenuti per regressioni con un numero generico k di regressori.

Questa formula mostra che possiamo quindi eseguire una semplice regressione di Y su $\hat{u}_j$ per ottenere $\hat{\beta}_j$. L'intuizione è la seguente: l'informazione fornita dai regressori X_j può essere suddivisa in due segnali: (1) la parte che può essere spiegata da altri fattori ($X_h, h \neq j$); (2) la parte che non dipende da X_h. Ad esempio, per $\hat{\beta}_1$, i residui $\hat{u}_{1,i}$ sono la parte di X_1 non correlata con X_2.

In altre parole, $\hat{u}_{1,i}$ rappresenta $X_{1,i}$ dopo che gli effetti di $X_{2,i}$ sono stati controllati. Quindi, $\hat{\beta}_1$ misura la **relazione campionaria tra Y e X_1 dopo che l'effetto di X_2 è stato controllato/eliminato**.

Valori predetti e residui. La previsione del valore atteso di Y, o valore predetto, è

$$\hat{Y}_i = \hat{E}[Y_i|X_1 = x_{1,i}, X_2 = x_{2,i}] = \hat{\alpha} + \hat{\beta}_1 x_{1,i} + \hat{\beta}_2 x_{2,i}$$

Il termine di errore viene stimato come la differenza tra la variabile osservata Y_i e il valore atteso stimato $\hat{Y}_i$. Viene detto **residuo** ed è definito come

$$\hat{\epsilon}_i = Y_i - \hat{\alpha} - \hat{\beta}_1 X_{1,i} - \hat{\beta}_2 X_{2,i} = Y_i - \hat{Y}_i$$

Come per la regressione semplice, ogni osservazione Y_i può essere scritta come la somma tra la previsione della media condizionale e della componente residuale:

$$Y_i = \hat{Y}_i + \hat{\epsilon}_i = \underbrace{\hat{\alpha} + \hat{\beta}_1 X_{1,i} + \hat{\beta}_2 X_{2,i}}_{\text{previsione}} + \underbrace{\hat{\epsilon}_i}_{\text{Residuo}}$$

□

(slide 30–33)

3.9. Il teorema di Frisch-Waugh-Lovell (caso a due regressori) e verifica numerica

Teorema 3.3. Come evidenziato prima, invece di calcolare $\hat{\beta}_1$ tramite la consueta procedura OLS, esso può essere ottenuto come segue:

(a) Si regredisce Y su X_2 e si ottiene il residuo $\hat{\epsilon}_y$.
(b) Si regredisce X_1 su X_2 e si calcolano i residui $\hat{u}$.
(c) Infine, si regredisce $\hat{\epsilon}_y$ su $\hat{u}$ per ottenere $\hat{\beta}_1$.

Questo risultato, noto come **Teorema di Frisch-Waugh-Lovell**, permette di interpretare ciascun coefficiente OLS β_1 come l'associazione lineare (pendenza della regressione parziale, non una correlazione) tra la variabile dipendente Y e il regressore X_1, una volta eliminati gli effetti di X_2 (lo stesso vale se siamo interessati a β_2).

Esempio. Consideriamo il modello di regressione che lega le performance e la dimensione della classe:

$$\text{avg_score}_i = \alpha + \beta_1 \text{str}_i + \beta_2 \text{avginc}_i + \epsilon_i$$

Le stime OLS basate su un campione di 420 osservazioni sono:

	Coef.	Std. Err.	t	P>|t|	[95% Conf.	Interval]
str	-.6487401	.354405	-1.83	0.068	-1.345383	.0479028
avginc	1.839112	.0927868	19.82	0.000	1.656724	2.0215

	Coef.	Std. Err.	t	P>|t|	[95% Conf.	Interval]
_cons	638.7292	7.449077	85.75	0.000	624.0867	653.3716

Il modello stimato diventa quindi

$$E[\text{avg_score}] = 638.73 - 0.649\,\text{str} + 1.839\,\text{avginc}$$

Usando il teorema di Frisch-Waugh-Lovell:

(1) Si stimi $\text{str} = a + b\,\text{avginc} + u_{str}$ e si calcoli $\hat{u}_{str}$:

	Coef.	Std. Err.	t	P>|t|	[95% Conf.	Interval]
avginc	-.0607907	.0124556	-4.88	0.000	-.0852741	-.0363073
_cons	20.57153	.2108957	97.54	0.000	20.15698	20.98608

(2) Si stimi $\text{avg_score} = a + b\,\text{avginc} + u_{score}$ e si calcoli $\hat{u}_{score}$:

	Coef.	Std. Err.	t	P>|t|	[95% Conf.	Interval]
avginc	1.87855	.0905044	20.76	0.000	1.700649	2.05645
_cons	625.3836	1.532405	408.11	0.000	622.3714	628.3958

(3) Si stimi $\hat{u}_{score} = a + b\,\hat{u}_{str} + u$ per ottenere $\hat{\beta}_1$:

	Coef.	Std. Err.	t	P>|t|	[95% Conf.	Interval]
resid_str	-.6487401	.3539808	-1.83	0.068	-1.344544	.0470642
_cons	1.35e-08	.6505869	0.00	1.000	-1.27883	1.27883

Il coefficiente ottenuto nel passo (3), -.6487401, coincide esattamente con il coefficiente di `str` stimato nella regressione multipla completa: è la verifica numerica del teorema.

(slide 34–36)

3.10. Bontà di adattamento (R^2)

Definizione 3.4. La misura della bontà di adattamento R^2 può essere calcolata anche per un modello di regressione multipla. Come per la regressione semplice, possiamo calcolarla come la correlazione al quadrato tra la variabile dipendente e la previsione, ovvero

$$R^2 = \text{Corr}^2(Y, \hat{Y})$$

Questo indicatore è appropriato per verificare se il modello prevede correttamente la variabile dipendente, **ma non indica presenza di relazioni causali**.

Output completo (esempio avg_score su str e avginc, n = 420):

Source	SS	df	MS	
(ESS) Model	77801.487	2	38900.7435	Number of obs = 420
(RSS) Residual	74308.1067	417	178.196898	F(2, 417) = 218.30
(TSS) Total	152109.594	419	363.030056	Prob > F = 0.0000
				R-squared = 0.5115
				Adj R-squared = 0.5091
				Root MSE = 13.349

	Coef.	Std. Err.	t	P>|t|	[95% Conf.	Interval]
str	-.6487401	.354405	-1.83	0.068	-1.345383	.0479028
avginc	1.839112	.0927868	19.82	0.000	1.656724	2.0215
_cons	638.7292	7.449077	85.75	0.000	624.0867	653.3716

(slide 37–38)

3.11. Proprietà degli stimatori OLS: distribuzione e varianza

Teorema 3.4. Come per la media campionaria, le stime OLS si basano su un dataset ottenuto da campionamento casuale. Per questo motivo campioni diversi forniscono stime diverse: **le stime OLS sono quindi variabili casuali**.

Si può dimostrare che $\hat{\beta}_j$, $\forall j$, è ben approssimato da una variabile casuale Normale. In particolare, se $E[\epsilon|X_1, X_2, \dots, X_k] = 0$, e $\hat{\beta}_j$ è uno stimatore OLS di β_j, allora

$$\hat{\beta}_j \sim N\left(\beta_j, \hat{\sigma}^2_{\hat{\beta}_j}\right)$$

in cui

$$\hat{\sigma}^2_{\hat{\beta}_j} = \frac{\hat{\sigma}^2}{\sum_{i=1}^n (X_{i,j} - \bar{X}_j)^2 (1 - R_j^2)}, \qquad \hat{\sigma}^2 = \frac{1}{n-k-1} \sum_{i=1}^n \hat{\epsilon}_i^2$$

e R_j^2 è il coefficiente di bontà di adattamento calcolato dalla regressione di X_j su tutte le altre variabili indipendenti. (Con k regressori più l'intercetta i gradi di libertà sono $n-k-1$, come nell'output Stata: $420 - 2 - 1 = 417$; le slide scrivono $n-k$, valido solo se k conta anche l'intercetta. La formula della varianza vale sotto omoschedasticità.) Questo risultato consente di effettuare test di ipotesi su β_j e di costruire intervalli di confidenza.

La varianza di $\hat{\beta}_j$. L'errore standard di $\hat{\beta}_j$ è

$$\hat{\sigma}_{\hat{\beta}_j} = \sqrt{\frac{\hat{\sigma}^2}{\sum_{i=1}^{n}(X_{i,j} - \bar{X}_j)^2(1 - R_j^2)}}$$

- Valori grandi di σ^2 rendono grande l'errore standard (nota: questa grandezza non dipende dalla dimensione del campione n);
- Valori grandi di $\sum_{i=1}^{n}(X_{ji} - \bar{X}_j)^2$ rendono piccolo l'errore standard. Cioè, maggiore è la variabilità di X_j, minore è l'errore standard;
- Inoltre, maggiore è la dimensione del campione n, minore è l'errore standard;
- Alta correlazione tra regressori (quasi collinearità) implica un errore standard grande. Nel caso di perfetta collinearità, $R_j^2 = 1 \Rightarrow \hat{\sigma}_{\hat{\beta}} \to +\infty$.

(slide 39–40)

3.12. Intervalli di confidenza per βj

Definizione 3.5. Come per la media campionaria, è utile fornire un intervallo di valori plausibili in cui riteniamo che il vero parametro β cada con alta probabilità (nel senso dei campioni ripetuti: una quota $1 - \alpha$ degli intervalli così costruiti contiene il vero valore). Si noti che anche $\hat{\beta}_j$ è normalmente distribuita.

Per questo valgono ancora tutti i risultati validi per la media campionaria. Un intervallo di confidenza per β_j può quindi essere calcolato come

$$\text{Intervallo di confidenza} = \left[\hat{\beta}_j - z_{\alpha/2} \times \hat{\sigma}_{\hat{\beta}_j} \; ; \; \hat{\beta}_j + z_{\alpha/2} \times \hat{\sigma}_{\hat{\beta}_j}\right]$$

Esempio: intervalli di confidenza per scores vs. income and class size. Nell'esempio del performance vs. class size e reddito, l'intervallo di confidenza al 95% per β_1 e β_2 è calcolato come

$$C.I.(\beta_1) \equiv [-0.6487 - 1.96 \times 0.3544 \; ; \; -0.6487 + 1.96 \times 0.3544] = [-1.343; \, 0.046]$$

$$C.I.(\beta_2) \equiv [1.8391 - 1.96 \times 0.0928 \; ; \; 1.8391 + 1.96 \times 0.0928] = [1.657; \, 2.021]$$

(Le slide riportano $[-1.345; \, 0.047]$ e $[1.656; \, 2.021]$ con coefficienti ed errori standard arrotondati, ma con quei valori e 1.96 il calcolo non dà quei risultati: sono, a meno di arrotondamenti, gli intervalli dell'output, ottenuti da Stata con il quantile $t_{417;\,0.975} \approx 1.966$ al posto di 1.96.)

	Coef.	Std. Err.	t	P>|t|	[95% Conf.	Interval]
str	-.6487401	.354405	-1.83	0.068	-1.345383	.0479028
avginc	1.839112	.0927868	19.82	0.000	1.656724	2.0215
_cons	638.7292	7.449077	85.75	0.000	624.0867	653.3716

Coef.	Std. Err.	t	P>|t|	[95% Conf.	Interval]

(slide 41–42)

3.13. Verifica d'ipotesi per βj

Teorema 3.5. Potremmo chiederci se X_1 o X_2 siano predittori utili, nel senso che hanno un impatto sul valore atteso di Y. Si ricordi che

$$\Delta\hat{Y} = \beta_j \Delta X_j.$$

Se β_j fosse 0, allora qualunque sia la variazione di X_j, la variazione attesa di Y prevista dal modello sarebbe nulla. Diventa quindi naturale verificare se β_j è sufficientemente vicino a 0.

In generale, potremmo essere interessati a verificare se l'evidenza empirica è **coerente** con qualche valore specifico del parametro. Si noti che $\hat{\beta}_j$ è distribuito secondo una variabile casuale gaussiana. Quindi la procedura di test può basarsi esattamente sugli stessi risultati forniti per la regressione semplice.

Per verificare $H_0 : \beta_j = 0$ rispetto all'alternativa $H_a : \beta_j \neq 0$, la statistica t è

$$t = \frac{\hat{\beta}_j - 0}{\hat{\sigma}_{\hat{\beta}_j}}$$

Il p-value si calcola come al solito.

Esempio. Nel punteggio medio vs. dimensione della classe e reddito, per il sistema di ipotesi $H_0 : \beta_1 = 0$ vs. $H_a : \beta_1 \neq 0$, la statistica t osservata è

$$t^{obs} = \frac{-.6487401 - 0}{.354405} = -1.83$$

e il p-value è calcolato come $2P_{H_0}(|t| > t^{oss}) = 0.068$. Ciò significa che a un livello del 5% non rifiutiamo l'ipotesi nulla e quindi questo parametro non è considerato statisticamente diverso da 0. Quindi, secondo questo modello, la dimensione della classe non risulta statisticamente significativa al 5% (lo sarebbe al 10%, coerentemente con «debolmente significativa» dell'esempio precedente; il mancato rifiuto di H_0 non prova che l'effetto sia nullo).

Per il sistema di ipotesi $H_0 : \beta_2 = 0$ vs. $H_a : \beta_2 \neq 0$ la statistica t osservata è

$$t^{obs} = \frac{1.839112 - 0}{.0927868} = 19.82$$

e il p-value calcolato è $2P_{H_0}(|t| > t^{obs}) \approx 0$. Ciò significa che al livello dell'1% (e anche al 5%) rifiutiamo l'ipotesi nulla: il reddito è un predittore statisticamente significativo.

(slide 43–44)

3.14. Il teorema di Gauss-Markov

Teorema 3.6. Un risultato importante può essere enunciato come segue. Se sono soddisfatte le seguenti ipotesi (a cui si aggiunge l'assenza di perfetta collinearità, vista sopra, senza la quale OLS non è definito):

- **Linearità**: nel modello sulla popolazione, la variabile dipendente Y è correlata alle variabili indipendenti $X_1, \dots, X_k$ e all'errore ϵ, come

$$Y = \alpha + \beta_1 X_1 + \dots + \beta_k X_k + \epsilon$$

- **Esogenità**: l'errore ϵ ha un valore atteso condizionato pari a zero per qualsiasi valore delle variabili esplicative. In altre parole, $E(\epsilon|X) = 0$.
- **Omoschedasticità**: $\text{Var}(Y|X_1, \dots, X_k) = \sigma^2$;
- **Campionamento casuale**: i dati sono ottenuti da un campione casuale di dimensione n, $(X_{1,i}, \dots, X_{k,i}, Y_i)$, $i = 1, \dots, n$.

Allora, OLS fornisce il **miglior stimatore lineare non distorto (BLUE)**, che è il più efficiente (con varianza minore) nella classe degli stimatori lineari e non distorti.

(slide 45–46)

3.15. Rappresentazione matriciale del modello

Definizione 3.6. La rappresentazione matriciale descrive un modello di regressione in modo compatto.

Definiamo la matrice dei regressori come

$$\mathbf{X}_{n\times(k+1)} = \begin{pmatrix} 1 & X_{11} & X_{12} & \dots & X_{1k} \\ 1 & X_{21} & X_{22} & \dots & X_{2k} \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ 1 & X_{n1} & \dots & \dots & X_{nk} \end{pmatrix}$$

X_{ij} è l'osservazione corrispondente al j-esimo regressore relativo all'i-esimo soggetto. La prima colonna rappresenta un regressore associato all'intercetta α.

Il vettore $\mathbf{Y}$ di dimensione $n \times 1$ (n righe e 1 colonna) raccoglie tutte le osservazioni relative alla variabile dipendente

$$\mathbf{Y}_{n\times 1} = \begin{pmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{pmatrix}$$

Il vettore β di dimensione $k+1$ raccoglie tutti i parametri associati ai k regressori $\beta_1, \dots, \beta_k$ e l'intercetta α.

$$\beta_{(k+1)\times 1} = \begin{pmatrix} \alpha \\ \beta_1 \\ \vdots \\ \beta_k \end{pmatrix}$$

Il vettore ϵ di dimensione $n \times 1$ include gli errori per ciascun soggetto

$$\epsilon_{n\times 1} = \begin{pmatrix} \epsilon_1 \\ \epsilon_2 \\ \vdots \\ \epsilon_n \end{pmatrix}$$

Il modello di regressione si scrive quindi come:

$$\begin{pmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{pmatrix} = \begin{pmatrix} 1 & X_{11} & X_{12} & \dots & X_{1k} \\ 1 & X_{21} & X_{22} & \dots & X_{2k} \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ 1 & X_{n1} & \dots & \dots & X_{nk} \end{pmatrix} \begin{pmatrix} \alpha \\ \beta_1 \\ \vdots \\ \beta_k \end{pmatrix} + \begin{pmatrix} \epsilon_1 \\ \epsilon_2 \\ \vdots \\ \epsilon_n \end{pmatrix}$$

… ed in forma compatta con

$$\mathbf{Y} = \mathbf{X}\beta + \epsilon$$

(slide 47–50)

3.16. OLS in notazione matriciale

Dimostrazione. OLS può essere scritto tramite la funzione quadratica

$$S(\alpha, \beta_1, \dots, \beta_k) = (\mathbf{Y} - \mathbf{X}\beta)'(\mathbf{Y} - \mathbf{X}\beta) = \epsilon'\epsilon = \sum_{i=1}^{n} \epsilon_i^2$$

I coefficienti β possono essere stimati, come al solito, minimizzando $\epsilon'\epsilon \approx n\text{Var}(\epsilon)$, cioè

$$\min_{\alpha,\beta_1,\dots,\beta_k} S(\alpha,\beta_1,\dots,\beta_k) = \min_{\beta} S(\beta)$$

Uguagliando a 0 le derivate prime rispetto a β si ottiene

$$\frac{\partial S}{\partial \beta} = -2\mathbf{X}'\mathbf{Y} + 2\mathbf{X}'\mathbf{X}\beta = 0$$

(Le slide omettono il fattore 2, che non cambia la soluzione.)

Gli stimatori OLS possono essere ottenuti come

$$\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y}$$

□

(slide 51)

3.17. Il teorema di Frisch-Waugh-Lovell (versione generale, matriciale)

Teorema 3.7. Consideriamo il seguente modello di regressione

$$\mathbf{Y} = \beta_1\mathbf{X}^1 + \beta_2\mathbf{X}^2 + \epsilon$$

in cui $\mathbf{X}^1$ e $\mathbf{X}^2$ sono sottoinsiemi dei regressori tali che $\mathbf{X} = [\mathbf{X}^1, \mathbf{X}^2]$ e il vettore dei parametri β viene diviso di conseguenza in due parti, ovvero $\beta = (\beta_1, \beta_2)$.

Il modello di regressione può quindi essere scritto come

$$\mathbf{Y} = [\mathbf{X}^1, \mathbf{X}^2]\begin{pmatrix}\beta_1 \\ \beta_2\end{pmatrix} + \epsilon$$

Il **teorema di Frisch-Waugh-Lovell** afferma che gli stimatori OLS per il vettore dei parametri β_1 possono essere calcolati come:

(a) Si regredisce $\mathbf{Y}$ su $\mathbf{X}^2$ e si ottiene il residuo $\hat{\epsilon}_y$.
(b) Quindi si regredisce **ogni** regressore in $\mathbf{X}^1$ su **tutti** i regressori in $\mathbf{X}^2$ per ottenere i residui $\hat{u}$.
(c) Infine, regredendo $\hat{\epsilon}_y$ su $\hat{u}$ si ottiene $\hat{\beta}_1$.

Stessi risultati si possono ottenere per $\hat{\beta}_2$.

(slide 52–53)

4 | Test F per le restrizioni multiple

Fonte: ECON_Teoria_04_Test-F-Restrizioni-Multiple.pdf — *18 slide*

4.1. Esempio introduttivo: differenze salariali tra gruppi

Esempio 4.1. Consideriamo il seguente modello di regressione:

$$\log(wage) = \alpha + \beta_1 educ + \beta_2 exper + \beta_3 tenure + \beta_4 south + \beta_5 urban + \beta_6 marr_black + \beta_7 single_black + \beta_8 marr_nonblack + \beta_9 single_nonblack + \epsilon$$

Ci sono 4 variabili dummy che suddividono il campione in 4 gruppi diversi e non sovrapposti. In particolare, definiamo *married_black*, *single_black*, *married_nonblack* e *single_nonblack* per distinguere lo stato civile insieme alla razza.

Siamo interessati a valutare se i lavoratori sposati e di colore e sposati non di colore ricevono, in media, la stessa quantità di denaro.

Le stime OLS (comando: `reg lwage educ exper tenure south urban marr_black single_black marr_nonblack single_nonblack`) sono:

lwage	Coef.	Std. Err.	t	P>|t|	[95% Conf. Interval]
educ	.0654751	.006253	10.47	0.000	.0532034 .0777469
exper	.0141462	.003191	4.43	0.000	.0078837 .0204087
tenure	.0116628	.0024579	4.74	0.000	.006839 .0164866
south	-.0919894	.0263212	-3.49	0.000	-.1436455 -.0403333
urban	.1843501	.0269778	6.83	0.000	.1314053 .2372948
marr_black	.2502685	.0940889	2.66	0.008	.0656162 .4349208
single_black	(dropped)				
marr_nonbl~k	.4297348	.0880447	4.88	0.000	.2569445 .6025251
single_non~k	.2408201	.0960229	2.51	0.012	.0523724 .4292678
_cons	5.162973	.1359471	37.98	0.000	4.896173 5.429773

(*single_black* viene escluso automaticamente dal software ("dropped") perché le quattro dummy di gruppo sommano a 1 e sono quindi perfettamente collineari con la costante (trappola delle variabili dummy); la dummy esclusa diventa la categoria di riferimento rispetto alla quale si interpretano le altre tre.)

I salari medi attesi per ogni gruppo, condizionati sulle altre variabili, sono:

- Se $married = 1$ e $black = 1$, cioè $marr_black = 1$:

$$E[lwage|X] = \alpha + \beta_1 educ + \cdots + \beta_6 \times 1 + \beta_8 \times 0 + \beta_9 \times 0$$

- Se $married = 1$ e $black = 0$, cioè $marr_nonblack = 1$:

$$E[lwage|X] = \alpha + \beta_1 educ + \cdots + \beta_6 \times 0 + \beta_8 \times 1 + \beta_9 \times 0$$

- Se $married = 0$ e $black = 1$, cioè $single_black = 1$:

$$E[lwage|X] = \alpha + \beta_1 educ + \cdots + \beta_6 \times 0 + \beta_8 \times 0 + \beta_9 \times 0$$

- Se $married = 0$ e $black = 0$, cioè $single_nonblack = 1$:

$$E[lwage|X] = \alpha + \beta_1 educ + \cdots + \beta_6 \times 0 + \beta_8 \times 0 + \beta_9 \times 1$$

(Le espressioni precedenti pongono $\beta_7 = 0$: *single_black* è la dummy esclusa, quindi per questo gruppo non compare alcun termine dummy.)

Sulla base del modello, tra le persone sposate, la differenza salariale causata dalla razza è rappresentata da:

$$E[lwage|married_black = 1] - E[lwage|married_nonblack = 1] = \beta_6 - \beta_8 = .2502685 - .4297348$$

È possibile verificare se questa differenza è statisticamente significativa? Una possibile soluzione è calcolare la seguente statistica t:

$$t = \frac{\hat{\beta}_6 - \hat{\beta}_8 - 0}{\text{st.err.}\left(\hat{\beta}_6 - \hat{\beta}_8\right)}$$

Sfortunatamente non è sempre immediato valutare il denominatore, cioè lo standard error di una combinazione lineare di stimatori correlati. Serve quindi una strategia più generale per questo tipo di test: il test F, sviluppato nelle sezioni seguenti.

(slide 2–5)

4.2. Perché un test t ripetuto non è una soluzione valida per ipotesi congiunte

Dimostrazione. **Esempio motivante: test di significatività congiunta.** Consideriamo un modello di regressione multipla

$$Y = \alpha + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \epsilon$$

e vogliamo testare se X_1, X_2 e X_3, congiuntamente, sono predittori utili per Y. Vogliamo cioè valutare l'ipotesi congiunta

$$H_0 : \beta_1 = \beta_2 = \beta_3 = 0 \quad \text{contro} \quad H_1 : \text{almeno un } \beta_j \neq 0,\ j = 1, 2, 3.$$

Se H_0 è vera, i tre regressori sono inutili per predire Y e la regressione si riduce a

$$Y = \alpha + \epsilon$$

(il *modello ristretto*). Serve una strategia che permetta di confrontare questo modello ristretto con il *modello completo*.

Un primo tentativo (naïve): ripetere il test t tre volte. La strategia consiste nel:

1. Calcolare tre statistiche t, cioè t_1, t_2 e t_3, per le ipotesi $H_0^{(1)} : \beta_1 = 0$, $H_0^{(2)} : \beta_2 = 0$ e $H_0^{(3)} : \beta_3 = 0$, contro l'alternativa bilaterale.
2. Decidere secondo lo schema seguente:
   - Se non rigettiamo tutte e tre le ipotesi nulle, non rigettiamo neanche l'ipotesi congiunta $H_0 : \beta_1 = \beta_2 = \beta_3 = 0$.
   - Se rigettiamo almeno una delle tre ipotesi, rigettiamo anche $H_0 : \beta_1 = \beta_2 = \beta_3 = 0$.

Questa strategia può portare a risultati errati. Se l'ipotesi nulla è vera, la probabilità di non rigettarla in un singolo test è $1 - 0.05$ quando $\alpha = 0.05$. Supponendo (per semplicità algebrica, anche se non è un'ipotesi credibile) che t_1, t_2 e t_3 siano test indipendenti, e ricordando che per tre eventi indipendenti A, B, C vale $P(A, B, C) = P(A)P(B)P(C)$, la probabilità di non rigettare congiuntamente le tre ipotesi nulle è

$$0.95 \times 0.95 \times 0.95 = 0.8574$$

L'errore di Tipo I del test congiunto, cioè la probabilità di rigettare l'ipotesi nulla quando è corretta, è quindi

$$1 - 0.8574 = 0.1426 \neq 0.05$$

ossia la probabilità di rigettare erroneamente l'ipotesi nulla è circa $3 \times \alpha$. Con la strategia naïve, quindi, si perde il controllo sul vero livello di significatività del test. □

(slide 6–8)

4.3. Restrizioni lineari: definizione generale

Definizione 4.1. I due esempi precedenti coinvolgono entrambi **restrizioni lineari** sui parametri, cioè vincoli del tipo

$$r_1\beta_1 + r_2\beta_2 + \cdots + r_{k-1}\beta_{k-1} + r_k\beta_k = q$$

dove $r_1, \ldots, r_k$ e q sono costanti note.

- Nel primo esempio (differenze salariali) questo è immediato: consideriamo $\beta_6 - \beta_8 = 0$, con $r_6 = 1$, $r_8 = -1$, tutti gli altri $r_i = 0$ e $q = 0$. Si tratta di un'unica combinazione lineare, cioè **1 restrizione**.
- Anche il secondo esempio (test di significatività congiunta) coinvolge restrizioni lineari particolari: ogni $\beta_j = 0$ è una combinazione lineare in cui tutti i pesi $r_i = 0$ per $i \neq j$, mentre $r_j = 1$ e $q = 0$. In questo caso ci sono **3 diverse combinazioni lineari** che devono essere soddisfatte congiuntamente (3 restrizioni).

Il **test F** consente di valutare in un unico passo se una o più restrizioni lineari sono coerenti con le evidenze empiriche.

(slide 9)

4.4. Costruzione del test F: modello completo vs modello ristretto

Un test su parametri multipli si può implementare con la **statistica F**.

Siano R_c^2 e R_r^2 gli indicatori di bontà di adattamento (R^2) rispettivamente del modello *completo* e del modello *ristretto*:

- il **modello ristretto** è quello in cui si ipotizza che l'ipotesi nulla sui parametri sia valida;
- il **modello completo** è il modello di regressione originale (non vincolato).

Se l'ipotesi alternativa fosse corretta, ci si aspetta che la capacità predittiva del modello completo sia superiore a quella del modello ristretto (che è vincolato). In particolare, la differenza tra i due R^2 sarà grande. Il test F studia quindi il comportamento della quantità $(R_c^2 - R_r^2)$.

(slide 10)

4.5. La statistica F: definizione

Definizione 4.2. Il test F è definito come

$$F_{s;\,n-k-1} = \frac{(R_c^2 - R_r^2)/s}{(1 - R_c^2)/(n-k-1)}$$

dove:

- s è il numero di vincoli sotto l'ipotesi nulla (nell'esempio di significatività congiunta è 3, poiché si ipotizza $\beta_1 = 0$, $\beta_2 = 0$ e $\beta_3 = 0$);
- k è il numero totale di regressori nel modello completo (nell'esempio è 3);
- n è la dimensione del campione.

La forma in termini di R^2 è valida solo se modello completo e modello ristretto hanno la stessa variabile dipendente, come negli esempi di questa nota; altrimenti si usano le somme dei quadrati dei residui dei due modelli.

(slide 11)

4.6. Proprietà del test F, regola di decisione e p-value

Teorema 4.1. Si può dimostrare che la statistica F ha le seguenti proprietà:

- **È sempre positiva.** Infatti si può dimostrare che R^2 è sempre non decrescente quando si aggiungono regressori (quindi $R^2_c \geq R^2_r$).
- **I valori di F vicini a 0 sono più favorevoli a H_0 che a H_1.** Ciò implica che si respinge l'ipotesi nulla solo quando F è grande: si tratta di un **test unilaterale**. In pratica si calcola la statistica F osservata, F^{oss}, e il p-value viene calcolato come $P(F > F^{oss})$. Se il p-value è più piccolo del livello α, si respinge l'ipotesi nulla; altrimenti non c'è sufficiente evidenza per respingerla.
- **Se l'ipotesi nulla è corretta**, allora la distribuzione di F è ben approssimata da una variabile casuale F con s e $n-k-1$ gradi di libertà (parametri). Per questa distribuzione sono disponibili tabelle.

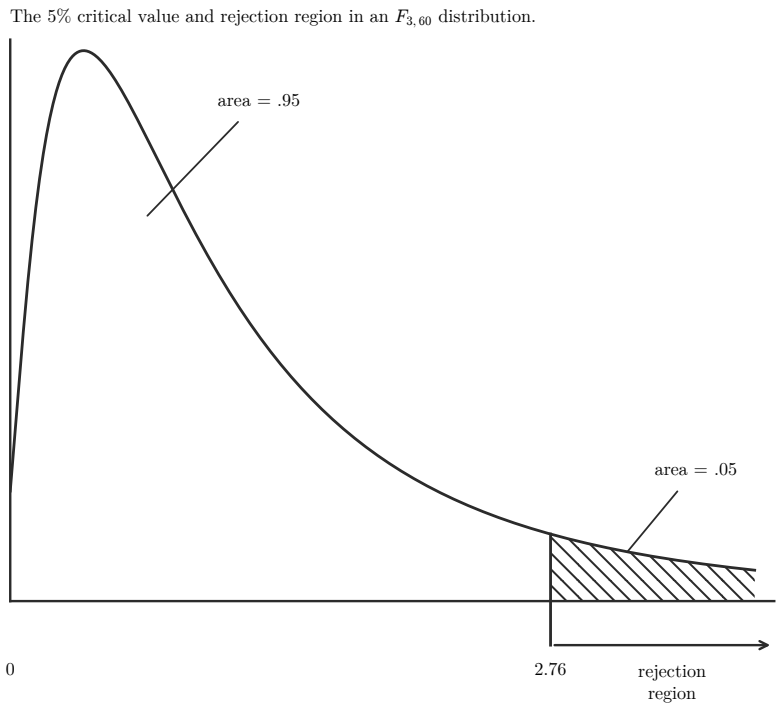


Figura 1 — Rappresentazione grafica della variabile casuale F. Il grafico (*"The 5% critical value and rejection region in an $F_{3,60}$ distribution"*) mostra la densità di una distribuzione F asimmetrica a destra: l'area fino al valore critico 2.76 è il 95% della probabilità ("area = .95"), l'area a destra di 2.76 ("area = .05", la *rejection region*) è il livello di significatività del 5%. Se la statistica F osservata cade in questa regione, si respinge l'ipotesi nulla.

Regola di decisione con il valore critico. Come al solito si può definire il livello α e calcolare il valore critico utilizzando tabelle F adeguate:

- se F^{oss} è più grande del livello critico, si respinge l'ipotesi nulla;
- se F^{oss} è più piccolo del livello critico, non c'è sufficiente evidenza per respingere l'ipotesi nulla.

Regola di decisione con il p-value. Si può calcolare anche il p-value, cioè $P_{H_0}(F > F^{oss})$: se il p-value è più piccolo di α (in percentuale), si respinge l'ipotesi nulla, altrimenti non la si può respingere.

(slide 12–14)

4.7. Relazione tra la distribuzione F e la distribuzione chi-quadro

Si noti che $k_1 F(k_1, k_2)$ è ben approssimata da una variabile $\chi^2_{k_1}$, cioè $F(k_1, k_2) \approx \chi^2_{k_1}/k_1$, se k_2 è sufficientemente grande (le slide scrivono $F(k_1, k_2) \approx \chi^2_{k_1}$, omettendo la divisione per k_1, che vale 1 solo per $k_1 = 1$). Questo accade quando n è grande, visto che $F \sim F_{s;\, n-k-1}$ (e quindi $k_2 = n - k - 1$ cresce con la numerosità campionaria).

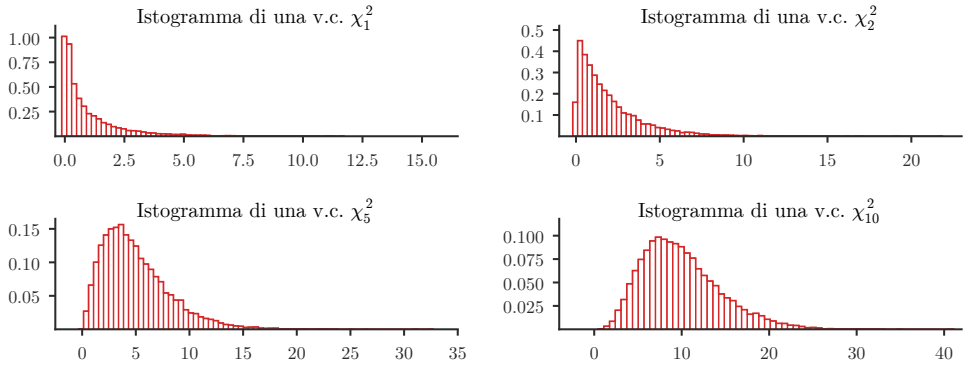


Figura 2 — χ^2_{df} con diversi gradi di libertà, cioè $df = 1, 2, 5, 10$. Il pannello mostra quattro istogrammi di variabili casuali chi-quadro simulate con 1, 2, 5 e 10 gradi di libertà: per $df = 1$ la densità è concentrata vicino allo zero e decrescente; al crescere dei gradi di libertà la distribuzione si sposta a destra, si allarga e diventa più simmetrica e campanulare. È la forma della χ^2_{df}, cioè della distribuzione limite di $s\,F$ con $df = s$ quando i gradi di libertà al denominatore sono grandi. *(slide 15)*

4.8. Esempio: dimensione della classe e reddito rispetto al punteggio del test

Esempio 4.2. Supponiamo di voler testare se `str` (dimensione della classe) e `avginc` (reddito medio) sono predittori utili per il punteggio del test. Il modello completo è

$$avg_score = \alpha + \beta_1\, str + \beta_2\, avginc + \epsilon$$

L'ipotesi nulla è quindi $H_0 : \beta_1 = \beta_2 = 0$ contro l'alternativa che almeno uno di questi due parametri sia diverso da 0.

Non è banale calcolare a mano la statistica F osservata, perché servono vari passaggi: stimare i due modelli (completo e ristretto), calcolare i loro indicatori di bontà di adattamento R^2, e valutare la statistica F osservata, cioè F^{oss}. Di solito i test F vengono calcolati tramite software statistici/econometrici.

Procedura con Gretl:

a. Si stimi la regressione completa.
b. Dall'output della regressione si utilizzi il menu *Test -> Vincoli lineari*.
c. Si definisca il test come segue:

```
b[str] = 0
b[avginc] = 0
```

L'output è riportato di seguito:

```
Insieme di vincoli
```

```
 1: b[str] = 0
 2: b[avginc] = 0

Statistica test: F(2, 417) = 218,302, con p-value = 1,3533e-65
```

In questo caso si respinge l'ipotesi nulla poiché il p-value è prossimo a 0. Ciò significa che almeno uno dei due regressori è un predittore utile per il punteggio medio.

(slide 16–17)

4.9. Esempio: verifica della differenza salariale tra gruppi con il test F

Esempio 4.3. Riprendendo l'esempio delle differenze salariali, per verificare se $\beta_6 - \beta_8 \neq 0$, cioè se la differenza tra lavoratori sposati di colore e sposati non di colore è statisticamente significativa, si implementa il test

$$H_0 : \beta_6 - \beta_8 = 0 \quad \text{vs.} \quad H_1 : \beta_6 - \beta_8 \neq 0$$

In Gretl si procede così:

1. Si stimi la regressione completa (`reg lwage` su `educ exper tenure south urban marr_black single_black marr_nonblack single_nonblack`; `reg` è la sintassi di Stata usata per la tabella, in Gretl il comando è `ols`).
2. Dall'output della regressione si utilizzi il menu *Test -> Vincoli lineari*.
3. Si definisca il test come segue:

```
b[marr_black] - b[marr_nonblack] = 0
```

L'output è riportato di seguito:

```
Insieme di vincoli
 1: b[marr_black] - b[marr_nonblack] = 0

Statistica test: F(1, 926) = 19,60, con p-value = 0.000
```

Il p-value è praticamente nullo (circa 0,00001, riportato come 0.000). In altre parole, la differenza tra i due gruppi (lavoratori sposati di colore vs. sposati non di colore) è significativamente diversa da 0. Il test F risponde così, con uno strumento generale, alla domanda dell'esempio introduttivo, senza passare dal calcolo diretto della statistica t per la combinazione $\hat{\beta}_6 - \hat{\beta}_8$.

(slide 18)

5 | L'ipotesi di Eteroschedasticità

Fonte: ECON_Teoria_05_Eteroschedasticita.pdf — *36 slide*

5.1. Introduzione e struttura della lezione

Corso: *Econometrics*, lezione **L'ipotesi di Eteroschedasticità**, tenuta da Davide Raggi, 25 novembre 2025.

Argomenti trattati nella lezione:

- L'ipotesi di omoschedasticità
- Soluzioni per l'eteroschedasticità
- Stimatori Robusti
- Test robusti (t ed F)
- Test per l'eteroschedasticità

(slide 1–2)

5.2. L'ipotesi di omoschedasticità

Definizione 5.1.

- L'ipotesi di omoschedasticità **non è necessaria** per dimostrare la non distorsione e la consistenza di $\hat{\beta}_j$.
- Tuttavia, per dimostrare il **teorema di Gauss-Markov**, si assume che le varianze condizionali di ϵ_i siano costanti:

$$\mathrm{Var}(\epsilon_i | X_{1i}, \dots, X_{ki}) = \sigma^2 \qquad \forall i$$

- In base a questa ipotesi, gli stimatori OLS sono **BLUE** (*Best Linear Unbiased Estimator*), ovvero quelli con la minore deviazione standard (migliori) nella classe degli stimatori lineari e non distorti.
- Domanda aperta: possiamo chiederci se/perché questa ipotesi sia rilevante per scopi pratici, e quali siano le conseguenze della sua violazione.

(slide 3)

5.3. Standard error nel modello semplice e conseguenze dell'eteroschedasticità

Richiamo. Nel modello di regressione semplice, l'ipotesi di omoschedasticità è stata utilizzata per calcolare le deviazioni standard degli stimatori. In particolare, le deviazioni standard di $\hat{\beta}$ e $\hat{\alpha}$ sono:

$$\hat{\sigma}_{\hat{\beta}} = \sqrt{\frac{\hat{\sigma}^2}{\sum_{i=1}^{n}(X_i - \bar{X})^2}}$$

$$\hat{\sigma}_{\hat{\alpha}} = \sqrt{\frac{\hat{\sigma}^2\left(\frac{1}{n}\sum_{i=1}^{n} X_i^2\right)}{\sum_{i=1}^{n}(X_i - \bar{X})^2}}$$

Domanda: questi stimatori per $\sigma_{\hat{\alpha}}$ e $\sigma_{\hat{\beta}}$ sono ancora affidabili nel caso in cui l'ipotesi di omoschedasticità non sia verificata?

Conseguenze della violazione.

- Si può dimostrare che sotto l'ipotesi di eteroschedasticità, gli stimatori della deviazione standard **non sono consistenti** e quindi forniscono una scarsa approssimazione alla vera deviazione standard.
- Una stima inaccurata di $\sigma_{\hat{\beta}}$ può portare al calcolo di statistiche t non affidabili (poiché $\sigma_{\hat{\beta}}$ è il denominatore di t). In particolare, una stima distorta della deviazione standard influirà probabilmente sui risultati inferenziali.
- I test di ipotesi e gli intervalli di confidenza saranno quindi fortemente influenzati dall'ipotesi che facciamo sulla varianza condizionale. È quindi naturale cercare stimatori ragionevoli per $\sigma_{\hat{\beta}}$ che siano coerenti anche con l'ipotesi di eteroschedasticità.

(slide 4–5)

5.4. Esempio: modello di regressione multipla sul prezzo delle case

Esempio 5.1. Si consideri un modello di regressione in cui il prezzo di alcune case (*price*) viene spiegato attraverso alcune variabili: la dimensione (*sqrft*), la dimensione del lotto (*lotsize*), il numero di stanze (*bdrms*). I dati sono raccolti in `hprices.gdt`.

Una delle principali ipotesi per la regressione stimata con OLS è l'omogeneità della varianza degli errori. Se il modello è ben definito, ci si aspetta che non emerga alcun pattern chiaro tra i residui e i valori predetti dal modello. Esistono metodi grafici e non grafici per rilevare l'eteroschedasticità. Un metodo grafico comunemente usato è rappresentare graficamente i residui (o i residui al quadrato) rispetto ai valori predetti (o ai singoli regressori).

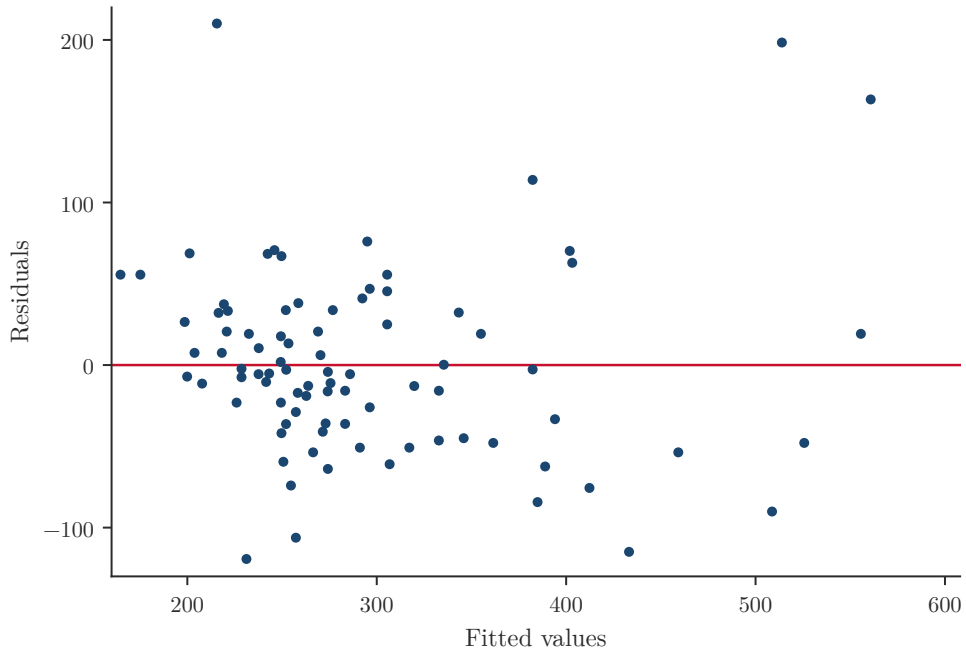


Figura 1 — Residui vs. valori adattati $\hat{\epsilon}$ vs. $\hat{Y}$. Lo scatterplot (residui tra circa -120 e 210, valori adattati tra circa 165 e 560) mostra che la dispersione dei residui non è costante: per valori elevati di $\hat{Y} = X\hat{\beta}$ la variabilità dei residui sembra aumentare, e sono presenti pochi residui estremi. In generale, questo grafico è usato per rilevare la non linearità, varianze degli errori non uguali e la presenza di outlier.

Dalla Figura 1 si evince che:

- I residui rimbalzano casualmente intorno alla linea 0 (media dei residui stessi). Ciò suggerisce che l'ipotesi di relazione lineare è ragionevole.
- I residui **non** formano approssimativamente una banda orizzontale intorno allo 0: per valori elevati di $\hat{Y}$ la dispersione/variabilità dei residui aumenta (**eteroschedasticità**).
- Pochi residui risultano estremi rispetto agli altri: questo accade solo per prezzi predetti maggiori di 500 e per una casa il cui residuo sfiora 200 pur avendo un prezzo predetto poco superiore a 200K dollari (il prezzo osservato è 425K).

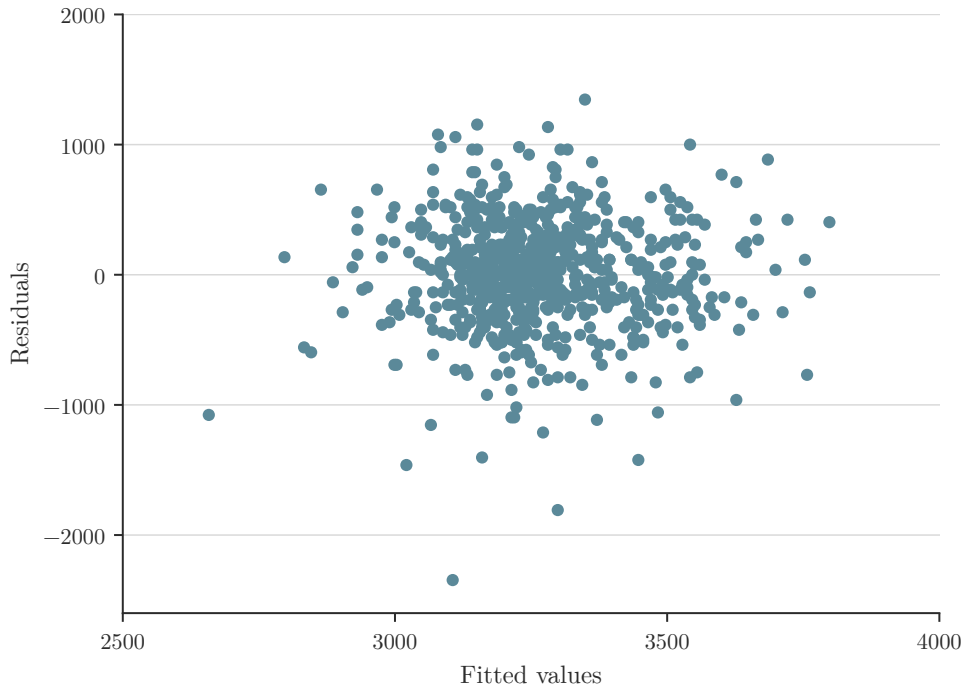


Figura 2 — Esempio di comportamento corretto di $\hat{\epsilon}$ vs. $\hat{Y}$. Lo scatterplot mostra i residui distribuiti in una banda orizzontale uniforme intorno allo zero su tutto il range dei valori adattati (2500–4000), senza l'allargamento a imbuto osservato in Figura 1: è il comportamento atteso da un modello omoschedastico ragionevole.

Confronto tra due specificazioni. Di seguito viene stimato il modello di regressione utilizzando due formule alternative per il calcolo degli standard error: il primo output riporta le stime OLS con deviazioni standard naïve ("normali"), il secondo fornisce una correzione per un'eventuale eteroschedasticità.

Modello 1 — Deviazioni standard normali:

price	Coef.	Std. Err.	t	P>|t|	[95% Conf.	Interval]
sqrft	.1227782	.0132374	9.28	0.000	.0964541	.1491022
lotsize	.0020677	.0006421	3.22	0.002	.0007908	.0033446
bdrms	13.85252	9.010145	1.54	0.128	-4.065141	31.77018
_cons	-21.77031	29.47504	-0.74	0.462	-80.38466	36.84405

Modello 2 — Correzione per eteroschedasticità:

price	Coef.	Std. Err.	t	P>|t|	[95% Conf.	Interval]
sqrft	.1227782	.0177253	6.93	0.000	.0875294	.158027
lotsize	.0020677	.0012514	1.65	0.102	-.0004209	.0045563
bdrms	13.85252	8.478625	1.63	0.106	-3.008154	30.7132
_cons	-21.77031	37.13821	-0.59	0.559	-95.62371	52.0831

Nelle slide originali la riga di *lotsize* è evidenziata in entrambi i modelli: passando dagli standard error naïve a quelli corretti, il p-value di *lotsize* passa da 0.002 (significativo) a 0.102 (non significativo), un esempio concreto di come la scelta degli standard error possa cambiare le conclusioni inferenziali. Domanda aperta: quale delle due specificazioni risulta più attendibile?

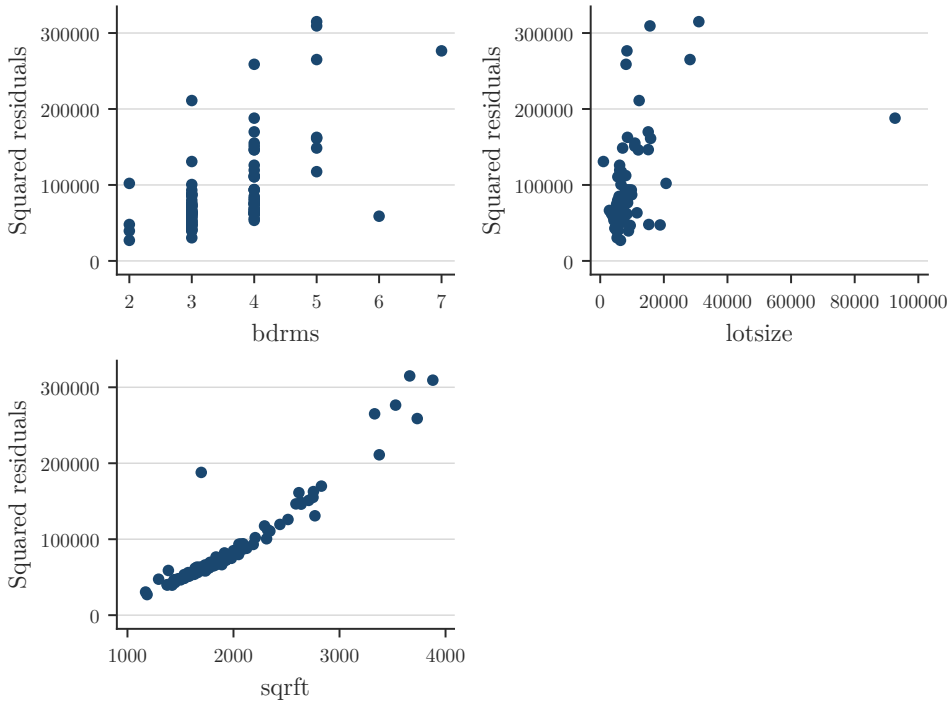


Figura 3 — Residui al quadrato vs. ogni regressore. I tre scatterplot mostrano $\hat{\epsilon}^2$ rispettivamente contro *bdrms* (asse 2–7), *lotsize* (asse 0–100000) e *sqrft* (asse 1000–4000), con i residui al quadrato sull'asse verticale nel range 0–300000 circa. Si osserva una chiara dipendenza crescente tra $\hat{\epsilon}^2$ e, rispettivamente, *bdrms* e *sqrft* (pattern più marcato e quasi lineare per *sqrft*), mentre la dipendenza con *lotsize* è meno netta. (Verifica sui dati HPRICE1: i punti della figura coincidono con i quadrati dei valori adattati $\hat{Y}^2$, non con i residui al quadrato, che arrivano al massimo a circa 43800. Con i veri $\hat{\epsilon}^2$ la dipendenza dai regressori è più debole ma significativa: la regressione di $\hat{\epsilon}^2$ su *sqrft*, *lotsize* e *bdrms* dà $R^2 = 0.160$, $F = 5.34$, p-value 0.002.)

I residui al quadrato, che sono una proxy della varianza condizionale, risultano dipendenti dalle variabili del modello: la varianza sembra quindi dipendere da X, segno di **eteroschedasticità**. In particolare, i residui al quadrato crescono proporzionalmente a *bdrms* e *sqrft*. La varianza condizionale non sembra costante, per cui l'output più credibile è il **Modello 2**, che corregge per l'eteroschedasticità.

(slide 6–12)

5.5. Soluzioni per l'eteroschedasticità: panoramica e Weighted Least Squares (WLS)

Definizione 5.2. Nella letteratura esistono due metodi principali per stimare gli errori standard di $\hat{\beta}_j$ in presenza di eteroschedasticità:

1. **Weighted Least Squares (WLS)** — forse meno utile, si basa su una standardizzazione adeguata del termine di errore ϵ: se $\text{Var}(\epsilon_i|X) = \sigma_i^2 = (\sigma\tilde{\sigma}_i)^2$, si valuta prima $\tilde{\sigma}_i$ per poi dividere ϵ_i per $\tilde{\sigma}_i$.
2. **Stima robusta** — si basa sulla consistenza degli stimatori OLS per ottenere stimatori robusti rispetto all'eteroschedasticità per gli errori standard: si utilizzano gli $\hat{\epsilon}_i$ per valutare la varianza vera di $\hat{\beta}_i$.

Weighted Least Squares. Si consideri la regressione

$$Y_i = \alpha + \beta_1 X_{i1} + \cdots + \beta_k X_{ik} + \epsilon_i$$

Si ipotizzi che $\text{Var}(\epsilon_i|X_1, \dots, X_k) = \sigma_i^2$, dove σ_i^2 dipende da alcuni regressori e da alcuni parametri sconosciuti. Ad esempio, può essere interessante utilizzare

$$\sigma_i^2 = \sigma^2 \exp\{\delta_0 + \delta_1 Z_1 + \cdots + \delta_m Z_m\} = (\sigma\tilde{\sigma}_i)^2$$

dove $Z_1, \dots, Z_m$ sono regressori (che possono coincidere con $X_1, \dots, X_k$).

Se i parametri $\delta_i,\ i = 0, \dots, m$ sono noti, possiamo valutare facilmente σ_i. In questo caso si considera la **regressione ausiliaria**

$$\frac{Y_i}{\tilde{\sigma}_i} = \alpha\frac{1}{\tilde{\sigma}_i} + \beta_1\frac{X_{i1}}{\tilde{\sigma}_i} + \cdots + \beta_k\frac{X_{ik}}{\tilde{\sigma}_i} + \frac{\epsilon_i}{\tilde{\sigma}_i}$$

E quindi il modello di regressione originale diventa

$$Y_i^* = \alpha X_{i0}^* + \beta_1 X_{i1}^* + \cdots + \beta_k X_{ik}^* + \epsilon_i^*$$

In questa versione $\text{Var}(\epsilon_i^*|X) = \sigma^2$ (errori omoschedastici) e quindi gli stimatori OLS forniscono stimatori **BLUE**.

(slide 13–15)

5.6. Feasible Generalized Least Squares (FGLS)

Definizione 5.3. Applicare OLS alla regressione ausiliaria (Y^*) fornisce risultati diversi rispetto agli OLS standard: WLS è un caso speciale del metodo **Generalized Least Squares (GLS)**. Tuttavia, per applicare WLS/GLS è necessario conoscere i coefficienti δ_j, il che in generale non è ovvio. Una possibile soluzione si basa sul **Feasible Generalized Least Squares (FGLS)**, in cui $\tilde{\sigma}_i$ è stimato tramite OLS.

Si ricordi che la media condizionale di Y è

$$E(Y|X) = \alpha + \beta_1 X_1 + \cdots + \beta_k X_k$$

Definiamo un modello che descriva $\text{Var}(Y|X)$. Intuitivamente, possiamo definire questa varianza come

$$\text{Var}(Y|Z_1, \dots, Z_m) = E[\epsilon^2|X] = g(Z_1, \dots, Z_m), \qquad g(\cdot) > 0$$

Un'ipotesi ragionevole, ad esempio, è

$$\epsilon^2 = \sigma^2 \exp\{\delta_0 + \delta_1 Z_1 + \cdots + \delta_m Z_m\}\, \nu$$

Consideriamo dunque il modello completo per le medie e le varianze condizionate (nelle slide manca β_k davanti a X_{ik} nella prima equazione):

$$Y_i = \alpha + \beta_1 X_{i1} + \cdots + \beta_k X_{ik} + \epsilon_i$$

$$\epsilon^2 = \sigma^2 \exp\{\delta_0 + \delta_1 Z_1 + \cdots + \delta_m Z_m\}\, \nu$$

Un procedimento ragionevole per calcolare $\hat{\sigma}_i$ è il seguente:

1. Regredire Y su $X_1, \dots, X_k$ e calcolare $\hat{\epsilon}$;
2. Calcolare $\log(\hat{\epsilon}^2)$;
3. Regredire $\log(\hat{\epsilon}^2)$ su $Z_1, \dots, Z_m$;
4. Calcolare $\hat{g} = \widehat{\log(\hat{\epsilon}^2)}$ e $\hat{\sigma}_i = \exp\{\hat{g}/2\}$;
5. Utilizzare $\hat{\sigma}_i$ per calcolare lo stimatore WLS.

(slide 16–18)

5.7. Stimatori robusti: l'idea di White (Huber-Eicker) nel modello semplice

Dimostrazione. Gli stimatori robusti (metodo di Eicker-Huber-White; nelle slide «Heicker» è un refuso per Eicker) sono un insieme di procedure che permettono di valutare gli standard error in maniera corretta sia in omoschedasticità sia in eteroschedasticità. L'idea parte dal fatto che gli stimatori OLS dei parametri sono consistenti ($\hat{\beta}_j \xrightarrow{p} \beta_j$) e non distorti, **indipendentemente dall'ipotesi che facciamo sulle varianze condizionali**.

Come calcolare gli standard error in presenza di eteroschedasticità? Per semplificare, si consideri il modello di regressione semplice

$$Y = \alpha + \beta X + \epsilon$$

Lo stimatore può essere espresso come funzione di ϵ, come al solito:

$$\hat{\beta} = \beta + \frac{\sum_{i=1}^{n}(X_i - \bar{X})\epsilon_i}{\sum_{i=1}^{n}(X_i - \bar{X})^2}$$

Nel caso di regressione multipla, otteniamo

$$\hat{\beta} = (X'X)^{-1}X' \underbrace{Y}_{=X\beta+\epsilon} = \beta + (X'X)^{-1}X'\epsilon$$

Vera varianza condizionale. Si vuole stimare la vera varianza condizionale di $\hat{\beta}$, cioè

$$\mathrm{Var}(\hat{\beta}|X) = \frac{\sum_{i=1}^{n} \overbrace{\widetilde{\sigma_i^2}}^{\mathrm{Var}(\epsilon_i|X)} (X_i - \bar{X})^2}{\left[\sum_{i=1}^{n}(X_i - \bar{X})^2\right]^2}$$

L'idea di White (1980) è semplice: dato che $\hat{\epsilon}_i$ è un'approssimazione di ϵ_i, allora $\hat{\epsilon}_i^2(X_i - \bar{X})^2$ è uno stimatore ragionevole per $E[\epsilon_i^2(X_i - \bar{X})^2|X] = \sigma_i^2(X_i - \bar{X})^2$. White ha proposto:

$$\widehat{\mathrm{Var}}(\hat{\beta}|X) = \frac{\sum_{i=1}^{n}(X_i - \bar{X})^2\hat{\epsilon}_i^2}{\left[\sum_{i=1}^{n}(X_i - \bar{X})^2\right]^2}$$

… e ha anche dimostrato che $\widehat{\mathrm{Var}}(\hat{\beta}|X)$ è **consistente** per $\mathrm{Var}(\hat{\beta}|X)$.

Intuizione del risultato. Nel modello di regressione semplice:

$$\hat{\epsilon}_i = Y_i - \hat{Y}_i = \underbrace{\alpha + \beta X_i + \epsilon_i}_{Y_i} - \underbrace{(\hat{\alpha} + \hat{\beta}X_i)}_{\hat{Y}_i} = \underbrace{(\alpha - \hat{\alpha})}_{=0 \text{ se } n\to+\infty} + \underbrace{(\beta - \hat{\beta})}_{=0 \text{ se } n\to+\infty} X_i + \epsilon_i$$

Di conseguenza, asintoticamente

$$\frac{1}{n}\sum_{i=1}^{n}\hat{\epsilon}_i^2(X_i - \bar{X})^2 \approx \frac{1}{n}\sum_{i=1}^{n}\epsilon_i^2(X_i - \bar{X})^2$$

Nella pratica, questo risultato serve per trovare uno stimatore consistente di $\mathrm{Var}(\hat{\beta}|X)$: se le due quantità sono equivalenti, lo saranno anche calcolando il limite per $n \to \infty$. Per la legge dei grandi numeri vale che

$$\frac{1}{n}\sum_{i=1}^{n}\epsilon_i^2(X_i - \bar{X})^2 \to E\left[\frac{1}{n}\sum_{i=1}^{n}\epsilon_i^2(X_i - \bar{X})^2\right] = \frac{1}{n}\sum_{i=1}^{n}\sigma_i^2(X_i - \bar{X})^2$$

$$\Rightarrow \frac{1}{n}\sum_{i=1}^{n}\hat{\epsilon}_i^2(X_i - \bar{X})^2 \to \frac{1}{n}\sum_{i=1}^{n}\sigma_i^2(X_i - \bar{X})^2$$

□

(slide 19–23)

5.8. Stimatori robusti: caso di regressione multipla e sintesi

Dimostrazione. Nel caso di regressione multipla

$$Y = \alpha + \beta_1 X_1 + \cdots + \beta_k X_k + \epsilon$$

si può dimostrare che

$$\widehat{\text{Var}}(\hat{\beta}_j|X) = \frac{\sum_{i=1}^n \hat{r}_{ij}^2 \hat{\epsilon}_i^2}{\left[\sum_{i=1}^n \hat{r}_{ij}^2\right]^2} \qquad j = 1, \dots, k$$

in cui $\hat{r}_{ij}$ è una stima del residuo i-esimo ottenuta dalla regressione di X_j su tutti gli altri regressori (nelle slide il denominatore è $\left[\sum_{i=1}^n (X_{ij} - \bar{X}_j)^2\right]^2$, valido solo nella regressione semplice, dove $\hat{r}_i = X_i - \bar{X}$):

$$X_j = \alpha_0 + \alpha_1 X_1 + \cdots + \alpha_{j-1} X_{j-1} + \alpha_{j+1} X_{j+1} + \cdots + \alpha_k X_k + u$$

Usando la notazione matriciale, si consideri la matrice diagonale varianza-covarianza Σ:

$$E[\epsilon\epsilon'] = \Sigma_{n\times n} = \begin{pmatrix} \sigma_1^2 & 0 & \dots & 0 \\ 0 & \sigma_2^2 & 0 & \dots \\ \vdots & \vdots & \vdots & \vdots \\ 0 & \dots & \dots & \sigma_n^2 \end{pmatrix}$$

Si può facilmente dimostrare che

$$\text{Var}(\hat{\beta}|X) = (X'X)^{-1} X' E[\epsilon\epsilon'] X (X'X)^{-1}$$

Come risultato generale, White ha dimostrato che uno stimatore consistente di $\frac{X'\Sigma X}{n}$ è $\frac{X'\hat{\Sigma}X}{n}$, in cui gli elementi diagonali di $\hat{\Sigma}$ sono stimati attraverso $\hat{\sigma}_i^2 = \hat{\epsilon}_i^2$.

Sintesi. Gli stimatori OLS $\hat{\sigma}_{\hat{\beta}_j}$ calcolati sotto l'ipotesi di omoschedasticità non sono adatti quando l'ipotesi non vale. Tuttavia, gli stimatori OLS sono consistenti e non distorti a prescindere, e quindi anche $\hat{\epsilon}$ è una misura ragionevole per ϵ: White-(Huber-Eicker) sfruttano questa proprietà per correggere il calcolo dell'errore standard.

Principali vantaggi:

- Nessuna ipotesi viene fatta sulla varianza condizionale: il metodo funziona in caso di omoschedasticità o di qualsiasi tipo di eteroschedasticità (**flessibilità**);
- OLS è ancora valido (**semplicità d'uso**).

D'altra parte, $\hat{\beta}_j$ **non è più BLUE**. □

(slide 24–26)

5.9. Test robusti all'eteroschedasticità: t e F

Definizione 5.4. Il Test t. Le statistiche t, costruite utilizzando gli errori standard robusti, si calcolano in maniera identica al caso omoschedastico. L'unica differenza è il denominatore, che deve essere calcolato in modo robusto (attraverso la formula di White). Quindi, la statistica t robusta è:

$$t = \frac{\hat{\beta} - \text{valore sotto } H_0}{\text{errore standard robusto}}$$

Il Test F. Il calcolo della versione robusta delle statistiche F è complicato. Tuttavia, molti software consentono di calcolarlo in modo automatico, una volta che gli errori standard sono stati stimati mediante metodi robusti (ad esempio, GRETL, STATA).

(slide 27)

5.10. Test per l'eteroschedasticità: principi generali e Test di Breusch-Pagan

Teorema 5.1. Principi generali. In generale, le procedure robuste sono preferibili, poiché consentono di calcolare i test t ed F senza dover fare alcuna ipotesi su $\text{Var}(Y|X)$. Tuttavia, l'utilizzo degli errori standard robusti in caso di omoschedasticità è inefficiente: lo standard error non è più il minimo. Talvolta può essere utile costruire test per validare l'ipotesi di omoschedasticità: se si rifiutasse questa ipotesi converrebbe implementare procedure robuste, altrimenti può essere utilizzato OLS classico.

IMPORTANTE: tutti i test per verificare l'ipotesi di omoschedasticità (ipotesi nulla) rispetto all'eteroschedasticità (ipotesi alternativa) **non accettano l'ipotesi nulla**, ma al più permettono di rifiutarla. In generale, questi test si basano su una definizione della forma funzionale per l'eteroschedasticità, che viene confrontata con l'ipotesi di omoschedasticità.

Test di Breusch-Pagan. Si consideri il solito modello di regressione multipla

$$Y = \alpha + \beta_1 X_1 + \cdots + \beta_k X_k + \epsilon$$

e si ipotizzi che la varianza condizionata sia

$$E[\epsilon^2|\mathbf{X}] = \delta_0 + \delta_1 X_1 + \cdots + \delta_k X_k$$

che porta al seguente modello di regressione

$$\epsilon^2 = \delta_0 + \delta_1 X_1 + \cdots + \delta_k X_k + u$$

Se tutti i coefficienti fossero nulli, i.e. $\delta_j = 0$, allora

$$H_0 : \text{Var}(\epsilon|X_1, \dots, X_k) = E[\epsilon^2|X_1, \dots, X_k] = \sigma^2$$

L'ipotesi nulla di omoschedasticità può essere verificata attraverso il seguente sistema di ipotesi

$$H_0 : \mathrm{Var}(\epsilon|X) = \sigma^2 \Leftrightarrow H_0 : \delta_1 = \delta_2 = \cdots = \delta_k = 0 \quad \text{vs.} \quad H_1 : \text{almeno un coefficiente non è zero}$$

Questo test è molto simile a un test F. Poiché ϵ^2 non è osservabile, lo si approssima con $\hat{\epsilon}^2$. Il modello ridotto (sotto H_0) è

$$\hat{\epsilon}^2 = \delta_0 + err \Rightarrow R_c^2 = 0$$

La statistica test risulta quindi

$$F_{k,n-k-1} = \frac{R^2_{\hat{\epsilon}^2}/k}{(1 - R^2_{\hat{\epsilon}^2})/(n-k-1)}$$

Questo test può essere calcolato in un modo leggermente diverso, chiamato **test di Breusch-Pagan** per l'eteroschedasticità:

$$T_{BP} = nR^2_{\hat{\epsilon}^2}$$

Rispetto alla statistica F, T_{BP} è approssimativamente distribuito come una χ^2_k.

Esempio (Gretl). Il test di Breusch-Pagan può essere implementato tramite Gretl come segue: si stima la regressione di interesse, poi dalla finestra di output si sceglie il menu `Test -> LMTEST - Eteroschedasticità -> Breusch-Pagan`. L'output finale è:

```
Test di Breusch-Pagan per l'eteroschedasticità -
  Ipotesi nulla: eteroschedasticità non presente
  Statistica test: LM = 30,0227
  con p-value = P(Chi-quadro(3) > 30,0227) = 1,36495e-06
```

In questo caso si rifiuta l'ipotesi nulla di omoschedasticità poiché il p-value è piccolo. (LM = 30,0227 è la statistica originale di Breusch-Pagan, valida con errori normali, che Gretl riporta di default; la versione nR^2 sopra, di Koenker, sugli stessi dati vale circa 14,09 con p-value 0,0028: la conclusione non cambia.)

(slide 28–32)

5.11. Test di White

Teorema 5.2. Probabilmente il test più comune per i dati cross-sectional è dovuto a White, anche se si basa sulla stessa idea del test di Breusch-Pagan. Il test è costruito mediante la regressione del residuo quadratico. Ad esempio, se si considera un modello con $k = 3$ regressori:

$$\hat{\epsilon}^2 = \delta_0 + \delta_1 X_1 + \delta_2 X_2 + \delta_3 X_3 + \delta_4 X_1^2 + \delta_5 X_2^2 + \delta_6 X_3^2 + \delta_7 X_1 X_2 + \delta_8 X_1 X_3 + \delta_9 X_2 X_3 + errore \quad (1)$$

Il test di White per l'eteroschedasticità si basa sulla valutazione dell'ipotesi $H_0 : \delta_1 = \cdots = \delta_9 = 0$, che se rifiutata produce evidenza in favore dell'eteroschedasticità.

Come per il test di Breusch-Pagan, il test di White può essere calcolato come segue:

$$T_W = nR^2_{\hat{\epsilon}^2} \sim \chi^2_{\#\text{vincoli}}$$

in cui $R^2_{\hat{\epsilon}^2}$ è la bontà di adattamento della regressione ausiliaria completa in eq. (1).

Esempio (Gretl). Si consideri l'esempio sul pricing delle case. Il test di White si ottiene stimando la regressione di interesse e scegliendo, dalla finestra di output, il menu `Test -> LMTEST - Eteroschedasticità -> Test di White`. L'output fornito da Gretl è:

```
Test di White per l'eteroschedasticità -
  Ipotesi nulla: eteroschedasticità non presente
  Statistica test: LM = 33,7317
  con p-value = P(Chi-quadro(9) > 33,7317) = 9,95294e-05
```

Anche in questo caso il test rifiuta l'ipotesi nulla di omoschedasticità.

Stima con errori standard robusti in Gretl. Stimare gli errori standard robusti tramite Gretl è facile: è sufficiente, in sede di definizione del modello, spuntare l'opzione *Errori Standard Robusti*. Dato che si rifiuta l'ipotesi nulla, è necessario stimare la regressione OLS mediante errori standard robusti. La procedura robusta restituisce i seguenti risultati (output nel formato di Stata; gli errori standard sono la variante HC1 della formula di White, con fattore $n/(n-k-1)$):

```
Linear regression                               Number of obs =       88
                                                F( 3,     84) =    23.72
                                                Prob > F      =   0.0000
                                                R-squared     =   0.6724
                                                Root MSE      =   59.833
```

price	Coef.	Robust Std. Err.	t	P>|t|	[95% Conf.	Interval]
sqrft	.1227782	.0177253	6.93	0.000	.0875294	.158027
bdrms	13.85252	8.478625	1.63	0.106	-3.008154	30.7132
lotsize	.0020677	.0012514	1.65	0.102	-.0004209	.0045563
_cons	-21.77031	37.13821	-0.59	0.559	-95.62371	52.0831

(slide 33–36)

6 | Introduzione ai Modelli Dinamici

Fonte: ECON_Teoria_06_Modelli-Dinamici.pdf — *108 slide*

6.1. Introduzione alle serie storiche

In econometria si fa largo uso di dati di serie storica, cioè osservazioni su una o più variabili economiche raccolte nel tempo. Gli eventi economici hanno una natura dinamica: il passato contribuisce a determinare, almeno in parte, il presente e, di conseguenza, la componente temporale pesa molto nella spiegazione e nell'interpretazione dei fatti economici. Per questo motivo in econometria sono stati sviluppati diversi modelli dinamici che catturano questo aspetto. I dati di serie storica sono ordinabili in modo oggettivo e universalmente accettato.

Questi dati sono molto diversi dai dati in cross-section: si tratta di dati **dipendenti**, cioè di osservazioni relative a un'unica entità che si protraggono nel tempo. *(slide 2)*

6.2. Definizione di processo stocastico e serie storica

Definizione 6.1. In termini semplicistici, un **processo stocastico** è definito come una sequenza di variabili casuali Y_t indicizzate da un indice t. Nel corso, t appartiene all'insieme dei numeri naturali $(0, 1, \dots, t, \dots)$.

Si assume che ognuna delle osservazioni sia descritta da una variabile casuale Y_t per cui:

- la media marginale di ogni Y_t è $E[Y_t] = \mu_t$;
- la varianza marginale di ogni Y_t è $\text{Var}(Y_t) = \sigma_t^2$;
- l'**autocorrelazione** tra due qualsiasi elementi del processo è

$$\text{Corr}(Y_t, Y_s) = \frac{E[(Y_t - \mu_t)(Y_s - \mu_s)]}{\sqrt{\sigma_t^2 \sigma_s^2}}.$$

Una **serie storica** è una sequenza finita di variabili casuali in cui l'indice $t = 1, \dots, T$ indica il tempo. Spesso con "serie storica" si intende anche la traiettoria osservata del processo stocastico.

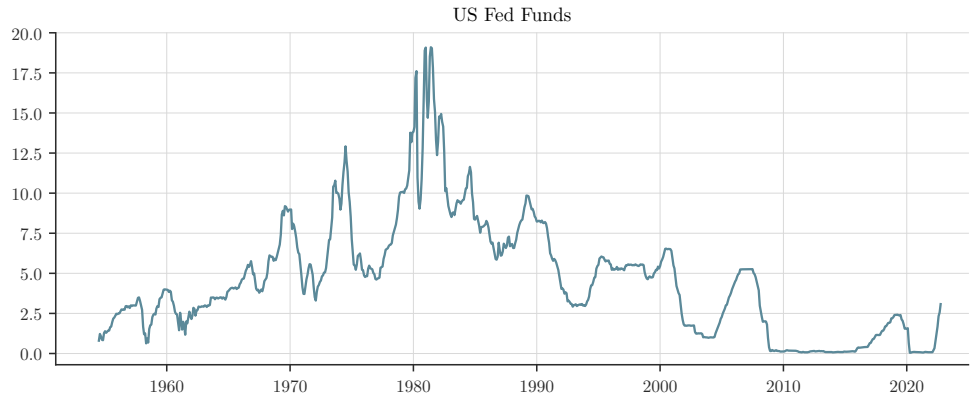


Figura 1 — Esempio di serie storica: Fed funds mensili osservati da luglio 1954 ad ottobre 2022. Il tasso di riferimento della Federal Reserve cresce marcatamente tra la fine degli anni '70 e i primi '80 (picco vicino al 20%) e poi scende fino a valori prossimi allo zero.

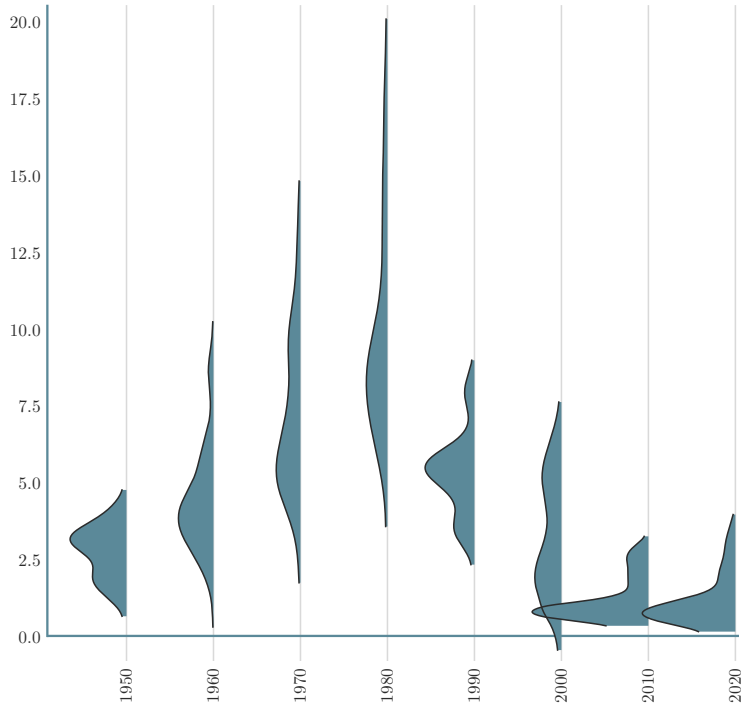


Figura 2 — Stima della distribuzione di probabilità dei tassi per decadi. Si nota che la distribuzione di Y_t tende a cambiare nel tempo (forma e posizione delle distribuzioni stimate cambiano decade per decade), quindi è difficile ipotizzare che le osservazioni siano identicamente distribuite.

(slide 3–5)

6.3. Notazione: ritardi, differenza prima, variazione percentuale

Definizione 6.2. Si consideri la variabile Y che si assume osservabile nel tempo:

- Y_t è la realizzazione della variabile osservata al tempo t, $t = 1, \dots, T$;
- Y_{t-j} è il ritardo j-esimo di Y_t;
- la **differenza prima** di una variabile Y_t è definita da

$$\Delta Y_t = Y_t - Y_{t-1};$$

- la **variazione percentuale** della serie Y_t tra i periodi t e $t-1$ è

$$100 \times \Delta \log Y_t = 100(\log Y_t - \log Y_{t-1}) \approx 100 \times \frac{\Delta Y_t}{Y_{t-1}}.$$

Infatti, sapendo che $\log(X + a) - \log X \approx a/X$ se $a \to 0$, si ha che

$$100 \times [\log Y_t - \log Y_{t-1}] = 100 \times [\log(Y_{t-1} + \Delta Y_t) - \log Y_{t-1}] \approx 100 \times \frac{\Delta Y_t}{Y_{t-1}}, \quad \text{se } \Delta Y_t \to 0.$$

(slide 6)

6.4. La trasformazione logaritmica e la stabilizzazione della varianza

Dimostrazione. Nell'analisi empirica spesso accade che, invece di analizzare la serie storica originale, risulti più conveniente considerare opportune trasformazioni monotone crescenti del tipo $Y_t = T(Z_t)$. In molti casi una trasformazione logaritmica consente di **stabilizzare la varianza** della serie trasformata.

Si consideri la trasformazione generica $Y_t = T(Z_t)$ e il suo sviluppo in serie di Taylor al primo ordine attorno alla media di Z_t, cioè μ_t:

$$T(Z_t) \approx T(\mu_t) + T'(\mu_t)(Z_t - \mu_t).$$

Dimostrazione. Si consideri una serie storica Z_t la cui varianza sia proporzionale al quadrato della media (le slide dicono "alla media"), cioè $\mathrm{Var}(Z_t) = \sigma_t^2 = c\mu_t^2$, con c costante positiva. Questa condizione si verifica spesso nelle serie storiche macroeconomiche e finanziarie.

Considerando $Y_t = T(Z_t) = \log(Z_t)$, per cui $T'(\mu_t) = 1/\mu_t$, si ottiene

$$\mathrm{Var}(Y_t) \approx \mathrm{Var}(T(\mu_t) + T'(\mu_t)(Z_t - \mu_t)) = 0 + \frac{1}{\mu_t^2} \underbrace{\mathrm{Var}(Z_t)}_{\substack{\text{per ip.} \\ \sigma_t^2 = c\mu_t^2}} = c\,\frac{1}{\mu_t^2}\mu_t^2 = c.$$

Quindi la varianza della serie trasformata $Y_t = \log(Z_t)$ non dipende più da t (in approssimazione di primo ordine, come lo sviluppo di Taylor: le slide scrivono "=" al posto di "≈"): la trasformazione logaritmica ha stabilizzato la varianza. □

(slide 7–8)

6.5. Distribuzioni condizionali e distribuzione congiunta

Definizione 6.3. I modelli per le serie storiche descrivono, come tutti i modelli di regressione, l'evoluzione delle **medie condizionali**. Rispetto ai modelli di regressione classica, mirano anche a misurare la relazione tra presente e passato di una certa variabile.

Più in generale, lo scopo dei modelli per le serie storiche è approssimare le **distribuzioni condizionali** dei dati; in particolare cercano di approssimare

$$p(Y_t|X_t) = p(Y_t|Y_{t-1}, Y_{t-2}, Y_{t-3}, \dots).$$

La distribuzione condizionale descrive, da un punto di vista statistico, il comportamento della variabile Y_t una volta che si osserva tutto quello che è successo prima, avendo quindi informazioni esatte su $Y_{t-1}, Y_{t-2}, \dots$ fino a Y_1.

In un'ottica di stima di massima verosimiglianza, tutte le distribuzioni condizionali contribuiscono a definire la **distribuzione congiunta**, cioè la distribuzione di probabilità dei dati nel loro insieme, $p(Y_1, Y_2, \dots, Y_T)$. In generale, la distribuzione congiunta si ottiene come prodotto delle distribuzioni condizionali:

$$p(Y_1, Y_2, \dots, Y_T) = p(Y_1)p(Y_2|Y_1) \dots p(Y_t|Y_{t-1}, Y_{t-2}, \dots, Y_1) \dots p(Y_T|Y_{T-1}, \dots, Y_1).$$

(slide 9–10)

6.6. Esempio: verosimiglianza di un modello AR(1) Normale

Esempio 6.1. Si consideri il modello di regressione

$$Y_t = \alpha + \beta Y_{t-1} + \epsilon_t,$$

che suggerisce che il dato odierno Y_t dipenda dall'osservazione misurata nel periodo precedente, Y_{t-1}, più uno shock ϵ_t che misura una variazione della variabile dipendente oggi, non predicibile. Ad esempio ϵ_t può essere una variabile casuale con media 0 e varianza σ^2.

In questo caso il generico regressore X_t coincide con la variabile Y osservata al periodo precedente, cioè Y_{t-1}. La distribuzione condizionale è descritta dalle seguenti medie e varianze:

- media condizionale: $E[Y_t|Y_{t-1}, Y_{t-2}, \dots] = \alpha + \beta Y_{t-1}$;
- varianza condizionale: $\mathrm{Var}[Y_t|Y_{t-1}, Y_{t-2}, \dots] = \sigma^2$.

Ipotizzando che ϵ_t sia una v.c. Normale con media 0 e varianza σ^2, si ottiene

$$p(Y_t|Y_{t-1}, Y_{t-2}, \dots, Y_1) \sim N(\underbrace{\alpha + \beta Y_{t-1}}_{E[Y|X]}, \underbrace{\sigma^2}_{\text{Var}[Y|X]}).$$

Di conseguenza la funzione di verosimiglianza è

$$p(Y_1, \dots, Y_T) = p(Y_1)p(Y_2|Y_1)p(Y_3|Y_2) \dots p(Y_T|Y_{T-1})$$

$$\propto \prod_{t=2}^{T} \frac{1}{\sigma\sqrt{2\pi}} \exp\left[-\frac{1}{2\sigma^2}(Y_t - \alpha - \beta Y_{t-1})^2\right] = \frac{1}{(2\pi\sigma^2)^{(T-1)/2}} \exp\left\{-\frac{\sum_{t=2}^{T}(Y_t - \alpha - \beta Y_{t-1})^2}{2\sigma^2}\right\}.$$

(Le slide riportano N come estremo del prodotto e l'esponente $T/2$; il prodotto ha $T-1$ fattori, da $t=2$ a $t=T$, e il fattore $p(Y_1)$ è trascurato nella proporzionalità.)

(slide 11–12)

6.7. La distribuzione marginale

Definizione 6.4. Scopo dell'analisi statistica delle serie storiche è descrivere **come** la distribuzione condizionale della variabile dipendente evolve nel tempo. La distribuzione condizionale non deve essere confusa con quella marginale, che descrive la variabile Y al netto del fattore tempo.

La distribuzione marginale di Y_t può essere calcolata dalla distribuzione congiunta di Y_t e Y_{t-1} sommando le probabilità di tutti i possibili risultati per i quali Y assume un valore specifico. Se Y_{t-1} potesse assumere k valori diversi $y_1, \dots, y_k$, allora la probabilità marginale che Y_t assuma il valore y è

$$p(Y_t = y) = \sum_{i=1}^{k} \Pr(Y_t = y,\ Y_{t-1} = y_i).$$

(slide 13)

6.8. Esempio: distribuzioni marginale e condizionale nell'albero binomiale

Esempio 6.2. Si consideri un modello statistico, detto **albero binomiale**, che cerca di approssimare l'andamento di una serie storica finanziaria; è utilizzato di solito nel *pricing* di titoli derivati.

Si consideri la variabile S che descrive il prezzo nel tempo di una *security*. Si ipotizzi che oggi (giorno 0) il prezzo sia 4\$. Il giorno 1 il prezzo può raddoppiare (evento H) con probabilità 0.4, o dimezzarsi (evento T) con probabilità 0.6. Lo stesso accade per il giorno 2. S_0, S_1, S_2 sono le variabili che descrivono il prezzo nei tre giorni analizzati.

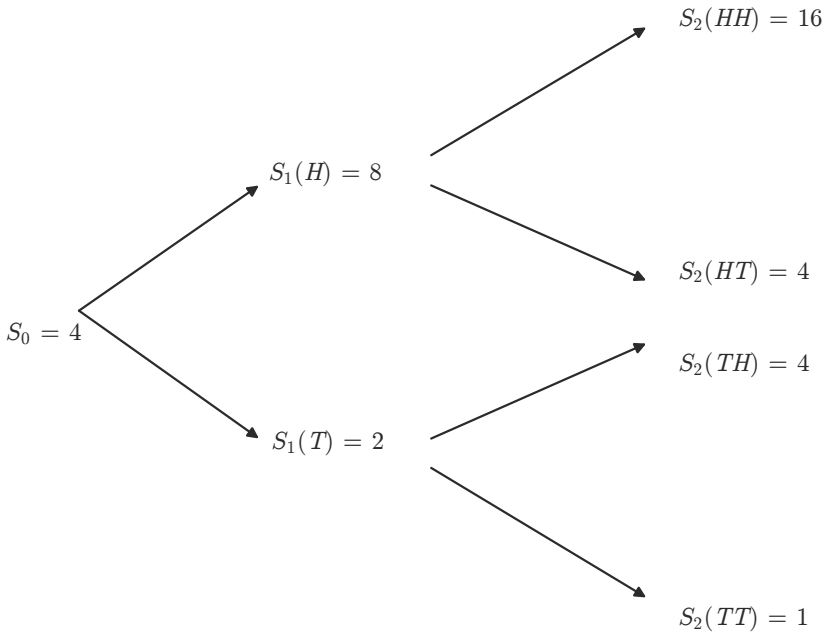


Figura 3 — Esempio di albero binomiale: da $S_0 = 4$ si diramano $S_1(H) = 8$ e $S_1(T) = 2$; da $S_1(H) = 8$ si diramano $S_2(HH) = 16$ e $S_2(HT) = 4$; da $S_1(T) = 2$ si diramano $S_2(TH) = 4$ e $S_2(TT) = 1$. Sono riportate tutte le traiettorie possibili del prezzo nei due giorni successivi ad oggi, con le relative probabilità di transizione (0.4 per il ramo "raddoppia", 0.6 per il ramo "dimezza").

La **distribuzione condizionale** tra un giorno è

$$p(S_1 = s_1 | S_0 = 4) = \begin{cases} s_1 = 8, & p = 0.4 \\ s_1 = 2, & p = 0.6 \end{cases}$$

Le **distribuzioni condizionali** tra due giorni risultano

$$p(S_2 = s_2 | S_1 = 8) = \begin{cases} s_2 = 16, & p = 0.4 \\ s_2 = 4, & p = 0.6 \end{cases} \qquad p(S_2 = s_2 | S_1 = 2) = \begin{cases} s_2 = 4, & p = 0.4 \\ s_2 = 1, & p = 0.6 \end{cases}$$

La **distribuzione marginale** dopo il primo giorno è

$$p(S_1 = s_1) = \begin{cases} s_1 = 8, & p = 0.4 \\ s_1 = 2, & p = 0.6 \end{cases}$$

La **distribuzione marginale** tra due giorni risulta quindi

$$p(S_2 = s_2) = \begin{cases} s_2 = 16, & p = 0.4^2 \\ s_2 = 4, & p = 0.4 \times 0.6 + 0.6 \times 0.4 \\ s_2 = 1, & p = 0.6^2 \end{cases}$$

si ottengono così i valori numerici $p(S_2 = 16) = 0.16$, $p(S_2 = 4) = 0.48$, $p(S_2 = 1) = 0.36$, che sommano a 1. Si noti la differenza concettuale rispetto alle distribuzioni condizionali sopra riportate: la marginale "integra via" l'informazione su S_1.

(slide 14–17)

6.9. Autocorrelazione: definizione, ACF e PACF

Definizione 6.5. Nelle serie temporali è lecito aspettarsi che il valore di Y al tempo t sia dipendente dal proprio valore nel periodo precedente (le slide dicono "successivo", refuso). La correlazione di una serie con i propri valori ritardati è detta **autocorrelazione** (o correlazione seriale): è la dipendenza lineare tra le realizzazioni di una variabile osservata in due istanti temporali diversi.

Se, ad esempio, esiste un'autocorrelazione positiva, ci si aspetta che se $Y_{t-1} > 0$, in media, anche Y_t tenderà ad assumere valori positivi; oppure, al contrario, un'osservazione negativa sarà seguita da un'altra osservazione negativa.

Si definisce la j-esima autocorrelazione ρ_j come

$$\rho_j = \frac{\mathrm{Cov}(Y_t, Y_{t-j})}{\sqrt{\mathrm{Var}(Y_t)\mathrm{Var}(Y_{t-j})}}.$$

Lo stimatore della covarianza è

$$\widehat{\mathrm{Cov}}(Y_t, Y_{t-j}) = \frac{1}{T-j-1} \sum_{t=j+1}^{T} (Y_t - \bar{Y}_{j+1,T})(Y_{t-j} - \bar{Y}_{1,T-j}),$$

dove $\bar{Y}_{j+1,T}$ è la media campionaria calcolata sulle osservazioni $t = j+1, \dots, T$. Quindi lo stimatore della correlazione, **nell'ipotesi che** $\mathrm{Var}(Y_t) = \mathrm{Var}(Y_{t-j})$, è

$$\hat{\rho}_j = \frac{\widehat{\mathrm{Cov}}(Y_t, Y_{t-j})}{\widehat{\mathrm{Var}}(Y_t)}.$$

La **funzione di autocorrelazione (ACF)** descrive in maniera sintetica la struttura di correlazione tra Y_t ed Y_{t-j}, indicata con ρ_j per qualsiasi $j \geq 1$. Una rappresentazione grafica di tale dipendenza al variare di j è detta **correlogramma**.

Il coefficiente di **autocorrelazione parziale** misura la dipendenza di Y_t da Y_{t-j} al netto dei valori intermedi $Y_{t-1}, \dots, Y_{t-j+1}$. La **funzione di autocorrelazione parziale (PACF)** descrive in maniera sintetica la sequenza di queste statistiche al variare di j.

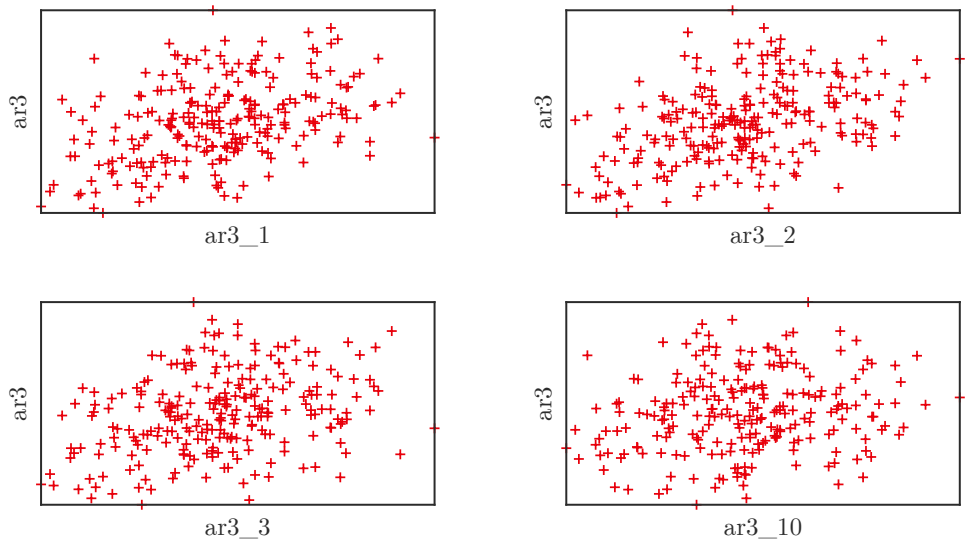


Figura 4 — Dipendenza tra Y_t e Y_{t-j}, $j = 1, 2, 3, 10$ (serie "ar3"; la didascalia delle slide riporta $j = 1, 2, 3, 4$, ma i pannelli sono etichettati ar3_1, ar3_2, ar3_3, ar3_10): quattro scatterplot di Y_t contro i propri ritardi mostrano che la nuvola di punti è più "allineata" (correlata) per ritardi bassi e diventa più dispersa (meno correlata) all'aumentare del ritardo.

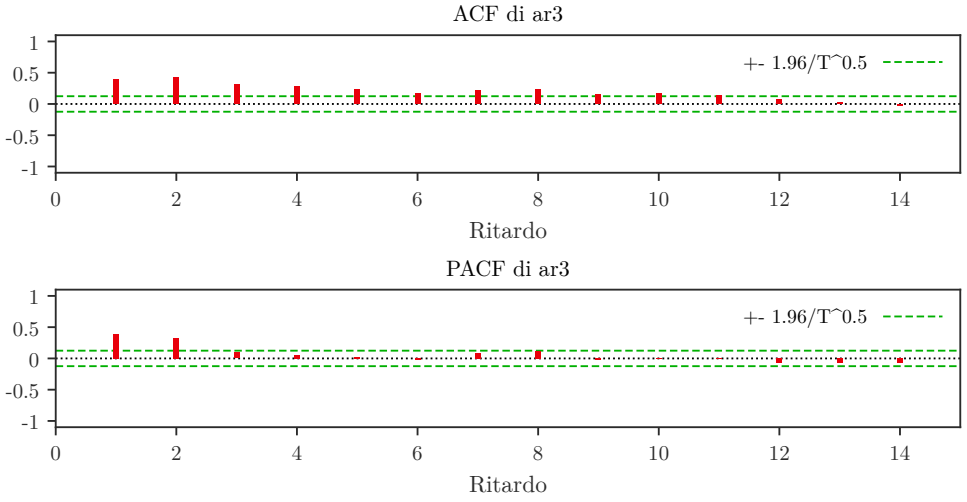


Figura 5 — Correlogramma della serie Y_t (ar3): l'ACF decresce lentamente e resta oltre le bande per circa i primi dieci ritardi, mentre la PACF supera le bande solo ai primissimi ritardi (coerente con un processo autoregressivo di ordine basso); le bande tratteggiate rappresentano i limiti di significatività $\pm 1.96/\sqrt{T}$.

(slide 18–22)

6.10. Il test di Ljung-Box per l'autocorrelazione

Teorema 6.1. La struttura di autocorrelazione di una serie storica fornisce importanti informazioni, utili (i) per identificare un modello appropriato per i dati e (ii) per verificare se il modello proposto è corretto. Occorre quindi controllare se le osservazioni presentano un'autocorrelazione seriale significativa. Tale verifica si basa sullo studio delle autocorrelazioni campionarie $\hat{\rho}_j$, $j = 1, 2, ...$, che al variare del ritardo j descrivono l'**autocorrelogramma**.

Si dimostra che, sotto opportune ipotesi,

$$\sqrt{T}\,\hat{\rho}_j \to N(0,1).$$

Quindi, per verificare l'ipotesi nulla $H_0 : \rho_j = 0$ si può usare la statistica $\sqrt{T}\hat{\rho}_j$ e calcolare l'opportuno p-value con la distribuzione $N(0,1)$.

Molto spesso si è interessati a verificare ipotesi più complesse, ad esempio l'ipotesi nulla congiunta $H_0 : \rho_1 = \rho_2 = \cdots = \rho_j = 0$, cioè che le prime j correlazioni siano nulle. Il **test di Ljung-Box** si basa sulla statistica

$$Q_{LB}(j) = T(T+2)\sum_{i=1}^{j}\frac{\hat{\rho}_i^2}{T-i} \to \chi^2_j,$$

ed è quindi possibile calcolare l'opportuno p-value.

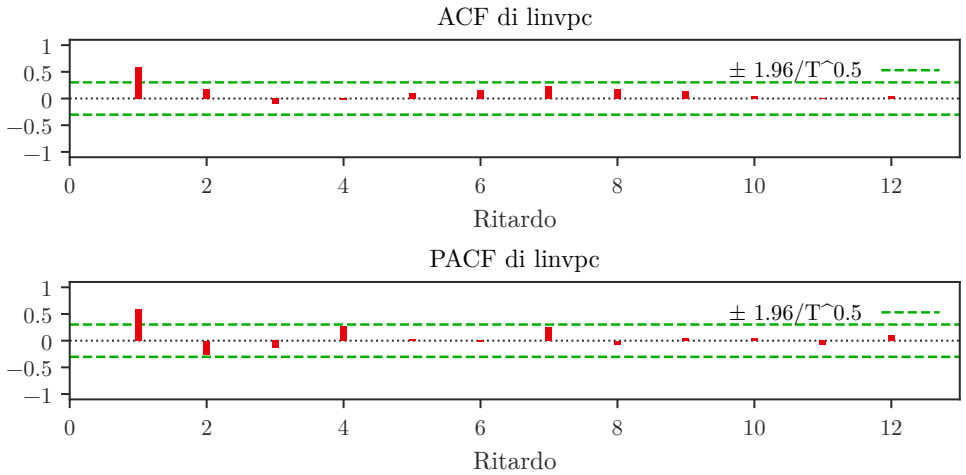


Figura 6 — Esempio di autocorrelogramma (serie "linvpc"): evidenzia la dipendenza tra un'osservazione della serie ed i suoi ritardi; sia ACF che PACF mostrano un picco marcato al primo ritardo, superiore alle bande di significatività.

Esempio numerico — Funzione di autocorrelazione per y_t per 12 ritardi:

LAG	ACF	Q-stat.	[p-value]
1	0.5941 ***	15.1699	[0.000]
2	0.1864	16.6981	[0.000]
3	-0.0987	17.1372	[0.001]
4	-0.0255	17.1674	[0.002]
5	0.1031	17.6713	[0.003]
6	0.1613	18.9365	[0.004]
7	0.2280	21.5325	[0.003]
8	0.1696	23.0087	[0.003]
9	0.1315	23.9214	[0.004]
10	0.0556	24.0896	[0.007]
11	0.0110	24.0964	[0.012]
12	0.0475	24.2268	[0.019]

Tutti i p-value della statistica $Q_{LB}(j)$ sono piccoli (≤ 0.019): si rifiuta l'ipotesi nulla di assenza di autocorrelazione fino al ritardo 12.

(slide 23–26)

6.11. Modelli statici e il Capital Asset Pricing Model (CAPM)

Esempio 6.3. Il primo esempio di regressione statica riguarda la regressione semplice tra due variabili Y ed X in cui la relazione è definita da

$$Y_t = \beta_0 + \beta_1 X_t + \epsilon_t, \qquad t = 1, \dots, T.$$

Il nome "statico" deriva dal fatto che si modella una relazione **contemporanea** tra le due grandezze. Questi modelli descrivono relazioni di lungo periodo, situazioni in cui l'economia si ipotizza essere in equilibrio. Sono proposti quando sembra ragionevole ipotizzare che X abbia un impatto immediato su Y; quindi, se $\Delta\epsilon_t = 0$, si può scrivere

$$\Delta Y_t = \beta_1 \Delta X_t.$$

Esempio: il CAPM. Un'idea rilevante della finanza moderna è che un investitore ha bisogno di un incentivo finanziario per assumere un rischio, cioè il rendimento atteso rischioso dovrebbe sempre essere maggiore di quello non rischioso. Il CAPM formalizza l'idea che il rischio dell'investimento è legato al rischio del mercato, approssimato tramite un **portafoglio di mercato**. Il CAPM si basa sulla relazione

$$r_t - r_f = \beta(r_{mt} - r_f) + \epsilon_t,$$

in cui r_t ed r_{mt} sono i rendimenti di un titolo rischioso e del portafoglio di mercato al tempo t, mentre r_f è il rendimento di un titolo risk-free.

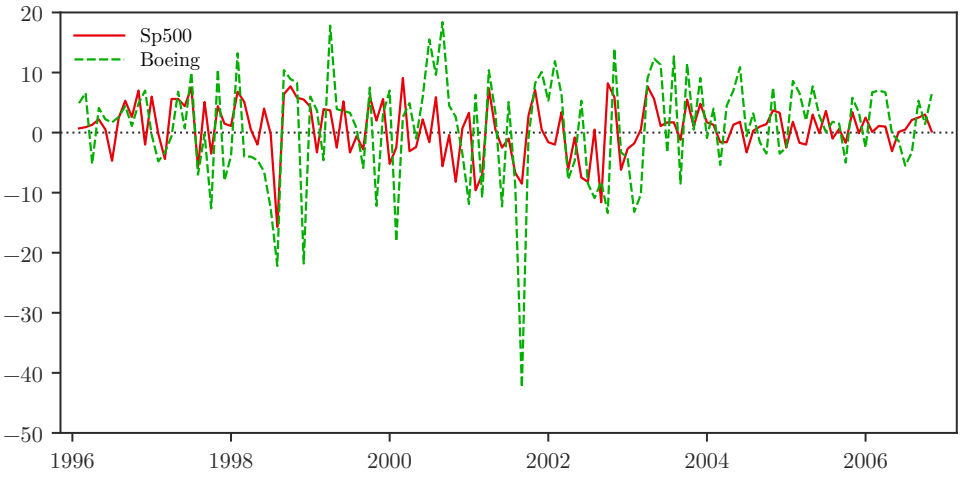


Figura 7 — Serie storiche del rendimento dell'indice Standard & Poor's 500 (portafoglio di mercato) e del titolo rischioso Boeing Co., dal 1996 al 2006: le due serie mostrano un andamento comovente, con la volatilità di Boeing generalmente amplificata rispetto a quella dell'indice.

Stime OLS usando le 130 osservazioni 1996:02-2006:11, variabile dipendente: return_ba

VARIABILE	COEFFICIENTE	ERRORE STD	STAT T	P-VALUE
return_sp	0.781803	0.161229	4.849	<0.00001 ***

Media della variabile dipendente = 0.729731; Deviazione standard della variabile dipendente = 8.77071; Somma dei quadrati dei residui = 8452.02; Errore standard dei residui = 8.09441; R-quadro = 0.154171; R-quadro corretto = 0.154171; Statistica F (1, 129) = 23.5132 (p-value < 0.00001); Statistica Durbin-Watson = 1.92748.

Un titolo con β minore di 1 risulta meno rischioso rispetto al portafoglio di mercato e ha quindi un eccesso di rendimento atteso minore rispetto al portafoglio stesso. In pratica, un incremento dell'1% al tempo t dell'eccesso di rendimento del portafoglio di mercato (S&P500) comporta in media un incremento dello 0.78% del rendimento di Boeing (le slide dicono "causerà": una regressione OLS misura un'associazione, non prova il nesso causale).

Il valore di

$$R^2 = \frac{\hat{\beta}_i^2 \hat{\sigma}_M^2}{\hat{\sigma}_i^2} = 0.15$$

può essere interpretato come la percentuale di rischio sistematico sul rischio complessivo.

(slide 27–31)

6.12. Motivazioni per la specificazione dinamica dei modelli

Esistono almeno due ragioni per ricorrere alla specificazione dinamica dei modelli.

- Da un lato vi è l'esigenza di giungere ad una migliore comprensione del funzionamento nel tempo del sistema oggetto di studio, differenziando, ad esempio, il comportamento di breve periodo da quello di lungo periodo.
- Dall'altro lato vi può essere la necessità di disporre di un modello che, utilizzando osservazioni provenienti da serie storiche, abbia caratteristiche idonee a produrre buone previsioni.

Quindi l'idea è considerare modelli che, oltre a relazioni statiche tra variabili, incorporino relazioni tra variabili differite nel tempo, quindi dinamiche. *(slide 32)*

6.13. Il processo white noise

Definizione 6.6. Una successione di variabili aleatorie ϵ_t si dice **white noise** (o rumore bianco) se ha le seguenti proprietà:

$$E[\epsilon_t] = 0 \qquad \forall t$$

$$E[\epsilon_t \epsilon_s] = \begin{cases} \sigma_\epsilon^2 & \text{se } t = s \\ 0 & \text{altrimenti.} \end{cases}$$

Questo modello in generale non è adeguato per descrivere dati reali, che come già accennato sono molto spesso dipendenti; viene tuttavia utilizzato spesso per definire il processo che descrive il termine di errore (in inglese *noise*) di modelli più generali.

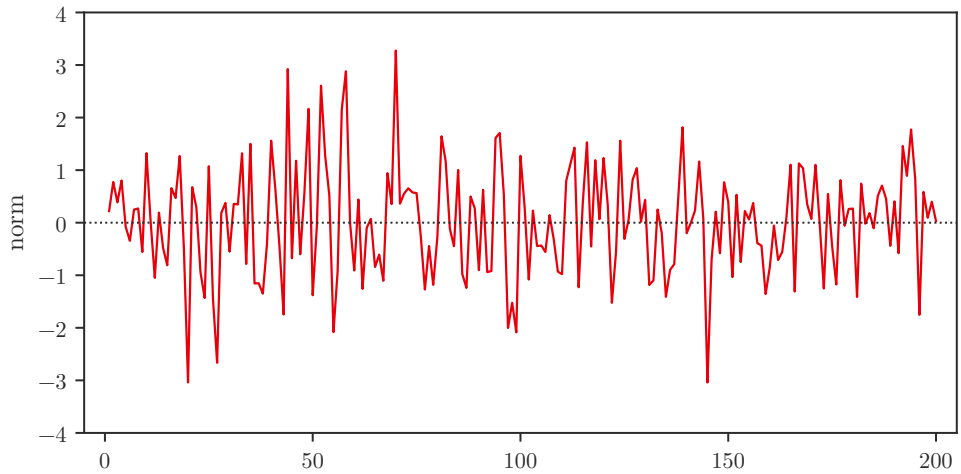


Figura 8 — Esempio di dati generati da un modello White Noise: la serie oscilla in modo irregolare attorno a zero, senza pattern visibile, con ampiezza compresa circa tra −3 e 3.

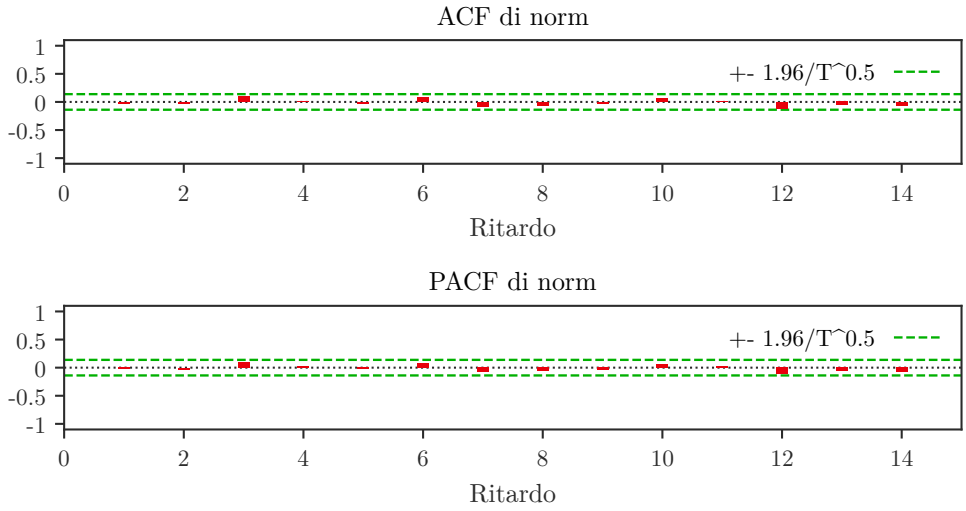


Figura 9 — Grafico dell'autocorrelogramma di un modello White Noise: né l'ACF né la PACF mostrano valori significativamente diversi da zero, coerentemente con l'assenza di dipendenza seriale.

(slide 33–35)

6.14. Modelli a media mobile MA(1) e MA(q)

Definizione 6.7. Una semplice estensione del modello White Noise si ottiene facendo dipendere l'osservazione presente dagli shock passati. Questa categoria di modelli prende il nome di **Moving Average (MA)**. Il modello MA(1), in cui l'osservabile dipende esclusivamente dallo shock passato e da quello presente, è

$$Y_t = \alpha + \epsilon_t + \theta\epsilon_{t-1}, \qquad \epsilon_t \sim WN(0, \sigma^2).$$

L'autocorrelogramma di Y_t si calcola come segue:

$$\mathrm{Cov}(Y_t, Y_{t-j}) = \begin{cases} (1+\theta^2)\sigma^2 & \text{se } j = 0 \\ \theta\sigma^2 & \text{se } j = 1 \\ 0 & \text{altrimenti.} \end{cases}$$

Nel caso $j = 0$ le slide riportano $(1+\theta)\sigma^2$, refuso: $\mathrm{Var}(Y_t) = \sigma^2 + \theta^2\sigma^2$, perché $\mathrm{Cov}(\epsilon_t, \epsilon_{t-1}) = 0$; la forma corretta coincide con la varianza di un MA(q) riportata più sotto.

Dimostrazione. Si ricordi che la sequenza ϵ_t soddisfa $\mathrm{Cov}(\epsilon_t, \epsilon_{t-j}) = 0$ per $j \geq 1$. Di conseguenza

$$\mathrm{Cov}(Y_t, Y_{t-1}) = \mathrm{Cov}(\alpha + \epsilon_t + \theta\epsilon_{t-1},\ \alpha + \epsilon_{t-1} + \theta\epsilon_{t-2}) = \theta\sigma^2.$$

La correlazione a ritardi superiori a 1 risulta sempre nulla.

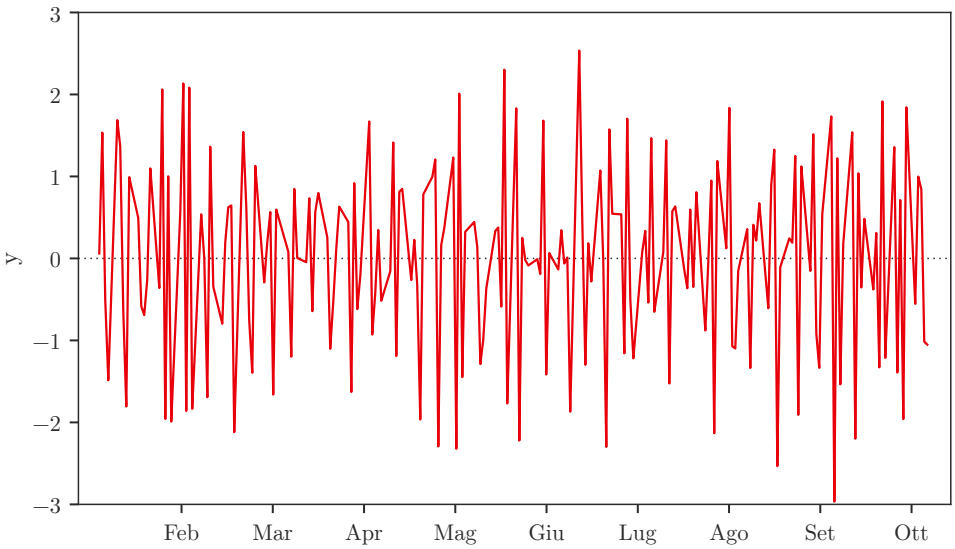


Figura 10 — Grafico di una serie storica MA(1) con $\theta = -0.7$ e $\sigma = 0.9$: la serie oscilla in modo irregolare, con frequenti inversioni di segno tra osservazioni consecutive, più "frastagliata" del white noise puro: con $\theta < 0$ la correlazione al ritardo 1 è negativa ($\rho_1 = \theta/(1+\theta^2) \approx -0.47$).

Generalizzazione: MA(q). L'osservazione di oggi dipende da q shock passati:

$$Y_t = \alpha + \epsilon_t + \theta_1\epsilon_{t-1} + \cdots + \theta_q\epsilon_{t-q}.$$

La media marginale è $E[Y_t] = \alpha$. La varianza marginale è

$$\mathrm{Var}[Y_t] = \sigma^2\big(1 + \theta_1^2 + \cdots + \theta_q^2\big).$$

In generale, la funzione di autocorrelazione di un modello MA(q) assume valori diversi da 0 solo ai primi q ritardi.

Esempio: MA(2). Si consideri $Y_t = \alpha+\epsilon_t+\theta_1\epsilon_{t-1}+\theta_2\epsilon_{t-2}$. La struttura di autocorrelazione si calcola come segue.

A ritardo 1:

$$\mathrm{Cov}(Y_t, Y_{t-1}) = \mathrm{Cov}(\epsilon_t + \theta_1\epsilon_{t-1} + \theta_2\epsilon_{t-2},\ \epsilon_{t-1} + \theta_1\epsilon_{t-2} + \theta_2\epsilon_{t-3}) = \sigma^2\theta_1 + \sigma^2\theta_1\theta_2 = \theta_1\sigma^2(1+\theta_2).$$

A ritardo 2:

$$\mathrm{Cov}(Y_t, Y_{t-2}) = \mathrm{Cov}(\epsilon_t + \theta_1\epsilon_{t-1} + \theta_2\epsilon_{t-2},\ \epsilon_{t-2} + \theta_1\epsilon_{t-3} + \theta_2\epsilon_{t-4}) = \sigma^2\theta_2.$$

Per ritardi $j > 2$:

$$\mathrm{Cov}(Y_t, Y_{t-j}) = \mathrm{Cov}(\epsilon_t + \theta_1\epsilon_{t-1} + \theta_2\epsilon_{t-2},\ \epsilon_{t-j} + \theta_1\epsilon_{t-j-1} + \theta_2\epsilon_{t-j-2}) = 0.$$

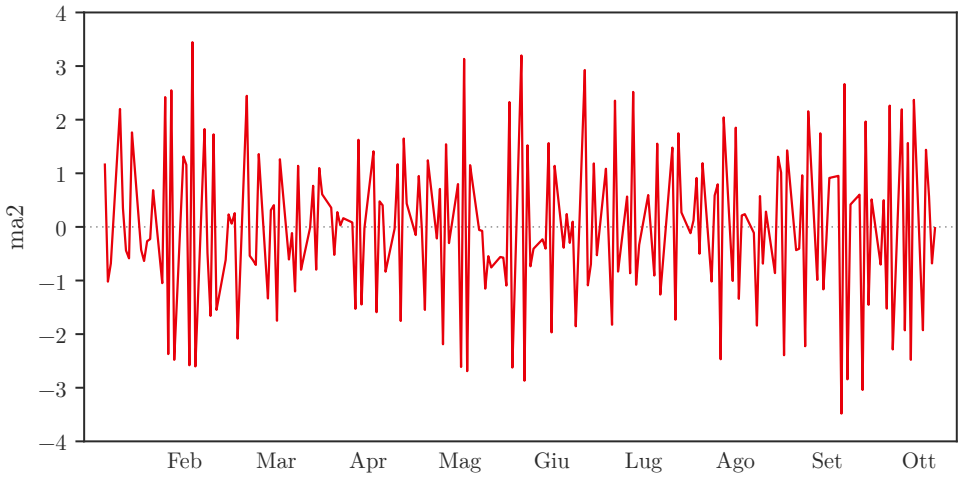


Figura 14 — Grafico di una serie storica di un modello MA(2) con $\theta_1 = -0.9, \theta_2 = 0.7, \sigma = 0.9$: la serie oscilla in modo irregolare, con frequenti inversioni di segno come nel MA(1): con questi parametri $\rho_1 < 0$ ($\rho_1 \approx -0.67$) e $\rho_2 > 0$ ($\rho_2 \approx 0.30$).

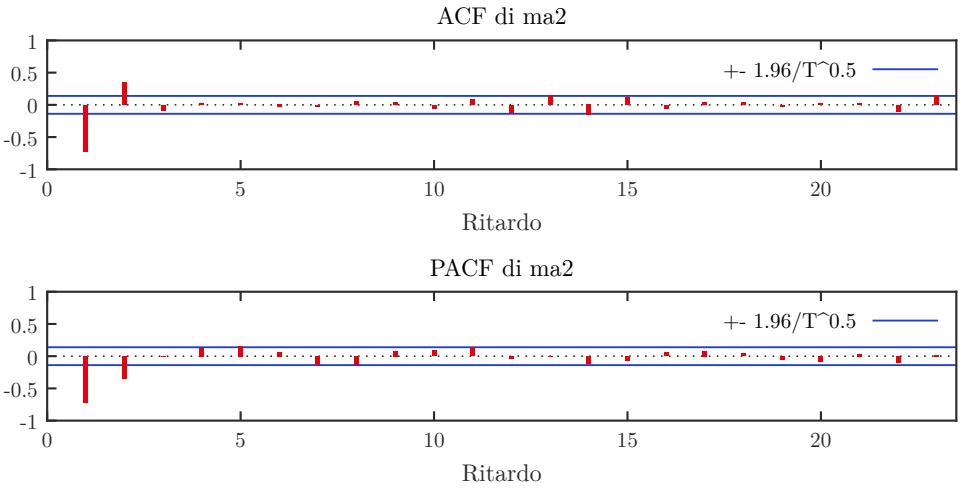


Figura 15 — Autocorrelogramma del modello MA(2) precedente: l'ACF mostra valori significativi solo ai primi due ritardi, come previsto dalla teoria per un MA(2); anche la PACF è marcata soprattutto ai primi due ritardi (in teoria, per un MA, la PACF decade gradualmente senza annullarsi).

(slide 36–38)

6.15. Esempio: il modello di Roll per il bid-ask spread (MA(1))

Esempio 6.4. In finanza il modello MA(1) può servire a descrivere l'andamento di un rendimento atteso in presenza di uno spread tra prezzi di domanda e di offerta.

In alcuni mercati (NYSE) i *market maker* forniscono liquidità comprando e vendendo quantità rilevanti di asset in maniera anonima, senza modificarne sostanzialmente il prezzo. In cambio si

riservano il diritto di vendere gli asset ad un prezzo leggermente maggiore rispetto a quello di acquisto. Essi acquistano un asset al prezzo *bid* P_b e cercano di venderlo al prezzo *ask* P_a; la differenza $S = P_a - P_b$, detta **bid-ask spread**, è di solito piccola.

Si consideri la serie storica dei prezzi intra-giornalieri di un asset finanziario osservata per 15 giorni nel mercato NYSE.

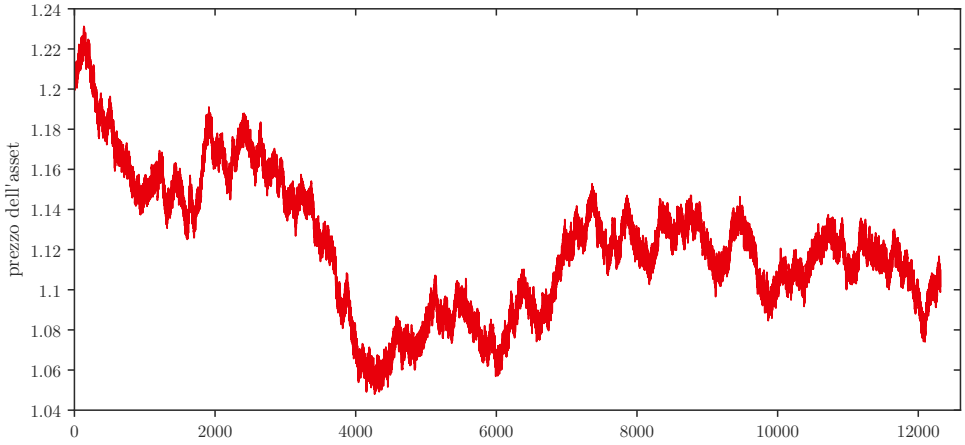


Figura 12 — Prezzi intra-giornalieri dell'asset: la serie oscilla tra circa 1.05 e 1.23, con andamento a zig-zag rapido tipico dei dati ad alta frequenza intraday. L'asse orizzontale arriva a circa 12300 osservazioni, cioè al campione usato nella stima più sotto.

Modello di Roll (1984). Il prezzo osservato P_t di un asset al tempo t è

$$P_t = P_t^* + I_t \frac{S}{2} = P_t^* + \begin{cases} +S/2 & \text{con prob. } 0.5 \\ -S/2 & \text{con prob. } 0.5 \end{cases}$$

dove: $S = P_a - P_b$ è lo spread; P_t^* è il prezzo teorico (fondamentale) dell'asset in un mercato senza frizioni; I_t è una sequenza di variabili binarie indipendenti (ipotesi necessaria per la covarianza nulla a ritardi superiori a 1, non esplicitata nelle slide) con $P(I_t = -1) = P(I_t = 1) = 0.5$, interpretabile come indicatore del tipo d'ordine: $+1$ se la transazione è iniziata dall'acquirente, -1 se dal venditore.

Ipotizzando che il prezzo fondamentale non cambi, si calcola il rendimento

$$\Delta P_t = (I_t - I_{t-1})\frac{S}{2}.$$

Si dimostra che:

- $E[\Delta P_t] = 0$ (coerente con la teoria dei mercati efficienti);
- $\mathrm{Var}(\Delta P_t) = S^2/2$;
- $\mathrm{Cov}(\Delta P_t, \Delta P_{t-1}) = -S^2/4 \Rightarrow \mathrm{Corr}(\Delta P_t, \Delta P_{t-1}) = -0.5$;
- $\mathrm{Cov}(\Delta P_t, \Delta P_{t-j}) = 0, \ \forall j > 1$.

Questo modello riproduce esattamente la struttura di autocorrelazione di un modello MA(1). Il bid-ask spread induce quindi una correlazione negativa a ritardo 1 nella serie osservata dei rendimenti: fenomeno chiamato in letteratura **bid-ask bounce**.

Intuizione. Ipotizzando $P_t^* = (P_a + P_b)/2$, il prezzo osservabile risulta essere P_a o P_b. Supponendo che il prezzo osservabile passato $(t-1)$ sia P_a, oggi il prezzo sarà ancora P_a oppure più basso (P_b). Come conseguenza:

$$\Delta P_t = \begin{cases} 0 & \text{con prob. } 0.5 \\ -S & \text{con prob. } 0.5 \end{cases}$$

L'autocorrelazione negativa a ritardo 1 (e non a ritardi successivi) emerge quindi in modo evidente.

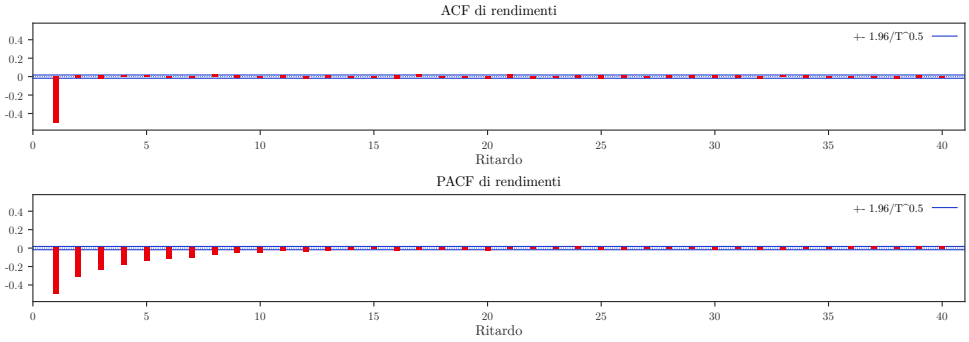


Figura 13 — Struttura di autocorrelazione (ACF e PACF) dei rendimenti calcolati sui dati di Figura 12: si osserva un unico valore negativo significativo al ritardo 1 nell'ACF, in linea con quanto atteso per un modello MA(1); la PACF mostra invece una struttura decrescente su più ritardi, tipica della rappresentazione AR di un processo MA.

Stima di massima verosimiglianza. I modelli MA si stimano tipicamente per massima verosimiglianza. Stima dei parametri del modello MA(1) $Y_t = \alpha + \theta\epsilon_{t-1} + \epsilon_t$:

Modello 2: MA, usando le osservazioni 1:002-124:017 (T = 12316). Stimato usando il filtro di Kalman (MV esatta). Variabile dipendente: rendimenti. Errori standard basati sull'Hessiana.

	coefficiente	errore std.	z	p-value
const	-8.20737e-06	9.22571e-06	-0.8896	0.3737
theta_1	-0.815431	0.00521480	-156.4	0.0000 ***

Media var. dipendente -8.80e-06; SQM var. dipendente 0.007132; Media innovazioni -7.63e-07; SQM innovazioni 0.005545; Log-verosimiglianza 46503.13; Criterio di Akaike -93000.26; Criterio di Schwarz -92978.01; Hannan-Quinn -92992.81. (Note: SQM = scarto quadratico medio; E.S. = errore standard)

(slide 39–46)

6.16. Modelli autoregressivi AR(1) e AR(p)

Definizione 6.8. I modelli specificati per dati di serie storica servono spesso a prevedere una variabile di interesse. Il primo modello considerato è il **Modello Autoregressivo**, in cui una variabile è spiegata dal proprio passato tramite ritardi. Il modello più semplice è quello autoregressivo del primo ordine, **AR(1)**:

$$Y_t = \beta_0 + \beta_1 Y_{t-1} + \epsilon_t.$$

L'autocorrelogramma tipico per questo modello tende a decrescere a zero: Y_t dipende fortemente dalle osservazioni vicine $(Y_{t-1}, Y_{t-2}, ...)$ ma non da quelle lontane. Ad esempio, ciò che è successo 10 giorni fa potrebbe non essere interessante per prevedere ciò che accadrà domani, mentre lo è ciò che è accaduto ieri, l'altro ieri e così via, con importanza decrescente, fino a diventare nulla ad un numero elevato di ritardi.

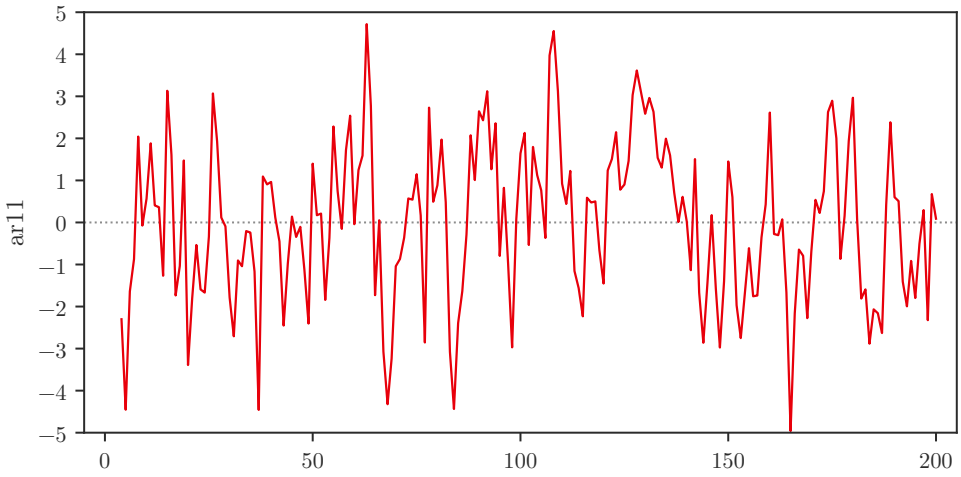


Figura 16 — Grafico di una serie autocorrelata al primo ordine: la serie oscilla con maggiore persistenza rispetto al white noise, alternando fasi più prolungate sopra e sotto lo zero.

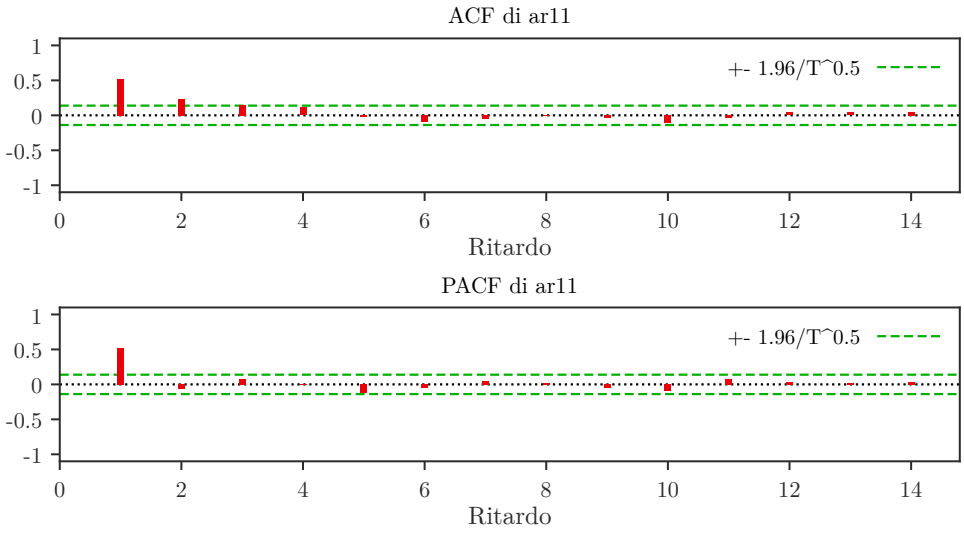


Figura 17 — Autocorrelogramma del modello AR(1): l'ACF decresce gradualmente verso zero all'aumentare del ritardo, mentre la PACF mostra un unico picco significativo al ritardo 1, coerente con la teoria del modello AR(1).

Modello AR(p). Il modello AR(1) utilizza solo l'informazione fornita da Y_{t-1} per prevedere Y_t. Un'estensione naturale è il modello autoregressivo di ordine p:

$$Y_t = \beta_0 + \beta_1 Y_{t-1} + \cdots + \beta_p Y_{t-p} + \epsilon_t.$$

La previsione per Y_{T+1} è data da

$$\hat{Y}_{T+1|T} = \hat{\beta}_0 + \hat{\beta}_1 Y_T + \cdots + \hat{\beta}_p Y_{T-p+1}.$$

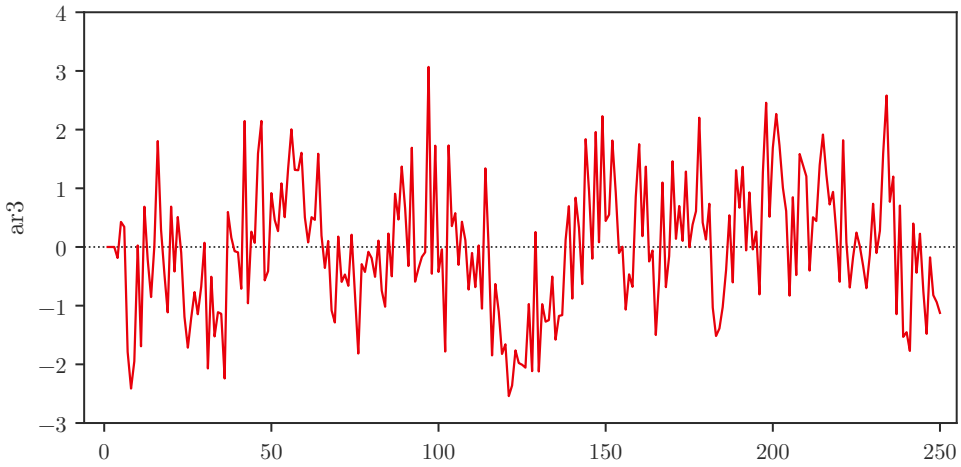


Figura 18 — Grafico di una serie autocorrelata al terzo ordine (AR(3)): la serie mostra fasi sopra e sotto lo zero più prolungate rispetto all'AR(1), con più lenta reversione verso lo zero; l'ampiezza delle oscillazioni è però minore (valori tra circa -2.5 e 3).

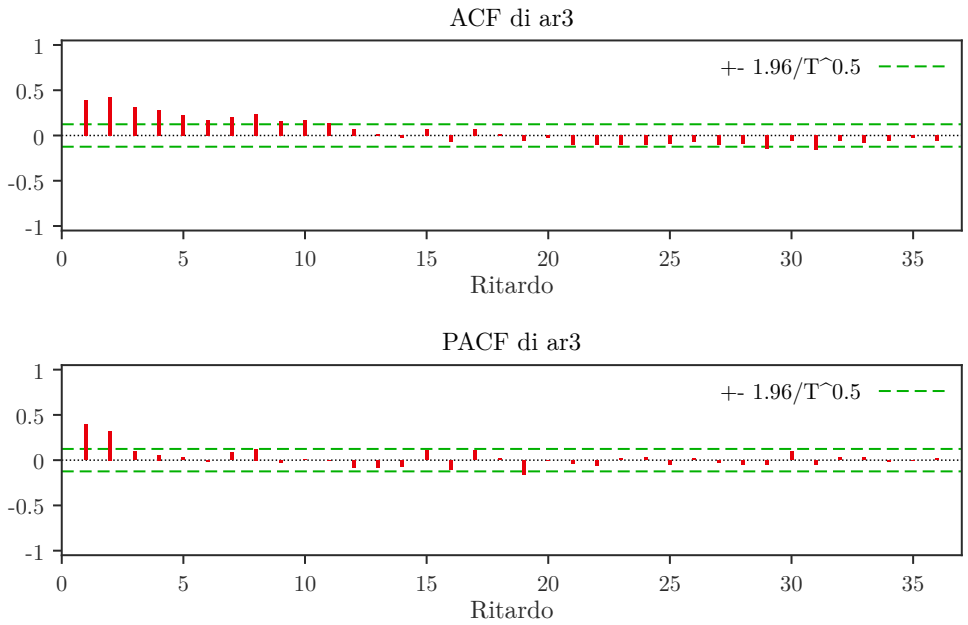


Figura 19 — Autocorrelogramma del modello AR(3): l'ACF decresce lentamente, restando positiva fino a circa il ritardo 12, mentre la PACF supera le bande di confidenza solo ai primi due ritardi (il terzo, di circa 0.1, resta all'interno; fuori banda c'è solo un valore isolato al ritardo 19), in linea con la teoria per un AR(p), la cui PACF si annulla oltre il ritardo p (qui $p = 3$).

(slide 51–56)

6.17. Il modello autoregressivo misto ADL(p,q)

Definizione 6.9. I modelli visti finora sono modelli statistici, utili per fare previsioni. In economia, però, interessano più spesso le relazioni causali tra variabili, cioè il tipo di dipendenza che esiste tra grandezze economiche. Per analizzarle, quando i dati sono espressi in forma di serie storica, si usano modelli più generali detti **modelli autoregressivi misti** o **ADL(p,q)** ("Autoregressive Distributed Lag"), definiti come segue:

$$Y_t = \beta_0 + \beta_1 Y_{t-1} + \cdots + \beta_p Y_{t-p} + \delta_0 X_t + \delta_1 X_{t-1} + \cdots + \delta_q X_{t-q} + \epsilon_t,$$

in cui la dinamica riguarda sia la parte autoregressiva (relativa a Y) sia la componente detta **a ritardi distribuiti** (legata a X).

(slide 57)

6.18. Le ipotesi per la stima OLS nei modelli dinamici: il problema dell'esogenità

Dimostrazione. Per fare inferenza è necessario prima verificare se sono soddisfatte le ipotesi per gli OLS. Si consideri ad esempio il modello AR(1)

$$Y_t = \beta Y_{t-1} + \epsilon_t.$$

Nel modello di regressione semplice deve valere, tra l'altro, $E[\epsilon_i|X_1, \dots, X_N] = 0, \ \forall i$. Nel contesto dinamico AR(1), l'unico regressore è $X_t \equiv Y_{t-1}$. La condizione di esogenità diviene quindi $E[\epsilon_t|Y_0, \dots, Y_{T-1}] = 0, \ \forall t$ (le slide scrivono $Y_1, \dots, Y_T$, ma i regressori delle T equazioni sono $Y_0, \dots, Y_{T-1}$).

Dimostrazione (l'esogenità stretta non vale nei modelli dinamici). Se vale $E[\epsilon_t|X_t] = E[\epsilon_t|Y_{t-1}] = 0$, allora $\text{Cov}[\epsilon_t, Y_{t-1}] = 0$. Si calcoli però

$$E[\epsilon_t X_{t+1}] = E[\epsilon_t Y_t] = E[\epsilon_t(\beta Y_{t-1} + \epsilon_t)] = \beta \underbrace{E[\epsilon_t Y_{t-1}]}_{=0 \text{ per ip.}} + E[\epsilon_t^2] \neq 0.$$

Quindi, nel caso di modelli dinamici, **non può essere utilizzata** l'ipotesi di stretta esogenità e non si può parlare di non distorsione (unbiasedness) dello stimatore OLS. È però ancora possibile dimostrare, sotto opportune ipotesi, che lo stimatore OLS è **consistente** (l'eventuale distorsione sparisce per T sufficientemente grande).

La sostituzione dell'ipotesi di indipendenza con la stazionarietà. Non si può utilizzare l'ipotesi di indipendenza del vettore $(Y, X_1, \dots, X_K)$: i dati in serie storica per loro natura non sono indipendenti. È comunque possibile indebolire tale ipotesi sostituendola con opportune condizioni di regolarità sulla forma di dipendenza, ad esempio richiedendo che la serie storica sia **stazionaria**.

Una serie storica è definita **stazionaria (debolmente)** se:

- la media di Y_t non dipende dal tempo, $E[Y_t] = \mu$;
- la varianza di Y_t non dipende da t, $\text{Var}(Y_t) = \sigma^2$;
- la struttura di dipendenza lineare dipende solo dalla distanza tra due osservazioni: $\text{Cov}(Y_s, Y_t) = \gamma_{t-s}$.

Un altro caso di endogenità: errore autocorrelato con endogena ritardata. Si consideri il modello

$$Y_t = \beta_1 + \beta_2 X_t + \beta_3 Y_{t-1} + \varepsilon_t, \qquad \varepsilon_t = \rho \varepsilon_{t-1} + \upsilon_t.$$

È vero che $E(Y_{t-1}\varepsilon_t) = 0$? Sostituendo,

$$Y_t = \beta_1 + \beta_2 X_t + \beta_3 Y_{t-1} + \underbrace{\rho \varepsilon_{t-1} + \upsilon_t}_{\varepsilon_t}.$$

Se $\rho \neq 0$, ε_t risulta chiaramente correlata con Y_{t-1} (poiché Y_{t-1} dipende, tramite la sua stessa equazione, da ε_{t-1}). Di conseguenza il modello non descrive una media condizionale corretta:

$$E(Y_t|X_t, Y_{t-1}) = \beta_1 + \beta_2 X_t + \beta_3 Y_{t-1} + \underbrace{E(\varepsilon_t|X_t, Y_{t-1})}_{\neq 0}.$$

OLS, di conseguenza, **non è consistente** in questo caso. □

(slide 58–61)

6.19. L'ipotesi di stazionarietà nel caso AR(1)

Dimostrazione. Si consideri il modello AR(1) definito da $Y_t = \beta_0 + \beta_1 Y_{t-1} + \epsilon_t$, con $\epsilon_t \sim WN(0, \sigma^2)$. Si cercano le condizioni sotto cui il modello risulta stazionario. Per semplicità si ipotizzi $\beta_0 = 0$; risolvendo all'indietro:

$$Y_t = \beta_1 \underbrace{Y_{t-1}}_{\beta_1 Y_{t-2} + \epsilon_{t-1}} + \epsilon_t = \beta_1^2 Y_{t-2} + \beta_1 \epsilon_{t-1} + \epsilon_t = \cdots = \sum_{j=0}^{\infty} \beta_1^j \epsilon_{t-j}.$$

Media. Si ha

$$E[Y_t] = \sum_{j=0}^{\infty} \beta_1^j E[\epsilon_{t-j}] = 0,$$

che non dipende da t.

Varianza. La varianza non dipende da t solo se $|\beta_1| < 1$:

$$\mathrm{Var}(Y_t) = \mathrm{Var}(\epsilon_t) \sum_{j=0}^{\infty} \beta_1^{2j} = \frac{\sigma^2}{1 - \beta_1^2}.$$

Nota: si ricordi che $\sum_{j=0}^{\infty} x^j = \frac{1}{1-x} \iff |x| < 1$. In questa applicazione $x \equiv \beta_1^2$.

Covarianza. La covarianza dipende unicamente dalla distanza tra le due osservazioni. Tramite opportune sostituzioni all'indietro si può scrivere

$$Y_t = \beta_1^s Y_{t-s} + \sum_{j=0}^{s-1} \beta_1^j \epsilon_{t-j},$$

per cui la covarianza tra Y_t ed Y_{t-s} risulta

$$\mathrm{Cov}(Y_t, Y_{t-s}) = E[Y_t Y_{t-s}] = E\left[\left(\beta_1^s Y_{t-s} + \sum_{j=0}^{s-1} \beta_1^j \epsilon_{t-j} \right) Y_{t-s} \right]$$

$$= \beta_1^s \mathrm{Var}[Y_{t-s}] + \sum_{j=0}^{s-1} \mathrm{Cov}(Y_{t-s}, \beta_1^j \epsilon_{t-j}) = \beta_1^s \mathrm{Var}(Y_t).$$

□

(slide 62–64)

6.20. Break strutturali e il test di Chow

Teorema 6.2. Quando si analizzano modelli di serie storiche, può succedere che un evento esterno modifichi il tipo di relazione tra variabile dipendente e regressore. I parametri del modello di regressione in un sotto-campione (ad esempio le prime T_1 osservazioni) possono essere diversi da quelli del secondo sotto-campione (le osservazioni da $T_1 + 1$ a T). Si parla in questi casi di **break strutturale**.

Si scelga, per fissare le idee, il modello ADL(1,1)

$$Y_t = \beta_0 + \beta_1 Y_{t-1} + \delta_0 X_t + \delta_1 X_{t-1} + \epsilon_t,$$

ipotizzando che un evento capace di causare un break strutturale sia avvenuto ad un tempo $\tau \in [1, T]$ **noto**.

Il test di Chow. Si vuole verificare se i parametri del modello per le osservazioni precedenti a τ sono diversi da quelli per le osservazioni successive. Si costruisce una variabile dummy $D_t(\tau)$:

$$D_t(\tau) = \begin{cases} 0 & \text{se } t \leq \tau \\ 1 & \text{se } t > \tau. \end{cases}$$

Il modello si riscrive come

$$Y_t = \beta_0 + \beta_1 Y_{t-1} + \delta_0 X_t + \delta_1 X_{t-1} + \gamma_0 D_t(\tau) + \gamma_1 D_t(\tau) Y_{t-1} + \gamma_2 D_t(\tau) X_t + \gamma_3 D_t(\tau) X_{t-1} + \epsilon_t,$$

che assume le due forme:

$$Y_t = \begin{cases} \beta_0 + \beta_1 Y_{t-1} + \delta_0 X_t + \delta_1 X_{t-1} + \epsilon_t & t \leq \tau \\ (\beta_0 + \gamma_0) + (\beta_1 + \gamma_1) Y_{t-1} + (\delta_0 + \gamma_2) X_t + (\delta_1 + \gamma_3) X_{t-1} + \epsilon_t & t > \tau. \end{cases}$$

Se non ci fosse rottura strutturale in τ, le funzioni di regressione prima e dopo tale data dovrebbero coincidere. Il test di Chow verifica sotto H_0 l'uguaglianza a zero dei parametri γ_i, $\forall i$, cioè $\gamma_0 = \gamma_1 = \gamma_2 = \gamma_3 = 0$. Se H_0 fosse vera, non si verificherebbe un cambiamento del modello in data τ. Dal punto di vista pratico si tratta di calcolare un'opportuna statistica F.

Il problema della data ignota e la statistica QLR. In generale non è nota a priori la data τ in cui si verificherà il break strutturale. Si può affrontare il problema calcolando il test di Chow per ogni potenziale valore di τ, ottenendo una sequenza di statistiche F_τ: la statistica F con valore più grande presumibilmente corrisponde al possibile break. La statistica **QLR** (Quandt Likelihood Ratio) è

$$QLR = \max\{F(\tau_0), \dots, F(\tau_1)\},$$

dove τ_0 e τ_1 escludono una quota iniziale e finale del campione, di solito il 15% come nell'esempio Exelon (le slide scrivono $F(1), \dots, F(T)$, ma agli estremi un sotto-campione è troppo piccolo per stimare i parametri). La distribuzione della statistica non è nota in forma chiusa, anche se è comunque possibile calcolare numericamente i p-value.

(slide 65–68)

6.21. Esempio: break strutturale nel titolo Exelon

Esempio 6.5. Si supponga di voler sottoporre a verifica il modello CAPM utilizzando gli extra-rendimenti mensili del titolo Exelon per il periodo 1991-2000, usando come proxy del mercato l'indice S&P 500.

La verifica del CAPM su tutto il periodo evidenzia come il β del titolo non sia significativamente diverso da zero (le slide dicono «nullo»; la stima è 0.0153, con $t = 0.089$) — risultato apparentemente strano. Un'analisi economica più dettagliata ha evidenziato come nel 1998, in corrispondenza di una breve crisi economica, il titolo Exelon abbia realizzato una serie di extra-rendimenti elevati in controtendenza con l'intero mercato. Ci si chiede quindi se nel 1998 si siano verificati break strutturali che spiegano un valore del β così anomalo.

Regressione sull'intero campione (extra-rendimenti dal 1991 al 2000). Stime OLS usando le 119 osservazioni 1991:02-2000:12, variabile dipendente: rend_exln

VARIABILE	COEFFICIENTE	ERRORE STD	STAT T	P-VALUE
const	0.00529475	0.00662467	0.799	0.42577
rend_mkt	0.0153368	0.171593	0.089	0.92893

Errore standard dei residui = 0.0722002; R-quadro = 6.82742e-005; R-quadro corretto = -0.00847815.

Test QLR. Test del rapporto di verosimiglianza di Quandt per break strutturale in un punto sconosciuto del campione, escludendo il 15 percento iniziale e finale: il massimo di $F(2, 115) = 7.6702$ corrisponde all'osservazione 1998:04, significativo al livello del 5 per cento (5% valore critico = 5.86). Il test suggerisce che la data τ più plausibile per il break strutturale corrisponde al mese di aprile 1998.

Regressione sul primo sottocampione (febbraio 1991 - marzo 1998, prima del break). Modello 2: stime OLS usando le 86 osservazioni 1991:02-1998:03, variabile dipendente: rend_exln

VARIABILE	COEFFICIENTE	ERRORE STD	STAT T	P-VALUE
const	-0.00507088	0.00580824	-0.873	0.38513
rend_mkt	0.582303	0.181555	3.207	0.00190 ***

Ora il β risulta significativamente diverso da 0.

Regressione sul secondo sottocampione (aprile 1998 - dicembre 2000, dopo il break). Stime OLS usando le 33 osservazioni 1998:04-2000:12, variabile dipendente: rend_exln

VARIABILE	COEFFICIENTE	ERRORE STD	STAT T	P-VALUE
const	0.0254586	0.0170836	1.490	0.14627
rend_mkt	-0.483655	0.328312	-1.473	0.15079

Ora il β risulta non significativo, ma solo in questo sottocampione (si verifichi che applicando il test QLR nei due sottocampioni non si verificano altri break).

(slide 69–73)

6.22. Trend deterministico e trend stocastico

Definizione 6.10. Le variabili economiche sono spesso influenzate da una componente detta **trend**, che rappresenta un movimento persistente di lungo periodo di una variabile nel corso del tempo. Esistono due tipi di trend, che producono effetti molto diversi sulle serie dei dati:

- **Trend deterministico**: la componente tendenziale è descritta da una funzione $g(\cdot)$ non aleatoria del tempo, ad esempio $g(t) = t$ oppure $g(t) = \alpha_1 t + \alpha_2 t^2 + \cdots + \alpha_p t^p$, con gli α_i costanti non aleatorie (le slide scrivono «noti»; in pratica sono incogniti e si stimano, ad esempio con OLS).
- **Trend stocastico**: la componente tendenziale varia nel tempo in maniera aleatoria; ad esempio può manifestarsi come un prolungato periodo di crescita della serie seguito da un prolungato periodo di stabilità o di decrescita.

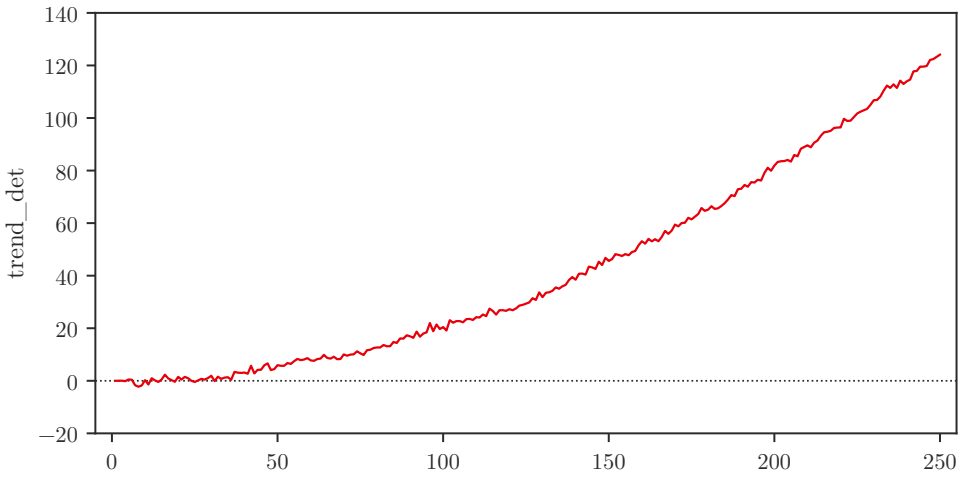


Figura 20 — Esempio di trend deterministico del tipo $Y_t = \alpha_0 + \alpha_1 t + \alpha_2 t^2 + \epsilon_t$: la serie cresce in modo regolare, curvilineo, con oscillazioni casuali di ampiezza contenuta attorno alla curva deterministica.

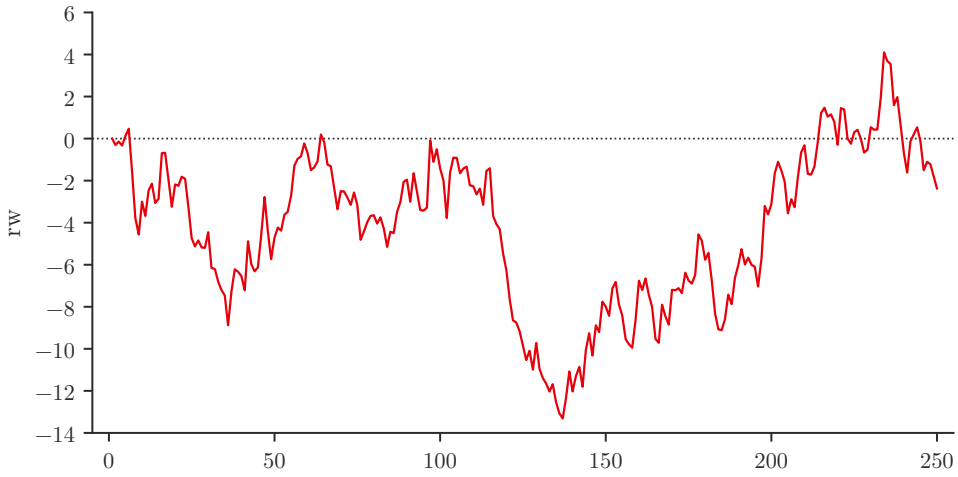


Figura 21 — Esempio di trend stocastico: la serie mostra fasi prolungate di crescita e decrescita irregolari, senza seguire un percorso deterministico prevedibile, scendendo fino a circa −13 nell'arco delle osservazioni mostrate.

(slide 74–76)

6.23. Il random walk e la sua non stazionarietà

Dimostrazione. In economia il caso più rilevante è quello dei trend stocastici, perché spesso non è credibile supporre che una serie storica economica sia predicibile in maniera deterministica. Uno dei modelli più semplici che generano trend stocastici è un AR(1) in cui $\beta_1 = 1$, detto **random walk**:

$$Y_t = Y_{t-1} + \epsilon_t.$$

L'idea di base è che quello che si osserverà domani, Y_{t+1}, sia uguale a quello che si osserva oggi, Y_t, più uno shock con media nulla. Tale modello sembra ragionevole soprattutto in applicazioni finanziarie, dove si pensa che la migliore previsione del prezzo di domani sia rappresentata dal prezzo osservato oggi (teoria dei mercati efficienti).

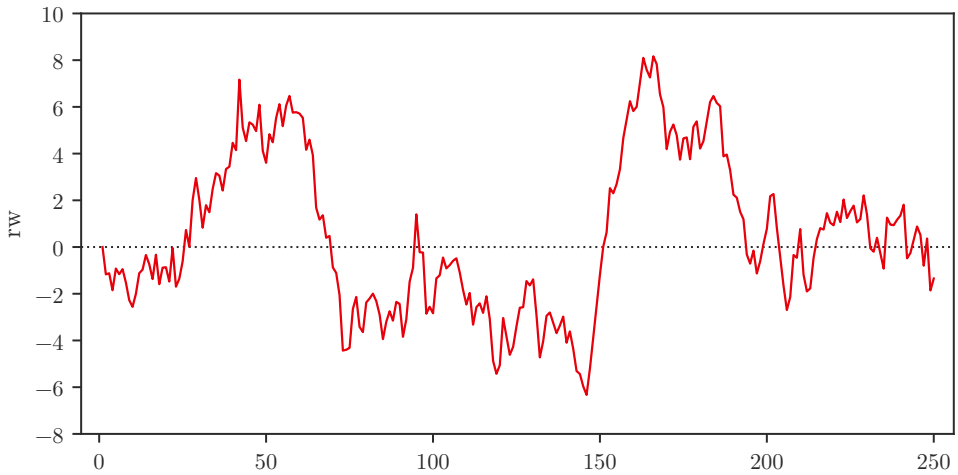


Figura 22 — Grafico di $Y_t = Y_{t-1} + \epsilon_t$: la serie mostra un tipico andamento "a deriva", con lunghe escursioni non prevedibili, muovendosi tra circa -6 e 8.

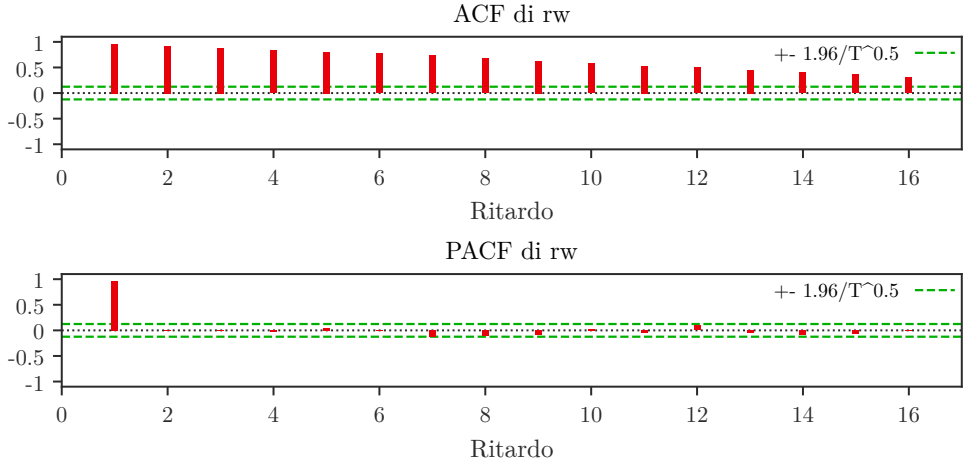


Figura 23 — Correlogramma di $Y_t = Y_{t-1} + \epsilon_t$: l'ACF decresce molto lentamente restando elevata anche a ritardi alti, mentre la PACF mostra un solo picco significativo al ritardo 1 — tipica "firma" di non stazionarietà.

Dimostrazione (il random walk non è stazionario). Il random walk è un caso particolare del modello AR(1) con $\beta_0 = 0, \beta_1 = 1$. Se fosse stazionario, si dovrebbe avere $\mathrm{Var}(Y_t) = \sigma_Y^2,\ \forall t$. Tuttavia

$$\mathrm{Var}(Y_t) = \mathrm{Var}(Y_{t-1}) + \mathrm{Var}(\epsilon_t),$$

condizione vera solo se $\mathrm{Var}(\epsilon_t) = 0$, il che è impossibile poiché $\mathrm{Var}(\epsilon_t) = \sigma^2$ per ipotesi.

Scrivendo Y_t in funzione degli errori passati, ipotizzando per semplicità $Y_0 = 0$, si ottiene

$$Y_1 = \epsilon_1, \quad Y_2 = Y_1 + \epsilon_2 = \epsilon_1 + \epsilon_2, \quad \dots, \quad Y_t = \epsilon_1 + \cdots + \epsilon_t = \underbrace{\sum_{j=1}^{t} \epsilon_j}_{\text{trend stocastico}}.$$

Quindi

$$\mathrm{Var}(Y_t) = \mathrm{Var}\left(\sum_{j=1}^{t} \epsilon_j\right) = t\sigma^2,$$

che dipende da t: la varianza diverge con t, e le autocorrelazioni non sono nemmeno definite (in senso teorico: $\mathrm{Corr}(Y_t, Y_{t-h}) = \sqrt{(t-h)/t}$ dipende da t e non solo dal ritardo h). Le autocorrelazioni campionarie però si possono comunque calcolare, e tendono ad essere prossime a uno anche ad elevati ritardi. □

(slide 77–81)

6.24. Random walk con drift

Definizione 6.11. Di frequente le serie economiche mostrano una tendenza sistematica. In questo caso una buona previsione non potrà essere data semplicemente dall'osservazione al tempo t, ma dovrà essere corretta per tenere conto della tendenza sistematica.

L'estensione più ovvia del modello random walk è il **Random Walk con drift**:

$$Y_t = \beta_0 + Y_{t-1} + \epsilon_t = \beta_0 t + Y_0 + \sum_{j=1}^{t} \epsilon_j.$$

- Se $\beta_0 > 0$ allora Y_t tenderà in media a crescere;
- Se $\beta_0 < 0$ allora Y_t tenderà in media a decrescere.

La previsione associata a questo modello è il valore osservato oggi più il drift β_0.

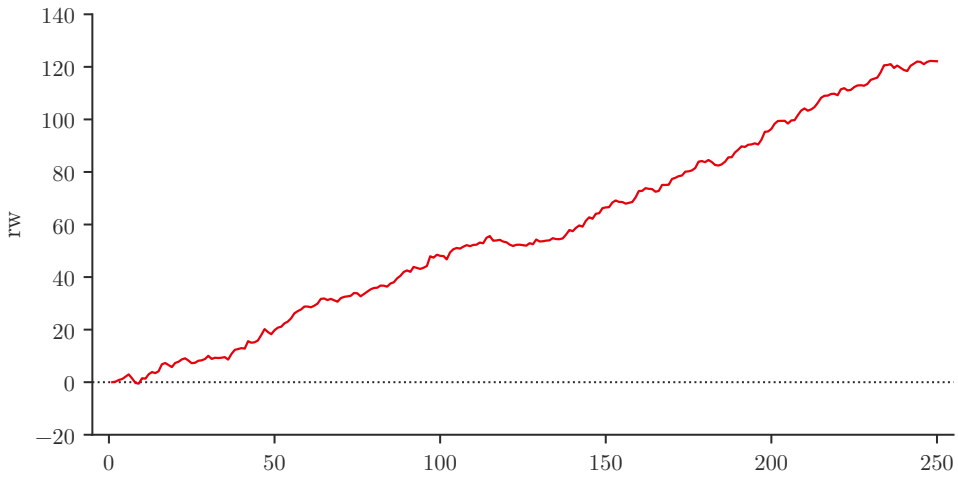


Figura 24 — Grafico di $Y_t = 0.5 + Y_{t-1} + \epsilon_t$: la serie mostra una crescita netta e progressiva, da circa 0 fino a circa 120, sovrapposta a fluttuazioni casuali di breve periodo — il drift positivo domina l'andamento di lungo periodo.

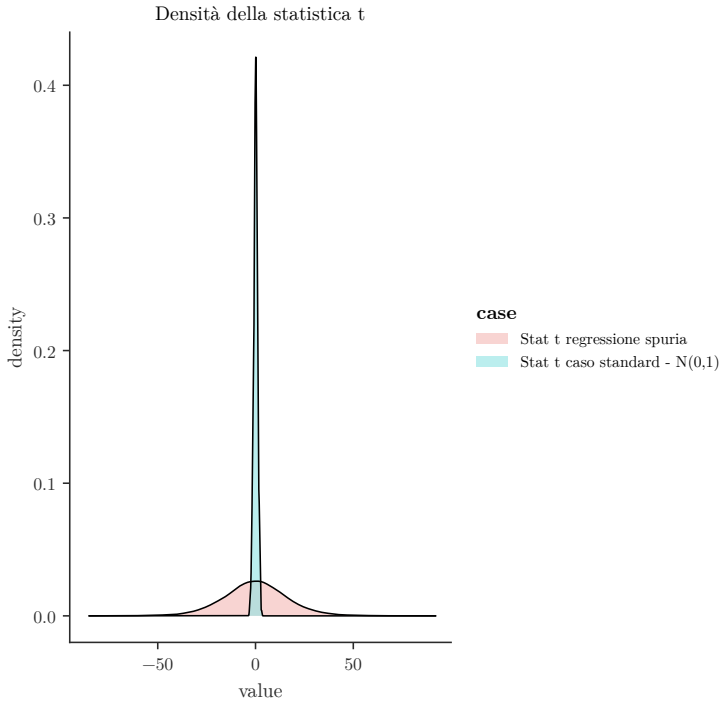
(slide 82–83)

6.25. Conseguenze dei trend stocastici per la stima OLS

Teorema 6.3. L'ipotesi di stazionarietà è necessaria per l'inferenza. La sua violazione ha due conseguenze:

1. Se un regressore X_{jt} ha un trend stocastico, la distribuzione della statistica $t = \dfrac{\hat{\beta}_j - \beta_{j0}}{\hat{\sigma}_{\hat{\beta}_j}}$ ha una distribuzione diversa da quella Gaussiana sotto H_0, con la conseguenza che l'abituale procedura di verifica d'ipotesi porta a risultati errati.

2. Se la serie Y_t è correttamente descritta da un modello random walk, ma per errore si stima un modello AR(1), si può dimostrare che lo stimatore è consistente ma **distorto**: infatti, per il modello con costante, $E[\hat{\beta}_1] \approx 1 - 5.3/T$. Inoltre, la distribuzione asintotica di $\hat{\beta}_1$ risulta non Gaussiana ed asimmetrica (verso lo zero).



Densità simulate con lo stesso esperimento dell'originale (regressione tra random walk indipendenti).

Figura 25 — Distribuzione della statistica t nel caso standard (area azzurra — $N(0,1)$) e nel caso in cui X ed Y sono random walk (area rosa), con $T = 500$: la densità dell'area rosa risulta molto più dispersa della Normale standard (la massa principale cade tra circa -40 e 40, contro l'intervallo ± 3 della $N(0,1)$), mostrando che la statistica t calcolata sotto trend stocastici non è confrontabile con i valori critici usuali di una $N(0,1)$.

(slide 84–85)

6.26. La regressione spuria

Teorema 6.4. Si consideri la regressione

$$Y_t = \beta_0 + \beta_1 X_t + \epsilon_t$$

in cui sia X_t che Y_t sono descritti da **random walk indipendenti**. Il vero valore di β_1 è 0 per costruzione. Si dimostra che:

- lo stimatore OLS $\hat{\beta}_1$ non converge a 0, ma ad una variabile casuale non Gaussiana e non necessariamente a media nulla;

- la statistica t ha una distribuzione molto lontana da una Normale standard (si veda la Figura 25);
- l'R^2 della regressione non tende a 0 né a 1, ma converge a una variabile casuale non degenere che può assumere valori elevati (le slide scrivono «tende a 1»; Phillips 1986 mostra un limite non degenere), e quindi il modello potrebbe sembrare avere un buon adattamento anche se non è correttamente specificato.

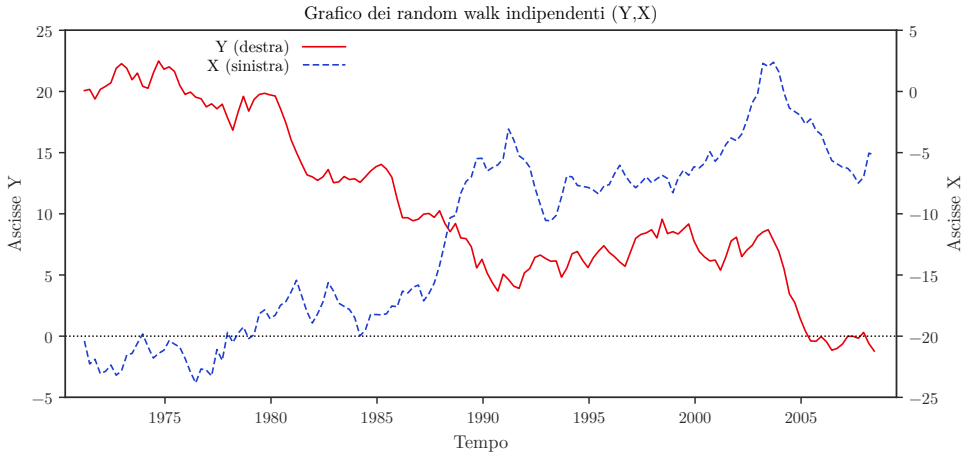


Figura 26 — Grafico delle serie storiche indipendenti (X, Y), entrambe simulate come random walk indipendenti dal 1971 al 2008: le due serie mostrano andamenti di lungo periodo apparentemente correlati (una cresce mentre l'altra decresce, o viceversa) pur essendo generate in modo completamente indipendente — l'illusione visiva alla base della regressione spuria.

Esempio numerico. Regressione tra Y ed X simulate al computer tramite due random walk indipendenti. Stime OLS usando le 150 osservazioni 1971:2-2008:3, variabile dipendente: Y, errori standard HAC (Kernel di Bartlett)

	coefficiente	errore std.	t-ratio	p-value
const	-2.99441	0.675510	-4.433	1.80E-05
X	-0.792102	0.0829947	-9.544	4.05E-017

Errore standard della regressione = 3.31238; R-quadro = 0.75623; R-quadro corretto = 0.75458.

Si noti che si rifiuta l'ipotesi nulla $H_0 : \beta_1 = 0$ — nonostante X e Y siano per costruzione indipendenti: è l'evidenza empirica del fenomeno della regressione spuria.

(slide 86–88)

6.27. Modelli per variabili non stazionarie: trend deterministico e stocastico

Definizione 6.12. La non stazionarietà di una serie può essere descritta da componenti deterministiche oppure stocastiche. Una formalizzazione generale è

$$Y_t = TD_t + Y_t^*,$$

dove: TD_t è la componente deterministica, che potrebbe essere una semplice costante $TD_t = \kappa$, una retta $TD_t = \kappa + \delta t$ oppure un polinomio di secondo grado $TD_t = \kappa + \delta t + \gamma t^2$; Y_t^* rappresenta la componente stocastica del processo generatore di Y_t; Y_t è la serie storica osservabile.

Se la componente stocastica Y_t^* è stazionaria, allora Y_t è detto **trend stazionario**, nel senso che il processo $Y_t - TD_t = Y_t^*$ è stazionario. In questi casi è possibile stimare la componente deterministica tramite OLS per poi descrivere la componente residuale (l'andamento di breve periodo) tramite un modello stazionario.

Se invece Y_t^* fosse un random walk, la componente di lungo periodo è descritta da

$$Y_t^* = \sum_{i=1}^{t} \epsilon_i + Y_0^*,$$

e si parla di presenza di **trend stocastico**.

Derivazione. Ipotizzando $Y_t^* = Y_{t-1}^* + \epsilon_t$ (random walk), con semplici passaggi algebrici il modello per Y_t diventa

$$Y_t = TD_t + Y_t^* = TD_t + Y_{t-1}^* + \epsilon_t = TD_t - TD_{t-1} + \underbrace{Y_{t-1}}_{Y_{t-1}^*} + \epsilon_t.$$

- Nel caso di trend deterministico costante, $TD_t = \kappa$, la serie originale è descritta da un random walk:
$$Y_t = Y_{t-1} + \epsilon_t.$$
- Nel caso di trend lineare, $TD_t = \kappa + \delta t$, si ricava un random walk con drift:
$$Y_t = \delta + Y_{t-1} + \epsilon_t = Y_0 + \delta t + \sum_{j=1}^{t} \epsilon_j.$$
- Nel caso di trend polinomiale di grado 2, si ottiene (le slide riportano $-2\gamma t$, segno errato: $TD_t - TD_{t-1} = \delta + \gamma(t^2 - (t-1)^2) = (\delta - \gamma) + 2\gamma t$)
$$Y_t = (\delta - \gamma) + 2\gamma t + Y_{t-1} + \epsilon_t.$$

(slide 89–92)

6.28. Verifica della non stazionarietà: il test di Dickey-Fuller

Teorema 6.5. Quando si usano serie storiche di dati economici, è necessario verificare se sono stazionarie. Esistono diversi test per verificare la presenza di una **radice unitaria**, cioè la presenza di una componente di tipo random walk nei dati.

Si consideri innanzitutto il modello AR(1),

$$Y_t = \beta_0 + \beta_1 Y_{t-1} + \epsilon_t, \qquad \text{Cov}(\epsilon_t, \epsilon_{t-j}) = 0, \ \forall j \geq 1.$$

Il random walk è un caso particolare di questo modello in cui $\beta_1 = 1$. L'idea alla base del test di **Dickey-Fuller (DF)** per verificare la non stazionarietà è di stimare il modello AR(1) e verificare il sistema d'ipotesi

$$H_0 : \beta_1 = 1 \quad \text{vs.} \quad H_1 : \beta_1 < 1.$$

Spesso in pratica risulta più utile considerare il modello AR(1) equivalente, riparametrizzato come

$$\Delta Y_t = \beta_0 + \delta Y_{t-1} + \epsilon_t, \qquad \delta = \beta_1 - 1,$$

con la conseguenza che l'ipotesi di interesse diventa

$$H_0 : \delta = 0 \quad \text{vs.} \quad H_1 : \delta < 0.$$

Il sistema di ipotesi si verifica tramite la solita statistica $t = \hat{\delta}/\hat{\sigma}_{\hat{\delta}}$. La distribuzione asintotica di tale statistica **non è una Normale standard** e dipende dal modello utilizzato per la stima di δ.

Ipotizzando che il vero processo generatore dei dati sia il random walk $Y_t = Y_{t-1} + \epsilon_t$, $\epsilon_t \sim WN(0, \sigma^2)$, la statistica t del test DF può essere calcolata sulla base di diversi modelli, ad esempio:

- $Y_t = \beta_1 Y_{t-1} + \epsilon_t$;
- $Y_t = \beta_0 + \beta_1 Y_{t-1} + \epsilon_t$.

Si può dimostrare che la distribuzione asintotica della statistica t dipende dal modello utilizzato (Figura 27). È comunque possibile calcolare per via numerica i valori critici ed i p-value; i pacchetti econometrici disponibili forniscono tali quantità.

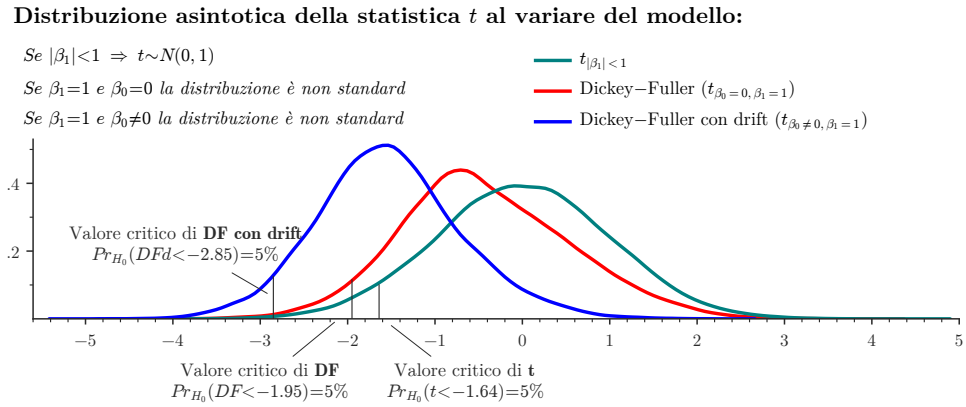


Figura 27 — Distribuzione asintotica della statistica t (o DF) al variare del modello: se $|\beta_1| < 1$, $t \to N(0,1)$; se $\beta_1 = 1, \beta_0 = 0$ la distribuzione è non standard (Dickey-Fuller, $t_{\beta_0=0,\beta_1=1}$); se $\beta_1 = 1, \beta_0 \neq 0$ la distribuzione è non standard (Dickey-Fuller con drift, $t_{\beta_0\neq 0,\beta_1=1}$); l'etichetta è quella delle slide: la curva «con drift» è la t del modello stimato con la costante β_0 quando il vero processo è un random walk senza drift, come nel testo, mentre con un vero drift $\beta_0 \neq 0$ la t calcolata con la costante sarebbe asintoticamente $N(0,1)$ (West 1988). Il grafico sovrappone le tre densità: la $N(0,1)$ è simmetrica e centrata in 0, mentre le due densità di Dickey-Fuller (senza e con drift) sono spostate verso sinistra (picco attorno a -0.7 senza drift e a -1.5 con drift) e asimmetriche, con coda sinistra più lunga. Il valore critico al 5% unilaterale a sinistra risulta -2.85 per il test DF con drift, -1.95 per il test senza drift, ed -1.64 per una $N(0,1)$ (i valori asintotici tabulati da MacKinnon sono -2.86 e -1.94 per i due test DF).

(slide 93–96)

6.29. Il test aumentato di Dickey-Fuller (ADF)

Dimostrazione. Il test DF fornisce una decisione corretta sulla non stazionarietà se la serie originale è descritta da un modello AR(1) con errori incorrelati, cioè $\text{Cov}(\epsilon_t, \epsilon_{t-j}) = 0, \ \forall j \geq 1$. In pratica questa ipotesi è spesso poco credibile. Nel caso di autocorrelazione dei residui, la distribuzione asintotica della statistica t risulta **non trattabile**.

Per ovviare a questo inconveniente è stato proposto il test **Augmented Dickey-Fuller (ADF)**, che estende il test DF a un modello autoregressivo generico di ordine p. Come prima, la statistica test verifica sotto H_0 la presenza di radici unitarie. Si ipotizzi che i dati seguano un processo AR(p):

$$Y_t = \beta_0 + \beta_1 Y_{t-1} + \cdots + \beta_p Y_{t-p} + \epsilon_t.$$

Una rappresentazione equivalente del modello, utile ai fini del calcolo del test, è

$$\Delta Y_t = \beta_0^* + \delta Y_{t-1} + \beta_1^* \Delta Y_{t-1} + \cdots + \beta_{p-1}^* \Delta Y_{t-p+1} + \epsilon_t.$$

In questa parametrizzazione $\delta = \beta_1 + \cdots + \beta_p - 1$ (le slide scrivono $\delta = \beta_1 - 1$, valido solo per $p = 1$, e indicizzano l'ultimo coefficiente come β_p^* invece di β_{p-1}^*). Il caso $\delta = 0$ è equivalente alla presenza di radice unitaria; se $\delta < 0$ vale la condizione di stazionarietà. L'alternativa è unilaterale, poiché se la serie fosse stazionaria δ risulterebbe negativo:

$$H_0 : \delta = 0 \quad \text{vs.} \quad H_1 : \delta < 0.$$

Dimostrazione (derivazione per un processo AR(2), $p = 2$).

$$Y_t = \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \epsilon_t = \phi_1 Y_{t-1} + (\phi_2 Y_{t-1} - \phi_2 Y_{t-1}) + \phi_2 Y_{t-2} + \epsilon_t$$

$$= (\phi_1 + \phi_2) Y_{t-1} - \phi_2 \Delta Y_{t-1} + \epsilon_t = \phi Y_{t-1} + \alpha \Delta Y_{t-1} + \epsilon_t \qquad (\phi \equiv \phi_1 + \phi_2,\ \alpha = -\phi_2).$$

Il primo regressore rappresenta il solito modello per il test DF; il secondo è la parte *augmented*, che se omessa introdurrebbe autocorrelazione nel termine d'errore della procedura standard del test DF.

Sotto l'ipotesi nulla, la statistica t si distribuisce seguendo una distribuzione non standard, che asintoticamente coincide con quella del test DF con le stesse componenti deterministiche (le slide scrivono «diversa rispetto al caso del modello AR(1)», ma i valori critici non dipendono da p: Said e Dickey 1984). Anche per il test ADF risulta possibile calcolare p-value e valori critici tramite simulazione.

Estensione: trend deterministico nel modello AR(p). Un'ulteriore generalizzazione consiste nell'ipotizzare un modello in cui, oltre alla componente AR(p), si aggiunge un trend deterministico:

$$Y_t = \beta_0 + \alpha_1 t + \alpha_2 t^2 + \beta_1 Y_{t-1} + \cdots + \beta_p Y_{t-p} + \epsilon_t.$$

Anche in questo caso è possibile calcolare la statistica test in maniera equivalente al caso precedente; quello che cambia in questa versione del test è la sua distribuzione asintotica. □

(slide 97–100)

6.30. Quale test di radice unitaria utilizzare?

Si ricordi che una serie storica può essere rappresentata dal modello $Y_t = TD_t + Y_t^*$. Risulta rilevante saper discriminare quale componente sia la causa della non stazionarietà, definendo un test che discrimini se una serie storica è (i) caratterizzata da trend stocastico, nel qual caso Y_t^* è assimilabile a un random walk; oppure (ii) da un trend deterministico, nel qual caso la componente TD_t risulta statisticamente significativa; oppure ancora (iii) se la non stazionarietà dipende da entrambi i fattori.

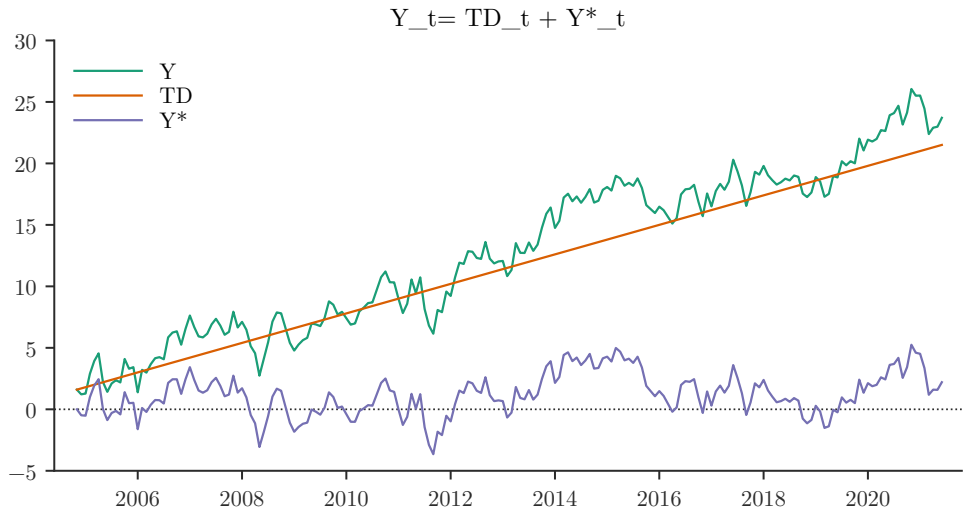


Figura 28 — $Y_t = TD_t + Y_t^*$: la linea verde Y_t rappresenta la serie osservata (con andamento crescente da circa 2 a fine 2004 fino a circa 24-26 nel 2021), rappresentata come combinazione del trend deterministico TD_t (retta arancione crescente) e della dinamica stocastica Y_t^* (serie viola senza trend, che oscilla tra circa -4 e 5).

Caso 1: trend deterministico costante. Si ipotizzi $TD_t = \kappa$ e $Y_t^* = \alpha Y_{t-1}^* + \epsilon_t$. Ne consegue che

$$Y_t = TD_t + Y_t^* = \kappa + \alpha Y_{t-1}^* + \epsilon_t = \kappa(1-\alpha) + \alpha Y_{t-1} + \epsilon_t.$$

Se fosse vera l'ipotesi nulla di non stazionarietà di Y_t^*, cioè $\alpha = 1$, si ottiene

$$Y_t = Y_{t-1} + \epsilon_t = Y_0 + \sum_{j=0}^{t-1} \epsilon_{t-j}.$$

Sotto la nulla, il modello diventa un random walk senza costante ma con valore iniziale Y_0 non necessariamente pari a 0.

Caso 2: trend deterministico lineare. Se $TD_t = \kappa + \delta t$,

$$Y_t = TD_t + Y_t^* = \kappa + \delta t + \alpha Y_{t-1}^* + \epsilon_t = \kappa(1-\alpha) + \delta\alpha + \delta(1-\alpha)t + \alpha Y_{t-1} + \epsilon_t.$$

Se fosse vera l'ipotesi nulla $\alpha = 1$, si ottiene

$$Y_t = \delta + Y_{t-1} + \epsilon_t,$$

cioè, sotto la nulla, un random walk con drift, con valore iniziale Y_0 non necessariamente pari a 0.

Regola approssimativa per decidere quale test utilizzare:

- se la serie storica non evidenzia un andamento tendenziale netto, si può usare il primo test (componente deterministica definita solo da una costante): sia sotto l'ipotesi nulla che sotto l'alternativa il processo ha media costante;

- se la serie storica evidenzia un andamento tendenziale di tipo lineare, si usa il secondo test: i processi compatibili sotto entrambe le ipotesi sono compatibili con un trend. Sotto la nulla il trend è causato dal drift del random walk; sotto l'alternativa è indotto dalla retta deterministica.

(slide 101–105)

6.31. La differenziazione come soluzione alla non stazionarietà

Il trend, o comunque gli andamenti di tipo evolutivo che spesso caratterizzano le serie economiche, impongono di apportare alcune trasformazioni ai dati prima di poterne fare un'analisi statistica corretta. La **differenziazione** dei dati costituisce una trasformazione tipica utilizzata per rendere stazionarie serie integrate del primo ordine, cioè serie le cui differenze sono stazionarie, per cui si considera

$$\Delta Y_t = \beta_0 + \beta_1 \Delta X_t + \epsilon_t.$$

In maniera analoga è possibile considerare la **differenza logaritmica**, anche se in questo caso i risultati devono essere interpretati in termini di tassi di crescita (o incrementi percentuali):

$$\Delta \log(Y_t) = \beta_0 + \beta_1 \Delta \log(X_t) + \epsilon_t.$$

(slide 106)

6.32. Riepilogo delle ipotesi OLS per le serie storiche e distribuzione asintotica

Teorema 6.6. Le ipotesi necessarie per ottenere stimatori OLS ottimali nel caso di modelli dinamici sono:

- il modello è lineare;
- il vettore (Y_t, X_t) è stazionario, ed inoltre la dipendenza seriale tra (Y_t, X_t) e (Y_{t-j}, X_{t-j}) diventa nulla per j grande;
- Y_t ed X_t possiedono almeno i primi 8 momenti;
- i regressori sono **esogeni**, nel senso che $E[\epsilon_t | X_{1,t}, \dots, X_{K,t}] = 0$;
- vale la condizione di **omoschedasticità**;
- non c'è perfetta collinearità.

Teorema (distribuzione asintotica per OLS). Se valgono le ipotesi precedenti, si dimostra che:

(i) lo stimatore $\hat{\beta}_j$ è **consistente**:

$$\hat{\beta}_j \xrightarrow{p} \beta_j \qquad \forall j;$$

(ii) lo stimatore $\hat{\beta}_j$ è **asintoticamente Normale**:

$$\hat{\beta}_j \overset{a}{\sim} N\left(\beta_j, \sigma^2_{\hat{\beta}_j}\right) \qquad \forall j;$$

(iii) la variabile casuale t, definita come $t = \dfrac{\hat{\beta}_j - \beta_j}{\hat{\sigma}_{\hat{\beta}_j}}$, converge ad una Normale standard:

$$t = \frac{\hat{\beta}_j - \beta_j}{\hat{\sigma}_{\hat{\beta}_j}} \xrightarrow{d} N(0,1);$$

(iv) lo stimatore $\hat{\sigma}_{\hat{\beta}_j}$ viene calcolato come nel caso del modello di regressione con errori omoschedastici.

(slide 107–108)

7 | Econometria — Introduzione alla Cointegrazione

Fonte: ECON_Teoria_07_Cointegrazione.pdf — *33 slide*

7.1. Motivazione: serie non stazionarie che si muovono insieme

Corso: Econometria — *Introduzione alla Cointegrazione*, Davide Raggi, 10 dicembre 2025.

Una variabile economica osservata come serie storica può avere un comportamento **non stazionario**, ma può evolvere in maniera simile ad altre variabili (a loro volta non stazionarie): pur essendo erratica, può **non discostarsi mai, in maniera sistematica, da altre**.

Questa evenienza può verificarsi quando più variabili tendono a muoversi attorno ad un **unico trend stocastico**. In questo caso, calcolando le differenze a coppie, queste tenderebbero ad essere stazionarie.

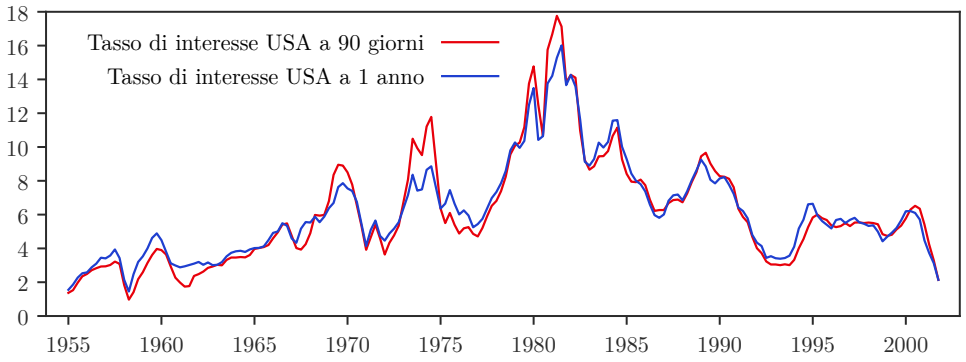


Figura 1 — Serie storiche dei tassi di interesse USA ad 1 anno ed a 90 giorni (rispettivamente $R1yr$ ed $R90$), dal 1955 al 2000. I trend stocastici tendono ad essere simili: le due serie si muovono in maniera pressoché parallela, come se condividessero lo stesso trend stocastico.

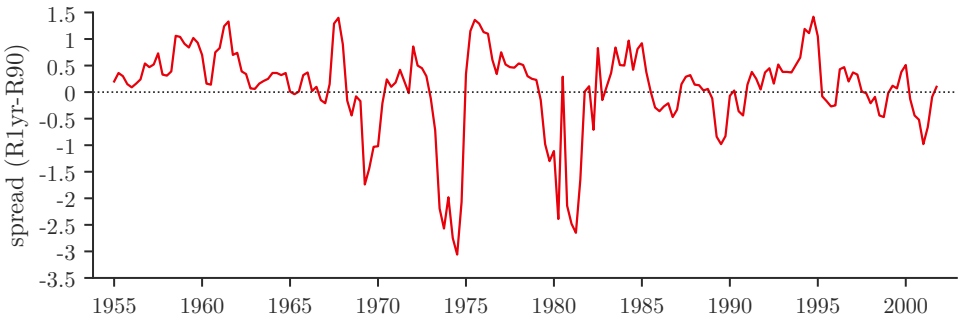


Figura 2 — La differenza tra tassi d'interesse, o spread $= (R1yr - R90)$, potrebbe sembrare un processo stazionario. Le serie di livello vagano senza un livello medio fisso; lo spread invece oscilla attorno a un valore vicino allo zero, senza trend persistente: la combinazione lineare delle due serie sembra stazionaria anche se le serie singole non lo sono. *(slide 1–4)*

7.2. Definizione di cointegrazione: combinazione lineare stazionaria

Definizione 7.1. Dall'esempio precedente sembrerebbe che la differenza tra due serie X ed Y, definita come $\epsilon_t = Y_t - X_t$, risulti essere stazionaria. In generale si può considerare una **generica combinazione lineare stazionaria** di X ed Y:

$$\epsilon_t = \beta_1 Y_t - \beta_2 X_t \propto Y_t - \underbrace{\frac{\beta_2}{\beta_1}}_{=\beta} X_t = Y_t - \beta X_t$$

Tale relazione tra X ed Y, essendo stazionaria, può essere interpretata come **stabile nel tempo**, o **di lungo periodo**. Il legame vale anche se il comportamento individuale di ogni serie risulta non stazionario. Si dice in questo caso che le variabili **co-integrano**, nel senso che sono integrate (non stazionarie), ma vagano attorno ad un unico trend stocastico.

Una prima soluzione al problema della regressione spuria sarebbe analizzare la relazione tra le serie differenziate:

$$\Delta Y_t = \beta_0 + \beta_1 \Delta X_t + \epsilon_t$$

Tuttavia questo modo di procedere può non essere soddisfacente, perché si perdono tutte le informazioni sul comportamento dei **livelli** delle variabili nel lungo periodo, che rappresentano spesso uno degli obiettivi dell'analisi econometrica. La cointegrazione si presta bene all'analisi economica, in quanto permette di formalizzare opportune relazioni tra variabili di lungo periodo, nel contesto di un modello economico teorico.

(slide 5–6)

7.3. Esempio: due random walk con trend stocastico comune

Esempio 7.1. Si considerino due random walk X_t ed Y_t:

$$Y_t = Y_{t-1} + \epsilon_{y,t} = \sum_{j=1}^{t} \epsilon_{y,j}$$

$$X_t = X_{t-1} + \epsilon_{x,t} = \sum_{j=1}^{t} \epsilon_{x,j}$$

Di solito, una combinazione lineare di due variabili non stazionarie X ed Y risulta **non stazionaria**, e quindi problematica dal punto di vista inferenziale.

Tuttavia, si ipotizzi la situazione in cui $\epsilon_{y,j} = \theta\epsilon_{x,j}$. Come conseguenza si avrà che $Y_t = \theta X_t$. In questo caso si dice che Y_t ed X_t condividono lo stesso trend stocastico, in quanto

$$Y_t = \theta \sum_{j=1}^{t} \epsilon_{x,j} \qquad \text{ed} \qquad X_t = \sum_{j=1}^{t} \epsilon_{x,j}$$

Ne segue che $Y_t - \theta X_t = 0$, relazione che rappresenta, dal punto di vista economico, una situazione di **equilibrio** tra le due variabili, per qualsiasi valore di t.

Più in generale, se si mantiene l'ipotesi che $\epsilon_{x,t}$ ed $\epsilon_{y,t}$ siano proporzionali, ma non IID (ad esempio autocorrelate), la sequenza di deviazioni dall'equilibrio potrebbe essere espressa da

$$\epsilon_t = Y_t - \theta X_t$$

in cui ϵ_t non è sistematicamente nulla ma risulta **stazionaria**.

Definizione. Si dice che X ed Y sono **cointegrate** se esiste una loro opportuna combinazione lineare che è stazionaria. Tale definizione può essere generalizzata ad una n-pla di variabili $(Y, X_1, \dots, X_{n-1})$.

Dal punto di vista statistico ha quindi senso pensare di stimare il parametro θ, che rappresenta il legame stabile nel tempo tra oggetti che individualmente sono instabili, ma congiuntamente stabili (le slide scrivono «ma congiuntamente lo sono», che letteralmente direbbe «instabili»).

(slide 7–9)

7.4. Stima OLS in presenza di cointegrazione: superconsistenza

Teorema 7.1. Siano X ed Y non stazionarie e cointegrate, e si vuole stimare

$$Y_t = \beta_0 + \beta_1 X_t + \epsilon_t$$

Per questo modello, pur essendo le variabili non stazionarie, si dimostra che lo stimatore OLS di β_1 è **superconsistente**, nel senso che

$$(\hat{\beta}_1 - \beta_1) \xrightarrow{p} 0$$

più velocemente rispetto allo stimatore OLS calcolato nelle ipotesi del modello di regressione con variabili stazionarie.

La distribuzione asintotica di $\hat{\beta}_1$ tuttavia **non è Gaussiana**. Tale distribuzione dipende dalle ipotesi che vengono fatte sul termine di errore ϵ_t, che comunque deve rimanere stazionario. In generale, si dimostra che la statistica t **non si distribuisce come una normale standard**. Un caso particolare, in cui vale l'approssimazione alla Normale, si ha quando ϵ_t ed $\epsilon_{x,t}$ sono serialmente e mutualmente incorrelati.

(slide 10)

7.5. Lo stimatore DOLS (Dynamic OLS)

Definizione 7.2. In termini pratici, con variabili cointegrate si ottengono stime puntuali molto accurate grazie alla superconsistenza. Non si possono però costruire statistiche test opportune, a causa della distribuzione asintotica non standard della statistica t.

Una soluzione è stata proposta da **Stock e Watson (1993)** con lo stimatore **DOLS (Dynamic Ordinary Least Squares)** per β_1. Tale stimatore si basa sulla stima OLS della regressione aumentata:

$$Y_t = \beta_0 + \beta_1 X_t + \underbrace{\gamma_0 \Delta X_t + \gamma_{-1} \Delta X_{t-1} + ... + \gamma_{-\ell_T} \Delta X_{t-\ell_T}}_{\text{lags}} + \underbrace{\gamma_1 \Delta X_{t+1} + ... + \gamma_{\ell_T} \Delta X_{t+\ell_T}}_{\text{leads}} + \epsilon_t^*$$

Il parametro ℓ_T indica il numero di regressori da aggiungere al modello originale (più precisamente, il numero di ritardi e di anticipi di ΔX: in tutto $2\ell_T + 1$ termini, contando ΔX_t). Il valore di ℓ_T dipende dalla numerosità campionaria T.

Si noti che i parametri di interesse nel modello aumentato sono solamente β_0 e β_1. Gli altri regressori hanno uno scopo puramente tecnico: servono ad eliminare l'effetto dovuto all'eventuale autocorrelazione di $\epsilon_{x,t}$.

Anche in questo caso la distribuzione asintotica dello stimatore DOLS $\hat{\beta}_1$ risulta **non Gaussiana**. In generale i residui del modello rimangono autocorrelati. Occorre quindi utilizza-

re uno stimatore consistente per gli errori standard che tenga conto dell'autocorrelazione e dell'eteroschedasticità (ad es. **Newey-West** o **HAC**).

La statistica t si distribuisce come una variabile casuale Normale standard sotto l'ipotesi nulla, con la conseguenza che l'inferenza può essere condotta come al solito.

(slide 11–12)

7.6. Test di cointegrazione di Engle-Granger (CDF)

Definizione 7.3. La presenza di una relazione di cointegrazione permette di derivare una corretta inferenza nel modello di regressione anche nel caso in cui le variabili in esame siano non stazionarie. Serve quindi un modo per accertare se, con variabili non stazionarie, questa relazione esiste.

Si consideri la relazione di lungo periodo

$$\epsilon_t = Y_t - \theta X_t$$

Se le variabili X ed Y condividessero lo stesso trend stocastico, ne risulterebbe la stazionarietà di ϵ_t e di conseguenza un test di radice unitaria rifiuterebbe l'ipotesi nulla. Un'idea per verificare la presenza di cointegrazione potrebbe basarsi sulla verifica dell'assenza di radice unitaria per ϵ_t.

Il processo ϵ_t risulta tuttavia non osservabile. Si ricordi però che gli stimatori OLS e DOLS $\hat{\theta}$ sono superconsistenti per θ, e quindi $\hat{\epsilon}_t = Y_t - \hat{\theta} X_t$ è consistente per ϵ_t.

L'idea di **Engle e Granger (1987)** per verificare la presenza di cointegrazione è dunque quella di calcolare un test di radice unitaria per la serie dei residui $\hat{\epsilon}_t$, ad esempio il test **Dickey-Fuller per la Cointegrazione (CDF)**.

NOTA: la distribuzione asintotica della statistica CDF cambia a seconda che nella relazione di lungo periodo sia inserita l'intercetta oppure no, e differisce da quella dei test di radice unitaria classici. I principali software econometrici gestiscono automaticamente tali differenze.

(slide 13–14)

7.7. Esempio applicato: cointegrazione tra tassi di interesse USA (r3 e r60)

Esempio 7.2. Si vuole verificare se le due serie storiche dei tassi di interesse USA, cioé $r3$ (tasso a 3 mesi) ed $r60$ (tasso a 5 anni), sono cointegrate. Occorre:

1. Verificare se $r3$ e $r60$ sono non stazionarie (integrate);
2. Stimare l'eventuale relazione di cointegrazione tramite OLS: $r60_t = a + b\, r3_t + \epsilon_t$;

3. Verificare se i residui della regressione $\hat{\epsilon}_t$ sono stazionari (tramite un opportuno test di tipo ADF).

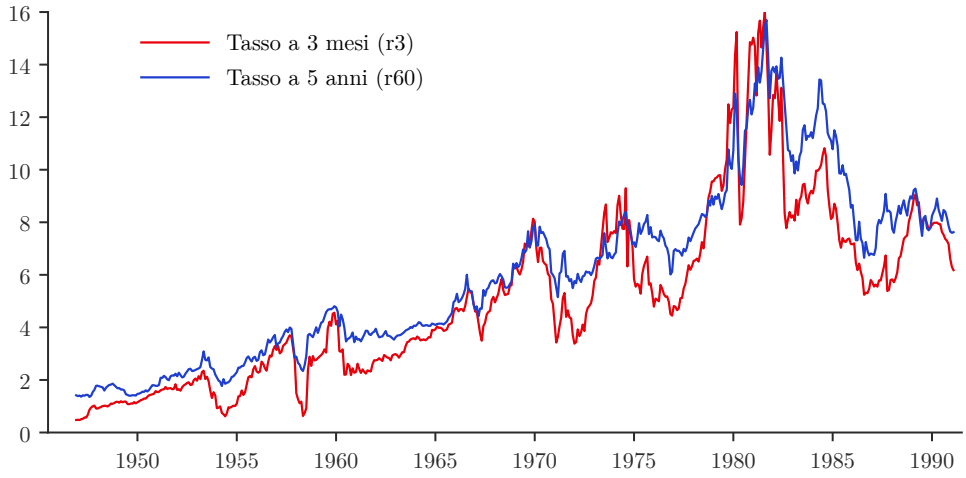


Figura 3 — Tassi USA a 3 mesi ed a 5 anni osservati da Dicembre 1946 a Febbraio 1991 (le slide riportano 1992, ma il campione è 1946:12-1991:02, $T = 531$ osservazioni mensili, tante quante ne contiene il dataset). Le due serie ($r3$ e $r60$) hanno andamenti simili, con picchi comuni (in particolare attorno al 1980): la cointegrazione è plausibile.

Passo 1 — Test ADF sulle singole serie. I test ADF evidenziano che entrambe le serie sono non stazionarie:

Serie	Ritardi di (1-L) inclusi	Specificazione	p-value asintotico
r3	8	Test con costante	0.3643
r60	7	Test con costante	0.5203

Passo 2 — Stima della relazione di cointegrazione. OLS, usando le osservazioni 1946:12-1991:02 ($T = 531$), variabile dipendente $r60$:

	coefficiente	errore std.	rapporto t	p-value
const	1.09161	0.0755948	14.44	4.36e-40 ***
r3	0.952326	0.0124198	76.68	1.06e-288 ***

E.S. della regressione: 0.939385. R-quadro: 0.917454. R-quadro corretto: 0.917298.

Si stimano quindi i residui del modello $\hat{\epsilon}_t$.

Passo 3 — Test CDF sui residui. Si calcola da: Modello ⇒ Serie Storiche Multivariate ⇒ Test di Cointegrazione (Engle-Granger). Vengono riportati i test di stazionarietà delle serie storiche individuali, la relazione di cointegrazione eventuale e l'opportuno test ADF sui residui

(di seguito solo l'ultimo passo, poiché i risultati dei passi precedenti coincidono con quelli già mostrati).

Passo 4 — Test per una radice unitaria in uhat. Test Dickey-Fuller aumentato per uhat, inclusi 12 ritardi di (1-L)uhat, ampiezza campionaria 518. Ipotesi nulla di radice unitaria: $a = 1$.

Modello: $(1 - L)y = b_0 + (a - 1)y_{(-1)} + ... + e$

- Coefficiente di autocorrelazione del prim'ordine per e: -0.000
- Differenze ritardate: $F(12, 505) = 1.793$ [0.0464]
- Valore stimato di $(a - 1)$: -0.0744308
- Statistica test: $\tau_c(2) = -3.44665$
- p-value asintotico: 0.03747

Il p-value del test CDF sui residui è basso (0.03747, sotto il 5% ma non sotto l'1%), per cui si rifiuta l'ipotesi nulla di radice unitaria nei residui: $r3$ ed $r60$ risultano **cointegrate**.

(slide 15–20)

7.8. Dal modello ADL(1,1) al Modello a Correzione dell'Errore (ECM)

Dimostrazione. I modelli ADL possono essere utilizzati per descrivere ipotesi di teoria economica in cui esiste una relazione di **equilibrio di lungo periodo** tra variabili. Ad esempio potrebbe valere una relazione lineare del tipo $Y = a + bX$.

Si riconsideri il modello ADL(1,1):

$$Y_t = \kappa + \alpha_1 Y_{t-1} + \beta_0 X_t + \beta_1 X_{t-1} + \epsilon_t$$

È possibile riparametrizzare il modello sottraendo Y_{t-1} e sommando/sottraendo $\beta_0 X_{t-1}$:

$$Y_t - Y_{t-1} = \kappa + \alpha_1 Y_{t-1} - Y_{t-1} + \beta_0 X_t + \beta_1 X_{t-1} + \beta_0 X_{t-1} - \beta_0 X_{t-1} + \epsilon_t$$

$$= \beta_0 \Delta X_t + (\alpha_1 - 1)\left(Y_{t-1} - \underbrace{\frac{\kappa}{1 - \alpha_1}}_{=a} - \underbrace{\frac{\beta_0 + \beta_1}{1 - \alpha_1}}_{=b} X_{t-1} \right) + \epsilon_t$$

In sintesi il modello ADL(1,1) può essere riparametrizzato come

$$\Delta Y_t = \beta_0 \Delta X_t + (\alpha_1 - 1) \underbrace{(Y_{t-1} - a - bX_{t-1})}_{\text{disequilibrio a } t-1} + \epsilon_t$$

Il modello così definito evidenzia un **meccanismo a correzione dell'errore**. In particolare una variazione della variabile dipendente viene spiegata da una variazione del regressore X_t e dall'eventuale scostamento dall'equilibrio (disequilibrio) realizzatosi nel periodo precedente. Anche ipotizzando che $\Delta X_t = 0$ e che $\epsilon_t = 0$, la variazione di Y_t risulta diversa da 0 in virtù del fatto che $Y_{t-1} \neq a + bX_{t-1}$ (le slide scrivono cX_{t-1}, simbolo mai definito: la relazione di lungo periodo è $Y = a + bX$).

La velocità del ritorno all'equilibrio statico dipende dal valore del coefficiente $(\alpha_1 - 1)$. □

(slide 21–22)

7.9. Interpretazione del coefficiente di aggiustamento e dinamica di ritorno all'equilibrio

Dimostrazione. Per interpretare $\alpha_y = \alpha_1 - 1$, si ipotizzi che il regressore sia stabile nel tempo, quindi $X_{t-1} = X_t = X_{t+1} = X_{t+2} = ...$, che $\epsilon_t = 0$ e, per semplicità, che $a = 0$ e $Y_{t-1} - bX_{t-1} \neq 0$.

$$\Delta Y_t = \underbrace{\beta_0 \Delta X_t}_{=0} + \alpha_y (Y_{t-1} - bX_{t-1})$$

$$\Rightarrow Y_t = Y_{t-1} + \alpha_y (Y_{t-1} - bX_{t-1})$$

$$\Rightarrow Y_t - bX_t = Y_{t-1} + \alpha_y (Y_{t-1} - bX_{t-1}) - \underbrace{bX_t}_{=bX_{t-1} \text{ per ip.}} = (1 + \alpha_y)(Y_{t-1} - bX_{t-1})$$

$$\Rightarrow \Delta Y_{t+1} = \beta_0 \Delta X_{t+1} + \alpha_y (Y_t - bX_t) = \alpha_y (1 + \alpha_y)(Y_{t-1} - bX_{t-1})$$

$$\Rightarrow \Delta Y_{t+2} = \alpha_y (Y_{t+1} - bX_{t+1}) = \alpha_y (1 + \alpha_y)^2 (Y_{t-1} - bX_{t-1})$$

Tipicamente, osservando valori di $\alpha_y < 0$, ci si attende che il ritorno ad un nuovo equilibrio arrivi ad un tasso di $\alpha_y (1 + \alpha_y)^j$. Il ri-equilibrio si otterrebbe se $\Delta Y_{t+j} = 0$ ed in particolare

$$\Delta Y_{t+j} = \alpha_y (1 + \alpha_y)^j (Y_{t-1} - bX_{t-1})$$

(Le slide scrivono $Y_{t+j-1} - bX_{t+j-1}$ e ΔY_{t+h}: incoerente con i passaggi precedenti, dove il fattore $(1 + \alpha_y)^j$ moltiplica il disequilibrio iniziale a $t - 1$; con il disequilibrio a $t + j - 1$ non comparirebbe alcuna potenza.)

Quando $\Delta Y_{t+j} = 0$, il disequilibrio passato è stato riassorbito completamente dal sistema (non essendoci altre variabili che possono aver influenzato la dipendente, in particolare shock e regressori esogeni, che sono fissati). □

(slide 23–24)

7.10. Esempio applicato: ECM per i tassi di interesse USA

Esempio 7.3. In precedenza è stato verificato come i tassi d'interesse USA a 3 mesi ed a 5 anni fossero legati da una relazione di cointegrazione. Si può quindi definire un modello a correzione dell'errore per descrivere tale relazione:

$$\underbrace{\Delta r60_t}_{} = \beta_1 \underbrace{\Delta r3_t}_{\text{staz.}} + \alpha \underbrace{(r60_{t-1} - a - b\, r3_{t-1})}_{\text{staz. se coint.}} + \epsilon_t$$

Per stimare questo modello occorre conoscere $r60_{t-1} - a - br3_{t-1}$. Ma questi non sono altro che i residui della relazione di cointegrazione calcolati ad un ritardo. Quindi per stimare il modello a correzione dell'errore è sufficiente definire $\Delta r3_t$, $\Delta r60_t$ ed $\hat{\epsilon}_{t-1}$.

Procedura operativa (gretl):

- Le variabili $\Delta r3_t$ e $\Delta r60_t$ si calcolano dal menu Aggiungi ⇒ Differenze delle Variabili Selezionate.
- I residui $\hat{\epsilon}_t$ si stimano a partire dall'output standard del modello di regressione $r60_t = a + br3_t + \epsilon_t$, usando il menu Salva ⇒ Residui ⇒ Nome dei residui.
- Il modello ECM si stima dal menu Modello ⇒ OLS, definendo i regressori e la variabile dipendente. Per includere il ritardo di $\hat{\epsilon}_t$ basta usare l'opzione Ritardi e definire 1 sia come ritardo minimo che come ritardo massimo.

Risultato. OLS, usando le osservazioni 1947:01-1991:02 ($T = 530$), variabile dipendente d_r60:

	coefficiente	errore std.	rapporto t	p-value
const	0.00691546	0.0116796	0.5921	0.5540
d_r3	0.438546	0.0216191	20.29	4.80e-68 ***
uhat_1	-0.0658423	0.0124831	-5.275	1.95e-07 ***

E.S. della regressione: 0.268831.

Il coefficiente di $uhat_1$ suggerisce che un disequilibrio osservato a $t-1$ viene assorbito nella misura di circa 0.066 punti percentuali al periodo t per ogni punto percentuale di scostamento, cioè circa il 6.6% del disequilibrio per mese (le slide riportano 0.065, ma il coefficiente è -0.0658423).

(slide 25–27)

7.11. La rappresentazione VECM (Vector Error Correction Mechanism)

Dimostrazione. Le relazioni di cointegrazione si prestano bene ad analizzare modelli di equilibrio economico nel contesto di modelli dinamici. Si consideri ad esempio un modello **multivariato**, che descrive congiuntamente la dinamica di due variabili non stazionarie X ed Y:

$$X_t = \delta_x + \phi_{11} X_{t-1} + \phi_{12} Y_{t-1} + \epsilon_{x,t}$$

$$Y_t = \delta_y + \phi_{22} Y_{t-1} + \phi_{21} X_{t-1} + \epsilon_{y,t}$$

Alcuni passaggi algebrici permettono di riparametrizzare il modello come segue:

$$\Delta X_t = \delta_x + \phi_{12}(Y_{t-1} - \beta_x X_{t-1}) + \epsilon_{x,t}$$

$$\Delta Y_t = \delta_y - (1 - \phi_{22})(Y_{t-1} - \beta_y X_{t-1}) + \epsilon_{y,t}$$

(Le slide riportano $-\phi_{12}$ nella prima equazione; dal modello per X_t scritto sopra il segno risulta $+\phi_{12}$, con $\beta_x = (1 - \phi_{11})/\phi_{12}$, e $\beta_y = \phi_{21}/(1 - \phi_{22})$. Di conseguenza nella forma finale $\alpha_x = -\phi_{12}$.)

ΔX_t, ΔY_t, $\epsilon_{x,t}$ ed $\epsilon_{y,t}$ sono stazionari per costruzione. Il modello risulta ben definito solo se $(Y_{t-1} - \beta_x X_{t-1})$ e $(Y_{t-1} - \beta_y X_{t-1})$ sono stazionarie. Di conseguenza deve esistere una relazione di cointegrazione tra X ed Y.

È possibile dimostrare che, nel caso di soli due processi cointegrati, tutti i possibili coefficienti di cointegrazione sono **proporzionali**. Questo consente di ottenere $\beta_x = \beta_y = \beta$ e quindi:

$$\Delta X_t = \delta_x - \alpha_x(Y_{t-1} - \beta X_{t-1}) + \epsilon_{x,t}$$

$$\Delta Y_t = \delta_y - \alpha_y(Y_{t-1} - \beta X_{t-1}) + \epsilon_{y,t}$$

Questo modello è definito **Meccanismo a Correzione dell'Errore Vettoriale**, o **VECM** (Vector Error Correction Mechanism). □

(slide 28–29)

7.12. VECM semplificato e interpretazione economica dell'aggiustamento

Esempio 7.4. Per capire come funziona in pratica il meccanismo di correzione dell'errore, è utile considerare il seguente sistema VECM semplificato, in cui $\delta_x = \delta_y = \alpha_x = 0$ e $\alpha_y > 0$:

$$\Delta X_t = \epsilon_{x,t}$$

$$\Delta Y_t = -\alpha_y(Y_{t-1} - \beta X_{t-1}) + \epsilon_{y,t}$$

In questo caso la variazione attesa ΔY_t risulta

$$E[\Delta Y_t \,|\, \text{passato}] = -\alpha_y(Y_{t-1} - \beta X_{t-1})$$

quindi dipende dal disequilibrio osservato nel periodo precedente. Se le variabili sono espresse in termini logaritmici, i risultati vanno interpretati in termini di variazioni percentuali o tassi di crescita.

Sulla base del modello precedente si possono verificare 3 possibili situazioni:

(a) **Nessun disequilibrio a** $t-1$, cioé $Y_{t-1} = \beta X_{t-1}$, per cui $E[Y_t \,|\, \text{passato}] = Y_{t-1}$. Se a $t-1$ si osserva equilibrio, ci si aspetta che le variabili rimangano in tale situazione.

(b) $Y_{t-1} > \beta X_{t-1}$: ci si attende una variazione negativa di Y. Per compensare un disequilibrio positivo occorre che Y_t decresca per tornare in equilibrio.

(c) $Y_{t-1} < \beta X_{t-1}$: ci si trova in una situazione sotto il livello di equilibrio; per compensare a tale situazione ci si aspetta che Y cresca.

La velocità con cui si ritorna ad un livello di equilibrio è determinata dal coefficiente $\alpha_y > 0$.

(slide 30–31)

7.13. Esempio: ritorno all'equilibrio nel VECM semplificato

Esempio 7.5. Si consideri il modello semplificato definito in precedenza. Si ipotizzi:

- Viene osservato un disequilibrio iniziale pari a $(Y_{t-1} - \beta X_{t-1}) = 2$;
- X sia costante nel tempo, quindi $X_{t-1} = X_t = ... = X_{t+j}$, ed $\epsilon_{y,t} = 0,\ \forall t$.

$$\Delta Y_t = -\alpha_y(Y_{t-1} - \beta X_{t-1}) \ \Rightarrow\ Y_t = Y_{t-1} - \alpha_y(Y_{t-1} - \beta X_{t-1})$$

$$\Rightarrow Y_t - \beta X_t = (1-\alpha_y)(Y_{t-1} - \beta X_{t-1})$$

$$\Rightarrow \Delta Y_{t+1} = -\alpha_y(1-\alpha_y)(Y_{t-1} - \beta X_{t-1})$$

Analogamente si ottiene

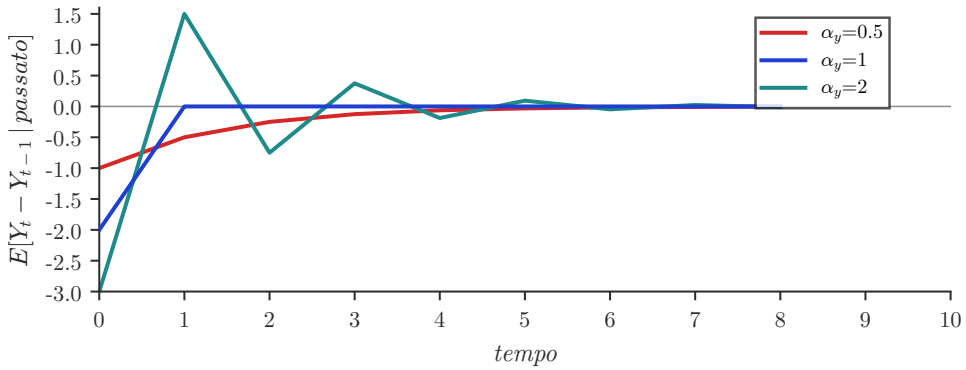
$$Y_{t+1} - \beta X_{t+1} = (1-\alpha_y)(Y_t - \beta X_t) \;\Rightarrow\; \Delta Y_{t+2} = -\alpha_y(1-\alpha_y)(Y_t - \beta X_t)$$

In generale, infine,

$$Y_{t+j} - \beta X_{t+j} = (1-\alpha_y)(Y_{t+j-1} - \beta X_{t+j-1})$$

$$\Rightarrow \Delta Y_{t+j+1} = -\alpha_y(1-\alpha_y)(Y_{t+j-1} - \beta X_{t+j-1}), \quad \forall j \geq 0$$

(Le slide scrivono la ricorsione al contrario, $Y_{t+j-1} - \beta X_{t+j-1} = (1-\alpha_y)(Y_{t+j} - \beta X_{t+j})$, e ΔY_{t+j} al primo membro: le forme sopra coincidono con i passaggi già visti per $j = 0$ e $j = 1$.)



Andamento di $E[\Delta Y_t \mid passato]$ per diversi valori di α_y

Figura — *Andamento di $E[\Delta Y_t \mid passato]$ per diversi valori di α_y* ($\alpha_y = 0.5$, $\alpha_y = 1$, $\alpha_y = 2$), sull'orizzonte temporale $t = 0, \ldots, 10$, partendo da un disequilibrio iniziale pari a 2. Con $\alpha_y = 1$ il disequilibrio viene riassorbito immediatamente (un solo periodo), con $\alpha_y = 0.5$ il ritorno all'equilibrio è più lento e monotono, mentre la curva etichettata $\alpha_y = 2$ oscilla attorno allo zero con ampiezza decrescente prima di stabilizzarsi (il rapporto tra due valori successivi è $1 - \alpha_y = -0.5$, che corrisponde a $\alpha_y = 1.5$: l'etichetta delle slide non è coerente con il modello, perché con $\alpha_y = 2$ il rapporto sarebbe -1 e l'oscillazione resterebbe di ampiezza costante). In generale valori di α_y tra 1 e 2 generano un aggiustamento oscillante con ampiezza decrescente (overshooting), $\alpha_y = 2$ un'oscillazione di ampiezza costante, $\alpha_y > 2$ un'oscillazione esplosiva, mentre valori tra 0 e 1 generano un aggiustamento monotono verso l'equilibrio.

(slide 32–33)