Università Ca' Foscari Venezia

Dipartimento di Economia

Laurea Magistrale in
Economia e Finanza

Appunti di Econometria

Sintesi a punti delle lezioni, in ordine cronologico

Appunti di:
Silvio Angelo Baratto Roldan

Contenuto:
2 lezioni

Anno Accademico:
2026/2027

Sintesi a punti delle lezioni, ricavata dalla trascrizione fedele della stessa lezione: dice solo ciò che dice quel testo, con meno parole, e ne conserva i titoli per ritrovare il passaggio completo. Le parti evidenziate sono ciò che il docente sottolinea. I passaggi che il riconoscimento vocale non permette di stabilire sono segnalati come «Da verificare». Documento a uso personale di studio.

Indice

1 Lezione del 10 novembre 2026: Introduzione al corso: causalità e correlazioni spurie **1**

2 Lezione del 12 novembre 2026: Regressione semplice: esogeneità e relazione causale **11**

1 | Lezione del 10 novembre 2026: Introduzione al corso: causalità e correlazioni spurie

1.1. Obiettivo del corso: interpretare, non calcolare

- L'idea è di farlo più intuitivo che tecnico; di solito una parte della classe ha già fatto econometria, ma solo dal punto di vista statistico.

Da verificare. La trascrizione riporta "scuota percento della classe"; la percentuale non è leggibile.

- Il corso si concentra sull'interpretazione economica ed è di fatto cosa non fare, perché l'econometria viene presentata come disciplina tecnica ma è una cosa ibrida.
- La distinzione tra econometria e statistica c'è, per via di un'ipotesi aggiuntiva con implicazione economica importante: l'ipotesi di esogeneità.
- Se costruisco il modello in modo non corretto, gli indicatori sono stimati in maniera sistematicamente distorta: stimo il parametro più una costante che non so cos'è, non l'effetto della politica.
- Più osservazioni ho, più sono preciso nello stimare lo sbaglio.
- la scelta del modello, la scelta delle variabili è la cosa più importante, più che la metodologia per fare i conti veri e propri.
- La scelta delle variabili permette di escludere il problema dell'endogeneità, che è il problema tecnico, economico.

1.2. Relazioni logiche e non quantitative

- Mi interessano relazioni logiche tra variabili, non relazioni quantitative: non conta che il modello si approssimi bene ai dati.
- gli indicatori tipo R quadro sono la misura peggiore per valutare il modello. Non dovete proprio utilizzarli, perché misurano solo una correlazione, e le correlazioni raccontano spesso relazioni spurie.

Da verificare. La trascrizione riporta "la misuratura peggiore"; si legge "la misura peggiore".

- Se si chiede a ChatGPT perché c'è una correlazione del 95% tra due variabili, qualcosa tira fuori, che abbia senso o no.

- Esempio: per un picco in una serie storica costruita con colleghi di Bologna, l'IA ha risposto "la rivoluzione industriale", avvenuta 100 anni prima o dopo, quindi risposta sbagliata.

Da verificare. La trascrizione riporta "Il fatto è che la correlazione allignment del fenomeno mi è stato spiegato in maniera non corretta"; la frase non è leggibile per intero.

- La consapevolezza di cosa non fare è più importante; l'IA può affinare l'intuizione, però il controllo, come diceva la professoressa, dovete avercelo voi.

1.3. I tre tipi di problema e il termine d'errore

- Le cause di problemi sono tipicamente di tre tipi; il primo è un modello sbagliato con troppe poche informazioni, e ciò che non è spiegato può avere un effetto sistematico sulla relazione che mi interessa.
- Servono la variabile dipendente y e il driver x; interessa la stima del parametro beta: se beta è positivo, se x aumenta aumenta y, se è negativo viceversa.
- Il modello ha anche il termine d'errore: statisticamente una variabile casuale con media zero, economicamente raccoglie le informazioni che non sono nel modello.
- Se quelle informazioni hanno un effetto sulla x, una variazione di x porta anche una variazione di y e misuro un misto di cose; la politica dipende anche dall'errore, che non osservo, e non valuto più cosa fa il modello.

Da verificare. Nel passaggio "dipende anche da Y, ma Y non lo osservo" il docente dice "Y" dove dal contesto sembra intendere l'errore; si riporta come detto.

1.4. Previsione e comprensione dei driver

- Non è un problema se lo scopo è la previsione: se la x assume questo livello, la y assumerà questo livello.
- Esempio Nutella: per la catena di produzione basta sapere che servono 7 tonnellate di noccioline in un certo momento dell'anno, come con una scatola nera; per capire perché la gente compra la Nutella (gusto, ricetta, packaging) serve la relazione logica.
- Lo scopo del corso è soprattutto la seconda parte, capire i driver; la previsione con un modellino banale è quasi automatica.
- Chi faceva le previsioni per le noccioline guadagnava sull'ordine del milione di euro l'anno, 15-20 anni fa.

Da verificare. La trascrizione riporta "Pensa per fare le previsioni per la Ferrari non è… non c'è nemmeno il tedesco per farlo" e "trent'anni da quando mi dicevano queste cifre"; il passaggio sulla Ferrari e l'epoca delle cifre (15-20 o trent'anni fa) non sono leggibili.

1.5. Esogeneità ed endogeneità

- La differenza tra statistica ed econometria è la relazione logica tra le variabili, tecnicamente esogeneità, formalizzata con un indicatore di correlazione tra un qualcosa che non osservo e un qualcosa che osservo.
- Vedremo come capire se un modello è affetto da endogeneità e come risolverlo.
- Primo caso: troppe poche variabili nel modello, e le altre finiscono nel termine d'errore epsilon.
- La variazione della variabile dipendente è una combinazione di due oggetti che non so misurare separatamente: misuro solo il totale.
- Si risolve togliendo variabili dal termine d'errore con ragionamenti logici, non numerici: cerco di capire quali variabili contano veramente.
- C'è la teoria economica che mi deve guidare nella definizione del modello, non sono i dati.

1.6. Causalità circolare

- Altro problema: non è chiaro se la x influenza la y o viceversa; introduco un riferimento circolare e non capisco quanto una variazione di x impatta sulla y.
- Questo crea una correlazione tra la x e l'errore, e la stima dei coefficienti diventa problematica.

1.7. Errore di misura

- Ultimo problema, più sottile: dati approssimativi inducono una distorsione nella stima dei parametri anche se il modello è perfetto, tanto più grande quanto è grande l'errore di misura.
- Esempio Istat: si chiede quanto si è speso al supermercato nell'ultima settimana; chi ha speso 190 o 205 riporta 200. Anche se la spesa media nel campione è corretta, c'è rumore che distorce la stima del parametro.
- Non si parla di gente che sistematicamente sottoriporta o sovrariporta, ma di gente imprecisa perché non ricorda.
- Esempio dell'aeroporto di Venezia: dopo sette mesi negli Stati Uniti ha detto circa 10.000 euro, poteva essere 15.000 o 5.000, un numero a caso; per una settimana di viaggio si sa quanto si è speso.

Da verificare. La trascrizione riporta "se uno sta via una settimana più o meno mi dà di quanto ha speso"; si legge "sa quanto ha speso".

- Diverso il caso delle evasioni fiscali: lì c'è una distorsione sistematica, che si controlla più facilmente.
- Qui si parla di gente onesta ma imprecisa; si vedrà con dati simulati, quindi controllabili.

1.8. Come si svolgerà il corso

- Un po' di teoria, perché la formula fa capire, e un po' di empirica, perché vedere le conseguenze è utile, senza algebra complicata e senza algebra matriciale.
- Serviranno algoritmi, derivate; la rappresentazione matriciale sarà solo per far vedere che non cambia nulla: la matrice rende le formule piccole e compatte, come le sommatorie.

Da verificare. La trascrizione riporta "algoritmi, derivate"; forse "logaritmi", le slide non lo stabiliscono.

Da verificare. La trascrizione riporta "come sottopo o per meno"; probabilmente "sommatorie", non determinabile con certezza.

- Prima parte: una survey del modello di regressione, focalizzata su quando non va bene.
- Seconda parte: dati in serie storica, in cui i modelli di regressione, sempre la stessa strategia, cambiano a seconda del tipo di dati.

1.9. Dati indipendenti e dati dinamici

- Nel modello di regressione si assume che le osservazioni siano pescate in maniera indipendente dalla popolazione.
- Nei sistemi dinamici (finanza, economia, serie storiche) le variabili hanno inerzia: se il tasso di interesse oggi è il 5%, domani non sarà lo 0% né il 10%, ma 5% più o meno una piccola variazione. Questo crea un problema di stabilità delle traiettorie.
- Il problema è che la statistica funziona bene se i dati sono stabili nel tempo.
- Esempio dei prezzi giornalieri dello Standard & Poor's: la media è un indicatore di centralità che va bene per un intervallo solo per caso, non per gli altri.
- Se i dati non sono stabili, la statistica descrittiva rappresenta una popolazione troppo eterogenea nel tempo, con medie diverse.
- Esempio: popolazione con 50% alto due metri e 50% alto un metro; la media è un metro e mezzo, utile né per i bassi né per gli alti.
- Numericamente posso calcolare tutto, ma senza regolarità i numeri non hanno significato logico.
- Una delle ipotesi che bisognerà fare quando si utilizzano i dati in serie storica è richiedere che la serie sia stabile nel tempo, quantomeno che abbia una media comune.

1.10. Stabilizzare le serie: rendimenti e modelli ARCH e GARCH

- Esistono trasformazioni uno a uno, che non fanno perdere informazione: anziché i prezzi si usano le variazioni di prezzo, cioè i rendimenti, con media stabile, tipicamente zero, mentre la variabilità cambia nel tempo.

- I modelli della classe ARCH o GARCH, che ha fatto vincere il premio Nobel nel 2000 e qualcosa, studiano come cambia la varianza, indicatore di rischio, e servono per misure di rischio operative (corsi di risk management).
- I dati osservati nel tempo non sono indipendenti; con una componente di trend la statistica descrittiva standard non funziona più.
- Il teorema del limite centrale e la legge dei grandi numeri non valgono più, ma il problema è logico: mischio dati non coerenti e ottengo una mistura di indicatori di centralità senza interpretazione.

1.11. Regressione spuria e cointegrazione

- Senza attenzione a questo fenomeno, anche con modelli semplici sembrerà che qualsiasi cosa non statisticamente significativa poi automaticamente diventa…

Da verificare. La trascrizione riporta "sembrerà che qualsiasi cosa non statisticamente significativa poi automaticamente diventa…"; la frase resta interrotta.

- Un test classico dà un p-value estremamente piccolo, il contrario di quello che mi aspetto: si chiama regressione spuria. Due cose indipendenti per costruzione hanno un coefficiente sempre diverso da zero.
- Il motivo è che il test usa la distribuzione normale, ma la distribuzione degli stimatori con quei dati non è più normale; il software non lo sa.
- Con dati non stabili non si può usare la regressione, a meno di stabilizzarli prima.
- Eccezione: la cointegrazione, importante in ambito finanziario ed economico; se le caratteristiche di regolarità sono più o meno stabili, il parametro che lega le variabili è identificabile.

1.12. Schema del corso

- Prima parte: cosa non guardare in un output di regressione e cosa non fare con dati sostanzialmente indipendenti.
- Poi cosa cambia nel contesto di dipendenza e quali modelli sfruttano l'irregolarità nel tempo; l'inerzia serve per fare previsioni e per trovare modelli migliori.
- Ultima cosa: i modelli a correzione di equilibrio.
- Più che cosa fare, sarà cosa non fare; conta l'interpretazione: perché uso un modello e come interpreto i risultati.

1.13. Materiale, Moodle e Gretl

- Tutto il materiale è sulla pagina Moodle, Econometria 2026-2027, aggiornato prima delle lezioni; a parte i primi due set di slide, gli altri sono la versione dell'anno prima. Ci sono lucidi e dataset.
- Le esercitazioni, in cui si scovano i problemi di un modello, le fa il dottor Peruzzi.

Da verificare. Il docente indica "dottor Peruzzi" per le esercitazioni; la slide 3 riporta "Marco Bidoia". Si riporta il nome detto dal docente.

- Il software è Gretl *(slide 3)*, scelto perché è semplice, gratuito e su ogni piattaforma, così ci si concentra sulla parte econometrica; il libro di testo dà i dati degli esempi, anche in formato Excel.
- Gretl va a tasti, con un linguaggio in background non essenziale; il problema in econometria non è stimare il modello ma capire se va bene o male.

Da verificare. La trascrizione riporta "Questa è la teoria, mi dice alla fine questo, ma almeno mi dà una casistica da controllare quando faccio questo tutorial"; l'inizio della frase non è leggibile.

Esame. Sulla pagina Moodle ci sono esami vecchi e prima dell'esame finale si fanno esercitazioni stile mock exam, con il docente, il dottor Peruzzi o il tutor.

- La lezione si può recuperare; il docente incoraggia il ricevimento: spiegare dove sono gli errori è troppo tardi, ormai il compito è fatto.

Da verificare. La trascrizione riporta "per mettervi di risolvere i problemi pre-esame non posto. Il coraggio di un esame, spiegare dove sono gli errori, è troppo tardi"; non si legge a quale momento si riferisca.

1.14. Iscrizione a Moodle, ricevimento ed esame

- Ci si deve iscrivere manualmente a Moodle, così il docente può contattare tutti in blocco.
- Si può scrivere per un altro orario di ricevimento, anche online.
- L'unica cosa che non si può fare online è la visione dell'esame. Chi vuole vedere l'esame esposto dovrà venire. Non c'è tempo per la scansione di cento compiti.

Da verificare. La trascrizione riporta "Ok, quindi a parte quello, però ricevimenti standard non possiamo fare"; non si capisce se il docente escluda o ammetta i ricevimenti standard online.

- Per chi ha diritto, le registrazioni delle lezioni saranno scaricabili dalla pagina, se funziona.

Esame. L'esame è scritto, di una decina di domande (numero non fissato), e si chiede di interpretare risultati, non di fare le stime.

- La stima con un software è per chi vuole diventare operativo, ma si consigliano le lezioni empiriche, che spiegano come interpretare i modelli.
- La prima lezione empirica, probabilmente la settimana prossima: riscalare le variabili con trasformazioni tipo logaritmo, interpretare gli effetti marginali in scala diversa, approssimata o esatta, e diagnosticare la quasi collinearità; la collinearità esatta è facile.
- Il variation factor serve a diagnosticare la quasi collinearità, normalmente un problema perché, se non me ne accorgo, penso che il modello mi dia risultati non corretti.

Da verificare. La trascrizione riporta “la collinearità esatta è facile, con due si pianta”; che cosa si pianti non è determinabile.

Da verificare. La trascrizione riporta “variation factor”; probabilmente il variance inflation factor, ma nelle slide non compare.

Da verificare. La trascrizione riporta “se non me ne accorgo, penso che il modello mi dia dei risultati che non sono corretti”; dal contesto il senso sembra l’opposto (li penso corretti e non lo sono), si riporta come detto.

- Le lezioni empiriche con il dottor Peruzzi legano teoria e pratica; il compito chiede di interpretare risultati, capire se il modello ha un problema, analizzando grafici e tabelle, e nelle serie storiche interpretare i risultati dinamici e statici di un modello dinamico. Ci sono già esempi.

1.15. Feedback e libro di testo

- Si può interrompere in qualsiasi momento: il corso è per gli studenti; al docente non piace correggere compiti.

Da verificare. La trascrizione riporta “doppi altissimi, che mi appello”; il senso probabile è “voti altissimi al primo appello”.

- Senza feedback può esserci un mismatch notato troppo tardi; il programma si può modificare, se c’è tempo, in base agli interessi.
- L’acquisto del libro non è obbligatorio, ma è utile: discorsivo, con molti esempi, soprattutto sulle serie storiche e la regressione, e argomenti in più *(slide 4)*; è in biblioteca.
- I lucidi sono solo uno schema per appunti o scaletta del docente, messa a punto in trent’anni di insegnamento; il libro dà di più.

1.16. Materiale di statistica di base

- Il primo set di lucidi è l’introduzione; ci sono anche appunti di un corso di statistica di base per richiamare i concetti essenziali, come medie e varianze e la notazione (per esempio E per la media), all’inizio della pagina Moodle.

1.17. Che cos’è l’econometria

- L’econometria ha tre scopi, ma in generale è un’analisi quantitativa di modelli economici *(slide 5)*; non esiste una definizione chiara.
- Il primo scopo è la misura delle relazioni causa-effetto tra variabili.
- Il secondo è fare previsioni, che è più statistica che econometria.
- Il terzo è usare metodologie anche avanzate per valutare teorie economiche, per esempio il CAPM: due pagine di algebra che danno l’equazione per cui gli extra rendimenti di un investimento sono proporzionali agli extra rendimenti del portafoglio di mercato.

- Il CAPM richiede molte ipotesi: mercato dei capitali e dei tassi di interesse in equilibrio, portafogli costruiti con l'algoritmo di Markowitz.

1.18. Validare un modello economico: il CAPM

- Domanda: la relazione è credibile e i dati la supportano? Se il modello fosse vero, un rendimento in media non dovrebbe garantire un premio extra per il rischio, quindi la regressione non può avere l'intercetta.
- Possibile test: una regressione semplice con intercetta, e valutare se è uguale a zero o diversa da zero.
- Se il modello non passa il test, non basta aggiungere l'intercetta: cambierebbero tutte le equazioni e ipotesi precedenti, e va rispecificato il modello economico.
- La validazione è la parte preferita del docente: ho una teoria, ho dei dati, voglio vedere se la teoria spiega i dati.

1.19. Relazioni causa-effetto e criteri di causalità

- Una relazione causale si rappresenta con un grafo asimmetrico: la x ha un impatto sulla y ma non viceversa, la x è un driver per la y; il problema è capire se x è una causa per y *(slide 6)*.
- Devono valere tre criteri. Il primo è statistico: serve almeno una relazione statistica; se le variabili sono quantitative, una correlazione statisticamente significativa tra x e y.
- La correlazione è simmetrica, quindi non dice nulla sul nesso causale, solo che c'è un legame di qualche natura.
- Serve anche un legame logico, una variabile che anticipi l'altra non solo temporalmente, con una storia che spieghi il legame statistico. E quella storia deve essere unica.

Da verificare. La trascrizione riporta "So più storie che coerentemente mi descrivono quella forma di dipendenza statistica, lo troverò migliore"; la frase non è leggibile, il senso probabile è che con più storie coerenti il legame non è stabilito.

- Il legame logico deve essere unico. La cosa importante da capire è che il legame statistico non è sufficiente.

1.20. Correlazioni spurie: gli esempi del sito

- Una pagina web di uno statistico buontempone *(slide 13)*: un programma cerca le coppie più correlate in un database di 10.000 variabili, senza pensare a che variabili sono.
- Primo esempio: gente che ha guardato Big Bang Theory contro ricerche Google che cominciano con "how to make"; nessun legame logico, ma si potrebbe prevedere l'una con l'altra. L'R quadro è 96,5%.
- Questo 96,5% mi spiega solo il legame statistico: dice che le serie si muovono insieme, non perché, e non che il modello è corretto dal punto di vista logico.
- Sul sito ci sono a volte spiegazioni fatte con l'IA della correlazione alta.

- Secondo esempio: partite di lacrosse contro biglietti venduti al cinema, correlazione intorno al 74%, senza legame sostanziale.

Da verificare. La trascrizione riporta "la cross"; si interpreta come lacrosse, ma le slide non lo confermano.

Da verificare. La trascrizione riporta "il 74% o più del 50%"; il valore non è del tutto leggibile.

- L'IA una storia la trova, ma non ha necessariamente senso; il legame statistico è solo il primo pezzo.
- Un R quadro grande non vuol dire che il modello vada bene.

Da verificare. La trascrizione riporta "se il primo modello di regressione, quando è grande"; dal seguito ("i modelli buoni non hanno R quadro così grande") si legge "R quadro".

- Tipicamente i modelli buoni non hanno R quadro molto grande; un R quadro troppo grande porta problemi di collinearità.
- Variabili legate statisticamente ma senza motivo logico non spiegano perché una si muova e non permettono analisi di scenario; quello che si trova è casuale e non replicabile.

1.21. Nessun modello è definitivo, ma si lavora con regole precise

- Quasi mai si ha una risposta definitiva, perché è quasi impossibile escludere tutte le altre spiegazioni logiche; la distinzione causale dà però una regola su come lavorare.

Da verificare. La trascrizione riporta "relazioni casuali" e "distinzione casuale"; la slide 11 tratta lo stesso passaggio come "relazione causale" e si adotta "causale".

- Ogni volta devo capire perché costruisco il modello e perché scelgo certe variabili; poi vedo se i coefficienti hanno il segno atteso, perché un segno sbagliato può indicare una stima non corretta.
- Lavorando in modo coerente il mio modello contribuisce al lavoro degli altri, finché si trova un consenso: provati 10.000 modelli, esclusi tutti gli altri.
- Un modello perfetto con le tre caratteristiche è troppo ambizioso, soprattutto la terza parte.
- la relazione statistica non è abbastanza: serve un legame logico che resista a spiegazioni alternative; provare modelli buttando dentro dati sperando nei segni giusti non basta.

1.22. Fumo e malattie dei polmoni

- Sintesi della letteratura epidemiologica sull'associazione tra fumo e malattie gravi ai polmoni *(slide 12)*: la correlazione c'è ma non basta per la relazione causa-effetto.

- Per decine di anni sono state testate ipotesi e trovati meccanismi biologici; ora c'è l'idea di una relazione causa-effetto, probabilmente definitiva, ma da ripensare se un biologo trovasse un'alternativa più convincente.
- quello che state facendo non deve essere un tentativo, ma deve essere un tentativo fatto con un background.
- Prima dei dati si capiscono i potenziali driver e poi si inseriscono nel modello; non si mette tutto dentro per selezionare finché non si trova qualcosa. La teoria definisce i legami logici a priori, non la correlazione.

Da verificare. La trascrizione riporta "Ho fatto il contrario, che è tutta la roba dentro modello"; si riporta in forma negativa, coerente con il contesto.

1.23. Boy scout e criminalità: causalità inversa

- Dati inventati da un libro di statistica, per capire da dove nascono le correlazioni spurie *(slide 9)*: tabella a doppia entrata tra chi ha fatto il boy scout e chi ha avuto problemi con la giustizia.
- Tra chi ha fatto il boy scout l'incidenza è più bassa: sembra una relazione negativa. Spiegazione logica: regole e principi insegnati, relazione boy scout verso delinquency *(slide 10)*.
- Spiegazione alternativa: chi è avverso alle regole non si iscrive ai boy scout, quindi la direzione è opposta.
- Il legame statistico, che è simmetrico, non mi dice nulla su qual è la direzionalità tra le variabili. Si chiama reverse causality.

1.24. Prossima lezione

- Oggi era una chiacchierata; giovedì si ragiona su come definire un modello statistico che descriva una relazione causale e su come capire quando lo supporta o no.

2 | Lezione del 12 novembre 2026: Regressione semplice: esogeneità e relazione causale

2.1. Le relazioni causa-effetto: richiamo

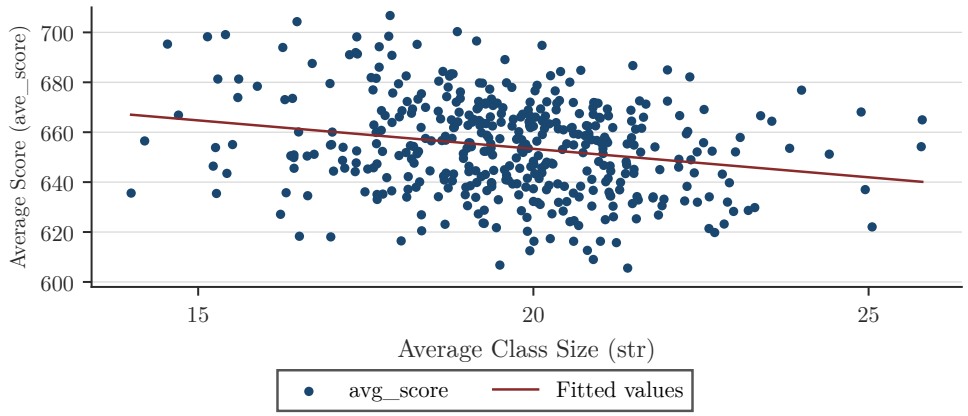
- Si resta su una componente di intuizione, perché secondo me è la cosa più importante da capire: poi la formalizzazione statistico-matematica è abbastanza semplice.
- Una relazione causa-effetto ha tre caratteristiche sostanziali; la prima è una correlazione tra le variabili di interesse, ma non basta.
- La correlazione è simmetrica (Y con X come X con Y), la relazione causale è unidirezionale: X ha un impatto su Y ma non viceversa.
- Il controesempio dei boy scout e del record giudiziario: l'associazione può spiegare un fenomeno e il suo opposto, quindi non è relazione causale.

2.2. Esempio: dimensione della classe e test

- Il problema posto in California: ridurre la dimensione della classe (asilo, scuola dell'infanzia) migliora l'apprendimento, cioè i test di fine anno? Intuitivamente sì, perché l'insegnante dedica più tempo a ogni bambino.
- Il costo è stato quantificato in circa 1,8 miliardi di dollari l'anno (più insegnanti, più classi, più attrezzatura). Vale la pena solo se la dimensione della classe è un driver logico, non solo statistico, della performance.

Da verificare. La trascrizione riporta "L'incontro è che per implementare"; si è letto "Il contro è che".

- I dati sono su circa 420 distretti scolastici: ogni pallino è un distretto, x è la dimensione media della classe, y il punteggio medio al test.



Slide 16

- La retta che approssima la nuvola ha pendenza negativa: la correlazione è minore di zero. Primo ingrediente della relazione causale trovato.
- Secondo ingrediente: una spiegazione logica plausibile (più attenzione a ogni bambino in classi piccole), che non è detto sia corretta.
- Terzo ingrediente: escludere altre spiegazioni più convincenti. Non si troverà mai una spiegazione esaustiva e corretta, ma si considerano alternative ragionevoli con criteri di scelta razionali.
- Stimare la pendenza dice di quanto cambia il punteggio per un'unità di classe in meno (per esempio 10 punti, dipende dalla scala), ma ora il problema è capire se ci sono modelli migliori, per esempio con altre variabili congiuntamente.
- Candidato: il reddito. Distretti ad alto reddito hanno più libri in famiglia e scuole pubbliche mediamente migliori (negli Stati Uniti la scuola privata costa decine di migliaia di dollari l'anno e le case vicino a buone scuole pubbliche costano molto di più).
- Il reddito potrebbe avere effetto positivo sulla performance e negativo sulla dimensione della classe (negli Stati Uniti è il rapporto studenti-insegnanti, e le scuole migliori hanno più insegnanti). Omettendolo, si vede solo la relazione negativa tra le due variabili iniziali.

Da verificare. La trascrizione riporta "se lo ometto vedo solo la marginale, vedo la correlazione condizionale"; le due parti si contraddicono.

2.3. Come controllare per il reddito

- Si vuole controllare per il reddito: se due distretti non differiscono per reddito, la correlazione tra dimensione della classe e performance non può dipendere dal reddito, perché il reddito è uguale per tutti.
- Si divide il campione in distretti ricchi e poveri e si guarda la dipendenza in ciascun sottocampione. Se non cambia, il reddito non è rilevante e aggiungerlo non serve. Se cambia, il reddito è determinante e serve per spiegare la correlazione negativa.
- Per il ministro della California la domanda è se quei due miliardi di dollari l'anno servano. Se la correlazione negativa è solo un effetto collaterale del reddito, assumere docenti non serve e forse conviene dare sussidi alle famiglie meno ricche.

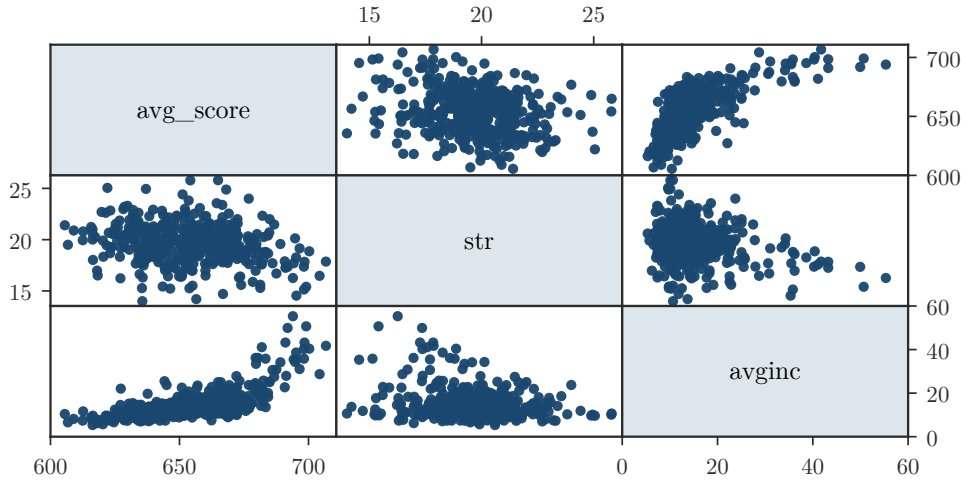
- Se le correlazioni nei due gruppi sono diverse, il reddito ha potere esplicativo; se restano uguali, la relazione resta uguale indipendentemente dal reddito.
- Se il modello più complesso non migliora, si tiene il precedente; se i numeri sono diversi, il precedente si scarta. L'analisi non è conclusa, perché potrebbero esserci altri fattori: si estende il modello, si confronta, si valuta in modo logico.
- La strategia è non fissarsi sull'idea iniziale ma estenderla per trovare la spiegazione migliore della correlazione negativa.

2.4. Statistiche descrittive e schema causale

- Variabili: Avginc è il reddito medio per distretto, STR la dimensione della classe (student teacher ratio), average score il punteggio medio.
- La correlazione tra punteggio e dimensione della classe è meno 0,22, statisticamente significativa.
- Reddito e punteggio: correlazione altissima, 0,70, significativa. Reddito e dimensione della classe: correlazione negativa, i distretti ad alto reddito hanno classi mediamente piccole. *(slide 18)*

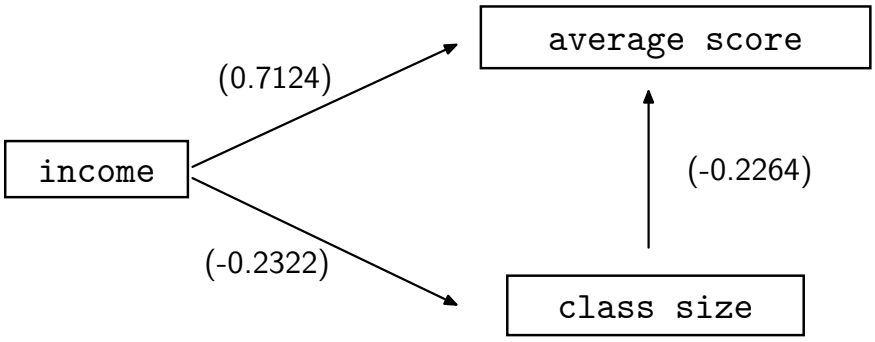
Da verificare. La trascrizione riporta "0,70 per cento"; la slide 18 riporta 0.7124. Si riporta quanto detto a lezione.

- Queste sono solo analisi grafiche.



Slide 19

- Lo schema logico raccontato a parole:



Slide 20

- Senza reddito, il primo candidato è dimensione della classe e performance: relazione negativa, significativa, sensata. Con il reddito (relazione negativa con la dimensione, positiva con la performance) ci si chiede se la correlazione negativa sia diretta o spiegata dal reddito.
- Si divide il campione alla mediana del reddito (analisi grezza, poi si vedrà con la regressione). Nei distretti a basso reddito la correlazione diventa piccola e non è statisticamente significativa. *(slide 21)*

Da verificare. La slide 21 riporta -0.1464 e la definisce "debolmente statisticamente significativa"; si riporta quanto detto a lezione.

- Per i distretti a basso reddito il reddito sembra il driver principale: condizionatamente al reddito basso la correlazione è sostanzialmente zero. Per i distretti ad alto reddito la correlazione è bassa e non significativa, con un p-value leggermente più alto.
- Il messaggio principale è questo: se controllo per il reddito, la correlazione tra le variabili che mi interessano e la variabile su cui voglio investire i soldi è non significativa.
- Il modello con il reddito supera l'altro perché è informazione in più; la correlazione marginale non è importante perché quella condizionata al reddito non è significativa. Spendere due miliardi di dollari l'anno sulla dimensione della classe sarebbe spendere su una variabile solo apparentemente legata alla performance; forse conviene migliorare le condizioni delle persone poco abbienti.

2.5. Anticipazione: il modello di regressione sull'esempio

- Modello di regressione tra punteggio e dimensione della classe: la pendenza è meno 2,27, con p-value zero, quindi esiste una pendenza negativa (la linea rossa dello scatter). È il primo modello.
- Aggiungendo il reddito, con la performance che dipende dalla dimensione della classe X1 e dal reddito X2, il coefficiente della dimensione si più che dimezza: anziché meno 2,2 è meno 0,64, con p-value più grande del 5%.
- Condizionatamente al reddito, la dipendenza lineare tra performance e dimensione della classe è zero. Un modello con due variabili equivale a dividere il campione in alto e basso reddito.

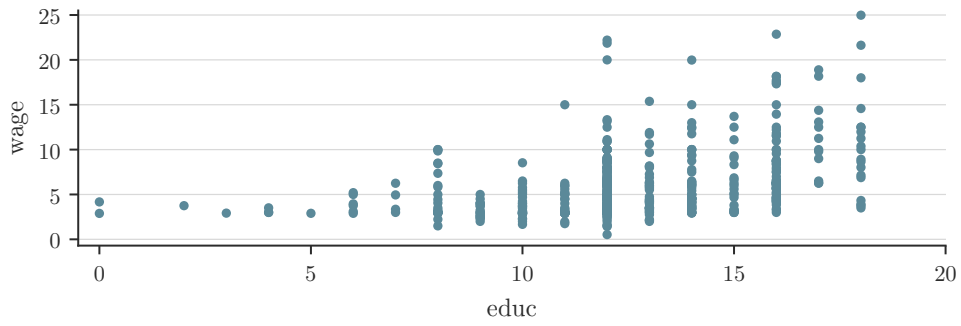
- Per capire se una relazione è causale si estende il modello in modo logico e si vede se migliora il precedente. Non si inseriscono variabili senza senso (il film di Nicolas Cage in California).
- Devo avere una storia da raccontare quando inserisco una variabile nel modello: non è che mi faccio dire dai dati cosa voglio spiegare. Questa è la cosa più importante.

2.6. Verso il modello di regressione semplice

- Si passa al trattamento formale del modello di regressione semplice: capito questo, l'estensione ai casi complicati cambia solo l'algebra.
- La relazione causa-effetto è buona se vale l'esogeneità, già accennata: le spiegazioni alternative non possono avere un impatto sistematico sulla relazione chiave tra le variabili.
- Le spiegazioni alternative stanno nel termine d'errore, tipicamente non osservabile: un bidone di informazioni che potrebbero avere impatto sulla relazione ma non sono usate.

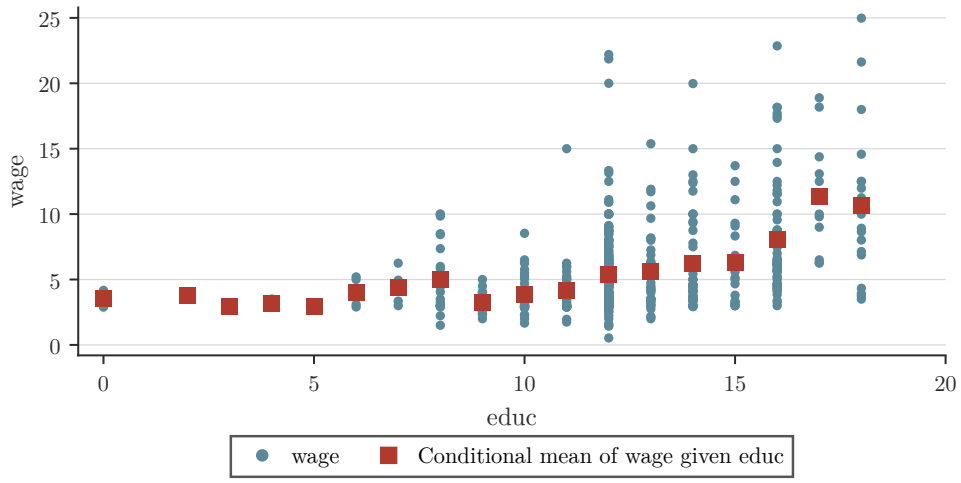
2.7. Esempio: salario e istruzione

- Problema classico dell'economia del lavoro: la relazione tra istruzione e salario. I dati sono degli anni '70 (salari orari in dollari, numeri piccoli).
- Sulle x c'è educ, l'istruzione in anni. Ogni colonna di punti è la distribuzione condizionale dei salari dei lavoratori con quel livello di istruzione (per esempio 10 anni, 15 anni). *(slide 3)*



Slide 3

- Al crescere dell'istruzione non cambia solo la media. I quadratini rossi sono le medie condizionali di ogni colonna e hanno una tendenza crescente: sotto i 5 dollari l'ora per chi ha poca istruzione, intorno ai 15 per chi ha studiato molto. *(slide 8)*

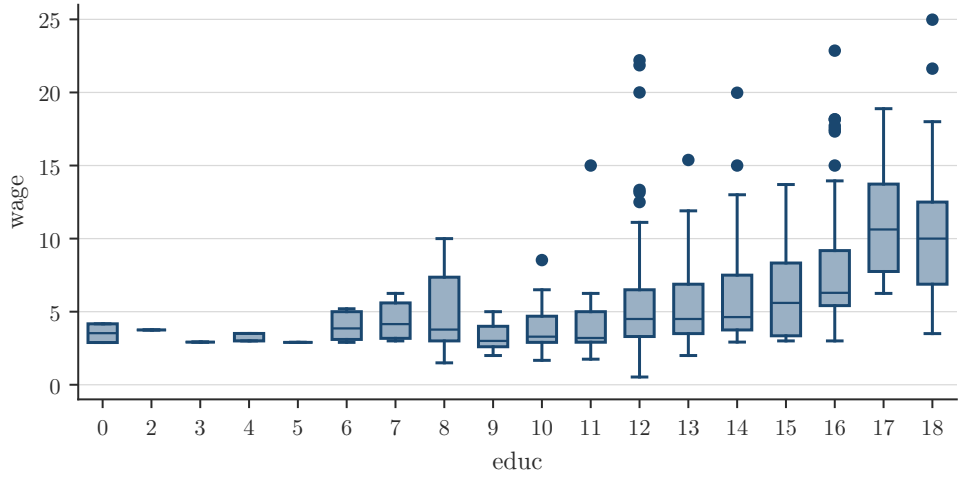


Slide 8

- Più studio, più in media guadagno, ma non è sicuro: dentro ogni gruppo c'è eterogeneità (il figlio di un dirigente, chi studia archeologia, l'effetto di genere).
- L'eterogeneità non è spiegata dall'istruzione, uguale in ogni colonna, ma da altro: reddito della famiglia, tipo di studi, intelligenza, genere, sede (Bocconi contro Cassino, i salari a Milano sono più alti). Questo altro si chiama termine d'errore, simbolo epsilon.

2.8. Perché una relazione causale

- Con la relazione causale si può capire se una magistrale (studiare due anni in più, da 13 a 15) conviene in termini di salario orario atteso, e rispondere a domande del tipo: se aumento o riduco X, che cosa succede a Y?
- Il primo problema è definire un modello coerente e logico; poi lo si usa per analisi di policy, di scelte, di scenario.
- Altra rappresentazione dei dati: ogni sottogruppo approssimato da un box plot, che mostra centralità e dispersione. *(slide 6)*



Slide 6

2.9. Il modello di regressione lavora sulle medie

- Il modello di regressione lavora sul momento di ordine uno, cioè sulle medie; interessano anche le varianze, ma l'obiettivo è come in media l'istruzione impatta sul salario.
- Serve un modello statistico che approssimi i quadratini rossi, che sono evidenza campionaria e non della popolazione. Interessa spiegare la popolazione, non il campione: nel campione basta guardare il file.
- Non serve essere troppo precisi sui quadratini rossi, che già si hanno. Interessa il quadratino verde, la media nella popolazione, che non si può calcolare perché richiederebbe di intervistare tutti i lavoratori degli Stati Uniti.

2.10. Perché un modello semplice: l'overfitting

- Si usano modelli semplici. Una funzione complicata che passa esattamente sui quadratini rossi si trova con un bottone, ma non serve: le medie condizionali del campione (500 e qualcosa lavoratori) già si hanno, e la differenza tra due medie dà il passaggio da 12 a 14 anni. *(slide 10)*
- Serve una funzione che approssimi bene anche i quadratini rossi di campioni diversi della stessa popolazione.
- Un modello perfetto sui dati che si hanno porta all'overfitting: si adatta troppo bene ai dati del campione ma non alla popolazione.
- Esempio fatto alla lavagna: la popolazione ha pallini blu e rossi, il campione sono i blu. La funzione verde approssima esattamente i blu, ma sui rossi l'errore di previsione è gigantesco.
- È preferibile un modello che non sia perfetto né per il gruppo blu né per il rosso, ma che mediamente non sbagli in modo sistematico.
- Trovare un modello che si adatta troppo bene al campione non è necessariamente una buona notizia.
- Un R quadro del 99% non è necessariamente una buona cosa; un R quadro del 20% potrebbe essere un ottimo modello.

2.11. Perché una retta

- Si cerca una funzione che rifletta un andamento di lungo periodo, universale e non specifico per il dataset.
- Una retta è un modello molto semplice: due parametri, intercetta e coefficiente angolare, che caratterizzano il comportamento dei dati su tutta la popolazione.
- il modello di regressione non approssima i dati direttamente, ma approssima una caratteristica dei dati, le medie condizionali. Approssimare i pallini blu è impossibile; le medie condizionali sono indicatori di centralità sufficientemente stabili.
- Altri modelli guardano a quantili e mediane: è la regressione quantilica, non parte del corso, interessante per le code delle distribuzioni, per esempio in finanza.

2.12. La notazione e il termine d'errore

- I rendimenti medi di un portafoglio sono mediamente zero: in finanza interessano le code, non la media. In questo corso si guarda alle medie condizionali, ma si può generalizzare.
- La media si indica con E (expectation): prima la variabile su cui si fa la media, dopo la barra verticale il condizionamento. I quadratini rossi sono il valore atteso condizionale dei salari rispetto all'istruzione, con wage come Y ed education come X. Il modello di regressione è la media di Y dato X, definita con una retta; noti alfa e beta è identificato tutto. *(slide 11)*

$$E[Y \mid X] = \alpha + \beta X$$

Da verificare. La trascrizione riporta "weight è la variabile y"; la slide 10 riporta "wage" e si adotta questa forma.

- Il legame tra le osservazioni individuali e la media condizionale: i è l'individuo (un lavoratore), X_i la sua istruzione, Y_i il suo salario.

$$Y_i = E[Y \mid X = X_i] + \epsilon_i$$

Da verificare. La forma scritta viene dalla slide 11, il parlato non detta la formula.

- Il salario di un individuo ha due componenti: una media, per l'appartenenza a un livello di istruzione, e una idiosincratica, individuale, che raccoglie tutte le caratteristiche diverse dall'istruzione (genere, famiglia, essere sveglio, master in finanza o in storia dell'arte). *(slide 12)*
- Le caratteristiche di questo oggetto sono cruciali, perché sulla base di queste caratteristiche posso decidere se il modello statistico definito in questo modo è una relazione causale oppure no. Conta in econometria più che in statistica.
- Si assume che la correlazione tra il termine d'errore e il fattore nel modello sia zero: si chiama esogeneità. Altrimenti si parla di endogeneità, con conseguenze pesanti sulla stima.
- Definizioni: Y è la variabile dipendente, X il regressore (letteratura economica) o predittore (letteratura statistica), epsilon il termine d'errore. Epsilon non è osservabile, quindi per verificare il modello bisogna girarci intorno.

2.13. Perché l'errore non deve dipendere da X

- Modello $Y = \alpha + \beta X + \epsilon$: per prevedere il salario di chi studia X_1 anni si calcola $\alpha + \beta X_1 + \epsilon$. Epsilon potrebbe dipendere dall'istruzione (più studio, più aumentano le skill), quindi si scrive $\epsilon(X_1)$. *(slide 13)*
- Se si studia ΔX in più (due anni), il salario è $\alpha + \beta(X_1 + \Delta X) + \epsilon(X_1 + \Delta X)$ e il beneficio è la differenza con quello di prima:

$$\Delta Y = \beta \Delta X + \Delta \epsilon$$

(slide 14)

- $\Delta\epsilon$ non si può calcolare ma c'è. La variazione di Y si calcola (differenza dei quadratini rossi, per esempio 3 dollari), ma non si sa quanto dipenda dalla scelta di studiare e quanto da altro: i 3 dollari potrebbero essere 1 più 2, 0 più 3, meno 3 più 6.
- L'unico modo per identificare $\beta\Delta X$ è fissare $\Delta\epsilon$, e lo si fissa a 0. Se $\Delta\epsilon$ non è zero, ΔY non è uguale a $\beta\Delta X$.

Da verificare. La trascrizione riporta "Se delta y non è uguale a zero, vuol dire che delta x non è uguale a beta delta x"; scritta come $\Delta\epsilon \neq 0$ implica $\Delta Y \neq \beta\Delta X$, formulazione non ricavabile dal parlato.

- La variazione di epsilon rappresenta quanto cambiano le altre variabili non nel modello in corrispondenza di una variazione di X. È zero quando la correlazione tra X e Y è uguale a zero.

Da verificare. La trascrizione riporta "correlazione tra x e y"; la slide 15 riporta $\text{Cov}(X, \epsilon) = 0$. Nello stesso passaggio il parlato dice Y dove il testo ha scritto variazione di epsilon, sulla base della slide 14.

- È una struttura di dipendenza che deve essere zero; X si misura, l'altra quantità no. Con questa ipotesi l'unica spiegazione di una variazione di Y è la variazione di X pesata da beta, la pendenza. *(slide 15)*
- L'ipotesi si chiama esogeneità stretta, tipica dei modelli di regressione classici; nella seconda parte del corso si userà l'esogeneità debole. Se la correlazione è diversa da zero, non si sa valutare perché Y varia.

2.14. Interpretabilità dei risultati e scopo del corso

- Il problema non è del modello di regressione in generale ma dell'interpretabilità dei risultati. In un corso di statistica l'eterogeneità non è considerata, perché lo scopo è fare previsioni sui prossimi dati.
- Qui interessa valutare con precisione il parametro, che dice quanti soldi si buttano via per l'istruzione dei bambini.
- Esempio: il bonus di mille euro della riforma Renzi, uno sconto fiscale a una fascia di lavoratori, per stimolare i consumi. Il costo è calcolabile (minore entrata dello Stato). Con consumi come Y e redditi come X (pro capite), la policy varia X di 1.000 euro: come sono variati i consumi?
- Se il parametro tra consumi e redditi è grande, 1.000 euro in più hanno un impatto sui consumi. Ma la variazione dipende da 1.000 euro in più o da altro (condizioni economiche del periodo)? Si vuole valutare l'impatto al netto degli effetti collaterali. Si pone un problema statistico, non si giudica la manovra.

- Si può investire molto e stimare un parametro grande, ma la policy ha impatto solo se si ipotizza che questa quantità sia zero; la variazione si calcola, ma non si sa da cosa dipenda.
- L'unico modo per essere sicuri dell'impatto è fissare a zero ciò che non si conosce; allora resta solo da stimare beta, il moltiplicatore.
- Non interessa avere un modello che si adatti ai dati o che mi serva per fare le previsioni: voglio un modello che mi stimi beta correttamente. Per farlo serve fissare delta epsilon a zero. Lo scopo del corso è stimare beta, non fare previsioni decenti.
- Il genitore che sceglie la scuola ha un problema di forecast: se la variabile che prevede meglio la performance è la dimensione del parcheggio, funziona, è una black box. Non interessa il perché (come sapere che serviranno sette tonnellate di ferro in magazzino senza sapere perché la gente le compra).

Da verificare. La trascrizione riporta "ragazzi, se frega se logicamente non ha senso, funziona" e "mozzoline di ferro"; si è reso il senso come "se logicamente non ha senso non importa, funziona".

- Per la previsione non interessa il parametro; per valutare politiche o confermare congetture economiche e finanziarie sì. L'unico modo per stimarlo correttamente è essere sicuri che la varianza di Y sia uguale a zero. Non c'è un approccio migliore: i problemi sono diversi.

Da verificare. La trascrizione riporta "la varianza di Y sia uguale a zero"; il discorso precedente riguarda la variazione di epsilon, ma non si può stabilire se intendesse quella.

2.15. La stima: i minimi quadrati

- Il metodo dei minimi quadrati trova alfa e beta tali che la distanza media tra Y e la trasformazione lineare di X sia la più piccola possibile. La distanza è al quadrato, perché gap positivi e negativi non si compensino. *(slide 17)*
- Si derivano rispetto ad alfa e beta, si pongono uguali a zero e si risolve il sistema di due equazioni in due incognite: beta è un rapporto di quantità, alfa una differenza di medie. Si mostra un'algebra più corta.

2.16. La stima con il metodo dei momenti

- Si ipotizza che il modello sia corretto e semplice: la covarianza tra X e Y è uguale a zero, ipotesi di esogeneità.

Da verificare. La trascrizione riporta "la covarianza tra X e Y"; la slide 15 riporta $\text{Cov}(X, \epsilon) = 0$. Si riporta quanto detto a lezione.

- Se Y è alfa più beta X più epsilon, la covarianza tra X e Y è:

$$\text{Cov}(X, Y) = \text{Cov}(X, \alpha + \beta X + \epsilon)$$

- La covarianza di una variabile con una combinazione lineare è la combinazione lineare delle covarianze (sommatorie e integrali sono operatori lineari). La covarianza tra X e la

costante alfa è zero; quella tra X ed epsilon è zero per ipotesi; quella tra X e beta X è beta per la varianza di X.

$$\mathrm{Cov}(X, Y) = \beta \,\mathrm{Var}(X)$$

- Quindi nella popolazione, il vero beta è:

$$\beta = \frac{\mathrm{Cov}(X, Y)}{\mathrm{Var}(X)}$$

- In ambito campionario, per la legge dei grandi numeri numeratore e denominatore convergono alla vera covarianza e alla vera varianza, quindi lo stimatore converge al vero beta. Con n osservazioni (nel caso specifico 526 lavoratori), $\bar{X}$ media campionaria: *(slide 18)*

$$\hat{\beta} = \frac{\sum_{i=1}^{n}(X_i - \bar{X})(Y_i - \bar{Y})}{\sum_{i=1}^{n}(X_i - \bar{X})^2}$$

- Questo si chiama metodo dei momenti: se il campione è abbastanza rappresentativo e n abbastanza grande, il rapporto approssima bene beta.
- Piace perché impone direttamente l'esogeneità tra le condizioni di stima: funziona solo se la covarianza vale zero. Minimizzando la distanza tra Y e il modello lo stimatore dei minimi quadrati coincide con questo; non sempre capita. *(slide 17)*

Da verificare. La trascrizione riporta "se minimizzo la varianza di y"; la slide 17 riporta "minimizzare la varianza del termine di errore". Si riporta quanto detto a lezione.

2.17. Cosa succede se non vale l'esogeneità

- La covarianza chiamata rho XY, un numero, è supposta diversa da zero:

$$\mathrm{Cov}(X, Y) = \beta \,\mathrm{Var}(X) + \rho_{XY}$$

- Se rho fosse noto:

$$\beta = \frac{\mathrm{Cov}(X, Y) - \rho_{XY}}{\mathrm{Var}(X)}$$

- Il software non sa stimare rho (non è noto) e fa finta che sia zero: la stima di beta è sistematicamente diversa dal vero beta nella popolazione.

Da verificare. La trascrizione riporta "la covarianza tra X e Y" per rho XY; per coerenza con quanto detto dopo si intende il legame tra X ed epsilon, ma il parlato non lo precisa.

- Con endogeneità (correlazione tra X ed epsilon diversa da zero) lo stimatore non è collegato a beta ma a beta più qualcosa: distorsione sistematica.

- Il problema dell'endogeneità è che gli stimatori che vedremo in questo corso sono distorti, e la distorsione non sparisce neanche se aumento il numero di osservazioni, è sistematica. La policy implication sarà sistematicamente sbagliata.
- Uno studente chiede se l'endogeneità sia l'assenza di esogeneità. Il docente risponde di sì: è il caso in cui la correlazione tra X ed epsilon è diversa da zero.
- Se l'errore è correlato con X il modello è sbagliato e andrebbe usata la formula corretta; il software non lo fa perché non gli si dice, e la stima di beta cambia in modo sostanziale.

2.18. Ritorno all'esempio della dimensione della classe

- Nella regressione tra performance e dimensione della classe c'è un problema di endogeneità: nel termine d'errore c'è l'effetto reddito, che non è nel modello. La correlazione tra reddito e dimensione della classe è significativamente diversa da zero; stimando si ipotizza che sia zero, e la stima di beta è meno 2,27.
- Si toglie il reddito dall'errore e lo si inserisce nel modello.

Da verificare. La trascrizione riporta "Togliamo da epsilon il termine d'errore, perché il candidato adesso è una rottura di scatole"; dal contesto si intende il reddito.

- L'epsilon del nuovo modello non contiene più l'effetto reddito, che ora è parte della media condizionale. Il parametro da meno 2,2 diventa 0,64.

Da verificare. La trascrizione riporta "da meno 2,2 diventa 0,64"; poche frasi dopo dice "meno 0,64". Il segno resta da verificare.

- Probabilmente il modello precedente aveva endogeneità: si era usata la formula sbagliata facendo finta che la correlazione tra reddito e dimensione della classe fosse zero. Da meno 2,2 a meno 0,64: la distorsione non è piccola. Sono le conseguenze di stimare facendo finta che $\Delta\epsilon$ sia zero.

Da verificare. La trascrizione riporta "ha un impatto tra note"; si è letto "notevole", ma non è certo.

- Tutto il gioco dell'econometria, a questo livello, è capire quando la variazione di epsilon è uguale a zero in corrispondenza della variazione di X. Il resto è algebra banale; la difficoltà è economica più che tecnica.