Università Ca' Foscari Venezia

Dipartimento di Economia

Laurea Magistrale in
Economia e Finanza

Appunti di Econometria

Appunti delle lezioni, in ordine cronologico

Appunti di:
Silvio Angelo Baratto Roldan

Contenuto:
3 lezioni

Anno Accademico:
2026/2027

Appunti ricavati dalla registrazione delle lezioni: la trascrizione automatica è stata riscritta in forma scritta senza alterarne il contenuto. I passaggi che il riconoscimento vocale non permette di stabilire sono segnalati come «Da verificare». Documento a uso personale di studio.

Indice

1 Lezione del 10 novembre 2026: Introduzione al corso: esogeneità, causalità e correlazioni spurie **1**

2 Lezione del 12 novembre 2026: Causalità, esogeneità e stima della regressione semplice **15**

3 Lezione del 13 novembre 2026: Regressione semplice: esogeneità e proprietà dello stimatore OLS **34**

1 | Lezione del 10 novembre 2026: Introduzione al corso: esogeneità, causalità e correlazioni spurie

1.1. Impostazione del corso: interpretazione economica ed esogeneità

L'impostazione è più intuitiva che tecnica. Il docente non conosce con precisione il background dell'aula: di solito una parte della classe ha già seguito corsi di econometria e circa il 50% ha visto i modelli solo dal punto di vista statistico. Per alzata di mano risulta che quasi tutti hanno già fatto econometria.

Da verificare. La trascrizione riporta "scuota percento della classe" per la quota di chi ha già fatto econometria; la percentuale non è ricostruibile.

Il corso si concentra sull'interpretazione economica ed è fatto soprattutto di ciò che non si deve fare, più che di come si eseguono i calcoli. L'econometria viene spesso presentata come una disciplina tecnica, ma è una disciplina ibrida: la distinzione rispetto all'economia non è netta, mentre lo è quella rispetto alla statistica. A separarla dalla statistica è un'ipotesi aggiuntiva con un'importante implicazione economica, l'ipotesi di esogeneità.

Lo scopo è mostrare che cosa accade quando un modello è costruito in modo scorretto, cioè senza rispettare le regole dell'economia. In quel caso tutti gli indicatori presentati in precedenza dal professore vengono stimati in modo sistematicamente distorto. Ciò che si stima non è l'effetto della politica considerata, ma tale effetto sommato a un fattore di rumore non eliminabile. Anzi, più osservazioni si hanno, più si è precisi nello stimare l'errore. Se interessa un parametro, si stima il parametro più una costante, e di questa costante non si sa nemmeno che cosa sia. Si interpreta quindi come effetto di una politica ciò che è la somma di più effetti collaterali, potenzialmente diversi da quello di interesse. Il corso mostra che cosa succede, sul piano teorico e su quello operativo.

Come ricordava il professore, la scelta del modello e delle variabili conta più della metodologia con cui si fanno poi i conti. Scegliere bene le variabili permette di escludere il problema dell'endogeneità, che è un problema tecnico ed economico insieme. La distinzione sottile è che interessano le relazioni logiche tra variabili, non le relazioni quantitative: non interessa che il modello si approssimi bene ai dati.

1.2. Correlazioni spurie e uso dell'intelligenza artificiale

Il docente avverte che gli indicatori come l'R^2 sono la misura peggiore per valutare un modello e che in questo corso non vanno utilizzati, perché non dicono altro che una correlazione. Le correlazioni possono raccontare storie quantomeno bizzarre, perché molto spesso indicano relazioni spurie tra variabili e non relazioni oggettive.

Lo stesso vale se si chiede a ChatGPT o a uno strumento analogo perché due variabili abbiano una correlazione del 95%: una spiegazione viene sempre prodotta, e che abbia senso o no è irrilevante, perché molto spesso non ne ha. Il docente riporta un episodio. Una serie storica costruita con colleghi di Bologna presentava un picco, e si voleva capire se in quel momento fosse accaduto qualcosa di specifico in quel mercato. Un sistema di intelligenza artificiale, di cui non ricorda il nome, rispose che il picco dipendeva dalla rivoluzione industriale di quegli anni. La rivoluzione industriale era però avvenuta circa 100 anni prima o dopo, e la risposta era completamente sbagliata: il fenomeno osservato era stato spiegato in modo non corretto.

La consapevolezza di ciò che si sta facendo, e di ciò che non si deve fare, è quindi probabilmente più importante. L'intelligenza artificiale, come qualsiasi strumento, può essere utile per affinare l'intuizione, ma il controllo, come diceva la professoressa Biglio, deve restare allo studente. Lo scopo del corso è dare questa consapevolezza: che cosa non fare e come capire quando un modello non va bene. A questo fine bisogna conoscere le potenziali cause di problemi, che sono tipicamente di tre tipi.

1.3. Il termine d'errore e i modelli con troppe poche informazioni

Il primo tipo di problema si ha quando il modello è sbagliato perché contiene troppe poche informazioni. In tal caso ciò che il modello non spiega potrebbe avere un effetto sistematico sulla relazione tra le variabili di interesse.

In statistica e in econometria occorre decidere quale sia la variabile dipendente, y, e quale il driver, x. Interessa la stima del parametro β che lega le due variabili: se β è positivo, all'aumento di x corrisponde un aumento di y, se è negativo accade il contrario. Il problema è stimare β. Il modello non contiene però soltanto due variabili. Nel contesto più semplice ne contiene una terza, il termine d'errore. Dal punto di vista puramente statistico, come si vede in un corso di statistica, è una variabile casuale con media zero e varianza qualsiasi. Dal punto di vista economico raccoglie tutte le informazioni che non sono dentro il modello.

Occorre chiedersi se queste informazioni siano rilevanti e se abbiano un effetto su x. Se lo hanno, a una variazione di x non corrisponde soltanto una variazione di x, ma anche una variazione di y, e ciò che si misura come variazione di y è un misto di cose. La politica economica, che dovrebbe dipendere solo da x, dipende anche da y, ma y non è osservato perché è una variabile casuale non osservabile, un errore. Di conseguenza non si è più in grado di valutare che cosa stia facendo il modello.

Da verificare. Nel passaggio la trascrizione riporta "Y" dove, per il senso (variabile casuale non osservabile, errore), si tratta probabilmente del termine d'errore.

1.4. Previsione e spiegazione: l'esempio della Nutella

Quanto detto non è un problema se lo scopo del modello è fare previsioni. La previsione è un gioco semplicemente statistico: se x assume un certo livello, y assumerà un certo livello. Per preparare la catena di produzione della Nutella non interessa sapere perché la gente la mangia, se sia buona, se costi poco o tanto. Interessa sapere che a un certo momento dell'anno bisogna comprare 7 tonnellate di nocciole. Capire se ci sia una relazione logica tra variabili non è particolarmente rilevante: il problema pratico è rifornire la catena di montaggio. Se una scatola nera indica di comprare 7 tonnellate in quel periodo, si comprano e non serve sapere altro.

Se invece si vuole capire perché la gente compra la Nutella, non basta sapere che la comprava anche ieri. Occorre sapere, per esempio, che il gusto non piace, perché allora bisogna cambiare la ricetta, il packaging e così via.

Il corso presenta esempi della distinzione tra l'analisi statistica, cioè la previsione, e la ricerca dei driver che muovono la variabile. Lo scopo è soprattutto il secondo: il primo, con un modello banale, si realizza in modo quasi automatico. Il docente aggiunge che chi faceva le previsioni sulle nocciole della Nutella guadagnava dell'ordine di un milione di euro l'anno, cifra riferita a 15-20 anni fa, quindi sono lavori di un certo interesse.

Da verificare. L'inciso sui compensi è in parte illeggibile (un riferimento alla Ferrari non è ricostruibile) e poi si parla di "trent'anni" fa, in contrasto con i 15-20 anni.

Il corso mostra soprattutto la distinzione tra statistica ed econometria, che sta nella relazione logica tra le variabili. Dal punto di vista puramente tecnico questa relazione si chiama esogeneità, e viene formalizzata con un indicatore di correlazione tra qualcosa che non si osserva e qualcosa che si osserva. Il docente mostrerà come capire se un modello è affetto da endogeneità e, su quella base, come risolvere il problema. Il primo caso di endogeneità si ha quando nel modello si mettono troppe poche variabili: tutte le altre variabili che non vengono inserite finiscono nel termine d'errore.

Quando una variabile omessa finisce nel termine d'errore, una variazione di x causa una variazione di y e, insieme, una variazione del termine d'errore, che si indica con ε. La variazione della variabile dipendente è allora una combinazione di due componenti, e se ne misura solo il totale senza sapere quanto conti ciascuna.

Da verificare. L'inizio del segmento è garbato ("di Y il termine d'errore chiama epsilon"); la ricostruzione sopra è la più probabile.

Se si capisce che l'imprecisione del modello deriva dal fatto di essere troppo piccolo, la soluzione è togliere variabili dal termine d'errore, cioè inserirle nel modello, usando ragionamenti logici e non numerici. Non si usa una procedura puramente statistica per selezionare l'errore: il

problema è economico, e si tratta di capire quali siano le variabili che contano davvero. A guidare la definizione del modello è la teoria economica, non i dati. Il docente tornerà più avanti su come risolvere il problema.

1.5. Causalità non chiara tra le variabili

Un secondo problema si ha quando la relazione di causa ed effetto non è chiara: è x che influenza y o y che influenza x? In questo contesto si può dimostrare che non si sa più se, muovendo una variabile, si muove l'altra. Si introduce di fatto un riferimento circolare, e non si capisce più quanto una variazione di x incida su y. Il cortocircuito crea una correlazione tra x e l'errore, e la stima dei coefficienti diventa problematica.

1.6. Errori di misura nei dati

L'ultimo problema è più tecnico e più sottile e riguarda la qualità dei dati. Si può dimostrare con facilità che, anche se il modello è perfetto, dati approssimativi e poveri di informazione inducono una distorsione nella stima dei parametri a causa dell'errore di misura delle osservazioni. La distorsione è tanto più grande quanto più è grande l'errore di misura.

Il docente propone un esempio. L'Istat, o un'agenzia che conduce analisi simili, intervista migliaia di persone per capire le loro preferenze di spesa e chiede, per esempio, quanto hanno speso al supermercato nell'ultima settimana. Il docente stesso non ricorderebbe con esattezza la cifra. Se ha speso 190 euro, gli è più facile ricordare 200 e scrivere 200 sul modulo; chi spende 205 riporta ugualmente 200. Quasi tutti fanno un'approssimazione di questo tipo. L'errore di riporto, anche se non è sistematico e la spesa media nel campione è corretta, introduce rumore nella procedura di stima, e questo a sua volta distorce la stima del parametro. Non si sta dicendo che la gente sottoriporti o sovrariporti sistematicamente ciò che ha fatto: è semplicemente imprecisa, perché non ricorda, magari perché la domanda si riferisce a qualcosa accaduto molto tempo prima.

A titolo di aneddoto, il docente racconta che, tornando dagli Stati Uniti dopo circa sette mesi, fu fermato nell'aeroporto di Venezia da addetti dell'Istat che chiedevano quanto avesse speso nell'ultimo viaggio. Diede una stima a spanne, dicendo 10.000 euro, che poteva essere 15.000 o 5.000: non lo ricordava affatto, e il numero era del tutto casuale. Chi invece è stato via una settimana sa indicare con una certa precisione quanto ha speso. Il punto è che la gente non sbaglia a riportare la spesa effettiva se non perché non ricorda.

Il caso è diverso per le evasioni fiscali. In un'analisi fiscale tutti tenderebbero a sottostimare o a sovrastimare, e in quel caso potrebbe esserci una distorsione sistematica. Un campione di quel tipo è quasi preferibile, perché una distorsione di quel tipo si può controllare più facilmente. Qui si parla invece di persone oneste ma un po' imprecise, e questo può creare grossi problemi. Il docente mostrerà con dati simulati, quindi controllabili, che cosa succede in questi casi.

1.7. Struttura del corso

Tutte queste questioni saranno analizzate in parte dal punto di vista teorico, perché la formula aiuta a capire meglio che cosa sta accadendo, e in parte dal punto di vista empirico, perché vedere le conseguenze delle azioni è probabilmente la cosa più utile. La teoria sarà svolta senza un'algebra complicata: il docente cercherà di non usare l'algebra matriciale e di ricorrere a strumenti relativamente semplici, come algoritmi e derivate. I sistemi studiati saranno rappresentati anche in forma matriciale, ma solo per mostrare che non c'è differenza rispetto alla notazione abituale. La matrice è soltanto una strategia per rendere le formule piccole e compatte, né più né meno.

Da verificare. La trascrizione riporta un confronto illeggibile ("rispetto a scrivere le cose come sottopo o per meno"), omesso qui.

La prima parte del corso è una rassegna del modello di regressione, concentrata sui casi in cui il modello non va bene. Nella seconda parte si analizzano i dati in serie storica: la strategia resta sempre la regressione, ma il modello cambia a seconda del tipo di dati disponibili.

1.8. Dati dinamici e stabilità: il limite della media

Nell'analisi del modello di regressione si assume di solito che le osservazioni siano pescate in modo indipendente dalla popolazione: si ha un campione di persone scelte a caso, e le unità statistiche che forniscono le informazioni sono indipendenti tra loro. Se le osservazioni fossero indipendenti, i coefficienti di legame tra di esse sarebbero uguali a zero.

Da verificare. La frase originale ("avrei tutti i coefficienti di legame tra la variabile sarebbe uguale a zero") è garbata; si intende probabilmente il legame tra le osservazioni della stessa variabile.

Nei sistemi dinamici, tipici della finanza, dell'economia e delle serie storiche, le variabili hanno una loro inerzia e non sono osservate in modo indipendente. Se il tasso di interesse oggi è il 5%, domani non sarà 0% né 10%, ma 5% con una piccola variazione. Questo crea un problema di stabilità delle traiettorie dei dati, e la statistica funziona bene se i dati sono stabili nel tempo. Il motivo è intuitivo.

Il docente lo illustra alla lavagna. Si supponga che i dati abbiano un andamento come quello disegnato, tipico del prezzo di un asset finanziario, per esempio i prezzi giornalieri dello Standard & Poor's. Ci si chiede se un fenomeno con una dinamica di questo tipo si possa descrivere con indicatori sintetici. Tecnicamente sì: si può calcolare la media dei prezzi giorno per giorno, e un software restituisce il numero. La media è però un indicatore di centralità, e cade in un punto intermedio rispetto ai dati, rappresentato da una riga orizzontale. Questo indicatore descrive bene il comportamento del fenomeno solo in un intervallo temporale, per puro caso, e non negli intervalli che lo precedono e lo seguono nel grafico.

Se i dati non sono stabili, la statistica descrittiva rappresenta caratteristiche di una popolazione troppo eterogenea nel tempo. Una media che mette insieme i prezzi tipici degli ultimi cinque anni e quelli di trent'anni fa è un numero utile né per descrivere ciò che accade oggi né per descrivere ciò che accadeva allora. Si stanno usando dati che provengono da popolazioni statistiche diverse, ciascuna con una media diversa; mescolandoli, la stima è una stima di medie.

Un esempio più semplice: una popolazione in cui il 50% è alto due metri e il 50% è alto un metro. Pescando a caso, nel campione metà della popolazione avrà altezza molto alta e metà molto bassa. Le medie che rappresentano la popolazione sono quindi due, quelle delle distribuzioni condizionali dei bassi e degli alti, un metro e due metri.

Calcolando però una media aritmetica sul campione, si ottiene una stima di circa un metro e mezzo, che non è un indicatore utile né per il gruppo dei bassi né per quello degli alti. Il problema della stabilità della serie è esattamente questo: se i dati non sono sufficientemente regolari, tutte le statistiche descrittive e tutti i parametri stimati dal modello non hanno alcun significato logico. Numericamente si può calcolare tutto, ma dal punto di vista operativo i numeri non significano nulla. Una delle ipotesi da fare quando si usano dati in serie storica è quindi che la serie sia stabile nel tempo, quantomeno che abbia una media comune.

1.9. Trasformazioni che stabilizzano la serie

Esistono trasformazioni delle serie storiche originali che tendono a stabilizzarle. Sono trasformazioni uno a uno, quindi non fanno perdere informazione, o ne fanno perdere zero. Tipicamente, anziché i prezzi si usano le variazioni di prezzo, cioè i rendimenti. I rendimenti hanno di solito una media stabile, tipicamente zero, come si osserva nei dati. Ciò che cambia nel tempo è invece la variabilità della serie, ma questo si può gestire in modo più naturale.

A questo è dedicata la classe di modelli ARCH e GARCH, usati in finanza, per i quali è stato assegnato il premio Nobel nel 2000 e qualcosa. Il problema diventa capire, per esempio in ambito finanziario, perché la varianza, che è un indicatore di rischio di un investimento, cambia nel tempo e in che modo cambia. Ciò permette di costruire misure di rischio utili dal punto di vista operativo, ed è quello che si fa tipicamente nei corsi di analisi del rischio e di risk management.

Quando i dati sono dinamici e osservati nel tempo, non sono indipendenti. Occorre controllare che la dipendenza sia sotto controllo. Se la dipendenza genera una componente di trend, la statistica descrittiva standard non funziona più. Si può dimostrare anche analiticamente che il teorema del limite centrale e la legge dei grandi numeri non valgono più, e che tutte le proprietà statistiche degli indicatori vengono meno. Il problema è però sostanzialmente logico: si mescolano dati non coerenti tra loro, e il risultato è una mistura di indicatori di centralità di cose estremamente diverse, un numero privo di interpretazione.

1.10. Regressione spuria e cointegrazione

Con le serie storiche bisogna prestare attenzione a questo fenomeno. Se non lo si considera, anche con modelli semplici e facilmente controllabili un test classico assegna un p-value estremamente piccolo, che è il contrario di ciò che ci si aspetta. Il fenomeno si chiama regressione spuria. Si prendono due serie indipendenti per costruzione, ma il test di significatività del coefficiente che le lega risulta sempre diverso da zero. Il motivo è che il test è calcolato sulla base di una distribuzione normale, mentre la distribuzione degli stimatori dei parametri, quando i dati hanno queste caratteristiche, non è più normale. Il software non lo sa e restituisce un numero privo di senso.

In generale, con dati non stabili non si può usare facilmente la regressione, a meno che i dati non siano stabilizzati prima. Fa eccezione la cointegrazione, estremamente importante soprattutto in ambito finanziario ma anche economico. Nonostante i dati abbiano le caratteristiche descritte, se le caratteristiche di regolarità sono più o meno stabili si può sperare che anche la relazione tra le variabili sia stabile, e che il parametro che lega le variabili sia sostanzialmente identificabile.

1.11. Percorso del corso

La prima parte del corso riguarda ciò che non va guardato in un output di regressione e ciò che non va fatto in un modello di regressione quando i dati sono indipendenti. La seconda mostra che cosa cambia in un contesto di dipendenza e quali modelli si possono usare per sfruttare la regolarità nel tempo delle serie. Dal punto di vista concettuale è una seccatura, ma una volta che si sa che un sistema dinamico ha una sua inerzia, la si può usare sia per fare previsioni, sia per cercare modelli migliori dal punto di vista statistico ed economico. I modelli a correzione d'equilibrio saranno l'ultimo argomento.

Lo scopo del corso è quindi dire più che cosa non fare che cosa fare. La parte di interpretazione è particolarmente importante: capire perché si usa un modello e come si interpretano i risultati di quello specifico modello.

1.12. Materiali, software ed esami

Tutto il materiale si trova nella pagina Moodle del corso, Econometria 2026-2027. Il docente carica il materiale prima delle lezioni e lo aggiorna di volta in volta. A parte i primi due set di slide che verranno utilizzati, gli altri sono la versione dell'anno precedente, cambiata solo in parte; quella presente può essere la penultima versione, aggiornata poi con regolarità. La pagina contiene sia i lucidi sia i dataset, perché una parte del corso è applicata. Nelle esercitazioni si vedrà come analizzare i dati e come scovare i problemi di un modello, che certe volte non sono facili da individuare. Le esercitazioni sono tenute dal dottor Peruzzi.

Il software utilizzato è Gretl. Il docente lo ha scelto perché è molto semplice da usare, e permette di concentrarsi sulla parte econometrica più che sui comandi. È immediato, gratuito, disponibile su qualsiasi piattaforma e in certi aspetti migliore di molti altri. Si usa a tasti, e

c'è anche un linguaggio in background, che però non è la cosa più importante. In più, il libro di testo mette a disposizione tutti i dati degli esempi, scaricabili anche in formato Excel: chi è interessato alla materia può riprendere gli esercizi del libro e replicare i calcoli per fare pratica. Il docente osserva che tutti i libri di testo che conosce mettono a disposizione i dati.

In econometria il problema non è stimare il modello, ma capire che cosa si sta facendo e se il modello stimato va bene oppure no. La teoria fornisce una casistica di problemi da controllare quando ci si approccia all'analisi empirica di un modello economico.

Sulla pagina Moodle sono presenti anche i vecchi esami. Prima dell'esame finale si faranno esercitazioni in stile esame, mock exam, per cui il docente potrà distribuire il testo con un certo anticipo; gli esercizi si svolgeranno con lui, con il dottor Peruzzi o con il tutor. Anche questa lezione si può recuperare.

Esame. Il docente incoraggia a venire a ricevimento, anche se di solito ci va poca gente. Conviene risolvere i problemi prima dell'esame, perché dopo l'esame spiegare dove sono gli errori è troppo tardi: il compito è ormai fatto.

1.13. Iscrizione a Moodle, ricevimento e modalità d'esame

Il docente chiede se gli studenti siano iscritti automaticamente alla pagina Moodle del corso quando l'esame è nel piano di studio. Gli studenti rispondono che devono iscriversi manualmente. Il docente consiglia di farlo, se non lo si è già fatto: in questo modo può contattare tutti insieme per comunicare un cambio d'orario di una lezione o l'invio di materiale extra, altrimenti non saprebbe come raggiungerli.

Gli studenti possono scrivere email al docente se l'orario di ricevimento ufficiale non va bene: se il docente è disponibile si può trovare un altro momento, anche online. L'unica cosa che non si può fare online è la visione dell'esame: chi vuole vedere il proprio compito deve andare di persona, perché il docente non ha tempo di scansionare cento compiti. Ricevimenti standard a parte questo non sono possibili. Per chi ne ha diritto, le registrazioni delle lezioni saranno scaricabili dalla pagina Moodle, se la funzione è attiva.

Esame. L'esame è scritto. Il docente rimanda agli esempi dei compiti vecchi. Tipicamente è organizzato in una decina di domande, ma il numero non è fissato, e si chiede di interpretare dei risultati: non si chiede di eseguire le stime. Spiegare come si fa una stima con un software o con un altro è utile a chi vuole diventare più operativo, ma per l'esame non è particolarmente necessario.

1.14. Le lezioni empiriche con il dottor Peruzzi

Il docente consiglia comunque di frequentare le lezioni della parte empirica, perché contengono anche spiegazioni su come interpretare i modelli. La prima di queste lezioni, probabilmente non oggi ma la settimana prossima, tratta che cosa succede quando si riscalano le variabili con trasformazioni come il logaritmo, e come si interpretano gli effetti marginali quando le variabili

sono in una scala diversa, approssimata o esatta. Tratta anche come diagnosticare un problema patologico del modello, la quasi collinearità: la collinearità esatta è facile, perché con due variabili esattamente collineari il software si blocca, mentre la quasi collinearità non è altrettanto facile da riconoscere. Questi casi sono trattati in modo empirico, ma servono anche nel compito. La parte empirica è più intuitiva per spiegare alcuni strumenti, come il variation factor, che serve a diagnosticare un problema di quasi collinearità. Se non ci si accorge del problema, si crede che il modello dia risultati corretti, mentre non lo sono.

Da verificare. La trascrizione riporta "variation factor"; probabilmente il variance inflation factor (VIF), che non compare nelle note del corso.

Le lezioni empiriche sono importanti perché, insieme alla parte meccanica (come si stima il modello, come si fanno le cose), contengono una componente di interpretazione legata a ciò che si fa dal punto di vista teorico. L'idea è creare un legame tra teoria e pratica.

Il compito conterrà dunque domande in cui si chiede di interpretare risultati, analizzando grafici e tabelle, e di capire se il modello ha un problema oppure no. Per la parte di serie storica si chiede inoltre di capire se un modello è corretto dal punto di vista metodologico, di interpretare i risultati dinamici e statici di un modello dinamico, e così via. Ci sono già esempi, e prima dell'esame si vedranno esercizi di questo tipo.

1.15. Feedback e libro di testo

Il docente invita a interromperlo in qualsiasi momento, perché il feedback sul momento gli fa piacere: il corso è per gli studenti, non per lui, e più ne beneficiano meglio è. Aggiunge che una delle cose che odia di più è correggere i compiti, quindi se tutti passassero con voti altissimi sarebbe la persona più felice del mondo. Se nessuno dà feedback, va avanti per la propria strada e potrebbe esserci uno scarto tra lui e gli studenti; se se ne accorge alle ultime tre lezioni, c'è poco da fare. Si possono dare feedback di qualsiasi natura, e il docente precisa di non essere vendicativo. Se ci sono interessi specifici da esplorare, il programma può essere modificato volentieri, se c'è tempo. Si può intervenire durante il corso, a fine lezione o a ricevimento.

L'acquisto del libro non è obbligatorio, perché non si può obbligare ad acquistarlo, ma è un supporto utile. Il docente lo segue abbastanza ed è molto discorsivo: contiene la parte tecnica ma anche molti esempi che portano a capire la tecnica, soprattutto nei capitoli sulle serie storiche e sulla regressione. Ci sono poi argomenti in più che non c'è il tempo di trattare. Il libro è disponibile in biblioteca. Il docente consiglia di leggerlo, perché aiuta a capire i dettagli che a lezione non fa in tempo a raccontare, e di non limitarsi ai lucidi pubblicati online: sono uno schema per prendere appunti, o una scaletta per il docente, messa a punto in circa trent'anni di insegnamento. Il libro dà di più, e in particolare contiene molti esempi che spiegano bene il perché delle cose.

1.16. Materiale introduttivo e definizione di econometria

Questo è il primo set di lucidi, di introduzione al corso. Il docente ha inserito nella pagina Moodle anche informazioni tratte da appunti usati qualche anno fa per un corso di statistica di base, per richiamare i concetti essenziali e gli strumenti che servono per dimostrare i risultati. Il materiale è molto semplice, ma una volta capito come funzionano varianze e medie, il resto è abbastanza semplice. Chi vuole richiamare la statistica per fissare la notazione, per esempio perché la media si indica con E, trova tutto all'inizio della pagina Moodle.

L'econometria ha tre scopi, che in generale si possono racchiudere nell'analisi quantitativa di modelli economici. Non esiste nemmeno una definizione chiara di che cosa sia: il docente dice di non averla ancora capita alla sua età, ma c'è abbastanza consenso su tre aspetti. Il primo è la misura delle relazioni di causa ed effetto tra variabili. Il secondo è fare previsioni, che è però più statistica che econometria; il docente osserva che gli econometrici sono "una famiglia accogliente" e prendono dentro anche gli statistici. Il terzo, che gli piace particolarmente, è usare metodologie anche avanzate per valutare teorie economiche.

Si parta da un modello economico astratto, per esempio il CAPM, che si vede spesso nelle applicazioni finanziarie. Il CAPM non è un'equazione: sono due pagine di algebra che portano a un'equazione secondo cui gli extra-rendimenti di un investimento sono proporzionali agli extra-rendimenti di un portafoglio di mercato, qualsiasi esso sia. Il problema è che quella è un'equazione. Per arrivare al modello occorrono molte ipotesi: che il mercato dei capitali sia in equilibrio, che il mercato dei tassi di interesse sia in equilibrio, che gli investitori costruiscano portafogli con l'algoritmo di Markowitz, ipotizzando che funzioni. Si fanno i conti e si ottiene quella relazione.

Il punto è se quella relazione sia credibile e se i dati la supportino. Come si può validare il modello? Se il modello fosse vero, un rendimento in media non dovrebbe garantire un premio extra per il rischio, e dal punto di vista operativo ciò si traduce nel fatto che il modello di regressione non può avere l'intercetta. Per validare un modello banale come il CAPM, dimenticando tutto ciò che porta all'equazione finale, si può costruire una regressione semplice che include l'intercetta e valutare se l'intercetta è uguale a zero oppure diversa da zero. Questo potrebbe essere un possibile test; non è detto che poi funzioni, ma è un'idea. L'idea è usare una metodologia econometrica per verificare se un modello economico è coerente con i dati, perché un modello economico incoerente con ciò che si osserva ha pochissima utilità.

Se il modello economico non supera il test econometrico, non si può semplicemente aggiungere un'intercetta al modello. Aggiungerla significherebbe cambiare tutte le equazioni e tutte le ipotesi fatte prima, cioè le due pagine di algebra precedenti. Se il test econometrico non supporta il modello economico, bisogna rispecificare il modello economico in modo che il modello statistico accetti quelle variazioni. La validazione di un modello è quindi un'altra funzione importante: si ha una teoria, si hanno dei dati, e si vuole vedere se la teoria è coerente nello spiegarli. Il docente dice che questa è la parte per lui particolarmente importante, la sua preferita.

1.17. Relazioni di causa ed effetto e criteri di causalità

La prima parte del corso riguarda le relazioni di causa ed effetto. Il docente vuole spiegare brevemente che cosa sono e qual è il pericolo nell'usare i metodi statistici senza aver pensato prima, a monte dell'analisi empirica, a quali siano le potenziali relazioni logiche tra le variabili.

Dal punto di vista grafico, una relazione causale si rappresenta con due variabili, x e y, e una relazione asimmetrica: x ha un impatto su y ma non viceversa. x è un driver per y, e il viceversa non vale. Il problema tipico è capire se x sia una causa di y oppure no. Perché la relazione tra due variabili sia di causa ed effetto, devono valere sostanzialmente tre criteri.

Il primo è un criterio puramente statistico. Il docente precisa che con ciò ritira quanto detto poco prima: la parte statistica è diversa dalla parte economica, ma in realtà è l'inizio. Per vedere se esiste una relazione causale tra due variabili occorre prima stabilire che esista almeno una relazione statistica. Senza relazione statistica, anche se ci fosse una relazione causale, una variazione di x non avrebbe impatto su y e l'interesse per il problema verrebbe meno. Se le variabili sono quantitative, ci deve essere una correlazione statisticamente significativa tra x e y.

Il problema è che la correlazione è una relazione simmetrica tra le variabili, mentre nel grafo si è definito che x ha un impatto su y e non viceversa. La correlazione tra x e y e quella tra y e x sono lo stesso numero, quindi una correlazione non dice nulla sulla direzione. Indica solo un legame di qualche natura, non necessariamente logico. Per definire una relazione causale bisogna aggiungere ipotesi: ci deve essere un legame logico tra le variabili, non solo statistico, con una variabile che ne anticipi l'altra non solo dal punto di vista temporale ma dal punto di vista puramente logico. Non basta un legame statistico tra due quantità: serve una storia che spieghi perché esiste quel legame statistico, e quella storia deve essere unica. Non basta sapere che c'è un legame logico, occorre che sia unico. Il docente mostrerà esempi per legare questo ragionamento astratto alla pratica economica, probabilmente nella lezione successiva, guardando alcuni dati.

Da verificare. Il docente annuncia tre criteri ma ne enumera esplicitamente solo il primo; gli altri due (legame logico con precedenza logica, storia unica) sono ricostruiti dal seguito. Il passaggio sul caso di più storie coerenti con la stessa dipendenza statistica ("lo troverò migliore") è garbato e non è riportato.

1.18. Correlazioni spurie: Big Bang Theory e lacrosse

La cosa importante è che il legame statistico non è sufficiente. Per mostrarlo, il docente propone un esempio scaricabile online da una pagina web di uno statistico buontempone. Lo statistico ha un database di circa 10.000 variabili e ha chiesto a un programma di cercare le coppie di variabili più correlate possibili, senza considerare quali variabili fossero.

Nel primo esempio la serie storica nera è il numero di persone che hanno guardato la serie televisiva Big Bang Theory, e la serie rossa è il numero di ricerche su Google che cominciano

con “how to make”. Dal punto di vista logico non c’è alcun legame tra le variabili, ma il grafico mostra due serie estremamente vicine. Paradossalmente, sapendo che nel 2016 Big Bang Theory ha avuto un certo livello di visibilità, si potrebbe usare questa informazione per prevedere il livello dell’altra variabile, perché la correlazione è forte. Dal punto di vista puramente predittivo le due serie sono correlate e si potrebbe usare l’una per prevedere l’altra. Ma questa correlazione non ha una spiegazione logica, e tipicamente le relazioni di questo tipo non ce l’hanno.

L’R^2 della relazione è 96,5%. Questo valore spiega solo il legame statistico, non altro, ed è un numero molto fuorviante: dice soltanto che le due serie si muovono insieme, non perché. Considerando un modello di regressione e usando l’R^2 come indicatore di bontà del modello, esso indica che i dati sono ben approssimati, non che il modello è corretto dal punto di vista logico, che è ciò che si cerca.

Sul sito, in alcuni casi, sono presenti spiegazioni prodotte con intelligenza artificiale del motivo di una correlazione così alta.

Un secondo esempio mette in relazione l’esito delle partite finali di lacrosse, sport molto popolare negli Stati Uniti (serie nera), con i biglietti venduti al cinema (serie rossa). Non c’è alcun legame sostanziale tra le serie, ma anche qui la correlazione è alta: intorno al 74%, in ogni caso oltre il 50%. Se si chiede all’intelligenza artificiale di spiegare l’associazione, qualcosa viene fuori, e una storia si può sempre trovare. Il punto è che non è una storia che abbia necessariamente senso.

Da verificare. “la cross” è ricostruito come lacrosse; la correlazione è riportata come “il 74% o più del 50%”, valore non univoco.

Il docente invita a guardare questi esempi per vedere che il legame statistico non ha niente a che fare con il legame logico. È solo uno dei prerequisiti, il primo pezzo. Un R^2 grande non vuol dire che il modello vada bene. Anzi, tipicamente i modelli buoni non hanno un R^2 molto grande, e un R^2 troppo grande porta con sé problemi statistici non banali, noti come problema di collinearità.

Nelle serie mostrate le variabili sono molto legate dal punto di vista statistico, ma nessun motivo logico le lega. Combinarle non spiega perché una delle due si muova, e quindi non dà alcuna capacità di fare analisi di scenario.

Le variabili degli esempi sono piuttosto inutili, ma si immagini di trovare una correlazione tra due variabili economiche che non c’entrano niente l’una con l’altra e di voler fare un’analisi di scenario, come quelle citate dal professore. Qualsiasi risultato sarebbe del tutto casuale e non replicabile, perché non c’è un legame.

1.19. Come lavorare quando non esiste una risposta definitiva

Per quanto ci si sforzi di trovare relazioni causali, non si sarà quasi mai in grado di avere una risposta definitiva. Si può spiegare logicamente il legame statistico tra due variabili, ma è

quasi impossibile escludere tutte le altre spiegazioni logicamente valide della correlazione. Nulla è però perduto: la distinzione causale fornisce una chiave di lettura e una regola di lavoro.

Ogni volta che si costruisce un modello bisogna capire perché lo si fa e perché si selezionano certi tipi di variabili. Si verifica poi se il modello descrive le aspettative, per esempio se i coefficienti hanno il segno corretto. Un segno sbagliato può indicare che le correlazioni attese non sono stimate in modo corretto, come si vedrà formalmente. Lavorare in modo logicamente coerente permette alla disciplina di avanzare, cioè di far progredire lo studio di un certo fenomeno. Il proprio modello può non essere quello definitivo, ma contribuisce al lavoro degli altri che cercano di risolvere lo stesso problema, provano altri modelli e valutano se il loro è migliore. Si va avanti finché non si trova un equilibrio in cui c'è consenso: si è provato con 10.000 modelli su un fenomeno specifico, si è convinti che la relazione causale sia esattamente questa e tutte le altre sono state escluse.

La speranza di trovare un modello perfetto, che rispecchi le tre caratteristiche viste, è quindi troppo ambiziosa; soprattutto la terza richiederebbe troppo tempo. Secondo il docente è importante capire che la relazione statistica non basta e che occorre ragionare ogni volta in termini di legame logico tra le variabili. Una volta pensato un legame logico, si prova a vedere se resiste a spiegazioni alternative logicamente ben strutturate. Un po' alla volta, nel tempo, ci si fa un'idea. Bisogna lavorare sempre in questa dimensione, pensando che ciò che si fa non sarà definitivo ma che va fatto con regole sostanzialmente precise. Provare regressioni e modelli buttando dentro i dati, nella speranza di trovare qualcosa che piaccia in termini di segni, non è sufficiente. È difficilissimo trovare relazioni causali, ma con un po' di pazienza qualcosa si trova.

1.20. Esempio: fumo e malattie ai polmoni

Il docente non ha con sé i dati reali, ma riassume quanto emerso nella letteratura epidemiologica nel corso di molti anni. L'associazione tra fumo e gravi malattie ai polmoni c'è, la correlazione c'è. È sufficiente per dire che esista una relazione di causa ed effetto? No. Negli anni sono state testate varie ipotesi e varie teorie, per decine di anni e non per settimane. Un po' alla volta si è trovato che il legame è logico, cioè c'è un motivo biologico per cui il consumo di sigarette può aumentare l'incidenza di certi tipi di malattie: sono stati individuati dei meccanismi. Basta? No, potrebbero esserci altri meccanismi non ancora visti. Questo screening tra le varie opzioni è però stato raffinato, e oggi si ritiene più o meno che esista una relazione di causa ed effetto. È definitiva? Probabilmente sì, ma se qualche biologo trovasse un'alternativa più convincente di quelle attuali, bisognerebbe ripensare tutto. La procedura va dunque avanti in modo progressivo, e trovare un modello che risolva tutti i problemi in modo definitivo è praticamente impossibile.

Da verificare. La trascrizione riporta "negli ultimi centinaia d'anni" per l'arco della letteratura epidemiologica; poco dopo il docente parla di "decine di anni".

Ciò che conta è che, ogni volta che si propone o si lavora su un modello, ci sia la convinzione che non sia un semplice tentativo, ma un tentativo fatto con un background. Prima di affrontare un problema economico e prima di arrivare ai dati, bisogna capire quali siano i potenziali driver

di interesse, e solo dopo inserirli nel modello. Non si deve fare il contrario, cioè mettere tutto nel modello e poi selezionare le variabili finché non si trova qualcosa. La teoria deve definire a priori i legami logici, e non ci si può far raccontare la storia dalla correlazione.

1.21. Esempio: boy scout e criminalità, la causalità inversa

Un altro tipo di problema si vede con un esempio di dati inventati, tratti da un libro di statistica, che mostra da dove possono nascere le correlazioni spurie tra variabili. È una tabella a doppia entrata in cui si osservano dei ragazzini: alcuni hanno fatto i boy scout da piccoli, e anni dopo è stato guardato il loro record criminale. I dati non sono reali, potrebbero esserlo; il docente li ha ricopiati da un libro di testo usato per un corso di statistica anni fa.

Una variabile indica se si è stati boy scout, sì o no; l'altra se si sono avuti problemi con la giustizia. Si osserva che tra chi ha fatto il boy scout l'incidenza di problemi con la giustizia è più bassa, mentre nelle altre celle della tabella le percentuali sono alte. Sembra quindi che ci sia una relazione negativa tra l'essere stati boy scout e l'essere un criminale.

Ci si chiede se questa correlazione sia supportata da un'intuizione logica. Chi ha fatto il boy scout viene magari educato a comportarsi bene: gli vengono date regole e principi, e gli si fa capire che aiutare un'anziana ad attraversare la strada è positivo. Chi ha fatto il boy scout avrebbe quindi ricevuto input diversi dagli altri, sarebbe una persona migliore, tra virgolette, e avrebbe una probabilità più bassa di essere arrestato. È una relazione del tipo boy scout, delinquenza.

Un'altra persona potrebbe obiettare che chi è totalmente cattivo probabilmente non si sarebbe mai iscritto ai boy scout: chi è avverso al rispetto delle regole non va in un posto dove ne trova molte. Essere una persona avversa alle regole farebbe quindi sì che non ci si iscriva ai boy scout, e la correlazione si spiegherebbe nella direzione opposta. Il legame statistico, che è simmetrico, non dice nulla sulla direzione tra le variabili. Questo si chiama reverse causality, ed è un problema per la stima di una relazione di causa ed effetto. Prima ancora di arrivare al modello bisogna quindi ragionare su quali siano i potenziali legami logici tra le variabili.

1.22. Prossima lezione

La lezione di oggi era una chiacchierata. A partire dalla prossima, giovedì, si ragionerà su come definire un modello statistico che cerchi di descrivere una relazione causale e su come capire quando il modello statistico supporta o non supporta una relazione di questo genere.

2 | Lezione del 12 novembre 2026: Causalità, esogeneità e stima della regressione semplice

2.1. Le condizioni della relazione causale

La lezione procede nello specifico, mantenendo una componente di intuizione. Il docente la considera la cosa più importante da capire, perché una volta acquisita l'intuizione formalizzarla con concetti statistico-matematici è abbastanza semplice.

Nella lezione precedente sono state introdotte le relazioni causa-effetto, che devono avere tre caratteristiche sostanziali. La prima è che tra le variabili di interesse ci sia una correlazione. La correlazione però non basta: tra variabili aleatorie quantitative è un concetto simmetrico, per cui la correlazione tra Y e X è uguale a quella tra X e Y, mentre la relazione causale è unidirezionale, nel senso che una X ha un impatto su Y ma non viceversa. Il controesempio, scherzoso, era quello dei boy scout e della probabilità di avere un record giudiziario non ottimale. L'associazione tra due variabili può spiegare un fenomeno ma anche il fenomeno reciproco, e in quel caso non si può parlare di relazione causale.

2.1.1. L'esempio della dimensione della classe in California

Un esempio più vicino a ciò che si farà nel corso è quello di cui sono disponibili i dati. Riguarda un problema posto in California qualche anno fa: investire in una politica pubblica per migliorare il livello scolastico dei bambini può essere utile oppure no? Definire un programma di questo tipo pone vari problemi, il primo dei quali è che cosa significhi "utile". Questo però non è un problema dell'econometrico o dello statistico, è un problema più filosofico.

Il problema concreto riguarda i bambini della scuola prescolastica (asilo, scuola dell'infanzia): ridurre la dimensione delle classi può migliorarne l'apprendimento? È intuitivo pensare di sì, perché in classi più piccole l'insegnante riesce a dedicare più tempo a ogni singolo bambino, con miglioramenti nelle capacità pratiche e astratte. Si vuole quindi capire se la policy sia utile, cioè se riducendo la dimensione della classe i bambini vadano meglio a scuola, intendendo con questo che ottengano risultati migliori nei test di fine anno.

Attuare una policy del genere però costa molto. Occorre assumere più docenti e riorganizzare le classi: se ci sono 100 bambini e li si distribuisce in classi da 10 anziché da 20, servono più classi, più computer e più attrezzatura. L'investimento è stato quantificato, a memoria del docente,

in circa 1,8 miliardi di dollari l'anno. Vale la pena farlo? Dipende dal fatto che la variabile su cui si interviene sia in relazione causale con la performance dei bambini. Serve quindi un modello causale che dica se la dimensione della classe sia un driver, non statistico ma logico, di tale performance.

2.1.2. I dati e la correlazione negativa

Per l'analisi sono stati raccolti dati reali sui distretti scolastici. La California è divisa in circa 420 distretti, e ogni pallino del grafico rappresenta un distretto. Sull'asse delle x c'è la dimensione media della classe nella scuola dell'infanzia del distretto, sull'asse delle y il punteggio medio dei bambini del distretto in un test. Il test valuta competenze di matematica, logica e lingua adatte all'età dei bambini ed è standardizzato.

Facendo passare una retta che approssimi la nuvola di punti, si osserva che la pendenza è negativa: all'aumentare della dimensione media della classe la performance tende a diminuire leggermente. Se la diminuzione sia piccola o grande è una valutazione che non spetta a questa analisi. La pendenza negativa significa, come si formalizzerà più avanti, che la correlazione tra le due variabili è minore di zero. Rispetto alla ricerca di una relazione causale, questo è il primo ingrediente.

Il secondo ingrediente è una spiegazione logica per cui una classe più piccola può avere effetti benefici sulla performance dei bambini. Il docente la ritiene soddisfatta in termini generali: dal punto di vista dell'attenzione che ogni bambino riceve dal docente, in teoria le classi più piccole sono più focalizzate e si lavora meglio. Non è detto che la spiegazione sia corretta, ma è plausibile. Si è dunque trovata una correlazione e una spiegazione più o meno sensata.

2.1.3. Il terzo ingrediente: escludere spiegazioni alternative

Il terzo ingrediente deve valere perché si possa parlare di relazione causale: bisogna poter escludere altre spiegazioni più convincenti. Occorre cioè chiedersi se l'effetto benefico della dimensione della classe sia la migliore spiegazione disponibile, sensata e coerente con la statistica. Per stabilirlo si devono fare altri esperimenti e provare modelli alternativi. Una spiegazione esaustiva non si troverà, perché non si possono costruire infiniti modelli che spieghino la correlazione negativa in modo alternativo. L'idea è che, avendo una teoria da verificare, si considera una serie di alternative ragionevoli per vedere se la teoria resta la strategia migliore o se c'è qualcosa di meglio.

Come già detto nella lezione precedente, non ci sarà mai una soluzione corretta in assoluto, ma una soluzione che si muove nella giusta direzione con criteri di scelta sostanzialmente razionali.

Stimando la pendenza della retta di regressione si può valutare, per esempio, se la riduzione di un'unità della dimensione della classe produca un beneficio di 10 punti al test. Il docente precisa che 10 punti possono essere molti o pochi, a seconda della scala del test. Il problema ora, però, non è quantificare gli effetti ma capire se esistano modelli migliori, e questi possono passare per l'analisi congiunta di altre variabili.

Una di queste è il reddito, che ha impatto su fondamentalmente tutte le scelte. Il reddito può spiegare in modo più convincente la relazione negativa tra dimensione della classe e performance? Dal punto di vista della catena logica può essere, perché i distretti ad alto reddito potrebbero avere performance migliori. In un distretto ad alto reddito le famiglie possono permettersi di comprare più libri ai bambini, e questo può riflettersi in una migliore performance scolastica.

Un'altra possibilità è che i distretti ad alto reddito abbiano scuole mediamente migliori. Trattandosi di dati americani, il distretto di appartenenza conta. Dove ci sono buone scuole pubbliche, la scuola privata costa moltissimo già dalle elementari, nell'ordine di decine di migliaia di dollari l'anno. Chi non può permettersi queste cifre vorrebbe una scuola pubblica, ma il livello delle scuole pubbliche è abbastanza eterogeneo. In alcuni distretti ci sono scuole pubbliche molto buone, e questo si riflette nel prezzo delle case della zona, che è estremamente più alto. La scuola pubblica buona, che costa relativamente poco, si trova quindi in un distretto ricco. Il reddito può dunque avere un effetto sulla qualità della scuola, che a sua volta incide sulla qualità dei risultati dei bambini.

Il reddito potrebbe così avere un effetto positivo sulla performance e un effetto negativo sulla dimensione della classe, perché le scuole migliori hanno già classi più piccole, magari perché hanno più insegnanti. Il docente osserva che negli Stati Uniti il concetto di dimensione della classe è un po' particolare: non ci sono necessariamente classi fisse, perché le classi si formano di volta in volta, e la dimensione viene calcolata come rapporto studenti-insegnanti. Una scuola migliore può avere più insegnanti e altre caratteristiche favorevoli.

Si vuole quindi vedere se esiste una relazione negativa tra reddito e dimensione della classe e una relazione positiva tra reddito e performance. In tal caso la relazione negativa osservata tra le due variabili iniziali potrebbe passare per l'effetto del reddito. Il reddito agisce con segno diverso sulle due variabili; se lo si omette, si vede soltanto la correlazione marginale tra dimensione e performance.

Da verificare. La trascrizione riporta "se lo ometto vedo solo la marginale, vedo la correlazione condizionale"; probabilmente il docente intendeva che omettendo il reddito si vede la correlazione marginale e non quella condizionale al reddito.

2.1.4. Come verificare il ruolo del reddito

Come stabilire quale dei due modelli sia migliore è ciò che si farà con i modelli statistici. Si vuole evitare che il reddito sia il vero driver, e quindi si controlla per il reddito. Se due distretti che non differiscono per reddito mostrano una correlazione alta o bassa tra le variabili chiave, il reddito non è un fattore determinante. Condizionandosi a distretti molto simili e studiando la correlazione tra performance e dimensione della classe, tale correlazione non può dipendere dal reddito, perché il reddito è uguale per tutti. Prendendo due distretti molto ricchi e calcolando tra loro la dipendenza tra dimensione della classe e performance, la correlazione non può dipendere dal reddito, perché le osservazioni provengono da un contesto molto omogeneo.

L'obiettivo è valutare se la correlazione stimata in precedenza, cioè la pendenza della retta rossa del grafico, sia spiegabile tramite il reddito. Il campione si divide in due sottoinsiemi, distretti ricchi e distretti poveri, e all'interno di ciascun sottocampione si studia la dipendenza tra le variabili chiave. Se la dipendenza non cambia, il reddito non è un fattore rilevante e aggiungerlo non ha alcuna utilità pratica. Se invece le correlazioni cambiano a seconda che si considerino distretti ricchi o poveri, il reddito è un fattore determinante, e per spiegare logicamente la correlazione negativa osservata tra performance e dimensione della classe bisogna passare per il reddito.

Per validare l'introduzione di una nuova variabile si controlla dunque se essa abbia un impatto sulla relazione di interesse. Quello che interessa al responsabile politico della California (provveditore, ministro o equivalente) è se i circa due miliardi di dollari l'anno da spendere servano a migliorare la performance. Se la correlazione negativa risultasse un semplice effetto collaterale del reddito, assumere nuovi docenti probabilmente non sarebbe particolarmente utile. Sarebbe forse più opportuno dare sussidi alle famiglie meno ricche, se l'obiettivo è migliorare la performance.

In pratica si prendono i 420 distretti, li si divide in ricchi e poveri e si calcola la correlazione tra performance e dimensione della classe tra i distretti ricchi e, allo stesso modo, tra i poveri. Se i due numeri sono diversi, il reddito ha potere esplicativo per il fenomeno. Se restano uguali, la relazione è la stessa indipendentemente dal reddito. Dal punto di vista operativo, se i dati dicono che un modello più complesso non vale la pena, tanto vale usare il modello logico precedente, quello senza reddito. Se invece i numeri sono diversi, aggiungere il reddito è importante, il modello precedente va scartato perché non soddisfacente e si passa al modello esteso.

L'analisi non è conclusa a questo punto, perché potrebbero esserci altri fattori da considerare. Si ha però un meccanismo di scelta: si estende il modello, si cerca di capire se migliora rispetto al precedente, si fanno valutazioni di natura logica e si traggono le conclusioni. La strategia è non fissarsi sul modello iniziale e sull'idea iniziale, ma estenderla per capire quale sia la spiegazione migliore dell'indicatore statistico visto all'inizio. Lo scopo è spiegare la correlazione negativa, cioè capire perché esista.

2.1.5. Le statistiche descrittive delle tre variabili

Le statistiche descrittive riguardano le tre variabili in gioco: avg inc, il reddito medio per distretto; STR, la dimensione della classe (student teacher ratio, rapporto studenti-insegnanti); average score, il punteggio medio. Tra punteggio e dimensione della classe c'è una correlazione negativa, pari a $-0{,}22$, statisticamente significativa nel senso che, in un test di significatività, risulta diversa da zero. Il reddito medio è fortemente correlato con il punteggio: i distretti ad alto reddito tendono ad avere performance decisamente migliori, con una correlazione altissima, significativa, pari a 0,70. Tra reddito e dimensione della classe c'è una correlazione negativa: i distretti ad alto reddito tendono ad avere classi mediamente piccole.

Da verificare. La trascrizione riporta "0,70 per cento" per la correlazione tra reddito e punteggio; poiché si tratta di un coefficiente di correlazione, il valore è presumibilmente 0,70.

I dati grezzi sono disponibili nella pagina Moodle del corso. Le analisi mostrate finora sono solo grafiche, e il grafo che segue è lo schema logico descritto fin qui a parole.

Se non si considera il reddito (ignorando la prima parte del grafo), la prima potenziale relazione causale tra le variabili è quella tra dimensione della classe e performance. La relazione è statisticamente rilevante e negativa, ha senso dal punto di vista logico e potrebbe essere un buon candidato come relazione causale. Quando si guarda l'effetto del reddito, risulta una relazione negativa con la dimensione della classe e una positiva con la performance. Aggiungendo questo fattore di controllo, ci si chiede che cosa succeda alla correlazione negativa iniziale: se essa sia una connessione diretta tra i due blocchi oppure se sia spiegata dalla terza variabile.

2.1.6. Il confronto tra distretti a basso e ad alto reddito

Per verificarlo si divide il campione in due parti e si calcola la correlazione tra le due variabili in ciascuna. L'analisi mostrata è molto grossolana: si è calcolata la mediana del reddito, e i distretti sotto la mediana sono stati classificati a basso reddito, quelli sopra ad alto reddito. Come funzioni questo procedimento si vedrà meglio con il modello di regressione.

Per i distretti a basso reddito la correlazione tra dimensione della classe e performance diventa piuttosto piccola. Il punto principale non è la differenza rispetto a $-0{,}22$, ma il fatto che, in un test di significatività, il valore non risulta statisticamente significativo.

Da verificare. La trascrizione riporta "il punto grosso non è neanche che il numero non è tanto diverso da meno 0,22"; il senso sembra essere che il valore è piccolo in assoluto, ma ciò che conta è la non significatività.

Per i distretti a basso reddito il reddito sembra dunque essere il driver principale della correlazione negativa: condizionatamente al reddito basso, la correlazione condizionale tra dimensione della classe e performance è sostanzialmente zero. Anche per i distretti ad alto reddito la correlazione è piuttosto bassa e il test di significatività la indica come non significativa. Il p-value del test è leggermente più alto, comunque non sufficiente a giustificare un livello di significatività.

Il messaggio principale è che, controllando per il reddito, la correlazione tra la variabile di interesse e quella su cui si vorrebbe investire è non significativa. Il nuovo modello, che passa per il reddito, supera quindi il precedente: contiene più informazione e le conclusioni inferenziali che ne derivano escludono il modello precedente. La correlazione tra dimensione della classe e performance non è significativa, e la correlazione marginale non è così importante perché la correlazione condizionale ai livelli di reddito non è statisticamente significativa. Il nuovo modello è anche sensato a parole, e il modello superiore esclude l'altro, per cui occorre concentrarsi su una relazione logica di questo tipo.

In caso contrario si spenderebbero circa due miliardi di dollari l'anno di denaro pubblico per intervenire su una variabile che solo apparentemente è legata alla variabile di interesse, la performance dei bambini, e da cui questa non dipende direttamente. Probabilmente non si avrebbe un effetto diretto sulla performance. Le risorse andrebbero forse usate per migliorare

le condizioni delle persone meno abbienti, perché il reddito sembra la variabile chiave con un impatto sulla performance dei bambini.

2.1.7. La stessa analisi con il modello di regressione

Il docente anticipa come tradurre tutto questo in un modello di regressione, che gli studenti hanno già visto in linea generale; interessa soprattutto l'intuizione, e le formule verranno spiegate meglio in seguito. Il primo modello è la relazione lineare tra il punteggio dei bambini e la dimensione della classe. La pendenza della retta di regressione stimata è $-2{,}27$. Con un test di significatività su questo coefficiente, per verificare se il parametro sia diverso da zero, il p-value risulta zero. Si può quindi affermare che esiste una pendenza negativa, quella della linea rossa dello scatter plot che descrive i dati.

Si aggiunge poi l'effetto del reddito. Nel nuovo modello di regressione l'aspettativa sulla performance dipende dalla dimensione della classe, X_1, e dal reddito, X_2. Stimando questo modello, il coefficiente che lega la performance alla dimensione della classe si più che dimezza: da circa $-2{,}2$ passa a $-0{,}64$. Il test di significatività dà un p-value maggiore del 5%, non esageratamente grande. Aggiungendo il reddito, l'impatto della dimensione della classe sulla performance si riduce di molto. In un'analisi stretta, condizionatamente al livello di reddito la dipendenza lineare tra performance e dimensione della classe è nulla, come già indicato dal p-value dell'analisi per sottocampioni.

Costruire un modello con due variabili equivale a dividere il campione in due pezzi, alto e basso reddito, e a calcolare il livello di dipendenza nei due sottoinsiemi. Questo sarà ripreso più avanti, la settimana prossima o forse già il giorno dopo.

2.1.8. Estendere il modello con coerenza logica

Per capire se una relazione sia causale, uno dei problemi principali è incrementare il modello in modo logico e verificare se il nuovo modello migliora il precedente. Il modello più esteso deve mantenere sempre coerenza logica, con una spiegazione che valga la pena di usare. Non si possono inserire informazioni come il numero di persone che in California vanno a vedere il film di Nicolas Cage: potrebbero essere correlate, ma la correlazione potrebbe dipendere da qualunque cosa. Quando si inserisce una variabile nel modello serve una storia da raccontare, e non si lascia che siano i dati a dire che cosa si vuole spiegare. Il docente indica questa come la cosa più importante, e con essa conclude la lezione di due giorni prima.

2.2. Il modello di regressione semplice e l'esogeneità

Si passa al trattamento formale del modello di regressione, che è il principale punto di riferimento per questo tipo di analisi, anche perché è estremamente semplice. Il docente si concentra sul modello di regressione semplice: se se ne capiscono le sottigliezze alla base della definizione, l'estensione ai casi più complicati è banale e cambia soltanto un po' l'algebra.

L'idea fondamentale è capire se la relazione causa-effetto sia buona. Lo è se vale una pro-

prietà statistica del modello, accennata nella lezione precedente: l'esogeneità. Essa significa che le spiegazioni alternative non possono avere un impatto sistematico sulla relazione chiave tra le variabili che si vogliono usare. Le spiegazioni alternative si descrivono con una variabile specifica del modello, tipicamente non osservabile, che è il termine d'errore. Il termine d'errore include tutte le informazioni che potrebbero avere un impatto sulla relazione di interesse ma non vengono utilizzate: è un contenitore di elementi non osservabili, che può però avere una sua interpretazione.

2.2.1. L'esempio di istruzione e salario

Il problema da cui si parte è abbastanza classico nell'economia del lavoro: la relazione tra livello di istruzione e salario.

I dati non sono particolarmente recenti ma sono abbastanza standard. I salari sull'asse delle y sono salari orari in dollari e sono numeri piccoli perché i dati risalgono agli anni Settanta; l'andamento non è molto diverso da quello che ci si aspetterebbe oggi, a parte la scala. L'esempio permette di definire alcuni concetti in modo molto intuitivo.

Sull'asse delle x c'è il livello di istruzione, chiamato educ (education) e misurato in anni. Ogni colonna di punti rappresenta la distribuzione dei salari dei lavoratori con uno specifico livello di istruzione. Per education uguale a 10, i punti della colonna sono la distribuzione dei salari dei lavoratori che hanno studiato esattamente 10 anni; un'altra colonna dà la distribuzione di quelli che hanno studiato esattamente 15 anni, e così via. Ogni fetta dello scatter rappresenta quindi una distribuzione condizionale, che dice in termini probabilistici quanto è probabile trovare, in quel sottogruppo, un lavoratore che guadagna molto o poco.

2.2.2. Le medie condizionali

Al variare dell'istruzione cambia non solo la media della distribuzione. Calcolando la media per ogni colonna, ci si aspetta valori che tendono a crescere con il livello di istruzione. Per i livelli più bassi la variabilità è scarsa e il salario medio è sotto i 5 dollari l'ora. Per un livello intermedio la media sarà poco sopra i 5 dollari. Per chi ha studiato molto il centro della distribuzione è intorno ai 15 dollari. Nel grafico i quadratini rossi rappresentano queste medie condizionali: per ogni livello di education è la media della distribuzione data la colonna. Si vede una tendenza crescente, cioè a più studio corrisponde in media un salario maggiore.

Questo non significa che studiando molto si guadagni di più con certezza. In corrispondenza di uno stesso gruppo ci sono persone che guadagnano meno di chi ha studiato zero anni e persone che guadagnano estremamente di più. È ragionevole. L'eterogeneità dice come varia il salario in funzione di informazioni diverse dall'istruzione: tutte le persone di una colonna hanno lo stesso livello di istruzione ma caratteristiche individuali diverse. Il punto in alto a circa 25 dollari l'ora può essere il figlio di un dirigente che finirà a fare il dirigente. Quello più in basso può essere qualcuno che ha deciso di studiare archeologia: se gli va bene guadagna molto, se gli va male finisce a fare scavi per i cantieri. Possono esserci anche effetti più sottili, come l'effetto di genere: gli uomini tendono a guadagnare più delle donne, che sia giusto o no, è ciò che si osserva nei

dati.

L'eterogeneità dei salari è quindi spiegata da fattori diversi dall'istruzione. All'interno di una colonna l'istruzione è esattamente la stessa, per cui non può essere la spiegazione dell'eterogeneità. Dipende da altro: il reddito della famiglia, il tipo di studi, l'intelligenza, il fatto di essere uomo o donna. A parità di anni di studio, chi si laurea alla Bocconi può avere aspettative diverse da chi si laurea a Cassino, anche solo perché a Milano i salari sono più alti. Questa parte dell'eterogeneità non spiegata dall'education, spiegata da qualcos'altro, viene chiamata termine d'errore e indicata con il simbolo greco ε.

2.2.3. Perché quantificare la relazione causale

Il problema è descrivere una relazione causale tra livello salariale e livello di istruzione. Conoscendone la forma, cioè applicando il modello, si potrebbe valutare se prendere una magistrale convenga in termini di salario atteso. Per esempio, studiare due anni in più, passando da 13 a 15 (il docente precisa che i numeri non sono esatti), si può quantificare in termini di salario orario: quanto si guadagna di più, e se ne vale la pena. Si vuole quantificare una relazione causale per rispondere a domande pratiche di questo tipo: se si aumenta o si riduce la X, che cosa succede alla Y, la variabile di interesse?

Il primo problema è definire un modello coerente e logico, cioè una relazione causa-effetto. Una volta disponibile, la si può usare per analisi quantitative di vario genere: analisi di policy, di scelte, di scenario.

Un'altra rappresentazione degli stessi dati usa, per ogni sottogruppo del campione, un box plot, che mostra come cambiano l'indicatore di centralità e la dispersione del fenomeno.

2.2.4. Il modello di regressione lavora sulle medie

Il modello di regressione lavora sul momento di ordine uno, cioè sulle medie. Interesseranno anche le varianze, che misurano la dispersione, ma in generale interessa capire come in media il livello di istruzione impatti sul salario. Serve un modello statistico che approssimi i quadratini rossi.

I quadratini rossi sono evidenza campionaria, non della popolazione. Quello che si vuole ottenere con il modello statistico, cioè il modello di regressione, è approssimare i quadratini rossi in modo ragionevole, non necessariamente molto preciso. Un modello statistico di interesse è dunque un modello che cerca di spiegare le medie condizionali.

In realtà l'obiettivo non è spiegare le medie condizionali nel campione, la nuvola di pallini blu del grafico, ma la popolazione. Nel campione non interessa sapere che cosa succeda: si ha un foglio Excel con tutti i numeri, e per conoscere guadagno e anni di studio dell'unità statistica numero 73 basta guardarlo, senza bisogno di prevederlo. Si vogliono usare queste informazioni per capire come si comportano le variabili nella popolazione. Non serve quindi essere troppo precisi nell'approssimare i quadratini rossi, che sono già stati calcolati. I quadratini rossi possono essere una buona approssimazione della media condizionale, ma sono solo un'approssimazione.

Si cerca un modello sufficientemente robusto che approssimi l'andamento dei quadratini rossi, sapendo che ciò che interessa non è il quadratino rosso ma il quadratino verde, cioè la media nella popolazione.

Calcolare la media nella popolazione richiederebbe di intervistare tutti i lavoratori degli Stati Uniti in un certo periodo e di conoscere con esattezza il loro reddito, il che è impossibile. Il problema è quindi approssimare, soltanto approssimare, la sequenza di quadratini rossi. Questi sono le medie condizionali, e sono approssimazioni delle medie condizionali di popolazione ottenute dall'evidenza campionaria.

Per farlo in generale si usano modelli semplici. Un modello complicato che si adatti molto bene ai quadratini rossi sarebbe possibile e nemmeno difficile: basta premere un tasto sul computer per trovare funzioni molto smooth che passano esattamente sopra i quadratini rossi. Ma questo non è ciò che interessa, perché i quadratini rossi sono già noti, calcolati in una tabella a parte, e non serve una funzione complicata per approssimarli. Per sapere che cosa succede passando da 12 a 14 anni di istruzione basta fare la differenza tra le due medie condizionali. Il campione è inoltre uno specifico insieme di 500 e qualcosa lavoratori, mentre l'obiettivo è approssimare la popolazione.

Il problema non è dunque trovare una funzione molto precisa sui quadratini rossi, che sono già noti, ma una funzione sufficientemente buona per approssimarli e, allo stesso tempo, per approssimare i quadratini rossi che si otterrebbero da campioni diversi estratti dalla stessa popolazione. Un modello che si adatti perfettamente ai quadratini rossi disponibili non è particolarmente utile: oltre all'informazione già nota, significa che il modello si adatta troppo bene ai dati posseduti e non a tutti i dati possibili, che sono quelli interessanti perché ignoti. Un modello costruito sui quadratini rossi osservati e perfetto, senza errore, incorre in un problema che si chiama overfitting: si adatta troppo bene ai dati ma non necessariamente alla popolazione.

2.2.5. Un esempio grafico di overfitting

Si supponga una popolazione composta da punti, alcuni blu e alcuni rossi. Tutti i punti sono persone con certe caratteristiche, appartenenti alla stessa popolazione. Il campione a disposizione è costituito dai punti blu; i rossi sono persone che potenzialmente si potrebbero avere nella popolazione ma che non sono nel campione. Si può pensare a un insieme di persone, in parte blu e in parte rosse, da cui si esegue l'analisi solo sul campione blu, lasciando fuori il rosso.

Si può costruire un modello che si adatti bene ai punti blu, che sono il campione. Rispetto ai dati usati, la funzione verde che ne risulta è perfetta, praticamente senza errore, perché approssima esattamente i punti blu. Ma l'obiettivo non è approssimare il campione, è approssimare il comportamento della popolazione, quindi anche delle persone non usate per stimare il modello. Calcolando la distanza tra ciò che il modello stima e ciò che si potrebbe avere nella popolazione, alcuni punti risultano estremamente distanti: il modello è molto distante da persone che potrebbero costituire il campione successivo, un altro campione della stessa popolazione. Il modello funziona molto bene su ciò che già si ha e molto male su ciò che si potrebbe avere.

Se si dovesse prevedere la y per un dato valore di x, si userebbe il punto sulla funzione stimata, che è la migliore approssimazione possibile con quella funzione, ma l'errore di previsione sarebbe gigantesco. Il modello va malissimo se una persona non appartiene a quel sottoinsieme della popolazione. È preferibile allora un modello che non approssimi troppo bene la linea blu ma che non vada troppo male nemmeno sulla rossa, cioè un modello che faccia da media rispetto alla curva verde che si stimerebbe con un campione diverso. Una funzione di questo tipo non è perfetta per il gruppo blu né per il gruppo rosso, ma in media non sbaglia in modo sistematico.

La linea verde è dunque un modello che fa overfitting rispetto al campione e va molto male fuori dal campione, che è ciò che interessa: il modello serve a capire che cosa succede su ciò che non si osserva, non su ciò che si è già osservato. Trovare un modello che si adatti troppo bene al campione non è necessariamente una buona notizia. Un modello di regressione con un R^2 del 99% non è necessariamente un buon modello, mentre uno con un R^2 del 20% potrebbe essere ottimo. Il docente accenna che, a chi fosse interessato, il tema si può approfondire con simulazioni più accurate e modelli più complicati; qui serviva solo dare un'idea. Stimare troppo bene un modello sui dati non è necessariamente una buona notizia, perché non c'è certezza che l'approssimazione funzioni fuori dal campione.

2.2.6. Perché una retta di regressione

Tornando al problema principale, si cerca una funzione che non approssimi troppo bene le medie condizionali del campione (i quadratini rossi) ma rifletta un andamento di lungo periodo. Poiché i quadratini rossi non sono i dati che si avrebbero con altri campioni, il modello deve essere universale e non specifico del singolo dataset.

Il secondo motivo per usare una retta di regressione è che è un modello molto semplice. Una linea è facile da identificare, senza curve, polinomi o altre sofisticazioni. Una retta dipende da due soli parametri, l'intercetta e il coefficiente angolare. Stimati questi due numeri, si può caratterizzare in modo completo il comportamento dei dati su tutta la popolazione.

2.2.7. Perché le medie condizionali

Il modello di regressione non approssima direttamente i dati, ma una loro caratteristica, le medie condizionali. Trovare un modello che approssimi i pallini blu è praticamente impossibile, perché non esiste una funzione che si adatti completamente ai dati. Si usano le medie condizionali perché sono indicatori di centralità sufficientemente stabili.

Esistono anche modelli statistici che, invece delle medie condizionali, considerano altri indicatori come i quantili e le mediane. Si tratta della regressione quantilica, che non fa parte del corso. Il docente la segnala perché è interessante per capire non solo come reagisce in media un fenomeno a una perturbazione, ma anche come reagiscono le code. In finanza questo può essere utile, perché interessa che cosa succede sulle code delle distribuzioni, cioè perdere o guadagnare molto, e non in media, dove non si guadagna e non si perde nulla.

I rendimenti medi di un portafoglio sono mediamente zero. A chi investe interessa coprirsi dagli eventi estremi, e quindi capire come una variazione della situazione geopolitica impatti

le code del portafoglio e non la sua media. In questo corso, tuttavia, si guarderà alle medie condizionali, un indicatore di centralità tutto sommato semplice, sapendo che l'impostazione si può generalizzare.

2.2.8. Notazione e definizione del modello

La media si indica con la lettera E, da expectation. Nella notazione $E(y \mid x)$ la prima variabile è quella su cui si calcola la media, mentre la seconda, che segue la barra verticale, è la variabile di condizionamento. I quadratini rossi rappresentano quindi il valore atteso condizionale dei salari rispetto all'istruzione: wage è la variabile y ed education la variabile x. In questo momento le variabili sono soltanto due.

Il modello di regressione è la formula che definisce la media di y dato x come il modello più semplice, cioè una retta: $E(y \mid x) = \alpha + \beta x$. Conosciuti i parametri α e β, tutto è identificato.

Dal punto di vista della stima e dell'inferenza, interessa però legare le osservazioni individuali alla media condizionale. Si considerano le coppie di osservazioni (y_i, x_i), dove i indica l'individuo, cioè l'unità statistica (un lavoratore nell'esempio precedente), x_i è l'istruzione del lavoratore i-esimo e y_i il suo livello di salario. Il legame tra le osservazioni grezze, i puntini blu del grafico, e la media condizionale è

$$y_i = \alpha + \beta x_i + \varepsilon_i.$$

Il salario esatto dell'individuo, che non è il salario medio, dipende da due fattori. Il primo è una componente media: per il fatto di appartenere a una categoria, cioè a un certo livello di istruzione, il salario atteso è il valore $\alpha + \beta x_i$. Il secondo è una componente idiosincratica, individuale, che rappresenta tutte le caratteristiche del lavoratore diverse dall'istruzione: il genere, la famiglia, se è sveglio o no, se ha fatto un master in finanza o in storia dell'arte, e così via. Il salario di una persona è quindi un salario medio, dovuto all'appartenenza a un gruppo, più una componente individuale con tutte le altre caratteristiche.

2.2.9. Esogeneità ed endogeneità

Le caratteristiche del termine ε determinano se il modello statistico così definito sia una relazione causale oppure no. Nel corso di statistica non sono così importanti, lo sono invece in econometria e in economia, perché la relazione tra ε e la variabile x è la ragione pratica e teorica che permette di dire se il modello è ben specificato, cioè se è una relazione causale. Si assumerà che la correlazione tra questo fattore e il fattore presente nel modello sia zero. Questa condizione si chiama esogeneità. Se non vale si parla di endogeneità, che ha conseguenze pesanti sulla stima del modello, come si vedrà in vari esempi.

Le definizioni sono queste. y è la variabile dipendente. x è il regressore o predittore: predittore se si segue una letteratura più statistica, regressore se più economica. ε è il termine d'errore. Il termine d'errore non è osservabile sulla base dei dati, quindi per capire se il modello sia corretto

bisogna calcolare le proprietà di qualcosa che non si può misurare direttamente, e occorre aggirare il problema per stabilire se il modello sia ragionevole.

2.2.10. Perché serve una condizione su ε: un esempio operativo

Si consideri il modello $y = \alpha + \beta x + \varepsilon$ e si supponga di voler prevedere, con esso, il salario atteso di chi studia esattamente x_1 anni (per esempio dieci). Il salario di un individuo che ha studiato x_1 anni è $\alpha + \beta x_1 + \varepsilon$. Il termine ε contiene altri fattori, diversi dall'istruzione, che in linea di principio potrebbero essere collegati al livello di istruzione: più si studia, più si impara, e le competenze possono aumentare. Si fa quindi dipendere ε anche da x_1, scrivendo $\varepsilon(x_1)$. Se ε rappresenta il livello di abilità conseguita, questo può dipendere da altre cose ma anche dall'istruzione. In questo modo si lega direttamente l'abilità di una persona al livello di istruzione.

Che cosa succede se si decide di studiare di più, aumentando la dotazione di istruzione di Δx, per esempio due anni? Si passa da x_1 a $x_1 + \Delta x$. Il salario della stessa persona diventa $\alpha + \beta(x_1 + \Delta x) + \varepsilon(x_1 + \Delta x)$. Il beneficio stimato dal modello per i due anni in più di studio è la differenza tra le due quantità. Indicata con Δy la variazione di y:

$$\Delta y = \alpha + \beta x_1 + \beta \Delta x + \varepsilon(x_1 + \Delta x) - \alpha - \beta x_1 - \varepsilon(x_1).$$

Semplificando i termini uguali si ottiene

$$\Delta y = \beta \Delta x + \Delta \varepsilon,$$

dove $\Delta\varepsilon$ è la differenza tra $\varepsilon(x_1 + \Delta x)$ ed $\varepsilon(x_1)$. Questo termine non è calcolabile, perché non è noto, ma teoricamente esiste. La variazione di salario dipende quindi in parte dal fatto di aver studiato due anni in più e in parte da effetti collaterali della scelta.

La variazione complessiva si può calcolare: prendendo la differenza dei quadratini rossi si trova, per esempio, 3 dollari. Sulla base del modello però non si sa se questi 3 dollari in più dipendano dalla scelta di studiare o da altro. Non si riesce a separare quanto vale $\beta\Delta x$ e quanto vale il resto: si conosce soltanto la somma. I 3 dollari potrebbero essere 1 più 2, oppure 0 più 3, oppure -3 più 6. L'effetto non è identificabile.

L'unico modo per identificare l'effetto della scelta, cioè $\beta\Delta x$, è fissare il valore di $\Delta\varepsilon$. Fissandolo, la variazione di y dipende semplicemente dalla scelta. Il valore più comodo da fissare è 0: se si assume che la variazione di ε sia uguale a zero, tutta la variazione di y dipende da $\beta\Delta x$. Per identificare l'effetto di un fattore su cui si sceglie bisogna quindi essere sicuri che gli effetti collaterali siano nulli.

Da verificare. La frase finale della trascrizione ("Se delta y non è uguale a zero, vuol dire che delta x non è uguale a beta delta x") è confusa; il senso probabile è che, se $\Delta\varepsilon$ non è nulla, la variazione di y non coincide con $\beta\Delta x$.

2.2.11. La condizione statistica per $\Delta\varepsilon = 0$

Resta da stabilire quale sia la condizione statistica per cui la variazione di tutto il resto è nulla in corrispondenza di una variazione di x. Qui tutto è lineare, quindi basta poco. La variazione di ε rappresenta quanto cambiano tutte le altre variabili che non sono nel modello quando varia x, dato che nel modello y dipende da x in modo diretto ed esplicito. Tale variazione è nulla quando la correlazione tra x ed ε è uguale a zero, e questa implica quella.

Da verificare. La trascrizione riporta "quando la correlazione tra x e y è uguale a zero"; dal contesto (la variazione che riguarda "tutte le altre variabili che non sono nel modello") si tratta probabilmente della correlazione tra x e il termine d'errore ε.

Si ha così un concetto statistico che permette di identificare gli effetti delle proprie scelte sulla variabile dipendente: una struttura di dipendenza, una correlazione, che deve essere uguale a zero. Concettualmente è difficile verificarla, perché x si può misurare ma ε no. Se però si può fare questa ipotesi aggiuntiva, si può affermare che l'unica spiegazione plausibile per una variazione di y è la variazione di x pesata dal coefficiente β, la pendenza della retta di regressione.

Questa ipotesi si chiama esogeneità, e in questo caso esogeneità stretta. Esistono vari concetti di esogeneità; nei modelli di regressione classici si usa quella stretta. Nella seconda parte del corso verrà abbandonata a favore dell'esogeneità debole, che è più che sufficiente. Se invece la correlazione fosse diversa da zero, la variazione di ε non potrebbe essere nulla in corrispondenza di una variazione di x, e non si saprebbe valutare perché si osservino variazioni di y.

2.2.12. Interpretabilità dei risultati e scopo dell'analisi

Il problema posto non è un problema generale del modello di regressione, ma di interpretabilità dei risultati. In un corso di statistica il problema dell'eterogeneità nel modello di regressione non viene praticamente considerato, perché lo scopo è trovare un modello da usare per fare previsioni sui dati successivi, e va benissimo. Qui invece interessa valutare con precisione il parametro β, perché esso dice, per esempio, quanto denaro si sta spendendo per l'istruzione dei bambini e se la scelta fatta è corretta.

2.2.13. Esempio: il bonus fiscale e i consumi

Un esempio più semplice. Uno dei problemi dell'Italia è che i consumi sono molto bassi. Per dare impulso ai consumi si danno tipicamente dei bonus; il docente richiama la riforma di Matteo Renzi dei mille euro, introdotta prima come sconto fiscale e destinata a una certa fascia di lavoratori. La misura è costosa, perché a ogni lavoratore di una fascia di reddito media si dà una somma, non grande ma significativa. Il costo si può valutare in modo abbastanza preciso, perché è una minore entrata per lo Stato, trattandosi di sconto fiscale. Lo scopo era stimolare i consumi, e ci si chiede se i consumi siano effettivamente migliorati in conseguenza della policy.

Per rispondere si può calcolare la relazione tra redditi e consumi, con i consumi come y e i redditi come x, entrambi pro capite. La policy varia x di 1.000 euro, e ci si chiede come siano

variati i consumi in corrispondenza di tale variazione. Il docente precisa di non aver svolto questa analisi, che gli interessa poco. In generale, se il parametro che lega consumi e redditi è grande, 1.000 euro in più alle famiglie avranno un impatto sui consumi, e la policy, giusta o sbagliata che sia, avrà ottenuto il risultato voluto.

Il problema è se il modello considerato sia corretto. La variazione dei consumi osservata potrebbe dipendere dai 1.000 euro in più, oppure da altro: le condizioni economiche di quel periodo, o qualsiasi altro fattore. Si vuole valutare se spendere molto denaro abbia un impatto al netto degli altri effetti collaterali della manovra. Se l'effetto collaterale fosse più importante, probabilmente sarebbe stato più efficiente usare quei soldi per altro. Il docente precisa che non sta valutando se la scelta sia stata giusta o sbagliata: pone un problema statistico.

Si può investire molto denaro in una policy e stimare un parametro grande tra le due variabili, da cui ci si aspetterebbe un impatto devastante. Tale impatto vale solo se si ipotizza che $\Delta\varepsilon$ sia zero. Altrimenti non si può dire che la policy abbia avuto un impatto, perché occorre considerare una combinazione di eventi e non solo uno o l'altro: la variazione si può calcolare ma non si sa da che cosa dipenda.

L'unico modo per essere sicuri che la policy, cioè l'investimento, abbia un impatto è fissare ciò che non si conosce, e ciò che non si conosce si fissa tipicamente a zero. Se $\Delta\varepsilon$ è zero, l'unica spiegazione della variazione di y è x, pesata da β, che è il moltiplicatore. Il solo problema diventa allora stimare β.

2.2.14. Stimare β, non prevedere

Lo scopo dell'analisi con i modelli di regressione in economia è capire quanto una policy abbia impatto, cioè valutare correttamente il parametro β. Non interessa un modello che si adatti ai dati o che serva per le previsioni, ma un modello che stimi β in modo corretto, e per farlo occorre fissare $\Delta\varepsilon$ a zero. In questo corso lo scopo è stimare β, non trovare un modello che faccia previsioni decenti. In un corso orientato alle previsioni, invece, che β sia calcolato bene o male non importa, purché la previsione sia corretta.

2.2.15. Il punto di vista del decisore e quello del genitore

Un economista vuole sapere se spendere 2 miliardi di dollari l'anno per ridurre la dimensione della classe sia utile dal punto di vista sistemico, a grande scala, che è un problema politico o economico. Si può però assumere il punto di vista di un genitore che deve iscrivere un figlio a scuola. Il criterio potrebbe essere scegliere la scuola in cui il voto finale del figlio sarà più alto, così da entrare l'anno dopo in una buona scuola con una borsa di studio e poter sopravvivere a un sistema di istruzione estremamente costoso.

Per il genitore lo scopo non è migliorare il mondo, ma trovare la scuola più adatta al proprio figlio. Il problema diventa allora di forecast. Se la variabile che prevede meglio la performance del figlio risultasse la dimensione del parcheggio della scuola, il genitore misurerebbe il parcheggio di tutte le scuole degli Stati Uniti e sceglierebbe in base a quello: non importa se logicamente non ha senso, funziona. È una black box.

Il docente paragona la previsione a una catena di produzione: non interessa sapere perché la gente compra un certo prodotto, né quanti componenti servano per la manutenzione, ma sapere che quel giorno bisogna avere sette tonnellate in magazzino, cioè che la catena di produzione funzioni.

Da verificare. La trascrizione riporta "mozzoline di ferro" e una frase confusa sull'esempio del magazzino; il senso è che in un problema di previsione conta la correttezza della previsione e non la comprensione delle cause.

Dal punto di vista dello statistico che fa previsione, quindi, non interessa calcolare esattamente il parametro che lega le variabili, perché non è necessariamente legato alla capacità previsiva del modello. Se invece si usa il modello per valutare politiche, o per confermare congetture economiche e finanziarie di qualsiasi tipo, interessa conoscere il parametro. L'unico modo per stimarlo correttamente è essere sicuri che la variazione di ε sia nulla.

Da verificare. La trascrizione riporta "essere sicuri che la varianza di Y sia uguale a zero"; per coerenza con la discussione precedente si intende probabilmente la variazione (o la correlazione con x) del termine d'errore ε, non la varianza di y.

Il docente precisa che non sta dicendo che un approccio sia migliore dell'altro: lo stesso strumento risponde a criteri diversi perché i problemi sono diversi.

2.3. Stima dei parametri del modello di regressione

Come si stima il parametro del modello di regressione? In generale tutti i libri indicano come modo corretto il metodo dei minimi quadrati. Si prendono le osservazioni su y e il modello, e si trovano α e β tali che la distanza media tra y e la trasformazione lineare di x sia la più piccola possibile. La distanza si calcola con il quadrato, per evitare che gli scarti positivi e negativi si compensino. Per risolvere il problema si derivano rispetto ad α e β, si pongono le derivate uguali a zero e si risolve il sistema di due equazioni in due incognite. La soluzione per β è un rapporto tra quantità, quella per α una differenza di medie.

Il docente considera questa la via più noiosa, e dato che gli studenti l'avranno già vista molte volte ne presenta una leggermente diversa, con un'algebra più breve e a suo parere più intuitiva.

2.3.1. Ricavare β dai momenti della popolazione

Si considera il modello di regressione e si ipotizza che sia corretto, cioè che valga l'esogeneità. Il docente non considera che cosa succeda stimando un modello logicamente sbagliato. L'ipotesi è che la covarianza tra x ed ε sia zero.

Da verificare. Più volte nel passaggio la trascrizione dice "la covarianza tra X e Y è uguale a zero" a proposito dell'ipotesi di esogeneità; subito dopo, nel calcolo, il docente usa l'ipotesi che la covarianza tra x ed ε sia zero, ed è quella riportata qui.

Si chiede come β si leghi alle caratteristiche dei dati, e lo si ricava dai momenti delle variabili. Supponendo che il modello sia corretto, si calcola la covarianza tra x e y nella popolazione. Scritta così non è molto informativa, ma si può sviluppare: si sa (come se si fosse una divinità) che y è data dalla combinazione $\alpha + \beta x + \varepsilon$, quindi

$$\mathrm{Cov}(x, y) = \mathrm{Cov}(x, \alpha + \beta x + \varepsilon).$$

Si usa una proprietà semplice della covarianza: la covarianza di una variabile rispetto a una combinazione lineare è la combinazione lineare delle covarianze. Si può pensare alla covarianza come a una media, a una sommatoria, o anche a un integrale; sommatorie e integrali sono operatori lineari, per cui la sommatoria di una somma è la somma delle sommatorie. Chi non si fida può verificare con un esempio con x, y e z, calcolando la covarianza di x rispetto a $y + z$ dalle definizioni. Si ottiene

$$\mathrm{Cov}(x, y) = \mathrm{Cov}(x, \alpha) + \mathrm{Cov}(x, \beta x) + \mathrm{Cov}(x, \varepsilon).$$

Il primo termine è zero, perché la covarianza tra una costante e una variabile casuale è nulla: al variare di x, α resta costante. Il terzo termine è zero per ipotesi. Il docente sottolinea che è una scelta, un'ipotesi non necessariamente corretta. Nel secondo termine la costante β si porta fuori dalla covarianza e resta la covarianza di x con se stessa, cioè la varianza di x. Quindi

$$\mathrm{Cov}(x, y) = \beta \, \mathrm{Var}(x),$$

da cui β si ricava in funzione dei momenti delle variabili:

$$\beta = \frac{\mathrm{Cov}(x, y)}{\mathrm{Var}(x)}.$$

Questa relazione vale nella popolazione: il vero β, quello che si otterrebbe considerando tutti i lavoratori degli Stati Uniti, è la covarianza tra livello di istruzione e salario divisa per la varianza del livello di istruzione.

2.3.2. Lo stimatore campionario e il metodo dei momenti

Se la formula vale nella popolazione, si può applicarla in ambito campionario. Il vero β è una covarianza divisa per una varianza; con un campione si possono stimare numeratore e denominatore. Per la legge dei grandi numeri, il numeratore converge alla vera covarianza e il denominatore alla vera varianza, per cui lo stimatore converge al vero β. Uno stimatore di β è quindi

$$\hat{\beta} = \frac{\sum_{i=1}^{n} (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^{n} (x_i - \bar{x})^2},$$

dove $\bar{x}$ e $\bar{y}$ sono le medie campionarie e n è il numero di osservazioni del campione, cioè di lavoratori, che nel caso specifico sono 526.

La teoria dice dunque che, se il modello è corretto, il vero β è dato da questo rapporto. Non si dispone di tutta la popolazione ma solo di un campione, che si suppone abbastanza rappresentativo, e il concetto astratto si calcola con le statistiche descrittive. Numeratore e denominatore convergono ai due momenti di popolazione, per cui per n sufficientemente grande lo stimatore approssima bene β. Questo procedimento si chiama metodo dei momenti.

Il docente si chiede perché questo approccio gli piaccia più della costruzione delle derivate rispetto ad α e β.

Il motivo è che con il metodo dei momenti l'ipotesi viene formulata in modo specifico: nelle condizioni usate per la stima si impone direttamente, in modo brutale, la condizione di esogeneità. La formula funziona solo se la covarianza tra x ed ε è uguale a zero; in quel caso il termine corrispondente sparisce per ipotesi e si ottiene lo stimatore visto sopra. Si usa dunque il metodo dei momenti anziché i minimi quadrati.

Nella slide successiva si minimizza la distanza tra y e il modello di regressione, e si trova che lo stimatore dei minimi quadrati coincide esattamente con quello appena ricavato.

Da verificare. La trascrizione riporta "se minimizzo la varianza di y, cioè se calcolo la distanza minima tra y e il modello di regressione"; il criterio dei minimi quadrati minimizza la distanza tra y e il modello, e il riferimento alla "varianza di y" sembra un lapsus.

In questo caso i due approcci coincidono, cosa che non sempre accade. Ci sono motivi profondi per cui succede, ma in generale quello che si è fatto prima non è molto diverso da quello che si fa ora, con la differenza che nel metodo dei momenti le ipotesi economiche specifiche, cioè l'esogeneità, sono imposte direttamente.

2.3.3. Che cosa succede se l'esogeneità non vale

Si supponga che la covarianza tra x ed ε sia diversa da zero e la si indichi con $\rho_{x\varepsilon}$, un numero diverso da zero.

Da verificare. La trascrizione parla di "covarianza tra x e y" e di "rho xy"; dal calcolo che segue si tratta della covarianza tra x e il termine d'errore, qui indicata con $\rho_{x\varepsilon}$.

Ripetendo il calcolo di prima, la covarianza tra x e y è uguale a $\beta \operatorname{Var}(x) + \rho_{x\varepsilon}$. Se questa condizione valesse e il numero fosse noto, β andrebbe calcolato come

$$\beta = \frac{\operatorname{Cov}(x, y) - \rho_{x\varepsilon}}{\operatorname{Var}(x)}.$$

Per ottenere β correttamente occorrerebbe dunque stimare anche $\rho_{x\varepsilon}$, cosa che non si sa fare. Un software non lo fa, anche perché quel numero non è noto. La formula però mostra una cosa

più sottile: il software fa finta che $\rho_{x\varepsilon}$ sia uguale a zero. La stima del parametro non è quindi fatta bene, perché manca un pezzo, e la stima di β sarà sistematicamente diversa dal vero β nella popolazione.

Uno studente chiede se l'endogeneità indichi l'assenza di esogeneità. Il docente conferma: si ha endogeneità quando la correlazione tra x ed ε è diversa da zero, cioè quando vale il contrario dell'esogeneità.

In presenza di endogeneità il software non lo sa, a meno che non gli venga detto, e tratta $\rho_{x\varepsilon}$ come se fosse zero. La stima di β basata sul rapporto tra covarianza e varianza è alterata, perché il numeratore dovrebbe essere ripulito dall'effetto di $\rho_{x\varepsilon}$. Applicando la formula sbagliata quando l'esogeneità non vale, lo stimatore di β non risulta collegato a β, ma a β più un termine ulteriore. Si ha quindi una distorsione sistematica tra ciò che si vuole stimare e ciò che si stima effettivamente dai dati. Con endogeneità, gli stimatori che si vedranno nel corso sono distorti, e la distorsione non sparisce nemmeno aumentando il numero di osservazioni: è sistematica. L'implicazione di policy che si vuole valutare con il modello sarà sistematicamente sbagliata.

Riassumendo: se si fa finta di essere in un contesto corretto, in cui x è esogena rispetto a ε, si assume che questa covarianza sia zero. Se il modello è invece sbagliato perché l'errore è correlato con x, andrebbe usata la formula corretta. Poiché il software non lo fa, dato che non gli viene detto, la stima di β cambia in modo sostanziale.

2.3.4. Il caso della dimensione della classe

Nell'esempio dei bambini a scuola c'è un problema di endogeneità. La prima regressione lega la performance dei bambini alla dimensione della classe più un termine d'errore, e nel termine d'errore c'è l'effetto del reddito, perché non è nel modello: ε raccoglie tutto ciò che non è dimensione della classe, e qui lo si può identificare con il reddito. Si è visto che la correlazione tra reddito e dimensione della classe è significativamente diversa da zero. Stimando quel modello si ipotizza di fatto che tale correlazione sia zero, e si ottiene una stima di β pari a $-2{,}27$.

Come anticipazione di ciò che si farà più avanti, si toglie dal termine d'errore il reddito, che è la variabile problematica, e lo si inserisce nel modello. L'errore del modello con il regressore in più non è più caratterizzato dall'effetto del reddito, perché questo è ora parte della media condizionale e non della parte residuale. Ristimando il modello si elimina una delle possibili cause di endogeneità, cioè una delle cause che creano relazione tra ε e la dimensione della classe. Il parametro passa da $-2{,}2$ a $-0{,}64$.

Probabilmente nel modello precedente c'era un problema di endogeneità che si era fatto finta di non vedere. I parametri sono cambiati molto, quindi per stimare β nella prima regressione si è probabilmente usata la formula sbagliata, perché si è supposto nulla la correlazione tra reddito e dimensione della classe, che invece non lo è. Scorporando questo effetto, $-2{,}2$ diventa $-0{,}64$: il livello di correlazione tra reddito e dimensione della classe ha un impatto notevole.

Da verificare. La trascrizione riporta "ha un impatto tra note"; il senso sembra essere che l'impatto è rilevante.

La distorsione non è piccola e il parametro cambia molto. Queste sono le conseguenze di stimare un modello facendo finta che $\Delta\varepsilon$ sia uguale a zero quando in realtà non lo è.

Tutto il gioco dell'econometria, almeno a questo livello, consiste nel capire quando si può dire che la variazione di ε è uguale a zero in corrispondenza della variazione di x. Tutto il resto è algebra banale: la difficoltà è economica più che tecnica. Nelle prossime lezioni si introdurrà gradualmente la parte tecnica, per mostrare che quanto detto qualitativamente ha un corrispettivo formale.

3 | Lezione del 13 novembre 2026: Regressione semplice: esogeneità e proprietà dello stimatore OLS

3.1. Il modello di regressione semplice: richiamo e problema dell'identificazione

Il modello di regressione semplice è ipersemplificato, ma ciò che si vede su di esso si trasferisce direttamente ai modelli più complessi, con il vantaggio che l'algebra è più semplice. Dalla lezione precedente: il modello di regressione è il valore atteso della variabile dipendente condizionato a X. Il modello più semplice con un minimo di senso logico è la retta, e si ipotizza che il valore atteso condizionato abbia questa forma.

Il valore atteso condizionato va inteso sulla distribuzione di probabilità congiunta della popolazione, non sul campione. La media è calcolata su tutti i possibili lavoratori, nell'esempio di salari e livello di istruzione, e non solo su quelli osservati. È quindi il modello teorico che regola la relazione tra i dati, in generale ignoto, che si decide di approssimare con una retta. L'ipotesi che la retta sia adeguata è molto forte ed è legata all'ipotesi di esogeneità. Se l'approssimazione non è corretta si entra nell'ambito dell'endogeneità, con i problemi descritti nella lezione precedente.

Per collegare le osservazioni del campione al vero modello nella popolazione si aggiunge un termine d'errore ε. Esso descrive le caratteristiche individuali che differenziano persone con lo stesso valore di X: nel caso di istruzione e salario possono essere il genere, il tipo di studio o qualsiasi altro aspetto. Le definizioni sono quindi le seguenti: Y è la variabile dipendente, X il regressore, ε il termine d'errore. L'errore è completamente casuale, non è osservabile e non lo sarà mai, e rappresenta tutte le caratteristiche dell'unità statistica i-esima del campione diverse da X.

3.1.1. Perché serve l'incorrelazione tra X ed epsilon

Si vuole trovare una spiegazione delle variazioni della variabile dipendente: il salario rispetto agli anni di studio, il livello dei consumi rispetto a una politica economica che dà più soldi ai lavoratori, oppure, aumentando i controlli fiscali, la riduzione del sommerso in un certo paese. Il parametro β rappresenta l'impatto della politica. Lo si identifica esattamente solo se si può escludere che a una variazione di X corrisponda anche una variazione di ε. Altrimenti la variazione osservata della variabile dipendente dipende non solo dalla politica, ma anche da

qualcosa fuori dal controllo di chi decide, perché ε non è osservabile.

Per identificare l'impatto della decisione occorre quindi che la componente ε resti fissa, cioè che la sua variazione sia nulla. Questo equivale a richiedere l'incorrelazione tra X ed ε. L'ipotesi minima per identificare una relazione causa-effetto è dunque che il modello sia corretto, nel senso che la parte residuale sia completamente esogena, non collegata alla parte strutturale.

Se c'è correlazione, si osserva la variazione complessiva ma non si sa se dipenda dalla parte strutturale o da ε. Si può allora investire molto in una politica senza accorgersi che β è in realtà uguale a zero e che tutta la variazione dipende dall'effetto collaterale: si spende per qualcosa che non serve, quando i fondi andrebbero usati per modificare il secondo fattore. Nel caso dei bambini a scuola, potrebbe convenire guardare al reddito delle famiglie piuttosto che alla dimensione della classe, e impiegare i due miliardi di dollari all'anno in sussidi alle persone a reddito basso. Il docente precisa di non sapere se sia la politica giusta; è solo un'illustrazione.

Una volta fissata a zero la variazione di ε, l'effetto marginale della politica è proporzionale al parametro β. Imporre variazione nulla di ε significa assumere l'incorrelazione tra X ed ε. Lo stimatore che sfrutta questa condizione, già visto nella lezione precedente, è la covarianza campionaria tra X e Y divisa per la varianza campionaria di X. Senza quell'ipotesi lo stimatore non è più ragionevole, perché stima sistematicamente una quantità diversa. I software si comportano come se la correlazione fosse nulla: se non lo è, il risultato differisce da quello che si vorrebbe ottenere. È il problema pratico.

3.1.2. Esempio con dati simulati

Un esempio con dati simulati mostra l'effetto, perché si conoscono esattamente le variabili e la relazione tra esse. Si fissano la costante $\alpha = 3$ e il coefficiente angolare $\beta = 1{,}5$, si costruiscono X e Y al computer e si aggiunge un termine d'errore scelto di proposito in modo che sia correlato con X. In questo modello si sa quindi che la formula standard, covarianza diviso varianza, è sbagliata.

Le varianze sono poste tutte uguali a 1 per comodità, per cui la covarianza è anche la correlazione, e la correlazione tra X ed errore è pari a 0,6, molto alta. Il processo che genera i dati (data generating process) è dato da queste due equazioni. Il dataset contiene 200 osservazioni simulate. Si applica il modello di regressione assumendo che la covarianza tra X ed errore sia nulla, cioè stimando β come covarianza tra X e Y divisa per la varianza di X.

La tabella dei risultati è stata prodotta con Gretl, il software usato nel corso. Tutte le tabelle di questo tipo hanno la stessa struttura, con piccole differenze. Alla riga `const` compare la stima dell'intercetta, il parametro α: 2,96, contro il vero valore 3. L'intervallo di confidenza ha limite inferiore 2,83 e limite superiore 3,08. Il valore 3 vi è contenuto, quindi è plausibile come vero valore del parametro, e la costante risulta stimata abbastanza bene.

Il coefficiente β, che nella realtà vale 1,5, è stimato con 2,1. Se 2,1 sia vicino o lontano da 1,5 dipende dalla precisione dello stimatore. Il ragionamento è lo stesso della statistica di base,

con un parametro al posto della media. Il significato dei numeri della tabella sarà spiegato più avanti.

3.1.3. La distorsione non scompare con più dati

L'intervallo di confidenza di $\widehat{\beta}$ indica che il vero valore del parametro dovrebbe cadere tra 2 e 2,25. Il valore 1,5 è fuori dall'intervallo: sulla base dei risultati è molto improbabile che sia il vero valore, ma a priori si sa che lo è. Dimenticare questo pezzo nella procedura di stima produce quindi una stima abbastanza diversa da quella che dovrebbe essere.

Inoltre 2,1 è esattamente 1,5 più 0,6. La distorsione non coincide in generale con la correlazione: qui il risultato è proprio quel numero perché la varianza di X è uguale a 1, altrimenti si avrebbe un altro valore, ma sempre una distorsione. Ignorare l'endogeneità significa sbagliare completamente l'impatto della politica, perché ciò che si stima non è β ma β più un termine aggiuntivo, di cui in generale non si conosce l'entità: può essere 0,1 oppure 0,99. Non si sa quindi quanto la stima disti da quella desiderata.

Il secondo problema è che questa distorsione non sparisce all'aumentare dei dati. Dalla statistica si sa che più dati si usano, più la stima è precisa e più preciso è il procedimento inferenziale. Qui però la parte di distorsione non è comprimibile: con più dati si converge sempre più a 2,1 e non a 1,5, perché ciò che si stima è 1,5 più 0,6. Si è molto precisi nello sbagliare. La distorsione dell'esempio non scompare aumentando il campione, e né la legge dei grandi numeri né il teorema del limite centrale servono a rimediare. L'esempio mostra che cosa succede quando l'ipotesi di incorrelazione non è valida.

3.1.4. Come ragionare sull'endogeneità

Nessuno dice se l'ipotesi di covarianza nulla sia valida. Non si può dimostrare, ma occorre ragionare per capire se è ragionevole. Un modo è chiedersi quando si presenti l'endogeneità, cioè quando X ed ε siano correlati. Come detto nella lezione precedente, un caso è il modello con troppe poche variabili: la media condizionale dipende da una sola variabile, mentre tutte le altre stanno dentro ε e potrebbero essere legate a X. Ciò induce correlazione, quindi endogeneità e stime sistematicamente sbagliate.

Si può allora togliere informazione a ε e inserirla nel modello, aggiungendo variabili alla media condizionale. Se il parametro associato alla variabile di interesse cambia di molto aggiungendo o no una variabile, nel modello con meno variabili c'è probabilmente un problema di variabile omessa, quindi di endogeneità. In una regressione si possono avere 100 parametri, ma si guardano solo i due o tre rilevanti per il problema economico; tutto il resto sono fattori di disturbo.

Conviene perciò individuare le potenziali cause di endogeneità e costruire una serie di modelli che verifichino se quei problemi sono presenti in quello usato. Se, aggiungendo variabili, il parametro di interesse non cambia più, probabilmente le variabili importanti sono state inserite tutte, perché nessun ulteriore modo di rendere neutrale il termine d'errore produce variazioni nella stima di β. Il docente avverte che sono regole del pollice e non un teorema. Il teorema dice che, se il modello ha troppe poche variabili, le stime sono sistematicamente sbagliate; empirica-

mente non è facile validarlo. Si continuano ad aggiungere variabili finché si può: se a un certo punto le stime si stabilizzano, non necessariamente allo stesso numero ma con gli stessi risultati dal punto di vista qualitativo, probabilmente il problema delle variabili omesse non c'è più. A quel punto si possono usare le formule standard di stima.

Quando si ignora il problema e si stima la regressione come se non esistesse, la stima del parametro è sistematicamente sbagliata: non si stima β ma β più un termine legato alla correlazione tra X ed errore. Più avanti lo si dimostrerà formalmente; l'idea è questa.

Esame. Il docente raccomanda di ricordare questa tabella dell'esempio, perché è più importante della derivazione teorica.

3.1.5. Qualità del risultato ed endogeneità come problema economico

Per giudicare se un modello sia buono nella qualità dei risultati, e non nella parte statistica, la parte statistica è corretta: lo stimatore dei minimi quadrati, o del metodo dei momenti descritto nella lezione precedente, è la covarianza tra X e Y divisa per la varianza di X. Con endogeneità la qualità del risultato è bassissima. Con esogeneità la formula dà esattamente ciò che serve, cioè un effetto marginale, il parametro β. Se non ci fosse esogeneità, tutti i modelli stimati sarebbero da buttare.

Esogeneità ed endogeneità sono quindi un'ipotesi da fare: il modello considerato deve essere corretto dal punto di vista logico, cioè deve rappresentare una relazione causa-effetto. Ogni deviazione da questa condizione porta a risultati sistematicamente sbagliati, nel senso che β non è più stimato correttamente. Occorre convincersi che il modello non sia influenzato dall'endogeneità. Se lo è, le soluzioni sono due: specificare diversamente il modello, oppure usare stimatori non standard, come le variabili strumentali, che non saranno trattate nel corso per mancanza di tempo.

Non si è mai sicuri della presenza o dell'assenza di endogeneità. Insieme al modello di interesse si stima una batteria di altri modelli e si fanno altri esercizi che permettano di escludere alcuni tipi di endogeneità. Una risposta definitiva non si avrà mai. Non basta stimare la regressione tra X e Y: servono, per esempio, altre 50 regressioni per convincersi che non manchino variabili e che quelle usate siano misurate con una certa precisione. L'endogeneità non si può mai escludere, ma si lavora per ridurne la probabilità. Generalmente si valutano molti modelli per convincersi che quello adottato sia relativamente corretto.

Il docente ribadisce che l'endogeneità è un problema economico, non statistico. In un corso di statistica generalmente non interessa molto, e probabilmente non è stata vista nel modello di regressione, perché se l'obiettivo è prevedere Y qualsiasi modello che funzioni va bene. In ambito economico interessa invece la misura del parametro, che in queste condizioni non funziona. La misura è interessante perché dice quanto vale la politica; altrimenti si rischia di prendere decisioni costose e sbagliate.

3.2. Previsione, residuo e modello teorico contro modello statistico

L'esempio con dati simulati, in cui i parametri sono noti, mostra gli effetti dell'endogeneità. Si lascia ora da parte il problema e si assume di usare lo stimatore corretto di β, dato dalla formula già vista. Non ci si sofferma sulla stima di α: l'intercetta non è un parametro particolarmente interessante, salvo applicazioni specifiche, e in generale si include nel modello a meno di ragioni molto forti per escluderla. Prima di chiedersi se la strategia di stima sia ragionevole, servono alcune definizioni.

3.2.1. Valore predetto e residuo

Una volta stimati i parametri, il modello si usa per la previsione. Il valore predetto si calcola approssimando il valore atteso condizionale con i parametri stimati al posto di quelli veri, $\hat{\alpha}+\hat{\beta}x$, dove x è un valore prefissato scelto da chi fa la previsione. Esso indica che cosa ci si aspetta dalla variabile dipendente quando X assume quel valore. Per brevità lo si indica con $\hat{y}$ ed è la stima di un valore atteso condizionale. È una variabile casuale, perché α e β sono incerti: si conoscono solo approssimazioni calcolate sul campione, non i veri parametri della popolazione.

Può essere utile anche misurare quanto la previsione si discosta dal valore effettivamente osservato, se noto. Questa differenza è il residuo, ossia il termine d'errore valutato per l'individuo i osservato: la differenza tra il salario osservato e il salario previsto per un dato valore di x.

Il residuo è diverso dal termine d'errore. Il residuo è la distanza tra un'osservazione e la sua previsione, un'evidenza campionaria riferita a una persona specifica, ed è un numero. Il termine d'errore ε è un concetto più astratto: è la distanza tra ogni individuo della popolazione, e non del campione, e il vero modello nella popolazione, ed è una variabile casuale. Il residuo non è un'approssimazione di ε; sono due concetti distinti, anche se il residuo ha una sua utilità. Nel grafico con la retta di regressione stimata e un'osservazione, il valore predetto è una distanza e la componente residuale è l'altra.

3.2.2. Quando la strategia dei minimi quadrati funziona

Assumendo che il modello sia ragionevole, in condizioni di esogeneità, ci si chiede se usare covarianza divisa per varianza dia in media risultati corretti e che cosa accada quando il campione cresce. Si vuole sapere se la strategia statistica funziona, quando funziona e quando no, e soprattutto qual è il fattore che definisce l'endogeneità.

L'endogeneità nasce tipicamente perché il modello statistico stimato non corrisponde al modello che descrive i dati nella popolazione. In ogni analisi empirica si hanno in mente due concetti: ciò che si fa, cioè una scelta individuale, e il processo generatore dei dati, un concetto astratto per cui i dati sono legati ad altre variabili in modo predeterminato. C'è quindi un modello teorico che descrive la realtà e un modello empirico che è il modo in cui la si vede. Se i due modelli coincidono non c'è endogeneità; se divergono, può esserci. Il modello teorico spiega la relazione tra le variabili nella popolazione e non è noto. Il modello statistico è quello scelto

da chi analizza, il comando da dare al software. Se il modello stimato è sbagliato rispetto al processo generatore dei dati si ricade nell'endogeneità, con problemi nella stima dei parametri di interesse.

Il problema chiave dell'econometria è capire se le formule usate per approssimare i parametri vadano bene. A questo scopo occorre conoscere le caratteristiche del termine d'errore, in particolare i suoi momenti condizionali rispetto a X.

3.2.3. Il momento condizionale dell'errore

Il modello statistico è $Y = \alpha + \beta X + \varepsilon$, e si ipotizza che la media condizionale di Y sia il modello di regressione, $\alpha + \beta X$. Si calcola il valore atteso condizionale di Y dato X sulla base di questo modello: fissato X, la media di $\alpha + \beta X + \varepsilon$ è $\alpha + \beta X + E[\varepsilon \mid X]$. Questa è la media condizionale rispetto alla distribuzione di probabilità nella popolazione, calcolata però a partire dal modello empirico. Essa coincide con $\alpha + \beta X$ se il modello è correttamente specificato, cioè se il modello statistico approssima correttamente la media condizionale. Ne segue che, se il modello teorico coincide con quello statistico, deve valere

$$E[\varepsilon \mid X] = 0.$$

Da verificare. Nella trascrizione il termine che si annulla compare come "y" ("la media condizionale di Y dato X deve essere uguale a zero"); dal ragionamento si tratta dell'errore ε, qui riportato di conseguenza.

Questo momento condizionale di una variabile casuale è legato all'esogeneità, presentata come covarianza nulla tra X ed errore, ma è una condizione leggermente più forte. Una volta assunto che sia uguale a zero, si dimostra facilmente che la covarianza tra X ed errore è nulla.

La covarianza si può sempre scrivere come la media del prodotto incrociato meno il prodotto delle medie: $\mathrm{Cov}(X, \varepsilon) = E[X\varepsilon] - E[X]E[\varepsilon]$. Si assume che la media di ε sia uguale a zero. Se non lo fosse, si può riscrivere il modello in modo che lo sia, riscalando e modificando l'intercetta, senza cambiare nulla. Il secondo termine sparisce allora per definizione.

Da verificare. Anche qui la trascrizione dice "media di y uguale a zero", ma il contesto riguarda la media dell'errore ε.

Dunque la covarianza tra X ed errore è uguale alla media del prodotto incrociato $E[X\varepsilon]$. Non è ovvio che questo termine sia nullo, ma lo si dimostra con una proprietà della statistica di base: la media di una variabile si può scrivere come la media delle medie condizionali.

Da verificare. Nella trascrizione l'errore è spesso chiamato "y" ("covarianza tra X ed Y", "media di Y dato X"). Per coerenza con il ragionamento qui e di seguito si riporta ε.

3.2.4. La legge delle aspettative iterate

Un grafico mostra i salari di 526 lavoratori. I lavoratori sono divisi in sottogruppi disgiunti, e per ciascun sottogruppo la media aritmetica è rappresentata da un quadratino rosso. Per calcolare la media marginale dei salari ci sono due strade. La prima: prendere tutti i pallini blu, considerarne la seconda coordinata (l'altezza) e farne la media aritmetica, cioè 1/526 per la somma dei salari. La seconda: poiché si conosce il salario medio di ogni sottogruppo, si fa la media dei quadratini rossi, pesata per il numero di osservazioni di ciascun gruppo. Un quadratino con due persone vale due, uno con una persona vale uno, uno con 60 persone vale 60. Si ottiene esattamente lo stesso numero.

La media delle medie condizionali è quindi uguale alla media marginale. È un risultato generale della statistica, valido anche nella popolazione e non solo nel campione: la media marginale si calcola come valore atteso iterato del valore atteso condizionato. Il docente metterà nei lucidi entro la sera la dimostrazione almeno per il caso discreto. Il risultato è importante in statistica e molto usato in econometria, anche in applicazioni più avanzate.

Applicato al prodotto incrociato: si calcola prima la media rispetto a ε del prodotto $X\varepsilon$ fissato X, che corrisponde ai quadratini rossi, cioè alle medie condizionali; poi si fa la media rispetto a tutti i possibili valori di X, cioè la media dei quadratini rossi:

$$E[X\varepsilon] = E\big[\, E[X\varepsilon \mid X]\,\big].$$

Una volta fissato X, esso è una costante e si può portare fuori dalla media condizionale:

$$E\big[\, E[X\varepsilon \mid X]\,\big] = E\big[\, X\, E[\varepsilon \mid X]\,\big].$$

Se il modello è corretto, cioè se il modello statistico coincide con quello teorico, $E[\varepsilon \mid X] = 0$. Qualunque sia il valore di X, l'argomento della media è sempre zero, quindi la media è zero. Il docente aggiunge che si tratta della media rispetto a X di una quantità identicamente nulla, e che gli eventuali passaggi formali con l'integrale rispetto alla densità di X non cambiano il risultato. Il docente segnala inoltre di aver dimenticato un termine alla lavagna e invita gli studenti a segnalare le imprecisioni.

Dunque $E[\varepsilon \mid X] = 0$, che è la definizione corretta di esogeneità, implica $\mathrm{Cov}(X, \varepsilon) = 0$. Il viceversa non vale necessariamente, ma l'implicazione è appena stata dimostrata.

3.2.5. Esogeneità e covarianza nulla

La condizione sul momento condizionale è un concetto complesso da ricordare dal punto di vista statistico e logico, mentre la covarianza e la correlazione sono più naturali. Nel corso i due concetti si possono considerare sostanzialmente equivalenti. È vero che dalla covarianza nulla non si dimostra il viceversa, ma esistono controesempi solo in casi patologici; in generale i due concetti sono strettamente legati. Chi preferisce può quindi pensare l'esogeneità così: X

non deve essere correlato con l'errore. Come si misura la correlazione, in un modo o nell'altro, cambia poco dal punto di vista intuitivo.

Si è dimostrato che un primo criterio per capire se si sta lavorando bene è stabilire se il modello stimato sia ragionevole per descrivere la relazione causa-effetto, cioè il processo che genera i dati. Operativamente è solo un'idea generale, ma ora è formalizzata. Occorre capire se il modello statistico sia una buona approssimazione di qualcosa che purtroppo non è noto. Per stabilire se ci siano problemi nel modello di regressione servono ipotesi sul termine d'errore, perché da come è fatto dipende la qualità della stima di β. Il docente chiede se ci siano domande.

3.2.6. Omoschedasticità ed eteroschedasticità

Non interessa solo la media di ε. Porre la media condizionale a zero dice che il modello va bene, ma si possono fare ipotesi anche su altri momenti. Un'altra ipotesi riguarda la varianza di ε per ogni valore fissato di X. È un'ipotesi più semplice di quella sull'esogeneità. Qualunque sia l'ipotesi sulla varianza di ε, le stime dei minimi quadrati restano valide: non è quello il problema. Tuttavia l'ipotesi sulla varianza condizionale ha conseguenze sulla capacità di fare test sui parametri, quindi sull'inferenza.

Le ipotesi principali sono due. L'omoschedasticità vale quando la varianza di ε dato X è costante, cioè la varianza della componente residuale è sempre la stessa al variare di X. Si parla di eteroschedasticità quando la varianza dell'errore varia in qualsiasi modo al variare di X.

Parlare della varianza di ε dato X e della varianza di Y dato X è esattamente la stessa cosa. Nel modello di regressione la varianza di Y per un livello fissato di X, qualunque esso sia, è

$$\mathrm{Var}(Y \mid X) = \mathrm{Var}(\alpha + \beta X + \varepsilon \mid X).$$

Nella formula va precisato che la varianza è condizionata a X. Fissato X, il termine $\alpha + \beta X$ è una costante: se il livello di istruzione è 5, α e β sono numeri ignoti ma pur sempre numeri, quindi $\alpha + \beta \cdot 5$ è un valore esatto.

3.2.7. Varianza condizionale dell'errore e varianza di Y

La varianza di una variabile casuale a cui si somma una costante non dipende dalla costante. Una variabile casuale è una collezione di valori, ciascuno con una probabilità; nel caso di un dado, sei facce con la loro probabilità. La varianza misura la dispersione del fenomeno, cioè indicativamente l'ampiezza dell'intervallo tra il valore più piccolo e il più grande: piccola se le osservazioni stanno in un intervallo ristretto, grande se stanno in uno ampio. Se a ogni faccia del dado si aggiunge 3, il fenomeno si sposta di 3 unità, ma la variabilità tra il valore minimo e quello massimo non cambia: invece della differenza tra 6 e 1 si ha quella tra 9 e 4, sempre 5. Traslare una variabile casuale per una costante lascia invariata la varianza.

Fissato X, quindi, la varianza di una costante più una variabile casuale è la varianza della variabile casuale:

$$\mathrm{Var}(Y \mid X) = \mathrm{Var}(\varepsilon \mid X).$$

L'eterogeneità dei salari corrisponde così all'eterogeneità della componente individuale del salario che non dipende dal livello di istruzione. Nella lezione precedente, guardando il grafico dei dati sui salari, si era osservato che la dispersione in ogni sottogruppo non dipende dal livello di istruzione, comune a tutti i membri del sottogruppo, ma da altro, che si era chiamato ε. La variabilità all'interno di ciascun sottogruppo è quindi la variabilità di tutto ciò che non è nel modello, cioè del termine d'errore. La varianza condizionale di ε è il coefficiente di eterogeneità dei lavoratori in ciascun sottogruppo.

Una nota tecnica del docente: la registrazione della lezione non sarà disponibile, perché il sistema è andato in crash.

3.2.8. Riconoscere omoschedasticità ed eteroschedasticità dai grafici

Sul grafico dei salari, la varianza condizionale di ε è più vicina all'omoschedasticità o all'eteroschedasticità? È eteroschedasticità: al variare di X la dispersione delle osservazioni tende ad aumentare, con un gruppo di lavoratori a varianza piccola e un altro, a livelli di istruzione maggiori, a varianza grande. In questo modello l'ipotesi di omoschedasticità non sembra sensata. In ogni caso non si può mai escludere una qualche forma di eteroschedasticità; sarà trattata più avanti in dettaglio. La varianza non deve necessariamente crescere con X: può diminuire, o essere grande, piccola, piccola, grande. Basta che non sia costante.

Due grafici illustrano la differenza. Il primo è costruito con dati simulati in ambito omoschedastico: i soggetti si dispongono intorno a una retta di regressione e la dispersione di ogni sottogruppo è più o meno costante. Nelle code ci sono meno osservazioni e la variabilità può essere qualsiasi, ma dove c'è il corpo della distribuzione la variabilità è sempre circa la stessa. Nel secondo, eteroschedastico, la dispersione è grande, poi piccola, poi di nuovo grande, e così via. Per giudicare bisogna guardare le oscillazioni di Y a ogni livello fissato di X: nel secondo caso non sono costanti.

Per il termine d'errore si fanno quindi due ipotesi. La prima è che la media condizionale sia zero: serve a definire un modello corretto dal punto di vista logico, legato a una relazione causale, a cui non manca nulla. La seconda riguarda la varianza condizionale, che può essere costante o no. Questa seconda ipotesi è di comodo, si gestisce in modo abbastanza semplice e non è così importante, anche se richiede qualche attenzione.

3.3. Proprietà dello stimatore OLS di beta

Si ritorna al problema principale: uno stimatore è una strategia statistica che crea un legame tra dati e parametro. Ci si chiede se lo stimatore dei minimi quadrati, cioè il rapporto covarianza su varianza, sia una buona strategia per stimare β. Una buona strategia dovrebbe, indipendentemente dal campione estratto, essere legata al vero valore del parametro, e dovrebbe essere

tanto più precisa quanto più dati si hanno. Si vuole quindi capire se covarianza fratto varianza sia legata al vero β e che cosa succeda quando il campione cresce.

Il docente avverte che la lezione prosegue con un po' di algebra, la più semplice possibile e senza matematica complicata, e che risulta un po' noiosa.

La lezione precedente ha derivato lo stimatore con il metodo dei momenti anziché con i minimi quadrati, ma i due coincidono. Si assume che i dati siano campionati dalla popolazione in modo indipendente, ipotesi importante. Con n numero di osservazioni e $\bar{x}$, $\bar{y}$ medie campionarie, lo stimatore è

$$\hat{\beta} = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^{n}(x_i - \bar{x})^2}.$$

Da verificare. Nella trascrizione il denominatore è detto "sommatoria della varianza della x"; si riporta la somma dei quadrati degli scarti di x_i dalla media, coerente con "covarianza su varianza". Si potrebbe anche dividere numeratore e denominatore per n, senza differenza.

La formula da sola non lega il vero β al β stimato, che è l'approssimazione statistica. Per costruire il legame si applica la formula al vero modello, sostituendo a y_i la sua rappresentazione $\alpha + \beta x_i + \varepsilon_i$. Prima, però, conviene semplificare il numeratore, perché gli econometrici sono pigri e semplificano quando possono. Si sviluppa il prodotto come prodotto di $(x_i - \bar{x})$ per y_i meno il prodotto di $(x_i - \bar{x})$ per $\bar{y}$.

3.3.1. Semplificazione del numeratore

Il docente avverte che, volendo semplificare, ha in realtà reso l'espressione più lunga, ma che il vantaggio si vede subito. Il numeratore diventa

$$\sum_i (x_i - \bar{x})\, y_i \;-\; \sum_i (x_i - \bar{x})\, \bar{y}.$$

Il secondo termine è nullo: $\bar{y}$ è una costante, quindi si porta fuori dalla sommatoria, e la somma degli scarti di una variabile dalla propria media è zero. Uno studente chiede perché il secondo termine sia zero. Il docente risponde che la proprietà fondamentale della media aritmetica è proprio questa: gli scostamenti delle osservazioni dalla media sommano a zero. Il termine riguarda solo il numeratore e deve essere esattamente zero. Resta

$$\hat{\beta} = \frac{\sum_i (x_i - \bar{x})\, y_i}{\sum_i (x_i - \bar{x})^2}.$$

3.3.2. Legame tra lo stimatore e il vero beta

Si sostituisce $y_i = \alpha + \beta x_i + \varepsilon_i$ nella formula. Il numeratore si scompone in tre somme:

$$\sum_i (x_i - \bar{x})\,\alpha \;+\; \sum_i (x_i - \bar{x})\,\beta x_i \;+\; \sum_i (x_i - \bar{x})\,\varepsilon_i,$$

il tutto diviso per $\sum_i (x_i - \bar{x})^2$.

La prima somma è nulla: α è una costante che si porta fuori, e resta la somma degli scarti dalla media, uguale a zero. È lo stesso ragionamento di prima, con il parametro costante al posto della media di y.

Nella seconda somma β è una costante e si porta fuori. Si sa che la somma degli scarti $(x_i - \bar{x})$ moltiplicata per una costante è zero, quindi si può sottrarre zero, nella forma $\beta \sum_i (x_i - \bar{x})\bar{x}$, senza cambiare il valore. Il numeratore di questo termine diventa $\beta \sum_i (x_i - \bar{x})(x_i - \bar{x}) = \beta \sum_i (x_i - \bar{x})^2$. Diviso per il denominatore, che è la stessa quantità, dà β.

Per concludere si raccolgono i primi due addendi, che hanno la stessa struttura, e si nota che numeratore e denominatore del termine in β coincidono, dato che $(x_i - \bar{x})$ moltiplicato per sé stesso è il quadrato dello scarto, quindi si semplificano. Il terzo termine resta. Si ottiene

$$\hat{\beta} = \beta + \frac{\sum_i (x_i - \bar{x})\,\varepsilon_i}{\sum_i (x_i - \bar{x})^2}.$$

Quindi, rispetto al vero modello, in cui la media condizionale di Y dato X è $\alpha + \beta X$, lo stimatore è uguale al vero parametro più una componente di rumore che dipende dall'eterogeneità degli individui.

3.3.3. Valore atteso dello stimatore

Ci si chiede quali siano le proprietà dello stimatore rispetto al vero β: se la sua media sia legata a β e quale sia la sua varianza. Lo stimatore è una variabile casuale perché dipende dai dati: cambiando il campione cambia la stima. È la collezione delle stime ottenibili da campioni diversi, ciascuna con la probabilità di estrarre quel campione, e quindi se ne possono calcolare valore atteso e varianza.

Si calcola il valore atteso condizionale ai valori di x del campione. Equivale a considerare campioni omogenei tra loro, che condividono gli stessi x ma non le stesse persone, perché ciò che cambia sono gli ε. Per capire il senso di campioni omogenei tra loro, il docente porta l'esempio dei colleghi che hanno fatto il dottorato con lui: persone con le stesse caratteristiche osservabili, ma che hanno fatto scelte diverse e hanno salari diversi. Sono uguali nelle x e diversi in ε.

Fissati tutti gli x del campione, β è una costante e il termine di rumore è una variabile casuale, perché ε non è fissato. La media di una costante più una variabile casuale è la costante più la media della variabile casuale. Il denominatore dipende solo da x, quindi è una costante e si porta fuori dalla media, dato che la media di una costante per una variabile casuale è la costante per la media. Inoltre la media di una somma è la somma delle medie, come quando si calcola il reddito medio familiare di una famiglia con due lavoratori sommando le medie dei due. L'operatore di

media si porta quindi dentro la sommatoria. Infine, fissati gli x, anche $(x_i - \bar{x})$ è una costante e si porta fuori:

$$E[\hat{\beta} \mid x] = \beta + \frac{1}{\sum_i (x_i - \bar{x})^2} \sum_i (x_i - \bar{x})\, E[\varepsilon_i \mid x].$$

Se il modello è corretto, $E[\varepsilon_i \mid x]$ è zero, quindi la somma è zero e

$$E[\hat{\beta} \mid x] = \beta.$$

In media lo stimatore è uguale a β.

3.3.4. Non distorsione e varianza dello stimatore

Se si prendono campioni con caratteristiche simili e si calcola $\hat{\beta}$ moltissime volte, la media di tutte queste stime deve essere il vero β, che per fortuna non è noto: se lo fosse, la statistica non servirebbe. Con un primo campione si ottiene $\hat{\beta}_1$, con un secondo $\hat{\beta}_2$, e così via. La teoria dice che la media di tutte queste stime è esattamente il vero valore. Si dice allora che lo stimatore è non distorto: non devia sistematicamente dal vero valore del parametro.

Finora si è guardata solo la media, non la distribuzione. La distribuzione si può calcolare in due modi: in modo esatto, oppure in modo asintotico, cioè approssimato, per campioni abbastanza grandi. Per calcolarla servono ipotesi più forti sul termine d'errore, sulla sua distribuzione di probabilità. Il docente non la affronta, perché non serve realmente, e dichiara di essere contrario alla distribuzione per campioni infiniti.

Il problema è che si ha un solo campione e non si sa se dia una stima vicina o lontana dalla media. La distanza dal vero valore dipende solo da ε, cioè dall'eterogeneità delle osservazioni in quel dataset specifico. Non dipende dal fatto che il modello sia sbagliato o che si usino formule sbagliate. Non si può valutare a monte, perché il vero valore non è noto. Serve quindi la distanza media tra lo stimatore, inteso come tutti i valori che può assumere su campioni diversi, e il vero parametro. La misura di distanza media in statistica è la varianza.

3.3.5. Varianza dello stimatore sotto omoschedasticità

Si calcola

$$\operatorname{Var}(\hat{\beta} \mid x) = \operatorname{Var}\left(\beta + \frac{\sum_i (x_i - \bar{x})\varepsilon_i}{\sum_i (x_i - \bar{x})^2} \,\middle|\, x \right).$$

Come visto, β è una costante e la varianza è insensibile alla traslazione, quindi conta solo il secondo termine. Per semplificare i calcoli si assume omoschedasticità, rimandando il caso generale a dopo. Il docente salta alcuni passaggi, solo noiosi. Fissato x, il denominatore è una costante, che uscendo dalla varianza va elevata al quadrato. Le osservazioni sono indipendenti,

quindi la varianza della somma è la somma delle varianze. Anche $(x_i - \bar{x})$ è costante e, portato fuori, va al quadrato:

$$\mathrm{Var}(\hat{\beta} \mid x) = \frac{\sum_i (x_i - \bar{x})^2 \,\mathrm{Var}(\varepsilon_i \mid x)}{\left(\sum_i (x_i - \bar{x})^2\right)^2}.$$

Se la varianza condizionale di ε è costante, la si chiama σ^2: non dipende da x e si porta fuori dalla sommatoria. Il numeratore si semplifica con uno dei due fattori del quadrato al denominatore:

$$\mathrm{Var}(\hat{\beta} \mid x) = \frac{\sigma^2}{\sum_i (x_i - \bar{x})^2}.$$

Dividendo numeratore e denominatore per n si ottiene una formula più intuitiva: il denominatore diventa la varianza campionaria di X, che per n abbastanza grande converge alla varianza di X nella popolazione, mentre il numeratore è σ^2/n. Il denominatore converge quindi a una costante, mentre il numeratore tende a zero al crescere di n. All'aumentare delle osservazioni l'incertezza dello stimatore tende a zero.

Ne segue che lo stimatore è consistente: con molti dati, la stima ottenuta da qualsiasi campione non si discosta dalla media. Il numero nella tabella di output, in un modello corretto e con abbastanza dati, collassa sul vero valore del parametro.

3.3.6. Illustrazione con campioni simulati

Il grafico mostra stime di β ottenute da campioni di numerosità diversa. Con campioni di dimensione 2, simulando col computer circa 10.000 campioni dalla stessa popolazione, si costruisce l'istogramma delle stime (blu). Con campioni di dimensione 10, sempre 10.000, la distribuzione è più concentrata: stime lontane, che con dimensione 2 compaiono, con dimensione 10 non capitano mai. Con dimensione 100 la distribuzione è molto più schiacciata attorno al vero parametro, il valore della popolazione.

Da verificare. La trascrizione riporta "campioni di dimensione n2" e "circa 10.000" ("mi sembra"); le dimensioni 2, 10 e 100 sono ricostruite dal contesto.

Se n tende all'infinito, si osservano tutte le persone della popolazione, tutti i campioni coincidono e lo stimatore dà sempre lo stesso numero: una variabile con media β e varianza zero. Osservando l'intera popolazione si trova il vero β. È un risultato teorico asintotico, ma l'intuizione è che più n è grande, più la varianza è piccola e più i valori ottenibili dalla procedura di stima sono concentrati intorno alla media, che si è dimostrato essere il vero valore. Con 100 osservazioni una stima molto distante dal vero β non capita praticamente mai.

3.3.7. Risultati fondamentali

Sotto l'ipotesi di esogeneità lo stimatore è non distorto. Sotto indipendenza delle osservazioni e varianza costante, cioè omoschedasticità, tende a essere consistente. Il secondo risultato si può dimostrare anche con dati dipendenti ed eteroschedasticità, ma la formula presentata è più semplice, a parte la noia della dimostrazione.

Da verificare. Il docente afferma che la consistenza vale anche con dati dipendenti; la dipendenza delle osservazioni richiede in generale condizioni aggiuntive, non discusse nella lezione.

Esame. Per il modello di regressione semplice, l'esogeneità è l'ipotesi cruciale: senza di essa non funziona niente. Le altre, come l'indipendenza delle osservazioni e l'omoschedasticità, sono tipicamente ipotesi di comodo e discutibili; saranno riprese più avanti.

Il docente chiede se ci siano domande, poi rimanda alla settimana successiva, quando proseguirà la teoria aggiungendo altri ingredienti.