

Università Ca' Foscari Venezia

Dipartimento di Economia

LAUREA MAGISTRALE IN
ECONOMIA E FINANZA

Econometria — esame del 21 gennaio 2025

Svolgimento completo e autosufficiente, con derivazioni e grafici

Appunti di:

Silvio Angelo Baratto Roldan

Codice insegnamento:

EM0004

Contenuto:

2 esercizi · 10 domande · 10 figure

Anno Accademico:

2026/2027

*Svolgimento personale a fini di studio, basato sulla teoria del corso (Econometria EM0004, prof. Davide Raggi).
Non è una soluzione ufficiale.*

Indice

1	Esercizio 1 — Prezzi delle case in Italia	1
1.1	Domanda 1 — Due stanze in più valgono più del 30%? (<i>3 punti</i>)	2
1.2	Domanda 2 — Perché nessuna dummy è stata eliminata (<i>3 punti</i>)	6
1.3	Domanda 3 — Elasticità dell'inquinamento (<i>3 punti</i>)	8
1.4	Domanda 4 — Differenziale di prezzo fra Zona 1 e Zona 2 (<i>3 punti</i>)	11
1.5	Domanda 5 — La zona ha rilevanza? Il sistema di ipotesi (<i>4 punti</i>)	15
1.6	Domanda 6 — Eteroschedasticità dal grafico dei residui (<i>3 punti</i>)	19
2	Esercizio 2 — Prezzi delle case e investimenti immobiliari negli Stati Uniti	23
2.1	Domanda 7 — Le due serie sono non stazionarie? (<i>3 punti</i>)	23
2.2	Domanda 8 — Engle-Granger: si può parlare di cointegrazione? (<i>4 punti</i>) . . .	27
2.3	Domanda 9 — L'ECM è ben definito? In quanti periodi si assorbe il 75%? (<i>3 punti</i>)	32
2.4	Domanda 10 — ACF e PACF: stazionarietà e scelta fra AR e MA (<i>3 punti</i>) . .	36

1 | Esercizio 1 — Prezzi delle case in Italia

Testo d'esame — Esercizio 1. In Italia è stato analizzato il problema della domanda di case e delle cause che ne potrebbero influenzare il prezzo. A tale scopo il Paese è stato diviso in 506 aree e per ciascuna di esse sono state osservate le seguenti variabili:

- **prezzo:** prezzo medio delle case nell'area i -esima (in euro);
- **crime:** tasso di criminalità (numero crimini per area);
- **nox:** concentrazione di inquinante nell'area i ;
- **rooms:** numero medio di camere;
- **zona1, zona2, zona3, zona4:** variabili dummy che identificano in maniera univoca l'area. Le zone di appartenenza delle case sono state classificate in quattro categorie a seconda di alcuni indicatori legati all'urbanizzazione ed alla vicinanza ad alcune utenze pubbliche (ospedali, fermate di mezzi pubblici, ecc.). Si noti inoltre che $\text{zona1} + \text{zona2} + \text{zona3} + \text{zona4} = 1$ per ogni area i analizzata.
 - **zona1:** = 1 se l'area è classificata come zona 1 e 0 altrimenti;
 - **zona2:** = 1 se l'area è classificata come zona 2 e 0 altrimenti;
 - **zona3:** = 1 se l'area è classificata come zona 3 e 0 altrimenti;
 - **zona4:** = 1 se l'area è classificata come zona 4 e 0 altrimenti.

Si consideri il seguente modello:

$$\begin{aligned} \log(\text{prezzo}) = & \beta_1 \text{crime} + \beta_2 \log(\text{nox}) + \beta_3 \text{rooms} \\ & + \delta_1 \text{zona1} + \delta_2 \text{zona2} + \delta_3 \text{zona3} + \delta_4 \text{zona4} + \epsilon. \end{aligned} \quad (1.1)$$

Le stime sono riportate di seguito:

Stime OLS.

	coefficiente	errore std.	rapporto t	p-value
crime	−0,0127792	0,00248715	−5,138	3,99e-07
nox	−0,0281161	0,00823410	−3,415	0,0007
rooms	0,0549082	0,0215226	2,551	0,0110
zona1	12,1767	0,137561	88,52	3,04e-307
zona2	11,8342	0,132916	89,04	0,0000

	coefficiente	errore std.	rapporto t	p-value
zona3	12,7239	0,169741	74,96	9,69e-274
zona4	12,4352	0,151612	82,02	8,82e-292

Lettura preliminare dell'output. Le quattro dummy sono esaustive e mutuamente esclusive: il testo dichiara esplicitamente che $\text{zona1} + \text{zona2} + \text{zona3} + \text{zona4} = 1$ per ogni i . Il modello (1.1) non contiene l'intercetta, ed è il fatto su cui ruota la Domanda 2. Ha dunque $k = 7$ regressori e nessuna costante: i gradi di libertà dei residui sono $n - k = 506 - 7 = 499$. La riga `nox` dell'output porta l'etichetta della variabile grezza, ma nel modello il regressore è $\log(\text{nox})$: il coefficiente β_2 è quindi un'elasticità, come si sfrutta alla Domanda 3.

1.1. Domanda 1 — Due stanze in più valgono più del 30%? (3 punti)

Testo della domanda. Domanda 1 (3 punti). Si costruisca un opportuno test per verificare se la presenza di due stanze aggiuntive induca in media un aumento del prezzo superiore al 30%. Si decida sulla base di un livello di significatività del 5%.

Richiami teorici. La dipendente è in logaritmo e `rooms` entra in livello: il modello è log-lin. In una specificazione di questo tipo β_j è l'effetto marginale parziale sul logaritmo della dipendente,

$$\frac{\partial E[\log Y \mid X_1, \dots, X_k]}{\partial X_j} = \beta_j, \quad \text{cioè} \quad \Delta \log Y = \beta_j \Delta X_j \quad (1.2)$$

a parità di tutti gli altri regressori, dove Y è la variabile dipendente in livello, X_j il regressore di interesse e Δ indica una variazione discreta. La traduzione di (1.2) in variazione percentuale non è enunciata a lezione e si ricava così: si parte dall'approssimazione $\log(X + a) - \log X \simeq a/X$, valida per $a \rightarrow 0$, e si pone $X = Y_0$ (valore iniziale) e $a = \Delta Y$, ottenendo

$$\begin{aligned} \beta_j \Delta X_j &= \log Y_1 - \log Y_0 \simeq \frac{\Delta Y}{Y_0}, \\ \% \Delta Y &\simeq 100 \beta_j \Delta X_j \quad (\text{versione approssimata}). \end{aligned} \quad (1.3)$$

Senza approssimare, da $\log Y_1 - \log Y_0 = \beta_j \Delta X_j$ segue $Y_1/Y_0 = e^{\beta_j \Delta X_j}$ e quindi

$$\% \Delta Y = 100(e^{\beta_j \Delta X_j} - 1) \quad (\text{versione esatta}). \quad (1.4)$$

L'approssimazione (1.3) è affidabile finché $|\beta_j \Delta X_j| \lesssim 0,1$; oltre, lo scarto diventa visibile ($\beta_j \Delta X_j = 0,20$ dà 20% approssimato contro 22,1% esatto; 0,50 dà 50% contro 64,9%). Da (1.4) segue la regola sulle soglie: se la domanda fissa una soglia percentuale p , l'ipotesi nulla coerente con la versione esatta è su $\log(1 + p)$ e non su p , perché è $\log(1 + p)$ il valore che $\beta_j \Delta X_j$ deve

assumere perché Y vari esattamente del p per cento. Per $p = 30\%$ si ha $\log(1,30) = 0,2623643$ contro 0,30: uno scarto di quasi quattro punti percentuali, che va dichiarato.

Lo strumento inferenziale è il test t su un valore specifico κ , non su zero. Se θ è il parametro di interesse e $\hat{\theta}$ il suo stimatore,

$$t = \frac{\hat{\theta} - \kappa}{\text{se}(\hat{\theta})}, \quad \text{con} \quad \text{se}(k \hat{\beta}_j) = |k| \text{se}(\hat{\beta}_j) \quad (k \text{ costante nota}). \quad (1.5)$$

Sotto $H_0 : \theta = \kappa$ la statistica (1.5) si distribuisce come una t di Student con i gradi di libertà residui del modello, asintoticamente $N(0,1)$; si rifiuta H_0 quando il p-value è minore del livello di significatività α , ovvero, nel caso unilaterale destro, quando $t > z_{1-\alpha}$. La seconda uguaglianza in (1.5) è essenziale: $2\hat{\beta}_3$ è un multiplo di un solo coefficiente, quindi nessuna covarianza fra stimatori entra in gioco e il test è calcolabile con il solo output. Per una somma o differenza di due coefficienti diversi servirebbe invece la covarianza fuori diagonale, che l'output non riporta: è il caso della Domanda 4.

L'intervallo di confidenza al 95% su θ è infine

$$IC_{95\%}(\theta) = \left[\hat{\theta} - z_{\alpha/2} \text{se}(\hat{\theta}) ; \hat{\theta} + z_{\alpha/2} \text{se}(\hat{\theta}) \right], \quad z_{\alpha/2} = 1,96, \quad (1.6)$$

e il test bilaterale si può condurre per ispezione: si rifiuta $H_0 : \theta = \kappa$ se e solo se $\kappa \notin IC_{95\%}(\theta)$.

Impostazione. La quantità di interesse non è β_3 ma $2\beta_3$: l'effetto di due stanze aggiuntive sul logaritmo del prezzo. L'affermazione da provare ("l'aumento supera il 30%") è una congettura che va messa in H_1 , perché il test protegge dal rifiuto erroneo di H_0 : si conclude "più del 30%" solo se i dati lo impongono. Il test è quindi unilaterale destro. La soglia ammette due letture legittime, 0,30 con la regola approssimata (1.3) e $\log(1,30)$ con quella esatta (1.4); le riportiamo entrambe.

Svolgimento. 1. Stima puntuale dell'effetto e suo errore standard. Applicando la seconda uguaglianza di (1.5) con $k = 2$,

$$\begin{aligned} 2\hat{\beta}_3 &= 2 \times 0,0549082 = 0,1098164, \\ \text{se}(2\hat{\beta}_3) &= 2 \times 0,0215226 = 0,0430452. \end{aligned} \quad (1.7)$$

2. Traduzione in percentuale. Con (1.3) e (1.4),

$$\begin{aligned} \% \Delta \text{prezzo} &\simeq 100 \times 0,1098164 = 10,98\%, \\ \% \Delta \text{prezzo} &= 100(e^{0,1098164} - 1) = 11,61\%. \end{aligned}$$

3. Le due soglie.

$$\begin{aligned}\kappa_{\text{appr}} &= 0,30, \\ \kappa_{\text{esatta}} &= \log(1,30) = 0,2623643.\end{aligned}$$

4. Sistema di ipotesi, identico nelle due versioni, cambia solo κ :

$$H_0 : 2\beta_3 = \kappa \quad \text{contro} \quad H_1 : 2\beta_3 > \kappa.$$

5. Statistiche osservate.

$$\begin{aligned}t_{\text{appr}} &= \frac{0,1098164 - 0,30}{0,0430452} = \frac{-0,1901836}{0,0430452} = -4,4182, \\ t_{\text{esatta}} &= \frac{0,1098164 - 0,2623643}{0,0430452} = \frac{-0,1525479}{0,0430452} = -3,5439.\end{aligned}\tag{1.8}$$

6. Distribuzione sotto H_0 e valore critico. $t \sim t_{499}$, in pratica $N(0,1)$. Il critico unilaterale destro al 5% è $z_{0,95} = 1,645$ ($t_{0,95;499} = 1,6479$, indistinguibile).

7. Decisione. Entrambe le statistiche (1.8) sono enormemente minori di $+1,645$: i p-value di coda destra valgono 0,99999 e 0,99978. Non si rifiuta H_0 in favore di “più del 30%”.

8. Il verso opposto. Poiché le statistiche cadono nella coda *sinistra*, testando $H_1 : 2\beta_3 < \kappa$ si ottiene p-value $6,1 \cdot 10^{-6}$ (soglia 0,30) e $2,2 \cdot 10^{-4}$ (soglia $\log 1,30$): l’effetto è significativamente inferiore al 30% con entrambe le soglie.

9. Intervallo di confidenza al 95% su $2\beta_3$, da (1.6) con $z_{\alpha/2} = 1,96$ e i valori (1.7):

$$IC_{95\%}(2\beta_3) = 0,1098164 \pm 1,96 \times 0,0430452 = [0,025448 ; 0,194185],\tag{1.9}$$

che in percentuale esatta corrisponde a $[+2,58\% ; +21,43\%]$. Né 0,30 né 0,2624 vi appartengono.

Lettura del grafico. Le due barre verticali del pannello (a) cadono a $-4,42$ e $-3,54$, cioè dalla parte opposta della regione di rifiuto: non c’è alcuna evidenza a favore di H_1 . Il pannello (b) mostra perché la scelta della soglia qui non è dirimente: l’intervallo di confidenza (1.9) si ferma a 0,194 e le due soglie candidate stanno entrambe ben oltre il suo estremo destro.

Risposta. No. Al 5% non si può affermare che due stanze aggiuntive facciano aumentare il prezzo di più del 30%: la statistica test vale $-4,42$ con la soglia 0,30 e $-3,54$ con la soglia esatta $\log(1,30)$, contro un critico di $+1,645$. Si può anzi affermare il contrario con forte evidenza:




Figura 1.1: Domanda 1. In alto la densità nulla con la regione di rifiuto unilaterale destra e le due statistiche osservate, entrambe lontanissime nella coda opposta; in basso l'intervallo di confidenza al 95% su $2\beta_3$, che esclude sia la soglia approssimata 0,30 sia quella esatta $\log(1,30) = 0,2624$.

l'effetto stimato è un aumento del 10,98% approssimato (11,61% esatto), con intervallo di confidenza al 95% pari a $[+2,58\%; +21,43\%]$, e la differenza rispetto al 30% è significativa in senso opposto (p-value $6,1 \cdot 10^{-6}$). In termini economici le camere in più fanno salire il prezzo, e il coefficiente è significativo ($t = 2,551$, p-value 0,0110), ma con un'intensità modesta. Per arrivare a un +30% servirebbero circa $0,30/0,0549 = 5,5$ stanze in più con la regola approssimata, ovvero $\log(1,30)/0,0549 = 4,8$ con quella esatta: cioè quattro o cinque stanze, ben più del doppio delle due ipotizzate.

Osservazione. Due errori costano punti qui. Il primo è testare β_3 invece di $2\beta_3$: la domanda parla di due stanze, non di una, e il fattore 2 va portato sia sul coefficiente sia sull'errore standard, come impone (1.5). Il secondo è mettere l'affermazione in H_0 : scrivendo $H_0: 2\beta_3 > 0,30$ si ribalta l'onere della prova e si finisce per “accettare” la congettura solo perché i dati sono poco

informativi. Si noti infine che le due soglie, 0,30 e $\log(1,30) = 0,2624$, differiscono di quasi quattro punti percentuali: in questo appello portano alla stessa conclusione, ma in un caso limite non lo farebbero, e la scelta va sempre dichiarata.

1.2. Domanda 2 — Perché nessuna dummy è stata eliminata (3 punti)

Testo della domanda. Domanda 2 (3 punti). Si spieghi perché nell'output del modello non è stata eliminata alcuna variabile dummy.

Richiami teorici. Con G dummy esaustive e mutuamente esclusive la loro somma è identicamente uguale a 1, cioè è la colonna della costante. Indicando con $\mathbf{z}_1, \dots, \mathbf{z}_G$ le colonne delle dummy e con $\boldsymbol{\iota}$ la colonna di uni dell'intercetta,

$$\sum_{j=1}^G \mathbf{z}_j = \boldsymbol{\iota}. \quad (1.10)$$

Tenere insieme intercetta e tutte le G dummy produce allora perfetta collinearità: per la (1.10) una colonna della matrice di disegno $\mathbf{X}$ è combinazione lineare esatta delle altre, il rango di $\mathbf{X}$ cade sotto il numero delle sue colonne e la matrice $\mathbf{X}'\mathbf{X}$ è singolare. Lo stimatore OLS

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y} \quad (1.11)$$

non è quindi definito: il sistema delle equazioni normali non ha soluzione unica, e la regola operativa è eliminare uno qualsiasi dei regressori che generano la collinearità. In presenza di dummy esaustive le uscite sono due e due soltanto:

1. si omette una categoria, che diventa il gruppo di riferimento; il modello conserva l'intercetta, e ogni δ_j è lo scostamento della media del proprio gruppo da quello di riferimento, cioè $E[Y \mid \text{gruppo } j] - E[Y \mid \text{gruppo base}] = \delta_j$ a parità delle altre variabili;
2. si omette l'intercetta; tutte le G dummy restano, e ogni δ_j è il livello medio della propria categoria, $E[Y \mid \text{gruppo } j] = \delta_j$ a parità delle altre variabili.

Le due parametrizzazioni sono statisticamente equivalenti: stessi residui e stessi valori predetti. Differiscono solo per che cosa si legge nei coefficienti. Quando un output riporta tutte le dummy, dunque, si controlli se manca la costante: è quello il motivo, non un errore del software.

Impostazione. La domanda si risolve leggendo l'output riga per riga, non enunciando la regola. Le righe sono sette (`crime`, `nox`, `rooms`, `zona1`, `zona2`, `zona3`, `zona4`) e non c'è la riga `const`. Il modello (1.1) scritto nel testo, del resto, non contiene alcun termine costante. È la seconda delle due uscite sopra: si è rinunciato all'intercetta invece che a una dummy, e per questo tutte e quattro le dummy possono restare.

Svolgimento. 1. La singolarità che si sarebbe prodotta. Con $G = 4$ la (1.10) diventa, per garanzia esplicita del testo,

$$\mathbf{z}_1 + \mathbf{z}_2 + \mathbf{z}_3 + \mathbf{z}_4 = \mathbf{1}, \quad (1.12)$$

cioè una combinazione lineare esatta fra cinque colonne: il rango della matrice di disegno cadrebbe sotto il numero di colonne e $(\mathbf{X}'\mathbf{X})^{-1}$ di (1.11) non esisterebbe. Un software come `gretl` reagisce scartando automaticamente una variabile e stampando (**dropped**) accanto ad essa.

2. Che cosa misura, di conseguenza, ciascun $\hat{\delta}_j$. Ponendo a zero le altre variabili,

$$E[\log(\text{prezzo}) \mid \text{zona } j, \text{ crime} = 0, \text{ nox} = 1, \text{ rooms} = 0] = \delta_j \quad (1.13)$$

(si noti $\text{nox} = 1$, perché il regressore è $\log(\text{nox})$ e $\log 1 = 0$). Ogni $\hat{\delta}_j$ è dunque un livello, non un differenziale.

3. Conseguenza sui rapporti t dell'output. I valori 88,52, 89,04, 74,96, 82,02 testano $H_0 : \delta_j = 0$, cioè, per la (1.13), “il prezzo medio della zona j è pari a $e^0 = 1$ euro”. Sono enormi e privi di interesse economico: la domanda rilevante riguarda le differenze fra zone, ed è quella delle Domande 4 e 5.

4. Ordinamento delle zone. Dai livelli stimati,

$$\hat{\delta}_3 = 12,7239 > \hat{\delta}_4 = 12,4352 > \hat{\delta}_1 = 12,1767 > \hat{\delta}_2 = 11,8342,$$

la Zona 3 è la più cara e la Zona 2 la più economica.

Lettura del grafico. Il pannello (a) mostra il meccanismo: qualunque sia l'area, la riga della matrice ha un solo 1 fra le quattro dummy, e la loro somma di riga è sempre 1, come afferma la (1.12). Nel pannello (b) si legge la conseguenza: i quattro punti stanno tutti attorno a 12, cioè sono livelli di $\log(\text{prezzo})$ e non differenze attorno allo zero, come sarebbe stato se una categoria fosse stata esclusa.

Risposta. Nessuna dummy è stata eliminata perché è stata eliminata l'intercetta: il modello del testo non contiene alcun termine costante, e l'output non riporta infatti la riga **const**. Poiché per costruzione $\text{zona1} + \text{zona2} + \text{zona3} + \text{zona4} = 1$, la somma delle quattro dummy coincide con la colonna della costante: tenerle tutte e quattro *insieme* all'intercetta darebbe collinearità perfetta e renderebbe $\mathbf{X}'\mathbf{X}$ non invertibile. Sacrificando l'intercetta la collinearità sparisce e tutte e quattro le dummy possono essere stimate. Il prezzo di questa scelta è interpretativo: ogni $\hat{\delta}_j$ non è più un differenziale rispetto a una zona di riferimento, ma il livello medio di $\log(\text{prezzo})$ della zona j , a parità di criminalità, inquinamento e numero di stanze. Le due parametrizzazioni restano statisticamente equivalenti, R^2 compreso: cambia solo che cosa leggiamo nei coefficienti.

Osservazione. Non si dica “è un errore del software”. E non si legga $e^{\hat{\delta}_j}$ come il prezzo medio della zona: $e^{12,1767} \approx 194\,000$ euro è il valore predetto in un'area con zero crimini, zero stanze medie




Figura 1.2: Domanda 2. A sinistra lo schema della matrice di disegno: la somma delle quattro dummy riproduce esattamente la colonna della costante, da cui la collinearità perfetta. A destra i quattro coefficienti stimati con il loro intervallo al 95%: senza intercetta ciascuno è il livello medio di log(prezzo) della propria zona, non uno scostamento da una categoria base.

e $\text{nox} = 1$, cioè un punto ben fuori dal campo di variazione dei dati. È un'estrapolazione, non una previsione. Si ricordi infine che senza intercetta i gradi di libertà residui sono $n - k = 499$ e non $n - k - 1 = 498$, e che gretl riporta per questi modelli un R^2 non centrato, non confrontabile con quello di un modello con costante.

1.3. Domanda 3 — Elasticità dell'inquinamento (3 punti)

Testo della domanda. Domanda 3 (3 punti). Si calcoli l'elasticità del fattore inquinamento e si dica se un aumento di tale fattore del 5% è coerente con una riduzione dei prezzi medi del 10%.

Richiami teorici. Rispetto a nox il modello (1.1) è log-log: dipendente e regressore entrano entrambi in logaritmo. In una specificazione $\log Y = \alpha + \beta \log X + \dots$ si ha $\Delta \log Y = \beta \Delta \log X$ e, applicando a entrambi i membri l'approssimazione $\log(X + a) - \log X \simeq a/X$,

$$\begin{aligned} \frac{\Delta Y}{Y} &\simeq \beta \frac{\Delta X}{X}, \\ \beta &= \frac{\% \Delta Y}{\% \Delta X} = \varepsilon_{Y,X}. \end{aligned} \quad (1.14)$$

Il coefficiente è l'elasticità di Y rispetto a X , ed è costante su tutto il campo di variazione: è la ragione per cui si sceglie la forma log-log. Una variazione dell' m per cento di X produce

dunque una variazione di $\beta \cdot m$ per cento di Y . Anche questa regola di interpretazione non è enunciata a lezione: le note contengono i modelli in logaritmo come specificazione, non la loro lettura in termini di elasticità. Si ricava come sopra, in due passaggi, dalla sola (1.2) applicata alla variabile trasformata.

La versione esatta, senza approssimazione, si ottiene dallo stesso argomento della (1.4): per una variazione relativa g di X si ha $\Delta \log X = \log(1 + g)$, dunque $\Delta \log Y = \beta \log(1 + g)$ e

$$\% \Delta Y = 100(e^{\beta \log(1+g)} - 1) = 100[(1 + g)^\beta - 1]. \quad (1.15)$$

Per il test su un valore specifico dell'elasticità e per l'intervallo di confidenza si usano (1.5) e (1.6), perché $\varepsilon_{Y,X}$ è qui un singolo coefficiente del modello e il suo errore standard è nell'output.

Impostazione. L'etichetta **nox** nell'output è ingannevole: nel modello il regressore è $\log(\text{nox})$, e la dipendente è $\log(\text{prezzo})$. Siamo dunque in un modello log-log rispetto all'inquinamento e il coefficiente stimato è già l'elasticità, senza alcuna trasformazione. La seconda parte della domanda si risolve confrontando l'elasticità stimata con quella che sarebbe necessaria perché un +5% produca un -10%, cioè $-10/5 = -2$.

Svolgimento. 1. Elasticità stimata. Per la (1.14),

$$\begin{aligned} \hat{\varepsilon}_{\text{prezzo, nox}} &= \hat{\beta}_2 = -0,0281161, \\ \text{se}(\hat{\beta}_2) &= 0,00823410, \quad t = -3,415, \quad \text{p-value} = 0,0007. \end{aligned}$$

L'elasticità è significativamente diversa da zero all'1%: l'inquinamento conta.

2. Effetto di un aumento del 5%. Con la regola approssimata (1.14) e con quella esatta (1.15), dove $\Delta \log(\text{nox}) = \log(1,05) = 0,0487902$,

$$\begin{aligned} \% \Delta \text{prezzo} &\simeq \hat{\beta}_2 \times 5 = -0,0281161 \times 5 = -0,1406\%, \\ \% \Delta \text{prezzo} &= 100(e^{-0,0281161 \times 0,0487902} - 1) \\ &= 100(e^{-0,0013718} - 1) = -0,1371\%. \end{aligned}$$

3. Intervallo di confidenza al 95% sull'elasticità, da (1.6):

$$IC_{95\%}(\beta_2) = -0,0281161 \pm 1,96 \times 0,00823410 = [-0,0442549 ; -0,0119773], \quad (1.16)$$

che si traduce, per un +5% di **nox**, in una variazione di prezzo compresa fra -0,216% e -0,058%.

4. Che elasticità servirebbe per un -10% ? Per la definizione (1.14),

$$\varepsilon^{\text{richiesta}} = \frac{\% \Delta \text{prezzo}}{\% \Delta \text{nox}} = \frac{-10}{5} = -2.$$

5. Test formale $H_0 : \beta_2 = -2$ contro $H_1 : \beta_2 \neq -2$, con $\kappa = -2$ in (1.5):

$$t = \frac{-0,0281161 - (-2)}{0,00823410} = \frac{1,9718839}{0,00823410} = 239,48,$$

contro un critico bilaterale di 1,96: si rifiuta con p-value numericamente nullo. L'elasticità richiesta dista 239 errori standard dalla stima.

6. **Lettura inversa.** Quale aumento di nox produrrebbe un -10% ? Con la regola approssimata e con quella esatta,

$$\begin{aligned} -10 &= -0,0281161 \times g & \implies & g = +356\%, \\ \Delta \log(\text{nox}) &= \frac{\log(0,90)}{\hat{\beta}_2} = 3,7473 \\ &\implies e^{3,7473} = 42,4, \text{ cioè } g = +4141\%. \end{aligned}$$

7. **Ordine di grandezza.** Persino un raddoppio dell'inquinamento ($g = +100\%$) abbasserebbe i prezzi solo di

$$100 \left(e^{\hat{\beta}_2 \log 2} - 1 \right) = -1,93\%.$$

Lettura del grafico. Nel pannello (a) la linea verticale del $+5\%$ incontra la curva praticamente a quota zero: l'effetto è talmente piccolo da essere invisibile alla scala della figura, mentre la riga del -10% resta irraggiungibile su tutto l'asse disegnato. Il pannello (b) rende esplicito il divario: anche prendendo l'estremo più sfavorevole dell'intervallo (1.16), $-0,216\%$, si resta quasi cinquanta volte al di sotto del -10% ipotizzato.

Risposta. L'elasticità del prezzo rispetto all'inquinamento è $\hat{\varepsilon} = \hat{\beta}_2 = -0,0281$: poiché il regressore è $\log(\text{nox})$ e la dipendente è $\log(\text{prezzo})$, il coefficiente si legge direttamente come elasticità, ed è costante su tutto il campo di variazione. È significativamente negativa (p-value 0,0007): più inquinamento, prezzi più bassi.

Un aumento del 5% non è affatto coerente con una riduzione dei prezzi del 10%. Un $+5\%$ di nox produce una riduzione dei prezzi medi di circa 0,14% ($-0,1406\%$ con la regola approssimata, $-0,1371\%$ con quella esatta), cioè circa settanta volte meno del 10% ipotizzato; l'intervallo di confidenza al 95% su questo effetto, $[-0,216\%; -0,058\%]$, non contiene nulla di vicino. Perché la congettura fosse vera l'elasticità dovrebbe valere -2 , valore rifiutato con $t = 239,5$. Equivalentemente, per ottenere un calo del 10% l'inquinamento dovrebbe aumentare del 356% (regola




Figura 1.3: Domanda 3. A sinistra la variazione percentuale del prezzo in funzione di quella di *nox*: la curva esatta (blu) con la sua banda al 95% e la regola lineare approssimata (ambra). Nessuna delle due tocca il -10% per un aumento del 5%; la riga rossa mostra quanto sarebbe lontano l'obiettivo. A destra il confronto di ordine di grandezza su scala logaritmica: fra l'effetto stimato di un +5% e il -10% ipotizzato corre un fattore 73.

approssimata) o del 4141% (regola esatta): cifre prive di plausibilità. La conclusione economica è che l'inquinamento è un determinante statisticamente significativo ma quantitativamente marginale del prezzo delle case in questo campione.

Osservazione. Non si confonda significatività statistica e rilevanza economica: qui il coefficiente è significativo all'uno per mille e al tempo stesso quasi irrilevante in grandezza. E non si legga $\hat{\beta}_2$ come "un'unità in più di *nox* abbassa il prezzo del 2,8%": sarebbe la lettura log-lin (1.3), sbagliata, perché il regressore entra in logaritmo. La variazione è del 2,8% per ogni cento per cento di aumento di *nox*, non per ogni unità.

1.4. Domanda 4 — Differenziale di prezzo fra Zona 1 e Zona 2 (3 punti)

Testo della domanda. Domanda 4 (3 punti). Si costruisca un intervallo di confidenza per il differenziale dei prezzi tra case appartenenti alla Zona 1 ed alla Zona 2, a parità di altre condizioni. A questo proposito, sappiamo che la covarianza tra gli stimatori dei parametri δ_1 e δ_2 è 0,0181234. Si decida, ad un livello del 5%, se la differenza nei prezzi tra le due zone risulta statisticamente significativa.

Richiami teorici. La matrice di covarianza dello stimatore OLS è $\text{Var}(\hat{\beta}) = \sigma^2(\mathbf{X}'\mathbf{X})^{-1}$. Per una combinazione lineare $\theta = \mathbf{a}'\beta$ vale allora $\text{Var}(\hat{\theta}) = \mathbf{a}'\text{Var}(\hat{\beta})\mathbf{a}$, che con due soli coefficienti

e $\mathbf{a} = (a, b)'$ diventa

$$\text{Var}(a\hat{\beta}_1 + b\hat{\beta}_2) = a^2 \text{Var}(\hat{\beta}_1) + b^2 \text{Var}(\hat{\beta}_2) + 2ab \text{Cov}(\hat{\beta}_1, \hat{\beta}_2). \quad (1.17)$$

Anche la (1.17) non è fra le formule enunciate a lezione: le note dichiarano soltanto che il denominatore della t su una differenza di coefficienti “non è immediato da valutare” e per questo passano al test F . Si ricava in una riga sviluppando la forma quadratica $\mathbf{a}' \text{Var}(\hat{\boldsymbol{\beta}}) \mathbf{a}$ con $\mathbf{a} = (a, b)'$ e

$$\text{Var}(\hat{\boldsymbol{\beta}}) = \begin{pmatrix} \text{Var}(\hat{\beta}_1) & \text{Cov}(\hat{\beta}_1, \hat{\beta}_2) \\ \text{Cov}(\hat{\beta}_1, \hat{\beta}_2) & \text{Var}(\hat{\beta}_2) \end{pmatrix}. \quad (1.18)$$

Per la differenza di due coefficienti si pone $a = 1$, $b = -1$ e si ottiene

$$\text{Var}(\hat{\beta}_1 - \hat{\beta}_2) = \text{Var}(\hat{\beta}_1) + \text{Var}(\hat{\beta}_2) - 2 \text{Cov}(\hat{\beta}_1, \hat{\beta}_2). \quad (1.19)$$

L'output di una regressione riporta solo la diagonale di (1.18), cioè gli errori standard: senza il termine fuori diagonale il test t su una differenza non è calcolabile. Le vie legittime sono tre e vanno nominate: (i) il test F su una restrizione lineare con $s = 1$, che non richiede la covarianza esplicita perché si costruisce sul confronto fra modello ristretto e modello completo; (ii) la riparametrizzazione del modello, in modo che la combinazione di interesse diventi un singolo coefficiente di cui l'output stampa l'errore standard; (iii) usare la covarianza se il testo la fornisce, come accade in questo appello. Sommare gli errori standard riportati equivale a porre $\text{Cov} = 0$ senza giustificazione ed è un errore grave.

Costruita $se(\hat{\theta}) = \sqrt{\text{Var}(\hat{\theta})}$, l'intervallo e il test si ottengono da (1.6) e (1.5) con $\kappa = 0$; la decisione per ispezione dell'intervallo è equivalente al test bilaterale. Poiché la dipendente è in logaritmo, la traduzione del differenziale in percentuale segue la regola esatta per una variabile indicatrice: se δ è il salto di $\log Y$ associato al passaggio da una categoria all'altra, allora

$$\% \Delta Y \simeq 100 \delta \quad (\text{approssimata}), \quad \% \Delta Y = 100(e^\delta - 1) \quad (\text{esatta}), \quad (1.20)$$

dove la seconda segue da $Y_1/Y_0 = e^\delta$ esattamente come la (1.4). Con $|\delta| > 0,3$ lo scarto fra le due versioni è già ben visibile e va dichiarato.

Impostazione. Poiché il modello è senza intercetta, δ_1 e δ_2 sono livelli, per la (1.13), e il differenziale cercato è la loro differenza, $\theta = \delta_1 - \delta_2$, misurata in logaritmi di prezzo. È il caso raro in cui il testo fornisce $\text{Cov}(\hat{\delta}_1, \hat{\delta}_2)$: il test t diventa pienamente calcolabile e non occorre ripiegare sul test F .

Svolgimento. 1. Stima puntuale del differenziale.

$$\hat{\theta} = \hat{\delta}_1 - \hat{\delta}_2 = 12,1767 - 11,8342 = 0,3425.$$

2. Varianza, termine per termine, secondo la (1.19):

$$\begin{aligned}\text{Var}(\hat{\delta}_1) &= (0,137561)^2 = 0,0189230287, \\ \text{Var}(\hat{\delta}_2) &= (0,132916)^2 = 0,0176666631, \\ 2 \text{Cov}(\hat{\delta}_1, \hat{\delta}_2) &= 2 \times 0,0181234 = 0,0362468000,\end{aligned}$$

da cui

$$\text{Var}(\hat{\theta}) = 0,0189230287 + 0,0176666631 - 0,0362468000 = 0,0003428918.$$

3. Errore standard.

$$\text{se}(\hat{\theta}) = \sqrt{0,0003428918} = 0,0185173. \quad (1.21)$$

4. Perché è così piccolo: la correlazione fra i due stimatori.

$$\widehat{\text{Corr}}(\hat{\delta}_1, \hat{\delta}_2) = \frac{\text{Cov}(\hat{\delta}_1, \hat{\delta}_2)}{\text{se}(\hat{\delta}_1) \text{se}(\hat{\delta}_2)} = \frac{0,0181234}{0,137561 \times 0,132916} = 0,9912. \quad (1.22)$$

I due stimatori sono correlati al 99%. Il motivo è strutturale: senza intercetta ogni $\hat{\delta}_j$ contiene la stessa informazione sul livello generale dei prezzi, che è comune e imprecisa; nella differenza quella componente si elide e resta solo l'informazione sul contrasto fra le due zone, che il campione determina molto bene. Il differenziale è quindi stimato con un errore standard sette volte più piccolo di quello dei singoli livelli (0,0185 contro 0,1376 e 0,1329).

5. Test t . Con $H_0 : \delta_1 - \delta_2 = 0$ contro $H_1 : \delta_1 - \delta_2 \neq 0$,

$$t = \frac{0,3425 - 0}{0,0185173} = 18,496,$$

contro un critico bilaterale al 5% di 1,96: si rifiuta H_0 , con p-value numericamente nullo.

6. Intervallo di confidenza al 95%.

$$IC_{95\%}(\delta_1 - \delta_2) = 0,3425 \pm 1,96 \times 0,0185173 = [0,306206 ; 0,378794].$$

Lo zero non vi appartiene: la stessa decisione del punto 5, per ispezione dell'intervallo.

7. Traduzione in percentuale, versione esatta della (1.20):

stima: $100(e^{0,3425} - 1) = +40,85\%$,

IC: $[100(e^{0,306206} - 1); 100(e^{0,378794} - 1)] = [+35,83\%; +46,05\%]$.

La versione approssimata darebbe $+34,25\%$, cioè 6,6 punti percentuali in meno: con $|\delta| > 0,3$ lo scarto fra le due regole va dichiarato.




Figura 1.4: Domanda 4. In alto la varianza del differenziale scomposta termine per termine: le due varianze si sommano a 0,036590, ma -2Cov ne sottrae 0,036247, lasciando un residuo di 0,000343 invisibile alla scala del grafico. In basso il confronto fra l'intervallo corretto e quello che si otterrebbe ponendo erroneamente la covarianza a zero: il primo esclude nettamente lo zero, il secondo lo contiene.

Lettura del grafico. Il pannello (a) rende visivo il meccanismo della (1.19): la barra rossa della covarianza cancella quasi esattamente la somma delle due barre azzurre, ed è questa quasi-cancellazione a generare l'errore standard minuscolo (1.21). Il pannello (b) mostra che

la questione non è cosmetica: l'intervallo corretto è largo 0,073 e sta tutto a destra dello zero, mentre quello costruito ignorando la covarianza è largo 0,750 e lo zero ci cade dentro.

Risposta. L'intervallo di confidenza al 95% per il differenziale $\delta_1 - \delta_2$ è $[0,3062 ; 0,3788]$ in unità di $\log(\text{prezzo})$, attorno alla stima puntuale 0,3425 con errore standard 0,0185.

Sì, la differenza è statisticamente significativa al 5%: lo zero è fuori dall'intervallo, e il test t dà $t = 18,50$ contro un critico di 1,96 (p-value praticamente nullo). Economicamente, a parità di criminalità, inquinamento e numero medio di stanze, una casa in Zona 1 costa in media il 40,8% in più di una in Zona 2, con un intervallo di confidenza al 95% che va dal +35,8% al +46,1%. Il divario è ampio e stimato con precisione: la classificazione urbanistica dell'area pesa sul prezzo due ordini di grandezza più dell'inquinamento (Domanda 3).

Osservazione. È l'errore che questa domanda è costruita per punire: sommare le varianze ignorando la covarianza. Si otterrebbe se $(\hat{\theta}) = \sqrt{0,0189230 + 0,0176667} = 0,1913$, quindi $t = 1,79$ e intervallo $[-0,0324; 0,7174]$, che contiene lo zero: si concluderebbe “differenza non significativa”, cioè il contrario del vero. Porre $\text{Cov} = 0$ senza giustificazione è un'ipotesi sostanziale, non un'approssimazione, e qui è falsa al 99%, come mostra la (1.22). Allo stesso modo, non si sottraggano gli errori standard: $\text{se}(\hat{\delta}_1) - \text{se}(\hat{\delta}_2)$ non ha alcun significato.

1.5. Domanda 5 — La zona ha rilevanza? Il sistema di ipotesi (4 punti)

Testo della domanda. Domanda 5 (4 punti). Sulla base del modello stimato, si definisca un opportuno sistema di ipotesi utile a decidere se la zona di appartenenza dell'immobile ha rilevanza nello spiegare il livello medio dei prezzi.

Richiami teorici. Ogni restrizione va scritta nella forma canonica

$$r_1\beta_1 + r_2\beta_2 + \dots + r_k\beta_k = q, \quad (1.23)$$

con $r_1, \dots, r_k$ e q costanti note; il primo passo obbligatorio è riscrivere l'ipotesi in questa forma e contare quante combinazioni lineari distinte sono imposte: quel numero è s . Così $\beta_6 - \beta_8 = 0$ è una restrizione ($r_6 = 1, r_8 = -1$, gli altri $r_i = 0, q = 0$), mentre $\beta_1 = \beta_2 = \beta_3 = 0$ sono tre combinazioni lineari.

Il modello ristretto è quello in cui si impongono le s restrizioni, cioè quello in cui H_0 è vera; il modello completo è il modello originale non vincolato. Il test confronta il loro adattamento attraverso i due coefficienti di determinazione, R_c^2 per il completo e R_r^2 per il ristretto, mediante la statistica

$$F_{s; n-k-1} = \frac{(R_c^2 - R_r^2)/s}{(1 - R_c^2)/(n - k - 1)}, \quad (1.24)$$

dove n è la numerosità campionaria, k il numero di regressori del modello completo e $n - k - 1$ i suoi gradi di libertà residui (il -1 è la costante, e va omissa se il modello non ne ha). Sotto H_0 la (1.24) è ben approssimata da una F con s e $n - k - 1$ gradi di libertà; H_1 afferma che almeno una delle s restrizioni non vale.

Il test è unilaterale destro. Il motivo è algebrico: l' R^2 non decresce quando si aggiungono regressori, dunque $R_c^2 \geq R_r^2$ e $F \geq 0$ sempre; i valori vicini a zero sono più favorevoli a H_0 che a H_1 , e la regione di rifiuto sta tutta a destra. Non si divide quindi α per due. Si rifiuta se F^{oss} supera il critico, oppure se il p-value di coda destra è minore di α .

Il test t ripetuto non è un sostituto del test F per un'ipotesi congiunta. Con tre test bilaterali indipendenti al 5% il livello effettivo diventa

$$1 - 0,95 \times 0,95 \times 0,95 = 1 - 0,8574 = 0,1426 \neq 0,05, \quad (1.25)$$

cioè circa 3α : si perde il controllo del livello di significatività. (Il calcolo assume l'indipendenza delle tre statistiche, ipotesi non credibile ma sufficiente a mostrare l'ordine di grandezza dell'errore.)

Impostazione. Il punto delicato è tradurre “la zona non ha rilevanza” in restrizioni, e la traduzione dipende dalla parametrizzazione. In un modello con intercetta e una categoria omessa, l'assenza di effetto sarebbe $\delta_1 = \delta_2 = \delta_3 = 0$. Qui però i coefficienti sono livelli per la (1.13), non scostamenti: dire che la zona non conta significa dire che i quattro livelli sono uguali fra loro, non che sono nulli. Tre uguaglianze indipendenti, non quattro.

Svolgimento. 1. Sistema di ipotesi.

$$H_0 : \delta_1 = \delta_2 = \delta_3 = \delta_4,$$

$$H_1 : \text{almeno una delle uguaglianze non vale.}$$

2. Forma canonica e conteggio di s . Scriviamo le uguaglianze come contrasti nella forma (1.23):

$$\begin{aligned} r_1 : \quad \delta_1 - \delta_2 &= 0, \\ r_2 : \quad \delta_2 - \delta_3 &= 0, \\ r_3 : \quad \delta_3 - \delta_4 &= 0. \end{aligned} \quad (1.26)$$

Sono tre combinazioni lineari distinte e linearmente indipendenti, quindi $s = 3$. Qualunque altra terna di contrasti indipendenti (per esempio $\delta_1 - \delta_4$, $\delta_2 - \delta_4$, $\delta_3 - \delta_4$) definisce lo stesso vincolo: con G categorie le uguaglianze indipendenti sono $G - 1$, e una quarta restrizione come $\delta_1 - \delta_4 = 0$ è già implicata dalle prime tre.

3. Modello ristretto. Imponendo $\delta_1 = \delta_2 = \delta_3 = \delta_4 \equiv \delta$ nel modello (1.1) e usando l'identità (1.12) nella sua forma scalare $\text{zona1} + \text{zona2} + \text{zona3} + \text{zona4} = 1$:

$$\begin{aligned}\log(\text{prezzo}) &= \beta_1 \text{crime} + \beta_2 \log(\text{nox}) + \beta_3 \text{rooms} \\ &\quad + \delta(\text{zona1} + \text{zona2} + \text{zona3} + \text{zona4}) + \epsilon \\ &= \beta_1 \text{crime} + \beta_2 \log(\text{nox}) + \beta_3 \text{rooms} + \delta + \epsilon.\end{aligned}\tag{1.27}$$

Il modello ristretto (1.27) è dunque il modello con la sola intercetta δ e senza alcuna dummy di zona: le quattro dummy collassano nella costante. Ha 4 parametri contro i 7 del completo, ed è la conferma che le restrizioni imposte sono $7 - 4 = 3$.

4. Statistica test e distribuzione. Dalla (1.24) con $s = 3$,

$$F^{oss} = \frac{(R_c^2 - R_r^2)/3}{(1 - R_c^2)/499} \sim F_{3,499} \quad \text{sotto } H_0.$$

I gradi di libertà del denominatore sono $n - k = 506 - 7 = 499$: il modello completo non ha costante, quindi non si sottrae l'unità aggiuntiva.

5. Regola di decisione. Si rifiuta H_0 se $F^{oss} > F_{3,499;0,95} = 2,623$ (con i gradi di libertà della nota, $F_{3,60} = 2,76$), oppure se il p-value di coda destra è inferiore a 0,05.

6. Che cosa si può dire numericamente. Il testo non riporta né R_c^2 né R_r^2 , quindi F^{oss} non è calcolabile da questo output. Ma la Domanda 4 ha già rifiutato r_1 da sola, con $t = 18,50$ e p-value nullo: una delle tre restrizioni (1.26) che compongono H_0 è violata con evidenza schiacciante, dunque l'ipotesi congiunta non è sostenibile.

Lettura del grafico. Nel pannello (a) i quattro livelli sono tutt'altro che allineati: Zona 3 sta quasi 0,9 sopra Zona 2 e i rispettivi intervalli di confidenza non si sovrappongono nemmeno. Una retta orizzontale unica, quale che sia il livello a cui la si ponga, è incompatibile con i dati: è questo, non la posizione della retta rossa, il punto del pannello. Il pannello (b) ricorda che il test è a una coda sola e che il critico al 5% è appena 2,623: qualunque plausibile F^{oss} cadrebbe ben oltre il bordo destro del grafico.

Risposta. Il sistema di ipotesi opportuno è l'uguaglianza dei quattro coefficienti di zona:

$$H_0 : \delta_1 = \delta_2 = \delta_3 = \delta_4 \quad \text{contro} \quad H_1 : \delta_i \neq \delta_j \text{ per almeno una coppia.}$$

Sotto H_0 tutte le zone hanno lo stesso livello medio di $\log(\text{prezzo})$ a parità delle altre variabili, cioè la classificazione urbanistica non aggiunge nulla. Le restrizioni indipendenti sono tre, non quattro: $\delta_1 - \delta_2 = 0$, $\delta_2 - \delta_3 = 0$, $\delta_3 - \delta_4 = 0$; quindi $s = 3$. Il modello ristretto corrispondente è

$$\log(\text{prezzo}) = \delta + \beta_1 \text{crime} + \beta_2 \log(\text{nox}) + \beta_3 \text{rooms} + \epsilon,$$




Figura 1.5: Domanda 5. A sinistra i quattro livelli stimati con i loro intervalli al 95% e le tre frecce che rappresentano le restrizioni indipendenti r_1, r_2, r_3 ; la retta rossa è un riferimento illustrativo, la media non ponderata dei quattro $\hat{\delta}$, e segna dove cadrebbe un livello comune: il valore effettivamente imposto dal modello ristretto è una stima OLS che dipende dalle numerosità dei gruppi e non è ricavabile dall’output (punto 6). A destra la densità $F_{3,499}$ con la regione di rifiuto unilaterale destra oltre 2,623.

cioè il modello con una sola intercetta e nessuna dummy, ottenuto sfruttando $\sum_j \text{zona}_j = 1$. Lo strumento è il test F su restrizioni lineari multiple, $F^{oss} = [(R_c^2 - R_r^2)/3]/[(1 - R_c^2)/499] \sim F_{3,499}$, unilaterale destro con critico 2,623 al 5%. Il valore osservato non è ricavabile dall’output fornito, perché mancano i due R^2 ; la Domanda 4 mostra però che già il solo contrasto Zona 1 contro Zona 2 è significativo con $t = 18,50$, e una singola restrizione di H_0 così nettamente violata rende impossibile che l’ipotesi congiunta regga. La conclusione economica attesa è quindi il rifiuto di H_0 : la zona di appartenenza ha rilevanza nello spiegare il livello medio dei prezzi.

Osservazione. Tre trappole. La prima è scrivere $H_0 : \delta_1 = \delta_2 = \delta_3 = \delta_4 = 0$: sono quattro restrizioni, non tre, e l’ipotesi significherebbe “il prezzo medio di ogni zona è di un euro”, non “la zona non conta”. Quella forma sarebbe corretta solo in un modello con intercetta e una categoria omessa, dove i δ sono scostamenti, e anche lì le restrizioni sarebbero tre, perché le dummy stimate sarebbero tre. La seconda è sostituire il test F con tre (o sei) test t separati: il livello effettivo salirebbe al 14,3%, come mostra la (1.25). La terza riguarda l’ R^2 : gretl riporta per i modelli senza costante un R^2 non centrato; la formula (1.24) resta applicabile perché entrambi i modelli contengono la costante nello spazio generato dalle colonne (nel completo come somma delle quattro dummy, nel ristretto esplicitamente), ma i due R^2 vanno presi sulla stessa base.

1.6. Domanda 6 — Eteroschedasticità dal grafico dei residui (3 punti)

Testo della domanda. Domanda 6 (3 punti). La Figura 1 rappresenta graficamente la relazione tra valori predetti e residui del modello. Si dica, se possibile, se dal grafico possiamo dire qualcosa rispetto all'ipotesi di eteroschedasticità, o se possiamo escluderla. Si motivi la risposta.

Figura 1 — Residui vs. valori predetti. Grafico vettoriale prodotto da gretl, alla pagina 4 del testo d'esame; è riprodotto qui sotto dall'originale, e la sua lettura quantitativa fascia per fascia è riportata integralmente nello svolgimento.




Figura 1.6: Figura 1 del tema d'esame: «Residui vs. valori predetti». Riprodotta dall'originale.

Richiami teorici. L'ipotesi in discussione riguarda la varianza condizionale dell'errore. Si ha omoschedasticità quando essa è costante,

$$\text{Var}(\epsilon \mid X_1, \dots, X_k) = \sigma^2 \quad \text{per ogni } (X_1, \dots, X_k), \quad (1.28)$$

ed eteroschedasticità quando dipende dai regressori,

$$\text{Var}(\epsilon \mid X_1, \dots, X_k) = \sigma^2(X_1, \dots, X_k). \quad (1.29)$$

L'omoschedasticità non serve per la non distorsione e la consistenza di $\hat{\beta}_j$: serve per il teorema di Gauss-Markov, cioè per l'ottimalità di OLS nella classe degli stimatori lineari non distorti, e per la validità della formula usuale della varianza dello stimatore.

La diagnostica grafica prevista dal corso legge il grafico dei residui $\hat{e}$ contro i valori predetti $\hat{Y} = \mathbf{X}\hat{\beta}$ (ed eventualmente $\hat{e}^2$ contro ciascun regressore, dato che il residuo al quadrato è una proxy della varianza condizionale) secondo quattro firme:

- residui che rimbalzano casualmente attorno a 0: relazione lineare ragionevole;
- banda orizzontale uniforme attorno a 0 su tutto il campo di $\hat{Y}$: comportamento omoschedastico, coerente con la (1.28);
- dispersione che cambia a imbuto al variare di $\hat{Y}$: eteroschedasticità, cioè la (1.29);
- pochi residui molto lontani dagli altri: outlier.

Le conseguenze della violazione sono tre: (i) gli stimatori della deviazione standard dei coefficienti non sono consistenti, cioè approssimano male la vera deviazione standard; (ii) poiché $se(\hat{\beta}_j)$ è il denominatore della statistica t , i rapporti t diventano non affidabili; (iii) test di ipotesi e intervalli di confidenza sono fortemente influenzati dall'ipotesi sulla varianza condizionale, mentre $\hat{\beta}_j$ resta non distorto e consistente. Il rimedio è ricalcolare gli errori standard con lo stimatore robusto di White e rifare i test su quella base; per decidere formalmente servono invece il test di Breusch-Pagan (versione F o LM) o il test di White, e va ricordato che un test con H_0 di omoschedasticità non permette mai di *accettare* H_0 , ma al più di rifiutarla.

Impostazione. La domanda chiede due cose distinte: se dal grafico si possa dire qualcosa, e se si possa escludere l'eteroschedasticità. Vanno risposte entrambe, e con esiti opposti: il grafico dice molto, ma non permette di escludere nulla, perché è una diagnostica e non un test.

Svolgimento. Che cosa mostra la **Figura 1**, riprodotta qui sopra (p. 4 del testo, $\hat{e}$ in ordinata fra -1 e $0,8$, $\hat{y}$ in ascissa fra $10,9$ e $13,1$):

1. La nube non è una nube, sono grappoli. I punti si addensano in blocchi verticali separati da vuoti netti, in particolare attorno a $\hat{y} \approx 11,9, 12,4, 12,65$ e $13,0$. È l'impronta delle quattro dummy di zona: ciascuna zona ha la propria intercetta, e i valori predetti si raccolgono in quattro bande.

2. L'escursione dei residui cambia moltissimo da banda a banda. Misurando l'escursione (massimo meno minimo) su ciascuna fascia di valori predetti:

fascia di $\hat{y}$	residuo minimo	residuo massimo	escursione
10,85–11,35	−0,27	+0,66	0,93
11,45–11,75	−0,72	+0,42	1,14
11,75–12,10	−0,81	+0,42	1,23
12,10–12,45	−0,25	+0,41	0,66
12,55–12,75	−0,11	+0,38	0,49
12,85–13,08	−0,26	+0,29	0,55

(valori letti a occhio sulla figura riprodotta sopra). L'escursione passa da circa 1,2 nella parte centrale-sinistra a circa 0,5 nella parte destra: si dimezza. La banda non è affatto uniforme.

3. L'imbuto è rovesciato. Il caso da manuale ha dispersione crescente con $\hat{y}$; qui la dispersione decresce. Non cambia nulla per la diagnosi: la condizione violata è la costanza della varianza condizionale postulata dalla (1.28), non il suo verso.

4. La distribuzione è asimmetrica dove è più dispersa. Nella fascia 11,75–12,10 i residui scendono fino a $-0,81$ ma non superano $+0,42$; la coda negativa è lunga il doppio di quella positiva. Nelle fasce a destra l'asimmetria sparisce.

5. Ci sono outlier isolati. Due punti a sinistra, attorno a $\hat{y} \approx 10,9$ e $11,3$, con residui $+0,66$ e $+0,59$, e alcuni punti a $-0,6/-0,8$ nella fascia centrale.

6. Non c'è curvatura. I residui restano centrati attorno allo zero su tutto il campo di $\hat{y}$: non si vede la “U” o la “gobba” che segnalerebbe una forma funzionale sbagliata. La parte sistematica del modello sembra ragionevole; è la varianza a non esserlo.




Figura 1.7: Domanda 6. A sinistra l'escursione dei residui per fascia di valori predetti, letta a occhio sulla Figura 1 del tema, riprodotta sopra (p. 4): l'ampiezza passa da circa 1,2 nella parte centrale a circa 0,5 a destra. A destra, per confronto, come apparirebbe una nube genuinamente omoschedastica con la stessa numerosità: una banda di larghezza costante (simulazione illustrativa, seme 20250121).

Lettura del grafico. Il confronto fra i due pannelli è la risposta in forma visiva: a destra la banda ha ovunque la stessa altezza, a sinistra i rettangoli si accorciano sistematicamente verso valori predetti alti. È la firma che il corso chiama “dispersione a imbuto”, qui percorsa in senso inverso.

Risposta. Sì, dal grafico possiamo dire qualcosa, e no, non possiamo escludere l'eteroschedasticità: al contrario, il grafico la suggerisce.

La nube non forma la banda orizzontale di larghezza costante che il corso indica come firma dell'omoschedasticità. La dispersione dei residui varia in modo sistematico con i valori predetti: per $\hat{y}$ compreso fra 11,75 e 12,10 i residui coprono un intervallo di circa 1,2 (da $-0,81$ a $+0,42$), mentre per $\hat{y}$ oltre 12,55 coprono appena 0,5. L'imbuto è rovesciato rispetto al caso da manuale, perché la varianza diminuisce al crescere del prezzo predetto anziché aumentare, ma l'ipotesi violata è la stessa: $\text{Var}(\epsilon | X)$ non è costante. Si notano inoltre una netta struttura a grappoli, imputabile alle quattro dummy di zona, una coda negativa più lunga di quella positiva nelle fasce a dispersione alta, e alcuni outlier isolati a sinistra.

Il grafico non può però escludere l'eteroschedasticità né dimostrarla: è una diagnostica esplorativa, non un test, e in ogni caso i test di omoschedasticità non permettono mai di *accettare* H_0 , ma solo eventualmente di rifiutarla. Per decidere formalmente servirebbero il test di Breusch-Pagan (versione F o LM) o il test di White, che il testo non riporta.

La rilevanza pratica è alta: se l'eteroschedasticità c'è, le stime $\hat{\beta}_1, \dots, \hat{\delta}_4$ restano non distorte e consistenti, ma gli errori standard riportati nell'output non lo sono, e con essi diventano inaffidabili tutte le inferenze delle Domande 1, 3, 4 e 5. Il rimedio previsto dal corso è ricalcolare gli errori standard con lo stimatore robusto di White e rifare i test su quella base.

Osservazione. Non si risponda “il grafico non mostra il classico imbuto crescente, quindi c'è omoschedasticità”: la firma da cercare è la non costanza della dispersione, in qualunque direzione. E non si scriva mai “il grafico esclude l'eteroschedasticità”: nessun grafico e nessun test possono farlo. Si eviti infine di attribuire i grappoli verticali a un problema: sono la conseguenza normale di avere quattro intercette discrete, non un sintomo di cattiva specificazione.

2 | Esercizio 2 — Prezzi delle case e investimenti immobiliari negli Stati Uniti

Testo d'esame — Esercizio 2. Sono state rilevate su base annuale le variabili aggregate relative all'indice dei prezzi delle case (**price**) ed il livello di investimenti immobiliari pro capite (**invpc**) dal 1947 al 1988 per gli Stati Uniti.

Lettura preliminare dei dati. Le due serie sono annuali e coprono il periodo 1947–1988, quindi $T = 42$ osservazioni. **price** è l'indice dei prezzi delle case e **invpc** il livello degli investimenti immobiliari pro capite; entrambe entrano nei modelli in logaritmo. Il testo dell'esame usa tre etichette per le stesse due grandezze: **invpc** nel testo delle domande, **pcinv** nella Domanda 7, **gprice** nella riga dell'output della Domanda 8 (dove il modello scritto è però $\log(\text{price})$) e **lprice** nei titoli della Figura 2. Sono residui di una sessione gretl: nel seguito si fa riferimento al modello scritto, non alle etichette. L'impianto dell'esercizio è la catena canonica del corso: radici unitarie sulle singole serie (Domanda 7) → relazione di lungo periodo e test di cointegrazione di Engle-Granger (Domanda 8) → modello a correzione dell'errore (Domanda 9) → identificazione di un $\text{AR}(p)$ o di un $\text{MA}(q)$ dal correlogramma (Domanda 10).

2.1. Domanda 7 — Le due serie sono non stazionarie? (3 punti)

Testo della domanda. Domanda 7 (3 punti). Opportuni test di radice unitaria per le variabili forniscono i seguenti valori ed i p-value (in parentesi), $-3,3283$ (0,001) e $-3,7029$ (0,022), rispettivamente per le variabili $\log(\text{pcinv})$ e $\log(\text{price})$. Si decida se le due serie storiche hanno un comportamento non stazionario, motivandone la risposta.

Richiami teorici. Il punto di partenza è l' $\text{AR}(1)$ $Y_t = \beta_0 + \beta_1 Y_{t-1} + \epsilon_t$, riparametrizzato sottraendo Y_{t-1} da entrambi i membri:

$$\Delta Y_t = \beta_0 + \delta Y_{t-1} + \epsilon_t, \quad \delta = \beta_1 - 1.$$

Il test aumentato di Dickey-Fuller (ADF) è la stessa idea applicata a un $\text{AR}(p)$: si stima la regressione aumentata con i ritardi delle differenze prime,

$$\Delta Y_t = \beta_0^* + \delta Y_{t-1} + \beta_1^* \Delta Y_{t-1} + \dots + \beta_{p-1}^* \Delta Y_{t-p+1} + \epsilon_t, \quad \delta = \beta_1 - 1,$$

e si costruisce il rapporto t sul coefficiente di Y_{t-1} ,

$$t = \frac{\hat{\delta}}{\hat{\sigma}_{\hat{\delta}}}. \quad (2.1)$$

I termini ΔY_{t-j} sono la parte *augmented*: se omessi introdurrebbero autocorrelazione nell'errore, rendendo la distribuzione asintotica non trattabile. Il sistema di ipotesi è

$$\begin{aligned} H_0 : \delta &= 0 \quad (\text{radice unitaria, serie non stazionaria}), \\ H_1 : \delta &< 0 \quad (\text{serie stazionaria}). \end{aligned} \quad (2.2)$$

Due avvertenze contano. La prima: il test è unilaterale sinistro e la distribuzione di (2.1) sotto H_0 è quella di Dickey-Fuller, non una normale standard: spostata a sinistra e più larga, impone tavole simulate e mai $\pm 1,96$. I soli valori critici numerici al 5% forniti dal corso sono $-1,95$ per la versione senza deterministica ($\beta_0 = 0$) e $-2,85$ per quella con costante ($\beta_0 \neq 0$); la versione con trend lineare non è tabulata nelle note. Per confronto, una $N(0,1)$ darebbe $-1,64$. La seconda: rifiutare H_0 significa stazionarietà, cioè assenza di radice unitaria; non rifiutare significa radice unitaria, e allora la serie va differenziata.

Punto decisivo per questa domanda: la distribuzione sotto H_0 dipende dalla componente deterministica inclusa nella regressione. Partendo dalla decomposizione $Y_t = TD_t + Y_t^*$ con $Y_t^* = \alpha Y_{t-1}^* + \epsilon_t$, si ha

$$\begin{aligned} TD_t = \kappa : \quad Y_t &= \kappa(1 - \alpha) + \alpha Y_{t-1} + \epsilon_t, \\ TD_t = \kappa + \varrho t : \quad Y_t &= \kappa(1 - \alpha) + \varrho \alpha + \varrho(1 - \alpha)t + \alpha Y_{t-1} + \epsilon_t, \end{aligned} \quad (2.3)$$

cosicché sotto $H_0 : \alpha = 1$ il primo caso è un random walk senza costante e il secondo un random walk con drift. Aggiungere il trend deterministico cambia ulteriormente la distribuzione asintotica, e sbagliare la specificazione della deterministica invalida i valori critici e quindi la conclusione del test. La regola approssimativa del corso è: se la serie non evidenzia un andamento tendenziale netto si usa la versione con la sola costante; se evidenzia un andamento tendenziale lineare si usa la versione con costante e trend.

Impostazione. La decisione è meccanica: si confrontano i p-value con 0,05. Ma il testo nasconde un'incoerenza apparente che va vista e spiegata: la statistica più negativa ha il p-value più grande. Poiché il p-value di un ADF è una funzione monotona decrescente della statistica, questo è impossibile *a parità di specificazione*: i due test non usano la stessa deterministica.

Svolgimento. 1. Le due decisioni, con i p-value dichiarati.

serie	statistica ADF	p-value	confronto con 0,05	decisione su H_0
log(pcinv)	-3,3283	0,001	$0,001 < 0,05$	si rifiuta
log(price)	-3,7029	0,022	$0,022 < 0,05$	si rifiuta

Rifiutare H_0 in (2.2) significa assenza di radice unitaria: entrambe le serie risultano stazionarie.

2. Controllo con i valori critici delle note. Entrambe le statistiche sono più negative sia di $-1,95$ (senza deterministica) sia di $-2,85$ (con costante):

$$\begin{aligned} -3,3283 &< -2,85 < -1,95, \\ -3,7029 &< -2,85 < -1,95, \end{aligned}$$

e sotto queste due specificazioni la stessa conclusione si raggiunge per confronto diretto, senza usare i p-value.

Il confronto non si estende però alla terza specificazione. Attenzione alle basi: $-1,95$ e $-2,85$ sono i critici asintotici enunciati nei richiami teorici, mentre il critico con costante e trend va preso a campione finito, $-3,52$ per $T = 42$ (asintotico $-3,41$). Ora $-3,7029 < -3,52$, ma $-3,3283 > -3,52$: sotto “costante + trend” log(pcinv) non rifiuterebbe. È il punto ripreso al passo 4.

3. La corrispondenza fra statistiche e p-value sembra invertita. Con la stessa specificazione e lo stesso T , $-3,7029$ dovrebbe dare un p-value minore di $-3,3283$, non maggiore. Verifichiamo le tre specificazioni possibili con le tavole asintotiche di MacKinnon (la superficie di risposta di MacKinnon non dipende da T : i p-value qui sotto sono asintotici):

statistica	senza deterministica	con costante	costante + trend
-3,3283	0,0009	0,0137	0,0617
-3,7029	0,0002	0,0041	0,0222

I due p-value dichiarati dal testo, 0,001 e 0,022, sono riprodotti esattamente dalle due caselle in grassetto. La corrispondenza non è invertita: i due test usano semplicemente deterministiche diverse (nessuna per log(pcinv), costante e trend per log(price)), e la distribuzione sotto H_0 , quindi il p-value, cambia con la specificazione, come dice la (2.3).

4. La conclusione è robusta? Per log(price) sì: la statistica $-3,7029$ porta a rifiutare sotto tutte e tre le specificazioni (0,0002, 0,0041, 0,0222). Per log(pcinv) no: con costante e trend il p-value salirebbe a $0,0617 > 0,05$ e non si rifiuterebbe più. La conclusione su questa serie dipende interamente da una scelta di specificazione, e la scelta “senza alcuna deterministica” è la meno difendibile delle tre per una serie di investimenti pro capite, che nel dopoguerra ha chiaramente un andamento tendenziale: la regola del corso prescrive la versione con costante, e con trend lineare se un andamento tendenziale è visibile.




Figura 2.1: Domanda 7. In alto le due statistiche ADF sulla retta reale, con i valori critici al 5% delle tre specificazioni deterministiche ($-1,95$ e $-2,85$ asintotici, gli unici tabulati nel corso; $-3,52$ a campione finito per $T = 42$): entrambe cadono a sinistra dei primi due, ma solo $-3,7029$ supera anche il critico “cost. + trend”: $-3,3283$ resta alla sua destra e sotto quella specificazione non rifiuta. In basso i p-value asintotici che ciascuna specificazione assegnerebbe alle due statistiche: le due caselle evidenziate riproducono i p-value dichiarati dal testo, che vengono dunque da due deterministiche diverse.

Lettura del grafico. Il pannello (a) va letto come la prima evidenza della fragilità di $\log(\text{pcinv})$, non come una conferma che la decisione sia fuori discussione. Entrambe le statistiche cadono a sinistra dei critici “senza deterministica” ($-1,95$) e “con costante” ($-2,85$), e sotto quelle due specificazioni rifiutano entrambe; ma solo $\log(\text{price})$, con $-3,7029$, cade a sinistra anche del critico “cost. + trend” ($-3,52$). Il punto di $\log(\text{pcinv})$, $-3,3283$, resta alla destra di quest’ultimo: sotto la specificazione con trend quella serie non rifiuta la radice unitaria. Il pannello (b) misura la stessa cosa in scala di p-value e spiega insieme l’apparente anomalia: la barra di $\log(\text{pcinv})$ sotto “cost. + trend” supera la linea del 5% ($p = 0,0617$), cioè quella stessa statistica, letta con la deterministica più naturale per una serie tendenziale, non rifiuterebbe affatto. È la fragilità discussa al punto 4, e su di essa poggiano le Domande 8 e 10.

Risposta. Sulla base dei p-value dichiarati, no: nessuna delle due serie mostra un comportamento non stazionario. L'ipotesi nulla del test ADF è la presenza di una radice unitaria; il test è unilaterale sinistro e si rifiuta quando il p-value è inferiore al livello di significatività. Qui $0,001 < 0,05$ per $\log(\text{pcinv})$ e $0,022 < 0,05$ per $\log(\text{price})$: si rifiuta H_0 in entrambi i casi, dunque entrambe le serie risultano stazionarie, cioè integrate di ordine zero. La stessa conclusione si ottiene confrontando le statistiche $-3,3283$ e $-3,7029$ con i valori critici delle note, $-1,95$ senza deterministica e $-2,85$ con costante: entrambe li superano ampiamente verso sinistra.

Sull'apparente inversione fra statistiche e p-value. La coppia $(-3,3283; 0,001)$ e $(-3,7029; 0,022)$ sembra invertita, perché a parità di specificazione un valore più negativo deve dare un p-value più piccolo. Non è un errore del testo: i due p-value sono riprodotti esattamente dalle tavole asintotiche di MacKinnon se il primo test è condotto senza deterministica ($p = 0,0009$) e il secondo con costante e trend ($p = 0,0222$). La distribuzione sotto H_0 dipende dalla deterministica inclusa, quindi la monotonia vale dentro una specificazione, non fra specificazioni diverse.

Riserva da mettere agli atti. La stazionarietà di $\log(\text{pcinv})$ non è robusta: con costante e trend, la scelta che il corso prescrive per una serie con andamento tendenziale, la stessa statistica darebbe $p = 0,0617$ e non si rifiuterebbe la radice unitaria. La conclusione qui adottata è quella imposta dai p-value dichiarati, ma è appoggiata alla specificazione più fragile delle tre, ed entra in contrasto con quanto mostrano le Domande 8 e 10.

Osservazione. L'errore più costoso è invertire il senso del rifiuto: rifiutare in un ADF significa stazionarietà, non radice unitaria. Il secondo errore è confrontare queste statistiche con $\pm 1,96$: sotto H_0 la distribuzione è quella di Dickey-Fuller, spostata a sinistra e più larga della normale, e $1,96$ porterebbe a rifiutare troppo spesso la non stazionarietà. Il terzo è dimenticare che il test è a una coda sola, quella sinistra.

2.2. Domanda 8 — Engle-Granger: si può parlare di cointegrazione? (4 punti)

Testo della domanda. Domanda 8 (4 punti). La stima della regressione

$$\log(\text{invpc}_t) = \alpha + \beta \log(\text{price}_t) + \epsilon_t \quad (2.4)$$

è riportata di seguito:

Testo d'esame — Stime OLS della Domanda 8.

	coefficiente	errore std.	rapporto t	p-value
const	-0,853255	0,0402911	-21,18	1,22e-22
gprice	3,87863	0,957999	4,049	0,0002

Il test di Engle-Granger sui residui fornisce un p-value del 2,67%. Si dica, ad un livello di significatività del 5%, se si può parlare di relazione di cointegrazione e si motivi la risposta.

La riga `gprice` dell'output corrisponde al regressore $\log(\text{price}_t)$ del modello (2.4) scritto nel testo; la variabile dipendente è $\log(\text{invpc})$.

Richiami teorici. Definizione. X e Y si dicono cointegrate se esiste una loro opportuna combinazione lineare che è stazionaria. Partendo da $\epsilon_t = \beta_1 Y_t - \beta_2 X_t$ e normalizzando rispetto a β_1 ,

$$\epsilon_t = \beta_1 Y_t - \beta_2 X_t \propto Y_t - \beta X_t \quad \text{stazionaria,} \quad \beta \equiv \frac{\beta_2}{\beta_1}. \quad (2.5)$$

L'interpretazione è che le serie sono singolarmente integrate, cioè non stazionarie, ma vagano attorno a un unico trend stocastico: la combinazione (2.5) è la relazione stabile nel tempo, o di lungo periodo, e ϵ_t misura lo scostamento dall'equilibrio al tempo t .

Procedura in tre passi, lo scheletro della risposta d'esame:

1. verificare che le singole serie siano non stazionarie con un ADF: in questo passo non si deve rifiutare H_0 ;
2. stimare via OLS la relazione di lungo periodo $Y_t = a + bX_t + \epsilon_t$;
3. verificare che i residui $\hat{\epsilon}_t$ siano stazionari con un test di tipo ADF (test CDF di Engle-Granger): in questo passo si deve rifiutare H_0 .

La cointegrazione richiede entrambe le condizioni: se il Passo 1 fallisce, il Passo 3 non certifica nulla.

Test di Engle-Granger. È un test di radice unitaria condotto sui residui stimati della relazione di lungo periodo. Il sistema di ipotesi è

$$\begin{aligned} H_0 : \hat{\epsilon}_t \text{ ha radice unitaria} &\Rightarrow \text{nessuna cointegrazione (relazione spuria),} \\ H_1 : \hat{\epsilon}_t \text{ stazionaria} &\Rightarrow \text{cointegrazione,} \end{aligned} \quad (2.6)$$

la statistica è $\tau_c(\cdot)$, cioè il rapporto t sul coefficiente del residuo ritardato nella regressione ADF sui residui (il pedice c indica la specificazione con costante, l'argomento il numero di variabili nella relazione di cointegrazione, qui 2). La distribuzione sotto H_0 è non standard, diversa da quella dei test di radice unitaria classici, e cambia a seconda che la relazione di lungo periodo contenga o no l'intercetta; i valori critici numerici non sono tabulati nelle note, quindi la regola operativa è rifiutare H_0 se il p-value asintotico riportato dal software è minore di α .

Inferenza nella regressione in livelli. Se le serie sono cointegrate, lo stimatore OLS di β nella (2.4) è superconsistente: $(\hat{\beta} - \beta) \xrightarrow{p} 0$ più rapidamente che nel caso di variabili stazionarie, e la stima puntuale si può usare. La distribuzione asintotica di $\hat{\beta}$ non è però gaussiana e la statistica t non si distribuisce come una normale standard: l'inferenza OLS in livelli non si fa. Per testare β o costruirne un intervallo servirebbe lo stimatore DOLS, che aggiunge alla (2.4) un numero di ritardi e di anticipi di ΔX_t ,

$$Y_t = \beta_0 + \beta_1 X_t + \sum_{j=-\ell_T}^{\ell_T} \gamma_j \Delta X_{t+j} + \epsilon_t^*, \quad (2.7)$$

con errori standard HAC (Newey-West), robusti ad autocorrelazione ed eteroschedasticità: solo con quella correzione la t su β_1 torna a distribuirsi come una $N(0,1)$. I regressori aggiunti nella (2.7) hanno scopo puramente tecnico e non si interpretano.

Impostazione. La domanda non si risolve guardando il solo 2,67%. La cointegrazione è una proprietà definita per serie integrate: se le serie sono già stazionarie, ogni loro combinazione lineare lo è automaticamente, e un test che rifiuta la radice unitaria nei residui non sta scoprendo nulla. Bisogna quindi riprendere il Passo 1, cioè il risultato della Domanda 7, e verificare se la premessa regge.

Svolgimento. 1. Coerenza interna dell'output.

$$t_{\text{const}} = \frac{-0,853255}{0,0402911} = -21,18 \quad \checkmark,$$

$$t_{\text{slope}} = \frac{3,87863}{0,957999} = 4,049 \quad \checkmark.$$

2. Lettura del coefficiente di lungo periodo. Entrambe le variabili sono in logaritmo: per la (1.14), $\hat{\beta} = 3,87863$ è l'elasticità di lungo periodo degli investimenti immobiliari pro capite rispetto all'indice dei prezzi delle case. Un aumento dell'1% dei prezzi si accompagna, nel lungo periodo, a un aumento di circa il 3,88% degli investimenti: un'elasticità molto maggiore di uno, plausibile per una variabile di investimento, che reagisce ai segnali di prezzo in modo amplificato.

3. Il Passo 3, preso da solo. Con il sistema (2.6) e $p\text{-value} = 0,0267 < 0,05$: si rifiuta H_0 al 5%. Si noti però che $0,0267 > 0,01$: all'1% non si rifiuterebbe. L'evidenza esiste ma non è robusta al livello di significatività.

4. Il Passo 1, però, è fallito. La Domanda 7 ha rifiutato la radice unitaria per entrambe le serie, con $p\text{-value}$ 0,001 e 0,022. Il Passo 1 richiede l'esatto contrario: non si deve rifiutare. La condizione necessaria non è soddisfatta e la procedura si ferma prima di arrivare al Passo 3.

5. Perché il 2,67% allora non aggiunge nulla. Se $\log(\text{invpc})$ e $\log(\text{price})$ sono entrambe $I(0)$, allora per qualunque coppia di costanti (a, b) la combinazione

$$\log(\text{invpc}_t) - a - b \log(\text{price}_t)$$

è stazionaria per costruzione, come differenza di serie stazionarie. Il test di Engle-Granger tende quindi a rifiutare, asintoticamente con probabilità 1, e il suo rifiuto non è evidenza di un trend stocastico comune: è la constatazione tautologica che una combinazione di serie stazionarie è stazionaria. “Tende a”, non “deve”: un test resta un evento aleatorio e con $T = 42$ la potenza è ben lontana da uno. Anzi, la marginalità del 2,67% è essa stessa un indizio contro questa

lettura: se le due serie fossero davvero $I(0)$, il Passo 3 dovrebbe rifiutare in modo schiacciante, non con un p-value che all'1% non rifiuterebbe.

6. Le due letture coerenti dell'esercizio.


	lettura A: serie $I(0)$	lettura B: serie $I(1)$
fonte	p-value dichiarati in D7	Figura 2 (D10) e ADF con costante/trend
cointegrazione	non definita, il test è tautologico	sì, Engle-Granger rifiuta al 5%
$\hat{\beta} = 3,879$	stima OLS ordinaria	stima superconsistente
$t = 4,049$ in livelli	utilizzabile	non utilizzabile, serve DOLS+HAC
ECM della D9	riparametrizzazione ADL(1,1) lecita ma non necessaria	modello appropriato , secondo passo della stima
coerenza con $\hat{\lambda} = -0,503$ significativo	debole	piena

Lettura del grafico. Il pannello (a) mette in fila i tre passi e mostra dove la catena si spezza: il riquadro del Passo 1 dice “si rifiuta” dove la procedura esige “non si rifiuta”. Il pannello (b) aggiunge la seconda riserva: il rombo cade appena a sinistra della soglia del 5% ma nettamente a destra di quella dell'1%, cioè in una zona di evidenza debole.

Risposta. No: al 5% non si può parlare di cointegrazione. È questa la risposta che si consegna, e vale presi alla lettera i risultati dichiarati nella Domanda 7; il 2,67% non la cambia. Il test di Engle-Granger, preso in isolamento, rifiuta: con H_0 di radice unitaria nei residui e p-value $2,67\% < 5\%$ si conclude che i residui della relazione di lungo periodo sono stazionari. Ma la cointegrazione, nella procedura del corso, richiede entrambe le condizioni: al Passo 1 le singole serie devono risultare non stazionarie, e alla Domanda 7 abbiamo rifiutato la radice unitaria per tutte e due. Se $\log(\text{invpc})$ e $\log(\text{price})$ sono già $I(0)$, allora ogni loro combinazione lineare è stazionaria per costruzione: il rifiuto del Passo 3 è automatico e non testimonia alcun trend stocastico comune. La nozione stessa di cointegrazione, cioè serie singolarmente non stazionarie che vagano attorno a un unico trend stocastico come nella (2.5), non è applicabile a serie stazionarie.

Lettura alternativa, da tenere come riserva. Vale *solo* se si accetta che la Domanda 7 adotti per $\log(\text{pcinv})$ la specificazione ADF sbagliata. Non è la risposta consegnata sopra, ma va messa agli atti perché è l'unica che rende coerente l'intero esercizio. Le Domande 7, 8, 9 e 10 non possono essere tutte vere insieme. La Domanda 10 mostra un correlogramma con otto ritardi fuori banda e un unico picco della PACF pari a 0,89, cioè la firma tipica della non stazionarietà; la Domanda 9 stima un ECM il cui coefficiente di correzione $\hat{\lambda} = -0,503$ è fortemente significativo, il che ha senso pieno solo se esiste davvero un equilibrio di lungo periodo da cui allontanarsi; e la Domanda 8 costruisce l'intero apparato della cointegrazione. Tutto questo presuppone serie $I(1)$. La Domanda 7 lo nega, e lo nega appoggiandosi, per $\log(\text{pcinv})$, alla specificazione ADF senza alcuna deterministica, che per una serie chiaramente tendenziale è la scelta meno difendibile: con costante e trend lo stesso valore $-3,3283$ darebbe $p = 0,0617$ e non rifiuterebbe. Su questa

(a) la procedura del corso in tre passi



(b) evidenza al 5%, ma non robusta all'1%




Figura 2.2: Domanda 8. In alto la procedura in tre passi del corso con l'esito di ciascuno: il Passo 1 fallisce perché la Domanda 7 rifiuta la radice unitaria su entrambe le serie, e il rifiuto del Passo 3 non può quindi certificare alcuna cointegrazione. In basso la collocazione del p-value di Engle-Granger, 2,67%, fra la soglia dell'1% e quella del 5%.

lettura alternativa, con serie $I(1)$ e cointegrate al 5%, il 2,67% acquisterebbe pieno significato: certificherebbe il trend stocastico comune, renderebbe $\hat{\beta} = 3,879$ una stima superconsistente dell'elasticità di lungo periodo e legittimerebbe l'ECM della Domanda 9. Resta una riserva, non la risposta: per adottarla bisogna dichiarare apertamente di correggere la Domanda 7, e anche così l'evidenza non sarebbe robusta, perché al livello dell'1% il test di Engle-Granger non rifiuterebbe.

Un'avvertenza che vale in ogni caso. Se le serie sono cointegrate, il rapporto $t = 4,049$ della regressione in livelli non va usato per inferenza: sotto cointegrazione la distribuzione di $\hat{\beta}$ non è gaussiana e la t non è una normale standard. La stima puntuale si usa, il test no; per fare inferenza sul parametro di lungo periodo servirebbe il DOLS (2.7) con errori standard HAC.

Osservazione. L'errore tipico è rispondere “p-value 2,67% < 5%, dunque c'è cointegrazione” e fermarsi lì: il punto della domanda, che vale quattro punti, è proprio la coerenza con il Passo 1. Un secondo errore è concludere “nessuna cointegrazione” perché il test fallisce: il test non

fallisce affatto, è la premessa a mancare, e la distinzione va scritta. Infine, non si confonda la cointegrazione con una correlazione elevata: un R^2 alto fra due serie non stazionarie è il sintomo della regressione spuria, non la prova di una relazione di lungo periodo.

2.3. Domanda 9 — L'ECM è ben definito? In quanti periodi si assorbe il 75%? (3 punti)

Testo della domanda. Domanda 9 (3 punti). Il seguente modello a correzione dell'errore è

$$\Delta \log(\text{invpc}_t) = \gamma_0 + \gamma_1 \Delta \log(\text{price}_t) + \lambda \text{ecm}_{t-1} + \epsilon_t$$

in cui $\text{ecm}_{t-1} = \log(\text{invpc}_{t-1}) - \hat{\alpha} - \hat{\beta} \log(\text{price}_{t-1})$, mentre $D\text{price} = \Delta \log(\text{price}_t)$ e $D\text{invpc} = \Delta \log(\text{invpc}_t)$. Le stime sono riportate di seguito:

Testo d'esame — Stime OLS della Domanda 9. Variabile dipendente: $D\text{invpc}$

	coefficiente	errore std.	rapporto t	p-value	
const	-0,00183076	0,0198986	-0,09200	0,9272	
Dprice	2,99909	1,05267	2,849	0,0070	***
ecm_1	-0,503193	0,137202	-3,668	0,0007	***

Si dica se il modello risulta ben definito. In quanti periodi possiamo attenderci un assorbimento di uno shock di circa il 75%?

Richiami teorici. Nel modello a correzione dell'errore

$$\Delta Y_t = \beta_0 \Delta X_t + \alpha_y (Y_{t-1} - a - bX_{t-1}) + \epsilon_t \quad (2.8)$$

il termine fra parentesi è il residuo ritardato della relazione di cointegrazione, cioè lo scostamento dall'equilibrio di lungo periodo in $t-1$, e α_y è il coefficiente di aggiustamento, con segno atteso $\alpha_y < 0$: soltanto con segno negativo il meccanismo corregge il disequilibrio anziché amplificarlo. Tutti i regressori della (2.8) sono stazionari (differenze prime più il residuo di cointegrazione, stazionario per definizione se le serie cointegrano), quindi l'inferenza OLS usuale è applicabile e il rapporto t dell'output si legge normalmente: su $H_0 : \alpha_y = 0$ (nessuna correzione dell'errore) si rifiuta se il p-value è minore di α .

Per l'orizzonte di assorbimento serve la legge di evoluzione del disequilibrio. Sotto le ipotesi della domanda tipo (X costante, $\Delta X_t = 0$; shock futuri nulli, $\epsilon_t = 0$; nessun drift), posto $z_t = Y_t - a - bX_t$ e scrivendo $Y_t = Y_{t-1} + \lambda z_{t-1}$ dalla (2.8), e usando $Y_t = Y_{t-1} + \lambda z_{t-1}$, si ottiene

$$\begin{aligned} z_t &= (Y_{t-1} + \lambda z_{t-1}) - a - bX_{t-1} = z_{t-1} + \lambda z_{t-1} = (1 + \lambda) z_{t-1}, \\ z_{t+h} &= (1 + \lambda)^h z_t \quad (h = 0, 1, 2, \dots). \end{aligned} \quad (2.9)$$

Anche questa regola operativa non è enunciata a lezione nella forma che serve alla domanda: le note derivano il sentiero $\Delta Y_{t+j} = \alpha_y(1 + \alpha_y)^j(Y_{t+j-1} - bX_{t+j-1})$ ma non l'orizzonte h^* . Si ricava dalla (2.9) in due righe. La quota di disequilibrio ancora presente dopo h periodi è $(1 + \lambda)^h$, quella assorbita è $1 - (1 + \lambda)^h$; imponendo che l'assorbimento sia almeno pari a una quota s ,

$$\begin{aligned} (1 + \lambda)^h &\leq 1 - s, \\ h^* &= \left\lceil \frac{\ln(1 - s)}{\ln(1 + \lambda)} \right\rceil. \end{aligned} \quad (2.10)$$

Il verso della disuguaglianza non si inverte passando ai logaritmi perché $\ln(1 + \lambda) < 0$ per $-1 < \lambda < 0$: entrambi i logaritmi sono negativi e il loro rapporto è positivo. Tre controlli accompagnano sempre la (2.10): (i) h^* conta periodi interi, quindi si arrotonda per eccesso e si dichiara l'unità di tempo leggendola dalla frequenza dei dati; (ii) serve $-2 < \lambda < 0$ perché il sistema converga, e in particolare con $-1 < \lambda < 0$ il ritorno è monotono, mentre con $\lambda < -1$ è oscillante; (iii) il segno del disequilibrio determina la direzione della correzione: $z_{t-1} > 0$ con $\lambda < 0$ dà $\Delta Y_t < 0$, cioè la Y rallenta o scende, e $z_{t-1} < 0$ dà $\Delta Y_t > 0$.

Impostazione. “Ben definito” va sciolto in una lista di controlli: segno del coefficiente di correzione, sua collocazione nell'intervallo di convergenza, sua significatività, significatività dell'effetto di breve periodo, e coerenza della costante con la teoria. Solo dopo si calcola l'orizzonte con la (2.10).

Svolgimento. 1. Verifica dei rapporti t dell'output.

$$\begin{aligned} \frac{-0,00183076}{0,0198986} &= -0,0920 \quad \checkmark, \\ \frac{2,99909}{1,05267} &= 2,849 \quad \checkmark, \\ \frac{-0,503193}{0,137202} &= -3,668 \quad \checkmark. \end{aligned}$$

2. Segno del coefficiente di correzione. $\hat{\lambda} = -0,503193 < 0$: è il segno richiesto perché il meccanismo corregga anziché amplificare il disequilibrio.

3. Zona di convergenza.

$$1 + \hat{\lambda} = 1 - 0,503193 = 0,496807 \in (0,1),$$

quindi $-1 < \hat{\lambda} < 0$: il ritorno all'equilibrio è convergente e monotono, senza oscillazioni.

4. Significatività del meccanismo di correzione. Con $H_0 : \lambda = 0$ (nessuna correzione dell'errore) contro $H_1 : \lambda \neq 0$: $t = -3,668$, p-value $0,0007 < 0,05$. Si rifiuta: il meccanismo di correzione esiste. L'inferenza è legittima perché tutti i regressori dell'ECM sono stazionari.

5. Effetto di breve periodo. $\hat{\gamma}_1 = 2,99909$, $t = 2,849$, p-value $0,0070 < 0,05$: significativo. Poiché entrambe le variabili sono in differenze logaritmiche, si legge come elasticità di breve periodo: a un aumento dell'1% dei prezzi nell'anno corrisponde un aumento contemporaneo di circa il 3,0% degli investimenti pro capite.

6. Confronto breve/lungo periodo.

$$\frac{\hat{\gamma}_1}{\hat{\beta}} = \frac{2,99909}{3,87863} = 0,773.$$

L'impatto immediato è il 77% dell'effetto di lungo periodo: il restante 23% si realizza attraverso il termine di correzione negli anni successivi. È il profilo atteso di un aggiustamento parziale.

7. La costante. $\hat{\gamma}_0 = -0,00183076$, p-value $0,9272$: non significativa. È corretto che sia così, perché un'intercetta significativa nell'ECM implicherebbe un drift nella relazione di equilibrio, mentre il livello di lungo periodo è già catturato da $\hat{\alpha}$ dentro `ecm_1`.

8. Orizzonte di assorbimento del 75%. Dalla (2.10) con $s = 0,75$ e $1 + \hat{\lambda} = 0,496807$:

$$h^* = \left\lceil \frac{\ln(1 - 0,75)}{\ln(0,496807)} \right\rceil = \left\lceil \frac{\ln(0,25)}{\ln(0,496807)} \right\rceil = \left\lceil \frac{-1,3862944}{-0,6995537} \right\rceil = \lceil 1,9817 \rceil = 2. \quad (2.11)$$

9. Verifica diretta.

h	quota residua $(1 + \hat{\lambda})^h$	quota assorbita
1	0,496807	50,32%
2	0,246817	75,32%
3	0,122621	87,74%
4	0,060919	93,91%

Dopo un anno l'assorbimento è del 50,3%, insufficiente; dopo due anni è del 75,3%, appena oltre la soglia. Poiché i dati sono annuali (1947–1988), $h^* = 2$ significa due anni.

Lettura del grafico. Poiché $\hat{\lambda}$ è quasi $-0,5$, la curva dimezza il disequilibrio residuo a ogni anno: la prima stella cade a $h = 1$ appena sotto 0,50, la seconda a $h = 2$ appena sotto 0,25. Il 75% si raggiunge quindi con due dimezzamenti consecutivi, e la soluzione continua $h = 1,98$ della (2.11) è praticamente un intero, così la risposta non dipende dall'arrotondamento.

Risposta. Sì, il modello risulta ben definito. Il coefficiente di correzione dell'errore è $\hat{\lambda} = -0,503193$: ha il segno negativo richiesto dal meccanismo di correzione, cade nell'intervallo $-1 <$




Figura 2.3: Domanda 9. Profilo di assorbimento del disequilibrio: la quota ancora presente dopo h anni, $(1 + \hat{\lambda})^h = 0,496807^h$, con le stelle che segnalano gli orizzonti in cui si superano rispettivamente il 50% e il 75% di assorbimento.

$\hat{\lambda} < 0$ che garantisce un ritorno all'equilibrio convergente e monotono (poiché $1 + \hat{\lambda} = 0,4968$ è positivo e minore di uno, non si hanno oscillazioni), ed è fortemente significativo ($t = -3,668$, p-value 0,0007): esiste davvero una forza che riporta gli investimenti verso la relazione di lungo periodo con i prezzi. Anche l'effetto di breve periodo è significativo ($\hat{\gamma}_1 = 2,999$, p-value 0,0070) e la costante non lo è ($p = 0,9272$), come deve essere, dato che il livello di equilibrio è già dentro il termine `ecm_1`. Le elasticità sono coerenti fra loro: 2,999 nel breve contro 3,879 nel lungo, cioè il 77% dell'effetto totale si manifesta subito e il resto matura attraverso la correzione.

Uno shock si assorbe al 75% in due periodi, cioè in due anni. Con $\hat{\lambda} = -0,503193$ la quota di disequilibrio ancora presente dopo h periodi è $(1 + \hat{\lambda})^h = 0,496807^h$, e

$$h^* = \left\lceil \frac{\ln(0,25)}{\ln(0,496807)} \right\rceil = \lceil 1,98 \rceil = 2.$$

Dopo un anno si è riassorbito il 50,3% del disequilibrio, dopo due anni il 75,3%. Poiché il coefficiente è praticamente $-0,5$, ogni anno il disequilibrio residuo si dimezza: l'aggiustamento è rapido, molto più veloce di quello dei tassi di interesse USA usato come riferimento nelle note, dove $\hat{\alpha} = -0,0658$ implicherebbe decine di periodi per lo stesso risultato.

Riserve. Il testo non riporta né il test di Ljung-Box sui residui dell'ECM né alcun test di eteroschedasticità, che sarebbero necessari per dire il modello ben specificato anche sotto il

profilo diagnostico. E l'intero impianto presuppone la cointegrazione fra le due serie, la cui premessa è messa in discussione dalla Domanda 7 (si veda la discussione nella Domanda 8).

Osservazione. Non si confonda la quota assorbita con quella residua: la formula (2.10) richiede al numeratore $\ln(1-s) = \ln(0,25)$, non $\ln(0,75)$. Usando $\ln(0,75)$ si otterrebbe $h = 0,41 \rightarrow 1$ periodo, cioè la risposta sbagliata. Non si dimentichi l'arrotondamento per eccesso: h conta periodi interi. E si dichiara sempre l'unità di tempo leggendo dalla frequenza dei dati: qui i dati sono annuali, quindi due anni, non due trimestri.

2.4. Domanda 10 — ACF e PACF: stazionarietà e scelta fra AR e MA (3 punti)

Testo della domanda. Domanda 10 (3 punti). L'autocorrelogramma e l'autocorrelogramma parziale della variabile Δprice è rappresentata in Figura 2. Sulla base del grafico, si dica se la serie storica possa sembrare stazionaria, ed eventualmente si proponga un modello di tipo AR oppure MA per descriverla, motivandone la risposta.

Figura 2 — ACF e PACF della serie Δprice . Grafico vettoriale prodotto da gretl, alla pagina 7 del testo d'esame; è riprodotto qui sotto dall'originale, e i valori misurati ritardo per ritardo sono riportati integralmente nello svolgimento.

Richiami teorici. L'ACF descrive l'autocorrelazione ρ_j di una serie per ogni ritardo $j \geq 1$ e la sua rappresentazione grafica è il correlogramma; la PACF misura la dipendenza di Y_t da Y_{t-j} al netto dei valori intermedi $Y_{t-1}, \dots, Y_{t-j+1}$. Poiché $\sqrt{T} \hat{\rho}_j \rightarrow N(0,1)$ sotto $H_0 : \rho_j = 0$, le bande di significatività al 5% del correlogramma sono

$$\pm \frac{1,96}{\sqrt{T}}, \quad (2.12)$$

e si rifiuta $H_0 : \rho_j = 0$ quando $|\hat{\rho}_j| > 1,96/\sqrt{T}$, cioè quando la barra esce dalle bande tratteggiate.

Le firme tipiche che il corso usa per identificare il processo sono quattro:

- ACF significativa solo ai primi q ritardi, poi taglio netto $\Rightarrow$ MA(q); per un MA(q) l'ACF è infatti nulla oltre il ritardo q , ed è il "taglio" a identificarne l'ordine;
- ACF che decresce gradualmente e PACF con picchi solo ai primi p ritardi $\Rightarrow$ AR(p);
- ACF che resta elevata anche a ritardi alti con un solo picco PACF al ritardo 1 $\Rightarrow$ non stazionarietà (random walk);
- nessun valore significativo $\Rightarrow$ white noise.

La terza firma ha un fondamento preciso. Per un random walk $Y_t = Y_{t-1} + \epsilon_t$ con $Y_0 = 0$ si ha $Y_t = \sum_{j=1}^t \epsilon_j$ e quindi

$$\text{Var}(Y_t) = \text{Var}\left(\sum_{j=1}^t \epsilon_j\right) = t \sigma^2,$$




Figura 2.4: Figura 2 del tema d’esame: «ACF e PACF della serie Δprice ». Riprodotta dall’originale: è il dato di partenza, mentre il correlogramma ricostruito più avanti ne è la lettura commentata.

varianza che diverge con t : la serie non è stazionaria e le autocorrelazioni teoriche non sono nemmeno definite, ma quelle campionarie si calcolano e tendono a essere prossime a uno anche ad elevati ritardi. Inoltre, se una serie è davvero un random walk ma vi si adatta per errore un $\text{AR}(1)$, lo stimatore è consistente ma distorto verso il basso:

$$E[\hat{\beta}_1] = 1 - \frac{5,3}{T}, \quad (2.13)$$

con distribuzione asintotica non gaussiana e asimmetrica verso lo zero. La (2.13) è il modo quantitativo di leggere un picco PACF vicino a uno in un campione corto. Si ricordi infine che la significatività di $\hat{\beta}_1$ in un $\text{AR}(1)$ si valuta con la t dell’output, ma quella t è valida solo se la serie è stazionaria: la decisione spetta al test ADF, non al correlogramma.

Impostazione. La domanda chiede due cose in sequenza: prima un giudizio di stazionarietà, poi, “eventualmente”, una proposta di modello. Il secondo passo ha senso solo se il primo lo consente, e la risposta completa deve dire anche che cosa fare se non lo consente.

Svolgimento. 1. Che cosa mostra la Figura 2, riprodotta qui sopra (p. 7 del testo, due pannelli, 25 ritardi). Prima osservazione: i titoli gretl dei due pannelli sono “ACF di lprice” e

“PACF di $\ln \text{price}$ ”, non Δprice come recita il testo della domanda. $\ln \text{price}$ è il livello di $\log(\text{price})$: l’etichetta e il testo non concordano, e la cosa va segnalata.

2. Il campione, ricavato dalle bande. Le bande orizzontali sono disegnate a circa $\pm 0,30$; poiché per la (2.12) valgono $\pm 1,96/\sqrt{T}$,

$$T \approx \left(\frac{1,96}{0,30} \right)^2 = 42,7,$$

coerente con $T = 42$ osservazioni annuali dal 1947 al 1988, per cui $1,96/\sqrt{42} = 0,3024$. La figura conferma il campione dichiarato.

3. L’ACF, ritardo per ritardo (valori misurati sui pixel della figura riprodotta sopra, calibrando sulle bande $\pm 0,3024$):

ritardo	1	2	3	4	5	6	7	8
$\hat{\rho}_j$	0,89	0,81	0,70	0,63	0,56	0,49	0,42	0,33

ritardo	9	10	12	14	16	18	21	25
$\hat{\rho}_j$	0,25	0,18	0,06	−0,02	−0,13	−0,20	−0,28	−0,29

I primi otto ritardi escono dalla banda superiore (il nono, 0,25, è già dentro) e il decadimento è lento e quasi lineare. L’ACF attraversa lo zero attorno al ritardo 13-14 e passa in territorio negativo, avvicinandosi alla banda inferiore fra i ritardi 20 e 25 (il minimo è circa $-0,29$) senza mai superarla: nessuna barra esce dalla banda inferiore. I ritardi fuori banda sono dunque otto, tutti positivi.

4. La PACF. Un unico picco altissimo al ritardo 1, pari a circa 0,89; tutti gli altri ritardi restano ampiamente dentro le bande $\pm 0,3024$, con valori in modulo non superiori a circa 0,14 (i più grandi sono $-0,14$ ai ritardi 8 e 20). Il taglio dopo il primo ritardo è netto.

5. Confronto con l’AR(1) stazionario, fatto con il benchmark giusto. Il confronto da non fare è quello fra l’ACF *campionaria* osservata e l’ACF *teorica* $0,89^j$: sono due oggetti diversi, e il divario fra loro non dice nulla sulla stazionarietà. Con $T = 42$ l’ACF campionaria di un AR(1) genuinamente stazionario con $\phi = 0,89$ è già molto più bassa di $0,89^j$ e passa in negativo da sola: vale infatti l’identità

$$\sum_{j=1}^{T-1} \hat{\rho}_j = -\frac{1}{2}, \quad (2.14)$$

che obbliga la somma delle autocorrelazioni campionarie a essere negativa qualunque sia il processo. Il termine di paragone corretto è dunque il valore atteso dell’ACF campionaria a

$T = 42$:

ritardo	1	2	3	4	5	6	7	8
0,89 ^j teorico	0,890	0,792	0,705	0,627	0,558	0,497	0,442	0,394
atteso campionario, $T = 42$	0,77	0,58	0,42	0,30	0,20	0,12	0,05	0,00
osservato	0,89	0,81	0,70	0,63	0,56	0,49	0,42	0,33

Letto così il quadro si rovescia: i valori osservati stanno molto sopra quelli che un AR(1) stazionario con $\phi = 0,89$ produrrebbe in 42 osservazioni (0,63 contro 0,30 al ritardo 4, 0,33 contro 0,00 al ritardo 8), e otto di essi restano fuori banda. È questa persistenza in eccesso, non il passaggio in negativo della coda, a indicare la radice unitaria; il segno negativo ai ritardi alti va anzi scartato come indizio, perché per la (2.14) è il comportamento normale di una ACF campionaria corta.

6. La distorsione prevista dal corso. Se la serie è un random walk e vi si adatta un AR(1), la (2.13) prevede

$$E[\hat{\beta}_1] = 1 - \frac{5,3}{T} = 1 - \frac{5,3}{42} = 0,874.$$

Il valore osservato nella PACF al ritardo 1, circa 0,89, è in quest'ordine di grandezza: il picco compatibile con $\phi = 0,89$ è anche quello che ci si aspetterebbe da una vera radice unitaria stimata su 42 osservazioni.

7. Esclusione della famiglia MA. Un MA(q) ha ACF nulla oltre il ritardo q ; qui l'ACF resta significativa fino al ritardo 8 e non si annulla nettamente in alcun punto prima di cambiare segno. Non esiste alcun q finito ragionevole: la famiglia MA è esclusa.

Lettura del grafico. Le barre marcate segnalano i ritardi fuori banda: otto consecutivi nell'ACF, uno solo nella PACF. È la combinazione che il corso associa alla non stazionarietà, non a un processo stazionario a memoria corta. La curva tratteggiata è il profilo che ci si aspetterebbe dall'ACF campionaria di un AR(1) stazionario con $\phi = 0,89$ su 42 osservazioni: le barre osservate le stanno sopra per tutti i primi otto ritardi, con un distacco già ampio al ritardo 4. È quel distacco, non la coda negativa che la curva attesa riproduce da sé, a dire che la persistenza osservata è più vicina a una radice unitaria che a un coefficiente autoregressivo stabile.

Risposta. No, la serie non sembra stazionaria. L'ACF parte da 0,89 e decade in modo molto lento e quasi lineare, restando fuori dalle bande $\pm 0,3024$ per otto ritardi consecutivi, mentre la PACF presenta un solo picco, al ritardo 1, di ampiezza circa 0,89, con tutti gli altri valori dentro le bande. È la firma che il corso associa alla non stazionarietà: ACF che resta elevata anche a ritardi alti con un unico picco della PACF al primo ritardo. A conferma, il paragone va fatto con l'ACF campionaria attesa da un AR(1) stazionario con $\phi = 0,89$ su $T = 42$, non con l'ACF




Figura 2.5: Domanda 10. In alto l'ACF misurata sulla Figura 2 del tema, riprodotta sopra, con le bande $\pm 1,96/\sqrt{42} = \pm 0,3024$ e, sovrapposta, l'ACF campionaria attesa da un AR(1) stazionario con $\phi = 0,89$ a $T = 42$ (non l'ACF teorica $0,89^j$, che sarebbe il termine di paragone sbagliato): gli otto ritardi fuori banda stanno tutti nettamente sopra quell'attesa, ed è questa persistenza in eccesso a segnalare la radice unitaria. La coda negativa, che l'attesa campionaria riproduce da sé, resta dentro la banda inferiore. In basso la PACF, con l'unico picco al ritardo 1 e tutto il resto ampiamente dentro le bande. I valori sono misurati sui pixel dei pannelli gretl riprodotti sopra (p. 7), che restano il dato di partenza: questa è la loro lettura commentata.

teorica $0,89^j$, che è un altro oggetto: quell'attesa vale 0,77; 0,58; 0,42; 0,30; 0,20; 0,12; 0,05; 0,00 ai primi otto ritardi, mentre l'osservata vale 0,89; 0,81; 0,70; 0,63; 0,56; 0,49; 0,42; 0,33. È questa persistenza in eccesso a segnalare la radice unitaria. Il passaggio in negativo della coda non è invece informativo, perché lo fa da sé anche un AR(1) stazionario in un campione così corto, dove $\sum_j \hat{\rho}_j = -1/2$ per costruzione; e in ogni caso quella coda non esce mai dalla banda inferiore: il minimo osservato è circa $-0,29$, contro una soglia di $-0,3024$. Va aggiunto che il picco PACF di 0,89 coincide con la distorsione che il corso prevede quando si stima un AR(1) su un random walk: $E[\hat{\beta}_1] = 1 - 5,3/42 = 0,874$.

Se si deve proporre un modello, è un AR, non un MA, e precisamente un AR(1). La famiglia MA è esclusa perché l'ACF di un MA(q) si annulla nettamente oltre il ritardo q , mentre qui non si annulla in alcun punto prima del ritardo 13. La famiglia AR è invece compatibile: la PACF taglia dopo il primo ritardo, e l'ordine di un AR si identifica proprio sulla PACF. Il modello

proposto è dunque

$$Y_t = \beta_0 + \beta_1 Y_{t-1} + \epsilon_t, \quad \hat{\beta}_1 \approx 0,89,$$

con l'avvertenza che $\hat{\beta}_1$ così vicino a uno colloca il processo sul confine della stazionarietà e che la t su $\hat{\beta}_1$ è valida solo se la serie è stazionaria. La procedura corretta è quindi: applicare il test ADF e, se la radice unitaria non viene rifiutata come il correlogramma suggerisce, differenziare la serie e rifare l'ADF sulla serie differenziata.

Incoerenza da segnalare. I pannelli sono intitolati `lprice`, cioè il livello di $\log(\text{price})$, mentre la domanda parla di Δprice . Nella lettura letterale dell'etichetta la figura dice che $\log(\text{price})$ è non stazionaria, il che contraddice la Domanda 7, dove la stessa serie veniva dichiarata stazionaria con $p\text{-value } 0,022$. Nella lettura letterale del testo della domanda, la figura direbbe che $\Delta \log(\text{price})$ è già non stazionaria, e quindi che $\log(\text{price})$ sarebbe $I(2)$: una contraddizione con la Domanda 7 ancora più forte. In entrambi i casi la figura testimonia una radice unitaria. Il correlogramma è l'evidenza più diretta e meno dipendente da scelte di specificazione, ed è il principale sostegno della lettura alternativa tenuta come riserva nella Domanda 8, quella in cui le due serie sono $I(1)$ e cointegrate.

Osservazione. Non si legga il decadimento graduale dell'ACF come prova di un $\text{AR}(1)$ *stazionario*: la differenza fra un $\text{AR}(1)$ con $\phi = 0,9$ e un random walk sta tutta nella velocità del decadimento e nel numero di ritardi che escono dalle bande, ed è indecidibile a occhio con $T = 42$. Per questo esiste il test ADF, che non va sostituito dalla lettura del correlogramma. Si eviti anche di proporre un $\text{MA}(8)$ “perché ci sono otto ritardi significativi”: in un $\text{MA}(q)$ l'ACF deve tagliare oltre q , e qui non taglia, prosegue in negativo. Infine, non si annunci un $\text{ARMA}(p, q)$ misto: la PACF con un solo picco e l'ACF a decadimento monotono indicano una struttura puramente autoregressiva, e il corso chiede esplicitamente di scegliere fra AR e MA.