Università Ca' Foscari Venezia

Dipartimento di Economia

Laurea Magistrale in
Economia e Finanza

Modulo 01 — Introduzione e causalità

Esercizi di preparazione

Appunti di:
Silvio Angelo Baratto Roldan

Codice insegnamento:
EM0004

Contenuto:
6 esercizi

Esercizi sintetici costruiti a fini di studio sul modello dei veri appelli e sulla teoria del corso (Econometria EM0004, prof. Davide Raggi). Non sono materiale ufficiale del docente.

Indice

1 Esercizio 1 — Palestra aziendale e assenze per malattia *(livello base)* 1

2 Esercizio 2 — Che tipo di dati sono? *(livello base)* 2

3 Esercizio 3 — Polizia e criminalità *(livello intermedio)* 4

4 Esercizio 4 — La spesa riportata male *(livello intermedio)* 5

5 Esercizio 5 — Gelati e incidenti in acqua *(livello d'appello)* 7

6 Esercizio 6 — Un fondo e il CAPM *(livello d'appello)* 9

1 | Esercizio 1 — Palestra aziendale e assenze per malattia *(livello base)*

Dati. In un'azienda con $n = 1096$ dipendenti si è rilevato, in un solo momento, se ciascuno è iscritto alla palestra aziendale e se nell'ultimo anno ha fatto almeno un'assenza per malattia. Non si sa quando i dipendenti si siano iscritti. Si può parlare di causalità $X \to Y$ solo se valgono contemporaneamente tre criteri: (1) c'è associazione fra le variabili; (2) c'è un ordine logico o temporale, con la causa che precede l'effetto; (3) sono escluse le spiegazioni alternative. I conteggi sono i seguenti.

	assenza: sì	assenza: no	totale
iscritti	75	342	417
non iscritti	232	447	679
totale	307	789	1096

Testo della domanda. **Domanda 1** ***(3 punti).*** **(a)** Quale percentuale degli iscritti ha fatto almeno un'assenza? **(b)** Quale percentuale dei non iscritti? **(c)** Si calcoli la differenza «percentuale degli iscritti meno percentuale dei non iscritti», in punti percentuali. **(d)** Il criterio (1), l'associazione, è soddisfatto, giudicando dal solo confronto delle due percentuali (senza test statistico)? Si risponda sì o no. **(e)** I dati permettono di stabilire che l'iscrizione precede le assenze, cioè che il criterio (2) è soddisfatto? Si risponda sì o no. **(f)** Si può concludere che l'iscrizione alla palestra riduce le assenze per malattia? Si risponda sì o no.

2 | Esercizio 2 — Che tipo di dati sono? *(livello base)*

Dati. I dati si dicono *cross section* se osservano molti soggetti in un solo istante, *serie storica* se osservano un solo soggetto in istanti successivi, *panel* se osservano gli stessi soggetti in più istanti. Quattro insiemi di dati sono riportati con una riga per ogni coppia soggetto-periodo.

Dataset A, fatturato di alcune imprese (milioni di euro):

soggetto	periodo	fatturato
impresa 1	2023	24,2
impresa 2	2023	37,7
impresa 3	2023	4,1
impresa 4	2023	5,4
impresa 5	2023	33,0

Dataset B, prezzo di chiusura mensile di un titolo (euro):

soggetto	periodo	prezzo
titolo	gen 2024	60,2
titolo	feb 2024	59,4
titolo	mar 2024	58,7
titolo	apr 2024	58,0
titolo	mag 2024	56,2
titolo	giu 2024	57,1

Dataset C, investimenti annui (milioni di euro). La tabella ne mostra un estratto: il dataset completo contiene $N = 187$ imprese osservate per $T = 9$ anni consecutivi, senza dati mancanti.

soggetto	periodo	investimenti
impresa 1	2019	4,7
impresa 1	2020	7,1
impresa 1	2021	2,8
impresa 2	2019	2,3
impresa 2	2020	2,3
impresa 2	2021	7,8
impresa 3	2019	3,8

soggetto	periodo	investimenti
impresa 3	2020	6,0
impresa 3	2021	2,9

Dataset D, prezzo di vendita (migliaia di dollari) delle case vendute in un comune nel 1978 e nel 1981, ciascuna con il proprio codice:

soggetto	periodo	prezzo
casa 1	1978	95,2
casa 2	1978	76,1
casa 3	1978	103,9
casa 4	1981	132,3
casa 5	1981	73,7
casa 6	1981	130,8

Testo della domanda. Domanda 2 ***(3 punti).*** **(a)** Il dataset A è una serie storica? Si risponda sì o no. **(b)** Il dataset B è una serie storica? Si risponda sì o no. **(c)** Il dataset C è un panel? Si risponda sì o no. **(d)** Il dataset D è un panel? Si risponda sì o no. **(e)** Quante osservazioni, cioè quante righe, contiene il dataset C completo? **(f)** Se del dataset C si tenessero soltanto le righe di un'impresa, i dati sarebbero un panel? Si risponda sì o no.

3 | Esercizio 3 — Polizia e criminalità *(livello intermedio)*

Dati. Su $n = 120$ città si osservano `reati` (reati ogni mille abitanti) e `poliziotti` (poliziotti ogni mille abitanti). Si è stimata la regressione semplice di `reati` su `poliziotti`

$$\text{reati} = \beta_0 + \beta_1 \,\text{poliziotti} + \epsilon,$$

	coefficiente	errore std.	rapporto t	p-value
const	10,1436	2,29837	4,413	2,26e-05
poliziotti	15,2926	1,05473	14,5	5,58e-28

n = 120; R^2 = 0,640489; SSR = 4250,06

e quella con i ruoli scambiati,

$$\text{poliziotti} = \gamma_0 + \gamma_1 \,\text{reati} + u.$$

	coefficiente	errore std.	rapporto t	p-value
const	0,335995	0,12609	2,665	0,0088
reati	0,0418822	0,00288861	14,5	5,58e-28

n = 120; R^2 = 0,640489; SSR = 11,6397

Testo della domanda. **Domanda 3** ***(3 punti).*** Si usi il valore critico 1,96. **(a)** Al livello del 5%, si decida se rifiutare o non rifiutare $H_0 : \beta_1 = 0$ contro $H_1 : \beta_1 \neq 0$. **(b)** Se si leggesse la prima regressione in senso causale, di quanti reati ogni mille abitanti varierebbe in media il numero di reati per un aumento di 0,5 poliziotti ogni mille abitanti? **(c)** Al livello del 5%, si decida se rifiutare o non rifiutare $H_0 : \gamma_1 = 0$ contro $H_1 : \gamma_1 \neq 0$. **(d)** Le due regressioni hanno lo stesso rapporto t per la pendenza e lo stesso R^2? Si risponda sì o no. **(e)** Dalla sola associazione fra le due variabili si può stabilire quale è la causa e quale l'effetto? Si risponda sì o no.

4 | Esercizio 4 — La spesa riportata male *(livello intermedio)*

Dati. Un'indagine chiede a $n = 200$ famiglie la spesa settimanale al supermercato e la spesa mensile non alimentare `y`. Le famiglie ricordano la spesa settimanale in modo impreciso: l'errore di ricordo è in media nullo. I dati sono simulati, quindi si conosce anche la spesa vera `spesa_vera`, che nella realtà non si osserva, mentre `spesa_rip` è quella riportata dalle famiglie. La spesa mensile è stata generata a partire dalla spesa vera con un coefficiente $\beta = 1{,}5$. Le medie e le deviazioni standard del campione sono le seguenti.

variabile	media	deviazione standard
spesa_vera	154,389	40,043
spesa_rip	156,954	55,163

Modello V, `y` su `spesa_vera`:

	coefficiente	errore std.	rapporto t	p-value
const	124,641	8,53482	14,6	2,92e-33
spesa_vera	1,49277	0,053519	27,89	1,65e-70

n = 200; $R^2 = 0{,}797126$; SSR = 180965

Modello R, `y` su `spesa_rip` (stesse famiglie):

	coefficiente	errore std.	rapporto t	p-value
const	212,333	9,49682	22,36	4,56e-56
spesa_rip	0,909668	0,0570998	15,93	2,55e-37

n = 200; $R^2 = 0{,}561756$; SSR = 390917

Modello G, `y` su `spesa_rip`, con un campione di 20000 famiglie generate allo stesso modo:

	coefficiente	errore std.	rapporto t	p-value
const	201,115	1,02984	195,3	0,0000
spesa_rip	0,956378	0,0065168	146,8	0,0000

n = 20000; R^2 = 0,518529

Testo della domanda. **Domanda 4** ***(3 punti).*** **(a)** In percentuale della media della spesa vera, di quanto differisce la media della spesa riportata (media riportata meno media vera)? **(b)** Quanto vale il rapporto fra la pendenza del Modello R e quella del Modello V, cioè la prima divisa per la seconda? **(c)** Quanto vale il rapporto fra la pendenza del Modello G e β, cioè la prima divisa per il secondo? **(d)** Nel Modello G, al livello del 5% (valore critico 1,96), si decida se rifiutare o non rifiutare $H_0 : \beta_1 = \beta$ contro $H_1 : \beta_1 \neq \beta$, con $t = (\hat{\beta}_1 - \beta)/\widehat{\text{se}}(\hat{\beta}_1)$. **(e)** Alla luce dei punti precedenti, un campione più grande basta a eliminare la distorsione dovuta all'errore di misura? Si risponda sì o no.

5 | Esercizio 5 — Gelati e incidenti in acqua *(livello d'appello)*

Dati. Su $n = 250$ località balneari si osservano in agosto `incidenti` (incidenti in acqua ogni 100 mila bagnanti), `gelati` (porzioni di gelato vendute per abitante a settimana) e `temperatura` (temperatura media in gradi centigradi). Si sono stimati il Modello 1

$$\text{incidenti} = \beta_0 + \beta_1\,\text{gelati} + \epsilon$$

	coefficiente	errore std.	rapporto t	p-value
const	2,84472	0,404656	7,03	1,99e-11
gelati	1,81139	0,0984205	18,4	2,8e-48

n = 250; R^2 = 0,577319; SSR = 727,097

il Modello 2, che aggiunge la temperatura,

$$\text{incidenti} = \beta_0 + \beta_1\,\text{gelati} + \beta_2\,\text{temperatura} + \epsilon$$

	coefficiente	errore std.	rapporto t	p-value
const	−20,9336	1,71149	−12,23	3,28e-27
gelati	0,178781	0,13698	1,305	0,1931
temperatura	1,11637	0,0790952	14,11	1,44e-33

n = 250; R^2 = 0,766026; SSR = 402,482

e la regressione ausiliaria $\text{gelati} = \delta_0 + \delta_1\,\text{temperatura} + u$.

	coefficiente	errore std.	rapporto t	p-value
const	−9,24898	0,533436	−17,34	1,19e-44
temperatura	0,487598	0,0196405	24,83	3,47e-69

n = 250; R^2 = 0,713075; SSR = 86,8437

Testo della domanda. **Domanda 5** ***(4 punti).*** In tutti i test si usi il livello del 5% e il valore critico 1,96. **(a)** Nel Modello 1, si decida se rifiutare o non rifiutare $H_0 : \beta_1 = 0$ contro $H_1 : \beta_1 \neq 0$. **(b)** Se si leggesse il Modello 1 in senso causale, di quanti incidenti ogni 100 mila bagnanti varierebbe in media il numero di incidenti per un aumento di 2 porzioni di gelato a settimana? **(c)** Nel Modello 2, si decida se rifiutare o non rifiutare $H_0 : \beta_1 = 0$ contro $H_1 : \beta_1 \neq 0$. **(d)** Nel Modello 2, di quanti incidenti ogni 100 mila bagnanti varia in media il numero di incidenti per un aumento di 3 gradi della temperatura, a parità di gelati? **(e)** Nella regressione ausiliaria, si decida se rifiutare o non rifiutare $H_0 : \delta_1 = 0$ contro $H_1 : \delta_1 \neq 0$. **(f)** Sia b la stima del coefficiente di `gelati` nel Modello 1. Nel Modello 2, si decida se rifiutare o non rifiutare $H_0 : \beta_1 = b$ contro $H_1 : \beta_1 \neq b$, con $t = (\hat{\beta}_1 - b)/\widehat{\text{se}}(\hat{\beta}_1)$, dove $\hat{\beta}_1$ e $\widehat{\text{se}}(\hat{\beta}_1)$ sono quelli del Modello 2.

6 | Esercizio 6 — Un fondo e il CAPM *(livello d'appello)*

Dati. Per $n = 240$ mesi consecutivi si osservano l'extra-rendimento mensile di un fondo, R_t, e quello del portafoglio di mercato, R_{mt}, entrambi in percentuale e al netto del tasso privo di rischio. Il CAPM prevede, per gli extra-rendimenti, $E[R_t] = \beta\, E[R_{mt}]$, cioè un'intercetta nulla. Per verificarlo si stima

$$R_t = \alpha + \beta\, R_{mt} + \epsilon_t, \qquad \mathrm{Var}(R_t) = \beta^2\, \mathrm{Var}(R_{mt}) + \sigma^2,$$

dove σ è il rischio idiosincratico, stimato con $\hat{\sigma} = \sqrt{\mathrm{SSR}/(n-2)}$. Le stime OLS sono le seguenti.

	coefficiente	errore std.	rapporto t	p-value
const	−0,0811511	0,161744	−0,5017	0,6163
mercato	1,12244	0,0354445	31,67	2,63e-87

n = 240; R^2 = 0,808192; SSR = 1387,36

Testo della domanda. **Domanda 6** ***(4 punti).*** In tutti i test si usi il livello del 5% e il valore critico 1,96. **(a)** I dati sono una serie storica? Si risponda sì o no. **(b)** Si decida se rifiutare o non rifiutare $H_0 : \alpha = 0$ contro $H_1 : \alpha \neq 0$. **(c)** Il risultato del punto (b) dimostra che il CAPM è vero? Si risponda sì o no. **(d)** Si decida se rifiutare o non rifiutare $H_0 : \beta = 1$ contro $H_1 : \beta \neq 1$, con $t = (\hat{\beta} - 1)/\widehat{\mathrm{se}}(\hat{\beta})$. **(e)** Di quanti punti percentuali varia in media l'extra-rendimento del fondo se quello del mercato aumenta di 3 punti percentuali? **(f)** Quanto vale la stima $\hat{\sigma}$ del rischio idiosincratico?