Università Ca' Foscari Venezia

Dipartimento di Economia

Laurea Magistrale in
Economia e Finanza

Modulo 00 — Fondamenta di probabilità e statistica

Soluzioni svolte e commentate

Appunti di:
Silvio Angelo Baratto Roldan

Codice insegnamento:
EM0004

Contenuto:
14 esercizi

Esercizi sintetici costruiti a fini di studio sul modello dei veri appelli e sulla teoria del corso (Econometria EM0004, prof. Davide Raggi). Non sono materiale ufficiale del docente.

Indice

1 **Esercizio 1 — Titolo di studio e opinione sullo smart working** ***(livello base)*** 1

2 **Esercizio 2 — Ore di studio e voto: la covarianza** ***(livello base)*** 3

3 **Esercizio 3 — Il reddito di una famiglia: media e varianza di una somma** ***(livello base)*** 5

4 **Esercizio 4 — Rendimento di un fondo con leva** ***(livello base)*** 7

5 **Esercizio 5 — Tempo di attesa al pronto soccorso: intervalli di confidenza** ***(livello base)*** 9

6 **Esercizio 6 — Peso delle confezioni: i tre test sulla media** ***(livello base)*** 11

7 **Esercizio 7 — Il reddito medio di un campione casuale** ***(livello intermedio)*** 13

8 **Esercizio 8 — Sondaggio: la maggioranza è favorevole?** ***(livello intermedio)*** 15

9 **Esercizio 9 — Quattro misure: la distribuzione t di Student** ***(livello intermedio)*** 17

10 **Esercizio 10 — Due servizi di assistenza: confronto fra medie** ***(livello intermedio)*** 19

11 **Esercizio 11 — Due offerte promozionali: confronto fra proporzioni** ***(livello intermedio)*** 21

12 **Esercizio 12 — Prima e dopo il corso: dati appaiati e covarianza** ***(livello appello)*** 23

13 **Esercizio 13 — Errore e media condizionale: l'incorrelazione non basta** ***(livello appello)*** 25

14 **Esercizio 14 — Alunni della stessa classe: osservazioni non indipendenti** ***(livello appello)*** 27

1 | Esercizio 1 — Titolo di studio e opinione sullo smart working *(livello base)*

Dati. In un'azienda si sono intervistati dipendenti diplomati e laureati sulla possibilità di lavorare da casa (smart working). La tabella riporta il numero di intervistati per titolo di studio e opinione.

	favorevole	indifferente	contrario	totale
Diplomati	159	140	240	539
Laureati	347	148	139	634
Totale	506	288	379	1173

Due variabili categoriche sono statisticamente indipendenti se la distribuzione condizionale dell'una è la stessa in ogni categoria dell'altra. Qui i dati si considerano incompatibili con l'indipendenza se, per almeno un'opinione, le percentuali dei due gruppi differiscono di più di 10 punti percentuali.

Testo della domanda. **Domanda 1** ***(3 punti).*** **(a)** Fra i laureati, quale percentuale è favorevole? **(b)** Fra i dipendenti favorevoli, quale percentuale è laureata? **(c)** Secondo il criterio indicato, titolo di studio e opinione risultano associati? Si risponda sì o no. **(d)** Se opinione e titolo di studio fossero statisticamente indipendenti, quanti laureati favorevoli ci si aspetterebbe, a parità di numerosità dei due gruppi e di totale dei favorevoli?

Richiamo. La distribuzione condizionale di una variabile, dato un valore dell'altra, si ottiene dividendo ogni cella per il totale della riga (o della colonna) che si condiziona: $P(A \mid B) = n(A \cap B)/n(B)$. In generale $P(A \mid B) \neq P(B \mid A)$, perché i denominatori sono diversi. Se A e B sono indipendenti, $P(A \mid B) = P(A)$ per ogni B: le distribuzioni condizionali coincidono con quella complessiva, e il numero atteso di unità in $A \cap B$ è $n(B)\,P(A)$.

Svolgimento. **Impostazione.** Le percentuali si calcolano dentro ciascun gruppo, dividendo per il suo totale; il confronto fra gruppi si fa sulle percentuali condizionali e non sui conteggi, perché i gruppi hanno numerosità diverse.

(a) Si condiziona sui laureati: $P(\text{favorevole} \mid \text{laureato}) = \dfrac{347}{634} = 54{,}7\%$.

(b) Si condiziona sui favorevoli: $P(\text{laureato} \mid \text{favorevole}) = \dfrac{347}{506} = 68{,}6\%$.

(c) Distribuzione dell'opinione fra i diplomati (favorevole, indifferente, contrario): 29,5%, 26,0%, 44,5%. Fra i laureati: 54,7%, 23,3%, 21,9%. Le differenze (laureati meno diplomati) sono 25,2, −2,6 e −22,6 punti percentuali; la più grande in valore assoluto è 25,2, maggiore di 10. Le due distribuzioni sono diverse: le variabili risultano associate.

(d) Con l'indipendenza la percentuale di favorevoli sarebbe la stessa nei due gruppi, cioè quella complessiva $506/1173 = 43{,}1\%$. I laureati favorevoli attesi sono $634 \times 506/1173 = 273{,}5$, contro 347 osservati.

Errore tipico. Scambiare le due condizionali: la (a) e la (b) hanno lo stesso numeratore, 347, ma denominatori diversi (634 laureati contro 506 favorevoli) e quindi rispondono a domande diverse. Un altro errore è confrontare i conteggi grezzi dei due gruppi senza dividere per le loro numerosità.

Risposta. **(a)** Il 54,7% dei laureati è favorevole. **(b)** Il 68,6% dei favorevoli è laureato. **(c)** Sì: per almeno un'opinione le percentuali dei due gruppi differiscono di più di 10 punti percentuali (al massimo 25,2), quindi titolo di studio e opinione non sono indipendenti. **(d)** Con l'indipendenza ci si aspetterebbero 273,5 laureati favorevoli, molti meno dei 347 osservati.

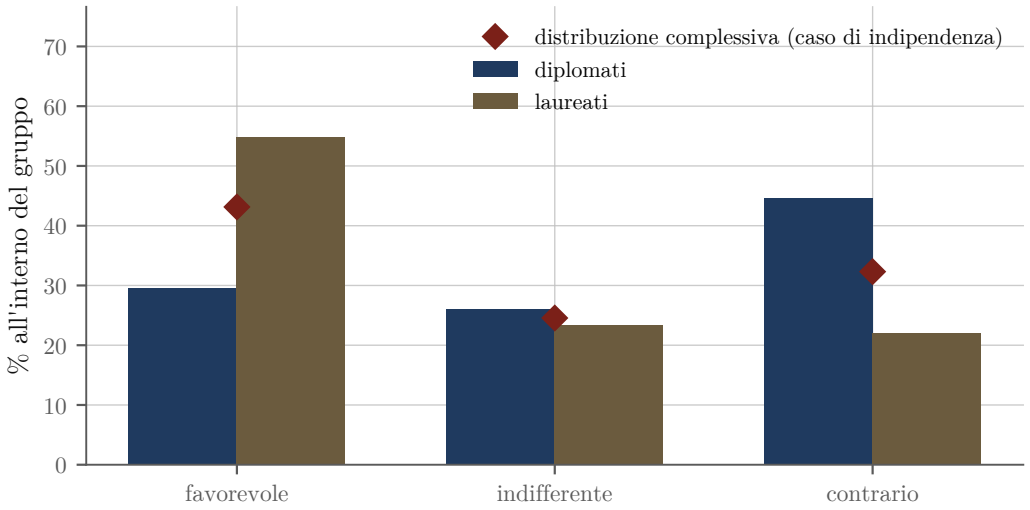


Figura 1.1: Distribuzione dell'opinione fra i diplomati e fra i laureati, a confronto con la distribuzione complessiva (rombi rossi). Con l'indipendenza le barre di entrambi i gruppi coinciderebbero con i rombi; qui i laureati sono molto più favorevoli e molto meno contrari.

2 | Esercizio 2 — Ore di studio e voto: la covarianza *(livello base)*

Dati. Per $n = 6$ studenti si sono rilevati il numero X di ore di studio settimanali e il voto Y all'esame, in trentesimi.

studente	ore di studio X	voto Y
S1	3	18
S2	5	19
S3	7	22
S4	14	23
S5	17	26
S6	20	30

La covarianza campionaria è $s_{xy} = \dfrac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})$, con divisore n. La covarianza di X con se stessa si calcola con la stessa formula.

Testo della domanda. **Domanda 2** ***(3 punti).*** **(a)** Quanto vale la covarianza campionaria s_{xy}? **(b)** Le ore vengono espresse in minuti, $X' = 60\,X$, e a ogni voto si aggiungono 2 punti, $Y' = Y + 2$. Quanto vale la covarianza campionaria fra X' e Y'? **(c)** Quanto vale la covarianza campionaria di X con X? **(d)** Ore di studio e voto tendono a muoversi nello stesso senso? Si risponda sì o no.

Richiamo. La covarianza campionaria è $s_{xy} = \dfrac{1}{n}\sum_i (x_i - \bar{x})(y_i - \bar{y}) = \dfrac{1}{n}\sum_i x_i y_i - \bar{x}\bar{y}$. È positiva se i valori di X sopra la media tendono ad accompagnarsi a valori di Y sopra la media. Proprietà: $\mathrm{Cov}(X, Y) = \mathrm{Cov}(Y, X)$; $\mathrm{Cov}(X, X) = \mathrm{Var}(X)$; $\mathrm{Cov}(aX, bY) = ab\,\mathrm{Cov}(X, Y)$; $\mathrm{Cov}(a + X, b + Y) = \mathrm{Cov}(X, Y)$, cioè sommare una costante non cambia la covarianza.

Svolgimento. **Impostazione.** Si calcolano le medie, le deviazioni dalla media e la somma dei loro prodotti; poi le proprietà della covarianza evitano di ricalcolare tutto per le variabili trasformate.

(a) Le medie sono $\bar{x} = 11$ e $\bar{y} = 23$. La somma dei prodotti $(x_i - \bar{x})(y_i - \bar{y})$ vale 149, quindi $s_{xy} = \dfrac{149}{6} = 24{,}83$.

(b) $\mathrm{Cov}(60X,\, Y + 2) = 60 \times \mathrm{Cov}(X, Y) = 60 \times \dfrac{149}{6} = 1490$: il fattore moltiplica la covarianza, la costante aggiunta non conta.

(c) $\mathrm{Cov}(X, X) = \mathrm{Var}(X) = \dfrac{1}{n}\sum_i (x_i - \bar{x})^2 = 40{,}33$.

(d) Sì: $s_{xy} = 24{,}83 > 0$.

Errore tipico. Aggiungere 2 alla covarianza, o moltiplicare per 60 anche la costante: solo il fattore moltiplicativo entra nella covarianza (e al quadrato nella varianza), le traslazioni no. Un altro errore è dividere per $n-1$ invece di n: il testo fissa il divisore n.

Risposta. **(a)** $s_{xy} = 24{,}83$. **(b)** $\mathrm{Cov}(X', Y') = 1490$, cioè 60 volte la covarianza di partenza. **(c)** $\mathrm{Cov}(X, X) = \mathrm{Var}(X) = 40{,}33$. **(d)** Sì: la covarianza è positiva, chi studia più ore tende ad avere voti più alti.

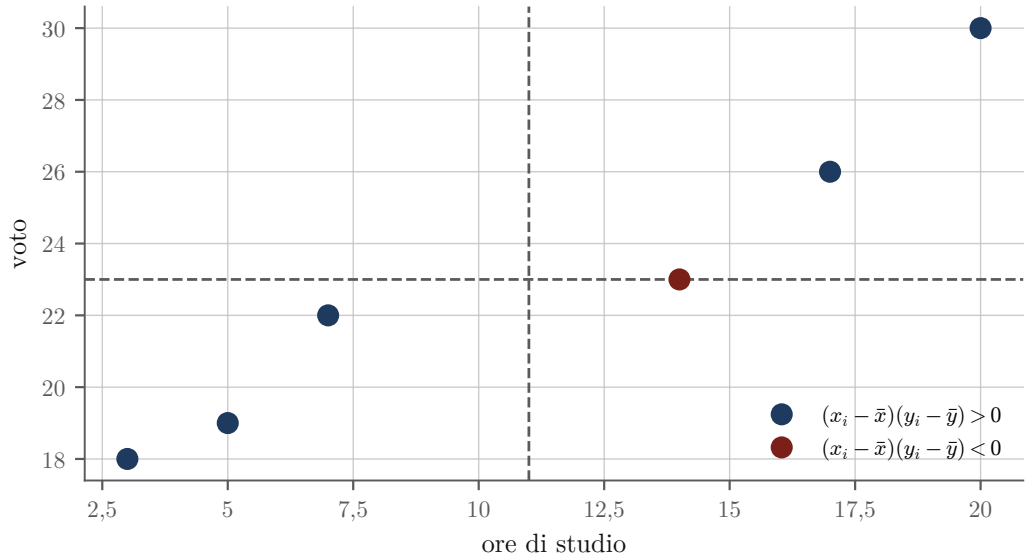


Figura 2.1: Le coppie (x_i, y_i) attorno alle medie (linee tratteggiate). I punti blu stanno nei quadranti in cui il prodotto $(x_i - \bar{x})(y_i - \bar{y})$ è positivo, i rossi in quelli in cui è negativo: i blu prevalgono, e la somma dei prodotti è 149.

3 | Esercizio 3 — Il reddito di una famiglia: media e varianza di una somma *(livello base)*

Dati. Su un campione di famiglie si osservano il reddito mensile del marito X e quello della moglie Y, in migliaia di euro. Il reddito della famiglia è $Z = X + Y$. Le statistiche descrittive sono nella tabella; la covarianza campionaria fra X e Y vale 0,157. Varianze e covarianza usano lo stesso divisore.

	media	dev. std.
X (marito)	2,09	0,77
Y (moglie)	1,60	0,58

Testo della domanda. **Domanda 3** ***(3 punti).*** **(a)** Quanto vale la media del reddito familiare $Z = X+Y$? **(b)** Quanto vale la varianza di Z? **(c)** Quanto vale il coefficiente di correlazione fra X e Y? **(d)** Quanto vale la varianza di $X - Y$? **(e)** Se X e Y fossero indipendenti, la varianza di Z sarebbe minore di quella ottenuta in (b)? Si risponda sì o no.

Richiamo. La media di una somma è la somma delle medie: $E[X + Y] = E[X] + E[Y]$. La varianza no: $\mathrm{Var}(X + Y) = \mathrm{Var}(X) + \mathrm{Var}(Y) + 2\,\mathrm{Cov}(X, Y)$ e, per la differenza, $\mathrm{Var}(X - Y) = \mathrm{Var}(X) + \mathrm{Var}(Y) - 2\,\mathrm{Cov}(X, Y)$. La correlazione è $\rho_{XY} = \mathrm{Cov}(X, Y)/(s_X\, s_Y)$ e sta sempre fra -1 e 1. Variabili indipendenti hanno covarianza nulla: allora la varianza della somma è la somma delle varianze.

Svolgimento. **Impostazione.** Le deviazioni standard della tabella vanno elevate al quadrato per ottenere le varianze, 0,5929 per X e 0,3364 per Y; la covarianza è 0,157.

(a) $E[Z] = 2{,}09 + 1{,}60 = 3{,}69$ migliaia di euro.

(b) $\mathrm{Var}(Z) = 0{,}5929 + 0{,}3364 + 2 \times 0{,}157 = 1{,}243$.

(c) $\rho_{XY} = \dfrac{0{,}157}{0{,}77 \times 0{,}58} = 0{,}352$.

(d) $\mathrm{Var}(X - Y) = 0{,}5929 + 0{,}3364 - 2 \times 0{,}157 = 0{,}615$.

(e) Con Cov $= 0$ la varianza della somma sarebbe $0{,}5929 + 0{,}3364 = 0{,}929$, minore di 1,243: la covarianza positiva allarga la distribuzione della somma.

Errore tipico. Sommare le varianze e basta, dimenticando 2 Cov, oppure sommare le deviazioni standard ($0{,}77 + 0{,}58$ non è la deviazione standard di Z, che vale 1,115). Per la differenza la covarianza entra con il segno meno: con redditi positivamente correlati $\mathrm{Var}(X-Y)$ è più piccola di $\mathrm{Var}(X+Y)$.

Risposta. **(a)** La media del reddito familiare è 3,69 migliaia di euro. **(b)** $\mathrm{Var}(Z) = 1{,}243$. **(c)** $\rho_{XY} = 0{,}352$: correlazione positiva e moderata. **(d)** $\mathrm{Var}(X-Y) = 0{,}615$. **(e)** Sì: con redditi indipendenti sarebbe 0,929, perché la covarianza positiva aumenta la varianza della somma.

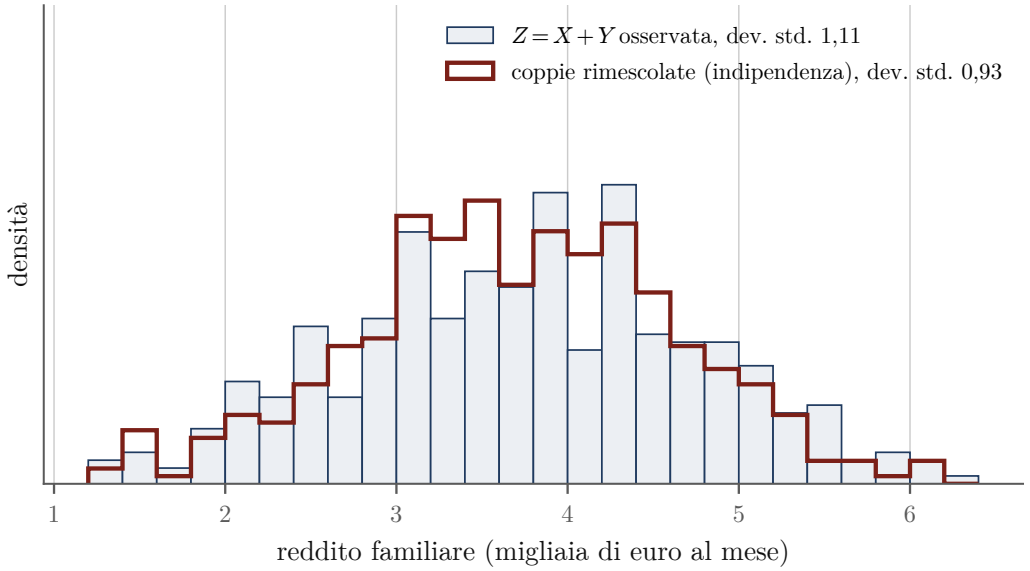


Figura 3.1: Distribuzione del reddito familiare $Z = X + Y$ osservata (barre blu) e quella che si avrebbe se i redditi dei coniugi fossero indipendenti (linea rossa). La covarianza positiva allarga la distribuzione: la deviazione standard di Z è 1,115.

4 | Esercizio 4 — Rendimento di un fondo con leva *(livello base)*

Dati. Il rendimento mensile X di un fondo, in punti percentuali, è una variabile casuale con la distribuzione seguente.

x	$P(X = x)$
-4	0,1
-1	0,2
2	0,3
5	0,1
8	0,3

Un investitore che prende a prestito parte del capitale ottiene il rendimento $Y = 3\,X - 2$, dove 2 è un costo fisso.

Testo della domanda. **Domanda 4** ***(3 punti).*** **(a)** Quanto vale il valore atteso $E[X]$? **(b)** Quanto vale la varianza $\mathrm{Var}(X)$? **(c)** Quanto vale $E[Y]$? **(d)** Quanto vale $\mathrm{Var}(Y)$?

Richiamo. Per una variabile casuale discreta $E[X] = \sum_x x\,P(X = x)$ e $\mathrm{Var}(X) = \sum_x (x - \mu)^2 P(X = x) = E[X^2] - \mu^2$. Per una trasformazione lineare $Y = aX - c$ valgono $E[Y] = aE[X] - c$ (la media è lineare) e $\mathrm{Var}(Y) = a^2\,\mathrm{Var}(X)$: la costante non conta e il coefficiente entra al quadrato.

Svolgimento. **Impostazione.** Si calcolano $E[X]$ e $E[X^2]$ dalla tabella; $\mathrm{Var}(X)$ ne segue, e le due trasformazioni lineari non richiedono nuove somme.

(a) $E[X] = (-4)(0{,}1) + (-1)(0{,}2) + (2)(0{,}3) + (5)(0{,}1) + (8)(0{,}3) = 2{,}9$.

(b) $E[X^2] = 24{,}7$, quindi $\mathrm{Var}(X) = E[X^2] - \mu^2 = 24{,}7 - (2{,}9)^2 = 16{,}29$.

(c) $E[Y] = 3 \times 2{,}9 - 2 = 6{,}7$.

(d) $\mathrm{Var}(Y) = 3^2 \times \mathrm{Var}(X) = 9 \times 16{,}29 = 146{,}61$.

Errore tipico. Sottrarre il costo fisso anche dalla varianza, scrivendo $9\,\mathrm{Var}(X) - 2$: una costante sposta la distribuzione ma non ne cambia la dispersione. Un altro errore è moltiplicare la varianza per 3 invece che per 9: è la deviazione standard a scalare con 3 (da 4,04 a 12,11).

Risposta. **(a)** $E[X] = 2{,}9$. **(b)** $\mathrm{Var}(X) = 16{,}29$. **(c)** $E[Y] = 6{,}7$. **(d)** $\mathrm{Var}(Y) = 146{,}61$: la leva moltiplica la deviazione standard per 3 e la varianza per 9, mentre il costo fisso sposta soltanto la media.

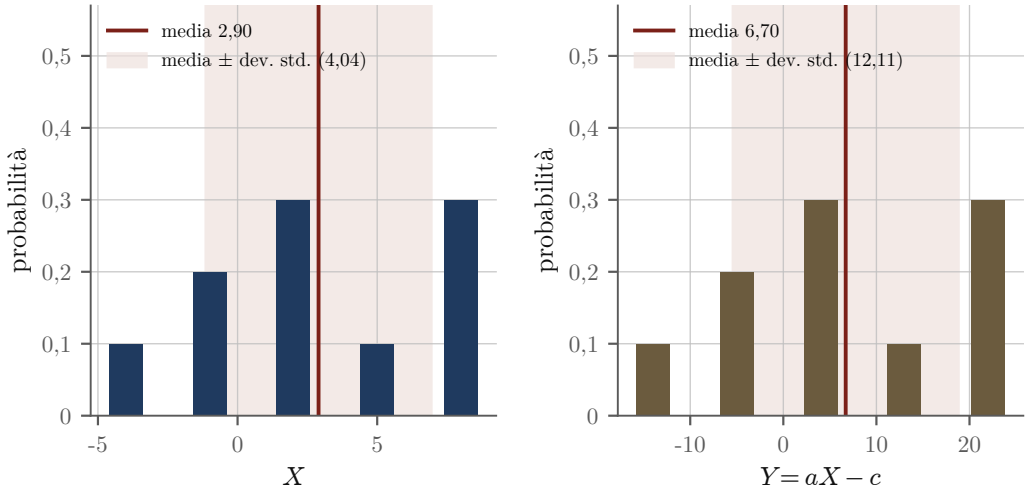


Figura 4.1: Distribuzione di X (a sinistra) e di $Y = aX - c$ (a destra) con la media (linea rossa) e la fascia di una deviazione standard: la trasformazione sposta e dilata la distribuzione, e la fascia si allarga di un fattore 3.

5 | Esercizio 5 — Tempo di attesa al pronto soccorso: intervalli di confidenza *(livello base)*

Dati. Un pronto soccorso rileva il tempo di attesa, in minuti, di un campione casuale semplice di pazienti. Il campione ha dato i risultati seguenti.

	n	media $\bar{y}$	dev. std. s
tempo di attesa (minuti)	100	24,3	8,37

Per la media μ si usa l'intervallo $\bar{y} \pm z\, s/\sqrt{n}$, con $z = 1{,}96$ al 95% e $z = 2{,}57$ al 99%.

Testo della domanda. **Domanda 5** ***(3 punti).*** **(a)** Quanto vale l'errore standard della media campionaria, $s/\sqrt{n}$? **(b)** Qual è l'estremo inferiore dell'intervallo di confidenza al 95% per il tempo medio di attesa μ? **(c)** E l'estremo superiore? **(d)** Quanto è ampio l'intervallo di confidenza al 99% (differenza fra estremo superiore e inferiore)? **(e)** Il direttore sostiene che il tempo medio di attesa sia di 27 minuti. Al livello del 5%, usando l'intervallo di confidenza al 95%, si decida se rifiutare o non rifiutare $H_0 : \mu = 27$ contro $H_1 : \mu \neq 27$. **(f)** Circa il 95% dei singoli tempi di attesa dei pazienti cade nell'intervallo calcolato in (b)–(c)? Si risponda sì o no.

Richiamo. In un campione casuale semplice $\bar{Y}$ ha media μ ed errore standard $\sigma/\sqrt{n}$, che si stima con $s/\sqrt{n}$; per il teorema del limite centrale $\bar{Y}$ è approssimativamente normale. L'intervallo di confidenza per μ è $\bar{y} \pm z\, s/\sqrt{n}$, con $z = 1{,}96$ al 95% e $z = 2{,}57$ al 99%. Il 95% si riferisce ai campioni ripetuti: costruendo l'intervallo su molti campioni, il 95% degli intervalli contiene μ. Non è la quota di dati dentro l'intervallo. Rifiutare $H_0 : \mu = \mu_0$ al 5% (bilaterale) equivale ad avere μ_0 fuori dall'intervallo al 95%.

Svolgimento. **Impostazione.** Dalla tabella: $n = 100$, $\bar{y} = 24{,}3$, $s = 8{,}37$.

(a) $s/\sqrt{n} = 8{,}37/\sqrt{100} = 0{,}837$.

(b) $\bar{y} - 1{,}96 \times 0{,}837 = 24{,}3 - 1{,}64 = 22{,}66$.

(c) $\bar{y} + 1{,}96 \times 0{,}837 = 24{,}3 + 1{,}64 = 25{,}94$.

(d) Al 99% l'intervallo è $\bar{y} \pm 2{,}57 \times 0{,}837 = [22{,}15;\ 26{,}45]$, con ampiezza $2 \times 2{,}57 \times 0{,}837 = 4{,}30$.

(e) L'intervallo di confidenza al 95% è [22,66; 25,94] e 27 ne è fuori: si rifiuta H_0. Lo stesso dice $t = (24{,}3 - 27)/0{,}837 = -3{,}23$, in valore assoluto maggiore di 1,96.

(f) No. L'intervallo di [22,66; 25,94] riguarda la media μ e ha l'errore standard $s/\sqrt{n}$. I singoli tempi variano con la deviazione standard s: se i tempi fossero approssimativamente normali, circa il 95% di essi starebbe in $\bar{y} \pm 1{,}96\, s = [7{,}9;\ 40{,}7]$, un intervallo molto più largo.

Errore tipico. Usare la deviazione standard s al posto dell'errore standard $s/\sqrt{n}$ (l'intervallo diventerebbe $\bar{y} \pm 1{,}96\, s = [7{,}9;\ 40{,}7]$, troppo largo), o leggere l'intervallo come il campo in cui cade il 95% delle osservazioni. Un altro errore è dire che μ ha il 95% di probabilità di stare nell'intervallo calcolato: μ è un numero fisso, è l'intervallo a cambiare da campione a campione.

Risposta. **(a)** L'errore standard della media è 0,837 minuti. **(b)–(c)** L'intervallo di confidenza al 95% per il tempo medio di attesa è [22,66; 25,94]. **(d)** L'intervallo al 99% è più largo, 4,30 minuti. **(e)** 27 minuti sta fuori dall'intervallo al 95%: si rifiuta H_0. **(f)** No: l'intervallo riguarda la media, non i singoli tempi di attesa, che sono molto più dispersi.

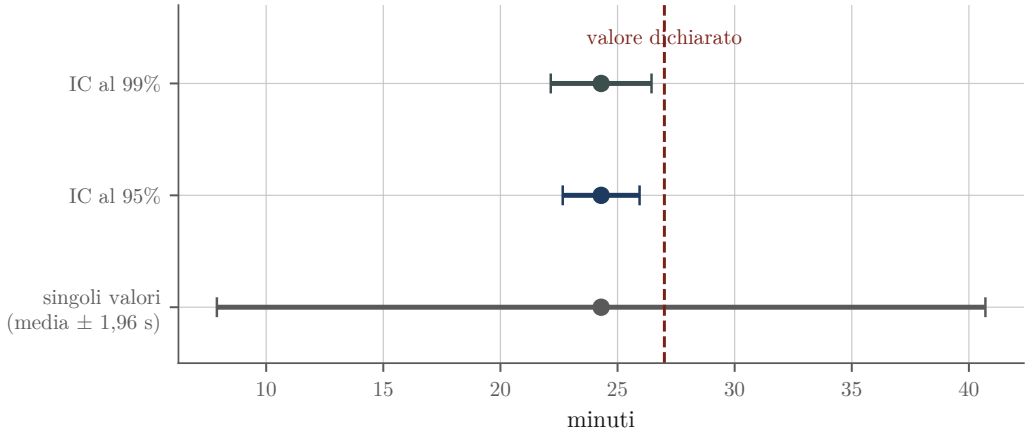


Figura 5.1: Intervalli di confidenza al 99% e al 95% per il tempo medio di attesa e intervallo $\bar{y} \pm 1{,}96\, s$ dei singoli valori. Il valore dichiarato (linea rossa) è fuori da entrambi gli intervalli per la media, ma i singoli valori lo contengono.

6 | Esercizio 6 — Peso delle confezioni: i tre test sulla media *(livello base)*

Dati. Un produttore dichiara che le sue confezioni di pasta pesano in media $\mu_0 = 500$ grammi. Un'associazione di consumatori pesa un campione casuale di confezioni e ottiene i risultati seguenti.

	n	media $\bar{y}$	dev. std. s
peso (grammi)	100	498,6	4,3

La statistica test è $t = \dfrac{\bar{y} - \mu_0}{s/\sqrt{n}}$, approssimativamente $N(0,\,1)$ sotto $H_0 : \mu = \mu_0$. Per il test contro $H_1 : \mu < \mu_0$ il programma di calcolo riporta il p-value 0,0006.

Testo della domanda. **Domanda 6** ***(3 punti).*** **(a)** Quanto vale la statistica t? Nelle domande seguenti si usi il livello del 5%, con valore critico 1,64 per i test unilaterali e 1,96 per quello bilaterale. **(b)** Si decida se rifiutare o non rifiutare H_0 contro $H_1 : \mu < \mu_0$ (si rifiuta se $t < -1{,}64$). **(c)** Si decida se rifiutare o non rifiutare H_0 contro $H_1 : \mu > \mu_0$ (si rifiuta se $t > 1{,}64$). **(d)** Si decida se rifiutare o non rifiutare H_0 contro $H_1 : \mu \neq \mu_0$ (si rifiuta se $|t| > 1{,}96$). **(e)** Quanto vale il p-value del test bilaterale di (d)? **(f)** Il p-value di (e) è la probabilità che H_0 sia vera? Si risponda sì o no.

Richiamo. Sotto $H_0 : \mu = \mu_0$ la statistica $t = (\bar{y} - \mu_0)/(s/\sqrt{n})$ è approssimativamente $N(0,\,1)$. L'alternativa decide dove si rifiuta. Contro $H_1 : \mu < \mu_0$ si rifiuta se $t < -1{,}64$ e il p-value è $P(Z \le t_{\text{oss}})$; contro $H_1 : \mu > \mu_0$ si rifiuta se $t > 1{,}64$ e il p-value è $P(Z \ge t_{\text{oss}})$; contro $H_1 : \mu \neq \mu_0$ si rifiuta se $|t| > 1{,}96$ e il p-value è $2\,P(Z \ge |t_{\text{oss}}|)$. Si rifiuta quando il p-value è minore del livello. Il p-value è la probabilità, sotto H_0, di un risultato almeno così contrario a H_0 come quello osservato: non è la probabilità che H_0 sia vera.

Svolgimento. **Impostazione.** Con gli stessi dati le tre alternative danno regioni di rifiuto diverse; conta anche il segno di t.

(a) $s/\sqrt{n} = 4{,}3/\sqrt{100} = 0{,}430$ e $t = \dfrac{498{,}6 - 500}{0{,}430} = -3{,}26$.

(b) $-3{,}26 < -1{,}64$: si rifiuta H_0 (p-value $0{,}0006 < 0{,}05$).

(c) $-3{,}26$ è negativo, quindi non supera 1,64: non si rifiuta H_0 (p-value $1 - 0{,}0006 = 0{,}9994$).

(d) $|t| = 3{,}26$ è maggiore di 1,96: si rifiuta H_0.

(e) Il p-value bilaterale è il doppio di quello unilaterale: $2 \times 0{,}0006 = 0{,}0012$.

(f) No. Il p-value è la probabilità di un risultato così estremo se H_0 fosse vera, non la probabilità che H_0 sia vera.

Errore tipico. Guardare solo $|t|$ e rifiutare anche contro $H_1 : \mu > \mu_0$: l'alternativa unilaterale a destra si rifiuta soltanto con t positivo e grande, e qui il campione sta dall'altra parte di μ_0. Un altro errore è leggere il p-value 0,0012 come la probabilità che H_0 sia vera: dice quanto sarebbe raro un campione simile se H_0 fosse vera.

Risposta. **(a)** $t = -3{,}26$. **(b)** Contro $H_1 : \mu < \mu_0$ si rifiuta H_0. **(c)** Contro $H_1 : \mu > \mu_0$ non si rifiuta H_0: t ha il segno sbagliato. **(d)** Contro $H_1 : \mu \neq \mu_0$ si rifiuta H_0. **(e)** Il p-value bilaterale è 0,0012. **(f)** No: è la probabilità di un campione così estremo sotto H_0.

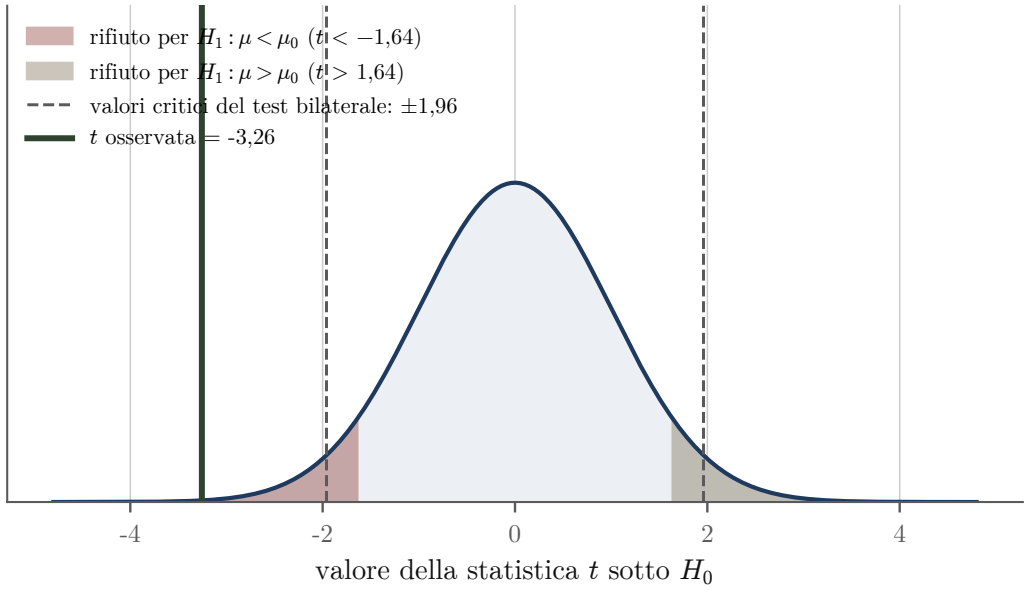


Figura 6.1: Distribuzione di t sotto H_0 con le regioni di rifiuto dei tre test al 5%. La t osservata ($-3{,}26$, linea verde) cade nella regione di rifiuto dell'alternativa a sinistra e del test bilaterale, non in quella dell'alternativa a destra.

7 | Esercizio 7 — Il reddito medio di un campione casuale *(livello intermedio)*

Dati. In una popolazione il reddito annuo Y, in migliaia di euro, ha media $\mu = 28$ e deviazione standard $\sigma = 12$; la distribuzione è asimmetrica, con una lunga coda a destra. Si estrae un campione casuale semplice di $n = 64$ persone, $Y_1, \dots, Y_n$, e si indica con $\bar{Y}$ la media campionaria.

Testo della domanda. **Domanda 7** ***(3 punti).*** **(a)** Quanto vale $\mathrm{Var}(Y_1 + Y_2)$, con Y_1 e Y_2 le prime due osservazioni del campione? **(b)** $\bar{Y}$ è uno stimatore corretto di μ, cioè $E[\bar{Y}] = \mu$? Si risponda sì o no. **(c)** Quanto vale l'errore standard di $\bar{Y}$? **(d)** Quale numerosità campionaria serve perché l'errore standard di $\bar{Y}$ sia 1? **(e)** Per il teorema del limite centrale $\bar{Y}$ è approssimativamente normale: quanto vale c nell'intervallo $[\mu - c,\ \mu + c]$ che contiene $\bar{Y}$ con probabilità circa del 95% (si usi 1,96)? **(f)** Un campione di $n = 64$ persone ha dato $\bar{y} = 32{,}4$: cade nell'intervallo $[\mu - c,\ \mu + c]$? Si risponda sì o no.

Richiamo. In un campione casuale semplice le Y_i sono indipendenti e hanno la distribuzione della popolazione: $E[Y_i] = \mu$, $\mathrm{Var}(Y_i) = \sigma^2$, $\mathrm{Cov}(Y_i, Y_j) = 0$ per $i \neq j$. Quindi $E[\bar{Y}] = \frac{1}{n}\sum_i E[Y_i] = \mu$ (stimatore corretto) e $\mathrm{Var}(\bar{Y}) = \frac{1}{n^2}\left[\sum_i \mathrm{Var}(Y_i) + \sum_{i \neq j} \mathrm{Cov}(Y_i, Y_j)\right] = \sigma^2/n$: l'errore standard è $\sigma/\sqrt{n}$ e tende a zero al crescere di n (legge dei grandi numeri). Per il teorema del limite centrale $(\bar{Y} - \mu)/(\sigma/\sqrt{n})$ è approssimativamente $N(0,\,1)$ anche se Y non è normale, quindi $P(|\bar{Y} - \mu| \le 1{,}96\,\sigma/\sqrt{n}) \approx 0{,}95$.

Svolgimento. Impostazione. Si usano indipendenza e identica distribuzione per ottenere media e varianza di $\bar{Y}$; la normalità approssimata di $\bar{Y}$ dà poi l'intervallo.

(a) Per l'indipendenza $\mathrm{Cov}(Y_1, Y_2) = 0$, quindi $\mathrm{Var}(Y_1 + Y_2) = \sigma^2 + \sigma^2 = 2 \times 12^2 = 288$.

(b) $E[\bar{Y}] = \dfrac{1}{n}\sum_i E[Y_i] = \dfrac{1}{n}\, n\, \mu = \mu$: sì, è corretto, per qualsiasi n.

(c) $\sigma/\sqrt{n} = 12/\sqrt{64} = 1{,}50$.

(d) Da $\sigma/\sqrt{n'} = 1$ si ricava $n' = (\sigma/1)^2 = (12/1)^2 = 144$.

(e) $c = 1{,}96 \times 1{,}50 = 2{,}94$, quindi l'intervallo è $[25{,}06;\ 30{,}94]$.

(f) $z = (\bar{y} - \mu)/(\sigma/\sqrt{n}) = (32{,}4 - 28)/1{,}50 = 2{,}93$, in valore assoluto maggiore di 1,96: 32,4 cade fuori dall'intervallo.

Errore tipico. Usare σ invece di $\sigma/\sqrt{n}$ nell'intervallo di (e): $1{,}96\,\sigma$ descrive la dispersione di un singolo reddito, non quella della media. Un altro errore è pensare che $\bar{Y}$ sia normale solo se Y lo è: il teorema del limite centrale vale anche per popolazioni asimmetriche, purché n sia abbastanza grande. In (a), poi, $\mathrm{Var}(Y_1 + Y_2)$ vale $2\sigma^2$ e non $4\sigma^2$: la somma di due variabili indipendenti ha varianza pari alla somma delle varianze.

Risposta. **(a)** $\mathrm{Var}(Y_1+Y_2) = 288$. **(b)** Sì: $E[\bar{Y}] = \mu$. **(c)** L'errore standard è 1,50. **(d)** Servono 144 osservazioni. **(e)** $c = 2{,}94$: $\bar{Y}$ cade in [25,06; 30,94] con probabilità circa 0,95. **(f)** No: 32,4 sta fuori, ed è un valore insolito per la media di un campione casuale di questa popolazione.

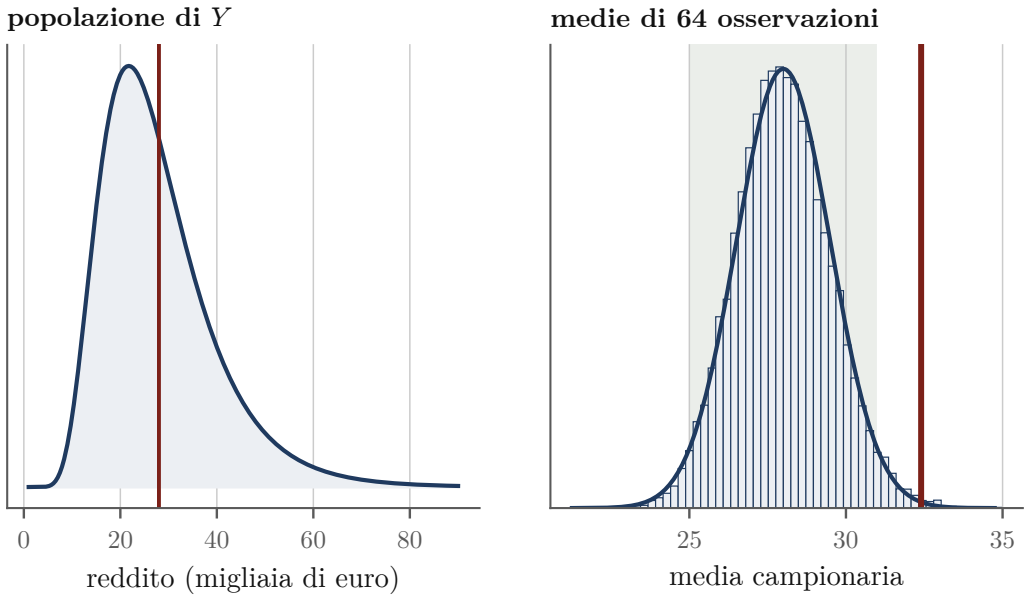


Figura 7.1: A sinistra la popolazione, asimmetrica, con la media μ (linea rossa). A destra le medie di molti campioni di $n = 64$ osservazioni: il loro istogramma segue la normale con media μ ed errore standard 1,50 (linea blu). La fascia verde è $[\mu - c,\ \mu + c]$; la linea rossa è la media osservata 32,4, fuori dalla fascia.

8 | Esercizio 8 — Sondaggio: la maggioranza è favorevole? *(livello intermedio)*

Dati. In un sondaggio su un campione casuale di $n = 900$ elettori, $x = 486$ si dichiarano favorevoli a un provvedimento. Sia π la proporzione di favorevoli nella popolazione e $\hat{\pi} = x/n$ la sua stima, che è la media di variabili di Bernoulli. L'errore standard stimato di $\hat{\pi}$ è $\sqrt{\hat{\pi}(1-\hat{\pi})/n}$. Il campione è abbastanza grande per usare l'approssimazione normale.

Testo della domanda. **Domanda 8** ***(3 punti).*** **(a)** Quanto vale l'errore standard stimato di $\hat{\pi}$? **(b)** Qual è l'estremo inferiore dell'intervallo di confidenza al 95% per π (con $z = 1{,}96$)? **(c)** E l'estremo superiore? Si vuole ora verificare, al livello del 5%, se la maggioranza è favorevole: $H_0 : \pi = 0{,}50$ contro $H_1 : \pi > 0{,}50$, con valore critico 1,64. **(d)** Quanto vale l'errore standard di $\hat{\pi}$ calcolato sotto H_0, $\text{se}_0 = \sqrt{\pi_0(1-\pi_0)/n}$? **(e)** Quanto vale la statistica $z = (\hat{\pi} - \pi_0)/\text{se}_0$? **(f)** Si decida se rifiutare o non rifiutare H_0.

Richiamo. Una proporzione è la media di variabili di Bernoulli: $\hat{\pi} = x/n$ ha media π e varianza $\pi(1-\pi)/n$, ed è approssimativamente normale. Per l'intervallo di confidenza, che non assume nulla su π, si stima l'errore standard con $\hat{\pi}$: $\hat{\pi} \pm 1{,}96\sqrt{\hat{\pi}(1-\hat{\pi})/n}$. Per un test su $H_0 : \pi = \pi_0$ si calcola invece l'errore standard sotto H_0, $\text{se}_0 = \sqrt{\pi_0(1-\pi_0)/n}$, e $z = (\hat{\pi} - \pi_0)/\text{se}_0$; contro $H_1 : \pi > \pi_0$ si rifiuta se $z > 1{,}64$.

Svolgimento. **Impostazione.** La stima puntuale è $\hat{\pi} = x/n = 486/900 = 0{,}540$.

(a) $\sqrt{\hat{\pi}(1-\hat{\pi})/n} = \sqrt{0{,}540 \times (1-0{,}540)/900} = 0{,}0166$.

(b)–(c) $\hat{\pi} \pm 1{,}96 \times 0{,}0166 = [0{,}507;\ 0{,}573]$. L'intervallo sta tutto sopra 0,50.

(d) $\text{se}_0 = \sqrt{0{,}50 \times (1-0{,}50)/900} = 0{,}0167$.

(e) $z = \dfrac{0{,}540 - 0{,}50}{0{,}0167} = 2{,}40$.

(f) $2{,}40 > 1{,}64$: si rifiuta $H_0 : \pi = 0{,}50$ a favore di $H_1 : \pi > 0{,}50$. Equivalentemente $\hat{\pi}$ supera la soglia $\pi_0 + 1{,}64\,\text{se}_0 = 0{,}5273$.

Errore tipico. Usare nel test l'errore standard stimato 0,0166 al posto di $\text{se}_0 = 0{,}0167$: il test calcola la distribuzione di $\hat{\pi}$ nel mondo in cui H_0 è vera, quindi $\pi = \pi_0$. Un altro errore è usare 1,96 per il test unilaterale: il valore critico unilaterale al 5% è 1,64.

Risposta. **(a)** L'errore standard stimato è 0,0166. **(b)–(c)** L'intervallo di confidenza al 95% per π è [0,507; 0,573]. **(d)** Sotto H_0 l'errore standard è 0,0167. **(e)** $z = 2{,}40$. **(f)** Si rifiuta H_0: al 5% i dati indicano che la maggioranza è favorevole.

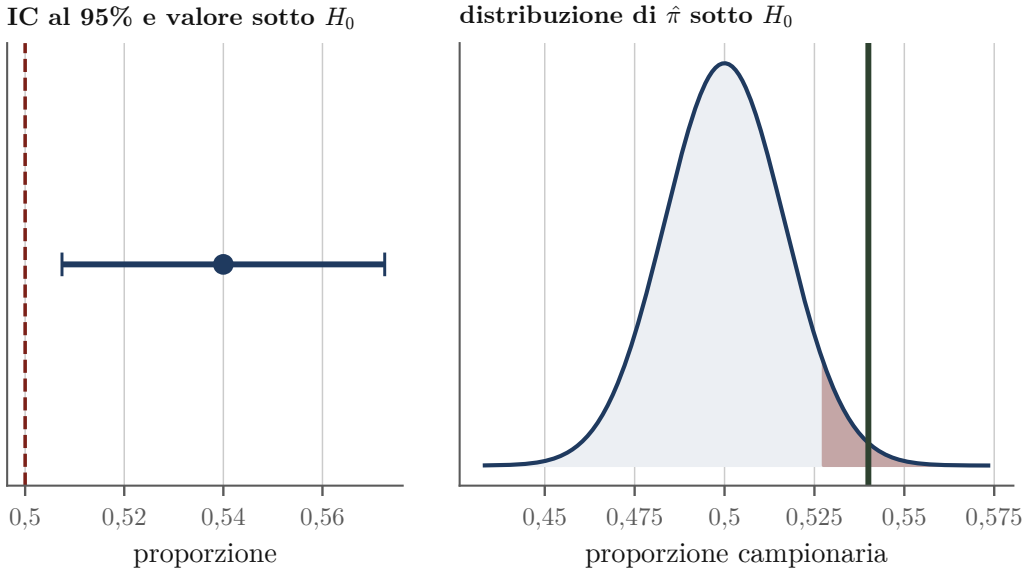


Figura 8.1: A sinistra l'intervallo di confidenza al 95% per π e il valore 0,50 sotto H_0 (linea rossa), fuori dall'intervallo. A destra la distribuzione di $\hat{\pi}$ sotto H_0 con la regione di rifiuto al 5% (in rosso) e la stima osservata 0,540 (linea verde).

9 | Esercizio 9 — Quattro misure: la distribuzione t di Student *(livello intermedio)*

Dati. Una macchina dovrebbe riempire flaconi da $\mu_0 = 50$ ml. Si misura il contenuto di $n = 4$ flaconi scelti a caso e si assume che il contenuto abbia distribuzione normale.

flacone	contenuto (ml)
F1	50,6
F2	54,4
F3	50,9
F4	52,9

Con un campione così piccolo la statistica $t = \dfrac{\bar{y} - \mu_0}{s/\sqrt{n}}$ segue una t di Student con $n - 1$ gradi di libertà. Il quantile della t che lascia il 5% complessivo nelle due code, per il numero di gradi di libertà di questo campione, vale 3,182.

Testo della domanda. **Domanda 9** ***(3 punti).*** **(a)** Quanto vale la statistica t? **(b)** Quanti sono i gradi di libertà? **(c)** Al livello del 5%, si decida se rifiutare o non rifiutare $H_0 : \mu = \mu_0$ contro $H_1 : \mu \neq \mu_0$, con il valore critico della t dato sopra. **(d)** Si decida se rifiutare o non rifiutare H_0 usando, impropriamente, il valore critico normale 1,96. **(e)** Qual è l'estremo inferiore dell'intervallo di confidenza al 95% per μ costruito con il quantile della t? **(f)** E l'estremo superiore?

Richiamo. Se la popolazione è normale e n è piccolo (sotto 25–30 osservazioni), $t = (\bar{y} - \mu_0)/(s/\sqrt{n})$ ha distribuzione t di Student con $n - 1$ gradi di libertà. La t ha code più pesanti della normale: il valore critico è più grande e l'intervallo $\bar{y} \pm t_{n-1}\, s/\sqrt{n}$ è più largo di quello con 1,96. Al crescere di n la t si avvicina alla normale. Con troppo pochi dati la normale rifiuta H_0 troppo spesso.

Svolgimento. **Impostazione.** Dai quattro valori: $\bar{y} = 52{,}200$, $s = 1{,}787$ e $s/\sqrt{n} = 0{,}893$.

(a) $t = \dfrac{52{,}200 - 50}{0{,}893} = 2{,}46.$

(b) Gradi di libertà: $n - 1 = 3$.

(c) $|t| = 2{,}46$ è minore del valore critico 3,182: non si rifiuta H_0.

(d) Con 1,96 si avrebbe $2{,}46 > 1{,}96$ e si rifiuterebbe H_0: conclusione opposta, ma sbagliata con soli quattro dati.

(e)–(f) $\bar{y} \pm 3{,}182 \times 0{,}893 = [49{,}36;\ 55{,}04]$, che contiene 50. Con 1,96 l'intervallo sarebbe [50,45; 53,95], troppo stretto, e lascerebbe fuori 50.

Errore tipico. Usare 1,96 per ogni n. Con 3 gradi di libertà la probabilità che $|t|$ superi 1,96 sotto H_0 è quasi il 15%, non il 5%: usare la normale vorrebbe dire rifiutare per errore in circa un caso su sette in cui H_0 è vera. Un altro errore è contare n invece di $n - 1$ per i gradi di libertà.

Risposta. **(a)** $t = 2{,}46$. **(b)** I gradi di libertà sono 3. **(c)** Non si rifiuta H_0: $2{,}46 < 3{,}182$. **(d)** Con 1,96 si rifiuterebbe H_0, ma il valore critico giusto per quattro dati è 3,182. **(e)–(f)** L'intervallo di confidenza al 95% è [49,36; 55,04] e comprende 50 ml.

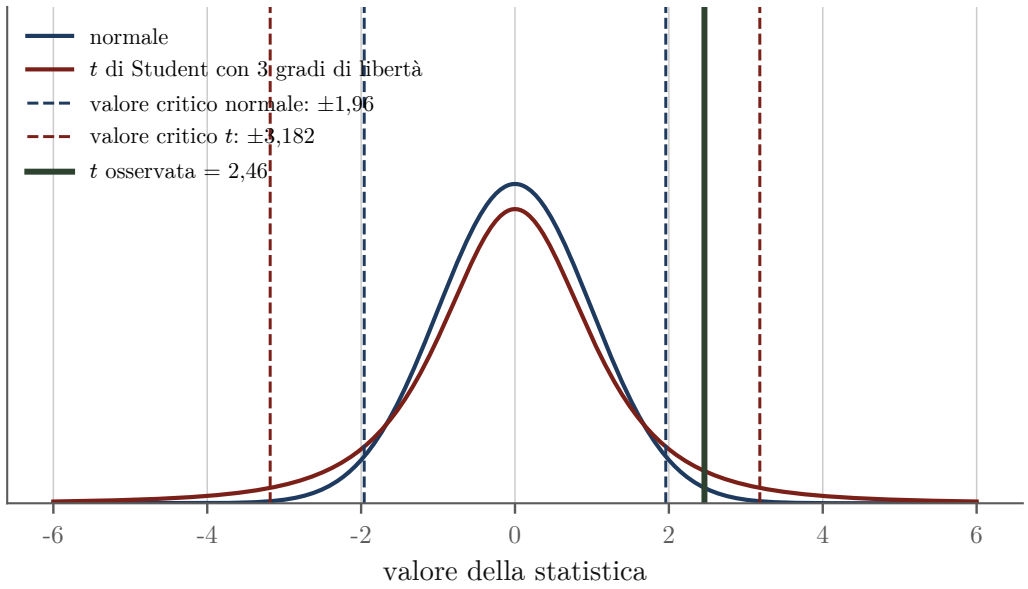


Figura 9.1: Densità della normale e della t di Student con 3 gradi di libertà, con i rispettivi valori critici al 5%. La t osservata, 2,46, supera il valore critico normale ma non quello della t.

10 | Esercizio 10 — Due servizi di assistenza: confronto fra medie *(livello intermedio)*

Dati. Un'azienda confronta il tempo di risposta, in secondi, di due servizi di assistenza, misurato su due campioni indipendenti di richieste.

servizio	n	media $\bar{y}$	dev. std. s
A	100	42,32	8,5
B	81	39,43	8,3

Siano μ_1 e μ_2 le medie dei due servizi. Lo stimatore della differenza è $\bar{Y}_1 - \bar{Y}_2$, con $\mathrm{Var}(\bar{Y}_1 - \bar{Y}_2) = \mathrm{Var}(\bar{Y}_1) + \mathrm{Var}(\bar{Y}_2) - 2\,\mathrm{Cov}(\bar{Y}_1, \bar{Y}_2)$; i campioni sono indipendenti, quindi $\mathrm{Cov}(\bar{Y}_1, \bar{Y}_2) = 0$. L'intervallo di confidenza al 95% di ciascuna media è $\bar{y}_i \pm 1{,}96\, s_i/\sqrt{n_i}$.

Testo della domanda. **Domanda 10** ***(3 punti).*** **(a)** Quanto vale l'errore standard di $\bar{Y}_1 - \bar{Y}_2$, cioè $\sqrt{s_1^2/n_1 + s_2^2/n_2}$? **(b)** Quanto vale la statistica $t = (\bar{y}_1 - \bar{y}_2)/\mathrm{se}$? **(c)** Al livello del 5%, si decida se rifiutare o non rifiutare $H_0 : \mu_1 = \mu_2$ contro $H_1 : \mu_1 \neq \mu_2$ (valore critico 1,96). **(d)** Gli intervalli di confidenza al 95% delle due medie si sovrappongono? Si risponda sì o no. **(e)** Qual è l'estremo inferiore dell'intervallo di confidenza al 95% per $\mu_1 - \mu_2$? **(f)** E l'estremo superiore?

Richiamo. Per due campioni indipendenti $\mathrm{Var}(\bar{Y}_1 - \bar{Y}_2) = \mathrm{Var}(\bar{Y}_1) + \mathrm{Var}(\bar{Y}_2) - 2\,\mathrm{Cov}(\bar{Y}_1, \bar{Y}_2)$ e la covarianza è nulla, quindi $\mathrm{se} = \sqrt{s_1^2/n_1 + s_2^2/n_2}$. Si testa $H_0 : \mu_1 = \mu_2$ con $t = (\bar{y}_1 - \bar{y}_2)/\mathrm{se}$ (rifiuto se $|t| > 1{,}96$) o, in modo equivalente, con l'intervallo $(\bar{y}_1 - \bar{y}_2) \pm 1{,}96\,\mathrm{se}$: si rifiuta se non contiene lo zero. Gli intervalli delle due medie che si sovrappongono sono solo un'indicazione: la differenza può essere significativa anche così, perché $\mathrm{se} < \mathrm{se}_1 + \mathrm{se}_2$.

Svolgimento. **Impostazione.** Dalla tabella: servizio A, $n_1 = 100$, $\bar{y}_1 = 42{,}32$, $s_1 = 8{,}5$; servizio B, $n_2 = 81$, $\bar{y}_2 = 39{,}43$, $s_2 = 8{,}3$. Differenza: $\bar{y}_1 - \bar{y}_2 = 2{,}89$.

(a) $\mathrm{se} = \sqrt{8{,}5^2/100 + 8{,}3^2/81} = \sqrt{0{,}850^2 + 0{,}922^2} = 1{,}254$.

(b) $t = 2{,}89/1{,}254 = 2{,}30$.

(c) $|t| = 2{,}30 > 1{,}96$: si rifiuta $H_0 : \mu_1 = \mu_2$.

(d) Gli intervalli sono [40,65; 43,99] per A e [37,62; 41,24] per B: si sovrappongono, perché il limite inferiore di A, 40,65, sta sotto il limite superiore di B, 41,24.

(e)–(f) $(2{,}89) \pm 1{,}96 \times 1{,}254 = [0{,}43;\ 5{,}35]$: lo zero è fuori, in accordo con (c).

Errore tipico. Concludere dalla sovrapposizione degli intervalli di (d) che le medie non differiscono. Gli intervalli si sovrappongono finché $|\bar{y}_1 - \bar{y}_2| < 1{,}96\,(\mathrm{se}_1 + \mathrm{se}_2) = 3{,}47$, mentre il test rifiuta già quando $|\bar{y}_1 - \bar{y}_2| > 1{,}96\sqrt{\mathrm{se}_1^2 + \mathrm{se}_2^2} = 2{,}46$: fra i due valori gli intervalli si sovrappongono e la differenza è comunque significativa.

Risposta. **(a)** L'errore standard della differenza è 1,254. **(b)** $t = 2{,}30$. **(c)** Si rifiuta H_0: i due tempi medi sono diversi al 5%. **(d)** Sì, gli intervalli delle due medie si sovrappongono, ma non basta per concludere che le medie coincidano. **(e)–(f)** L'intervallo di confidenza al 95% per $\mu_1 - \mu_2$ è [0,43; 5,35] e non contiene lo zero.

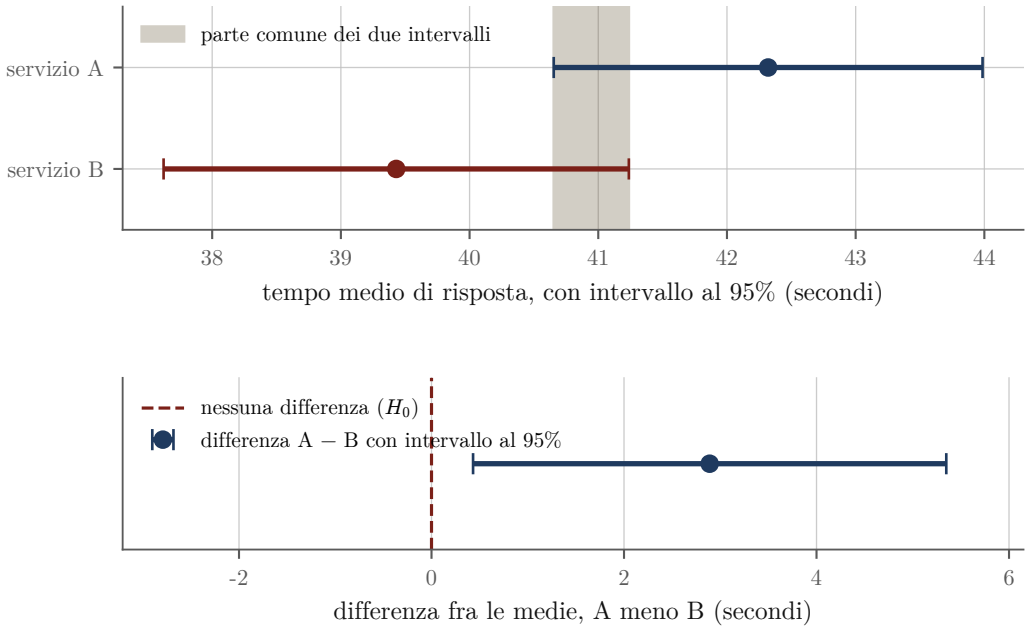


Figura 10.1: In alto gli intervalli di confidenza al 95% delle due medie: si sovrappongono (zona ocra). In basso l'intervallo per la differenza, 2,89: lo zero ne è fuori, quindi il test rifiuta H_0.

11 | Esercizio 11 — Due offerte promozionali: confronto fra proporzioni *(livello intermedio)*

Dati. Una banca propone due offerte, A e B, a due campioni indipendenti di clienti. La tabella riporta il numero di clienti e quanti hanno accettato.

offerta	n	accettazioni x
A	400	139
B	300	73

Sia $\hat\pi_1 = x_1/n_1$ la quota di accettazioni dell'offerta A e $\hat\pi_2 = x_2/n_2$ quella di B. Per il test di $H_0 : \pi_1 = \pi_2$ i due campioni hanno, sotto H_0, la stessa proporzione, stimata con la proporzione combinata $\hat\pi = (x_1 + x_2)/(n_1 + n_2)$; l'errore standard sotto H_0 è $\text{se}_0 = \sqrt{\hat\pi(1-\hat\pi)\,(1/n_1 + 1/n_2)}$ e la statistica è $z = (\hat\pi_1 - \hat\pi_2)/\text{se}_0$. Per l'intervallo di confidenza della differenza, dove non si assume H_0, si usa $\text{se} = \sqrt{\hat\pi_1(1-\hat\pi_1)/n_1 + \hat\pi_2(1-\hat\pi_2)/n_2}$.

Testo della domanda. **Domanda 11** ***(3 punti).*** **(a)** Quanto vale la proporzione combinata $\hat\pi$? **(b)** Quanto vale se_0? **(c)** Quanto vale la statistica z? **(d)** Al livello del 5%, si decida se rifiutare o non rifiutare $H_0 : \pi_1 = \pi_2$ contro $H_1 : \pi_1 \neq \pi_2$ (valore critico 1,96). **(e)** Qual è l'estremo inferiore dell'intervallo di confidenza al 95% per $\pi_1 - \pi_2$? **(f)** E l'estremo superiore?

Richiamo. Le proporzioni sono medie di variabili di Bernoulli. Sotto $H_0 : \pi_1 = \pi_2$ i due campioni provengono dalla stessa popolazione, quindi la proporzione comune si stima con quella combinata $\hat\pi = (x_1 + x_2)/(n_1 + n_2)$ e $\text{se}_0 = \sqrt{\hat\pi(1-\hat\pi)(1/n_1 + 1/n_2)}$; si rifiuta se $|z| > 1{,}96$. L'intervallo per $\pi_1 - \pi_2$ non assume H_0 e usa gli errori standard separati: $\hat\pi_1 - \hat\pi_2 \pm 1{,}96\sqrt{\hat\pi_1(1-\hat\pi_1)/n_1 + \hat\pi_2(1-\hat\pi_2)/n_2}$.

Svolgimento. **Impostazione.** $\hat\pi_1 = 139/400 = 0{,}3475$, $\hat\pi_2 = 73/300 = 0{,}2433$; differenza 0,1042.

(a) $\hat\pi = \dfrac{139 + 73}{400 + 300} = 0{,}3029.$

(b) $\text{se}_0 = \sqrt{0{,}3029 \times (1 - 0{,}3029) \times (1/400 + 1/300)} = 0{,}0351.$

(c) $z = \dfrac{0{,}1042}{0{,}0351} = 2{,}97$.

(d) $|z| = 2{,}97 > 1{,}96$: si rifiuta $H_0 : \pi_1 = \pi_2$.

(e)–(f) L'errore standard senza H_0 è 0,0344 e l'intervallo è $(0{,}1042) \pm 1{,}96 \times 0{,}0344 = [0{,}037;\ 0{,}172]$: lo zero è fuori, in accordo con (d).

Errore tipico. Calcolare se_0 come per un solo campione, $\sqrt{\hat\pi(1-\hat\pi)/(n_1+n_2)}$ con $n_1+n_2 = 700$, invece di $\sqrt{\hat\pi(1-\hat\pi)(1/n_1+1/n_2)}$: l'errore standard verrebbe 0,0174 e la statistica 6,00, molto più grande. La varianza della differenza è la somma delle varianze dei due campioni. Un altro errore è costruire l'intervallo di (e)–(f) con se_0: l'intervallo non può assumere $\pi_1 = \pi_2$ e usa gli errori standard separati. Infine, la proporzione combinata va pesata con le numerosità e non è la media semplice delle due quote.

Risposta. **(a)** $\hat\pi = 0{,}3029$. **(b)** $\text{se}_0 = 0{,}0351$. **(c)** $z = 2{,}97$. **(d)** Si rifiuta H_0: le due offerte hanno quote di accettazione diverse al 5%. **(e)–(f)** L'intervallo di confidenza al 95% per $\pi_1 - \pi_2$ è [0,037; 0,172] e non contiene lo zero.

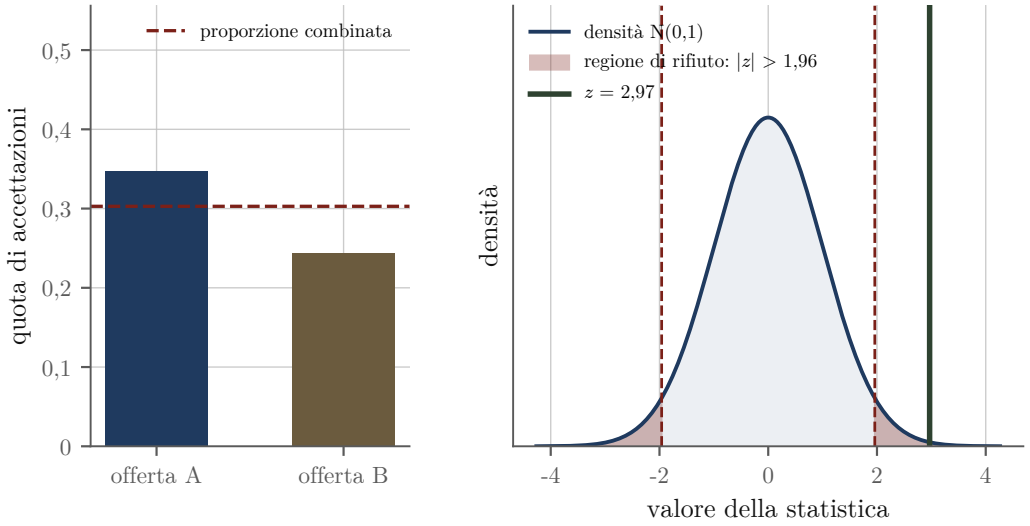


Figura 11.1: A sinistra le due quote di accettazione e la proporzione combinata. A destra la distribuzione di z sotto H_0 con la regione di rifiuto al 5% e la statistica osservata, 2,97.

12 | Esercizio 12 — Prima e dopo il corso: dati appaiati e covarianza *(livello appello)*

Dati. Per $n = 36$ operai si è misurata la produttività (pezzi all'ora) prima e dopo un corso di formazione. Le due misure riguardano gli stessi operai (dati appaiati). Le statistiche descrittive sono nella tabella; la covarianza campionaria fra le due misure vale 45,70. Varianze e covarianza usano lo stesso divisore, $n - 1$.

	media	dev. std.
prima	49,8	7,24
dopo	51,3	6,88

Sia $D = \text{dopo} - \text{prima}$, con media $\bar{d} = \bar{y}_{\text{dopo}} - \bar{y}_{\text{prima}}$ e varianza $s_d^2 = s_{\text{dopo}}^2 + s_{\text{prima}}^2 - 2\, s_{\text{dopo,prima}}$. La statistica è $t = \bar{d}/(s_d/\sqrt{n})$, approssimativamente $N(0,\,1)$ perché n è grande.

Testo della domanda. **Domanda 12** ***(4 punti).*** **(a)** Quanto vale $\bar{d}$? **(b)** Quanto vale il coefficiente di correlazione fra le due misure? **(c)** Quanto vale la deviazione standard s_d delle differenze? **(d)** Quanto vale la statistica t? **(e)** Al livello del 5%, si decida se rifiutare o non rifiutare $H_0 : \mu_D = 0$ contro $H_1 : \mu_D > 0$ (il corso aumenta la produttività), con valore critico 1,64. **(f)** Un collega tratta le due misure come campioni indipendenti, cioè pone la covarianza uguale a zero, e calcola la statistica t con $s_d^2 = s_{\text{dopo}}^2 + s_{\text{prima}}^2$: quanto vale la sua t? **(g)** Con la statistica di (f), si decida se rifiutare o non rifiutare H_0 contro $H_1 : \mu_D > 0$ (valore critico 1,64).

Richiamo. Con dati appaiati si lavora sulle differenze $d_i = \text{dopo}_i - \text{prima}_i$: la media delle differenze è la differenza delle medie e la loro varianza è $s_d^2 = s_{\text{dopo}}^2 + s_{\text{prima}}^2 - 2\, s_{\text{dopo,prima}}$, dalla varianza di una combinazione lineare. La covarianza positiva, perché le due misure riguardano lo stesso operaio, riduce la varianza delle differenze e quindi l'errore standard $s_d/\sqrt{n}$. Il coefficiente di correlazione è $r = s_{xy}/(s_x\, s_y)$. Trattare le due misure come indipendenti, cioè ignorare la covarianza, usa una varianza troppo grande e fa perdere potenza al test.

Svolgimento. **Impostazione.** Dalla tabella: prima $\bar{y} = 49{,}8$, $s = 7{,}24$; dopo $\bar{y} = 51{,}3$, $s = 6{,}88$; covarianza 45,70.

(a) $\bar{d} = 51{,}3 - 49{,}8 = 1{,}50$.

(b) $r = \dfrac{45{,}70}{7{,}24 \times 6{,}88} = 0{,}917$: le due misure sono fortemente correlate.

(c) $s_d^2 = 52{,}4176 + 47{,}3344 - 2 \times 45{,}70 = 8{,}352$, quindi $s_d = 2{,}890$.

(d) $t = \dfrac{1{,}50}{2{,}890/\sqrt{36}} = \dfrac{1{,}50}{0{,}482} = 3{,}11$.

(e) $3{,}11 > 1{,}64$: si rifiuta $H_0 : \mu_D = 0$ a favore di $H_1 : \mu_D > 0$.

(f) Con Cov $= 0$ si avrebbe $s_d^2 = 52{,}4176 + 47{,}3344 = 99{,}752$, errore standard 1,665 e $t = 1{,}50/1{,}665 = 0{,}90$.

(g) $0{,}90 < 1{,}64$: con quella statistica non si rifiuterebbe H_0.

Errore tipico. Confrontare le due medie come se venissero da due campioni indipendenti, con se $= \sqrt{(s^2_{\text{dopo}} + s^2_{\text{prima}})/n} = 1{,}665$: si ignora il termine $-2\, s_{\text{dopo,prima}} = 91{,}40$ con il segno meno e l'errore standard viene \$3{,}5 volte quello giusto (0,482). La conclusione si ribalta: l'aumento sembra non significativo mentre la produttività media è aumentata in modo significativo. Attribuirlo al corso richiede di escludere altre cause, e un confronto prima/dopo senza gruppo di controllo non lo permette. Con dati appaiati la variabilità fra operai si cancella nelle differenze.

Risposta. **(a)** $\bar{d} = 1{,}50$. **(b)** $r = 0{,}917$. **(c)** $s_d = 2{,}890$. **(d)** $t = 3{,}11$. **(e)** Si rifiuta H_0: al 5% la produttività media è aumentata in modo significativo; attribuirlo al corso richiede di escludere altre cause, e un confronto prima/dopo senza gruppo di controllo non lo permette. **(f)** Ignorando la covarianza si ottiene $t = 0{,}90$. **(g)** Con quella statistica non si rifiuta H_0: è la conclusione sbagliata, dovuta a un errore standard gonfiato.

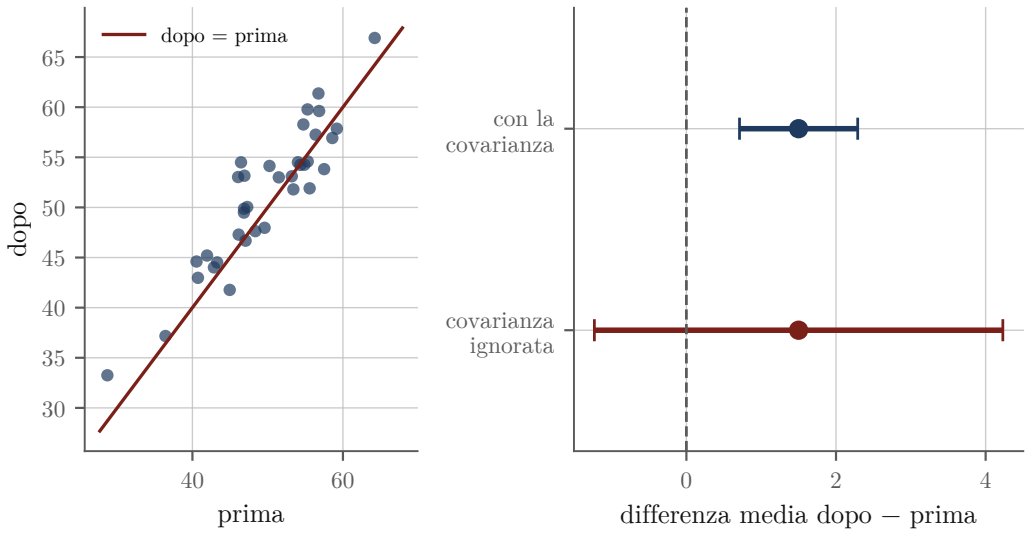


Figura 12.1: A sinistra le coppie (prima, dopo) stanno vicino alla retta tratteggiata e tendono a stare sopra: le due misure sono molto correlate. A destra la differenza media 1,50 con l'intervallo $\bar{d} \pm 1{,}64\,\text{se}$: con la covarianza l'estremo inferiore sta sopra lo zero (rifiuto), ignorandola l'intervallo comprende lo zero.

13 | Esercizio 13 — Errore e media condizionale: l'incorrelazione non basta *(livello appello)*

Dati. Si considera il modello $Y = \alpha + \beta X + \epsilon$ con $\alpha = 10$ e $\beta = 3$ (valori veri). La variabile X ha la distribuzione della tabella. Per l'errore ϵ si confrontano due modelli, P e Q, che differiscono solo per la media condizionale $E[\epsilon \mid X = x]$.

x	$P(X = x)$	$E[\epsilon \mid X = x]$ modello P	$E[\epsilon \mid X = x]$ modello Q
1	0,10	1,40	−0,80
2	0,20	−0,10	−0,40
3	0,40	−0,60	0,00
4	0,20	−0,10	0,40
5	0,10	1,40	0,80

Le medie condizionali permettono di calcolare $E[\epsilon] = \sum_x P(X = x)\, E[\epsilon \mid X = x]$ e $E[X\epsilon] = \sum_x x\, P(X = x)\, E[\epsilon \mid X = x]$; poi $\mathrm{Cov}(X, \epsilon) = E[X\epsilon] - E[X]\, E[\epsilon]$. La pendenza della retta di regressione nella popolazione è $\mathrm{Cov}(X, Y)/\mathrm{Var}(X)$.

Testo della domanda. **Domanda 13** ***(4 punti).*** Nel modello P: **(a)** quanto vale $E[\epsilon]$? **(b)** Quanto vale $\mathrm{Cov}(X, \epsilon)$? **(c)** L'errore ha media condizionale nulla, $E[\epsilon \mid X = x] = 0$ per ogni x? Si risponda sì o no. **(d)** Di quanto varia $E[Y \mid X]$ quando X passa da 3 a 4? Nel modello Q: **(e)** quanto vale $\mathrm{Cov}(X, \epsilon)$? **(f)** Quanto vale la differenza $\mathrm{Cov}(X, Y)/\mathrm{Var}(X) - \beta$?

Richiamo. $E[\epsilon \mid X = x]$ è la media dell'errore fra le unità con $X = x$. Se $E[\epsilon \mid X = x] = 0$ per ogni x, allora $E[\epsilon] = 0$, $\mathrm{Cov}(X, \epsilon) = 0$ e $E[Y \mid X] = \alpha + \beta X$, quindi $\Delta E[Y \mid X] = \beta\, \Delta X$. Non vale il contrario: un errore può essere incorrelato con X ed avere comunque media condizionale non nulla (dipendenza non lineare). Allora $E[Y \mid X = x] = \alpha + \beta x + E[\epsilon \mid X = x]$ non è la retta e $\Delta E[Y \mid X] = \beta\, \Delta X + \Delta E[\epsilon \mid X]$. Se invece $\mathrm{Cov}(X, \epsilon) \neq 0$, la pendenza della regressione è $\mathrm{Cov}(X, Y)/\mathrm{Var}(X) = \beta + \mathrm{Cov}(X, \epsilon)/\mathrm{Var}(X) \neq \beta$.

Svolgimento. **Impostazione.** Dalla distribuzione di X: $E[X] = 3{,}0$ e $\mathrm{Var}(X) = 1{,}20$.

(a) $E[\epsilon] = (0{,}10)(1{,}40) + (0{,}20)(-0{,}10) + (0{,}40)(-0{,}60) + (0{,}20)(-0{,}10) + (0{,}10)(1{,}40) = 0{,}00$.

(b) $E[X\epsilon] = \sum_x x\, P(X = x)\, E[\epsilon \mid X = x] = 0{,}00$, quindi $\mathrm{Cov}(X, \epsilon) = 0{,}00 - 3{,}0 \times 0{,}00 = 0{,}00$.

(c) No: le medie condizionali valgono 1,40, −0,10, −0,60, −0,10, 1,40, non sono tutte nulle. Covarianza nulla non implica media condizionale nulla: nel modello P l'errore dipende da X attraverso $(X - 3{,}0)^2$, una relazione non lineare che la covarianza non vede.

(d) $E[Y \mid X = x] = \alpha + \beta x + E[\epsilon \mid X = x]$. Per $x = 3$ vale 18,40 e per $x = 4$ vale 21,90: la variazione è $\beta + (E[\epsilon \mid X = 4] - E[\epsilon \mid X = 3]) = 3 + (-0{,}10 - (-0{,}60)) = 3{,}50$, e non $\beta = 3$.

(e) Nel modello Q $E[\epsilon] = 0{,}00$ e $E[X\epsilon] = 0{,}480$, quindi $\mathrm{Cov}(X, \epsilon) = 0{,}480$.

(f) $\dfrac{\mathrm{Cov}(X, Y)}{\mathrm{Var}(X)} - \beta = \dfrac{\mathrm{Cov}(X, \epsilon)}{\mathrm{Var}(X)} = \dfrac{0{,}480}{1{,}20} = 0{,}400$: la pendenza della regressione vale 3,400 e non $\beta = 3$.

Errore tipico. Concludere dalla covarianza nulla del modello P che $E[\epsilon \mid X] = 0$ e quindi che β misuri ovunque l'effetto di X su Y: l'incorrelazione è solo una conseguenza di $E[\epsilon \mid X] = 0$, non equivale ad essa. Nel modello P la pendenza della regressione è ancora 3,00, ma l'effetto di un passo di X cambia con x. Nel modello Q, invece, anche la pendenza è sbagliata di 0,400.

Risposta. **(a)** Nel modello P $E[\epsilon] = 0{,}00$. **(b)** $\mathrm{Cov}(X, \epsilon) = 0{,}00$. **(c)** No: l'errore ha medie condizionali non nulle, benché incorrelato con X. **(d)** $E[Y \mid X]$ varia di 3,50, non di $\beta = 3$. **(e)** Nel modello Q $\mathrm{Cov}(X, \epsilon) = 0{,}480$. **(f)** La pendenza della regressione supera β di 0,400.

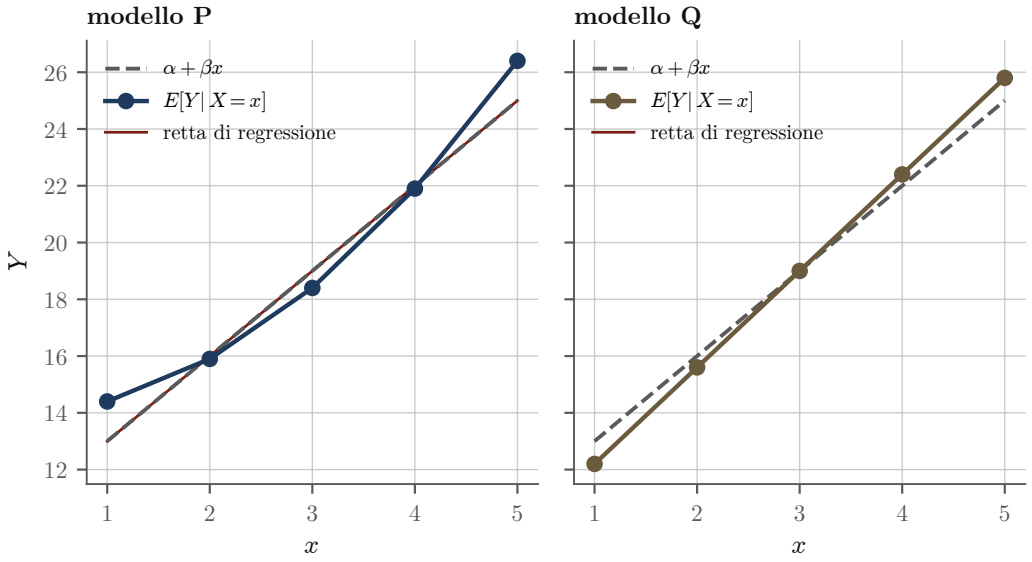


Figura 13.1: Medie condizionali $E[Y \mid X = x]$ (punti) contro la retta $\alpha + \beta x$ (tratteggio grigio) e la retta di regressione (rossa). Nel modello P i punti formano una curva attorno alla retta, che ha però pendenza β: covarianza nulla ma media condizionale non nulla. Nel modello Q i punti stanno su una retta più ripida, di pendenza 3,400.

14 | Esercizio 14 — Alunni della stessa classe: osservazioni non indipendenti *(livello appello)*

Dati. Un insegnante vuole sapere se il punteggio medio μ della sua scuola in un test differisce dalla media nazionale $\mu_0 = 60$. Misura $n = 36$ alunni della stessa classe, invece di alunni scelti a caso in tutta la scuola. Ogni punteggio Y_i ha deviazione standard $\sigma = 10$ e due alunni qualsiasi della stessa classe hanno punteggi con correlazione $\rho = 0{,}10$ (effetto classe). La media del campione è $\bar{y} = 64{,}3$. Si consideri $\bar{Y}$ approssimativamente normale.

Testo della domanda. **Domanda 14** ***(4 punti).*** **(a)** Se i punteggi fossero un campione casuale semplice, cioè indipendenti, quanto varrebbe l'errore standard di $\bar{Y}$, $\sigma/\sqrt{n}$? **(b)** Con la correlazione ρ, $\bar{Y}$ è ancora uno stimatore corretto di μ? Si risponda sì o no. **(c)** Quanto vale $\mathrm{Var}(Y_1 + \cdots + Y_n)$ con correlazione ρ fra ogni coppia di alunni? **(d)** Quanto vale l'errore standard di $\bar{Y}$ con la correlazione? **(e)** Al livello del 5%, con $H_0 : \mu = \mu_0$ contro $H_1 : \mu \neq \mu_0$ e valore critico 1,96, si decida se rifiutare o non rifiutare H_0 usando l'errore standard di (a). **(f)** Si decida se rifiutare o non rifiutare H_0, alle stesse condizioni, usando l'errore standard di (d).

Richiamo. In un campione casuale semplice le Y_i sono indipendenti, $\mathrm{Cov}(Y_i, Y_j) = 0$, e $\mathrm{Var}(\bar{Y}) = \sigma^2/n$. Se ogni coppia di osservazioni ha correlazione ρ, $\mathrm{Cov}(Y_i, Y_j) = \rho\,\sigma^2$ e $\mathrm{Var}(Y_1 + \cdots + Y_n) = \sum_i \mathrm{Var}(Y_i) + \sum_{i \neq j} \mathrm{Cov}(Y_i, Y_j) = n\sigma^2 + n(n-1)\rho\sigma^2 = n\sigma^2\,[1 + (n-1)\rho]$. Dunque $\mathrm{Var}(\bar{Y}) = \frac{\sigma^2}{n}\,[1 + (n-1)\rho]$. La media resta corretta, $E[\bar{Y}] = \mu$, perché il valore atteso non dipende dalle covarianze, ma l'errore standard cresce di $\sqrt{1 + (n-1)\rho}$: osservazioni correlate valgono meno di osservazioni indipendenti, e trattarle da indipendenti fa rifiutare troppo.

Svolgimento. **Impostazione.** Si confrontano la varianza della somma sotto indipendenza e con correlazione ρ, poi si ripete il test con i due errori standard.

(a) $\sigma/\sqrt{n} = 10/\sqrt{36} = 1{,}667$.

(b) $E[\bar{Y}] = \dfrac{1}{n}\sum_i E[Y_i] = \mu$: sì, la correlazione non incide sul valore atteso.

(c) I termini con $i \neq j$ sono $n(n-1) = 1260$, ciascuno con covarianza $\rho\sigma^2 = 10$. Quindi $\mathrm{Var}(Y_1 + \cdots + Y_n) = 36 \times 10^2 + 1260 \times 10 = 16200$, contro 3600 con osservazioni indipendenti.

(d) se $= \sqrt{\mathrm{Var}(\bar{Y})} = \sqrt{16200}/36 = 3{,}536$, cioè 2,12 volte l'errore standard di (a): $\sqrt{1 + (n-1)\rho} = \sqrt{4{,}50}$.

(e) $t = (64{,}3 - 60)/1{,}667 = 2{,}58$, in valore assoluto maggiore di 1,96: si rifiuta H_0.

(f) $t = (64{,}3 - 60)/3{,}536 = 1{,}22$, in valore assoluto minore di 1,96: non si rifiuta H_0. L'intervallo di confidenza al 95% è [57,37; 71,23] e contiene 60, mentre con l'errore standard ingenuo sarebbe [61,03; 67,57].

Errore tipico. Usare $\sigma/\sqrt{n}$ come se gli alunni fossero un campione casuale semplice. La correlazione non distorce $\bar{Y}$ ma ne cambia la varianza: l'errore standard ingenuo è 2,12 volte troppo piccolo e porta a rifiutare H_0 per un effetto che può essere solo l'effetto classe. Le 36 osservazioni correlate valgono come 8,0 osservazioni indipendenti.

Risposta. **(a)** L'errore standard con osservazioni indipendenti sarebbe 1,667. **(b)** Sì: $\bar{Y}$ resta corretto. **(c)** $\mathrm{Var}(Y_1 + \cdots + Y_n) = 16200$. **(d)** L'errore standard è 3,536. **(e)** Con l'errore standard ingenuo si rifiuta H_0. **(f)** Con quello corretto non si rifiuta H_0: la differenza dalla media nazionale non è significativa.

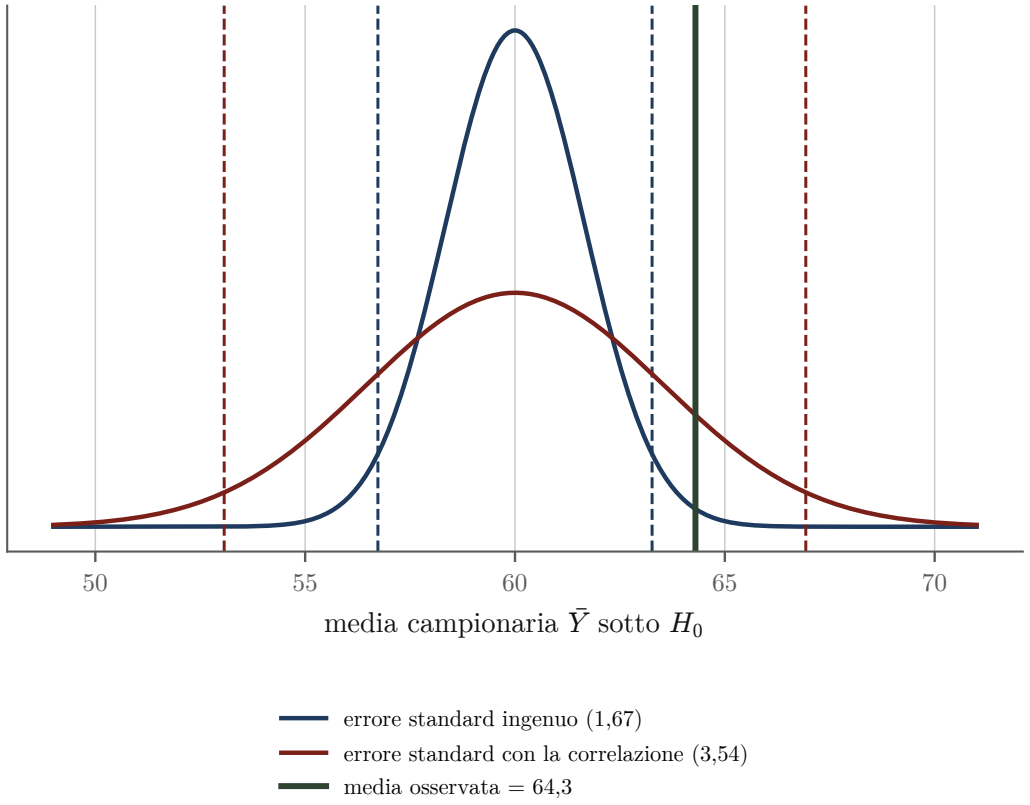


Figura 14.1: Distribuzione di $\bar{Y}$ sotto H_0 con l'errore standard ingenuo (blu) e con quello corretto per la correlazione (rosso); le linee tratteggiate sono $\mu_0 \pm 1{,}96\,\mathrm{se}$. La media osservata, 64,3, sta fuori dalle linee blu e dentro quelle rosse.