Università Ca' Foscari Venezia

Dipartimento di Economia

Laurea Magistrale in
Economia e Finanza

Modulo 01 — Introduzione e causalità

Soluzioni svolte e commentate

Appunti di:
Silvio Angelo Baratto Roldan

Codice insegnamento:
EM0004

Contenuto:
6 esercizi

Esercizi sintetici costruiti a fini di studio sul modello dei veri appelli e sulla teoria del corso (Econometria EM0004, prof. Davide Raggi). Non sono materiale ufficiale del docente.

Indice

1 Esercizio 1 — Palestra aziendale e assenze per malattia *(livello base)* 1

2 Esercizio 2 — Che tipo di dati sono? *(livello base)* 3

3 Esercizio 3 — Polizia e criminalità *(livello intermedio)* 6

4 Esercizio 4 — La spesa riportata male *(livello intermedio)* 9

5 Esercizio 5 — Gelati e incidenti in acqua *(livello d'appello)* 12

6 Esercizio 6 — Un fondo e il CAPM *(livello d'appello)* 15

1 | Esercizio 1 — Palestra aziendale e assenze per malattia *(livello base)*

Dati. In un'azienda con $n = 1096$ dipendenti si è rilevato, in un solo momento, se ciascuno è iscritto alla palestra aziendale e se nell'ultimo anno ha fatto almeno un'assenza per malattia. Non si sa quando i dipendenti si siano iscritti. Si può parlare di causalità $X \to Y$ solo se valgono contemporaneamente tre criteri: (1) c'è associazione fra le variabili; (2) c'è un ordine logico o temporale, con la causa che precede l'effetto; (3) sono escluse le spiegazioni alternative. I conteggi sono i seguenti.

	assenza: sì	assenza: no	totale
iscritti	75	342	417
non iscritti	232	447	679
totale	307	789	1096

Testo della domanda. **Domanda 1** ***(3 punti).*** **(a)** Quale percentuale degli iscritti ha fatto almeno un'assenza? **(b)** Quale percentuale dei non iscritti? **(c)** Si calcoli la differenza «percentuale degli iscritti meno percentuale dei non iscritti», in punti percentuali. **(d)** Il criterio (1), l'associazione, è soddisfatto, giudicando dal solo confronto delle due percentuali (senza test statistico)? Si risponda sì o no. **(e)** I dati permettono di stabilire che l'iscrizione precede le assenze, cioè che il criterio (2) è soddisfatto? Si risponda sì o no. **(f)** Si può concludere che l'iscrizione alla palestra riduce le assenze per malattia? Si risponda sì o no.

Richiamo. In una tabella di contingenza si confrontano le percentuali di riga: per un gruppo con n_g soggetti di cui k_g hanno l'evento, la percentuale è $100 \cdot k_g/n_g$. Confrontare i conteggi sarebbe sbagliato quando i gruppi hanno numerosità diverse. Si può parlare di causalità $X \to Y$ solo se valgono contemporaneamente tre criteri: associazione, ordine logico o temporale, esclusione di spiegazioni alternative. L'associazione è un criterio statistico e simmetrico: la correlazione fra X e Y è la stessa di quella fra Y e X, quindi non dice quale variabile preceda l'altra. Se il verso del legame non è chiaro si parla di causalità inversa.

Svolgimento. **Impostazione.** Le prime tre domande sono percentuali di riga; le ultime tre applicano i tre criteri.

(a) $100 \times \dfrac{75}{417} = 18{,}0\%$.

(b) $100 \times \dfrac{232}{679} = 34{,}2\%$.

(c) $18{,}0 - 34{,}2 = -16{,}2$ punti percentuali: fra gli iscritti le assenze sono meno frequenti.

(d) Sì. Le due percentuali sono diverse e la differenza, $-16{,}2$ punti, è ampia: il criterio (1) è soddisfatto.

(e) No. L'informazione è raccolta in un solo momento e non si sa quando i dipendenti si siano iscritti, quindi non si può stabilire che l'iscrizione preceda le assenze. Anzi, anche il verso opposto ha senso logico: chi sta spesso male difficilmente si iscrive in palestra (causalità inversa). Il criterio (2) non è soddisfatto.

(f) No. Dei tre criteri è soddisfatto soltanto il primo: l'ordine non è chiaro e non sono escluse spiegazioni alternative, per esempio l'età o la mansione, che possono influire sia sull'iscrizione sia sulle assenze.

Errore tipico. Confrontare i conteggi, 75 assenti fra gli iscritti contro 232 fra i non iscritti, invece delle percentuali: i due gruppi hanno numerosità diverse (417 e 679) e il confronto dei conteggi esagera la differenza. L'errore più grave è concludere dall'associazione che la palestra riduca le assenze.

Risposta. **(a)** Fra gli iscritti ha fatto almeno un'assenza il 18,0%. **(b)** Fra i non iscritti il 34,2%. **(c)** La differenza è di $-16{,}2$ punti percentuali. **(d)** Sì: c'è associazione. **(e)** No: i dati non dicono se l'iscrizione venga prima delle assenze, e potrebbe valere il verso opposto. **(f)** No: l'associazione è solo il primo dei tre criteri di causalità.

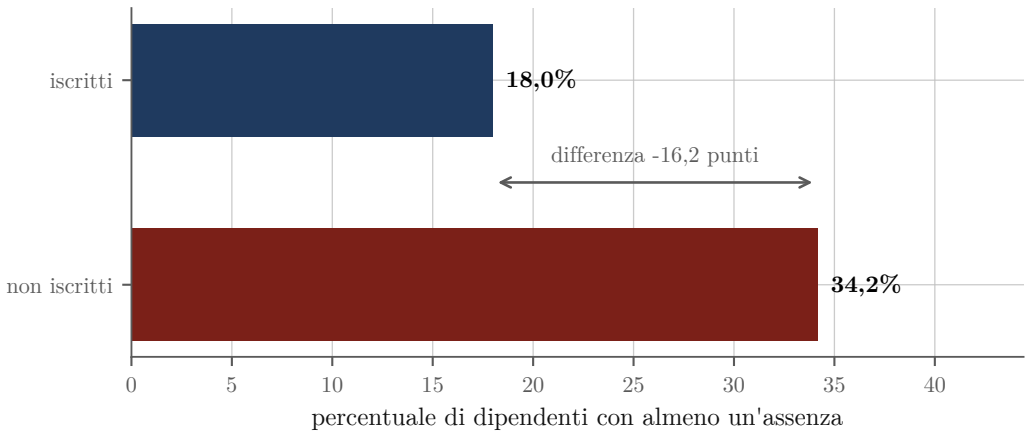


Figura 1.1: Percentuale di dipendenti con almeno un'assenza, per iscritti e non iscritti: la differenza fra le barre è l'associazione, il primo criterio. Il grafico non dice nulla sull'ordine fra iscrizione e assenze.

2 | Esercizio 2 — Che tipo di dati sono? *(livello base)*

Dati. I dati si dicono *cross section* se osservano molti soggetti in un solo istante, *serie storica* se osservano un solo soggetto in istanti successivi, *panel* se osservano gli stessi soggetti in più istanti. Quattro insiemi di dati sono riportati con una riga per ogni coppia soggetto-periodo.

Dataset A, fatturato di alcune imprese (milioni di euro):

soggetto	periodo	fatturato
impresa 1	2023	24,2
impresa 2	2023	37,7
impresa 3	2023	4,1
impresa 4	2023	5,4
impresa 5	2023	33,0

Dataset B, prezzo di chiusura mensile di un titolo (euro):

soggetto	periodo	prezzo
titolo	gen 2024	60,2
titolo	feb 2024	59,4
titolo	mar 2024	58,7
titolo	apr 2024	58,0
titolo	mag 2024	56,2
titolo	giu 2024	57,1

Dataset C, investimenti annui (milioni di euro). La tabella ne mostra un estratto: il dataset completo contiene $N = 187$ imprese osservate per $T = 9$ anni consecutivi, senza dati mancanti.

soggetto	periodo	investimenti
impresa 1	2019	4,7
impresa 1	2020	7,1
impresa 1	2021	2,8
impresa 2	2019	2,3
impresa 2	2020	2,3
impresa 2	2021	7,8
impresa 3	2019	3,8

soggetto	periodo	investimenti
impresa 3	2020	6,0
impresa 3	2021	2,9

Dataset D, prezzo di vendita (migliaia di dollari) delle case vendute in un comune nel 1978 e nel 1981, ciascuna con il proprio codice:

soggetto	periodo	prezzo
casa 1	1978	95,2
casa 2	1978	76,1
casa 3	1978	103,9
casa 4	1981	132,3
casa 5	1981	73,7
casa 6	1981	130,8

Testo della domanda. **Domanda 2** ***(3 punti).*** **(a)** Il dataset A è una serie storica? Si risponda sì o no. **(b)** Il dataset B è una serie storica? Si risponda sì o no. **(c)** Il dataset C è un panel? Si risponda sì o no. **(d)** Il dataset D è un panel? Si risponda sì o no. **(e)** Quante osservazioni, cioè quante righe, contiene il dataset C completo? **(f)** Se del dataset C si tenessero soltanto le righe di un'impresa, i dati sarebbero un panel? Si risponda sì o no.

Richiamo. Si guardano due cose: quanti soggetti e quanti periodi compaiono, e se gli stessi soggetti ricompaiono in periodi diversi. *Cross section*: molti soggetti in un solo periodo. *Serie storica*: un solo soggetto in molti periodi, e il tempo ne definisce l'ordine. *Panel*: gli stessi soggetti osservati in più periodi, con una doppia dimensione, soggetto e tempo; se i soggetti sono N e i periodi T, senza dati mancanti le osservazioni sono $N \times T$. Se in ogni periodo si osservano soggetti diversi non è un panel, ma una sequenza di cross section.

Svolgimento. **Impostazione.** Per ogni dataset si contano soggetti e periodi e si controlla se i soggetti si ripetono.

(a) Le imprese del dataset A compaiono tutte nello stesso anno: è una cross section, non una serie storica. No.

(b) Il dataset B ha un solo soggetto, il titolo, osservato in mesi successivi: è una serie storica. Sì.

(c) Le stesse imprese ricompaiono in tutti gli anni: il dataset C è un panel. Sì.

(d) Nel 1978 e nel 1981 i codici delle case sono diversi: nessuna casa è osservata due volte, quindi il dataset D è una cross section ripetuta e non un panel. No.

(e) Con $N = 187$ imprese e $T = 9$ anni, senza dati mancanti, le righe sono $N \times T = 187 \times 9 = 1683$.

(f) Con una sola impresa il soggetto è uno e il tempo definisce l'ordine delle osservazioni: i dati sono una serie storica, non un panel. No.

Errore tipico. Chiamare panel il dataset D perché copre due anni. Un panel richiede di osservare gli stessi soggetti in più periodi, come fa il dataset C con le imprese; qui in ciascun anno c'è un campione diverso di case. Un altro errore è sommare invece di moltiplicare: le osservazioni di un panel sono $N \times T$, non $N + T$.

Risposta. **(a)** No: A è una cross section. **(b)** Sì: B è una serie storica. **(c)** Sì: C è un panel. **(d)** No: D è una cross section ripetuta, perché le case del 1978 e del 1981 sono diverse. **(e)** Il dataset C completo ha 1683 osservazioni. **(f)** No: con una sola impresa è una serie storica.

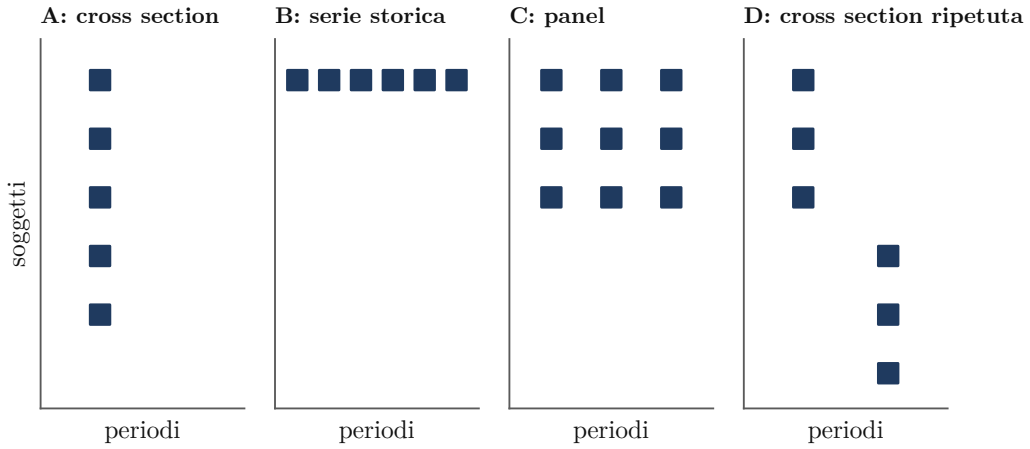


Figura 2.1: Ogni dataset come griglia di soggetti (righe) per periodi (colonne): un quadrato è una coppia osservata. Una colonna sola è una cross section, una riga sola una serie storica, una griglia in cui gli stessi soggetti ricompaiono è un panel; in D nessun soggetto si ripete.

3 | Esercizio 3 — Polizia e criminalità *(livello intermedio)*

Dati. Su $n = 120$ città si osservano `reati` (reati ogni mille abitanti) e `poliziotti` (poliziotti ogni mille abitanti). Si è stimata la regressione semplice di `reati` su `poliziotti`

$$\text{reati} = \beta_0 + \beta_1 \,\text{poliziotti} + \epsilon,$$

	coefficiente	errore std.	rapporto t	p-value
const	10,1436	2,29837	4,413	2,26e-05
poliziotti	15,2926	1,05473	14,5	5,58e-28

n = 120; R^2 = 0,640489; SSR = 4250,06

e quella con i ruoli scambiati,

$$\text{poliziotti} = \gamma_0 + \gamma_1 \,\text{reati} + u.$$

	coefficiente	errore std.	rapporto t	p-value
const	0,335995	0,12609	2,665	0,0088
reati	0,0418822	0,00288861	14,5	5,58e-28

n = 120; R^2 = 0,640489; SSR = 11,6397

Testo della domanda. **Domanda 3** ***(3 punti).*** Si usi il valore critico 1,96. **(a)** Al livello del 5%, si decida se rifiutare o non rifiutare $H_0 : \beta_1 = 0$ contro $H_1 : \beta_1 \neq 0$. **(b)** Se si leggesse la prima regressione in senso causale, di quanti reati ogni mille abitanti varierebbe in media il numero di reati per un aumento di 0,5 poliziotti ogni mille abitanti? **(c)** Al livello del 5%, si decida se rifiutare o non rifiutare $H_0 : \gamma_1 = 0$ contro $H_1 : \gamma_1 \neq 0$. **(d)** Le due regressioni hanno lo stesso rapporto t per la pendenza e lo stesso R^2? Si risponda sì o no. **(e)** Dalla sola associazione fra le due variabili si può stabilire quale è la causa e quale l'effetto? Si risponda sì o no.

Richiamo. In una regressione semplice $y = \beta_0 + \beta_1 x + \epsilon$ una variazione Δx comporta $\Delta y = \beta_1 \Delta x$. Il rapporto $t = \hat{\beta}_1 / \widehat{\text{se}}(\hat{\beta}_1)$ e l'R^2 dipendono dai dati solo attraverso la correlazione campionaria r fra x e y, $t = r\sqrt{n-2}/\sqrt{1-r^2}$ e $R^2 = r^2$, che è simmetrica: scambiando i ruoli di x e di y restano uguali t e R^2, mentre le pendenze cambiano e il loro prodotto è R^2. Una correlazione non dice quale variabile sia la causa. Se non è chiaro se x influenzi y o il contrario si ha causalità inversa: si crea un riferimento circolare e il regressore risulta correlato con l'errore, per cui la stima del coefficiente è problematica.

Svolgimento. **Impostazione.** Le due regressioni usano gli stessi dati con gli assi scambiati; si confrontano le loro statistiche e si ragiona sul verso del legame.

(a) Il rapporto t di $\hat{\beta}_1$ è 14,50, in valore assoluto maggiore di 1,96: si rifiuta $H_0 : \beta_1 = 0$.

(b) Δreati $= \hat{\beta}_1 \times \Delta$poliziotti $= 15{,}293 \times 0{,}5 = 7{,}6$ reati ogni mille abitanti: letta in senso causale, la stima direbbe che più poliziotti portano più reati.

(c) Il rapporto t di $\hat{\gamma}_1$ è 14,50, in valore assoluto maggiore di 1,96: si rifiuta $H_0 : \gamma_1 = 0$.

(d) Sì. I due rapporti t coincidono (14,50 e 14,50) e coincide l'R^2, 0,6405. Le pendenze invece sono diverse, 15,293 e 0,0419, e il loro prodotto è $15{,}293 \times 0{,}0419 = 0{,}6405 = R^2$.

(e) No. L'associazione è la stessa in entrambe le direzioni ed è significativa in entrambe: non dice se siano i poliziotti a influire sui reati o i reati ad attirare i poliziotti. La seconda lettura è plausibile (le città con più reati assumono più poliziotti): può trattarsi di causalità inversa (o di variabili omesse), l'ordine logico non è chiaro e quindi non si può parlare di causalità.

Errore tipico. Credere che la seconda pendenza sia l'inverso della prima: $1/\hat{\beta}_1 = 0{,}0654$, mentre $\hat{\gamma}_1 = 0{,}0419$, perché il loro prodotto è R^2 e non 1. L'errore più grave è concludere dalla (a) che aumentare i poliziotti faccia aumentare i reati: il segno e la significatività della stima possono essere prodotti dalla causalità inversa (o da variabili omesse); l'ordine logico non è chiaro, quindi non si può parlare di causalità.

Risposta. **(a)** Si rifiuta H_0: la pendenza è significativa. **(b)** Letta in senso causale, la stima darebbe 7,6 reati in più ogni mille abitanti. **(c)** Si rifiuta H_0 anche nella regressione scambiata. **(d)** Sì: stesso t (14,50) e stesso R^2 (0,6405). **(e)** No: l'associazione è simmetrica e non indica il verso del legame; la stima può essere prodotta dalla causalità inversa (o da variabili omesse), l'ordine logico non è chiaro e quindi non si può parlare di causalità.

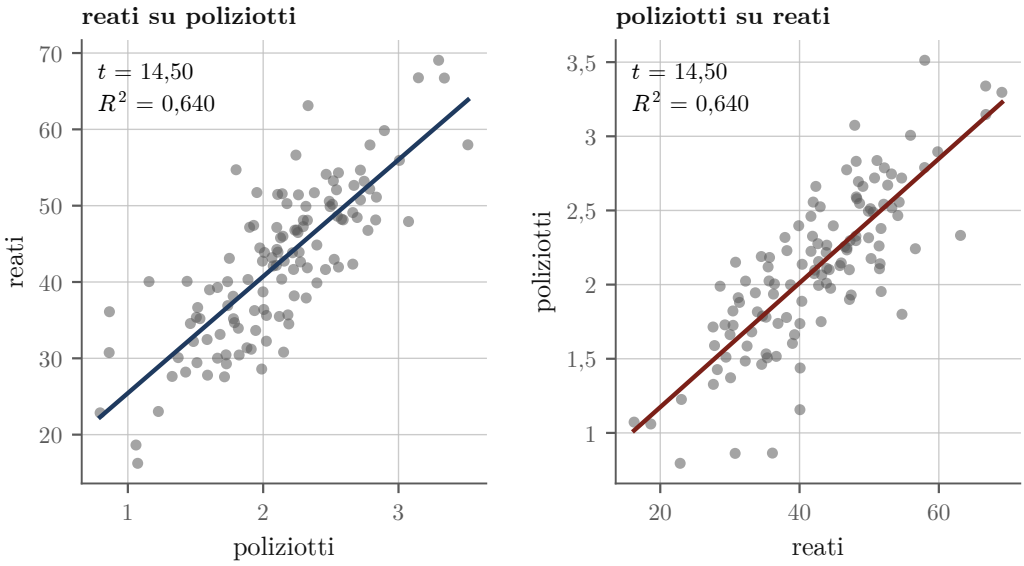


Figura 3.1: La stessa nuvola di città con gli assi scambiati: a sinistra reati su poliziotti, a destra poliziotti su reati. In entrambi i casi la retta è significativa, con lo stesso t e lo stesso R^2: i dati non indicano il verso del legame.

4 | Esercizio 4 — La spesa riportata male *(livello intermedio)*

Dati. Un'indagine chiede a $n = 200$ famiglie la spesa settimanale al supermercato e la spesa mensile non alimentare `y`. Le famiglie ricordano la spesa settimanale in modo impreciso: l'errore di ricordo è in media nullo. I dati sono simulati, quindi si conosce anche la spesa vera `spesa_vera`, che nella realtà non si osserva, mentre `spesa_rip` è quella riportata dalle famiglie. La spesa mensile è stata generata a partire dalla spesa vera con un coefficiente $\beta = 1{,}5$. Le medie e le deviazioni standard del campione sono le seguenti.

variabile	media	deviazione standard
spesa_vera	154,389	40,043
spesa_rip	156,954	55,163

Modello V, `y` su `spesa_vera`:

	coefficiente	errore std.	rapporto t	p-value
const	124,641	8,53482	14,6	2,92e-33
spesa_vera	1,49277	0,053519	27,89	1,65e-70

n = 200; $R^2 = 0{,}797126$; SSR = 180965

Modello R, `y` su `spesa_rip` (stesse famiglie):

	coefficiente	errore std.	rapporto t	p-value
const	212,333	9,49682	22,36	4,56e-56
spesa_rip	0,909668	0,0570998	15,93	2,55e-37

n = 200; $R^2 = 0{,}561756$; SSR = 390917

Modello G, `y` su `spesa_rip`, con un campione di 20000 famiglie generate allo stesso modo:

	coefficiente	errore std.	rapporto t	p-value
const	201,115	1,02984	195,3	0,0000
spesa_rip	0,956378	0,0065168	146,8	0,0000

n = 20000; $R^2 = 0{,}518529$

Testo della domanda. **Domanda 4** ***(3 punti).*** **(a)** In percentuale della media della spesa vera, di quanto differisce la media della spesa riportata (media riportata meno media vera)? **(b)** Quanto vale il rapporto fra la pendenza del Modello R e quella del Modello V, cioè la prima divisa per la seconda? **(c)** Quanto vale il rapporto fra la pendenza del Modello G e β, cioè la prima divisa per il secondo? **(d)** Nel Modello G, al livello del 5% (valore critico 1,96), si decida se rifiutare o non rifiutare $H_0 : \beta_1 = \beta$ contro $H_1 : \beta_1 \neq \beta$, con $t = (\hat{\beta}_1 - \beta)/\widehat{\text{se}}(\hat{\beta}_1)$. **(e)** Alla luce dei punti precedenti, un campione più grande basta a eliminare la distorsione dovuta all'errore di misura? Si risponda sì o no.

Richiamo. Un errore di misura nel regressore rende distorta (attenuata) la stima dei parametri, anche se il modello è corretto e anche se l'errore è in media nullo: la media del campione può restare corretta, ma l'errore aggiunge rumore alla variabile osservata e la stima del coefficiente si sposta. La distorsione non è una fluttuazione campionaria e non scompare aumentando il numero di osservazioni: un campione più grande rende solo più precisa, cioè con errore standard più piccolo, una stima sbagliata. Per verificare se un valore β_0 è compatibile con i dati si usa $t = (\hat{\beta}_1 - \beta_0)/\widehat{\text{se}}(\hat{\beta}_1)$ e si rifiuta se $|t| > 1{,}96$.

Svolgimento. **Impostazione.** Si confrontano le medie, che non risentono dell'errore, con le pendenze, che ne risentono, e poi si guarda che cosa cambia con un campione più grande.

(a) $100 \times \dfrac{156{,}954 - 154{,}389}{154{,}389} = 1{,}66\%$: le due medie sono quasi uguali.

(b) $\dfrac{\hat{\beta}_R}{\hat{\beta}_V} = \dfrac{0{,}9097}{1{,}4928} = 0{,}61$: con la spesa riportata la pendenza stimata è molto più piccola di quella che si ottiene con la spesa vera.

(c) $\dfrac{\hat{\beta}_G}{\beta} = \dfrac{0{,}9564}{1{,}5} = 0{,}64$: con un campione molto più grande il rapporto è praticamente lo stesso.

(d) $t = \dfrac{0{,}9564 - 1{,}5}{0{,}00652} = -83{,}4$, in valore assoluto maggiore di 1,96: si rifiuta $H_0 : \beta_1 = \beta$.

(e) No. Con il campione grande l'errore standard è più piccolo ma la stima resta lontana da β, e il valore vero è escluso con grande sicurezza: la distorsione non dipende dalla numerosità.

Errore tipico. Concludere dalla (a) che i dati riportati siano affidabili perché le medie coincidono. L'errore di ricordo non sposta la media, ma rende la spesa riportata più dispersa (la deviazione standard sale da 40,043 a 55,163) e questo basta a distorcere la pendenza. Un altro errore è pensare che un campione più grande risolva il problema.

Risposta. **(a)** La media della spesa riportata differisce da quella vera del 1,66%. **(b)** Il rapporto fra le pendenze del Modello R e del Modello V è 0,61. **(c)** Il rapporto fra la pendenza del Modello G e β è 0,64. **(d)** Si rifiuta H_0: β non è compatibile con la stima del campione grande. **(e)** No: un campione più grande rende più precisa la stima, ma non elimina la distorsione.

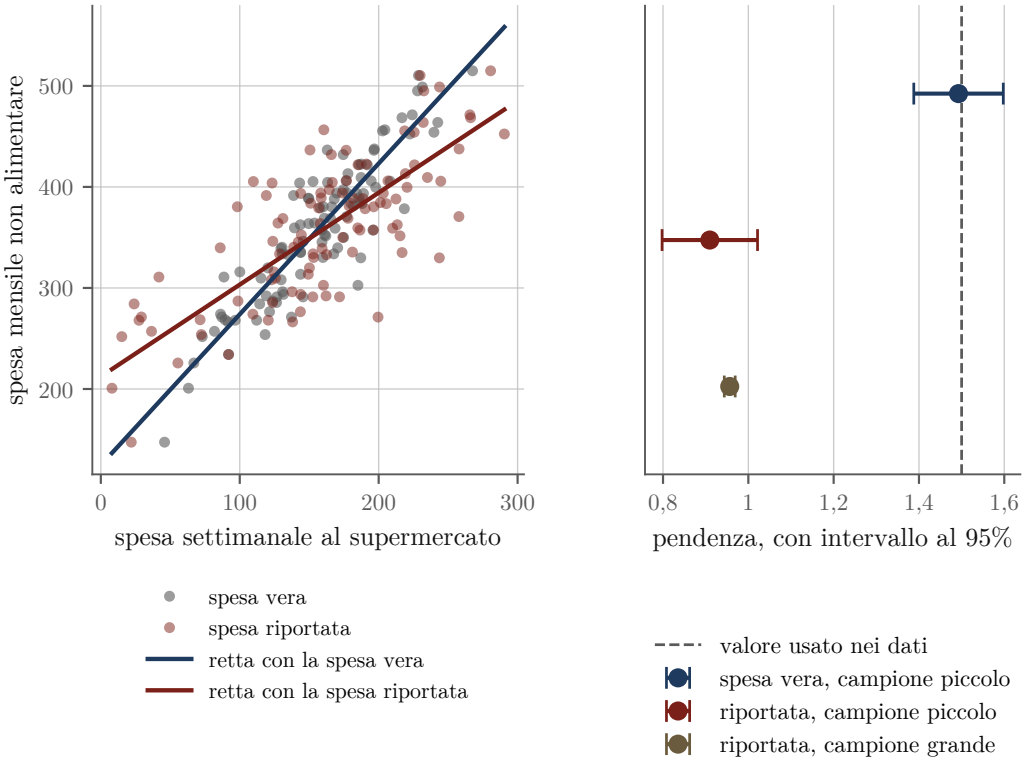


Figura 4.1: A sinistra la spesa mensile contro la spesa vera e contro quella riportata, con le due rette: l'errore di misura rende più piatta la retta. A destra la pendenza stimata nei tre modelli con intervallo al 95%: nel campione grande l'intervallo è stretto e non contiene il valore usato per generare i dati.

5 | Esercizio 5 — Gelati e incidenti in acqua *(livello d'appello)*

Dati. Su $n = 250$ località balneari si osservano in agosto `incidenti` (incidenti in acqua ogni 100 mila bagnanti), `gelati` (porzioni di gelato vendute per abitante a settimana) e `temperatura` (temperatura media in gradi centigradi). Si sono stimati il Modello 1

$$\text{incidenti} = \beta_0 + \beta_1\,\text{gelati} + \epsilon$$

	coefficiente	errore std.	rapporto t	p-value
const	2,84472	0,404656	7,03	1,99e-11
gelati	1,81139	0,0984205	18,4	2,8e-48

n = 250; R^2 = 0,577319; SSR = 727,097

il Modello 2, che aggiunge la temperatura,

$$\text{incidenti} = \beta_0 + \beta_1\,\text{gelati} + \beta_2\,\text{temperatura} + \epsilon$$

	coefficiente	errore std.	rapporto t	p-value
const	−20,9336	1,71149	−12,23	3,28e-27
gelati	0,178781	0,13698	1,305	0,1931
temperatura	1,11637	0,0790952	14,11	1,44e-33

n = 250; R^2 = 0,766026; SSR = 402,482

e la regressione ausiliaria $\text{gelati} = \delta_0 + \delta_1\,\text{temperatura} + u$.

	coefficiente	errore std.	rapporto t	p-value
const	−9,24898	0,533436	−17,34	1,19e-44
temperatura	0,487598	0,0196405	24,83	3,47e-69

n = 250; R^2 = 0,713075; SSR = 86,8437

Testo della domanda. **Domanda 5 *(4 punti).*** In tutti i test si usi il livello del 5% e il valore critico 1,96. **(a)** Nel Modello 1, si decida se rifiutare o non rifiutare $H_0 : \beta_1 = 0$ contro $H_1 : \beta_1 \neq 0$. **(b)** Se si leggesse il Modello 1 in senso causale, di quanti incidenti ogni 100 mila bagnanti varierebbe in media il numero di incidenti per un aumento di 2 porzioni di gelato a settimana? **(c)** Nel Modello 2, si decida se rifiutare o non rifiutare $H_0 : \beta_1 = 0$ contro $H_1 : \beta_1 \neq 0$. **(d)** Nel Modello 2, di quanti incidenti ogni 100 mila bagnanti varia in media il numero di incidenti per un aumento di 3 gradi della temperatura, a parità di gelati? **(e)** Nella regressione ausiliaria, si decida se rifiutare o non rifiutare $H_0 : \delta_1 = 0$ contro $H_1 : \delta_1 \neq 0$. **(f)** Sia b la stima del coefficiente di `gelati` nel Modello 1. Nel Modello 2, si decida se rifiutare o non rifiutare $H_0 : \beta_1 = b$ contro $H_1 : \beta_1 \neq b$, con $t = (\hat{\beta}_1 - b)/\widehat{\text{se}}(\hat{\beta}_1)$, dove $\hat{\beta}_1$ e $\widehat{\text{se}}(\hat{\beta}_1)$ sono quelli del Modello 2.

Richiamo. Una relazione fra X e Y si dice spuria quando è indotta da una variabile Z che influisce su entrambe. Se Z è omessa dal modello, la stima del coefficiente di X coglie anche l'effetto di Z: è la prima delle tre cause di problemi nella stima, le variabili omesse. Se, controllando per Z, l'associazione fra X e Y si riduce a zero, è il sintomo di una relazione spuria. Una variazione Δx comporta $\Delta y = \beta\,\Delta x$. Per verificare un valore β_0 si usa $t = (\hat{\beta} - \beta_0)/\widehat{\text{se}}(\hat{\beta})$ e si rifiuta se $|t| > 1{,}96$. Non si può dimostrare che una relazione sia causale: si possono confutare le spiegazioni alternative, e un test che non rifiuta H_0 non dimostra che H_0 sia vera.

Svolgimento. **Impostazione.** Si confrontano i due modelli, si controlla che la temperatura sia legata sia agli incidenti sia ai gelati e si verifica che il Modello 2 escluda l'effetto letto nel Modello 1.

(a) Nel Modello 1 $t = 18{,}40$, in valore assoluto maggiore di 1,96: si rifiuta $H_0 : \beta_1 = 0$.

(b) $\Delta\text{incidenti} = \hat{\beta}_1 \times \Delta\text{gelati} = 1{,}8114 \times 2 = 3{,}62$ incidenti ogni 100 mila bagnanti, se si leggesse il Modello 1 in senso causale.

(c) Nel Modello 2 $t = 1{,}30$, in valore assoluto minore di 1,96: non si rifiuta $H_0 : \beta_1 = 0$.

(d) $\Delta\text{incidenti} = \hat{\beta}_2 \times \Delta\text{temperatura} = 1{,}1164 \times 3 = 3{,}35$ incidenti ogni 100 mila bagnanti, a parità di gelati.

(e) Nella regressione ausiliaria $\hat{\delta}_1 = 0{,}4876$ con $t = 24{,}83$, in valore assoluto maggiore di 1,96: si rifiuta $H_0 : \delta_1 = 0$. Più la temperatura è alta, più gelati si vendono.

(f) Con $b = 1{,}8114$ si ha $t = \dfrac{0{,}1788 - 1{,}8114}{0{,}13698} = -11{,}9$, in valore assoluto maggiore di 1,96: si rifiuta $H_0 : \beta_1 = b$. Il Modello 2 esclude che l'effetto dei gelati sia quello letto nel Modello 1.

Lettura. La temperatura influisce sugli incidenti (c'è più gente in acqua) e sui gelati: è una causa comune. Il Modello 1 la omette e l'associazione fra gelati e incidenti è spuria, indotta dalla variabile omessa.

Errore tipico. Leggere la stima del Modello 1, 1,8114, come l'effetto causale dei gelati: coglie anche l'effetto della temperatura. Un secondo errore è concludere dalla (c) che l'effetto dei

gelati sia dimostrato nullo: il test non rifiuta $H_0 : \beta_1 = 0$, ma non lo dimostra. Ciò che i dati escludono, al 5%, è il valore del Modello 1 (punto (f)): la confutazione di una spiegazione, non la dimostrazione dell'altra.

Risposta. **(a)** Si rifiuta H_0: nel Modello 1 i gelati sembrano significativi. **(b)** Letta in senso causale, la stima darebbe 3,62 incidenti in più ogni 100 mila bagnanti. **(c)** Non si rifiuta H_0: controllando per la temperatura i gelati non sono più significativi. **(d)** Con 3 gradi in più gli incidenti aumentano in media di 3,35, a parità di gelati. **(e)** Si rifiuta H_0: la temperatura influisce sui gelati. **(f)** Si rifiuta H_0: il Modello 2 esclude l'effetto del Modello 1. L'associazione del Modello 1 è spuria, indotta dalla temperatura omessa.

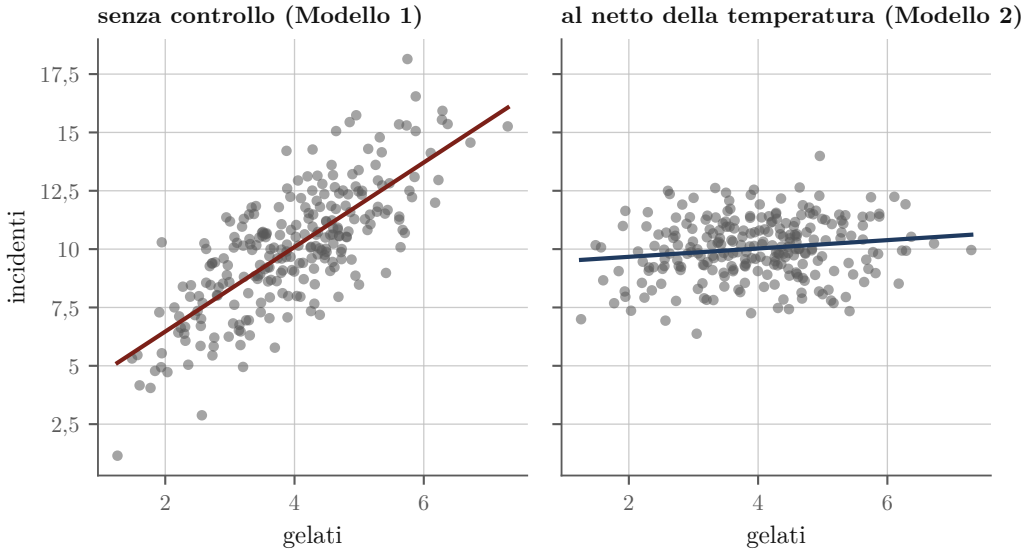


Figura 5.1: A sinistra incidenti contro gelati con la retta del Modello 1, di pendenza 1,8114. A destra gli incidenti al netto dell'effetto stimato della temperatura, incidenti $-\,\hat{\beta}_2$ temperatura, con la retta del Modello 2, di pendenza 0,1788: l'associazione sparisce.

6 | Esercizio 6 — Un fondo e il CAPM *(livello d'appello)*

Dati. Per $n = 240$ mesi consecutivi si osservano l'extra-rendimento mensile di un fondo, R_t, e quello del portafoglio di mercato, R_{mt}, entrambi in percentuale e al netto del tasso privo di rischio. Il CAPM prevede, per gli extra-rendimenti, $E[R_t] = \beta\, E[R_{mt}]$, cioè un'intercetta nulla. Per verificarlo si stima

$$R_t = \alpha + \beta\, R_{mt} + \epsilon_t, \qquad \mathrm{Var}(R_t) = \beta^2\, \mathrm{Var}(R_{mt}) + \sigma^2,$$

dove σ è il rischio idiosincratico, stimato con $\hat{\sigma} = \sqrt{\mathrm{SSR}/(n-2)}$. Le stime OLS sono le seguenti.

	coefficiente	errore std.	rapporto t	p-value
const	−0,0811511	0,161744	−0,5017	0,6163
mercato	1,12244	0,0354445	31,67	2,63e-87

n = 240; R^2 = 0,808192; SSR = 1387,36

Testo della domanda. **Domanda 6** ***(4 punti).*** In tutti i test si usi il livello del 5% e il valore critico 1,96. **(a)** I dati sono una serie storica? Si risponda sì o no. **(b)** Si decida se rifiutare o non rifiutare $H_0 : \alpha = 0$ contro $H_1 : \alpha \neq 0$. **(c)** Il risultato del punto (b) dimostra che il CAPM è vero? Si risponda sì o no. **(d)** Si decida se rifiutare o non rifiutare $H_0 : \beta = 1$ contro $H_1 : \beta \neq 1$, con $t = (\hat{\beta} - 1)/\widehat{\mathrm{se}}(\hat{\beta})$. **(e)** Di quanti punti percentuali varia in media l'extra-rendimento del fondo se quello del mercato aumenta di 3 punti percentuali? **(f)** Quanto vale la stima $\hat{\sigma}$ del rischio idiosincratico?

Richiamo. Per gli extra-rendimenti il CAPM prevede $E[R_t] = \beta\, E[R_{mt}]$, cioè $\alpha = 0$ nella regressione $R_t = \alpha + \beta R_{mt} + \epsilon_t$, con $\beta = \mathrm{Cov}(R_t, R_{mt})/\mathrm{Var}(R_{mt})$ e $\mathrm{Var}(R_t) = \beta^2\, \mathrm{Var}(R_{mt}) + \sigma^2$. Il modello si valida stimando la regressione con l'intercetta e verificando $H_0 : \alpha = 0$ con $t = \hat{\alpha}/\widehat{\mathrm{se}}(\hat{\alpha})$: se si rifiuta, il CAPM è confutato; se non si rifiuta, è compatibile con i dati ma non dimostrato. Con $\beta > 1$ il fondo amplifica i movimenti del mercato ed è più rischioso. Per verificare $\beta = 1$ si usa $t = (\hat{\beta} - 1)/\widehat{\mathrm{se}}(\hat{\beta})$. Una variazione ΔR_m comporta $\Delta R = \beta\, \Delta R_m$. Il rischio idiosincratico si stima con $\hat{\sigma} = \sqrt{\mathrm{SSR}/(n-2)}$. Una serie storica osserva un solo soggetto in istanti successivi.

Svolgimento. **Impostazione.** Un solo fondo è osservato mese dopo mese; si testano due ipotesi diverse, $\alpha = 0$ e $\beta = 1$, e si ricava il rischio dalla SSR.

(a) Un solo soggetto, il fondo, osservato in mesi successivi: sì, è una serie storica.

(b) $t = \hat{\alpha}/\widehat{\text{se}}(\hat{\alpha}) = -0{,}50$, in valore assoluto minore di 1,96: non si rifiuta $H_0 : \alpha = 0$.

(c) No. Non rifiutare $H_0 : \alpha = 0$ vuol dire che i dati non confutano l'intercetta nulla; il CAPM resta compatibile con i dati, ma non è dimostrato.

(d) $t = \dfrac{1{,}1224 - 1}{0{,}03544} = 3{,}45$, in valore assoluto maggiore di 1,96: si rifiuta $H_0 : \beta = 1$. L'intervallo di confidenza al 95% [1,053; 1,192] non contiene 1 e sta sopra: $\beta > 1$, il fondo è più rischioso del mercato.

(e) $\Delta R = \hat{\beta} \times \Delta R_m = 1{,}1224 \times 3 = 3{,}37$ punti percentuali.

(f) $\hat{\sigma} = \sqrt{\dfrac{\text{SSR}}{n-2}} = \sqrt{\dfrac{1387{,}36}{240-2}} = 2{,}414$ punti percentuali.

Errore tipico. Verificare $H_0 : \beta = 0$ per giudicare se il fondo è più rischioso del mercato: quel test dà $t = 31{,}67$: per un fondo azionario come questo il test su $\beta = 0$ rifiuta quasi sempre, ma non dice nulla sul confronto con 1. Un altro errore è leggere il mancato rifiuto di $H_0 : \alpha = 0$ come la prova che il CAPM sia vero, invece di una mancata confutazione.

Risposta. **(a)** Sì: un fondo osservato nel tempo è una serie storica. **(b)** Non si rifiuta $H_0 : \alpha = 0$. **(c)** No: il CAPM non è confutato, ma non è dimostrato. **(d)** Si rifiuta $H_0 : \beta = 1$: $\hat{\beta} = 1{,}1224$ è significativamente maggiore di 1 e il fondo è più rischioso del mercato. **(e)** Con il mercato +3 punti il fondo varia in media di 3,37 punti. **(f)** Il rischio idiosincratico stimato è $\hat{\sigma} = 2{,}414$.

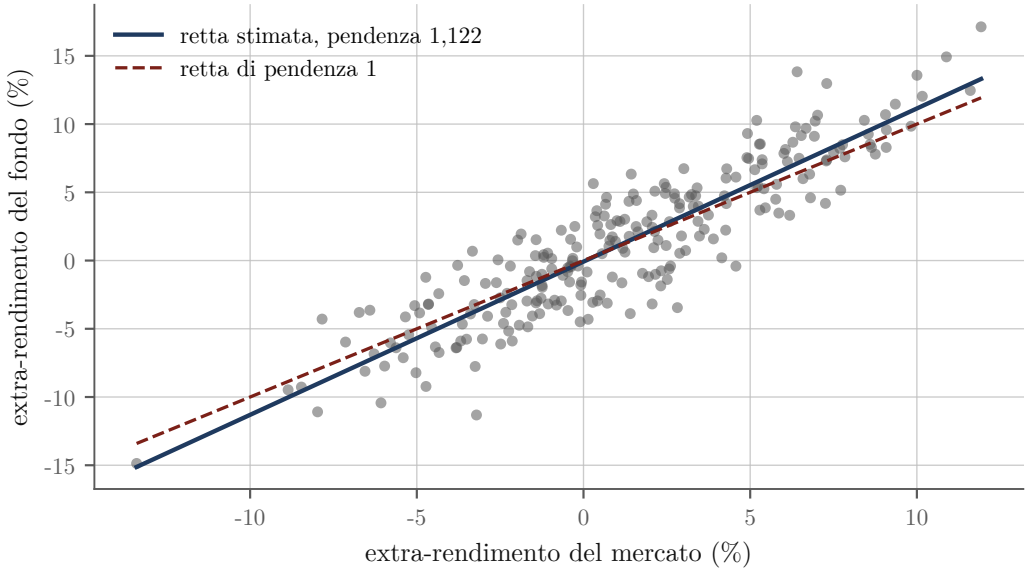


Figura 6.1: Extra-rendimenti mensili del fondo contro quelli del mercato, con la retta stimata e la retta di pendenza 1: la retta stimata è più ripida, il fondo amplifica i movimenti del mercato; l'intercetta stimata, −0,0812, è vicina a zero.