Università Ca' Foscari Venezia

Dipartimento di Economia

Laurea Magistrale in
Economia e Finanza

Modulo 02 — Regressione semplice

Soluzioni svolte e commentate

Appunti di:
Silvio Angelo Baratto Roldan

Codice insegnamento:
EM0004

Contenuto:
12 esercizi

Esercizi sintetici costruiti a fini di studio sul modello dei veri appelli e sulla teoria del corso (Econometria EM0004, prof. Davide Raggi). Non sono materiale ufficiale del docente.

Indice

1 **Esercizio 1 — Ore di studio e punteggio: la retta dai momenti campionari** *(livello base)* **1**

2 **Esercizio 2 — Prezzo e superficie: varianza dell'errore ed errore standard** *(livello base)* **3**

3 **Esercizio 3 — Affitto e distanza: la tavola ANOVA incompleta** *(livello base)* **5**

4 **Esercizio 4 — Formazione e rendimento: quando OLS è distorto** *(livello base)* **7**

5 **Esercizio 5 — Salario e istruzione: un valore dichiarato** *(livello intermedio)* **10**

6 **Esercizio 6 — Formazione e produttività: «almeno»** *(livello intermedio)* **12**

7 **Esercizio 7 — Auto usate: intervallo di confidenza per un effetto percentuale** *(livello intermedio)* **14**

8 **Esercizio 8 — Spesa e reddito: eteroschedasticità in una simulazione** *(livello intermedio)* **16**

9 **Esercizio 9 — Salario e QI: R quadro basso, pendenza significativa** *(livello intermedio)* **19**

10 **Esercizio 10 — Visite commerciali e vendite: oltre la soglia, ma non significativamente** *(livello appello)* **21**

11 **Esercizio 11 — Costi di produzione: errori standard e due test** *(livello appello)* **24**

12 **Esercizio 12 — Nord e Sud: la differenza fra due pendenze** *(livello appello)* **27**

1 | Esercizio 1 — Ore di studio e punteggio: la retta dai momenti campionari *(livello base)*

Dati. Su $n = 150$ studenti si osservano le ore di studio settimanali (`ore`) e il punteggio ottenuto a una prova (`punteggio`, su 100). Si stima con OLS il modello

$$\text{punteggio} = \alpha + \beta\,\text{ore} + \epsilon.$$

Le medie e le varianze campionarie sono nella tabella; la covarianza campionaria fra `ore` e `punteggio` è 42,8063. Varianze e covarianza sono calcolate con lo stesso divisore (n oppure $n-1$): il loro rapporto non dipende dalla scelta.

	media	varianza
ore	13,7441	20,4848
punteggio	67,0961	171,4861

Testo della domanda. **Domanda 1** ***(3 punti).*** **(a)** Si calcoli la stima OLS $\hat\beta$ della pendenza. **(b)** Si calcoli la stima OLS $\hat\alpha$ dell'intercetta. **(c)** Di quanti punti varia in media il punteggio per 4 ore di studio in più? **(d)** Qual è il punteggio atteso di uno studente che studia 15 ore a settimana?

Richiamo. Nel modello $E[Y|X] = \alpha + \beta X$ lo stimatore OLS della pendenza è $\hat\beta = \widehat{\mathrm{Cov}}(X,Y)\big/\widehat{\mathrm{Var}}(X)$ e quello dell'intercetta è $\hat\alpha = \bar y - \hat\beta\,\bar x$: la retta passa per il punto delle medie $(\bar x, \bar y)$. Da $\Delta Y = \beta\,\Delta X$ la variazione attesa di Y per ΔX unità in più di X è $\hat\beta\,\Delta X$, e il valore atteso in x_0 è $\hat\alpha + \hat\beta\,x_0$. Il divisore ($n$ oppure $n-1$) è lo stesso in covarianza e varianza e si semplifica nel rapporto.

Svolgimento. **Impostazione.** Le statistiche campionarie bastano per le due stime; la (c) e la (d) usano la retta stimata.

(a) $\hat\beta = \dfrac{\widehat{\mathrm{Cov}}(X,Y)}{\widehat{\mathrm{Var}}(X)} = \dfrac{42{,}8063}{20{,}4848} = 2{,}0897.$

(b) $\hat\alpha = \bar y - \hat\beta\,\bar x = 67{,}0961 - 2{,}0897 \times 13{,}7441 = 38{,}376.$

(c) $\Delta Y = \hat{\beta}\,\Delta X = 2{,}0897 \times 4 = 8{,}36$ punti.

(d) $\hat{\alpha} + \hat{\beta}\,x_0 = 38{,}376 + 2{,}0897 \times 15 = 69{,}72$.

Errore tipico. Dividere la covarianza per la varianza di `punteggio` (171,4861) invece che per quella di `ore`: nella pendenza di Y su X il denominatore è la varianza del regressore. Un altro errore è dimenticare l'intercetta nella previsione di (d): $\hat{\beta}\,x_0$ da solo non è il punteggio atteso.

Risposta. **(a)** $\hat{\beta} = 2{,}0897$: un'ora di studio in più si associa a circa 2,0897 punti in più. **(b)** $\hat{\alpha} = 38{,}376$, il punteggio atteso con zero ore di studio: zero ore è probabilmente fuori dall'intervallo dei dati (estrapolazione), quindi l'intercetta va letta con cautela. **(c)** Per 4 ore in più il punteggio atteso cresce di circa 8,36 punti. **(d)** Con 15 ore a settimana il punteggio atteso è circa 69,72.

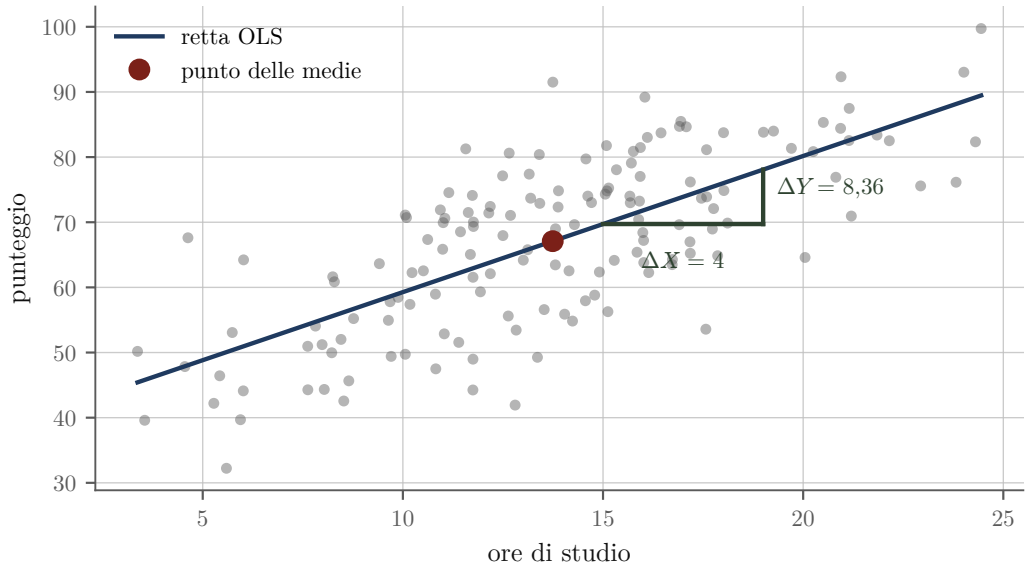


Figura 1.1: Nuvola dei dati e retta OLS, che passa per il punto delle medie $(\bar{x}, \bar{y})$: 4 ore in più spostano la retta di 8,36 punti.

2 | Esercizio 2 — Prezzo e superficie: varianza dell'errore ed errore standard *(livello base)*

Dati. Su $n = 60$ appartamenti in vendita si è stimato con OLS il modello

$$\text{prezzo} = \alpha + \beta\,\text{sup} + \epsilon,$$

dove `prezzo` è in migliaia di euro e `sup` è la superficie in metri quadrati. Gli errori sono omoschedastici. Dalla stima si ricavano la somma dei quadrati dei residui, $\text{SSR} = \sum_i \hat{\epsilon}_i^2 = 46259{,}47$, e la somma dei quadrati degli scarti della superficie dalla sua media, $\sum_i (x_i - \bar{x})^2 = 32542{,}39$.

Testo della domanda. **Domanda 2** ***(3 punti).*** **(a)** Si calcoli la stima non distorta $\hat{\sigma}^2$ della varianza dell'errore. **(b)** Si calcoli $\hat{\sigma}$, l'errore standard della regressione. **(c)** Si calcoli l'errore standard stimato di $\hat{\beta}$. **(d)** Se la numerosità del campione fosse 4 volte più grande, a parità di $\hat{\sigma}$ e di varianza campionaria di `sup` (quindi con $\sum_i (x_i - \bar{x})^2$ 4 volte più grande), per quale fattore si moltiplicherebbe l'errore standard di $\hat{\beta}$?

Richiamo. Con errori omoschedastici $\hat{\sigma}^2 = \dfrac{1}{n-2}\sum_i \hat{\epsilon}_i^2 = \dfrac{\text{SSR}}{n-2}$ è uno stimatore non distorto di σ^2: si dividono i residui per $n-2$, e non per n, perché due gradi di libertà sono spesi per stimare α e β. L'errore standard della pendenza è $\widehat{\text{se}}(\hat{\beta}) = \sqrt{\hat{\sigma}^2 \big/ \sum_i (x_i - \bar{x})^2}$: cresce con la dispersione dell'errore e diminuisce con la variabilità del regressore, che aumenta con la numerosità.

Svolgimento. **Impostazione.** Si passa da SSR a $\hat{\sigma}^2$, poi a $\hat{\sigma}$ e all'errore standard di $\hat{\beta}$; la (d) scala la formula.

(a) I gradi di libertà sono $n - 2 = 58$ e $\hat{\sigma}^2 = \text{SSR}/(n-2) = 46259{,}47/58 = 797{,}58$.

(b) $\hat{\sigma} = \sqrt{\hat{\sigma}^2} = \sqrt{797{,}58} = 28{,}241$.

(c) $\widehat{\text{se}}(\hat{\beta}) = \sqrt{\hat{\sigma}^2 \big/ \sum_i (x_i - \bar{x})^2} = \sqrt{797{,}58/32542{,}39} = 0{,}1566$.

(d) Con numerosità 4 volte più grande, a parità di $\hat{\sigma}$ e di varianza di `sup`, $\sum_i (x_i - \bar{x})^2$ diventa 4 volte più grande, quindi $\widehat{\text{se}}(\hat{\beta})$ si moltiplica per $1\big/\sqrt{4} = 0{,}50$.

Errore tipico. Dividere SSR per n invece che per $n-2$: si otterrebbe 770,99 invece di 797,58, una stima sistematicamente troppo bassa di σ^2 (in una simulazione SSR/n resta in media sotto σ^2, SSR/$(n-2)$ no). Un altro errore è rispondere in (d) che l'errore standard si divide per 4 (cioè diventa 1/4 del valore) perché n è moltiplicato per 4: è la radice di n che entra, non n.

Risposta. **(a)** $\hat{\sigma}^2 = 797{,}58$. **(b)** $\hat{\sigma} = 28{,}241$. **(c)** $\widehat{\mathrm{se}}(\hat{\beta}) = 0{,}1566$. **(d)** L'errore standard si moltiplica per 0,50, cioè si dimezza quando i dati diventano 4 volte tanti.

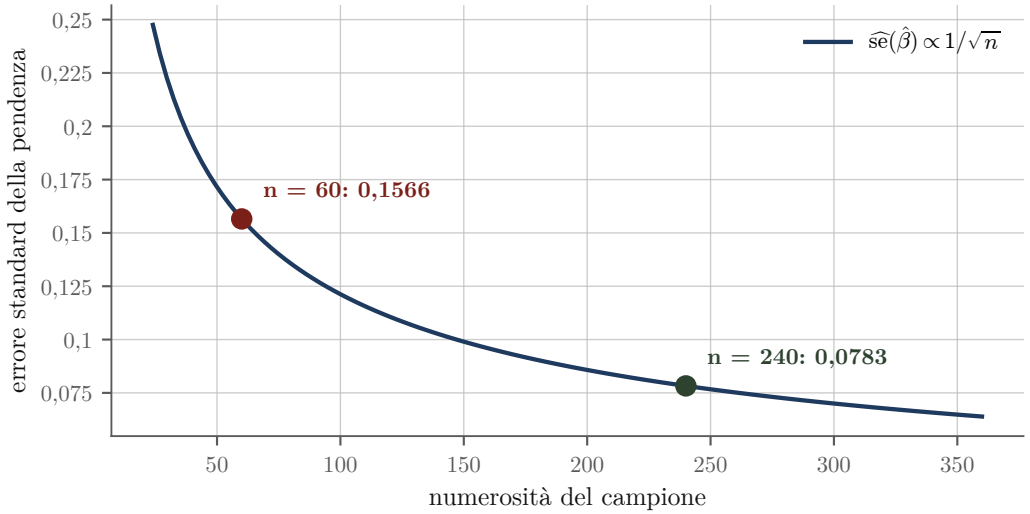


Figura 2.1: Errore standard della pendenza al variare della numerosità, a parità di $\hat{\sigma}$ e di varianza di `sup`: con 4 volte i dati scende alla metà.

3 | Esercizio 3 — Affitto e distanza: la tavola ANOVA incompleta *(livello base)*

Dati. Su $n = 80$ appartamenti in affitto si è stimato il modello

$$\text{affitto} = \alpha + \beta\,\text{dist} + \epsilon,$$

dove `affitto` è il canone mensile in centinaia di euro e `dist` la distanza dal centro in chilometri. La stima della pendenza è $\hat{\beta} = -0{,}5445$. Le devianze sono $\text{SST} = \sum_i (y_i - \bar{y})^2$ (totale), $\text{SSE} = \sum_i (\hat{y}_i - \bar{y})^2$ (spiegata dal modello) e $\text{SSR} = \sum_i (y_i - \hat{y}_i)^2$ (residua), con $\text{SST} = \text{SSE} + \text{SSR}$. Della tavola ANOVA è rimasta soltanto la riga dei residui e quella del totale.

fonte	devianza	gdl	media delle devianze
Residuo	386,78	78	4,959
Totale	630,14	79	7,976

Testo della domanda. **Domanda 3** ***(3 punti).*** **(a)** Quanto vale la devianza spiegata SSE? **(b)** Si calcoli l'indice R^2. **(c)** Si calcoli $\hat{\sigma}$, l'errore standard della regressione. **(d)** Qual è il coefficiente di correlazione lineare fra `dist` e `affitto`, con il suo segno? (Nella regressione semplice R^2 è il quadrato di tale coefficiente.)

Richiamo. La devianza totale si scompone in spiegata e residua: $\text{SST} = \text{SSE} + \text{SSR}$, con $\text{SST} = \sum_i (y_i - \bar{y})^2$, $\text{SSE} = \sum_i (\hat{y}_i - \bar{y})^2$ e $\text{SSR} = \sum_i (y_i - \hat{y}_i)^2$. L'indice di adattamento è $R^2 = \text{SSE}/\text{SST} = 1 - \text{SSR}/\text{SST}$, la quota della variabilità di y spiegata da x. La varianza dell'errore si stima con $\hat{\sigma}^2 = \text{SSR}/(n-2)$. Nella regressione semplice $R^2 = \text{Corr}(x, y)^2$ e il coefficiente di correlazione ha il segno di $\hat{\beta}$.

Svolgimento. **Impostazione.** La tavola dà SST e SSR: da qui si ricava SSE, poi R^2; $\hat{\sigma}$ viene da SSR e la correlazione da R^2 e dal segno di $\hat{\beta}$.

(a) $\text{SSE} = \text{SST} - \text{SSR} = 630{,}14 - 386{,}78 = 243{,}4$.

(b) $R^2 = \text{SSE}/\text{SST} = 243{,}4/630{,}14 = 0{,}3862$: `dist` spiega il 38,6% della devianza di `affitto`.

(c) $\hat{\sigma} = \sqrt{\text{SSR}/(n-2)} = \sqrt{386{,}78/78} = 2{,}227$, la radice della media delle devianze dei residui in tabella.

(d) $\hat{\beta} = -0{,}5445$ è negativo, quindi $r = -\sqrt{R^2} = -\sqrt{0{,}3862} = -0{,}621$.

Errore tipico. Rispondere 0,621 in (d): la radice di R^2 è sempre positiva e dà solo il valore assoluto della correlazione. Il segno è quello di $\hat{\beta}$, e qui più distanza dal centro significa affitto più basso. Un altro errore è calcolare $R^2 = \text{SSR}/\text{SST}$, che è la quota di variabilità **non** spiegata.

Risposta. **(a)** SSE = 243,4. **(b)** $R^2 = 0{,}3862$: la distanza spiega il 38,6% della variabilità dell'affitto; il resto, 61,4%, è lasciato ai residui. **(c)** $\hat{\sigma} = 2{,}227$. **(d)** La correlazione fra distanza e affitto è $-0{,}621$, negativa come $\hat{\beta}$.

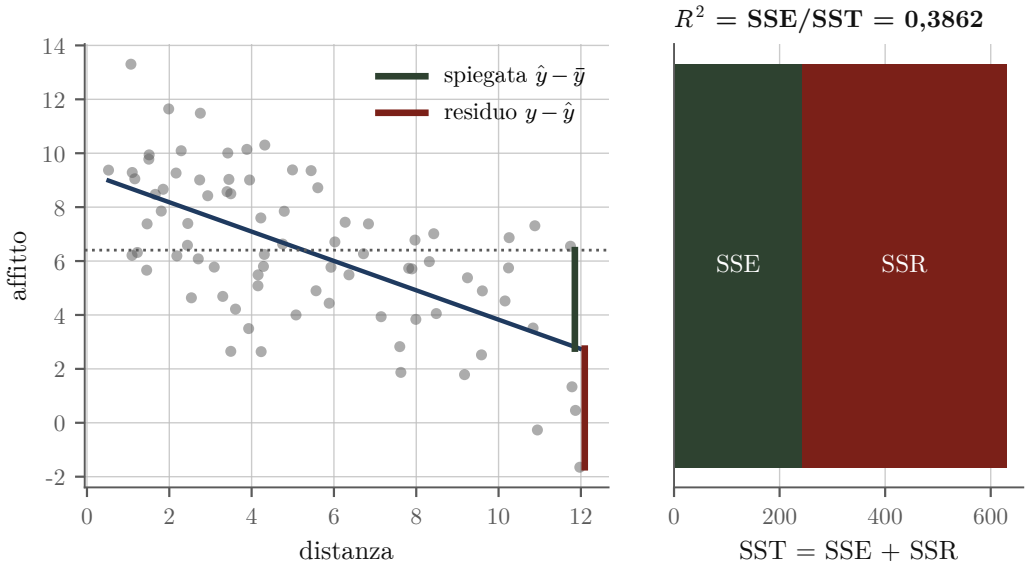


Figura 3.1: A sinistra la scomposizione di uno scarto, $y - \bar{y} = (\hat{y} - \bar{y}) + (y - \hat{y})$; a destra SST ripartita fra SSE e SSR, con $R^2 = 0{,}3862$.

4 | Esercizio 4 — Formazione e rendimento: quando OLS è distorto *(livello base)*

Dati. Un ricercatore vuole misurare l'effetto delle ore di formazione (X) sul rendimento (Y) con il modello

$$Y = \alpha + \beta\, X + \epsilon, \qquad \beta = 1{,}5.$$

I lavoratori più motivati scelgono più formazione e la motivazione, che non si osserva, finisce in ϵ: $\mathrm{Var}(X) = 4$ e $\mathrm{Cov}(X, \epsilon) = 2$. Per capire come si comporta OLS simula $R = 2000$ campioni da questo modello, per due numerosità, e riporta per ciascuna la media delle R stime di β, la loro deviazione standard e la media degli errori standard calcolati con la formula usuale.

campioni	media delle stime	dev. std. delle stime	media degli errori std.
n = 50	2,00033	0,10791	0,1083
n = 800	1,99963	0,02688	0,0266

Si consideri la media delle stime lontana dal vero β se $|\text{media} - \beta|$ supera 3 volte l'errore standard della media delle stime, cioè dev. std.$/\sqrt{R}$.

Testo della domanda. **Domanda 4** ***(3 punti).*** **(a)** Con $n = 50$ lo stimatore OLS di β è non distorto in questo modello? Si risponda sì o no. **(b)** A quale valore converge $\hat{\beta}$ quando n tende all'infinito? (Si ricordi che, con $\mathrm{Cov}(X, \epsilon) \neq 0$, $\hat{\beta}$ converge a $\beta + \mathrm{Cov}(X, \epsilon)/\mathrm{Var}(X)$.) **(c)** Con $n = 800$ la distorsione è scomparsa, cioè la media delle stime è vicina al vero β? Si risponda sì o no. **(d)** Il teorema di Gauss-Markov garantisce che OLS sia il miglior stimatore lineare non distorto in questo modello? Si risponda sì o no. **(e)** Quale ipotesi del modello è violata? Si spieghi.

Richiamo. La pendenza si scrive $\hat{\beta} = \beta + \sum_i \omega_i \epsilon_i$, con $\omega_i = (x_i - \bar{x}) \big/ \sum_j (x_j - \bar{x})^2$. Se $E[\epsilon | X] = 0$ (esogeneità) allora $E[\hat{\beta}] = \beta$ e OLS è non distorto. Se $\mathrm{Cov}(X, \epsilon) \neq 0$ la media di $\hat{\beta}$ non è β e lo stimatore non è consistente: converge a $\beta + \mathrm{Cov}(X, \epsilon)/\mathrm{Var}(X)$, quindi aumentare n restringe la distribuzione attorno al valore sbagliato. Il teorema di Gauss-Markov dà OLS come miglior

stimatore lineare non distorto (BLUE) solo se valgono linearità, campione i.i.d., esogeneità e omoschedasticità.

Svolgimento. **Impostazione.** Si confronta la media delle stime con il vero β in unità di errore standard della media, dev. std.$/\sqrt{R}$ con $\sqrt{R} = 44{,}72$.

(a) Con $n = 50$: $\dfrac{|2{,}00033 - 1{,}5|}{0{,}10791/44{,}72} = 207$, ben oltre 3: la media delle stime è lontana da β e lo stimatore è distorto.

(b) $\beta + \mathrm{Cov}(X, \epsilon)/\mathrm{Var}(X) = 1{,}5 + 2/4 = 2{,}00$: è il valore attorno a cui si concentrano le stime (la media a $n = 800$ è 1,99963).

(c) Con $n = 800$: $\dfrac{|1{,}99963 - 1{,}5|}{0{,}02688/44{,}72} = 831$, ancora oltre 3: la distorsione non è scomparsa, la dispersione è solo diminuita.

(d) No: serve l'esogeneità, che qui non vale.

(e) È violata l'esogeneità: $\mathrm{Cov}(X, \epsilon) = 2 \neq 0$, perché la motivazione non osservata sta in ϵ e muove anche X. Di conseguenza $E[\epsilon|X] \neq 0$.

Errore tipico. Pensare che un campione più grande risolva il problema: con $\mathrm{Cov}(X, \epsilon) \neq 0$ la numerosità riduce la varianza di $\hat{\beta}$ ma non la distorsione, quindi lo stimatore non è consistente. Un altro errore è leggere la piccola deviazione standard a $n = 800$ (0,02688) come prova di affidabilità: stima con precisione il valore sbagliato.

Risposta. **(a)** No: con $n = 50$ la media delle stime dista circa 207 errori standard della media da β. **(b)** $\hat{\beta}$ converge a 2,00, non al vero valore 1,5. **(c)** No: anche con $n = 800$ la media dista circa 831 errori standard della media da β. **(d)** No: Gauss-Markov richiede l'esogeneità. **(e)** L'ipotesi violata è l'esogeneità, $\mathrm{Cov}(X, \epsilon) \neq 0$: la motivazione non osservata è nell'errore e correlata con la formazione.

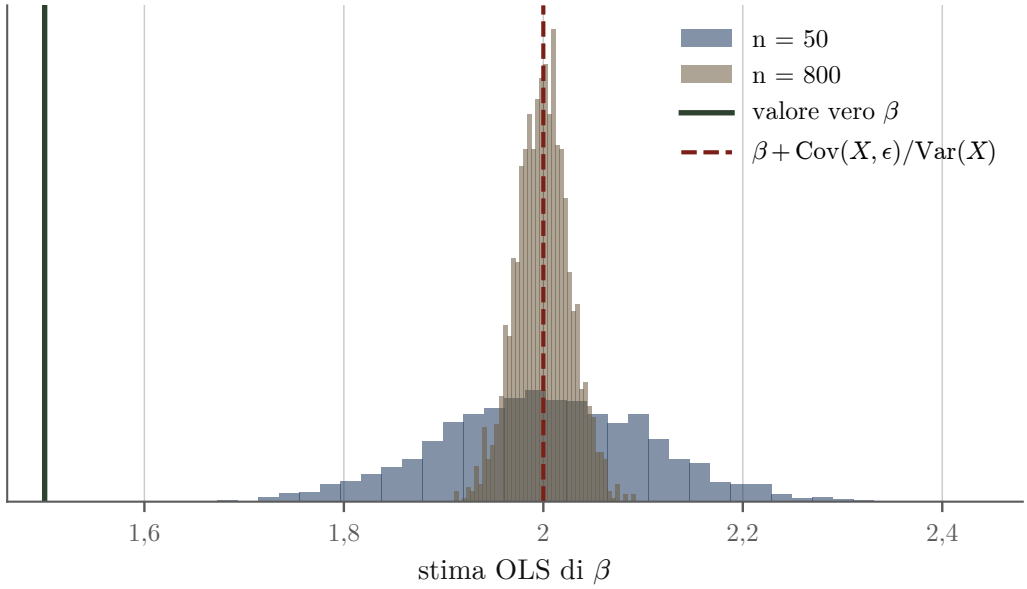


Figura 4.1: Distribuzione simulata delle stime OLS per le due numerosità: con n grande si stringe, ma attorno a 2,00 e non attorno al vero $\beta = 1{,}5$.

5 | Esercizio 5 — Salario e istruzione: un valore dichiarato *(livello intermedio)*

Dati. Su $n = 300$ lavoratori si è stimato il modello

$$\text{salario} = \alpha + \beta\,\text{istr} + \epsilon,$$

dove `salario` è la retribuzione oraria in euro e `istr` gli anni di istruzione. Le stime OLS sono le seguenti.

	coefficiente	errore std.	rapporto t	p-value
const	−1,06649	0,672025	−1,587	0,1136
istr	0,57228	0,0460836	12,42	8,08e-29

n = 300; $R^2 = 0{,}341021$; SSR = 2753,73

Testo della domanda. **Domanda 5** ***(3 punti).*** Un'agenzia di orientamento sostiene che 2 anni di istruzione in più fanno salire il salario orario atteso di 1,50 euro. Si usi il quantile 1,96. **(a)** Quale valore di β corrisponde all'affermazione? **(b)** Si calcoli il rapporto t per il sistema $H_0 : 2\beta = 1{,}50$ contro $H_1 : 2\beta \neq 1{,}50$, cioè la differenza fra la stima e il valore sotto H_0 divisa per il suo errore standard. **(c)** Al livello del 5%, si decida se rifiutare o non rifiutare H_0. **(d)** Il valore dichiarato di 1,50 euro cade nell'intervallo di confidenza al 95% per l'effetto di 2 anni, $[2(\hat\beta \pm 1{,}96\,\widehat{\text{se}})]$? Si risponda sì o no.

Richiamo. Da $\Delta Y = \beta\,\Delta X$, ΔX anni in più valgono $\beta\,\Delta X$: l'affermazione «ΔX anni valgono c euro» equivale a $\beta = c/\Delta X$. Per un valore puntuale non nullo, $H_0 : \beta = k$ contro $H_1 : \beta \neq k$, la statistica è $t = (\hat\beta - k)/\widehat{\text{se}}(\hat\beta)$ e al 5% si rifiuta se $|t| > 1{,}96$. Equivalentemente si rifiuta se k cade fuori dall'intervallo di confidenza $\hat\beta \pm 1{,}96\,\widehat{\text{se}}(\hat\beta)$; l'intervallo dell'effetto di ΔX anni è ΔX volte quello di β.

Svolgimento. **Impostazione.** L'affermazione riguarda 2β: la si riporta su β, poi si testa un valore diverso da zero.

(a) $2\beta = 1{,}50$ equivale a $\beta = k = 1{,}50/2 = 0{,}75$.

(b) $t = \dfrac{\hat{\beta} - k}{\widehat{\text{se}}(\hat{\beta})} = \dfrac{0{,}5723 - 0{,}75}{0{,}0461} = -3{,}86.$

(c) Il rapporto $t = -3{,}86$ supera 1,96 in valore assoluto: si rifiuta H_0.

(d) L'intervallo per l'effetto di 2 anni è $2 \times (0{,}5723 \pm 1{,}96 \times 0{,}0461) = [0{,}96;\ 1{,}33]$ e 1,50 ne è fuori. È la stessa conclusione del test.

Errore tipico. Usare il rapporto t della tabella (12,42), che verifica $H_0 : \beta = 0$, e non quello con k al numeratore: porterebbe a rifiutare per il motivo sbagliato. Un altro errore è confrontare 1,50 euro con $\hat{\beta}$, che è l'effetto di un solo anno, senza dividere per 2 (o, all'inverso, senza moltiplicare $\hat{\beta}$ e il suo errore standard per 2).

Risposta. **(a)** $k = 0{,}75$ euro per anno. **(b)** $t = -3{,}86$. **(c)** Si rifiuta H_0: l'affermazione non è compatibile con i dati al 5%. **(d)** No: 1,50 euro cade fuori dall'intervallo di confidenza al 95% [0,96; 1,33] dell'effetto di 2 anni; l'effetto stimato è 1,14 euro, più basso di quello dichiarato.

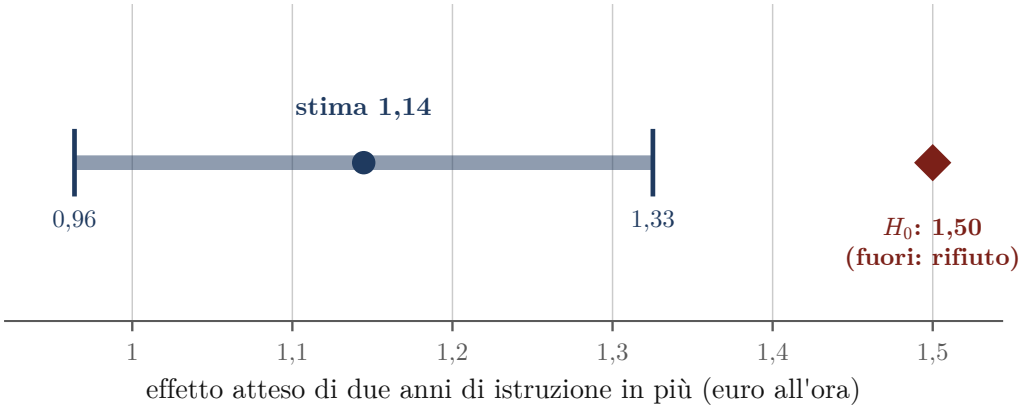


Figura 5.1: Intervallo di confidenza al 95% per l'effetto atteso di 2 anni di istruzione, [0,96; 1,33]: il valore dichiarato è fuori.

6 | Esercizio 6 — Formazione e produttività: «almeno» *(livello intermedio)*

Dati. Su $n = 120$ operai si è stimato il modello

$$\text{prod} = \alpha + \beta\,\text{ore} + \epsilon,$$

dove `prod` è la produttività oraria (pezzi all'ora) e `ore` le ore di formazione ricevute nell'anno. Le stime OLS sono le seguenti.

	coefficiente	errore std.	rapporto t	p-value
const	18,2396	0,710486	25,67	4,03e-50
ore	0,201245	0,0306336	6,569	1,43e-09

n = 120; $R^2 = 0{,}267795$; SSR = 1788,25

Testo della domanda. **Domanda 6** ***(3 punti).*** Un'azienda sostiene che ogni 10 ore di formazione in più fanno salire la produttività di almeno 3 pezzi all'ora. Si indichi con k il valore di β per cui 10 ore valgono esattamente 3 pezzi. Il quantile unilaterale al 5% della normale standard è 1,64. **(a)** Quanto vale k? **(b)** Si calcoli il rapporto $t = (\hat{\beta} - k)/\widehat{\text{se}}(\hat{\beta})$. **(c)** Al livello del 5%, si decida se rifiutare o non rifiutare $H_0 : \beta \geq k$ contro $H_1 : \beta < k$. **(d)** L'affermazione dell'azienda è compatibile con i dati? Si risponda sì o no (l'affermazione è l'ipotesi nulla).

Richiamo. Un'affermazione «almeno k» è l'ipotesi nulla: $H_0 : \beta \geq k$ contro $H_1 : \beta < k$, alternativa unilaterale a sinistra. Con una soglia $k \neq 0$ la statistica è $t = (\hat{\beta} - k)/\widehat{\text{se}}(\hat{\beta})$ e al 5% si rifiuta H_0 se $t < -1{,}64$, dove 1,64 è il quantile unilaterale della normale standard. Se H_0 è rifiutata l'affermazione non è compatibile con i dati; se non lo è, è compatibile.

Svolgimento. **Impostazione.** Si riporta la soglia su β ($k = \Delta Y/\Delta X$), poi si fa un test a una coda a sinistra.

(a) $k = \Delta Y/\Delta X = 3/10 = 0{,}30$ pezzi all'ora per ogni ora di formazione.

(b) $t = \dfrac{\hat{\beta} - k}{\widehat{\text{se}}(\hat{\beta})} = \dfrac{0{,}2012 - 0{,}30}{0{,}0306} = -3{,}22.$

(c) $t = -3{,}22 < -1{,}64$: si rifiuta $H_0 : \beta \geq k$ a favore di $H_1 : \beta < k$.

(d) L'affermazione è l'ipotesi nulla e viene rifiutata: non è compatibile con i dati.

Errore tipico. Guardare il rapporto t della tabella (6,57), che verifica $H_0 : \beta = 0$: è grande e positivo, ma risponde a un'altra domanda. Un altro errore è cercare la regione di rifiuto dalla parte sbagliata, $t > 1{,}64$: con l'alternativa $\beta < k$ si rifiuta per valori molto negativi di t.

Risposta. **(a)** $k = 0{,}30$. **(b)** $t = -3{,}22$. **(c)** Si rifiuta H_0 al 5%, perché $t < -1{,}64$. **(d)** No: la stima 0,2012 è significativamente più bassa della soglia 0,30, quindi «almeno 3 pezzi ogni 10 ore» non è sostenibile.

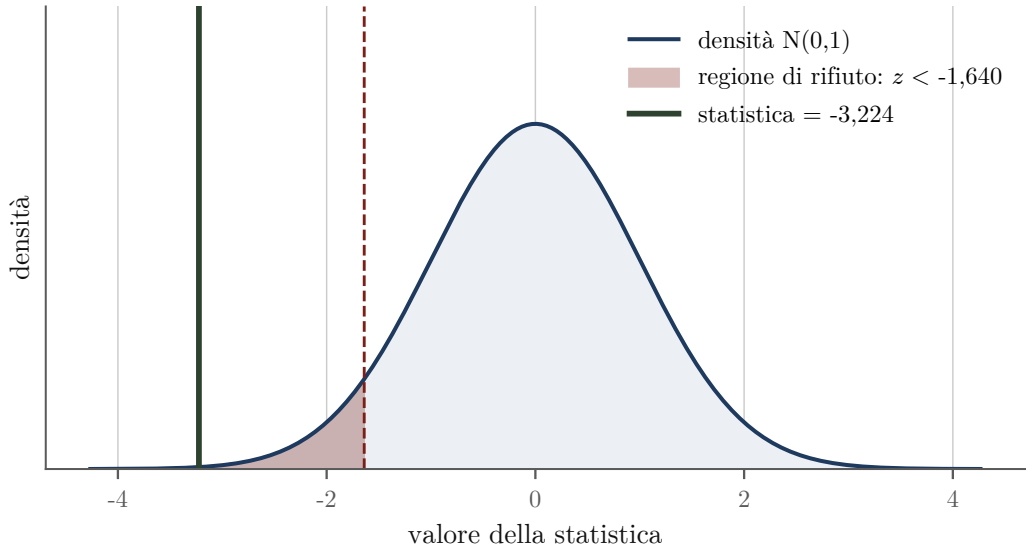


Figura 6.1: Regione di rifiuto a sinistra al 5% (sotto $-1{,}64$) e rapporto $t = -3{,}22$ osservato: cade nella regione di rifiuto.

7 | Esercizio 7 — Auto usate: intervallo di confidenza per un effetto percentuale *(livello intermedio)*

Dati. Su $n = 250$ auto usate si è stimato il modello

$$\log(\text{prezzo}) = \alpha + \beta\,\text{eta} + \epsilon,$$

dove `eta` è l'età dell'auto in anni. Le variazioni percentuali si calcolano con l'approssimazione $\Delta\%\, y \approx 100\,\Delta \log(y)$. Le stime OLS sono le seguenti.

	coefficiente	errore std.	rapporto t	p-value
const	9,90296	0,0375434	263,8	9,12e-306
eta	−0,0955804	0,00496525	−19,25	3,94e-51

n = 250; $R^2 = 0{,}599066$; SSR = 19,4273

Testo della domanda. **Domanda 7** ***(3 punti).*** Si usi il quantile 1,96. **(a)** Qual è l'estremo inferiore dell'intervallo di confidenza al 95% per β? **(b)** E l'estremo superiore? **(c)** Si trasformi l'intervallo in una variazione percentuale del prezzo per 2 anni di età in più: qual è l'estremo inferiore, cioè il valore più basso (il più negativo) della variazione? **(d)** E l'estremo superiore, cioè il valore più alto? **(e)** Un rivenditore sostiene che 2 anni di età in più fanno perdere in media il 20% del prezzo. L'affermazione è compatibile con i dati, cioè il valore −20% cade nell'intervallo di (c)-(d)? Si risponda sì o no.

Richiamo. Con la dipendente in logaritmo $\Delta \log(y) = \beta\,\Delta x$ e $\Delta\%\, y \approx 100\,\beta\,\Delta x$. L'intervallo di confidenza al 95% per β è $\hat\beta \pm 1{,}96\,\widehat{\text{se}}(\hat\beta)$; quello per la variazione percentuale dovuta a Δx si ottiene moltiplicando entrambi gli estremi per $100\,\Delta x$. Un valore è compatibile con i dati al 5% se cade nell'intervallo; «perdere il c%» con Δx anni equivale a $\beta = -c/(100\,\Delta x)$.

Svolgimento. **Impostazione.** Si costruisce l'intervallo di β, lo si trasforma in percentuale e si verifica se il valore del rivenditore vi cade.

(a) e **(b)** $\hat\beta \pm 1{,}96\,\widehat{\text{se}}(\hat\beta) = -0{,}0956 \pm 1{,}96 \times 0{,}0050$, cioè $[-0{,}1053;\ -0{,}0858]$.

(c) e **(d)** Moltiplicando per $100\,\Delta x = 100 \times 2$ si ottiene $[-21{,}1;\ -17{,}2]\%$.

(e) Perdere il 20% in 2 anni equivale a $\beta = -20/(100 \times 2) = -0{,}100$, che sta in $[-0{,}1053;\ -0{,}0858]$. Lo stesso dice $t = (\widehat{\beta} - \beta_0)/\widehat{\text{se}} = 0{,}89$, in valore assoluto minore di 1,96.

Errore tipico. Dimenticare il fattore $100\,\Delta x$ e leggere gli estremi di β come percentuali, oppure moltiplicare per $100\,\Delta x$ soltanto la stima e non l'errore standard (o un solo estremo). Un altro errore è dedurre dalla compatibilità del 20% che l'affermazione sia vera: l'intervallo contiene molti altri valori.

Risposta. **(a)** $-0{,}1053$. **(b)** $-0{,}0858$. **(c)** $-21{,}1\%$. **(d)** $-17{,}2\%$. **(e)** Sì: il valore -20% cade nell'intervallo $[-21{,}1;\ -17{,}2]\%$, quindi l'affermazione non si può escludere al 5%. La stima puntuale è $-19{,}1\%$.

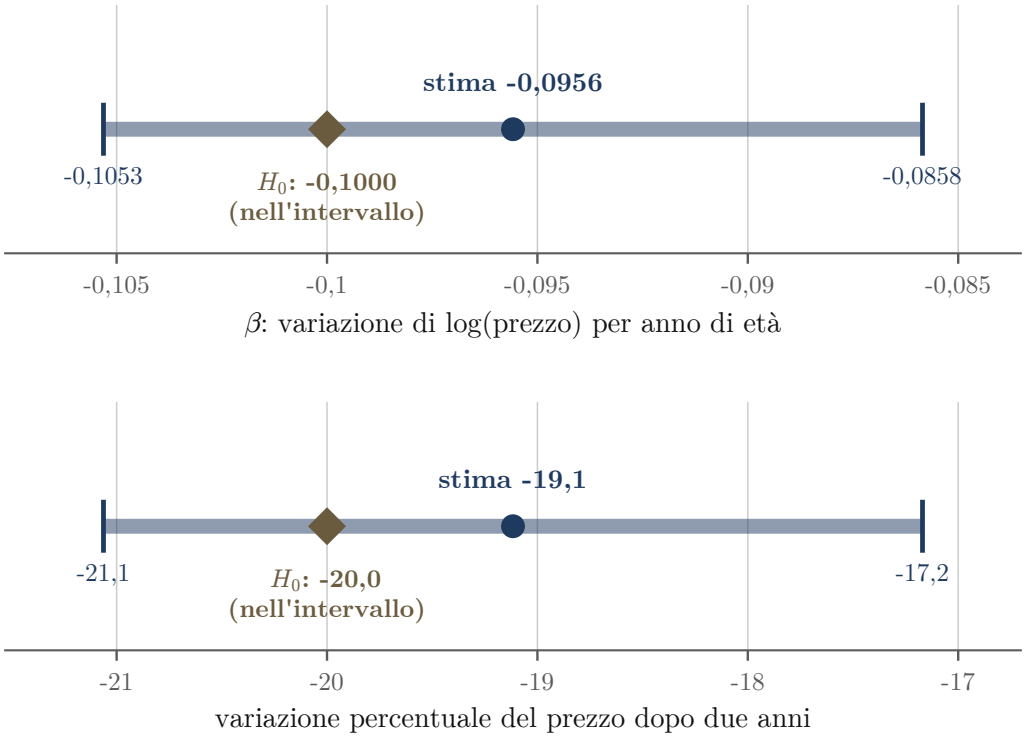


Figura 7.1: Intervallo di confidenza al 95% per β (sopra) e per la variazione percentuale del prezzo dopo 2 anni (sotto): il valore del rivenditore cade dentro entrambi.

8 | Esercizio 8 — Spesa e reddito: eteroschedasticità in una simulazione *(livello intermedio)*

Dati. Si studia la spesa mensile (`spesa`) in funzione del reddito mensile (`reddito`) con il modello spesa $= \alpha + \beta\,\text{reddito} + \epsilon$ e $\beta = 0{,}25$. Per capire quando OLS è affidabile si simulano $R = 2000$ campioni di $n = 100$ osservazioni in due scenari: nel primo gli errori hanno varianza costante, nel secondo la variabilità della spesa cresce con il reddito (la figura seguente ne mostra un campione per scenario). Per ogni scenario si riportano la media delle R stime di β, la loro deviazione standard e la media degli errori standard calcolati con la formula usuale $\sqrt{\hat\sigma^2/\sum_i (x_i-\bar x)^2}$.

scenario	media delle stime	dev. std. delle stime	media degli errori std.
omoschedastici	0,25022	0,04120	0,04070
eteroschedastici	0,24986	0,06190	0,04015

Si consideri la media delle stime lontana dal vero β se $|\text{media} - \beta|$ supera 3 volte dev. std.$/\sqrt{R}$. Gli errori standard si considerano affidabili se il rapporto fra la deviazione standard delle stime e la media degli errori standard dista da 1 per meno del 10%.

Testo della domanda. **Domanda 8** ***(3 punti).*** **(a)** Nello scenario con errori eteroschedastici lo stimatore OLS di β è ancora non distorto? Si risponda sì o no. **(b)** In quello scenario il teorema di Gauss-Markov garantisce che OLS sia il miglior stimatore lineare non distorto? Si risponda sì o no. **(c)** Si calcoli, nello scenario eteroschedastico, il rapporto fra la deviazione standard delle stime e la media degli errori standard. **(d)** Gli errori standard usuali sono affidabili nello scenario eteroschedastico? Si risponda sì o no. **(e)** E nello scenario con errori a varianza costante? Si risponda sì o no. **(f)** Quale ipotesi è violata nel secondo scenario e quale conseguenza ha sul test t di $H_0 : \beta = 0$? Si spieghi.

Richiamo. L'esogeneità, $E[\epsilon|X] = 0$, rende OLS non distorto: $E[\hat\beta] = \beta$. L'omoschedasticità, $\text{Var}(\epsilon|X) = \sigma^2$, serve alla formula $\widehat{\text{se}}(\hat\beta) = \sqrt{\hat\sigma^2/\sum_i (x_i-\bar x)^2}$ e al teorema di Gauss-Markov, per cui OLS è il miglior stimatore lineare non distorto solo se valgono linearità, campione i.i.d., esogeneità e omoschedasticità. Con $\text{Var}(\epsilon|X) = \sigma^2(X)$ le stime restano non distorte, ma la formula usuale non misura più la vera dispersione di $\hat\beta$. In una simulazione la si controlla confrontando la deviazione standard delle stime con la media degli errori standard.

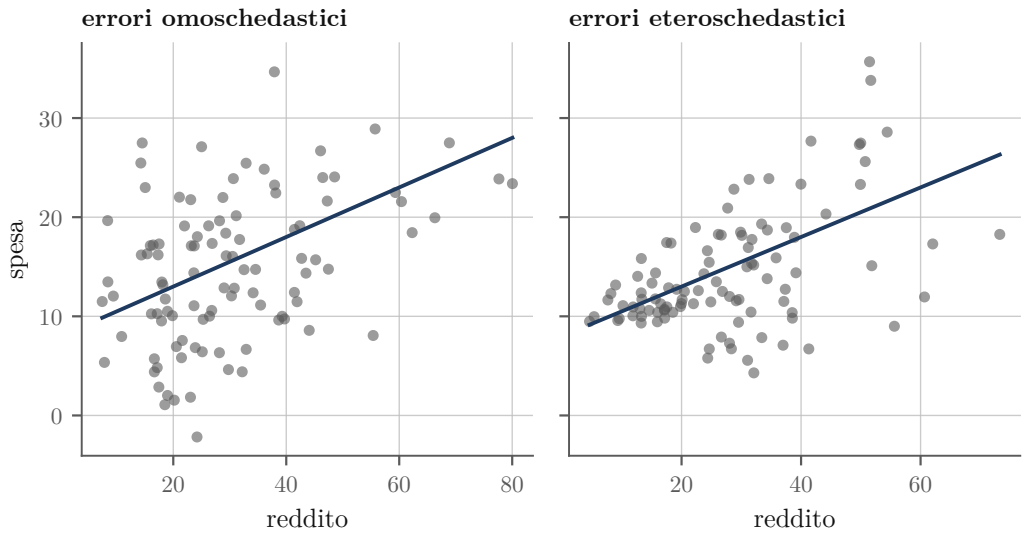


Figura 8.1: Un campione simulato per scenario: la nuvola attorno alla retta ha ampiezza costante a sinistra e crescente con il reddito a destra.

Svolgimento. **Impostazione.** Per ogni scenario si legge la tabella: la media dice se c'è distorsione, il rapporto fra dev. std. e media degli errori standard dice se la formula usuale è affidabile.

(a) $\dfrac{|0{,}24986 - 0{,}25|}{0{,}06190/44{,}72} = 0{,}1$, con $\sqrt{R} = 44{,}72$: sotto 3, la media coincide con β entro l'errore di simulazione. Sì, è non distorto.

(b) No: manca l'omoschedasticità, una delle quattro ipotesi del teorema.

(c) $0{,}06190/0{,}04015 = 1{,}54$.

(d) $|1{,}54 - 1|$ supera 0,10 (cioè il 10%): le stime variano molto più di quanto dicano gli errori standard. Non sono affidabili.

(e) Nello scenario omoschedastico $0{,}04120/0{,}04070 = 1{,}01$, entro il 10% da 1: affidabili.

(f) Nel secondo scenario è violata l'omoschedasticità. La formula usuale sottostima la dispersione di $\widehat{\beta}$ (rapporto maggiore di 1), quindi i rapporti t risultano troppo grandi e il test rifiuta H_0 più spesso del 5% anche quando è vera. Servono errori standard robusti all'eteroschedasticità.

Errore tipico. Concludere dall'eteroschedasticità che le stime siano distorte: non lo sono, la media è 0,24986 contro $\beta = 0{,}25$. Il difetto sta negli errori standard. L'errore opposto è fidarsi del test t perché le stime sono centrate: un errore standard troppo piccolo gonfia il rapporto t.

Risposta. **(a)** Sì. **(b)** No: l'omoschedasticità è violata. **(c)** 1,54. **(d)** No: il rapporto è lontano da 1. **(e)** Sì: il rapporto è 1,01. **(f)** È violata l'omoschedasticità: le stime restano non distorte ma gli errori standard usuali sono troppo piccoli, i rapporti t troppo grandi e il test rifiuta troppo spesso; vanno usati errori standard robusti.

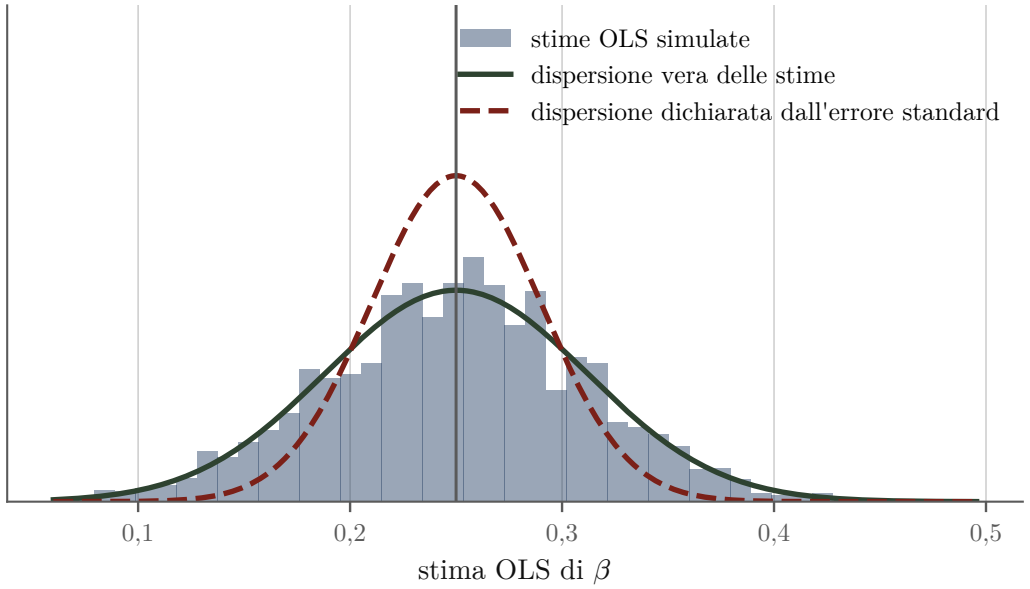


Figura 8.2: Distribuzione simulata delle stime con errori eteroschedastici: la dispersione vera (verde) è molto più ampia di quella che gli errori standard usuali dichiarano (rosso tratteggiato).

9 | Esercizio 9 — Salario e QI: R quadro basso, pendenza significativa *(livello intermedio)*

Dati. Su $n = 400$ lavoratori si è stimato il modello

$$\text{salario} = \alpha + \beta\,\text{qi} + \epsilon,$$

dove `salario` è il salario mensile in centinaia di euro e `qi` il punteggio di un test di quoziente intellettivo. La stima della pendenza è $\hat\beta = 0{,}08430$ e la somma dei quadrati degli scarti di `qi` dalla sua media è $\sum_i (x_i - \bar x)^2 = 83814{,}03$. La tavola ANOVA, con SST = SSE + SSR (totale, spiegata, residua), è la seguente.

fonte	devianza	gdl	media delle devianze
Modello (SSE)	595,61	1	595,61
Residuo (SSR)	9376,90	398	23,560
Totale (SST)	9972,51	399	24,994

Testo della domanda. **Domanda 9** ***(3 punti).*** Si usi il quantile 1,96. **(a)** Si calcoli R^2. **(b)** Si calcoli l'errore standard stimato di $\hat\beta$. **(c)** Si calcoli il rapporto t per $H_0 : \beta = 0$. **(d)** Al livello del 5%, si decida se rifiutare o non rifiutare $H_0 : \beta = 0$ contro $H_1 : \beta \neq 0$. **(e)** Si calcoli la statistica $F = \dfrac{\text{SSE}/1}{\text{SSR}/(n-2)}$. **(f)** Un R^2 così basso implica che il QI non abbia alcun effetto sul salario? Si risponda sì o no.

Richiamo. $R^2 = \text{SSE}/\text{SST}$ è la quota di devianza spiegata. La varianza dell'errore si stima con $\hat\sigma^2 = \text{SSR}/(n-2)$, l'errore standard della pendenza con $\widehat{\text{se}}(\hat\beta) = \hat\sigma \big/ \sqrt{\sum_i (x_i - \bar x)^2}$ e il test di $H_0 : \beta = 0$ usa $t = \hat\beta / \widehat{\text{se}}(\hat\beta)$, che si rifiuta al 5% se $|t| > 1{,}96$. La statistica $F = \dfrac{\text{SSE}/1}{\text{SSR}/(n-2)}$ con un solo regressore coincide con t^2. Un R^2 basso dice che x spiega poco della variabilità di y, non che la pendenza sia nulla.

Svolgimento. **Impostazione.** Dalla tavola ANOVA si ottiene R^2 e $\hat\sigma$; con la dispersione di `qi` si passa all'errore standard, al rapporto t e alla decisione.

(a) $R^2 = \text{SSE}/\text{SST} = 595{,}61/9972{,}51 = 0{,}0597$.

(b) $\hat{\sigma} = \sqrt{\mathrm{SSR}/(n-2)} = \sqrt{9376{,}90/398} = 4{,}854$ e $\widehat{\mathrm{se}}(\hat{\beta}) = \hat{\sigma}/\sqrt{\sum_i (x_i - \bar{x})^2} = 4{,}854/\sqrt{83814{,}03} = 0{,}0168$.

(c) $t = \hat{\beta}/\widehat{\mathrm{se}}(\hat{\beta}) = 0{,}08430/0{,}0168 = 5{,}03$.

(d) $|t| = 5{,}03$ supera 1,96: si rifiuta H_0.

(e) $F = \dfrac{595{,}61/1}{9376{,}90/398} = 25{,}28$, che coincide con $t^2 = 25{,}28$ a meno dell'arrotondamento.

(f) No: la pendenza è significativa nonostante l'R^2 basso.

Errore tipico. Concludere da un R^2 basso (0,0597) che x non abbia effetto: l'R^2 misura quanta variabilità di y è spiegata, il test su β misura se la pendenza si distingue da zero. Con tanti dati si stima bene una pendenza anche se attorno alla retta c'è molta dispersione. Un altro errore è dividere SSR per n invece che per $n-2$ nel calcolo di $\hat{\sigma}$.

Risposta. **(a)** $R^2 = 0{,}0597$. **(b)** $\widehat{\mathrm{se}}(\hat{\beta}) = 0{,}0168$. **(c)** $t = 5{,}03$. **(d)** Si rifiuta H_0: il QI è significativo al 5%. **(e)** $F = 25{,}28 = t^2$. **(f)** No: il QI spiega poco della variabilità del salario ma la sua pendenza è significativamente diversa da zero.

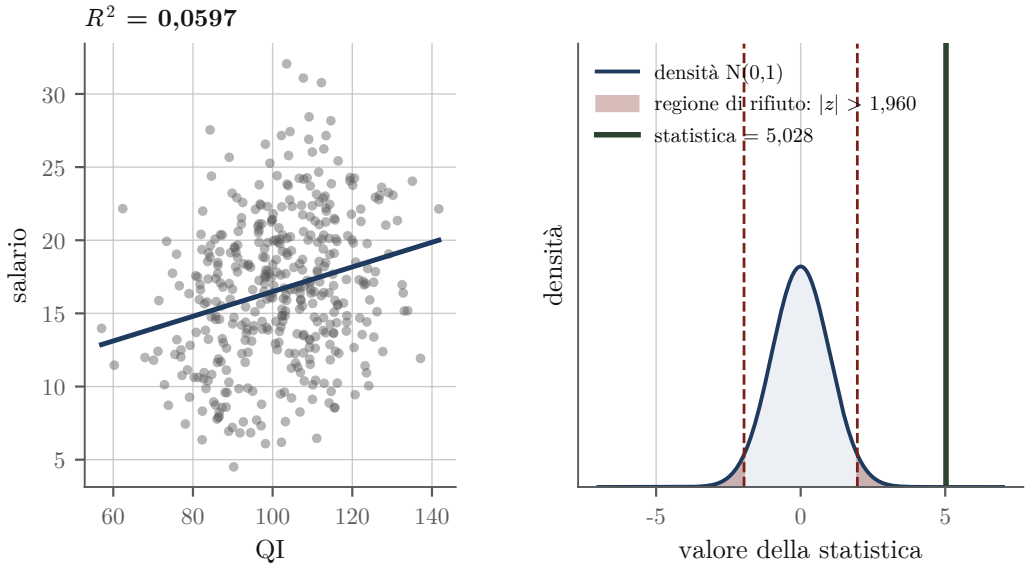


Figura 9.1: A sinistra la nuvola con la retta stimata (R^2 basso: molta dispersione); a destra il rapporto $t = 5{,}03$ ben dentro la regione di rifiuto.

10 | Esercizio 10 — Visite commerciali e vendite: oltre la soglia, ma non significativamente *(livello appello)*

Dati. Su $n = 160$ agenti commerciali si è stimato il modello

$$\log(\text{vendite}) = \alpha + \beta\,\text{visite} + \epsilon,$$

dove `visite` è il numero di visite settimanali ai clienti. Le variazioni percentuali si calcolano con l'approssimazione $\Delta\%\, y \approx 100\,\Delta \log(y)$. Le stime OLS sono le seguenti.

	coefficiente	errore std.	rapporto t	p-value
const	8,23411	0,0874415	94,17	1,04e-140
visite	0,0617416	0,00941709	6,556	7,43e-10

n = 160; $R^2 = 0{,}213874$; SSR = 45,975

Testo della domanda. **Domanda 10** ***(4 punti).*** Il direttore commerciale sostiene che 2 visite in più alla settimana fanno salire le vendite del 10%. Si indichi con κ il valore di β per cui 2 visite valgono esattamente il 10%. Il quantile unilaterale al 5% della normale standard è 1,64. **(a)** Di quanto varia in percentuale, secondo la stima, il valore atteso delle vendite per 2 visite in più? **(b)** Si calcoli il rapporto $t = (\hat{\beta} - \kappa)/\widehat{\text{se}}(\hat{\beta})$. **(c)** Se l'affermazione fosse «almeno il 10%», al livello del 5% si decida se rifiutare o non rifiutare $H_0 : \beta \geq \kappa$ contro $H_1 : \beta < \kappa$. **(d)** Se l'affermazione fosse «più del 10%», al livello del 5% si decida se rifiutare o non rifiutare $H_0 : \beta \leq \kappa$ contro $H_1 : \beta > \kappa$. **(e)** Si può affermare, al livello del 5%, che 2 visite in più fanno salire le vendite di più del 10%? Si affermi soltanto ciò che i dati permettono di dedurre rifiutando l'ipotesi nulla contraria. Si risponda sì o no.

Richiamo. Con la dipendente in logaritmo $\Delta\%\, y \approx 100\,\beta\,\Delta x$: «$\Delta x$ visite valgono il $s\%$» (con s la percentuale dichiarata) equivale a $\beta = \kappa = s/(100\,\Delta x)$. Con $t = (\hat{\beta} - \kappa)/\widehat{\text{se}}(\hat{\beta})$, l'affermazione «almeno» è $H_0 : \beta \geq \kappa$ contro $H_1 : \beta < \kappa$ e si rifiuta se $t < -1{,}64$; l'affermazione «più di» si verifica con $H_0 : \beta \leq \kappa$ contro $H_1 : \beta > \kappa$ e si rifiuta se $t > 1{,}64$. Si può affermare H_1 solo se H_0 è rifiutata: una stima puntuale oltre la soglia non basta.

Svolgimento. **Impostazione.** Si porta la soglia su β, si calcola un'unica statistica t e la si confronta con le due code.

(a) $100 \times 2 \times \hat{\beta} = 100 \times 2 \times 0{,}0617 = 12{,}3\%$, sopra la soglia del 10%.

(b) $\kappa = 10/(100 \times 2) = 0{,}050$ e $t = \dfrac{\hat{\beta} - \kappa}{\widehat{\mathrm{se}}(\hat{\beta})} = \dfrac{0{,}0617 - 0{,}050}{0{,}0094} = 1{,}25$.

(c) «Almeno»: $t = 1{,}25 > -1{,}64$, non si rifiuta $H_0 : \beta \geq \kappa$.

(d) «Più di»: $t = 1{,}25 < 1{,}64$, non si rifiuta $H_0 : \beta \leq \kappa$.

(e) Per affermare «più del 10%» si dovrebbe rifiutare $H_0 : \beta \leq \kappa$, e non succede: no.

Errore tipico. Concludere dalla stima puntuale (12,3% contro 10%) che l'effetto superi la soglia. Lo scarto è di soli 1,25 errori standard: i dati sono compatibili sia con $\beta \geq \kappa$ sia con $\beta < \kappa$, nessuna delle due ipotesi si rifiuta. Un altro errore è usare il rapporto t della tabella (6,56), che verifica $\beta = 0$, o confrontare con la coda sbagliata.

Risposta. **(a)** Circa 12,3%. **(b)** $t = 1{,}25$. **(c)** Non si rifiuta H_0. **(d)** Non si rifiuta H_0. **(e)** No: la stima supera la soglia ma non in modo statisticamente significativo, quindi non si può affermare che le vendite crescano di più del 10% e non si può nemmeno escludere che crescano di meno.

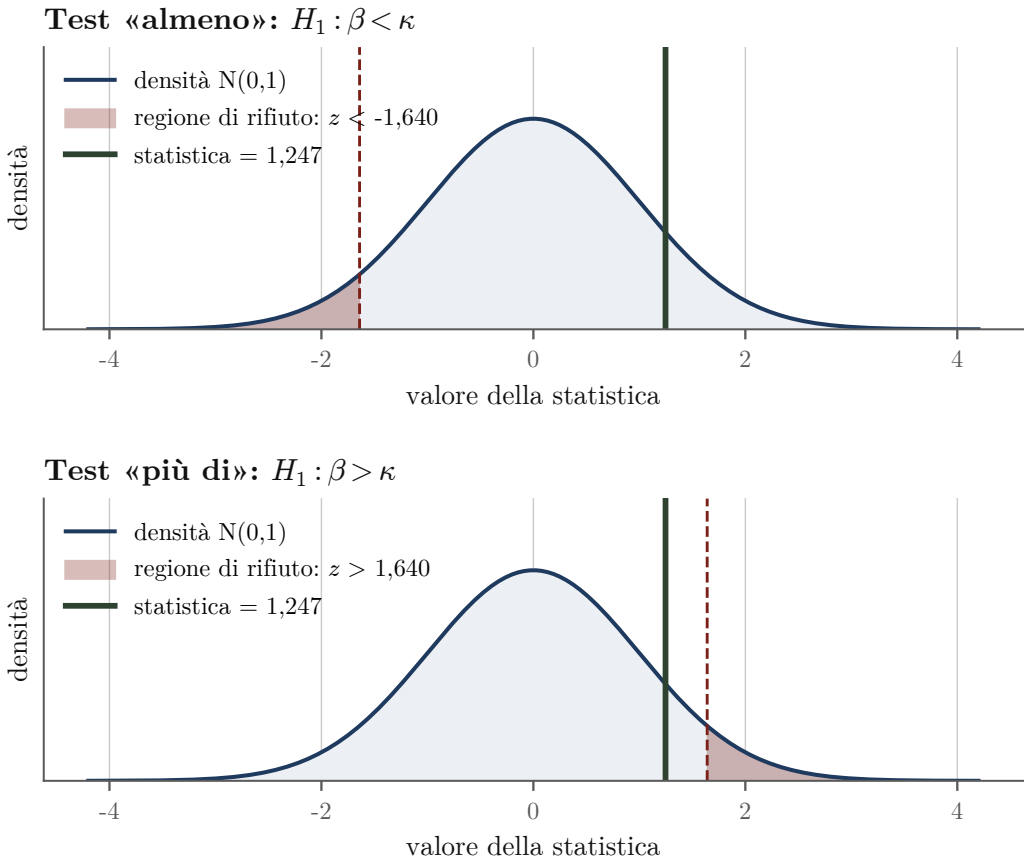


Figura 10.1: Lo stesso rapporto $t = 1{,}25$ nelle due regioni di rifiuto unilaterali al 5%: in nessuno dei due test cade nella regione.

11 | Esercizio 11 — Costi di produzione: errori standard e due test *(livello appello)*

Dati. Su $n = 36$ mesi di attività di un'impresa si è stimato il modello

$$\text{costo} = \alpha + \beta\,\text{prod} + \epsilon,$$

dove `costo` è il costo totale mensile in migliaia di euro e `prod` la produzione mensile in migliaia di pezzi: α misura i costi fissi e β il costo variabile per migliaio di pezzi. Gli errori sono omoschedastici. I coefficienti stimati sono i seguenti.

	coefficiente
const	48,3135
prod	3,1244

Si conoscono inoltre la somma dei quadrati dei residui, SSR = 1247,18, la somma dei quadrati degli scarti della produzione dalla sua media, $\sum_i (x_i - \bar{x})^2 = 2495{,}44$, e la produzione media, $\bar{x} = 39{,}3189$. L'errore standard dell'intercetta è $\widehat{\text{se}}(\hat{\alpha}) = \sqrt{\hat{\sigma}^2 \left(\frac{1}{n}\sum_i x_i^2\right) \big/ \sum_i (x_i - \bar{x})^2}$, con $\sum_i x_i^2 = \sum_i (x_i - \bar{x})^2 + n\bar{x}^2$.

Testo della domanda. **Domanda 11** ***(4 punti).*** L'impresa dichiara che il costo variabile è di 3000 euro per ogni migliaio di pezzi e che i costi fissi sono di 35000 euro al mese. Si usi il quantile 1,96. **(a)** Si calcoli $\hat{\sigma}$, l'errore standard della regressione. **(b)** Si calcoli l'errore standard stimato di $\hat{\beta}$. **(c)** Si indichi con β_0 il costo variabile dichiarato, espresso nelle unità del modello: si calcoli il rapporto $t = (\hat{\beta} - \beta_0)/\widehat{\text{se}}(\hat{\beta})$ per $H_0 : \beta = \beta_0$ contro $H_1 : \beta \neq \beta_0$. **(d)** Al livello del 5%, si decida se rifiutare o non rifiutare tale H_0. **(e)** Si calcoli l'errore standard stimato di $\hat{\alpha}$. **(f)** Si indichi con α_0 il costo fisso dichiarato, espresso nelle unità del modello: al livello del 5%, si decida se rifiutare o non rifiutare $H_0 : \alpha = \alpha_0$ contro $H_1 : \alpha \neq \alpha_0$.

Richiamo. Con errori omoschedastici $\hat{\sigma}^2 = \text{SSR}/(n-2)$, $\widehat{\text{se}}(\hat{\beta}) = \sqrt{\hat{\sigma}^2 \big/ \sum_i (x_i - \bar{x})^2}$ e $\widehat{\text{se}}(\hat{\alpha}) = \sqrt{\hat{\sigma}^2 \left(\frac{1}{n}\sum_i x_i^2\right) \big/ \sum_i (x_i - \bar{x})^2}$, con $\sum_i x_i^2 = \sum_i (x_i - \bar{x})^2 + n\bar{x}^2$. Per un valore puntuale non nullo,

$H_0 : \theta = \theta_0$ contro $H_1 : \theta \neq \theta_0$, la statistica è $t = (\hat{\theta} - \theta_0)/\widehat{\text{se}}(\hat{\theta})$ e al 5% si rifiuta se $|t| > 1{,}96$. Il valore dichiarato va espresso nelle unità del modello.

Svolgimento. **Impostazione.** Gli errori standard non sono dati: si costruiscono da SSR e dalla dispersione di `prod`. I valori dichiarati sono in euro, il modello è in migliaia di euro: si dividono per mille.

(a) $n - 2 = 34$, $\hat{\sigma}^2 = 1247{,}18/34 = 36{,}682$ e $\hat{\sigma} = \sqrt{36{,}682} = 6{,}057$.

(b) $\widehat{\text{se}}(\hat{\beta}) = \sqrt{36{,}682/2495{,}44} = 0{,}1212$.

(c) Il costo variabile dichiarato è $3000/1000 = 3{,}0$ migliaia di euro per migliaio di pezzi. $t = \dfrac{3{,}1244 - 3{,}0}{0{,}1212} = 1{,}03$.

(d) $|t| = 1{,}03$ è minore di 1,96: non si rifiuta H_0.

(e) $\sum_i x_i^2 = 2495{,}44 + 36 \times 39{,}3189^2 = 58151$ e $\widehat{\text{se}}(\hat{\alpha}) = \sqrt{36{,}682 \times \dfrac{58151}{36} \Big/ 2495{,}44} = 4{,}873$.

(f) I costi fissi dichiarati sono $35000/1000 = 35$ migliaia di euro. $t = \dfrac{48{,}3135 - 35}{4{,}873} = 2{,}73$, maggiore di 1,96: si rifiuta H_0.

Errore tipico. Confrontare 3000 con $\hat{\beta} = 3{,}1244$ senza convertire in migliaia di euro: il rapporto t verrebbe enorme e si rifiuterebbe sempre. Altri errori: dividere SSR per n invece che per $n-2$, e usare per l'intercetta l'errore standard della pendenza (0,1212 invece di 4,873), che ignora il termine $\bar{x}^2$: l'intercetta è stimata molto meno precisamente perché la retta è estrapolata fino a produzione zero.

Risposta. **(a)** $\hat{\sigma} = 6{,}057$. **(b)** $\widehat{\text{se}}(\hat{\beta}) = 0{,}1212$. **(c)** $t = 1{,}03$. **(d)** Non si rifiuta H_0: il costo variabile dichiarato è compatibile con i dati. **(e)** $\widehat{\text{se}}(\hat{\alpha}) = 4{,}873$. **(f)** Si rifiuta H_0: i costi fissi dichiarati sono significativamente diversi dalla stima 48,3135 migliaia di euro (rapporto $t = 2{,}73$).

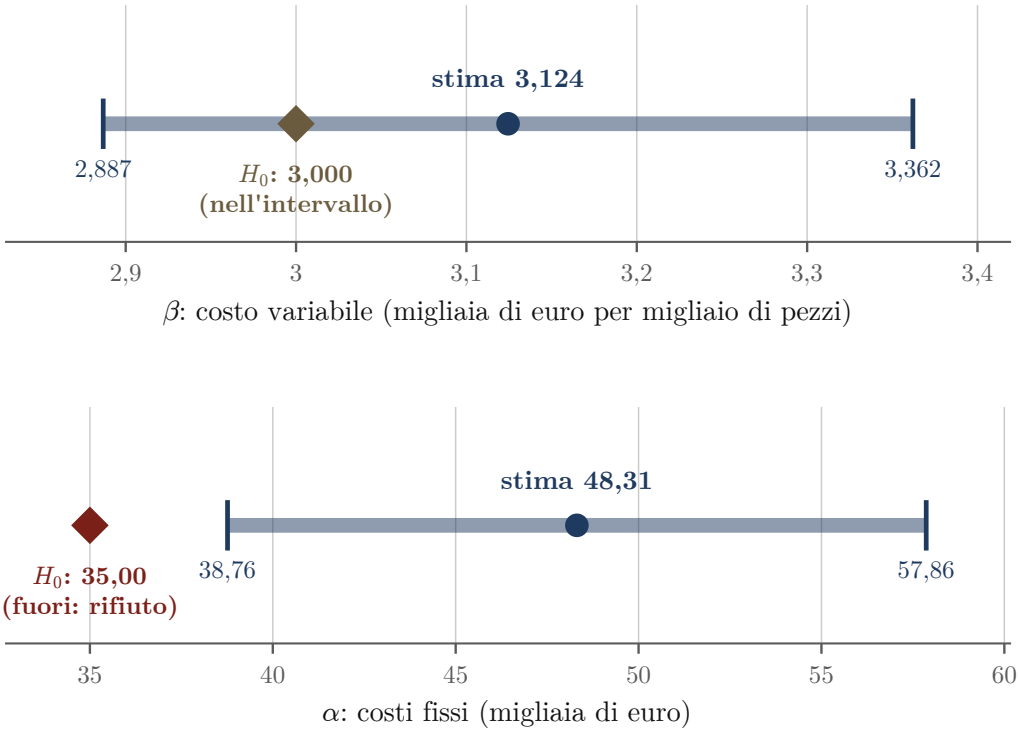


Figura 11.1: Intervalli di confidenza al 95% di β (sopra) e α (sotto) con i valori dichiarati: il costo variabile è dentro l'intervallo, i costi fissi sono fuori.

12 | Esercizio 12 — Nord e Sud: la differenza fra due pendenze *(livello appello)*

Dati. Un'agenzia stima separatamente, su $n_N = 140$ appartamenti del Nord e su $n_S = 110$ del Sud, il modello

$$\text{prezzo} = \alpha + \beta\,\text{sup} + \epsilon,$$

dove `prezzo` è in migliaia di euro e `sup` è la superficie in metri quadrati; β_N e β_S sono i prezzi marginali (migliaia di euro per metro quadrato) delle due aree. I due campioni sono indipendenti, quindi le due stime sono incorrelate: $\widehat{\text{Cov}}(\hat\beta_N, \hat\beta_S) = 0$.

Nord:

	coefficiente	errore std.	rapporto t	p-value
const	31,6316	10,6188	2,979	0,0034
sup	2,61155	0,111882	23,34	9,18e-50

n = 140; R^2 = 0,797905; SSR = 116854

Sud:

	coefficiente	errore std.	rapporto t	p-value
const	21,8921	11,7685	1,86	0,0656
sup	2,18619	0,131849	16,58	1,87e-31

n = 110; R^2 = 0,717964; SSR = 82061,8

Testo della domanda. **Domanda 12** ***(4 punti).*** Si usi il quantile 1,96. **(a)** Gli intervalli di confidenza al 95% per β_N e per β_S si sovrappongono? Si risponda sì o no. **(b)** Si calcoli l'errore standard stimato della differenza $\hat\beta_N - \hat\beta_S$. **(c)** Qual è l'estremo inferiore dell'intervallo di confidenza al 95% per $\beta_N - \beta_S$? **(d)** E l'estremo superiore? **(e)** Al livello del 5%, la differenza fra i due prezzi marginali è significativa, cioè si rifiuta $H_0 : \beta_N = \beta_S$ contro $H_1 : \beta_N \neq \beta_S$? Si risponda sì o no. **(f)** La risposta di (a) basta a decidere su (e)? Si spieghi.

Richiamo. L'intervallo di confidenza al 95% per una pendenza è $\hat\beta \pm 1{,}96\,\widehat{\text{se}}(\hat\beta)$. Per la differenza di due stime da campioni indipendenti la covarianza è nulla, quindi $\text{Var}(\hat\beta_N - \hat\beta_S) = \text{Var}(\hat\beta_N) + \text{Var}(\hat\beta_S)$ e $\widehat{\text{se}}(\hat\beta_N - \hat\beta_S) = \sqrt{\widehat{\text{se}}_N^2 + \widehat{\text{se}}_S^2}$, che è minore di $\widehat{\text{se}}_N + \widehat{\text{se}}_S$. L'intervallo della differenza è $(\hat\beta_N - \hat\beta_S) \pm 1{,}96\,\widehat{\text{se}}(\hat\beta_N - \hat\beta_S)$ e la differenza è significativa al 5% se lo zero ne sta fuori.

Svolgimento. **Impostazione.** Si confrontano prima i due intervalli, poi si costruisce l'intervallo della differenza con l'errore standard giusto.

(a) Nord: $2{,}6115 \pm 1{,}96 \times 0{,}1119 = [2{,}392;\ 2{,}831]$. Sud: $2{,}1862 \pm 1{,}96 \times 0{,}1318 = [1{,}928;\ 2{,}445]$. Il limite inferiore del Nord, 2,392, è sotto il limite superiore del Sud, 2,445: gli intervalli si sovrappongono.

(b) $\widehat{\text{se}}(\hat\beta_N - \hat\beta_S) = \sqrt{0{,}1119^2 + 0{,}1318^2} = 0{,}1729$.

(c) e **(d)** $\hat\beta_N - \hat\beta_S = 2{,}6115 - 2{,}1862 = 0{,}4254$ e l'intervallo è $0{,}4254 \pm 1{,}96 \times 0{,}1729 = [0{,}0864;\ 0{,}7643]$.

(e) Lo zero è fuori dall'intervallo: si rifiuta $H_0 : \beta_N = \beta_S$. Lo stesso dice $t = 0{,}4254/0{,}1729 = 2{,}46$, maggiore di 1,96.

(f) No: la sovrapposizione dei due intervalli singoli non implica che la differenza non sia significativa.

Errore tipico. Concludere dalla sovrapposizione degli intervalli che la differenza non sia significativa. Sommando gli errori standard, $0{,}1119 + 0{,}1318 = 0{,}2437$ invece di sommare le varianze, si ottiene un intervallo troppo largo, con limite inferiore $-0{,}052$, che include lo zero: ma per due stime indipendenti si sommano le varianze, non gli errori standard, e l'errore standard della differenza è 0,1729.

Risposta. **(a)** Sì, i due intervalli si sovrappongono. **(b)** 0,1729. **(c)** 0,0864. **(d)** 0,7643. **(e)** Sì: lo zero è fuori dall'intervallo [0,0864; 0,7643], quindi si rifiuta H_0 e il prezzo marginale del Nord è significativamente più alto. **(f)** No: due intervalli singoli possono sovrapporsi anche quando la differenza è significativa, perché l'errore standard della differenza è minore della somma dei due.

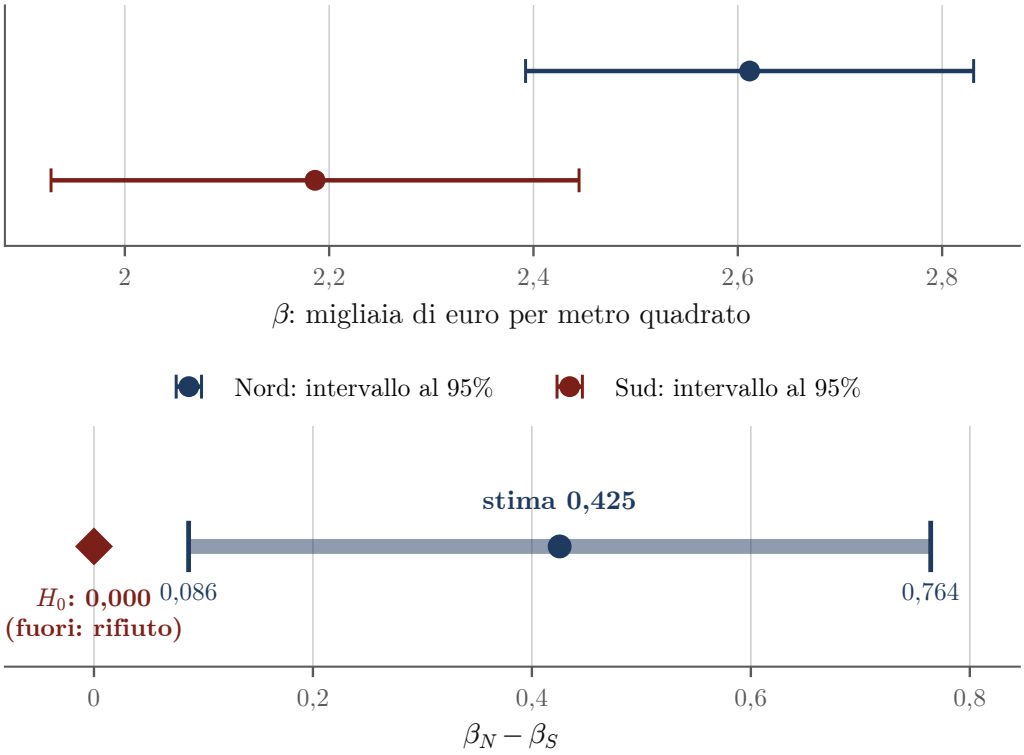


Figura 12.1: In alto i due intervalli singoli, che si sovrappongono; in basso l'intervallo della differenza $\beta_N - \beta_S$, che non contiene lo zero.