Università Ca' Foscari Venezia

Dipartimento di Economia

Laurea Magistrale in
Economia e Finanza

Modulo 03 — Regressione multipla

Soluzioni svolte e commentate

Appunti di:
Silvio Angelo Baratto Roldan

Codice insegnamento:
EM0004

Contenuto:
13 esercizi

Esercizi sintetici costruiti a fini di studio sul modello dei veri appelli e sulla teoria del corso (Econometria EM0004, prof. Davide Raggi). Non sono materiale ufficiale del docente.

Indice

1 **Esercizio 1 — Il rendimento dell'istruzione** *(livello base)* 1

2 **Esercizio 2 — Prezzo delle case e inquinamento** *(livello base)* 3

3 **Esercizio 3 — Il reddito e il suo quadrato: i VIF** *(livello base)* 5

4 **Esercizio 4 — Salario, istruzione e stato civile: percentuali e dollari** *(livello intermedio)* 8

5 **Esercizio 5 — Ricchezza e logaritmo del reddito** *(livello intermedio)* 10

6 **Esercizio 6 — Esperienza e salario: una relazione non lineare** *(livello intermedio)* 12

7 **Esercizio 7 — Salario, istruzione e ore lavorate** *(livello intermedio)* 14

8 **Esercizio 8 — Il reddito dichiarato** *(livello intermedio)* 17

9 **Esercizio 9 — Classe e reddito: il teorema di Frisch-Waugh-Lovell** *(livello intermedio)* 19

10 **Esercizio 10 — Reddito e spesa: non linearità, punto di svolta e dollari** *(livello appello)* 22

11 **Esercizio 11 — Affitti: superficie e distanza dal centro** *(livello appello)* 25

12 **Esercizio 12 — Esperienza e anzianità: collinearità o variabile omessa?** *(livello appello)* 27

13 **Esercizio 13 — Salario, istruzione e abilità** *(livello appello)* 30

1 | Esercizio 1 — Il rendimento dell'istruzione *(livello base)*

Dati. Su $n = 400$ lavoratori si è stimato il modello

$$\log(\text{salario}) = \beta_0 + \beta_1\,\text{istr} + \beta_2\,\text{esper} + \epsilon,$$

dove `istr` sono gli anni di istruzione ed `esper` gli anni di esperienza. Le variazioni percentuali si calcolano con l'approssimazione $\Delta\%\, y \approx 100\,\Delta \log(y)$. Le stime OLS sono le seguenti.

	coefficiente	errore std.	rapporto t	p-value
const	1,2707	0,0840957	15,11	4,5e-41
istr	0,0665677	0,00544415	12,23	2,13e-29
esper	0,0131933	0,00228312	5,779	1,52e-08

n = 400; $R^2 = 0{,}319112$; SSR = 66,5684

Testo della domanda. **Domanda 1** ***(3 punti).*** **(a)** Di quanto varia in percentuale, in media, il salario per un anno di istruzione in più? **(b)** Al livello del 5%, si decida se rifiutare o non rifiutare $H_0 : \beta_1 = 0$ contro $H_1 : \beta_1 \neq 0$ (cioè se l'istruzione ha un effetto significativo sul salario).

Richiamo. Con la dipendente in logaritmo, una variazione Δx del regressore dà $\Delta \log(y) = \beta\,\Delta x$, e poiché $\Delta \log(y) \approx \Delta y / y$ la variazione percentuale attesa è $100 \cdot \beta\,\Delta x$. Per decidere su $H_0 : \beta = 0$ si guarda l'intervallo di confidenza al 95%, $\hat{\beta} \pm 1{,}96\,\widehat{\text{se}}(\hat{\beta})$: se lo zero ne sta fuori si rifiuta.

Svolgimento. **Impostazione.** La (a) chiede un effetto in percentuale su una dipendente in logaritmo; la (b) è un test bilaterale su β_1.

(a) Con $\Delta\text{istr} = 1$: $\Delta\%\,\text{salario} \approx 100 \times \hat{\beta}_1 = 100 \times 0{,}0666 = 6{,}7$.

(b) Si verifica $H_0 : \beta_1 = 0$ contro $H_1 : \beta_1 \neq 0$. L'intervallo di confidenza al 95% è [0,0559; 0,0772] e lo zero ne è fuori. Lo stesso dice il rapporto $t = 12{,}23$, in valore assoluto maggiore di 1,96.

Errore tipico. Leggere $\hat{\beta}_1 = 0{,}0666$ come se fosse già una percentuale. Con la dipendente in logaritmo il coefficiente è una variazione in punti di log: va moltiplicato per 100.

Risposta. **(a)** Un anno di istruzione in più fa aumentare il salario di circa 6,7%. **(b)** Lo zero non cade nell'intervallo di confidenza al 95%, quindi si rifiuta H_0: l'istruzione è significativa al 5%.

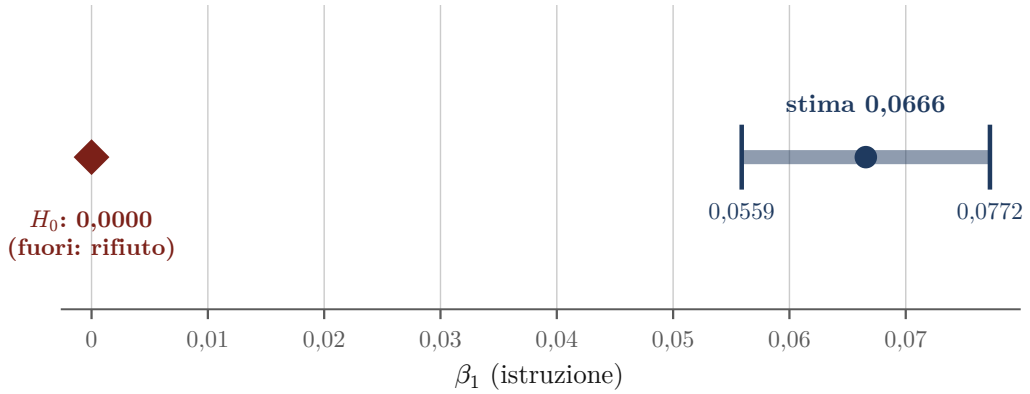


Figura 1.1: Intervallo di confidenza al 95% per β_1, [0,0559; 0,0772]: lo zero è fuori dall'intervallo.

2 | Esercizio 2 — Prezzo delle case e inquinamento *(livello base)*

Dati. Su $n = 400$ distretti si è stimato il modello

$$\log(\text{prezzo}) = \beta_0 + \beta_1 \log(\text{nox}) + \beta_2 \log(\text{dist}) + \epsilon,$$

dove `prezzo` è il prezzo mediano delle case, `nox` la concentrazione di ossidi di azoto (una misura dell'inquinamento) e `dist` la distanza dai centri lavorativi. Nella tabella `l_nox` e `l_dist` sono i logaritmi di `nox` e di `dist`. Le variazioni percentuali si calcolano con l'approssimazione $\Delta \log(z) \approx \Delta z / z$. Le stime OLS sono le seguenti.

	coefficiente	errore std.	rapporto t	p-value
const	10,3543	0,067631	153,1	0,0000
l_nox	−0,436322	0,0351856	−12,4	4,5e-30
l_dist	−0,178962	0,0237073	−7,549	3,04e-13

n = 400; $R^2 = 0{,}336757$; SSR = 23,7084

Testo della domanda. **Domanda 2** ***(3 punti).*** **(a)** Qual è l'elasticità del prezzo rispetto all'inquinamento? **(b)** Di quanto varia in percentuale il prezzo atteso se `nox` aumenta del 5%? **(c)** Al livello del 5%, si decida se rifiutare o non rifiutare $H_0 : \beta_1 = 0$ contro $H_1 : \beta_1 \neq 0$.

Richiamo. Con dipendente e regressore entrambi in logaritmo, $\Delta \log(y) = \beta \, \Delta \log(x)$ e, poiché $\Delta \log(z) \approx \Delta z / z$, si ha $\Delta y / y \approx \beta \, \Delta x / x$: β è l'elasticità, il rapporto fra la variazione percentuale di y e quella di x. Una variazione di x del m per cento fa variare y di $\beta \, m$ per cento. Per decidere su $H_0 : \beta = 0$ si guarda l'intervallo di confidenza al 95%, $\hat{\beta} \pm 1{,}96 \, \widehat{\text{se}}(\hat{\beta})$.

Svolgimento. **Impostazione.** Dipendente e regressore sono in logaritmo: $\hat{\beta}_1$ si legge come elasticità e la variazione di `nox` entra già in percentuale, senza moltiplicare per 100.

(a) L'elasticità è $\hat{\beta}_1 = -0{,}436$.

(b) $\Delta\%\,\text{prezzo} \approx \hat{\beta}_1 \times \Delta\%\,\text{nox} = -0{,}436 \times 5 = -2{,}18\%$.

(c) Si verifica $H_0 : \beta_1 = 0$ contro $H_1 : \beta_1 \neq 0$. L'intervallo di confidenza al 95% è $[-0{,}505; -0{,}367]$ e lo zero ne è fuori. Lo stesso dice $t = -12{,}40$, in valore assoluto maggiore di 1,96.

Errore tipico. Moltiplicare $\hat{\beta}_1$ per 100 come si fa con un regressore in livello. Qui $\hat{\beta}_1$ è già il rapporto fra due variazioni percentuali: $100 \times \hat{\beta}_1$ darebbe la variazione per $\Delta \log(\text{nox}) = 1$, non per un raddoppio: un raddoppio è $\Delta \log(\text{nox}) = \ln 2$ e l'approssimazione lineare non regge per variazioni così grandi.

Risposta. **(a)** L'elasticità del prezzo rispetto all'inquinamento è $-0{,}436$: ad ogni aumento dell'1% di `nox` il prezzo atteso varia di circa $-0{,}436\%$. **(b)** Con `nox` $+5\%$ il prezzo varia di circa $-2{,}18\%$. **(c)** Lo zero non cade nell'intervallo di confidenza al 95%, quindi si rifiuta H_0: l'effetto è significativo al 5%.

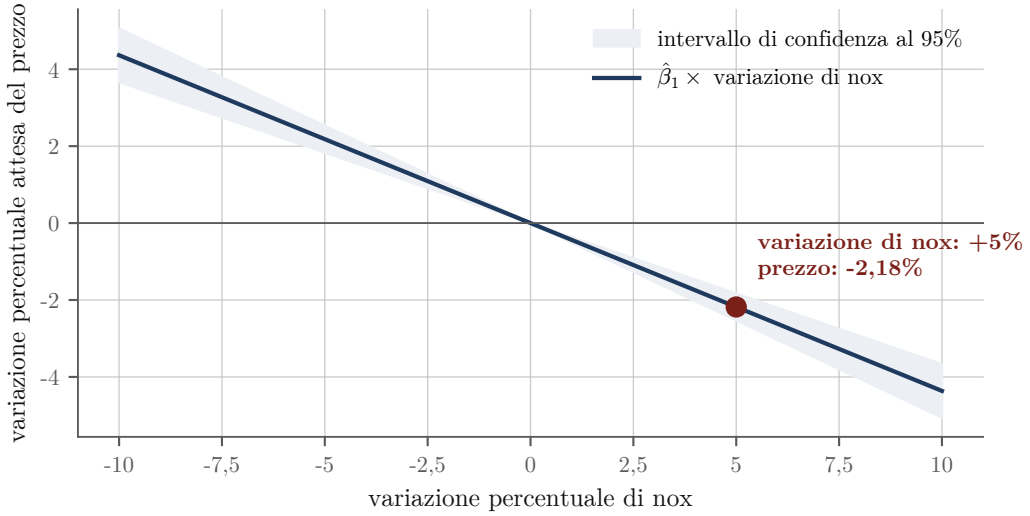


Figura 2.1: Variazione percentuale attesa del prezzo al variare di `nox`: retta di pendenza $\hat{\beta}_1 = -0{,}436$ con banda al 95%. Per $+5\%$ di `nox` il prezzo varia di $-2{,}18\%$.

3 | Esercizio 3 — Il reddito e il suo quadrato: i VIF *(livello base)*

Dati. Su $n = 150$ famiglie si è stimato il modello

$$\log(\text{consumi}) = \beta_0 + \beta_1\,\text{reddito} + \beta_2\,\text{reddito}^2 + \beta_3\,\text{famiglia} + \beta_4\,\text{eta} + \beta_5\,\text{proprieta} + \epsilon,$$

dove `reddito` è misurato in decine di migliaia di dollari, `sq_reddito` è il suo quadrato, `famiglia` è il numero di componenti, `eta` l'età del capofamiglia e `proprieta` vale 1 se la famiglia possiede l'abitazione. Le stime OLS sono le seguenti.

	coefficiente	errore std.	rapporto t	p-value
const	5,26061	0,484547	10,86	1,96e-20
reddito	0,22017	0,151108	1,457	0,1473
sq_reddito	−0,0184085	0,0126829	−1,451	0,1488
famiglia	0,14199	0,0295808	4,8	3,93e-06
eta	0,00953397	0,00390719	2,44	0,0159
proprieta	0,252382	0,103631	2,435	0,0161

n = 150; $R^2 = 0{,}199252$; SSR = 56,2097

I fattori di inflazione della varianza sono $\text{VIF}(j) = 1/(1-R_j^2)$, dove R_j^2 è l'R^2 della regressione di x_j sugli altri regressori.

variabile	VIF
reddito	16,850
sq_reddito	16,856
famiglia	1,018
eta	1,018
proprieta	1,030

Testo della domanda. **Domanda 3** ***(3 punti).*** Si usi la soglia 10 per il VIF. **(a)** Quanti regressori presentano un VIF superiore alla soglia? **(b)** Rispetto al caso in cui i regressori fossero indipendenti fra loro, di quante volte ci si aspetta che sia gonfiato l'errore standard

del coefficiente di `reddito`? **(c)** La non significatività del coefficiente di `reddito` al 5% può dipendere dalla quasi-collinearità? Si risponda sì o no.

Richiamo. Per lo stimatore di β_j vale $\widehat{\mathrm{Var}}(\hat{\beta}_j) = \dfrac{\hat{\sigma}^2}{\sum_i (x_{ij} - \bar{x}_j)^2} \cdot \dfrac{1}{1 - R_j^2}$ e il secondo fattore è il VIF_j. Rispetto al caso di regressori indipendenti ($R_j^2 = 0$) la varianza è moltiplicata per il VIF e l'errore standard per $\sqrt{\mathrm{VIF}_j}$. Con un VIF maggiore di 10 si parla di quasi-collinearità. La quasi-collinearità non distorce gli stimatori: ne gonfia soltanto gli errori standard e abbassa le statistiche t.

Svolgimento. **Impostazione.** La (a) è un confronto di ogni VIF con la soglia 10; la (b) è la radice quadrata del VIF di `reddito`; la (c) incrocia il VIF con la significatività del coefficiente.

(a) I VIF di `reddito` (16,850) e di `sq_reddito` (16,856) superano 10; tutti gli altri stanno sotto soglia, il più alto è 1,030. I regressori sopra soglia sono 2.

(b) $\sqrt{\mathrm{VIF}} = \sqrt{16{,}850} = 4{,}10$: l'errore standard di $\hat{\beta}_1$ è circa 4,10 volte quello che si avrebbe con regressori indipendenti.

(c) Il coefficiente di `reddito` ha $t = 1{,}46$, in valore assoluto minore di 1,96: non è significativo. Il suo VIF supera 10.

Errore tipico. Rispondere 16,850 volte, cioè il VIF stesso: il VIF moltiplica la varianza, e l'errore standard ne è la radice. Un altro errore è dedurre dal VIF alto che le stime siano distorte: la quasi-collinearità gonfia la varianza, non crea distorsione. Il VIF alto fra x e x^2 è strutturale (centrando x scompare, senza cambiare adattamento né effetti marginali), e la t di β_1 verifica l'effetto marginale in reddito $= 0$, non la rilevanza del reddito, che si giudica con un test F congiunto su $H_0 : \beta_1 = \beta_2 = 0$ o con l'effetto marginale a livelli osservati.

Risposta. **(a)** Due regressori hanno un VIF superiore a 10: `reddito` e `sq_reddito`, com'è naturale perché la seconda è il quadrato della prima. **(b)** L'errore standard di `reddito` è gonfiato di circa 4,10 volte. **(c)** Sì: il VIF è maggiore di 10 e il coefficiente non è significativo, quindi la quasi-collinearità è una spiegazione plausibile della non significatività.

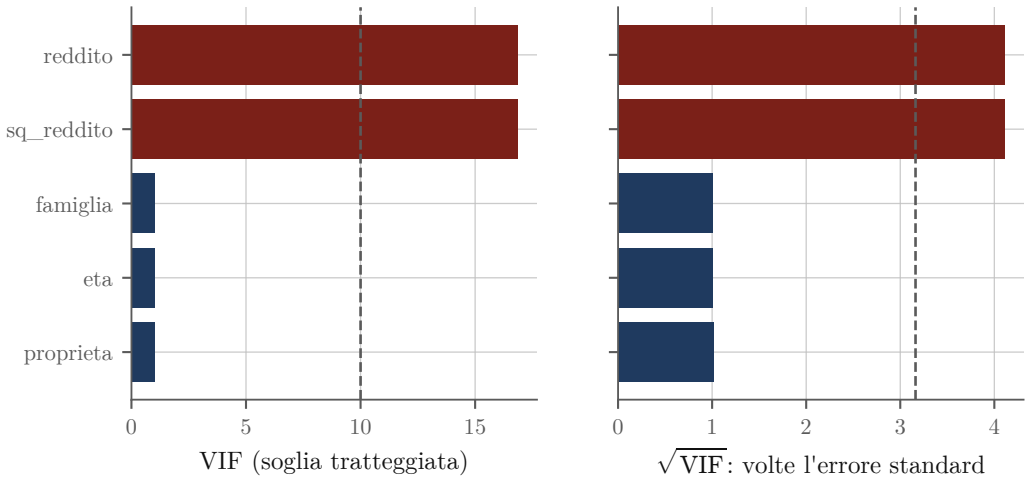


Figura 3.1: VIF di ogni regressore con la soglia 10 (a sinistra) e fattore $\sqrt{\text{VIF}}$ di aumento dell'errore standard (a destra): in rosso i due regressori sopra soglia.

4 | Esercizio 4 — Salario, istruzione e stato civile: percentuali e dollari *(livello intermedio)*

Dati. Su $n = 500$ lavoratori si è stimato il modello

$$\log(\text{salario}) = \beta_0 + \beta_1\,\text{istr} + \beta_2\,\text{esper} + \beta_3\,\text{sposato} + \epsilon,$$

dove `salario` è il salario mensile in dollari, `istr` ed `esper` sono gli anni di istruzione e di esperienza e `sposato` vale 1 per i lavoratori sposati e 0 per gli altri. Le variazioni percentuali si calcolano con l'approssimazione $\Delta\%\, y \approx 100\,\Delta \log(y)$. Le stime OLS sono le seguenti.

	coefficiente	errore std.	rapporto t	p-value
const	6,20024	0,0846486	73,25	3,93e-268
istr	0,0634816	0,00521189	12,18	4,86e-30
esper	0,0149685	0,00213609	7,007	7,96e-12
sposato	0,0839911	0,0380345	2,208	0,0277

n = 500; $R^2 = 0{,}291234$; SSR = 88,7779

Testo della domanda. **Domanda 4** ***(3 punti).*** **(a)** Di quanti anni deve aumentare l'istruzione perché il salario atteso cresca del 15%, a parità di esperienza e di stato civile? **(b)** Di quanto è più alto in percentuale, in media, il salario di un lavoratore sposato rispetto a quello di un single con le stesse altre caratteristiche? **(c)** Un single guadagna 2000 dollari al mese: di quanti dollari in più guadagna in media uno sposato con le stesse altre caratteristiche? **(d)** Un collega sostiene che uno sposato guadagna in media 400 dollari al mese in più di un single che ne guadagna 2000. Al livello del 5%, l'affermazione è compatibile con i dati? Si risponda sì o no.

Richiamo. Con la dipendente in logaritmo $\Delta y/y \approx \beta\,\Delta x$: l'effetto è una variazione relativa, non un importo. Per ottenere Δx data una variazione relativa si inverte la formula, $\Delta x = (\Delta y/y)/\beta$. Per una dummy $\Delta x = 1$ e la variazione percentuale è $100\,\beta$. Un importo in dollari si ottiene moltiplicando per il salario di partenza, $\Delta y \approx \beta\, y_0$; per confrontare un'affermazione in dollari con il coefficiente la si divide per y_0 e la si guarda nell'intervallo di confidenza $\hat\beta \pm 1{,}96\,\widehat{\text{se}}(\hat\beta)$.

Svolgimento. **Impostazione.** La (a) inverte l'effetto marginale di `istr`; la (b) legge la dummy come percentuale; la (c) e la (d) portano la percentuale in dollari.

(a) Si cerca Δistr tale che $\Delta\text{salario}/\text{salario} = 15/100$: $\Delta\text{istr} = \dfrac{15/100}{\hat{\beta}_1} = \dfrac{15/100}{0{,}0635} = 2{,}36$ anni.

(b) Per `sposato` $\Delta x = 1$: $100 \times \hat{\beta}_3 = 100 \times 0{,}0840 = 8{,}4\%$.

(c) $\Delta\text{salario} \approx \hat{\beta}_3 \times w_0 = 0{,}0840 \times 2000 = 168$ dollari al mese.

(d) L'affermazione equivale a $\beta_3\, w_0 = 400$, cioè $\beta_3 = 400/2000 = 0{,}200$. L'intervallo di confidenza al 95% per l'effetto in dollari è $(\hat{\beta}_3 \pm 1{,}96\,\widehat{\text{se}}(\hat{\beta}_3)) \times w_0 = [19;\, 317]$ e 400 ne è fuori. Lo stesso dice $t = (0{,}0840 - 0{,}200)/0{,}0380 = -3{,}05$, in valore assoluto maggiore di 1,96.

Errore tipico. Leggere 0,0840 o 8,4 come dollari. Con la dipendente in logaritmo il coefficiente della dummy è una variazione relativa del salario e diventa un importo in dollari solo moltiplicandolo per il salario di partenza. Per lo stesso motivo non si può confrontare l'affermazione in dollari direttamente con $\hat{\beta}_3$.

Risposta. **(a)** Servono circa 2,36 anni di istruzione in più. **(b)** Uno sposato guadagna in media circa il 8,4% in più di un single con le stesse altre caratteristiche. **(c)** Su un salario di 2000 dollari sono circa 168 dollari al mese. **(d)** No: l'intervallo di confidenza al 95% per la differenza è [19; 317] dollari e non contiene 400, quindi l'affermazione non è compatibile con i dati.

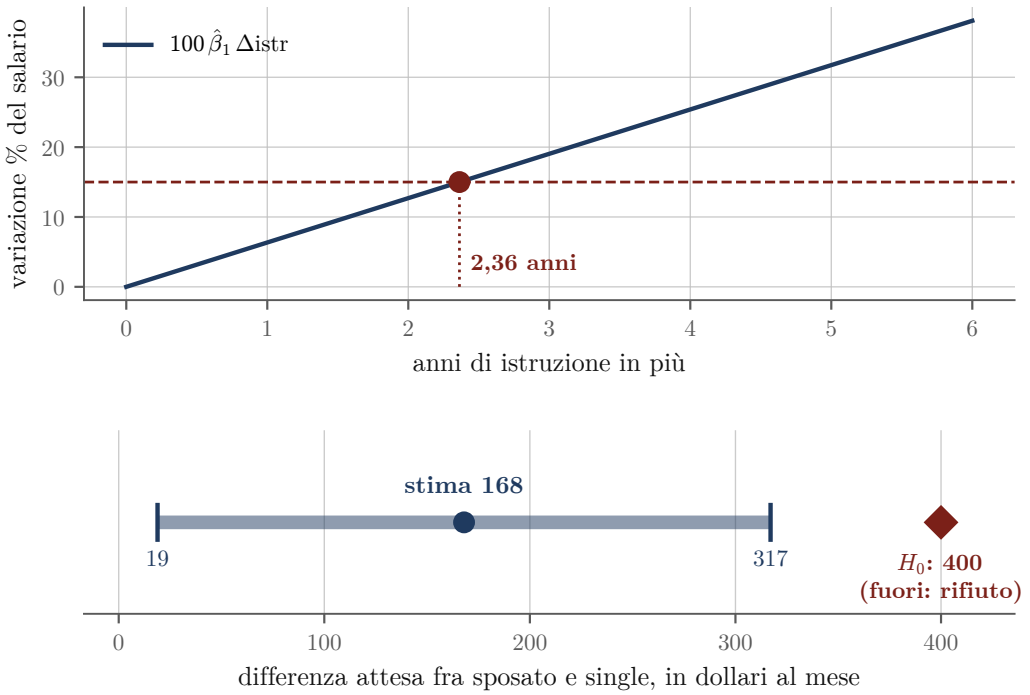


Figura 4.1: Sopra: variazione percentuale attesa del salario al crescere dell'istruzione; l'obiettivo del 15% si raggiunge con 2,36 anni in più. Sotto: intervallo di confidenza al 95% per la differenza in dollari fra sposato e single, con l'affermazione di 400 dollari fuori dall'intervallo.

5 | Esercizio 5 — Ricchezza e logaritmo del reddito *(livello intermedio)*

Dati. Su $n = 350$ famiglie si è stimato il modello

$$\text{rich} = \beta_0 + \beta_1 \, \log(\text{red}) + \beta_2 \, \text{eta} + \epsilon,$$

dove `rich` è la ricchezza netta e `red` il reddito annuo, entrambi in migliaia di dollari, ed `eta` è l'età del capofamiglia. Nella tabella `l_red` è il logaritmo di `red`. Per una variazione relativa del reddito si usi l'approssimazione $\Delta \log(\text{red}) \approx \Delta\text{red}/\text{red}$. Le stime OLS sono le seguenti.

	coefficiente	errore std.	rapporto t	p-value
const	−12,5206	5,19837	−2,409	0,0165
l_red	11,5373	1,19256	9,674	9,33e-20
eta	0,472052	0,0541443	8,718	1,19e-16

n = 350; $R^2 = 0{,}317464$; SSR = 47807,1

Testo della domanda. **Domanda 5** ***(3 punti).*** **(a)** Di quanti dollari varia in media la ricchezza se il reddito aumenta del 10%, a parità di età? **(b)** Di quanto deve aumentare in percentuale il reddito perché la ricchezza attesa cresca di 2100 dollari? **(c)** Al livello del 5%, si decida se rifiutare o non rifiutare $H_0 : \beta_1 = 0$ contro $H_1 : \beta_1 \neq 0$. **(d)** Una famiglia ha un reddito di 25 e un'altra di 80 (migliaia di dollari). La variazione attesa di ricchezza per un aumento del 10% del reddito è la stessa nei due casi? Si risponda sì o no.

Richiamo. Con la dipendente in livello e un regressore in logaritmo, $\Delta y = \beta \, \Delta \log(x)$ e, siccome $\Delta \log(x) \approx \Delta x/x$, si ha $\Delta y \approx \beta \, (\Delta x/x)$. Un aumento relativo del reddito del m per cento ($\Delta x/x = m/100$) fa variare y di $\beta \, m/100$ unità di misura di y: non è una percentuale di y, e non dipende dal livello di partenza di x. Per decidere su $H_0 : \beta = 0$ si guarda l'intervallo di confidenza al 95%, $\hat{\beta} \pm 1{,}96 \, \widehat{\text{se}}(\hat{\beta})$.

Svolgimento. **Impostazione.** `rich` è in livello (migliaia di dollari) e `red` entra in logaritmo: $\hat{\beta}_1$ è in migliaia di dollari per unità di log(red).

(a) $\Delta\text{rich} \approx \hat{\beta}_1 \times \dfrac{10}{100} = 11{,}5373 \times \dfrac{10}{100} = 1{,}154$ migliaia di dollari, cioè 1154 dollari.

(b) Da $\Delta\text{rich} = \hat{\beta}_1\,\Delta\text{red}/\text{red}$ si ha $\Delta\text{red}/\text{red} = \Delta\text{rich}/\hat{\beta}_1$, con Δrich in migliaia di dollari: $\Delta\%\,\text{red} = 100 \times \dfrac{2100/1000}{11{,}5373} = 18{,}2\%$.

(c) L'intervallo di confidenza al 95% è [9,200; 13,875] e lo zero ne è fuori. Lo stesso dice $t = 9{,}67$, in valore assoluto maggiore di 1,96.

(d) La variazione attesa $\hat{\beta}_1\,\Delta\text{red}/\text{red}$ dipende solo dalla variazione relativa del reddito, non dal suo livello: per un aumento del 10% è 1,154 migliaia di dollari sia con reddito 25 sia con reddito 80.

Errore tipico. Leggere $\hat{\beta}_1 = 11{,}5373$ come una variazione percentuale della ricchezza, o moltiplicarlo per 100, come si fa quando la dipendente è in logaritmo. Qui la dipendente è in livello: $\hat{\beta}_1$ è in migliaia di dollari e per una variazione relativa del reddito va diviso per 100. Un altro errore è dimenticare di convertire le migliaia in dollari.

Risposta. **(a)** Con il reddito +10% la ricchezza attesa aumenta di circa 1154 dollari. **(b)** Per 2100 dollari in più il reddito deve crescere di circa il 18,2%. **(c)** Lo zero non cade nell'intervallo di confidenza al 95%, quindi si rifiuta H_0: il reddito è significativo al 5%. **(d)** Sì: a parità di variazione relativa del reddito, la variazione attesa di ricchezza è la stessa per i due redditi.

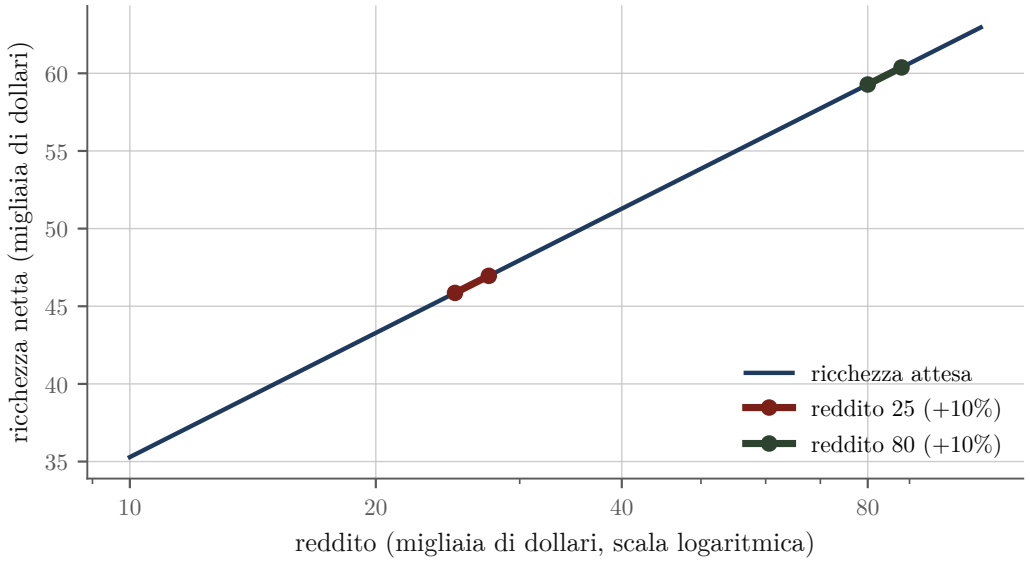


Figura 5.1: Ricchezza attesa in funzione del reddito, a età fissata: un aumento del 10% aggiunge circa 1,154 migliaia di dollari sia partendo da 25 sia da 80.

6 | Esercizio 6 — Esperienza e salario: una relazione non lineare *(livello intermedio)*

Dati. Su $n = 500$ lavoratori si è stimato il modello

$$\log(\text{salario}) = \beta_0 + \beta_1\,\text{istr} + \beta_2\,\text{esper} + \beta_3\,\text{esper}^2 + \epsilon,$$

dove `esper2` è il quadrato di `esper`. Le variazioni percentuali si calcolano con l'approssimazione $\Delta\%\, y \approx 100\,\Delta\log(y)$. Le stime OLS sono le seguenti.

	coefficiente	errore std.	rapporto t	p-value
const	1,05098	0,0878968	11,96	3,95e-29
istr	0,0654028	0,00482575	13,55	8,01e-36
esper	0,047647	0,00602637	7,906	1,73e-14
esper2	−0,000885667	0,000142423	−6,219	1,07e-09

n = 500; $R^2 = 0{,}346257$; SSR = 80,4355

Testo della domanda. **Domanda 6** ***(3 punti).*** **(a)** Al livello del 5%, si decida se rifiutare o non rifiutare $H_0 : \beta_3 = 0$ contro $H_1 : \beta_3 \neq 0$. **(b)** Si calcoli l'effetto marginale dell'esperienza, in percentuale, per un lavoratore con esper = 10 anni. **(c)** A quale livello di esperienza l'effetto marginale dell'esperienza si annulla?

Richiamo. Quando compaiono x e x^2 l'effetto di x dipende dal livello a cui lo si valuta. Da $\Delta\log(y) = \beta_2\,\Delta x + \beta_3\,\Delta(x^2)$ e $\Delta(x^2) \approx 2x\,\Delta x$ si ottiene l'effetto marginale $\Delta\log(y) \approx (\beta_2 + 2\beta_3 x)\,\Delta x$, in percentuale $100\,(\beta_2 + 2\beta_3 x)$. Si annulla in $x^* = -\beta_2/(2\beta_3)$: con $\beta_3 < 0$ l'effetto è positivo prima di x^* e negativo dopo.

Svolgimento. **Impostazione.** La (a) è un test su β_3; la (b) valuta l'effetto marginale in un punto; la (c) cerca il punto in cui si annulla.

(a) $H_0 : \beta_3 = 0$ contro $H_1 : \beta_3 \neq 0$. Il rapporto t vale $-6{,}22$, in valore assoluto maggiore di 1,96: si rifiuta H_0.

(b) $100\,(\hat\beta_2 + 2\hat\beta_3\,x_0) = 100 \times (0{,}04765 + 2 \times (-0{,}0008857) \times 10) = 2{,}99$.

(c) $x^* = -\hat{\beta}_2/(2\hat{\beta}_3) = -0{,}04765 \,/\, (2 \times (-0{,}0008857)) = 26{,}9$ anni.

Errore tipico. Interpretare $\hat{\beta}_2$ da solo come effetto dell'esperienza: con il termine al quadrato nel modello l'effetto è $\hat{\beta}_2 + 2\hat{\beta}_3\, x$ e cambia con x. Un altro errore è dimenticare che x^* va confrontato con l'intervallo di esperienza osservato: fuori da quell'intervallo è un'estrapolazione.

Risposta. **(a)** Il termine al quadrato è significativo al 5%: la relazione non è lineare. **(b)** Con 10 anni di esperienza un anno in più fa aumentare il salario di circa 2,99%. **(c)** L'effetto marginale si annulla a circa 26,9 anni: prima il salario cresce con l'esperienza, poi decresce.

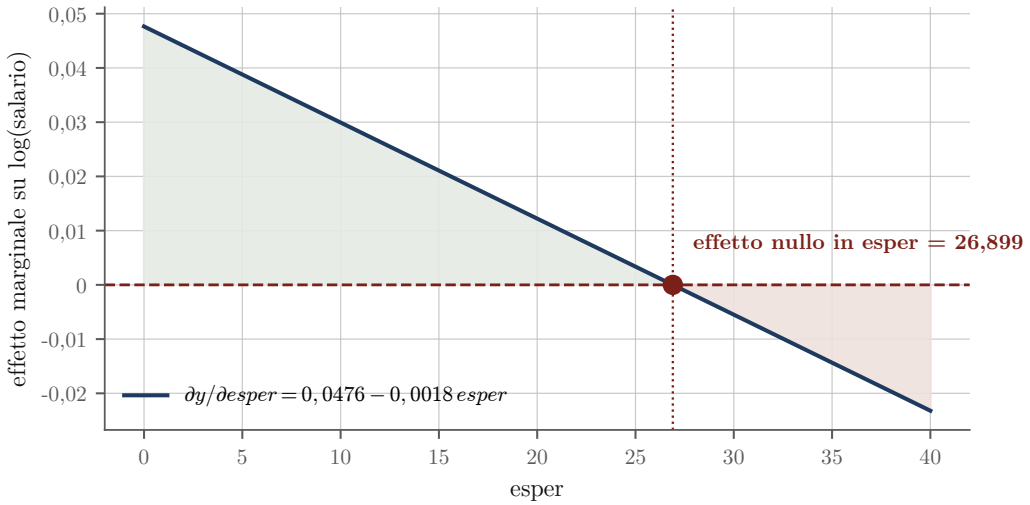


Figura 6.1: Effetto marginale dell'esperienza: positivo fino a 26,9 anni, poi negativo.

7 | Esercizio 7 — Salario, istruzione e ore lavorate *(livello intermedio)*

Dati. Su $n = 450$ lavoratori si è stimato, per log(salario), il Modello 1

$$\log(\text{salario}) = \beta_0 + \beta_1\,\text{istr} + \beta_2\,\text{esper} + \epsilon$$

	coefficiente	errore std.	rapporto t	p-value
const	1,55047	0,0765724	20,25	3,62e-65
istr	0,0641165	0,00482701	13,28	3,6e-34
esper	0,0112584	0,00200155	5,625	3,28e-08

n = 450; $R^2 = 0{,}31138$; SSR = 67,8729

e il Modello 2, che aggiunge `ore`, le ore lavorate a settimana:

$$\log(\text{salario}) = \beta_0 + \beta_1\,\text{istr} + \beta_2\,\text{esper} + \beta_3\,\text{ore} + \epsilon$$

	coefficiente	errore std.	rapporto t	p-value
const	0,949913	0,139239	6,822	2,93e-11
istr	0,0653086	0,00470289	13,89	1,08e-36
esper	0,0107591	0,00195013	5,517	5,85e-08
ore	0,0152009	0,00297726	5,106	4,89e-07

n = 450; $R^2 = 0{,}349406$; SSR = 64,1249

Si è stimata infine la regressione ausiliaria $\text{ore} = \delta_0 + \delta_1\,\text{istr} + \delta_2\,\text{esper} + u$.

	coefficiente	errore std.	rapporto t	p-value
const	39,5078	1,18373	33,38	1,87e-123
istr	−0,0784277	0,0746206	−1,051	0,2938
esper	0,0328487	0,0309419	1,062	0,2890

n = 450; R^2 = 0,00518564; SSR = 16220,3

Testo della domanda. **Domanda 7 *(3 punti).*** Si indichi con $\tilde{\beta}_1$ la stima di β_1 nel Modello 1 e con $\hat{\beta}_1$ quella nel Modello 2. **(a)** Quanto vale, in punti percentuali, $100\,(\tilde{\beta}_1 - \hat{\beta}_1)$? **(b)** Al livello del 5%, si decida se rifiutare o non rifiutare $H_0 : \beta_3 = 0$ nel Modello 2. **(c)** Al livello del 5%, si decida se rifiutare o non rifiutare $H_0 : \delta_1 = 0$ nella regressione ausiliaria. **(d)** Al livello del 5%, il Modello 1 soffre di distorsione da variabile omessa dovuta a `ore`? Si risponda sì o no.

Richiamo. Se il modello completo ha x_1 e x_2 e si omette x_2, la stima di β_1 nel modello ristretto è $\tilde{\beta}_1 = \hat{\beta}_1 + \hat{\beta}_2\,\hat{\delta}_1$, dove $\hat{\delta}_1$ è il coefficiente di x_1 nella regressione di x_2 sui regressori inclusi. La distorsione c'è soltanto se valgono **entrambe** le condizioni: x_2 conta ($\beta_2 \neq 0$) e x_2 è correlata con x_1 ($\delta_1 \neq 0$). Se ne manca una, omettere x_2 non distorce la stima di β_1.

Svolgimento. **Impostazione.** Si controllano le due condizioni, una nel Modello 2 e una nella regressione ausiliaria.

(a) $100 \times (\tilde{\beta}_1 - \hat{\beta}_1) = 100 \times (0{,}0641 - 0{,}0653) = -0{,}12$ punti percentuali: la stima quasi non si muove.

(b) Nel Modello 2 il rapporto t di `ore` vale 5,11, in valore assoluto maggiore di 1,96: si rifiuta $H_0 : \beta_3 = 0$, quindi `ore` conta.

(c) Nella regressione ausiliaria $\hat{\delta}_1 = -0{,}0784$ con $t = -1{,}05$, in valore assoluto minore di 1,96: non si rifiuta $H_0 : \delta_1 = 0$, quindi non c'è evidenza di correlazione (parziale) fra `ore` e `istr`.

(d) Manca la seconda condizione. Come verifica, $100\,\hat{\beta}_3\,\hat{\delta}_1 = 100 \times 0{,}0152 \times (-0{,}0784) = -0{,}12$ punti percentuali, uguale alla differenza in (a).

Errore tipico. Concludere per la distorsione solo perché la variabile omessa è significativa nel Modello 2. Serve anche che sia correlata con il regressore incluso: se non lo è, il Modello 1 lascia `ore` nell'errore ma l'errore resta incorrelato con `istr`, e la stima del rendimento dell'istruzione cambia di poco. Il mancato rifiuto di $H_0 : \delta_1 = 0$ non prova che δ_1 sia nullo: dice che i dati non lo distinguono da zero, e infatti la stima cambia di poco.

Risposta. **(a)** $100\,(\tilde{\beta}_1 - \hat{\beta}_1) = -0{,}12$ punti percentuali: la stima del rendimento dell'istruzione quasi non cambia. **(b)** Si rifiuta $H_0 : \beta_3 = 0$: `ore` è rilevante per il salario. **(c)** Non si rifiuta $H_0 : \delta_1 = 0$: non c'è evidenza di correlazione (parziale) fra `ore` e `istr`. **(d)** No: il Modello 1 omette una variabile rilevante, ma non c'è evidenza di correlazione (parziale) fra `ore` e `istr`, quindi non c'è evidenza di distorsione da variabile omessa su $\hat{\beta}_1$.

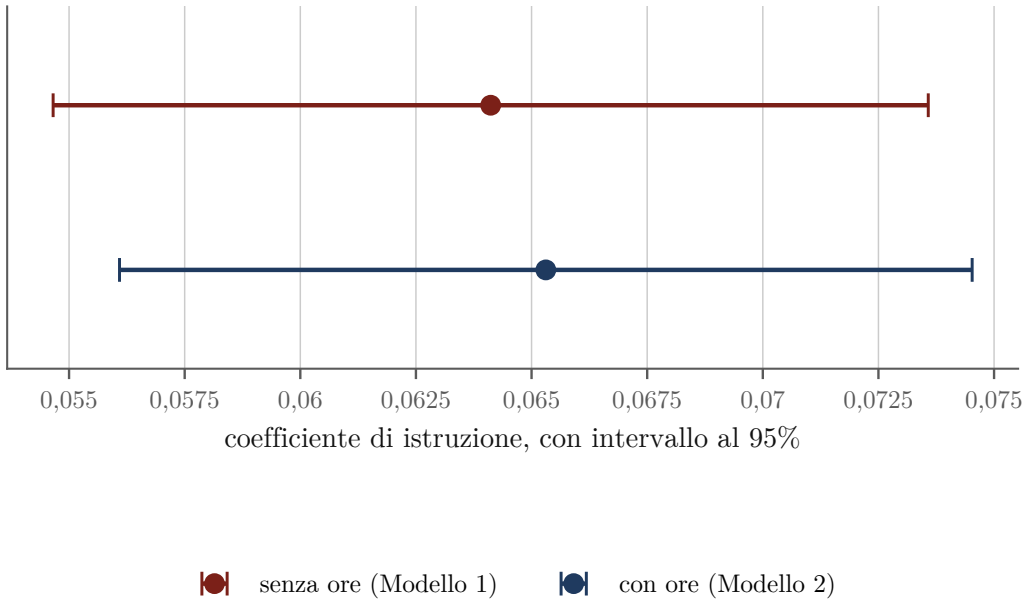


Figura 7.1: Coefficiente dell'istruzione, con intervallo al 95%: nei due modelli i punti e gli intervalli sono quasi sovrapposti.

8 | Esercizio 8 — Il reddito dichiarato *(livello intermedio)*

Dati. Su $n = 300$ famiglie i consumi y dipendono dal reddito vero x secondo il modello $y = \alpha + \gamma\, x + \epsilon$, con $\gamma = 1{,}5$ (dati simulati). Il reddito vero non è osservabile: si osserva solo il reddito dichiarato $x^* = x + u$, dove u è un errore di misura incorrelato con x e con ϵ. Le varianze valgono $\mathrm{Var}(x) = 4{,}00$ e $\mathrm{Var}(u) = 2{,}25$. Con il reddito vero (`red`) si otterrebbe

	coefficiente	errore std.	rapporto t	p-value
const	2,53943	0,567665	4,473	1,1e-05
red	1,56503	0,054784	28,57	2,51e-87

n = 300; $R^2 = 0{,}732516$; SSR = 1239,19

mentre con il reddito dichiarato (`red_dich`) si ottiene

	coefficiente	errore std.	rapporto t	p-value
const	7,41916	0,658841	11,26	9,57e-25
red_dich	1,07772	0,0626754	17,2	1,64e-46

n = 300; $R^2 = 0{,}498044$; SSR = 2325,43

Testo della domanda. **Domanda 8** ***(3 punti).*** **(a)** Quanto vale il rapporto $\lambda = \mathrm{Var}(x)/(\mathrm{Var}(x) + \mathrm{Var}(u))$? **(b)** Quale valore ci si aspetta, al limite per $n \to \infty$, per il coefficiente di `red_dich`? **(c)** Si scriva il modello in funzione di x^*, $y = \alpha + \gamma\, x^* + \epsilon^*$: quanto vale $\mathrm{Cov}(x^*, \epsilon^*)$? **(d)** L'intervallo di confidenza al 95% per il coefficiente di `red_dich` contiene il valore vero γ? Si risponda sì o no. **(e)** Si spieghi perché l'errore di misura rende x^* endogeno anche se u ha media nulla.

Richiamo. Se si osserva $x^* = x + u$, con u incorrelato con x e con ϵ, il modello $y = \alpha + \gamma\, x + \epsilon$ diventa $y = \alpha + \gamma\, x^* + \epsilon^*$ con $\epsilon^* = \epsilon - \gamma\, u$. Allora $\mathrm{Cov}(x^*, \epsilon^*) = \mathrm{Cov}(x + u,\, \epsilon - \gamma u) = -\gamma\, \mathrm{Var}(u) \neq 0$: il regressore è endogeno anche se u ha media nulla. Lo stimatore OLS converge a $\mathrm{Cov}(x^*, y)/\mathrm{Var}(x^*) = \gamma\, \mathrm{Var}(x)/(\mathrm{Var}(x) + \mathrm{Var}(u))$: la stima è attenuata verso zero e non è consistente.

Svolgimento. **Impostazione.** Si calcolano il fattore di attenuazione, il limite della stima e la covarianza che genera l'endogeneità, poi si confronta il limite con la tabella.

(a) $\lambda = \dfrac{4{,}00}{4{,}00 + 2{,}25} = 0{,}640$.

(b) Il limite è $\gamma\lambda = 1{,}5 \times 0{,}640 = 0{,}960$. La stima della tabella, 1,0777, è molto più vicina a questo valore che a γ.

(c) $\mathrm{Cov}(x^*, \epsilon^*) = -\gamma \,\mathrm{Var}(u) = -1{,}5 \times 2{,}25 = -3{,}375$.

(d) L'intervallo di confidenza al 95% per il coefficiente di `red_dich` è [0,955; 1,201] e $\gamma = 1{,}5$ ne è fuori.

(e) Nel modello scritto con x^* l'errore $\epsilon^* = \epsilon - \gamma u$ contiene u, e u è una parte di $x^* = x + u$: regressore ed errore sono correlati, anche se u ha media nulla e non è correlato con x.

Errore tipico. Ritenere innocuo l'errore di misura perché ha media zero. Contano la correlazione fra il regressore osservato e l'errore, non la media di u: x^* contiene u. Un altro errore è pensare che la distorsione sparisca aumentando n: è una non consistenza, la stima converge a $\gamma\lambda$ e non a γ.

Risposta. **(a)** $\lambda = 0{,}640$. **(b)** Il coefficiente di `red_dich` converge a $\gamma\lambda = 0{,}960$, non a $\gamma = 1{,}5$: la stima è attenuata. **(c)** $\mathrm{Cov}(x^*, \epsilon^*) = -3{,}375$. **(d)** No: l'intervallo di confidenza al 95% non contiene il valore vero. **(e)** Il regressore osservato contiene l'errore di misura, che finisce anche nell'errore del modello: è endogeno, e gli stimatori OLS sono distorti e non consistenti.

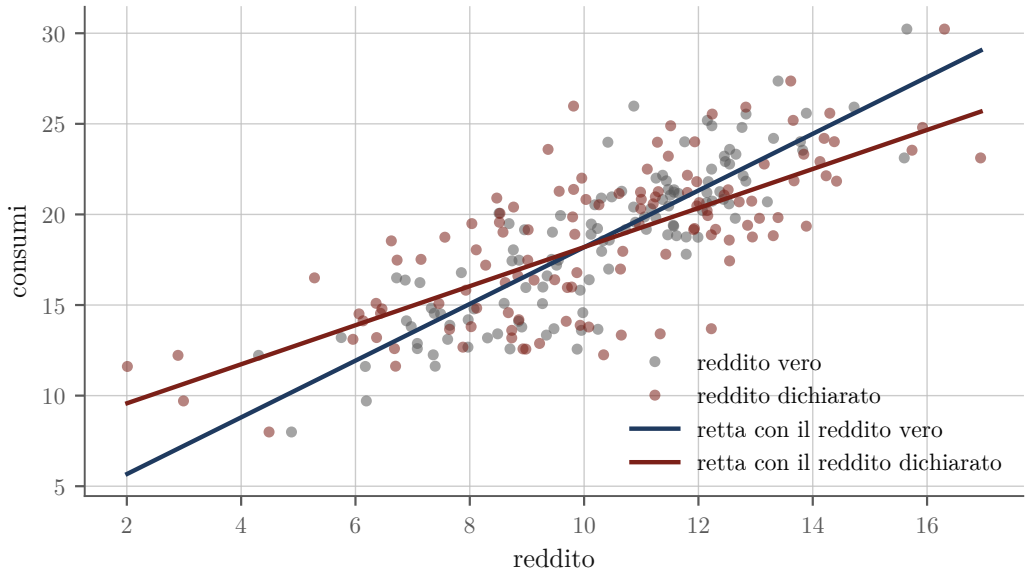


Figura 8.1: Consumi contro reddito vero e contro reddito dichiarato, con le due rette stimate: l'errore di misura appiattisce la pendenza.

9 | Esercizio 9 — Classe e reddito: il teorema di Frisch-Waugh-Lovell *(livello intermedio)*

Dati. Su $n = 420$ distretti scolastici si vuole stimare il modello

$$\text{punteggio} = \beta_0 + \beta_1\,\text{classe} + \beta_2\,\text{reddito} + \epsilon,$$

dove `classe` è il numero medio di studenti per insegnante e `reddito` il reddito medio del distretto. L'output della regressione completa non è disponibile: si hanno solo i tre passi seguenti.

Passo (1). Regressione di `classe` su `reddito`; u_{classe} indica i suoi residui.

	coefficiente	errore std.	rapporto t	p-value
const	21,9598	0,152559	143,9	0,0000
reddito	−0,18473	0,00971323	−19,02	1,48e-58

n = 420; R^2 = 0,463897; SSR = 900,246

Passo (2). Regressione di `punteggio` su `reddito`; $u_{\text{punteggio}}$ indica i suoi residui.

	coefficiente	errore std.	rapporto t	p-value
const	633,32	1,35457	467,5	0,0000
reddito	1,94051	0,086244	22,5	4,96e-74

n = 420; R^2 = 0,547746; SSR = 70972,8

Passo (3). Regressione di $u_{\text{punteggio}}$ su u_{classe} (nella tabella `u_classe`).

	coefficiente	errore std.	rapporto t	p-value
const	0	0,634439	0	1,0000
u_classe	−0,584484	0,433345	−1,349	0,1781

n = 420; R^2 = 0,00433326; SSR = 70665,2

Testo della domanda. **Domanda 9** ***(3 punti).*** **(a)** Quanto vale la stima di β_1 nella regressione completa di `punteggio` su `classe` e `reddito`? **(b)** Al livello del 5%, si decida se rifiutare o non rifiutare $H_0 : \beta_1 = 0$ contro $H_1 : \beta_1 \neq 0$. **(c)** Quanto vale il VIF di `classe` nella regressione completa, con $\text{VIF}(j) = 1/(1 - R_j^2)$ e R_j^2 l'R^2 della regressione di x_j sugli altri regressori? **(d)** Si spieghi perché la costante del passo (3) è nulla.

Richiamo. Il teorema di Frisch-Waugh-Lovell dice che $\hat{\beta}_1$ della regressione multipla di y su x_1 e x_2 si ottiene in tre passi: (1) si regredisce x_1 su x_2 e si prendono i residui u_1; (2) si regredisce y su x_2 e si prendono i residui u_y; (3) si regredisce u_y su u_1. La pendenza del passo (3) coincide con $\hat{\beta}_1$: è l'associazione fra y e la parte di x_1 non spiegata da x_2. Il VIF di x_1 è $1/(1 - R_1^2)$, con R_1^2 l'R^2 della regressione di x_1 sugli altri regressori, qui la (1).

Svolgimento. **Impostazione.** La (a) e la (b) si leggono dal passo (3); la (c) usa l'R^2 del passo (1).

(a) Il coefficiente di `u_classe` nel passo (3) è $\hat{\beta}_1 = -0{,}5845$.

(b) Si verifica $H_0 : \beta_1 = 0$ contro $H_1 : \beta_1 \neq 0$. L'intervallo di confidenza al 95% è $[-1{,}434;\ 0{,}265]$ e contiene lo zero. Lo stesso dice $t = -1{,}35$, in valore assoluto minore di 1,96.

(c) $R^2 = 0{,}4639$ nel passo (1), quindi $\text{VIF} = 1/(1 - R^2) = 1/(1 - 0{,}4639) = 1{,}87$.

(d) I residui di una regressione con la costante hanno media nulla; $u_{\text{punteggio}}$ e u_{classe} hanno entrambi media zero, e la retta che li interpola passa per l'origine: la costante vale zero.

Errore tipico. Leggere la pendenza del passo (1) o del passo (2) come effetto di `classe`: sono relazioni fra `reddito` e un'altra variabile. Un altro errore è stimare `punteggio` su `classe` senza controllare per `reddito`: la pendenza grezza è molto più negativa (figura a sinistra) perché assorbe l'effetto del reddito. Il passo (3) usa $n - 2$ gradi di libertà anziché $n - 3$, quindi la sua t è appena più grande di quella della regressione completa: la decisione non cambia.

Risposta. **(a)** $\hat{\beta}_1 = -0{,}5845$: a parità di reddito, un'unità in più di `classe` fa variare il punteggio di questo valore. **(b)** Lo zero cade nell'intervallo di confidenza al 95%: non si rifiuta H_0, `classe` non è significativa al 5%. **(c)** VIF = 1,87, inferiore a 10. **(d)** I residui hanno media zero, quindi la retta fra i residui passa per l'origine.

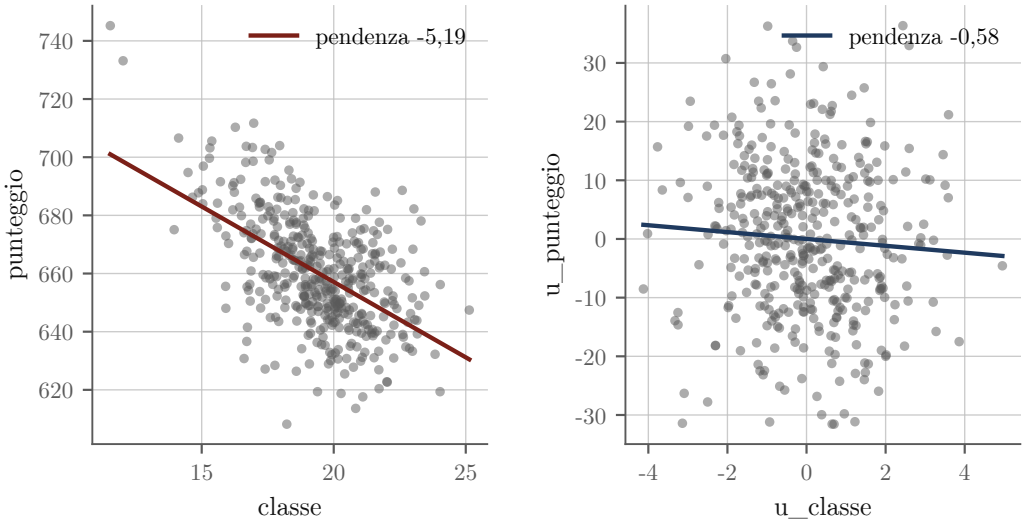


Figura 9.1: A sinistra la nuvola grezza di `punteggio` contro `classe`, con la pendenza della regressione semplice; a destra i residui del passo (3), con pendenza $\hat{\beta}_1 = -0{,}5845$.

10 | Esercizio 10 — Reddito e spesa: non linearità, punto di svolta e dollari *(livello appello)*

Dati. Su $n = 300$ famiglie si è stimato il modello

$$\log(\text{spesa}) = \beta_0 + \beta_1\,\text{red} + \beta_2\,\text{red}^2 + \beta_3\,\text{eta} + \epsilon,$$

dove `red` è il reddito in decine di migliaia di dollari (`red` = 1 corrisponde a 10000 dollari), `sq_red` è il suo quadrato ed `eta` l'età del capofamiglia. Le variazioni percentuali si calcolano con l'approssimazione $\Delta\%\,y \approx 100\,\Delta\log(y)$. Le stime OLS sono le seguenti; la covarianza stimata fra $\hat\beta_1$ e $\hat\beta_2$ vale $-0{,}00031875$.

	coefficiente	errore std.	rapporto t	p-value
const	5,0181	0,17931	27,99	3,87e-85
red	0,378446	0,0591034	6,403	5,96e-10
sq_red	−0,0304878	0,00558777	−5,456	1,03e-07
eta	0,00390098	0,00282549	1,381	0,1684

n = 300; $R^2 = 0{,}152304$; SSR = 98,0876

Testo della domanda. **Domanda 10** ***(4 punti).*** **(a)** Al livello del 5%, si decida se rifiutare o non rifiutare $H_0 : \beta_2 = 0$ contro $H_1 : \beta_2 \neq 0$. **(b)** L'effetto marginale del reddito è decrescente? Si risponda sì o no. **(c)** Per quale reddito, espresso in dollari, l'effetto marginale del reddito si annulla? **(d)** Si calcoli l'effetto marginale del reddito (la derivata di log(spesa) rispetto a `red`), in percentuale, per una famiglia con red = 5. **(e)** Al livello del 5%, si decida se rifiutare o non rifiutare l'ipotesi che tale effetto marginale sia nullo, $H_0 : \beta_1 + 2\times 5\times\beta_2 = 0$, contro l'alternativa bilaterale.

Richiamo. Con x e x^2 nel modello l'effetto marginale è $\Delta\log(y) \approx (\beta_1 + 2\beta_2 x)\,\Delta x$, in percentuale $100\,(\beta_1 + 2\beta_2 x)$; è decrescente se $\beta_2 < 0$ e si annulla in $x^* = -\beta_1/(2\beta_2)$. La non linearità si verifica con $H_0 : \beta_2 = 0$. L'errore standard dell'effetto in x_0 è quello di una combinazione lineare: $\text{Var}(\hat\beta_1 + 2x_0\hat\beta_2) = \text{Var}(\hat\beta_1) + 4x_0^2\,\text{Var}(\hat\beta_2) + 4x_0\,\text{Cov}(\hat\beta_1, \hat\beta_2)$. Se x è misurata in unità da u dollari, x^* va moltiplicato per u per averlo in dollari.

Svolgimento. **Impostazione.** La (a) e la (b) riguardano β_2; la (c) cerca lo zero dell'effetto marginale e lo converte in dollari; la (d) e la (e) valutano l'effetto in x_0 e ne testano la significatività con la covarianza.

(a) $H_0 : \beta_2 = 0$ contro $H_1 : \beta_2 \neq 0$. Il rapporto t vale $-5{,}46$, in valore assoluto maggiore di 1,96: si rifiuta H_0 e la relazione non è lineare.

(b) $\hat{\beta}_2 = -0{,}0304878$ è negativo e significativo: l'effetto marginale $\beta_1 + 2\beta_2\,\text{red}$ decresce al crescere di `red`.

(c) $\text{red}^* = -\hat{\beta}_1/(2\hat{\beta}_2) = -0{,}378446\,/\,(2\times(-0{,}0304878)) = 6{,}2065$. Un'unità di `red` vale 10000 dollari, quindi $6{,}2065 \times 10000 = 62065$ dollari.

(d) $100\,(\hat{\beta}_1 + 2\hat{\beta}_2\,x_0) = 100 \times (0{,}378446 + 2 \times (-0{,}0304878) \times 5) = 7{,}36\%$.

(e) $\widehat{\text{se}} = 100\sqrt{\widehat{\text{se}}(\hat{\beta}_1)^2 + 4x_0^2\,\widehat{\text{se}}(\hat{\beta}_2)^2 + 4x_0\,\widehat{\text{Cov}}} = 100\sqrt{0{,}059103^2 + 4 \times 5^2 \times 0{,}0055878^2 + 4 \times 5 \times (-0{,}00031}$ 1,55. Il rapporto t è $7{,}36/1{,}55 = 4{,}74$, in valore assoluto maggiore di 1,96: si rifiuta H_0.

Errore tipico. Calcolare l'errore standard dell'effetto marginale senza il termine di covarianza: si otterrebbe 8,13 invece di 1,55 e non si rifiuterebbe l'ipotesi. $\hat{\beta}_1$ e $\hat{\beta}_2$ sono fortemente correlati, perché `red` e `sq_red` si muovono insieme, e la covarianza (negativa) riduce la varianza della combinazione. Un altro errore è dimenticare l'unità di misura: 6,2065 sono decine di migliaia di dollari, non dollari.

Risposta. **(a)** Si rifiuta $H_0 : \beta_2 = 0$: la relazione fra reddito e spesa non è lineare. **(b)** Sì: $\hat{\beta}_2$ è negativo e significativo, l'effetto marginale è decrescente. **(c)** L'effetto marginale si annulla per un reddito di circa 62065 dollari. **(d)** In red $= 5$ l'effetto marginale è del 7,36% per ogni (piccolo) aumento di una decina di migliaia di dollari; per un aumento discreto di un'intera unità l'aumento è minore, perché $\hat{\beta}_2$ è negativo e l'effetto marginale decresce. **(e)** Con errore standard 1,55 (che include la covarianza) il rapporto t è 4,74: si rifiuta H_0, l'effetto in x_0 è significativamente diverso da zero anche se già prossimo al punto di svolta.

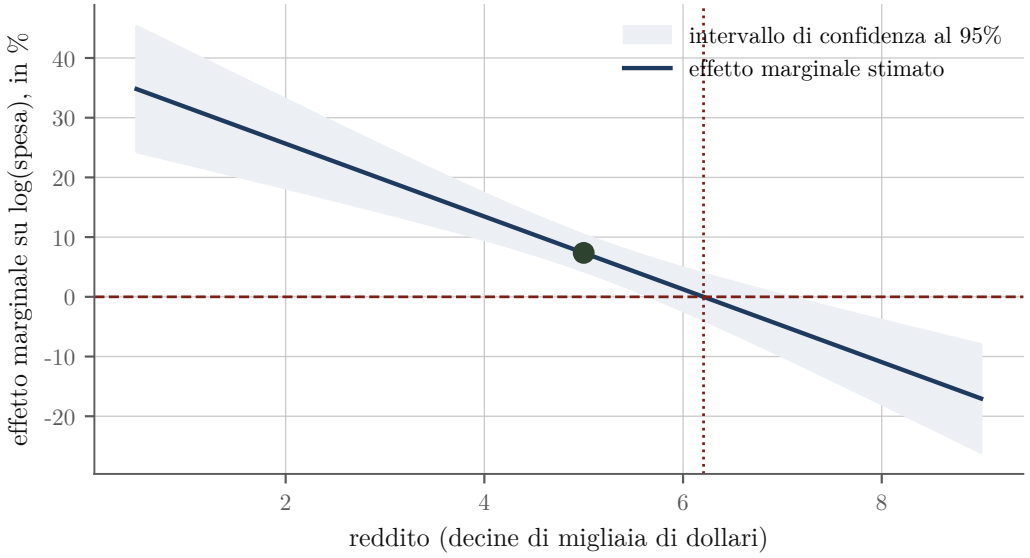


Figura 10.1: Effetto marginale del reddito con la banda al 95% calcolata con la covarianza: positivo e significativo in $x_0 = 5$ (punto verde), si annulla in 6,2065 (linea tratteggiata verticale), dove la banda comprende lo zero.

11 | Esercizio 11 — Affitti: superficie e distanza dal centro *(livello appello)*

Dati. Su $n = 300$ appartamenti in affitto si è stimato il modello

$$\log(\text{affitto}) = \beta_0 + \beta_1 \, \log(\text{mq}) + \beta_2 \, \text{km} + \beta_3 \, \text{ascensore} + \epsilon,$$

dove `affitto` è il canone mensile in euro, `mq` la superficie in metri quadrati (nella tabella `l_mq` è il suo logaritmo), `km` la distanza dal centro in chilometri e `ascensore` vale 1 se l'edificio ha l'ascensore. Le variazioni percentuali si calcolano con le approssimazioni $\Delta\% \, y \approx 100 \, \Delta \log(y)$ e $\Delta \log(x) \approx \Delta x / x$. Le stime OLS sono le seguenti.

	coefficiente	errore std.	rapporto t	p-value
const	4,04091	0,165031	24,49	3,93e-73
l_mq	0,733267	0,0380222	19,29	3,05e-54
km	−0,0433894	0,00460975	−9,413	1,41e-18
ascensore	0,067853	0,0235179	2,885	0,0042

n = 300; $R^2 = 0{,}595845$; SSR = 11,678

Testo della domanda. **Domanda 11** ***(4 punti).*** **(a)** Di quanto varia in percentuale l'affitto atteso se la superficie aumenta del 10%, a parità del resto? **(b)** E se l'appartamento è 2 chilometri più lontano dal centro? **(c)** Di quanto, in percentuale, deve aumentare la superficie perché l'affitto atteso non cambi, nonostante i 2 chilometri in più? **(d)** Un'agenzia sostiene che un aumento della superficie del 10% fa salire l'affitto del 7%. Al livello del 5%, l'affermazione è compatibile con i dati? Si risponda sì o no.

Richiamo. Con dipendente e regressore in logaritmo $\Delta y / y \approx \beta \, \Delta x / x$: β è un'elasticità e una variazione di x del m per cento fa variare y di $\beta \, m$ per cento. Con un regressore in livello $\Delta y / y \approx \beta \, \Delta x$, in percentuale $100 \, \beta \, \Delta x$. Per confrontare due effetti li si porta entrambi in variazione percentuale di y. Un'affermazione «x aumenta del m per cento e y del p per cento» equivale a un'elasticità p/m, che si confronta con l'intervallo di confidenza $\hat{\beta} \pm 1{,}96 \, \widehat{\text{se}}(\hat{\beta})$.

Svolgimento. **Impostazione.** `mq` è in logaritmo (elasticità), `km` è in livello (semi-elasticità): le due vanno portate nella stessa unità, la variazione percentuale dell'affitto.

(a) $\Delta\%\,\text{affitto} \approx \hat{\beta}_1 \times \Delta\%\,\text{mq} = 0{,}733 \times 10 = 7{,}33\%$.

(b) $\Delta\%\,\text{affitto} \approx 100 \times \hat{\beta}_2 \times \Delta\text{km} = 100 \times (-0{,}0434) \times 2 = -8{,}68\%$.

(c) Si cerca s con $\hat{\beta}_1\, s + (-8{,}68) = 0$, cioè $s = -(-8{,}68)/0{,}733 = 11{,}8\%$.

(d) Un aumento della superficie del 10% che fa salire l'affitto del 7% equivale a un'elasticità $7/10 = 0{,}70$. L'intervallo di confidenza al 95% per β_1 è $[0{,}659;\ 0{,}808]$ e contiene 0,70. Lo stesso dice $t = (0{,}733 - 0{,}70)/\widehat{\text{se}}(\hat{\beta}_1) = 0{,}87$, in valore assoluto minore di 1,96.

Errore tipico. Applicare $100\,\hat{\beta}$ anche a `l_mq`: la superficie è in logaritmo e $\hat{\beta}_1$ è già un'elasticità, mentre la regola $100\,\hat{\beta}\,\Delta x$ vale per `km`, che è in livello. Un altro errore è confrontare «10% di superficie» con «2 chilometri» senza portarli entrambi in variazione percentuale dell'affitto.

Risposta. **(a)** Con la superficie +10% l'affitto aumenta di circa 7,33%. **(b)** Con 2 chilometri in più l'affitto varia di circa −8,68%. **(c)** Per compensare la perdita serve una superficie maggiore di circa il 11,8%. **(d)** Sì: l'elasticità implicita nell'affermazione, 0,70, cade nell'intervallo di confidenza al 95% per β_1, quindi l'affermazione è compatibile con i dati.

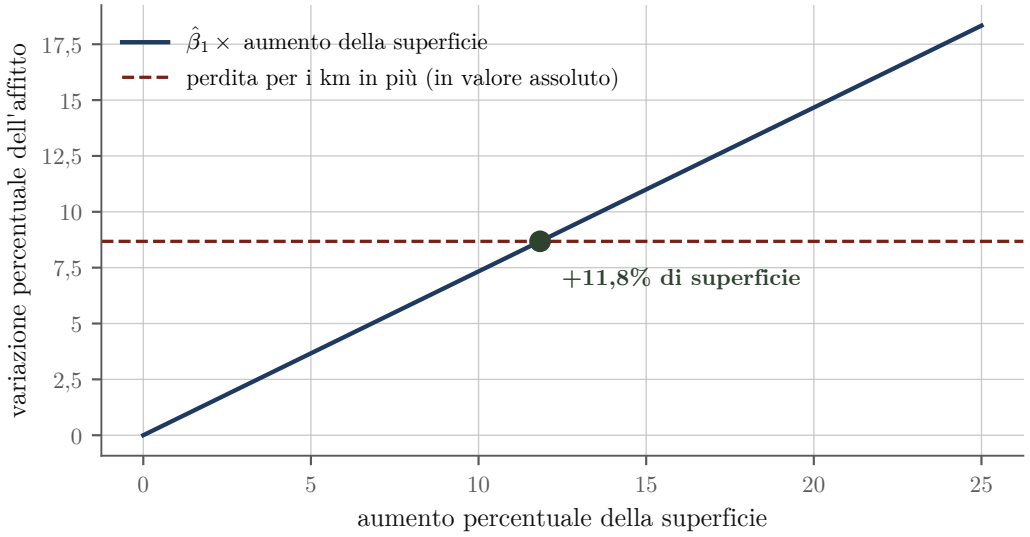


Figura 11.1: Variazione percentuale dell'affitto per un aumento della superficie (retta blu) contro la perdita dovuta ai 2 chilometri in più (linea rossa): le due si pareggiano in +11,8% di superficie.

12 | Esercizio 12 — Esperienza e anzianità: collinearità o variabile omessa? *(livello appello)*

Dati. Su $n = 200$ lavoratori si è stimato, per log(salario), il Modello 1

$$\log(\text{salario}) = \beta_0 + \beta_1\,\text{istr} + \beta_2\,\text{esper} + \beta_3\,\text{anz} + \epsilon,$$

dove `esper` sono gli anni di esperienza complessiva e `anz` gli anni di anzianità nell'azienda attuale.

	coefficiente	errore std.	rapporto t	p-value
const	1,27373	0,145801	8,736	1,07e-15
istr	0,0607297	0,00868509	6,992	4,15e-11
esper	0,0018428	0,0122756	0,1501	0,8808
anz	0,0216826	0,0135459	1,601	0,1111

n = 200; $R^2 = 0{,}305892$; SSR = 37,027

I VIF del Modello 1, con $\text{VIF}(j) = 1/(1 - R_j^2)$, sono

variabile	VIF
istr	1,021
esper	15,709
anz	15,635

Eliminando `anz` si è stimato il Modello 2.

	coefficiente	errore std.	rapporto t	p-value
const	1,24325	0,145125	8,567	3,06e-15
istr	0,0615384	0,00870469	7,07	2,64e-11
esper	0,0208449	0,00313702	6,645	2,9e-10

n = 200; $R^2 = 0{,}296819$; SSR = 37,511

Testo della domanda. **Domanda 12** ***(4 punti).*** Si usi la soglia 10 per il VIF. **(a)** I VIF indicano la presenza di quasi-collinearità? Si risponda sì o no. **(b)** Rispetto al caso in cui i regressori fossero indipendenti fra loro, di quante volte ci si aspetta che sia gonfiato l'errore standard del coefficiente di `esper` nel Modello 1? **(c)** Quante volte l'errore standard di `esper` nel Modello 1 è più grande di quello nel Modello 2? **(d)** Al livello del 5%, nel Modello 1 si decida se rifiutare o non rifiutare $H_0 : \beta_2 = 0$. **(e)** Lo stesso nel Modello 2. **(f)** Di quanti punti percentuali sale la stima del coefficiente di `esper` passando dal Modello 1 al Modello 2, cioè quanto vale $100 \times$ (stima nel Modello 2 − stima nel Modello 1)? **(g)** Eliminare `anz` è una soluzione corretta al problema? Si motivi.

Richiamo. Per lo stimatore di β_j vale $\widehat{\mathrm{Var}}(\hat\beta_j) = \dfrac{\hat\sigma^2}{\sum_i (x_{ij} - \bar x_j)^2} \cdot \dfrac{1}{1 - R_j^2}$ e il secondo fattore è il VIF_j: rispetto a regressori indipendenti l'errore standard cresce di $\sqrt{\mathrm{VIF}_j}$. Con un VIF maggiore di 10 si parla di quasi-collinearità, che gonfia gli errori standard ma non distorce le stime. Omettere invece un regressore rilevante e correlato con uno incluso distorce: $\tilde\beta_1 = \hat\beta_1 + \hat\beta_3\,\hat\delta_1$.

Svolgimento. **Impostazione.** Si leggono i VIF, li si confronta con il cambio degli errori standard fra i due modelli e si controlla che cosa succede alla stima quando si toglie `anz`.

(a) I VIF di `esper` (15,709) e di `anz` (15,635) superano 10, quello di `istr` è 1,021: c'è quasi-collinearità fra `esper` e `anz`, com'è naturale perché più si lavora e più cresce l'anzianità.

(b) $\sqrt{\mathrm{VIF}} = \sqrt{15{,}709} = 3{,}96$.

(c) $\widehat{\mathrm{se}}_1 / \widehat{\mathrm{se}}_2 = 0{,}01228 / 0{,}00314 = 3{,}91$, vicino a $\sqrt{\mathrm{VIF}}$: nel Modello 2 `esper` ha solo `istr` come altro regressore, e con esso è quasi incorrelata.

(d) Nel Modello 1 $t = 0{,}15$, in valore assoluto minore di 1,96: non si rifiuta $H_0 : \beta_2 = 0$.

(e) Nel Modello 2 $t = 6{,}64$, in valore assoluto maggiore di 1,96: si rifiuta $H_0 : \beta_2 = 0$.

(f) $100 \times (0{,}0208 - 0{,}0018) = 1{,}9$ punti percentuali.

(g) No. I dati non separano i due effetti: il salto della stima da 0,0018 a 0,0208 è $\hat\beta_3\,\hat\delta$, con $\hat\delta$ il coefficiente di `esper` nella regressione ausiliaria di `anz`, e ha la stessa imprecisione di $\hat\beta_3$, che non è significativo. La rilevanza di `anz` va motivata con la teoria o con un test F congiunto su $H_0 : \beta_2 = \beta_3 = 0$; se `anz` è rilevante, eliminarla introduce una distorsione da variabile omessa.

Errore tipico. Togliere `anz` perché fa risultare `esper` non significativa. Nel Modello 2 `esper` risulta significativa perché l'errore standard è più piccolo, ma i dati non separano i due effetti: se `anz` è rilevante, la stima di `esper` assorbe parte del suo effetto, sale e diventa distorta; la rilevanza di `anz` va motivata con la teoria o con un test F congiunto su $H_0 : \beta_2 = \beta_3 = 0$. La quasi-collinearità non si cura eliminando un regressore che può essere rilevante: si accetta l'errore standard più grande, si raccolgono più dati o si lavora su una combinazione delle due variabili.

Risposta. **(a)** Sì: i VIF di `esper` e `anz` sono maggiori di 10. **(b)** L'errore standard di `esper` è gonfiato di circa 3,96 volte. **(c)** Il Modello 1 ha un errore standard circa 3,91 volte più grande

del Modello 2, in linea con $\sqrt{\text{VIF}}$. **(d)** Non si rifiuta H_0 nel Modello 1. **(e)** Si rifiuta H_0 nel Modello 2. **(f)** La stima sale di 1,9 punti percentuali. **(g)** No: i dati non separano i due effetti, e il salto della stima ha la stessa imprecisione di $\hat{\beta}_3$, che non è significativo. La rilevanza di `anz` va motivata con la teoria o con un test F congiunto su $H_0 : \beta_2 = \beta_3 = 0$; se `anz` è rilevante, togliere `anz` introduce una distorsione da variabile omessa.

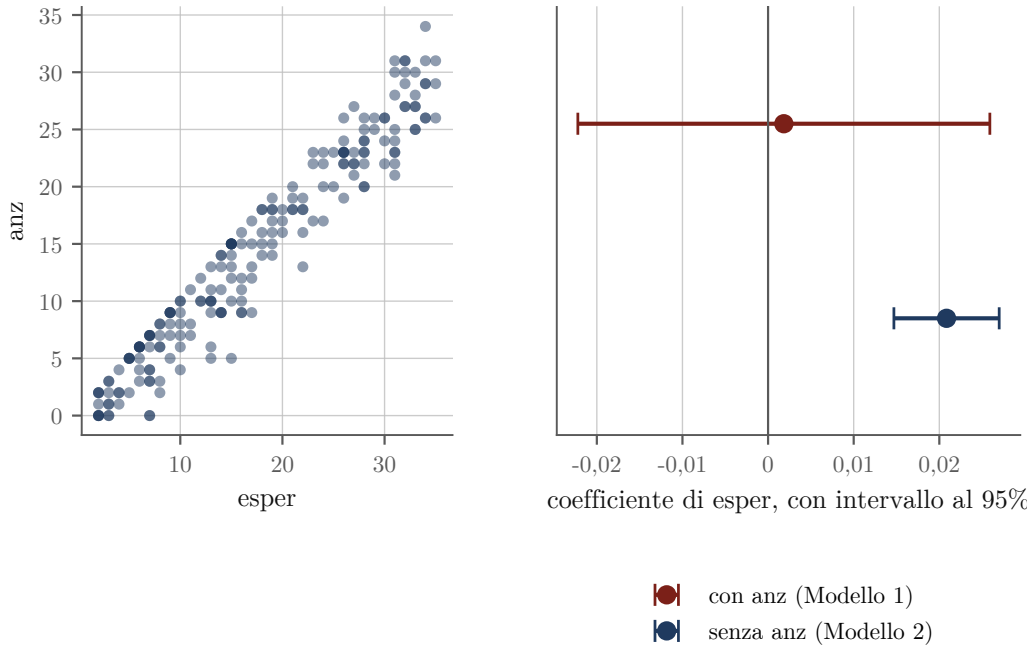


Figura 12.1: A sinistra `esper` contro `anz`: i punti stanno quasi su una retta. A destra il coefficiente di `esper` con intervallo al 95%: largo e con lo zero dentro nel Modello 1, stretto nel Modello 2 dove può assorbire l'effetto di `anz`.

13 | Esercizio 13 — Salario, istruzione e abilità *(livello appello)*

Dati. Su $n = 500$ lavoratori si è stimato, per log(salario), il Modello 1

$$\log(\text{salario}) = \beta_0 + \beta_1\,\text{istr} + \beta_2\,\text{esper} + \epsilon$$

	coefficiente	errore std.	rapporto t	p-value
const	0,827129	0,113498	7,288	1,25e-12
istr	0,0789463	0,00818164	9,649	2,62e-20
esper	0,0130355	0,00202887	6,425	3,09e-10

n = 500; $R^2 = 0{,}206339$; SSR = 83,2342

e il Modello 2, che aggiunge `abil`, un punteggio standardizzato di abilità:

$$\log(\text{salario}) = \beta_0 + \beta_1\,\text{istr} + \beta_2\,\text{esper} + \beta_3\,\text{abil} + \epsilon$$

	coefficiente	errore std.	rapporto t	p-value
const	1,16825	0,156576	7,461	3,87e-13
istr	0,0532766	0,0115293	4,621	4,88e-06
esper	0,0128032	0,00201249	6,362	4,54e-10
abil	0,0834754	0,0266482	3,132	0,0018

n = 500; $R^2 = 0{,}221736$; SSR = 81,6195

Si è stimata infine la regressione ausiliaria $\text{abil} = \delta_0 + \delta_1\,\text{istr} + \delta_2\,\text{esper} + u$.

	coefficiente	errore std.	rapporto t	p-value
const	−4,08649	0,189377	−21,58	2,31e-73
istr	0,307511	0,0136514	22,53	5,88e-78
esper	0,00278265	0,00338526	0,822	0,4115

n = 500; R^2 = 0,5052; SSR = 231,727

Testo della domanda. **Domanda 13 *(4 punti).*** Si indichi con $\tilde{\beta}_1$ la stima di β_1 nel Modello 1 e con $\hat{\beta}_1$ quella nel Modello 2. **(a)** Quanto vale, in punti percentuali, $100\,(\tilde{\beta}_1 - \hat{\beta}_1)$? **(b)** Si dica, al livello del 5%, se il Modello 1 soffre di distorsione da variabile omessa. Si risponda sì o no. **(c)** Si calcoli, in punti percentuali, $100\,\hat{\beta}_3\,\hat{\delta}_1$ con i numeri delle tabelle e lo si confronti con la risposta (a). **(d)** Il Modello 1 sovrastima il rendimento dell'istruzione rispetto al Modello 2? Si risponda sì o no.

Richiamo. Se il modello completo ha x_1 e x_2 e si omette x_2, la stima di β_1 nel modello ristretto è $\tilde{\beta}_1 = \hat{\beta}_1 + \hat{\beta}_2\,\hat{\delta}_1$, dove $\hat{\delta}_1$ è il coefficiente di x_1 nella regressione di x_2 sui regressori inclusi. La distorsione c'è se x_2 conta ($\beta_2 \neq 0$) **e** è correlata con x_1 ($\delta_1 \neq 0$). Nel campione la formula è un'identità esatta.

Svolgimento. **Impostazione.** Si confrontano i due modelli e si usa la regressione ausiliaria per capire da dove viene la differenza.

(a) $100 \times (\tilde{\beta}_1 - \hat{\beta}_1) = 100 \times (0{,}0789 - 0{,}0533) = 2{,}6$ punti percentuali.

(b) Servono due condizioni. L'abilità conta nel Modello 2: $t = 3{,}13$, in valore assoluto maggiore di 1,96. E l'abilità è correlata con l'istruzione: nella regressione ausiliaria $t = 22{,}53$ per $\hat{\delta}_1$. Entrambe sono soddisfatte.

(c) $100\,\hat{\beta}_3\,\hat{\delta}_1 = 100 \times 0{,}0835 \times 0{,}3075 = 2{,}6$ punti percentuali: coincide con la risposta (a).

(d) La differenza in (a) è positiva: $\tilde{\beta}_1 > \hat{\beta}_1$. Con $\hat{\beta}_3 > 0$ e $\hat{\delta}_1 > 0$ l'omissione dell'abilità gonfia il rendimento dell'istruzione.

Errore tipico. Concludere per la distorsione solo perché la stima cambia di molto, senza controllare che la variabile omessa sia rilevante e correlata con l'incluso. Oppure presentare il Modello 2 come privo di distorsione: potrebbero mancare altre variabili.

Risposta. **(a)** La stima del rendimento dell'istruzione scende di 2,6 punti percentuali passando dal Modello 1 al Modello 2. **(b)** Sì: il Modello 1 omette `abil`, che è significativa e correlata con `istr`. **(c)** $100\,\hat{\beta}_3\,\hat{\delta}_1 = 2{,}6$, uguale alla differenza in (a). **(d)** Sì: il segno è positivo, omettere l'abilità gonfia il rendimento dell'istruzione.

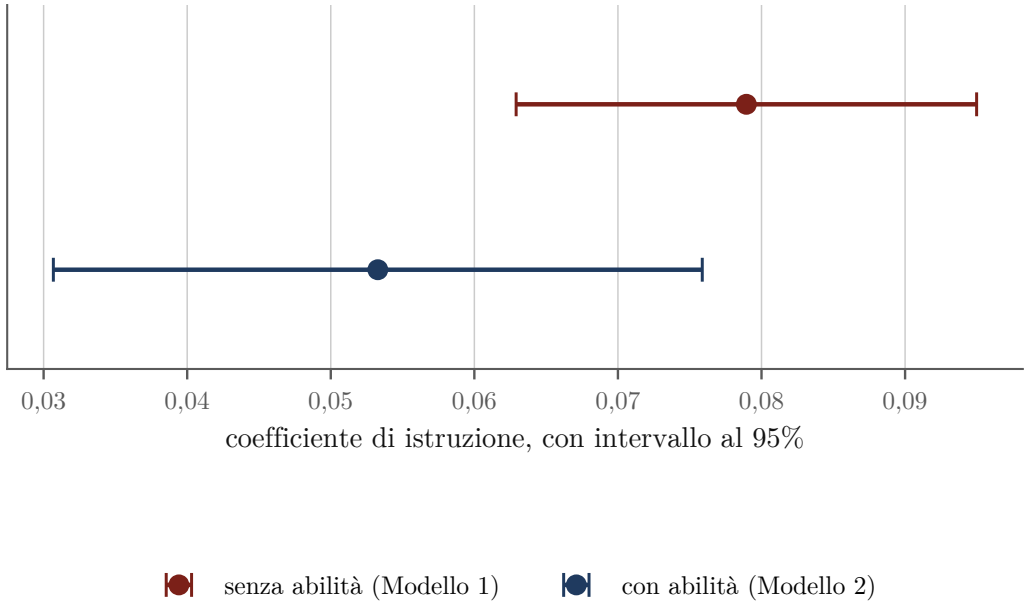


Figura 13.1: Coefficiente dell'istruzione, con intervallo al 95%: senza abilità (Modello 1) e con abilità (Modello 2).