Università Ca' Foscari Venezia

Dipartimento di Economia

Laurea Magistrale in
Economia e Finanza

Modulo 04 — Test F e restrizioni multiple

Soluzioni svolte e commentate

Appunti di:
Silvio Angelo Baratto Roldan

Codice insegnamento:
EM0004

Contenuto:
12 esercizi

Esercizi sintetici costruiti a fini di studio sul modello dei veri appelli e sulla teoria del corso (Econometria EM0004, prof. Davide Raggi). Non sono materiale ufficiale del docente.

Indice

1 **Esercizio 1 — Ruolo e salario dei giocatori** ***(livello base)*** **1**

2 **Esercizio 2 — Balcone e box: un test F da calcolare** ***(livello base)*** **3**

3 **Esercizio 3 — Rendimenti di scala** ***(livello base)*** **6**

4 **Esercizio 4 — Titolo di studio: il sistema d'ipotesi del test F** ***(livello intermedio)*** **8**

5 **Esercizio 5 — Il rendimento dell'istruzione dipende dal genere** ***(livello intermedio)*** **11**

6 **Esercizio 6 — Due lavoratori a confronto** ***(livello intermedio)*** **13**

7 **Esercizio 7 — Tre test t non bastano: la significatività congiunta** ***(livello intermedio)*** **16**

8 **Esercizio 8 — Istruzione ed esperienza: l'interazione fra due regressori** ***(livello appello)*** **19**

9 **Esercizio 9 — Promozione e pubblicità: due negozi a confronto** ***(livello appello)*** **22**

10 **Esercizio 10 — Zone senza costante: livelli, vincoli e riferimento** ***(livello appello)*** **25**

11 **Esercizio 11 — Cambiare la categoria di riferimento** ***(livello appello)*** **28**

12 **Esercizio 12 — Due restrizioni insieme: riscrivere il modello** ***(livello appello)*** **31**

1 | Esercizio 1 — Ruolo e salario dei giocatori *(livello base)*

Dati. Su $n = 300$ giocatori di pallacanestro si è stimato il modello

$$\log(\text{salario}) = \beta_0 + \beta_1\,\text{guardia} + \beta_2\,\text{ala} + \beta_3\,\text{punti} + \beta_4\,\text{esper} + \epsilon,$$

dove `salario` è il compenso annuale, `guardia` e `ala` sono due variabili dummy che valgono 1 per i giocatori di quel ruolo e 0 per gli altri, `punti` sono i punti segnati per partita ed `esper` gli anni da professionista. Ogni giocatore è una guardia, un'ala o un centro. Le variazioni percentuali si calcolano con l'approssimazione $\Delta\%\, y \approx 100\,\Delta \log(y)$. Le stime OLS sono le seguenti.

	coefficiente	errore std.	rapporto t	p-value
const	6,09363	0,0966172	63,07	2,82e-173
guardia	−0,29763	0,080149	−3,713	0,0002
ala	−0,123292	0,0813477	−1,516	0,1307
punti	0,0548424	0,00686574	7,988	3,11e-14
esper	0,0373191	0,00675861	5,522	7,37e-08

n = 300; $R^2 = 0{,}274233$; SSR = 85,2711

Testo della domanda. **Domanda 1** ***(3 punti).*** **(a)** Di quanto varia in percentuale, in media, il salario passando da un centro a una guardia con gli stessi punti e la stessa esperienza? **(b)** E passando da una guardia a un centro? **(c)** Al livello del 5%, si decida se rifiutare o non rifiutare $H_0 : \beta_2 = 0$ contro $H_1 : \beta_2 \neq 0$. **(d)** Al livello del 5%, si decida se rifiutare o non rifiutare $H_0 : \beta_1 = 0$ contro $H_1 : \beta_1 \neq 0$. **(e)** Si spieghi perché nella tabella non compare la dummy del centro e che cosa misurano β_1 e β_2.

Richiamo. Con la dipendente in logaritmo, una dummy che passa da 0 a 1 fa variare $\log(y)$ di β, cioè y di circa $100\,\beta$ per cento. Le tre dummy di ruolo sommano a 1, come la costante: tenerle tutte e tre nel modello insieme alla costante darebbe collinearità perfetta (trappola delle dummy), perciò una va esclusa. La categoria esclusa è il riferimento e ogni coefficiente di dummy è la differenza attesa rispetto ad essa, a parità del resto; invertendo il confronto il segno cambia. Per decidere su $H_0 : \beta = 0$ si guarda l'intervallo di confidenza al 95%, $\hat\beta \pm 1{,}96\,\widehat{\text{se}}(\hat\beta)$.

Svolgimento. **Impostazione.** `guardia` e `ala` sono confrontate con il centro, la categoria omessa.

(a) Passando dal centro alla guardia, `guardia` va da 0 a 1 e `ala` resta 0: $\Delta\%$ salario $\approx 100\,\hat{\beta}_1 = 100 \times (-0{,}2976) = -29{,}8\%$.

(b) Il confronto è invertito: $-100\,\hat{\beta}_1 = -100 \times (-0{,}2976) = 29{,}8\%$.

(c) Si verifica $H_0 : \beta_2 = 0$ contro $H_1 : \beta_2 \neq 0$. L'intervallo di confidenza al 95% è $[-0{,}2827;\ 0{,}0361]$ e contiene lo zero. Lo stesso dice $t = -1{,}52$, in valore assoluto minore di 1,96: non si rifiuta H_0.

(d) Si verifica $H_0 : \beta_1 = 0$ contro $H_1 : \beta_1 \neq 0$. L'intervallo di confidenza al 95% è $[-0{,}4547;\ -0{,}1405]$ e lo zero ne è fuori. Lo stesso dice $t = -3{,}71$, in valore assoluto maggiore di 1,96: si rifiuta H_0.

(e) I ruoli sono tre e le tre dummy sommano a 1, come la costante: per evitare la collinearità perfetta una è stata esclusa, e quella esclusa, il centro, è la categoria di riferimento. β_1 è la differenza attesa di log(salario) fra una guardia e un centro e β_2 fra un'ala e un centro, a parità di punti ed esperienza.

Errore tipico. Leggere $\hat{\beta}_1$ come differenza fra guardia e ala, o fra guardia e le altre due categorie: ogni coefficiente confronta il ruolo con il centro e nient'altro. Un altro errore è rispondere $-29{,}8\%$ anche alla (b): invertire il confronto cambia il segno. Infine non si deve pensare che la dummy del centro sia stata dimenticata: è esclusa proprio per evitare la collinearità con la costante.

Risposta. **(a)** Da un centro a una guardia il salario varia di circa $-29{,}8\%$. **(b)** Da una guardia a un centro varia di circa 29,8%. **(c)** Lo zero cade nell'intervallo di confidenza dell'ala: non si rifiuta $H_0 : \beta_2 = 0$, un'ala non guadagna in modo significativamente diverso da un centro. **(d)** Lo zero non cade nell'intervallo della guardia: si rifiuta $H_0 : \beta_1 = 0$, una guardia guadagna significativamente meno. **(e)** Il centro è la categoria di riferimento, esclusa per la trappola delle dummy; β_1 e β_2 sono le differenze di log(salario) rispetto al centro.

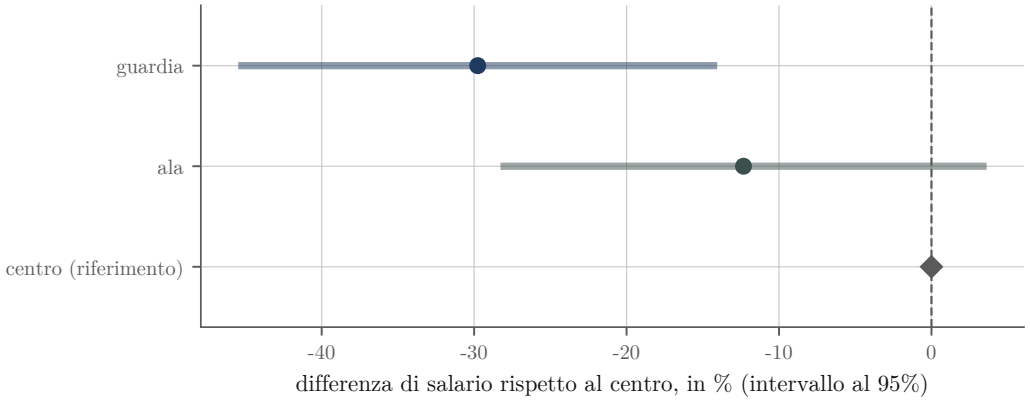


Figura 1.1: Differenza di salario rispetto al centro, in percentuale, con intervallo di confidenza al 95%: quello dell'ala contiene lo zero, quello della guardia no.

2 | Esercizio 2 — Balcone e box: un test F da calcolare *(livello base)*

Dati. Su $n = 200$ appartamenti in vendita si è stimato il modello completo

$$\log(\text{prezzo}) = \beta_0 + \beta_1 \log(\text{mq}) + \beta_2\,\text{eta} + \beta_3\,\text{ascensore} + \beta_4\,\text{balcone} + \beta_5\,\text{box} + \epsilon,$$

dove `mq` è la superficie in metri quadrati (nella tabella `l_mq` è il suo logaritmo), `eta` gli anni dell'edificio e `ascensore`, `balcone` e `box` sono dummy che valgono 1 se l'appartamento ha quella caratteristica.

	coefficiente	errore std.	rapporto t	p-value
const	2,91956	0,249999	11,68	3,3e-24
l_mq	0,851872	0,0560688	15,19	7,37e-35
eta	−0,00430074	0,00103333	−4,162	4,74e-05
ascensore	0,0818848	0,0354102	2,312	0,0218
balcone	0,0428955	0,0353959	1,212	0,2270
box	−0,0296525	0,0359381	−0,8251	0,4103

n = 200; $R^2 = 0{,}579313$; SSR = 11,5928

Si vuole verificare se `balcone` e `box`, congiuntamente, influenzano il prezzo: $H_0 : \beta_4 = \beta_5 = 0$ contro H_1: almeno uno dei due è diverso da zero. Il modello ristretto, che impone H_0, esclude le due variabili.

	coefficiente	errore std.	rapporto t	p-value
const	2,91969	0,249929	11,68	2,85e-24
l_mq	0,856195	0,0555557	15,41	1,26e-35
eta	−0,00437839	0,00103228	−4,241	3,42e-05
ascensore	0,0727274	0,0348605	2,086	0,0383

n = 200; $R^2 = 0{,}574665$; SSR = 11,7209

Il valore critico al 5% della distribuzione F con i gradi di libertà di questo test è 3,04.

Testo della domanda. **Domanda 2** ***(3 punti).*** Sia k il numero di regressori del modello completo, costante esclusa. **(a)** Quante restrizioni s impone H_0? **(b)** Quanti sono i gradi di

libertà $n-k-1$ del denominatore? **(c)** Quanto vale $F = \dfrac{(\mathrm{SSR}_r - \mathrm{SSR}_c)/s}{\mathrm{SSR}_c/(n-k-1)}$, con SSR_r e SSR_c le somme dei quadrati dei residui del modello ristretto e del completo? **(d)** Quanto vale la stessa statistica calcolata con gli R^2, $F = \dfrac{(R^2_c - R^2_r)/s}{(1-R^2_c)/(n-k-1)}$? **(e)** Al livello del 5%, confrontando F con il valore critico, si decida se rifiutare o non rifiutare H_0.

Richiamo. Il test F confronta il modello completo con il modello ristretto, che impone H_0. Con s restrizioni e $n-k-1$ gradi di libertà del modello completo,

$$F = \frac{(\mathrm{SSR}_r - \mathrm{SSR}_c)/s}{\mathrm{SSR}_c/(n-k-1)} = \frac{(R^2_c - R^2_r)/s}{(1-R^2_c)/(n-k-1)},$$

dove la seconda forma vale perché i due modelli hanno la stessa variabile dipendente. F è sempre positiva ($\mathrm{SSR}_r \geq \mathrm{SSR}_c$) e si rifiuta H_0 solo se F supera il valore critico: il test è unilaterale destro.

Svolgimento. **Impostazione.** Le due variabili escluse dal modello ristretto danno le restrizioni; poi si usano le due somme dei quadrati dei residui, o i due R^2, stampati sotto le tabelle.

(a) $H_0 : \beta_4 = 0$ e $\beta_5 = 0$ sono due restrizioni: $s = 2$ (quanti regressori in meno ha il modello ristretto).

(b) Il modello completo ha $k = 5$ regressori: $n - k - 1 = 200 - 5 - 1 = 194$.

(c) $F = \dfrac{(11{,}7209 - 11{,}5928)/2}{11{,}5928/194} = \dfrac{0{,}128/2}{11{,}5928/194} = 1{,}07.$

(d) $F = \dfrac{(0{,}579313 - 0{,}574665)/2}{(1-0{,}579313)/194} = 1{,}07$: lo stesso valore della (c).

(e) $F = 1{,}07$ è minore del valore critico 3,04: non si rifiuta H_0.

Errore tipico. Scrivere $\mathrm{SSR}_c - \mathrm{SSR}_r$ al numeratore: sarebbe negativo, ma F non può esserlo. Un altro errore è dimenticare di dividere per s il numeratore, o usare $n-k$ gradi di libertà invece di $n-k-1$ (la costante è un parametro). E F non è la somma dei due t^2 di β_4 e β_5: con stimatori incorrelati coincide con la loro media, in generale dipende anche dalla covarianza fra gli stimatori.

Risposta. **(a)** $s = 2$. **(b)** $n-k-1 = 194$. **(c)** $F = 1{,}07$ con le somme dei quadrati dei residui. **(d)** $F = 1{,}07$ con gli R^2, lo stesso valore. **(e)** F è minore del valore critico 3,04, quindi non si rifiuta H_0: al 5% `balcone` e `box` non sono congiuntamente significative e i dati non danno evidenza contro il modello ristretto.

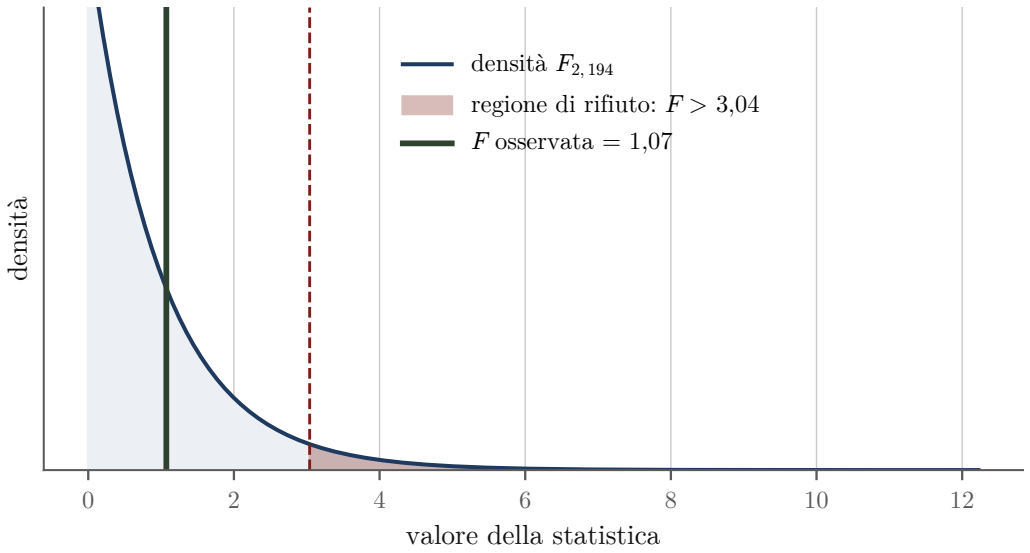


Figura 2.1: Densità $F(2,\,194)$ con la regione di rifiuto al 5%: la statistica osservata 1,07 cade a sinistra del valore critico 3,04, quindi non si rifiuta H_0.

3 | Esercizio 3 — Rendimenti di scala *(livello base)*

Dati. Su $n = 120$ imprese manifatturiere si è stimata la funzione di produzione

$$\log(Q) = \beta_0 + \beta_1 \log(K) + \beta_2 \log(L) + \beta_3 \,\text{esporta} + \epsilon,$$

dove Q è il valore della produzione, K lo stock di capitale, L le ore lavorate (nella tabella `l_cap` e `l_lav` sono i logaritmi di K e di L) ed `esporta` vale 1 se l'impresa esporta. I rendimenti di scala sono costanti quando $\beta_1 + \beta_2 = 1$: se capitale e lavoro crescono entrambi dell'1%, la produzione cresce dell'1%. Le stime OLS sono le seguenti; la covarianza stimata fra $\hat\beta_1$ e $\hat\beta_2$ vale $-0{,}00335448$.

	coefficiente	errore std.	rapporto t	p-value
const	0,644205	0,168575	3,821	0,0002
l_cap	0,343006	0,0601384	5,704	9,11e-08
l_lav	0,521568	0,0696584	7,488	1,49e-11
esporta	0,133522	0,0643593	2,075	0,0402

n = 120; $R^2 = 0{,}793156$; SSR = 13,8698

Testo della domanda. **Domanda 3** ***(3 punti).*** Si verifichi, al livello del 5%, $H_0 : \beta_1 + \beta_2 = 1$ (rendimenti di scala costanti) contro $H_1 : \beta_1 + \beta_2 \neq 1$. **(a)** Quanto vale la stima di $\beta_1 + \beta_2$? **(b)** Quanto vale l'errore standard di $\hat\beta_1 + \hat\beta_2$? **(c)** Quanto vale il rapporto $t = (\hat\beta_1 + \hat\beta_2 - 1)/\widehat{\text{se}}(\hat\beta_1 + \hat\beta_2)$? **(d)** Si decida se rifiutare o non rifiutare H_0. **(e)** Con una sola restrizione ($s = 1$) la statistica F è il quadrato di t: quanto vale F?

Richiamo. Una combinazione lineare di coefficienti ha varianza $\text{Var}(\hat\beta_1 + \hat\beta_2) = \text{Var}(\hat\beta_1) + \text{Var}(\hat\beta_2) + 2\,\text{Cov}(\hat\beta_1, \hat\beta_2)$: la tabella dà solo le varianze, la covarianza va presa dal testo. Il rapporto $t = (\hat\beta_1 + \hat\beta_2 - q)/\widehat{\text{se}}(\hat\beta_1 + \hat\beta_2)$ si confronta con 1,96; per una sola restrizione la statistica F è t^2.

Svolgimento. **Impostazione.** L'ipotesi è una sola restrizione lineare, $\beta_1 + \beta_2 = 1$: si stima la somma, se ne calcola l'errore standard con la covarianza e si fa un test t.

(a) $\hat\beta_1 + \hat\beta_2 = 0{,}3430 + 0{,}5216 = 0{,}865$.

(b) $\widehat{\text{se}} = \sqrt{0{,}06014^2 + 0{,}06966^2 + 2 \times (-0{,}00335448)} = 0{,}0420$.

(c) $t = \dfrac{0{,}865 - 1}{0{,}0420} = -3{,}23$.

(d) $t = -3{,}23$ è in valore assoluto maggiore di 1,96: si rifiuta H_0. Lo stesso dice l'intervallo di confidenza al 95% per $\beta_1 + \beta_2$, [0,782; 0,947], che non contiene 1.

(e) $F = t^2 = (-3{,}23)^2 = 10{,}42$.

Errore tipico. Calcolare l'errore standard senza la covarianza, $\sqrt{0{,}06014^2 + 0{,}06966^2} = 0{,}0920$ invece di 0,0420: si otterrebbe $t = -1{,}47$ e non si rifiuterebbe H_0. Capitale e lavoro si muovono insieme, i loro coefficienti sono correlati negativamente e la covarianza (negativa) riduce la varianza della somma. Un altro errore è sommare direttamente i due errori standard.

Risposta. **(a)** $\hat{\beta}_1 + \hat{\beta}_2 = 0{,}865$. **(b)** L'errore standard della somma, con la covarianza, è 0,0420. **(c)** $t = -3{,}23$. **(d)** Si rifiuta H_0: i rendimenti di scala non sono costanti e, essendo la somma minore di 1, sono decrescenti. **(e)** $F = 10{,}42$.

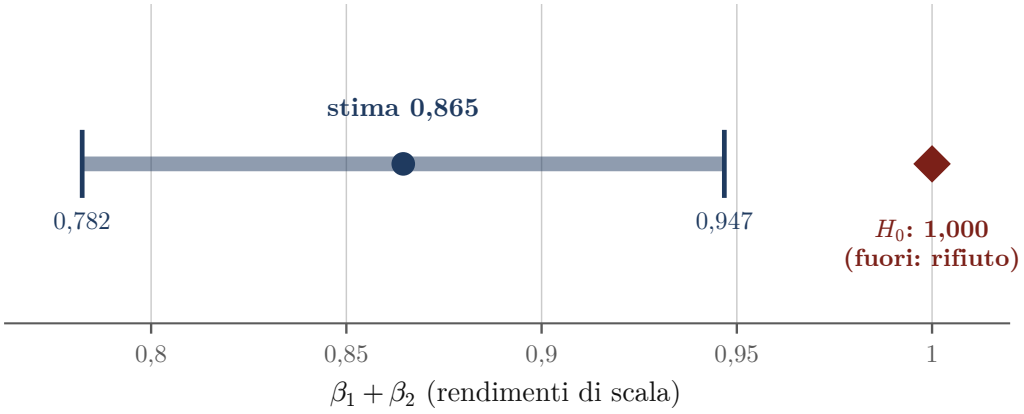


Figura 3.1: Intervallo di confidenza al 95% per $\beta_1 + \beta_2$, [0,782; 0,947]: il valore 1 dei rendimenti di scala costanti è fuori dall'intervallo.

4 | Esercizio 4 — Titolo di studio: il sistema d'ipotesi del test F *(livello intermedio)*

Dati. Su $n = 350$ lavoratori si è stimato il modello completo

$$\log(\text{salario}) = \alpha + \delta_1\,\text{obbligo} + \delta_2\,\text{diploma} + \beta_1\,\text{esper} + \beta_2\,\text{anz} + \epsilon,$$

dove `obbligo` vale 1 per i lavoratori con la sola scuola dell'obbligo e 0 per gli altri, `diploma` vale 1 per i diplomati e 0 per gli altri, ed `esper` e `anz` sono gli anni di esperienza e di anzianità in azienda. Ogni lavoratore ha la sola scuola dell'obbligo, un diploma o una laurea.

	coefficiente	errore std.	rapporto t	p-value
const	6,85753	0,0609355	112,5	5,03e-274
obbligo	−0,290483	0,0656515	−4,425	1,3e-05
diploma	−0,0930604	0,0583351	−1,595	0,1116
esper	0,0154819	0,00285264	5,427	1,08e-07
anz	0,00739439	0,00595876	1,241	0,2155

n = 350; $R^2 = 0{,}15085$

Per verificare se il titolo di studio ha rilevanza nel modello si è stimato anche il modello ristretto, senza le due dummy; i due modelli hanno la stessa variabile dipendente.

	coefficiente	errore std.	rapporto t	p-value
const	6,74212	0,0513522	131,3	7,12e-298
esper	0,0152551	0,00291722	5,229	2,95e-07
anz	0,00736994	0,00611059	1,206	0,2286

n = 350; $R^2 = 0{,}100221$

Il valore critico al 5% della distribuzione F con i gradi di libertà di questo test è 3,02.

Testo della domanda. **Domanda 4** ***(3 punti).*** **(a)** Qual è la categoria di riferimento? Che cosa misurano δ_1 e δ_2, e perché la dummy dei laureati non compare nel modello? **(b)** Si

scriva il sistema d'ipotesi del test F con cui si verifica se il titolo di studio ha rilevanza nel modello. **(c)** Quante restrizioni s impone H_0? **(d)** Quanti sono i gradi di libertà $n-k-1$ del denominatore, con k il numero di regressori del modello completo, costante esclusa? **(e)** Quanto vale $F = \dfrac{(R_c^2 - R_r^2)/s}{(1-R_c^2)/(n-k-1)}$? **(f)** Al livello del 5%, confrontando F con il valore critico, si decida se rifiutare o non rifiutare H_0. **(g)** Se come categoria di riferimento si scegliesse il diploma anziché la laurea, la statistica F cambierebbe? Si risponda sì o no.

Richiamo. Una variabile qualitativa con tre categorie si codifica con tre dummy mutuamente esclusive che sommano a 1. Con la costante nel modello se ne tengono due: la terza è la categoria di riferimento e ogni coefficiente di dummy è la differenza attesa rispetto ad essa, a parità del resto (tenerle tutte e tre con la costante dà collinearità perfetta). Il titolo di studio conta se almeno una di queste differenze non è nulla: $H_0 : \delta_1 = \delta_2 = 0$ contro H_1: almeno un $\delta_j \neq 0$, cioè s restrizioni. Il modello ristretto esclude le dummy e

$$F = \frac{(R_c^2 - R_r^2)/s}{(1-R_c^2)/(n-k-1)},$$

da confrontare con il valore critico: si rifiuta se F lo supera. Cambiare la categoria di riferimento non cambia l'adattamento del modello.

Svolgimento. Impostazione. La (a) e la (b) traducono la domanda in un sistema d'ipotesi; poi si contano le restrizioni e si calcola F dagli R^2 dei due modelli.

(a) Le dummy esplicite sono `obbligo` e `diploma`: la categoria di riferimento è la laurea, che ha entrambe le dummy a 0. δ_1 è la differenza attesa di log(salario) fra un lavoratore con la sola scuola dell'obbligo e un laureato ($-0{,}2905$) e δ_2 quella fra un diplomato e un laureato ($-0{,}0931$). La dummy dei laureati non compare perché le tre dummy sommano a 1, come la costante: tenerle tutte darebbe collinearità perfetta.

(b) $H_0 : \delta_1 = \delta_2 = 0$ contro $H_1 : \delta_1 \neq 0$ oppure $\delta_2 \neq 0$. Se H_0 è vera il titolo di studio non ha rilevanza e il modello si riduce a quello ristretto.

(c) Due uguaglianze: $s = 2$.

(d) Il modello completo ha $k = 4$ regressori: $n - k - 1 = 350 - 4 - 1 = 345$.

(e) $F = \dfrac{(0{,}150850 - 0{,}100221)/2}{(1-0{,}150850)/345} = \dfrac{0{,}0506/2}{(1-0{,}150850)/345} = 10{,}28.$

(f) $F = 10{,}28$ è maggiore del valore critico 3,02: si rifiuta H_0.

(g) No. Con il diploma come riferimento le dummy cambierebbero (`obbligo` e `laurea`) ma il modello avrebbe gli stessi valori stimati, lo stesso R^2 e lo stesso modello ristretto: la stessa F.

Errore tipico. Decidere dai due rapporti t delle dummy: quello di `obbligo` è $-4{,}42$ e quello di `diploma` è $-1{,}59$, ma ciascuno confronta una categoria con la laurea e non dice nulla sull'ipotesi congiunta; ripetere i test t non controlla il livello del 5%. Un altro errore è scrivere $H_0 : \delta_1 = \delta_2$, che confronta obbligo e diploma fra loro (una restrizione), e non $H_0 : \delta_1 = \delta_2 = 0$ (due).

Risposta. **(a)** La categoria di riferimento è la laurea; δ_1 e δ_2 sono le differenze rispetto ai laureati e la dummy dei laureati è omessa per evitare la collinearità perfetta con la costante. **(b)** $H_0 : \delta_1 = \delta_2 = 0$ contro $H_1 : \delta_1 \neq 0$ oppure $\delta_2 \neq 0$. **(c)** $s = 2$. **(d)** $n - k - 1 = 345$. **(e)** $F = 10{,}28$. **(f)** F supera il valore critico 3,02: si rifiuta H_0 e il titolo di studio ha rilevanza nel modello. **(g)** No: la scelta della categoria di riferimento non cambia F.

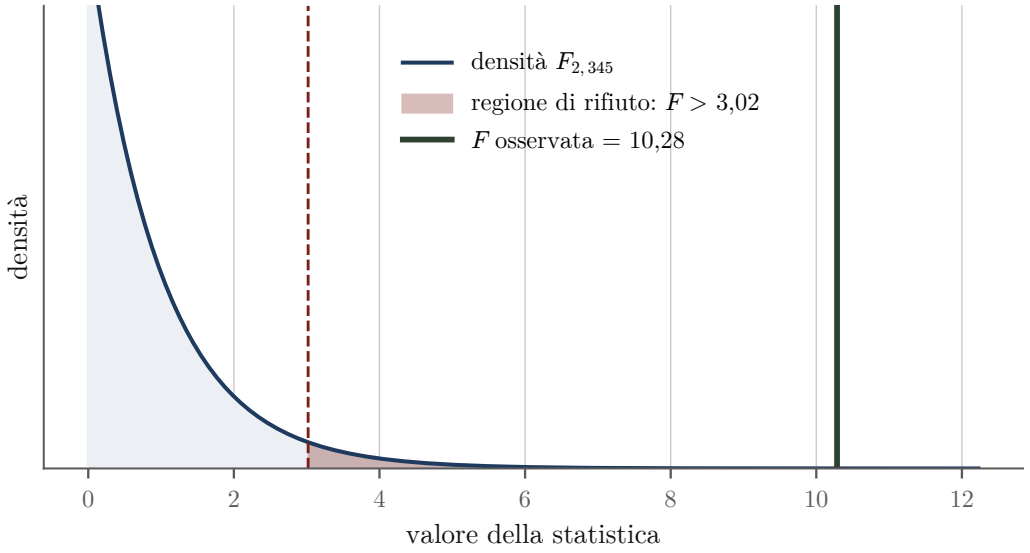


Figura 4.1: Densità $F(2,\,345)$ con la regione di rifiuto al 5%: la statistica osservata 10,28 cade nella regione di rifiuto, a destra del valore critico 3,02.

5 | Esercizio 5 — Il rendimento dell'istruzione dipende dal genere *(livello intermedio)*

Dati. Su $n = 500$ lavoratori si è stimato il modello

$$\log(\text{salario}) = \beta_0 + \beta_1\,\text{istr} + \beta_2\,\text{donna} + \beta_3\,\text{esper} + \beta_4\,(\text{donna} \times \text{istr}) + \epsilon,$$

dove `istr` ed `esper` sono gli anni di istruzione e di esperienza, `donna` vale 1 per le donne e 0 per gli uomini e `d_istr` è il prodotto `donna`×`istr`. Le variazioni percentuali si calcolano con l'approssimazione $\Delta\%\, y \approx 100\,\Delta \log(y)$. Le stime OLS sono le seguenti.

	coefficiente	errore std.	rapporto t	p-value
const	1,12438	0,104017	10,81	1,35e-24
istr	0,0827601	0,00688759	12,02	2,31e-29
donna	0,0359817	0,136639	0,2633	0,7924
esper	0,00993973	0,00204652	4,857	1,6e-06
d_istr	−0,0228041	0,00943	−2,418	0,0160

n = 500; $R^2 = 0{,}38907$; SSR = 79,29

Testo della domanda. **Domanda 5** ***(3 punti).*** **(a)** Di quanto varia in percentuale, in media, il salario di un uomo per un anno di istruzione in più, a parità di esperienza? **(b)** E quello di una donna? **(c)** Al livello del 5%, si decida se rifiutare o non rifiutare $H_0 : \beta_4 = 0$ contro $H_1 : \beta_4 \neq 0$ (cioè se il rendimento dell'istruzione dipende dal genere). **(d)** Di quanto differisce in percentuale il salario atteso di una donna da quello di un uomo (donna meno uomo) con la stessa esperienza e 16 anni di istruzione? **(e)** Il coefficiente β_2 misura il divario di salario fra donne e uomini a qualunque livello di istruzione? Si risponda sì o no.

Richiamo. Con il termine $\beta_4(\text{donna} \times \text{istr})$ la variazione attesa per un anno di istruzione in più è $\Delta \log(y) = (\beta_1 + \beta_4\,\text{donna})\,\Delta\text{istr}$: β_1 per gli uomini, $\beta_1 + \beta_4$ per le donne, in percentuale $100\times$ questi valori. L'effetto dipende dal genere solo se $\beta_4 \neq 0$, che si verifica con $H_0 : \beta_4 = 0$. Il divario donna meno uomo a parità di esperienza e con istr $= e$ è la differenza dei due log-salari attesi, $\beta_2 + \beta_4\, e$: dipende dal livello e e coincide con β_2 solo per $e = 0$.

Svolgimento. **Impostazione.** La (a) e la (b) sono le due pendenze, la (c) è il test sull'interazione, la (d) la differenza fra le due rette in un punto.

(a) Per un uomo `donna`$= 0$ e l'effetto è $100\,\hat{\beta}_1 = 100 \times 0{,}0828 = 8{,}3\%$.

(b) Per una donna `donna`$= 1$: $100\,(\hat{\beta}_1 + \hat{\beta}_4) = 100 \times (0{,}0828 + (-0{,}0228)) = 6{,}0\%$.

(c) $H_0 : \beta_4 = 0$ contro $H_1 : \beta_4 \neq 0$. L'intervallo di confidenza al 95% è $[-0{,}0413;\ -0{,}0043]$ e lo zero ne è fuori. Lo stesso dice $t = -2{,}42$, in valore assoluto maggiore di 1,96: si rifiuta H_0.

(d) $100\,(\hat{\beta}_2 + e_0\,\hat{\beta}_4) = 100 \times (0{,}0360 + 16 \times (-0{,}0228)) = -32{,}9\%$.

(e) No. $\hat{\beta}_2 = 0{,}0360$ è il divario per istr $= 0$, un livello che non si osserva fra i lavoratori; il divario cambia con l'istruzione e a 16 anni vale $-32{,}9\%$, di segno opposto.

Errore tipico. Leggere $\hat{\beta}_1$ come rendimento dell'istruzione per tutti: vale per gli uomini, e per le donne va sommato $\hat{\beta}_4$. Un altro errore è interpretare la dummy `donna` da sola: qui $\hat{\beta}_2$ è positivo, ma il divario a 16 anni di istruzione è negativo perché l'interazione $\hat{\beta}_4$ lo trascina verso il basso.

Risposta. **(a)** Per un uomo un anno di istruzione in più aumenta il salario di circa 8,3%. **(b)** Per una donna di circa 6,0%. **(c)** Si rifiuta $H_0 : \beta_4 = 0$: il rendimento dell'istruzione dipende dal genere. **(d)** A 16 anni di istruzione il salario atteso di una donna differisce di circa $-32{,}9\%$ da quello di un uomo con la stessa esperienza. **(e)** No: β_2 è il divario solo per un'istruzione nulla; per gli altri livelli serve $\beta_2 + \beta_4$ istr.

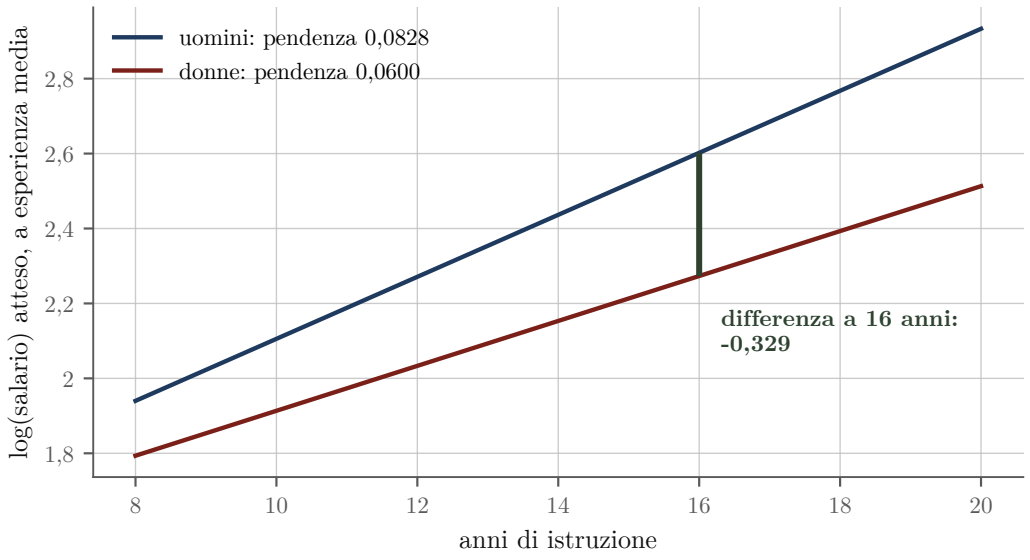


Figura 5.1: Log-salario atteso in funzione dell'istruzione, a esperienza media: la retta delle donne ha pendenza minore e il divario (segmento verde) a 16 anni vale $-32{,}9\%$.

6 | Esercizio 6 — Due lavoratori a confronto *(livello intermedio)*

Dati. Su $n = 400$ lavoratori, ciascuno appartenente a uno e uno solo di quattro gruppi (single o sposati, laureati o non laureati), si è stimato il modello

$$\log(\text{salario}) = \alpha + \delta_1\,\text{sp_nl} + \delta_2\,\text{si_l} + \delta_3\,\text{sp_l} + \beta\,\text{esper} + \epsilon,$$

dove `sp_nl`, `si_l` e `sp_l` valgono 1 rispettivamente per gli sposati non laureati, i single laureati e gli sposati laureati, e 0 altrimenti, ed `esper` sono gli anni di esperienza. Le variazioni percentuali si calcolano con l'approssimazione $\Delta\%\, y \approx 100\,\Delta \log(y)$. Le stime OLS sono le seguenti; la covarianza stimata fra $\hat{\delta}_3$ e $\hat{\beta}$ vale $-0{,}000130251$.

	coefficiente	errore std.	rapporto t	p-value
const	6,78526	0,0524333	129,4	0,0000
sp_nl	0,0928467	0,0641967	1,446	0,1489
si_l	0,312564	0,0738971	4,23	2,91e-05
sp_l	0,315134	0,0726212	4,339	1,82e-05
esper	0,017223	0,00383928	4,486	9,53e-06

n = 400; $R^2 = 0{,}160423$; SSR = 72,5859

Testo della domanda. **Domanda 6** ***(3 punti).*** Si considerino due lavoratori: A è sposato e laureato con 12 anni di esperienza, B è single e non laureato con 5 anni di esperienza. **(a)** Qual è la categoria di riferimento del modello? Si scriva la differenza attesa di log(salario) fra A e B (A meno B) in funzione dei coefficienti. **(b)** Di quanto differisce in percentuale, in media, il salario di A da quello di B? **(c)** Quanto vale l'errore standard di tale differenza, in punti percentuali? **(d)** Qual è l'estremo inferiore dell'intervallo di confidenza al 95% per la differenza, in percentuale? **(e)** E l'estremo superiore? **(f)** Al livello del 5%, si decida se rifiutare o non rifiutare l'ipotesi che i due lavoratori abbiano lo stesso salario atteso, contro l'alternativa bilaterale.

Richiamo. Con la costante e tre dummy per quattro gruppi, il gruppo con tutte le dummy a 0 è il riferimento e ogni δ_j è la differenza attesa rispetto ad esso, a parità di esperienza. La differenza fra due lavoratori è la differenza delle loro medie condizionate, una combinazione lineare dei coefficienti: per A (sposato laureato, esperienza e_A) e B (riferimento, esperienza e_B)

vale $\delta_3 + (e_A - e_B)\,\beta$. Per la varianza, con $d = e_A - e_B$,

$$\operatorname{Var}(\hat{\delta}_3 + d\,\hat{\beta}) = \operatorname{Var}(\hat{\delta}_3) + d^2 \operatorname{Var}(\hat{\beta}) + 2\,d \operatorname{Cov}(\hat{\delta}_3, \hat{\beta}),$$

e l'intervallo di confidenza al 95% è la stima $\pm\, 1{,}96\,\widehat{\text{se}}$.

Svolgimento. **Impostazione.** Si scrive la differenza A meno B come combinazione lineare dei coefficienti, poi si stima, si calcola l'errore standard con la covarianza e si costruisce l'intervallo.

(a) Il riferimento è il gruppo dei single non laureati (le tre dummy valgono 0). Per A: $E[\log(\text{salario})] = \alpha + \delta_3 + \beta\, e_A$; per B: $\alpha + \beta\, e_B$. La differenza è $\delta_3 + (e_A - e_B)\,\beta$, con $e_A - e_B = 12 - 5 = 7$.

(b) $\hat{\delta}_3 + d\,\hat{\beta} = 0{,}3151 + 7 \times 0{,}0172 = 0{,}4357$, cioè 43,6%.

(c) $\widehat{\text{Var}} = 0{,}07262^2 + 7^2 \times 0{,}003839^2 + 2 \times 7 \times (-0{,}000130251) = 0{,}004173$, quindi $100\sqrt{0{,}004173} = 6{,}46$ punti percentuali.

(d) e **(e)** $43{,}6 \pm 1{,}96 \times 6{,}46 = [30{,}9;\ 56{,}2]$.

(f) Si verifica $H_0 : \delta_3 + d\,\beta = 0$ contro l'alternativa bilaterale. Lo zero non cade nell'intervallo di confidenza; lo stesso dice $t = 43{,}6/6{,}46 = 6{,}74$, in valore assoluto maggiore di 1,96: si rifiuta H_0.

Errore tipico. Leggere $\hat{\delta}_3$ da solo come differenza fra A e B: vale solo per due lavoratori con la stessa esperienza, e qui A ha 7 anni in più, che pesano $d\,\hat{\beta}$. Un altro errore è omettere la covarianza: l'errore standard sarebbe 7,74 invece di 6,46. Fra una dummy di gruppo e l'esperienza la covarianza è diversa da zero perché gli sposati hanno in media più esperienza.

Risposta. **(a)** Il riferimento è il gruppo dei single non laureati; la differenza A meno B è $\delta_3 + (e_A - e_B)\,\beta$. **(b)** A guadagna in media circa 43,6% più di B. **(c)** L'errore standard è 6,46 punti percentuali. **(d)** L'estremo inferiore dell'intervallo al 95% è 30,9%. **(e)** L'estremo superiore è 56,2%. **(f)** Lo zero è fuori dall'intervallo: si rifiuta l'ipotesi di uguale salario atteso.

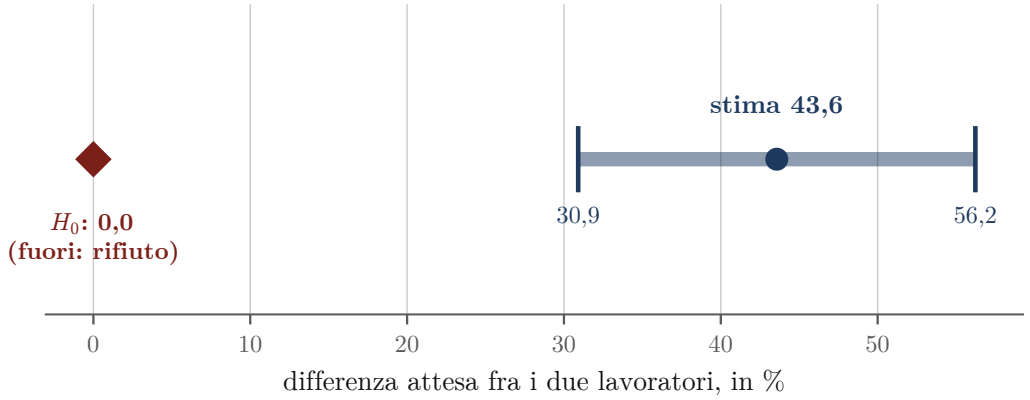


Figura 6.1: Intervallo di confidenza al 95% per la differenza attesa fra A e B, in percentuale: [30,9; 56,2], lo zero è fuori.

7 | Esercizio 7 — Tre test t non bastano: la significatività congiunta *(livello intermedio)*

Dati. Su $n = 100$ neolaureati si è stimato il modello

$$\log(\text{salario}) = \beta_0 + \beta_1\,\text{p_mat} + \beta_2\,\text{p_logica} + \beta_3\,\text{p_lingua} + \epsilon,$$

dove `p_mat`, `p_logica` e `p_lingua` sono i punteggi ottenuti in tre test di ingresso (matematica, logica, lingua), che misurano in buona parte la stessa abilità e sono quindi molto correlati fra loro. Le stime OLS sono le seguenti.

	coefficiente	errore std.	rapporto t	p-value
const	7,54754	0,175103	43,1	1,28e-64
p_mat	0,00606939	0,00908063	0,6684	0,5055
p_logica	0,0114567	0,00795494	1,44	0,1531
p_lingua	0,0117242	0,00890138	1,317	0,1909

n = 100; $R^2 = 0{,}431344$

Per il test di significatività congiunta il modello ristretto contiene la sola costante, quindi $R^2_r = 0$. Il valore critico al 5% della distribuzione F con i gradi di libertà di questo test è 2,70.

Testo della domanda. **Domanda 7** ***(3 punti).*** **(a)** Quanti dei tre coefficienti sono significativamente diversi da zero al livello del 5%, con un test t bilaterale per ciascuno? **(b)** Si verifichi ora congiuntamente $H_0 : \beta_1 = \beta_2 = \beta_3 = 0$ contro H_1: almeno un β_j è diverso da zero. Quante restrizioni s impone H_0? **(c)** Quanti sono i gradi di libertà $n - k - 1$ del denominatore, con k il numero di regressori, costante esclusa? **(d)** Quanto vale $F = \dfrac{(R^2_c - R^2_r)/s}{(1 - R^2_c)/(n - k - 1)}$? **(e)** Al livello del 5%, confrontando F con il valore critico, si decida se rifiutare o non rifiutare H_0. **(f)** Se i tre test t fossero indipendenti, ciascuno al livello del 5%, quale sarebbe la probabilità di rifiutare almeno una delle tre ipotesi $\beta_j = 0$ quando sono tutte vere? Si risponda con quattro decimali.

Richiamo. Il test di significatività congiunta confronta il modello completo con quello che ha la sola costante, per cui $R_r^2 = 0$ e $s = k$:

$$F = \frac{R^2/k}{(1-R^2)/(n-k-1)},$$

da confrontare con il valore critico. Ripetere i test t non è una soluzione valida: se i test fossero indipendenti la probabilità di rifiutare almeno una volta quando H_0 è vera sarebbe $1-(1-0{,}05)^k$, molto più del 5%. Inoltre con regressori molto correlati gli errori standard sono grandi e i singoli t piccoli anche quando insieme i regressori spiegano molto.

Svolgimento. **Impostazione.** Si contano i coefficienti con $|t| > 1{,}96$, poi si calcola F dall'R^2 stampato sotto la tabella, con modello ristretto la sola costante.

(a) I rapporti t sono 0,67, 1,44 e 1,32, tutti in valore assoluto minori di 1,96: i coefficienti significativi sono 0.

(b) Tre uguaglianze, $\beta_1 = 0$, $\beta_2 = 0$, $\beta_3 = 0$: $s = 3$.

(c) $n - k - 1 = 100 - 3 - 1 = 96$.

(d) $F = \dfrac{0{,}431344/3}{(1-0{,}431344)/96} = 24{,}27$.

(e) $F = 24{,}27$ è maggiore del valore critico 2,70: si rifiuta H_0.

(f) $1 - (1-0{,}05)^3 = 0{,}1426$.

Errore tipico. Concludere dai tre t non significativi che nessun punteggio conta. I tre test misurano in buona parte la stessa abilità, sono molto correlati e le stime individuali sono imprecise, ma insieme spiegano una parte importante del salario: il test F rifiuta H_0. Per lo stesso motivo non si può decidere sul test congiunto guardando i singoli t: il valore 0,1426 è il livello del procedimento «tre test separati» solo se i test fossero indipendenti; con regressori correlati le t non lo sono e il livello vero sta fra 0,05 e quel valore. Questo esercizio mostra soprattutto una perdita di potenza dei test singoli: nessuna t è significativa, ma F rifiuta.

Risposta. **(a)** Nessuno dei tre coefficienti è significativo al 5%: 0. **(b)** $s = 3$. **(c)** $n - k - 1 = 96$. **(d)** $F = 24{,}27$. **(e)** F supera il valore critico 2,70: si rifiuta H_0, i tre punteggi sono congiuntamente significativi. **(f)** La probabilità è 0,1426, quasi il triplo del 5%.

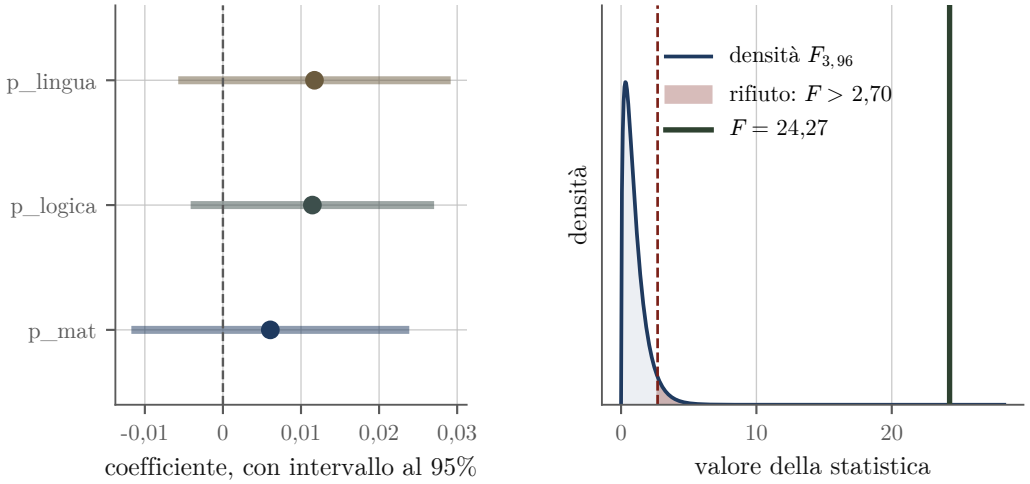


Figura 7.1: A sinistra gli intervalli di confidenza al 95% dei tre coefficienti: tutti contengono lo zero. A destra la densità $F(3, 96)$: la statistica 24,27 supera di molto il valore critico 2,70.

8 | Esercizio 8 — Istruzione ed esperienza: l'interazione fra due regressori *(livello appello)*

Dati. Su $n = 300$ lavoratori si è stimato il modello

$$\log(\text{salario}) = \beta_0 + \beta_1\,\text{istr} + \beta_2\,\text{esper} + \beta_3\,(\text{istr} \times \text{esper}) + \beta_4\,\text{donna} + \epsilon,$$

dove `istr` ed `esper` sono gli anni di istruzione e di esperienza, `istr_esp` è il prodotto `istr`×`esper` e `donna` vale 1 per le donne e 0 per gli uomini. Le variazioni percentuali si calcolano con l'approssimazione $\Delta\%\, y \approx 100\,\Delta \log(y)$. Le stime OLS sono le seguenti; la covarianza stimata fra $\hat\beta_1$ e $\hat\beta_3$ vale $-0{,}000015145$.

	coefficiente	errore std.	rapporto t	p-value
const	1,1305	0,277128	4,079	5,82e-05
istr	−0,015439	0,0186948	−0,8258	0,4096
esper	0,00436572	0,0138159	0,316	0,7522
istr_esp	0,0028057	0,000941782	2,979	0,0031
donna	−0,0772971	0,0741644	−1,042	0,2982

n = 300; $R^2 = 0{,}378311$; SSR = 118,008

Testo della domanda. **Domanda 8** ***(4 punti).*** **(a)** Si scriva l'effetto marginale dell'istruzione, cioè la variazione attesa di log(salario) per un anno di istruzione in più, e si dica da che cosa dipende. **(b)** Al livello del 5%, si decida se rifiutare o non rifiutare $H_0 : \beta_3 = 0$ contro $H_1 : \beta_3 \neq 0$ (cioè se l'effetto dell'istruzione dipende dall'esperienza). **(c)** Al livello del 5%, si decida se rifiutare o non rifiutare $H_0 : \beta_1 = 0$ contro $H_1 : \beta_1 \neq 0$, e si dica a quale lavoratore si riferisce β_1. **(d)** Di quanto varia in percentuale il salario atteso per un anno di istruzione in più, per un lavoratore con 20 anni di esperienza? **(e)** Quanto vale l'errore standard di tale effetto, in punti percentuali? **(f)** Al livello del 5%, si decida se rifiutare o non rifiutare $H_0 : \beta_1 + 20\,\beta_3 = 0$ contro l'alternativa bilaterale.

Richiamo. Con il termine $\beta_3(\text{istr} \times \text{esper})$ la variazione attesa per un anno di istruzione in più è $\Delta \log(y) = (\beta_1 + \beta_3\,\text{esper})\,\Delta\text{istr}$: l'effetto dipende dall'esperienza se e solo se $\beta_3 \neq 0$. β_1 è

l'effetto per esper $= 0$, cioè per un lavoratore senza esperienza. Per esper $= x_0$ l'effetto è la combinazione lineare $\beta_1 + x_0\,\beta_3$, in percentuale $100\,(\beta_1 + x_0\,\beta_3)$, con

$$\operatorname{Var}(\hat\beta_1 + x_0\hat\beta_3) = \operatorname{Var}(\hat\beta_1) + x_0^2\operatorname{Var}(\hat\beta_3) + 2\,x_0\operatorname{Cov}(\hat\beta_1, \hat\beta_3).$$

Si decide con il rapporto t della combinazione, da confrontare con 1,96.

Svolgimento. **Impostazione.** La (a) dà l'effetto marginale; la (b) e la (c) sono i test sui due coefficienti; dalla (d) alla (f) si valuta l'effetto in x_0 e si verifica che non sia nullo.

(a) $\Delta\log(\text{salario}) \approx (\beta_1 + \beta_3\,\text{esper})\,\Delta\text{istr}$ con $\Delta\text{istr} = 1$: dipende dall'esperienza, attraverso β_3.

(b) $H_0 : \beta_3 = 0$ contro $H_1 : \beta_3 \neq 0$: $t = 2{,}98$, in valore assoluto maggiore di 1,96, si rifiuta H_0 e l'effetto dell'istruzione dipende dall'esperienza.

(c) $H_0 : \beta_1 = 0$ contro $H_1 : \beta_1 \neq 0$: $t = -0{,}83$, in valore assoluto minore di 1,96, non si rifiuta H_0. β_1 si riferisce a un lavoratore con esper $= 0$.

(d) $100\,(\hat\beta_1 + x_0\,\hat\beta_3) = 100 \times (-0{,}01544 + 20 \times 0{,}002806) = 4{,}07\%$.

(e) $100\sqrt{0{,}01869^2 + 20^2 \times 0{,}000942^2 + 2 \times 20 \times (-0{,}000015145)} = 0{,}99$ punti percentuali.

(f) L'intervallo di confidenza al 95% per l'effetto è $4{,}07 \pm 1{,}96 \times 0{,}99 = [2{,}12;\ 6{,}01]$ e lo zero ne è fuori. Lo stesso dice $t = 4{,}07/0{,}99 = 4{,}10$, in valore assoluto maggiore di 1,96: si rifiuta H_0.

Errore tipico. Concludere dalla (c) che l'istruzione non conta: $\hat\beta_1$ non significativo dice solo che l'effetto per un lavoratore senza esperienza non si distingue da zero; con 20 anni di esperienza l'effetto è 4,07% ed è significativo. Un altro errore è dimenticare la covarianza: l'errore standard sarebbe 2,65 invece di 0,99, il rapporto t scenderebbe a 1,53 e non si rifiuterebbe H_0. $\hat\beta_1$ e $\hat\beta_3$ sono fortemente correlati negativamente, perché `istr` e il prodotto si muovono insieme.

Risposta. **(a)** L'effetto marginale dell'istruzione è $\beta_1 + \beta_3\,\text{esper}$, quindi dipende dall'esperienza. **(b)** Si rifiuta $H_0 : \beta_3 = 0$. **(c)** Non si rifiuta $H_0 : \beta_1 = 0$: β_1 è l'effetto per esper $= 0$. **(d)** Con 20 anni di esperienza un anno di istruzione in più fa aumentare il salario di circa 4,07%. **(e)** L'errore standard è 0,99 punti percentuali. **(f)** Si rifiuta $H_0 : \beta_1 + 20\,\beta_3 = 0$: l'effetto è significativo.

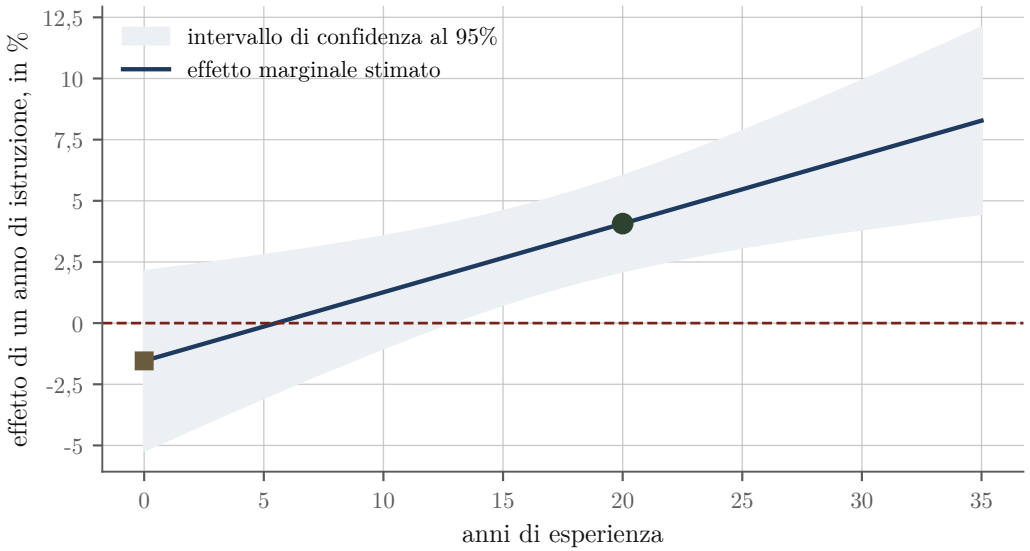


Figura 8.1: Effetto marginale dell'istruzione in funzione dell'esperienza, con la banda al 95% calcolata con la covarianza: il punto ambra è $\widehat{\beta}_1$ (esperienza nulla, banda che comprende lo zero), il punto verde è l'effetto a 20 anni, 4,07%, significativamente diverso da zero.

9 | Esercizio 9 — Promozione e pubblicità: due negozi a confronto *(livello appello)*

Dati. Su $n = 450$ negozi si è stimato il modello

$$\log(\text{vendite}) = \beta_0 + \beta_1\,\text{promo} + \beta_2\,\text{pub} + \beta_3\,(\text{pub} \times \text{promo}) + \epsilon,$$

dove `vendite` sono le vendite mensili, `promo` vale 1 se nel negozio è in corso una promozione e 0 altrimenti, `pub` è la spesa in pubblicità in migliaia di euro e `pub_promo` è il prodotto `pub`×`promo`. Le variazioni percentuali si calcolano con l'approssimazione $\Delta\%\, y \approx 100\,\Delta \log(y)$. Le stime OLS sono le seguenti. Le covarianze stimate fra gli stimatori valgono $\widehat{\text{Cov}}(\hat\beta_2, \hat\beta_3) = -0{,}000047380$, $\widehat{\text{Cov}}(\hat\beta_1, \hat\beta_2) = 0{,}000207865$ e $\widehat{\text{Cov}}(\hat\beta_1, \hat\beta_3) = -0{,}000406500$.

	coefficiente	errore std.	rapporto t	p-value
const	8,02555	0,0349098	229,9	0,0000
promo	0,170235	0,049392	3,447	0,0006
pub	0,0471245	0,00688334	6,846	2,52e-11
pub_promo	−0,0282839	0,00947027	−2,987	0,0030

n = 450; $R^2 = 0{,}118223$; SSR = 29,8249

Testo della domanda. **Domanda 9** ***(4 punti).*** **(a)** Di quanto variano in percentuale, in media, le vendite di un negozio con promozione per mille euro in più di pubblicità? **(b)** Un consulente sostiene che, in un negozio con promozione, ogni mille euro in più di pubblicità fa crescere le vendite del 2%, cioè $\beta_2 + \beta_3 = 0{,}02$. Al livello del 5%, si decida se rifiutare o non rifiutare $H_0 : \beta_2 + \beta_3 = 0{,}02$ contro l'alternativa bilaterale. Si considerino ora il negozio A, con promozione e 5 mila euro di pubblicità, e il negozio B, senza promozione e con 3 mila euro di pubblicità. **(c)** Di quanto differiscono in percentuale, in media, le vendite di A da quelle di B (A meno B)? **(d)** Quanto vale l'errore standard di tale differenza, in punti percentuali? **(e)** Al livello del 5%, si decida se rifiutare o non rifiutare l'ipotesi che i due negozi abbiano le stesse vendite attese, contro l'alternativa bilaterale.

Richiamo. Con $\beta_3(\text{pub} \times \text{promo})$ l'effetto di mille euro in più di pubblicità è $\Delta \log(y) = (\beta_2 + \beta_3\,\text{promo})\,\Delta\text{pub}$: β_2 senza promozione, $\beta_2 + \beta_3$ con la promozione, in percentuale 100× questi

valori. La differenza fra due profili è la differenza delle medie condizionate: A (promo = 1, pub = p_A) e B (promo = 0, pub = p_B) differiscono di $\beta_1 + (p_A - p_B)\,\beta_2 + p_A\,\beta_3$. Per una combinazione $w_1\hat\beta_1 + w_2\hat\beta_2 + w_3\hat\beta_3$,

$$\text{Var} = \sum_i w_i^2 \,\text{Var}(\hat\beta_i) + 2\sum_{i<j} w_i w_j \,\text{Cov}(\hat\beta_i, \hat\beta_j).$$

Si decide con il rapporto $t = (\text{stima} - q)/\widehat{\text{se}}$ confrontato con 1,96.

Svolgimento. **Impostazione.** La (a) e la (b) riguardano la combinazione $\beta_2 + \beta_3$ (due termini, una covarianza); dalla (c) alla (e) il confronto fra A e B è una combinazione di tre termini (tre covarianze).

(a) $100\,(\hat\beta_2 + \hat\beta_3) = 100 \times (0{,}0471 + (-0{,}0283)) = 1{,}88\%$.

(b) $\widehat{\text{se}}(\hat\beta_2 + \hat\beta_3) = \sqrt{0{,}006883^2 + 0{,}009470^2 + 2 \times (-0{,}000047380)} = 0{,}0065$. L'intervallo di confidenza al 95% per $\beta_2 + \beta_3$ è [0,0061; 0,0316] e contiene 0,02. Lo stesso dice $t = \dfrac{0{,}0188 - 0{,}02}{0{,}0065} = -0{,}18$, in valore assoluto minore di 1,96: non si rifiuta H_0.

(c) Con $p_A - p_B = 2$ la differenza è $\beta_1 + 2\,\beta_2 + 5\,\beta_3$, stimata da $100 \times (0{,}1702 + 2 \times 0{,}0471 + 5 \times (-0{,}0283)) = 12{,}3\%$.

(d) $\widehat{\text{Var}} = 0{,}049392^2 + 2^2 \times 0{,}006883^2 + 5^2 \times 0{,}009470^2 + 2 \times 2 \times (0{,}000207865) + 2 \times 5 \times (-0{,}000406500) + 2 \times 2 \times 5 \times (-0{,}000047380) = 0{,}000690$, quindi $100\sqrt{0{,}000690} = 2{,}63$ punti percentuali.

(e) L'intervallo di confidenza al 95% è $12{,}3 \pm 1{,}96 \times 2{,}63 = [7{,}2;\ 17{,}5]$ e lo zero ne è fuori; $t = 4{,}68$, in valore assoluto maggiore di 1,96: si rifiuta H_0.

Errore tipico. Scambiare β_2 con l'effetto con la promozione: $\hat\beta_2$ vale solo per i negozi senza promozione, per gli altri serve $\hat\beta_2 + \hat\beta_3$. Un altro errore è confrontare A e B con il solo $\hat\beta_1$, trascurando che hanno anche una spesa pubblicitaria diversa, o dimenticare uno dei tre termini di covarianza. Il peso di β_3 è p_A e non $p_A - p_B$: il prodotto pub × promo vale p_A per A e 0 per B.

Risposta. **(a)** Con la promozione mille euro in più di pubblicità fanno crescere le vendite di circa 1,88%. **(b)** $t = -0{,}18$: non si rifiuta $H_0 : \beta_2 + \beta_3 = 0{,}02$, l'affermazione è compatibile con i dati. **(c)** Le vendite di A superano quelle di B di circa 12,3%. **(d)** L'errore standard della differenza è 2,63 punti percentuali. **(e)** Lo zero è fuori dall'intervallo di confidenza: si rifiuta l'ipotesi che A e B abbiano le stesse vendite attese.

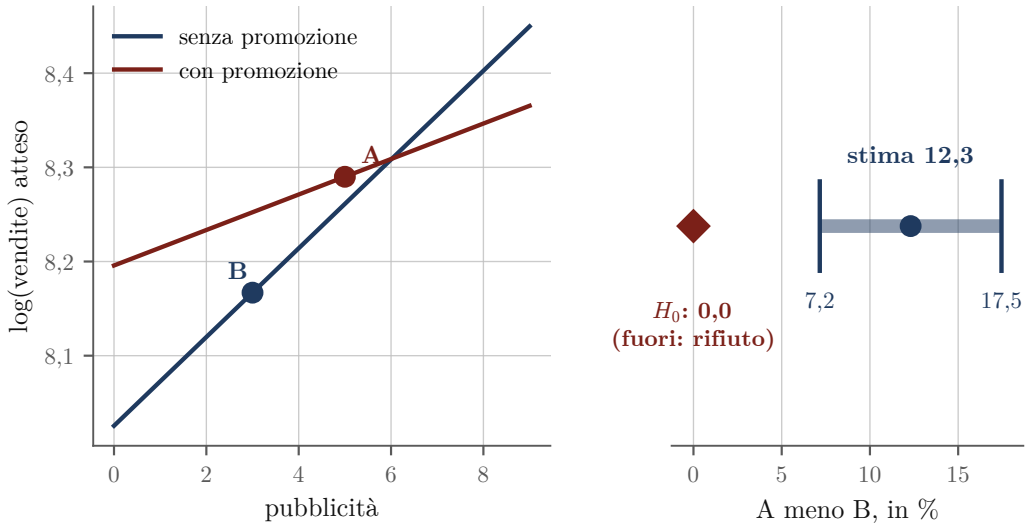


Figura 9.1: A sinistra il log-vendite atteso in funzione della pubblicità, con e senza promozione; i punti sono i negozi A e B. A destra l'intervallo di confidenza al 95% per la loro differenza, in percentuale: lo zero è fuori.

10 | Esercizio 10 — Zone senza costante: livelli, vincoli e riferimento *(livello appello)*

Dati. Su $n = 400$ abitazioni si è stimato il modello, senza costante,

$$\log(\text{prezzo}) = \delta_1\,\text{zona1} + \delta_2\,\text{zona2} + \delta_3\,\text{zona3} + \delta_4\,\text{zona4} + \beta_1\,\text{crime} + \beta_2\,\text{rooms} + \epsilon,$$

dove `zona1`, …, `zona4` sono dummy che valgono 1 se l'abitazione si trova in quella zona e 0 altrimenti (ogni abitazione appartiene a una e una sola zona, quindi zona1 + zona2 + zona3 + zona4 = 1), `crime` è il tasso di criminalità e `rooms` il numero medio di stanze. Le variazioni percentuali si calcolano con l'approssimazione $\Delta\%\, y \approx 100\,\Delta \log(y)$.

	coefficiente	errore std.	rapporto t	p-value
zona1	8,5743	0,143815	59,62	2,76e-199
zona2	8,35511	0,145073	57,59	5,67e-194
zona3	8,83762	0,145989	60,54	1,22e-201
zona4	8,71381	0,147521	59,07	7,45e-198
crime	−0,0109936	0,00525171	−2,093	0,0370
rooms	0,0883754	0,022577	3,914	0,0001

n = 400; SSR = 37,8681

Per verificare se la zona ha rilevanza nel livello dei prezzi si è stimato anche il modello ristretto, con una sola costante comune a tutte le zone. Nessuno dei due modelli stampa l'R^2, ma entrambi hanno la stessa variabile dipendente.

	coefficiente	errore std.	rapporto t	p-value
const	8,5603	0,16054	53,32	4,38e-183
crime	−0,0184057	0,00586068	−3,141	0,0018
rooms	0,101309	0,0253455	3,997	7,64e-05

n = 400; SSR = 48,4762

Il valore critico al 5% della distribuzione F con i gradi di libertà di questo test è 2,63.

Testo della domanda. **Domanda 10** ***(4 punti).*** **(a)** Si spieghi perché nel modello completo non è stata eliminata nessuna dummy e che cosa misura ciascun δ_j. **(b)** Si scriva il sistema d'ipotesi del test F con cui si verifica se la zona ha rilevanza nel livello dei prezzi. **(c)** Quante restrizioni s impone H_0? **(d)** Quanti sono i gradi di libertà del denominatore, cioè n meno il numero di parametri stimati nel modello completo? **(e)** Quanto vale $F = \dfrac{(\mathrm{SSR}_r - \mathrm{SSR}_c)/s}{\mathrm{SSR}_c/(n-p)}$, con p il numero di parametri del modello completo? **(f)** Al livello del 5%, confrontando F con il valore critico, si decida se rifiutare o non rifiutare H_0. Si stimi ora lo stesso modello con una costante e le dummy `zona1`, `zona2` e `zona3`, quindi con la zona 4 come categoria di riferimento. **(g)** Quanto vale la stima della costante? **(h)** Quanto vale la stima del coefficiente di `zona1`, in percentuale?

Richiamo. Senza costante e con G dummy che sommano a 1, ogni coefficiente δ_j è il livello (l'intercetta) della zona j, non una differenza: le dummy sommano a 1, prendono il posto della costante e nessuna va eliminata (con la costante ne andrebbe tolta una, trappola delle dummy). Il modello equivalente con la costante e $G-1$ dummy, con la zona 4 di riferimento, ha costante δ_4 e coefficienti $\delta_j - \delta_4$, stessa SSR e stessi valori stimati. La zona non ha rilevanza se i livelli sono uguali: $H_0 : \delta_1 = \delta_2 = \delta_3 = \delta_4$, cioè $G-1$ restrizioni indipendenti ($\delta_1 - \delta_4 = 0$, $\delta_2 - \delta_4 = 0$, $\delta_3 - \delta_4 = 0$). Il modello ristretto ha una costante comune e

$$F = \frac{(\mathrm{SSR}_r - \mathrm{SSR}_c)/s}{\mathrm{SSR}_c/(n-p)},$$

con p i parametri del modello completo. Qui si usano le SSR: l'R^2 di un modello senza costante non è calcolato rispetto alla media e non è confrontabile con quello del modello con la costante.

Svolgimento. **Impostazione.** Le tre domande iniziali traducono la richiesta in un sistema d'ipotesi; poi si calcola F dalle due SSR e si riscrive il modello con una zona di riferimento.

(a) Le quattro dummy sommano a 1, come farebbe la costante: sono già esaustive e il modello non ha costante, quindi non c'è collinearità perfetta e nessuna dummy va eliminata. δ_j è l'intercetta specifica della zona j; le differenze $\delta_j - \delta_k$ sono i divari a parità di `crime` e `rooms`. Le stime sono 8,574, 8,355, 8,838 e 8,714.

(b) $H_0 : \delta_1 = \delta_2 = \delta_3 = \delta_4$ contro H_1: almeno una delle uguaglianze non vale. Sotto H_0 resta una sola costante comune.

(c) Tre uguaglianze indipendenti: $s = 3$, pari alla differenza fra i parametri dei due modelli, $6 - 3$.

(d) $n - p = 400 - 6 = 394$.

(e) $F = \dfrac{(48{,}4762 - 37{,}8681)/3}{37{,}8681/394} = \dfrac{10{,}6/3}{37{,}8681/394} = 36{,}79.$

(f) $F = 36{,}79$ è maggiore del valore critico 2,63: si rifiuta H_0.

(g) Con la zona 4 di riferimento la costante è il livello della zona 4: $\hat{\delta}_4 = 8{,}714$.

(h) Il coefficiente di `zona1` è la differenza fra i livelli: $100\,(\hat{\delta}_1 - \hat{\delta}_4) = 100 \times (8{,}574 - 8{,}714) = -14{,}0\%$.

Errore tipico. Credere che manchi una dummy o che la costante sia stata dimenticata: qui la costante è assente per costruzione. Un altro errore è leggere δ_1 come differenza rispetto a una zona di riferimento, mentre è il livello della zona 1. Infine non si deve calcolare F con gli R^2 stampati da un software per il modello senza costante: non sono confrontabili con quelli del modello con la costante, e con le SSR il confronto è corretto in ogni caso.

Risposta. **(a)** Le quattro dummy sommano a 1 e sostituiscono la costante, che non c'è: nessuna va eliminata e ogni δ_j è il livello della zona j. **(b)** $H_0 : \delta_1 = \delta_2 = \delta_3 = \delta_4$ contro H_1: almeno una uguaglianza non vale. **(c)** $s = 3$. **(d)** 394 gradi di libertà. **(e)** $F = 36{,}79$. **(f)** F supera il valore critico 2,63: si rifiuta H_0, la zona ha rilevanza nel livello dei prezzi. **(g)** La costante vale 8,714. **(h)** Il coefficiente di `zona1` vale $-14{,}0\%$.

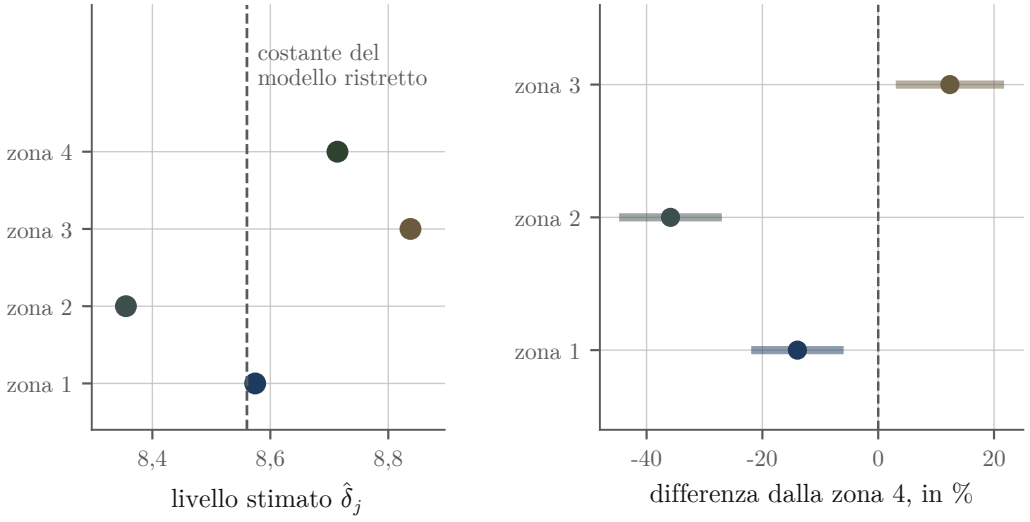


Figura 10.1: A sinistra i quattro livelli stimati $\hat{\delta}_j$ e la costante del modello ristretto (linea tratteggiata). A destra le differenze fra ciascuna zona e la zona 4, in percentuale, con intervallo al 95%: sono i coefficienti del modello con la costante e le tre dummy, e il test F le verifica insieme.

11 | Esercizio 11 — Cambiare la categoria di riferimento *(livello appello)*

Dati. Su $n = 360$ famiglie si è stimato il modello

$$\log(\text{reddito}) = \alpha + \delta_1\,\text{nord} + \delta_2\,\text{sud} + \beta_1\,\text{istr} + \beta_2\,\text{eta} + \epsilon,$$

dove `nord` e `sud` valgono 1 per le famiglie residenti in quell'area e 0 altrimenti (le famiglie del Centro sono la categoria di riferimento), `istr` sono gli anni di istruzione e `eta` l'età del capofamiglia. Le variazioni percentuali si calcolano con l'approssimazione $\Delta\%\, y \approx 100\,\Delta\log(y)$. Le stime OLS sono le seguenti; la covarianza stimata fra $\hat{\delta}_1$ e $\hat{\delta}_2$ vale 0,003859230.

	coefficiente	errore std.	rapporto t	p-value
const	8,96754	0,159099	56,36	3,48e-179
nord	0,0707607	0,0750601	0,9427	0,3465
sud	−0,0911807	0,0749376	−1,217	0,2245
istr	0,0426162	0,00748027	5,697	2,56e-08
eta	0,0110256	0,00231343	4,766	2,75e-06

n = 360; $R^2 = 0{,}152908$; SSR = 91,6871

Testo della domanda. **Domanda 11** ***(4 punti).*** **(a)** Al livello del 5%, si decida se rifiutare o non rifiutare $H_0 : \delta_1 = 0$ contro $H_1 : \delta_1 \neq 0$ (Nord contro Centro). **(b)** Lo stesso per $H_0 : \delta_2 = 0$ (Sud contro Centro). Si riscriva ora il modello scegliendo il Sud come categoria di riferimento, con le dummy `centro` e `nord`: $\log(\text{reddito}) = \alpha' + \delta_1'\,\text{centro} + \delta_2'\,\text{nord} + \beta_1\,\text{istr} + \beta_2\,\text{eta} + \epsilon$. **(c)** Quanto vale la stima di δ_1', in percentuale? **(d)** Quanto vale la stima di δ_2', in percentuale? **(e)** Quanto vale l'errore standard di $\hat{\delta}_2'$, in punti percentuali? **(f)** Al livello del 5%, nel nuovo modello si decida se rifiutare o non rifiutare $H_0 : \delta_2' = 0$ contro $H_1 : \delta_2' \neq 0$. **(g)** Il test F per H_0: «l'area non ha rilevanza» cambierebbe passando dal Centro al Sud come categoria di riferimento? Si risponda sì o no.

Richiamo. Con la costante e le dummy `nord` e `sud` (riferimento: centro) le medie condizionate sono $E[y \mid \text{centro}] = \alpha$, $E[y \mid \text{nord}] = \alpha + \delta_1$ ed $E[y \mid \text{sud}] = \alpha + \delta_2$ (a parità del resto). Con il sud come riferimento e le dummy `centro` e `nord` le stesse medie sono α', $\alpha' + \delta_1'$ e $\alpha' + \delta_2'$:

quindi $\alpha' = \alpha + \delta_2$, $\delta_1' = -\delta_2$ e $\delta_2' = \delta_1 - \delta_2$. Il modello non cambia, cambia solo la lettura dei coefficienti. L'errore standard di una differenza è $\sqrt{\mathrm{Var}(\hat{\delta}_1) + \mathrm{Var}(\hat{\delta}_2) - 2\,\mathrm{Cov}(\hat{\delta}_1, \hat{\delta}_2)}$, e il test F sull'irrilevanza dell'area, che confronta con un modello senza dummy, non dipende dal riferimento.

Svolgimento. **Impostazione.** Si leggono i due test della tabella, poi si ricostruiscono i coefficienti del modello con il Sud come riferimento come combinazioni lineari di quelli stampati.

(a) $H_0 : \delta_1 = 0$: $t = 0{,}94$, in valore assoluto minore di 1,96, non si rifiuta H_0.

(b) $H_0 : \delta_2 = 0$: $t = -1{,}22$, in valore assoluto minore di 1,96, non si rifiuta H_0.

(c) $\hat{\delta}_1' = -\hat{\delta}_2$: $100 \times (-(-0{,}0912)) = 9{,}1\%$.

(d) $\hat{\delta}_2' = \hat{\delta}_1 - \hat{\delta}_2$: $100 \times (0{,}0708 - (-0{,}0912)) = 16{,}2\%$.

(e) $\widehat{\mathrm{se}}(\hat{\delta}_2') = 100\sqrt{0{,}07506^2 + 0{,}07494^2 - 2 \times (0{,}003859230)} = 5{,}94$ punti percentuali.

(f) $t = 16{,}2/5{,}94 = 2{,}73$, in valore assoluto maggiore di 1,96; l'intervallo di confidenza al 95% è [4,5; 27,8] e lo zero ne è fuori: si rifiuta H_0.

(g) No: i valori stimati, la SSR e il modello ristretto senza dummy sono gli stessi, quindi F non cambia.

Errore tipico. Dedurre dal fatto che il Nord e il Sud non differiscono significativamente dal Centro che il Nord e il Sud non differiscono fra loro. Ogni test della tabella confronta un'area con il riferimento; il confronto fra Nord e Sud è un'altra combinazione lineare, $\delta_1 - \delta_2$, con un altro errore standard. Se si omette la covarianza l'errore standard diventa 10,61 invece di 5,94 e non si rifiuta: i due stimatori sono correlati positivamente perché condividono la stima del riferimento, e la covarianza riduce la varianza della differenza.

Risposta. **(a)** Non si rifiuta $H_0 : \delta_1 = 0$. **(b)** Non si rifiuta $H_0 : \delta_2 = 0$. **(c)** $\hat{\delta}_1' = 9{,}1\%$. **(d)** $\hat{\delta}_2' = 16{,}2\%$. **(e)** L'errore standard è 5,94 punti percentuali. **(f)** Nel nuovo modello si rifiuta $H_0 : \delta_2' = 0$: il Nord e il Sud differiscono significativamente, pur non differendo significativamente dal Centro. **(g)** No: cambiare la categoria di riferimento non cambia F.

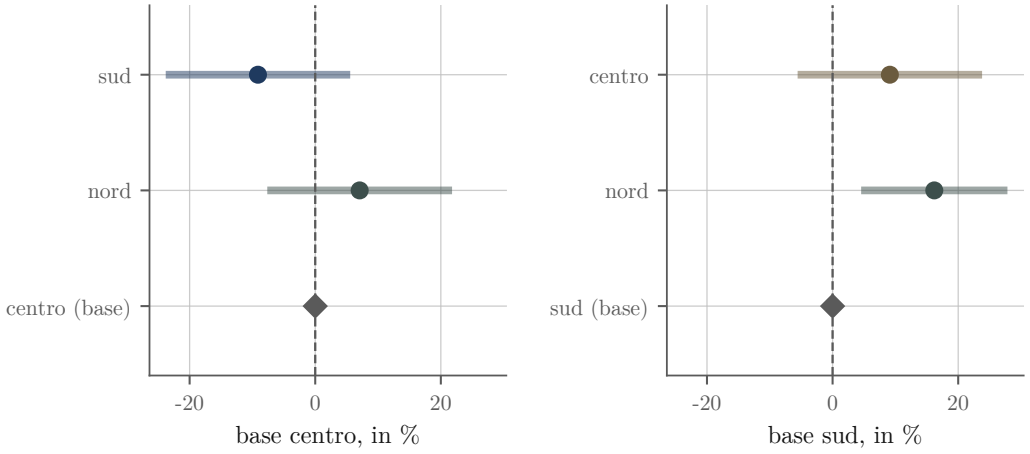


Figura 11.1: Coefficienti delle aree in percentuale, con intervallo al 95%. A sinistra con il Centro come riferimento: entrambi gli intervalli comprendono lo zero. A destra con il Sud come riferimento: l'intervallo del Nord ne è fuori.

12 | Esercizio 12 — Due restrizioni insieme: riscrivere il modello *(livello appello)*

Dati. Su $n = 500$ lavoratori si è stimato il modello completo

$$\log(\text{salario}) = \beta_0 + \beta_1\,\text{istr} + \beta_2\,\text{esper} + \beta_3\,\text{anz} + \beta_4\,\text{donna} + \epsilon,$$

dove `istr`, `esper` e `anz` sono gli anni di istruzione, di esperienza e di anzianità in azienda e `donna` vale 1 per le donne e 0 per gli uomini.

	coefficiente	errore std.	rapporto t	p-value
const	0,849382	0,0827271	10,27	1,5e-22
istr	0,0703407	0,00484084	14,53	4,25e-40
esper	0,0231831	0,00226726	10,23	2,15e-22
anz	0,0192605	0,00449727	4,283	2,22e-05
donna	−0,0983576	0,0366655	−2,683	0,0076

n = 500; $R^2 = 0{,}434467$; SSR = 82,5697

Si vuole verificare congiuntamente che un anno di istruzione e un anno di esperienza abbiano lo stesso effetto e che l'anzianità non abbia effetto: $H_0 : \beta_1 = \beta_2$ e $\beta_3 = 0$, contro H_1: almeno una delle due condizioni non vale. Sotto H_0 il modello diventa

$$\log(\text{salario}) = \beta_0 + \beta_1\,(\text{istr} + \text{esper}) + \beta_4\,\text{donna} + \epsilon,$$

che si è stimato con il regressore `istr_esper` = `istr` + `esper`.

	coefficiente	errore std.	rapporto t	p-value
const	1,36715	0,0665301	20,55	2,24e-68
istr_esper	0,0325153	0,00210517	15,45	3,06e-44
donna	−0,10922	0,0397725	−2,746	0,0062

n = 500; $R^2 = 0{,}331226$; SSR = 97,6434

Il valore critico al 5% della distribuzione F con i gradi di libertà di questo test è 3,01. La covarianza stimata fra $\hat\beta_1$ e $\hat\beta_2$ nel modello completo vale 0,000001117.

Testo della domanda. **Domanda 12** ***(4 punti).*** Sia k il numero di regressori del modello completo, costante esclusa. **(a)** Quante restrizioni s impone H_0? **(b)** Quanti sono i gradi di libertà $n-k-1$ del denominatore? **(c)** Quanto vale $F = \dfrac{(\mathrm{SSR}_r - \mathrm{SSR}_c)/s}{\mathrm{SSR}_c/(n-k-1)}$? **(d)** Al livello del 5%, confrontando F con il valore critico, si decida se rifiutare o non rifiutare H_0. **(e)** Si consideri ora la sola restrizione $H_0 : \beta_1 = \beta_2$ ($s = 1$), per cui $F = t^2$ con $t = \dfrac{\hat\beta_1 - \hat\beta_2}{\widehat{\mathrm{se}}(\hat\beta_1 - \hat\beta_2)}$: quanto vale F? **(f)** Al livello del 5%, con la stessa t, si decida se rifiutare o non rifiutare $H_0 : \beta_1 = \beta_2$ contro $H_1 : \beta_1 \neq \beta_2$. **(g)** Si spieghi come si ottiene il modello ristretto da quello completo.

Richiamo. Il modello ristretto si ottiene imponendo H_0 nel modello completo e riscrivendolo: con $\beta_2 = \beta_1$ e $\beta_3 = 0$ il termine $\beta_1\,\mathrm{istr} + \beta_2\,\mathrm{esper}$ diventa $\beta_1\,(\mathrm{istr} + \mathrm{esper})$ e `anz` sparisce. Con s restrizioni,

$$F = \frac{(\mathrm{SSR}_r - \mathrm{SSR}_c)/s}{\mathrm{SSR}_c/(n-k-1)},$$

da confrontare con il valore critico. Per una sola restrizione lineare $\beta_1 = \beta_2$ la statistica F è il quadrato di $t = (\hat\beta_1 - \hat\beta_2)/\widehat{\mathrm{se}}$, con

$$\widehat{\mathrm{se}} = \sqrt{\mathrm{Var}(\hat\beta_1) + \mathrm{Var}(\hat\beta_2) - 2\,\mathrm{Cov}(\hat\beta_1, \hat\beta_2)}.$$

Svolgimento. **Impostazione.** Due restrizioni si testano insieme con F dalle SSR dei due modelli; la prima, presa da sola, si può testare anche con una t.

(a) $\beta_1 = \beta_2$ e $\beta_3 = 0$: $s = 2$ (il modello completo ha $k = 4$ regressori, il ristretto due).

(b) $n - k - 1 = 500 - 4 - 1 = 495$.

(c) $F = \dfrac{(97{,}6434 - 82{,}5697)/2}{82{,}5697/495} = \dfrac{15{,}1/2}{82{,}5697/495} = 45{,}18$.

(d) $F = 45{,}18$ è maggiore del valore critico 3,01: si rifiuta H_0.

(e) $\hat\beta_1 - \hat\beta_2 = 0{,}0703 - 0{,}0232 = 0{,}0472$ e $\widehat{\mathrm{se}} = \sqrt{0{,}004841^2 + 0{,}002267^2 - 2 \times (0{,}000001117)} = 0{,}00513$, quindi $t = \dfrac{0{,}0472}{0{,}00513} = 9{,}19$ e $F = t^2 = 84{,}43$.

(f) $|t| = 9{,}19$ è maggiore di 1,96: si rifiuta $H_0 : \beta_1 = \beta_2$.

(g) Sotto H_0 si sostituisce $\beta_2 = \beta_1$ e si pone $\beta_3 = 0$: $\beta_1\,\mathrm{istr} + \beta_1\,\mathrm{esper} = \beta_1\,(\mathrm{istr} + \mathrm{esper})$. Il modello ristretto ha come regressori la somma `istr_esper` e `donna`.

Errore tipico. Imporre solo $\beta_3 = 0$, o solo $\beta_1 = \beta_2$, nel modello ristretto: il numero di restrizioni s e la SSR non sono più quelli di H_0. Un altro errore è togliere `istr` e `esper` dal modello ristretto invece di sostituirle con la loro somma: $\beta_1 = \beta_2$ non significa $\beta_1 = \beta_2 = 0$. Infine nella t non va dimenticata la covarianza: in generale l'errore standard della differenza dipende dal termine $-2\,\widehat{\mathrm{Cov}}$ (qui è piccolo, perché istruzione ed esperienza sono quasi incorrelate).

Risposta. **(a)** $s = 2$. **(b)** $n - k - 1 = 495$. **(c)** $F = 45{,}18$. **(d)** F supera il valore critico 3,01: si rifiuta H_0, istruzione ed esperienza non hanno lo stesso effetto oppure l'anzianità conta. **(e)** Per la sola restrizione $\beta_1 = \beta_2$, $F = t^2 = 84{,}43$. **(f)** Si rifiuta anche $H_0 : \beta_1 = \beta_2$: un anno di istruzione e uno di esperienza non valgono lo stesso. **(g)** Si sostituiscono $\beta_2 = \beta_1$ e $\beta_3 = 0$ e si usa la somma `istr`+`esper` come unico regressore.

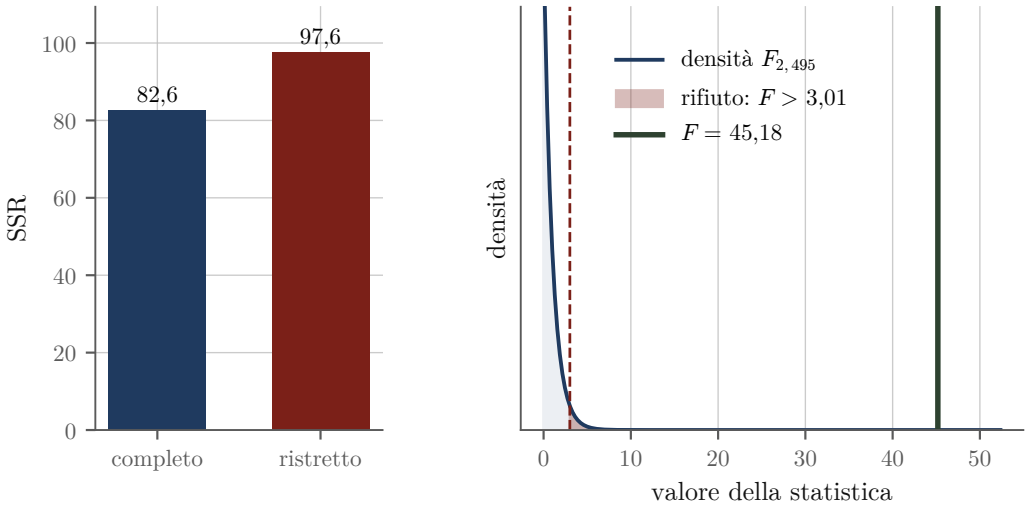


Figura 12.1: A sinistra le SSR del modello completo e del ristretto: imporre H_0 le fa crescere. A destra la densità $F(2, 495)$: la statistica 45,18 cade nella regione di rifiuto, oltre il valore critico 3,01.